손계산 워크북

PPML 손계산 워크북

FedAvg · 무작위 응답 · 라플라스 잡음 · DP-SGD · 비밀 분산

본편 강의 덱의 수식을 숫자로 따라가는 별도 자료

모든 문제는 계산기 없이 풀 수 있도록 숫자를 골랐다.
각 쪽은 문제 설정 → 계산 → 해석 순서로 읽는다.

여덟 문제로 본편의 핵심 수식을 확인한다

본편 II판 PART 1~4의 수식과 같은 기호를 쓴다

번호	주제	확인할 것
W0	재식별 확률	세 칸만으로 혼자가 될 확률
W1	FedAvg 가중 평균	데이터가 많은 기관이 결과를 끌어당기는 정도
W2·W3	무작위 응답	개인은 숨기고 집단 비율을 되찾는 방법과 그 ε
W4·W5	라플라스 잡음과 예산 분할	ε를 쪼갤수록 공개값이 얼마나 흔들리는지
W6	DP-SGD 기울기 자르기	한 사람의 영향 상한을 거는 방법
W7	비밀 분산 합계	조각만으로 총합을 정확히 맞추는 원리

같은 칸을 쓰는 사람이 평균 0.14명이면 87%가 혼자다

우편번호·생년월일·성별 조합 K = 365 × 80 × 2 = 58,400개, 생일은 고르게 퍼졌다고 가정

① 칸 하나의 평균 인원

λ = N / K
미국 우편번호 7,900 ÷ 58,400 ≈ 0.135

② 나 말고 아무도 없을 확률

포아송 근사로
Pr[0명] = e^(−λ)

③ 한국 읍면동

평균 약 1.48만 명
14,800 ÷ 58,400 ≈ 0.25

$$e^{-7{,}900/58{,}400} = e^{-0.135} \approx 0.87$$

$$e^{-14{,}800/58{,}400} = e^{-0.25} \approx 0.78$$

해석: 시군구(평균 약 23만 명)로 넓히면 λ ≈ 3.9, e^(−3.9) ≈ 2%로 떨어진다

가중 평균은 데이터가 많은 기관 쪽으로 기운다

세 은행이 신용평가 모델의 같은 가중치 성분 하나를 학습했다

기관	데이터 수 n_k	학습한 가중치 w_k
은행 A	1,000명	0.3
은행 B	800명	0.4
은행 C	1,200명	0.2

$$w_{\text{전역}} = \frac{1000(0.3) + 800(0.4) + 1200(0.2)}{3000} = \frac{860}{3000} \approx 0.287$$

해석: 단순 평균 0.30보다 낮다. 데이터가 가장 많은 은행 C(0.2)가 결과를 끌어내린다

응답 비율에서 실제 비율을 거꾸로 계산한다

1,000명에게 동전 규칙으로 물었더니 400명이 예라고 답했다

① 기대식 세우기

앞면(½)이면 사실대로, 뒷면이면 다시 던져 ½ 확률로 예
Pr[예] = ½π + ¼

② 관측값 넣기

p̂ = 400 / 1,000 = 0.40

③ 거꾸로 풀기

0.40 = ½π + 0.25
→ π = 0.30

$$\hat{\pi} = \frac{\hat{p} - 0.25}{0.5} = \frac{0.40 - 0.25}{0.5} = 0.30$$

실제로 해당 행동을 한 사람은 약 30%로 추정된다. 그러나 누가 그 30%인지는 아무도 모른다

동전 규칙의 프라이버시 손실은 ln 3이다

참 예와 참 아니오가 예라고 답할 확률의 비를 비교한다

실제 답	예라고 답할 확률	계산
참 예	0.75	½(사실대로) + ½ × ½(무작위)
참 아니오	0.25	½ × ½(무작위)만

$$\varepsilon = \ln \frac{\Pr[\text{예} \mid \text{참 예}]}{\Pr[\text{예} \mid \text{참 아니오}]} = \ln \frac{0.75}{0.25} = \ln 3 \approx 1.10$$

해석: 예라는 답을 들어도 그 사람이 참 예일 가능성은 참 아니오의 3배를 넘지 않는다

ε가 열 배 작아지면 흔들림도 열 배 커진다

개수 질의(민감도 Δf = 1)의 공개값이 90% 확률로 들어오는 범위

$$b = \frac{\Delta f}{\varepsilon}, \qquad \Pr\left[\,|\text{잡음}| > t\,\right] = e^{-t/b}$$

ε	잡음 크기 b = 1/ε	90% 범위 t = b × ln 10 ≈ 2.3b
1	1	참값 ± 2.3명
0.5	2	참값 ± 4.6명
0.1	10	참값 ± 23명

e^(−t/b) = 0.1을 풀면 t = b × ln 10이다. ln 10 ≈ 2.3만 기억하면 된다

같은 예산을 네 질의에 나누면 질의마다 흔들림이 네 배가 된다

총예산 ε = 1을 연령대별 고객 수 네 개 공개에 똑같이 나눈다

① 예산 분할

질의마다 ε = 1 / 4 = 0.25

② 잡음 크기

b = 1 / 0.25 = 4

③ 90% 범위

± 2.3 × 4 ≈ ± 9.2명

해석

- 한 질의에 예산을 모두 쓰면 ± 2.3명, 네 개로 나누면 각각 ± 9.2명이다
- 공개할 표의 개수를 줄이는 것이 곧 정확도를 지키는 방법이다

기울기 길이가 상한을 넘으면 길이만 줄이고 방향은 둔다

한 고객의 기울기 g = (3, 4), 상한 C = 1

① 길이 재기

‖g‖ = √(9 + 16) = 5

② 비교

5 > C = 1 이므로 자른다

③ 축소

g × 1/5 = (0.6, 0.8)

$$\mathrm{clip}(g, C) \;=\; g \cdot \min\left(1,\; \frac{C}{\|g\|}\right) \;=\; (3,4) \cdot \frac{1}{5} \;=\; (0.6,\; 0.8)$$

비교: g = (0.3, 0.4)면 길이 0.5 < 1이라 그대로 둔다. 상한 덕분에 누구도 영향이 1을 넘지 않는다

서버 셋은 조각만 더해도 정확한 총합을 맞춘다

세 사람의 연봉(백만 원)을 q = 1000 기준으로 세 조각씩 나눈다

사람 (연봉)	서버 1 조각	서버 2 조각	서버 3 조각	검산 (mod 1000)
가 (52)	310	455	287	1052 → 52
나 (61)	802	120	139	1061 → 61
다 (47)	615	733	699	2047 → 47
서버 합	1727 → 727	1308 → 308	1125 → 125	

$$(727 + 308 + 125) \bmod 1000 = 160 = 52 + 61 + 47$$

각 서버가 본 조각은 무작위 숫자처럼 보인다. 세 합을 모아야 총합 160(평균 약 53)이 나온다

여덟 계산이 주는 판단 기준

본편 종합 슬라이드의 세 메시지와 연결된다

1

가중 평균은 공정하지만 중립적이지 않다

데이터가 많은 참여자의 분포가 전역 모델을 지배한다 (W1).

2

ε는 흔들림의 크기로 번역해 설명한다

ε = 0.1은 ± 23명, ε = 1은 ± 2.3명 — 숫자로 말하면 경영진도 판단할 수 있다 (W4·W5).

3

자르기와 조각내기가 개인의 영향을 묶는다

DP-SGD는 영향의 상한을, 비밀 분산은 열람 범위를 제한한다 (W6·W7).