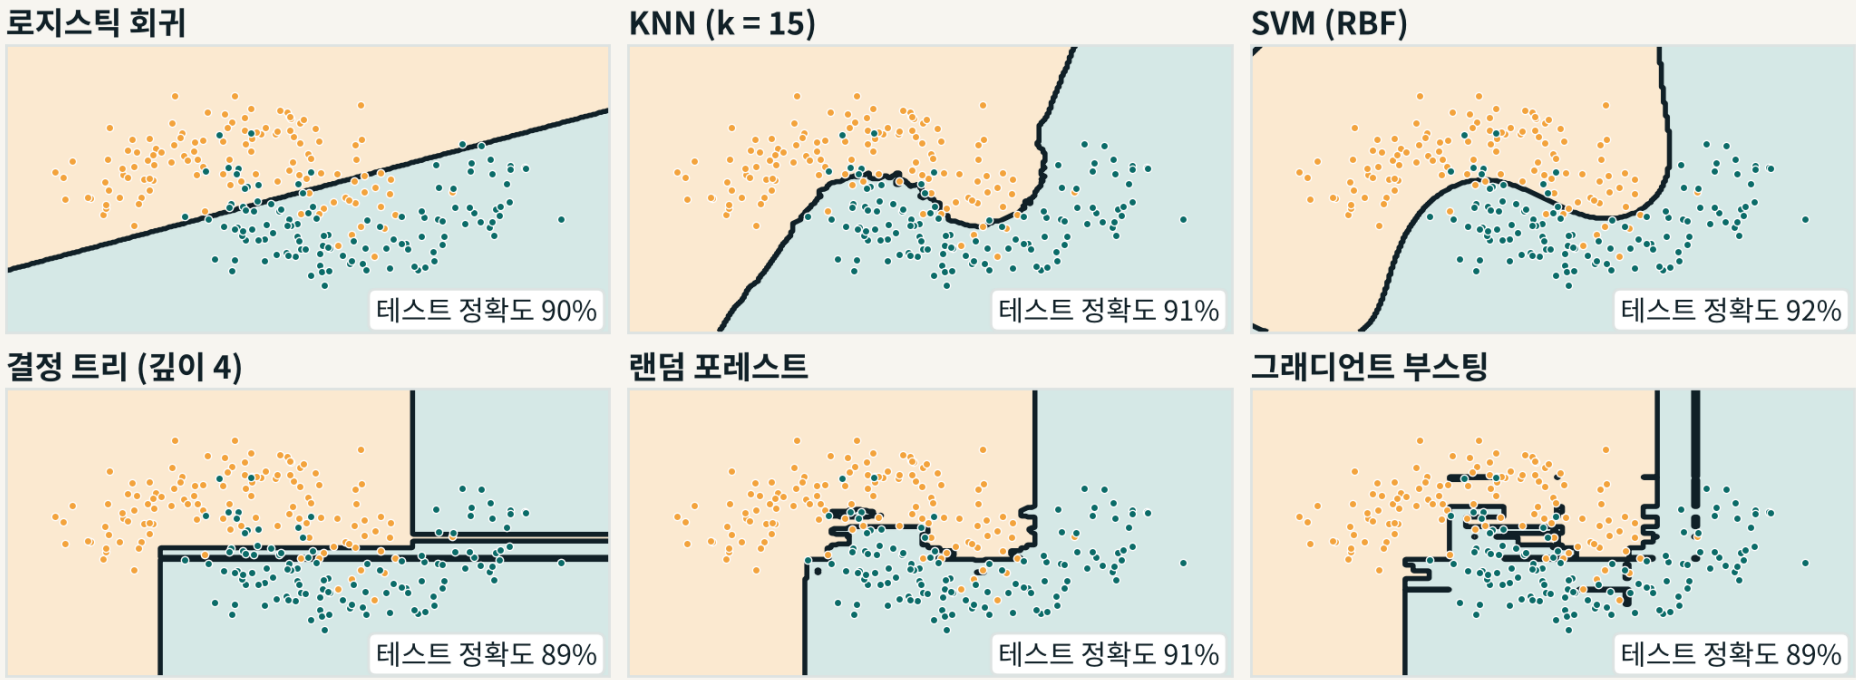
같은 자료라도 모형마다 경계선의 모양이 다릅니다

반달 모양 합성 자료(make_moons, 400개)를 학습 60%·테스트 40%로 나눈 결과 · 배경색 = 모형이 예측한 클래스



직선(로지스틱) · 매끈한 곡선(KNN·SVM) · 계단(트리) · 계단의 조합(앙상블)

정확도는 비슷해도 경계의 성격이 다르므로, 자료의 모양에 맞는 모형을 고릅니다

※ 결정 경계(decision boundary): 모형이 두 클래스를 가르는 선 · 분류(classification): 정해진 범주 중 하나를 맞히는 문제

로지스틱 회귀는 점수를 확률로 바꿔 직선 하나로 두 집단을 나눕니다

Logistic Regression — 이름은 '회귀'지만 분류에 쓰는 기본 모형

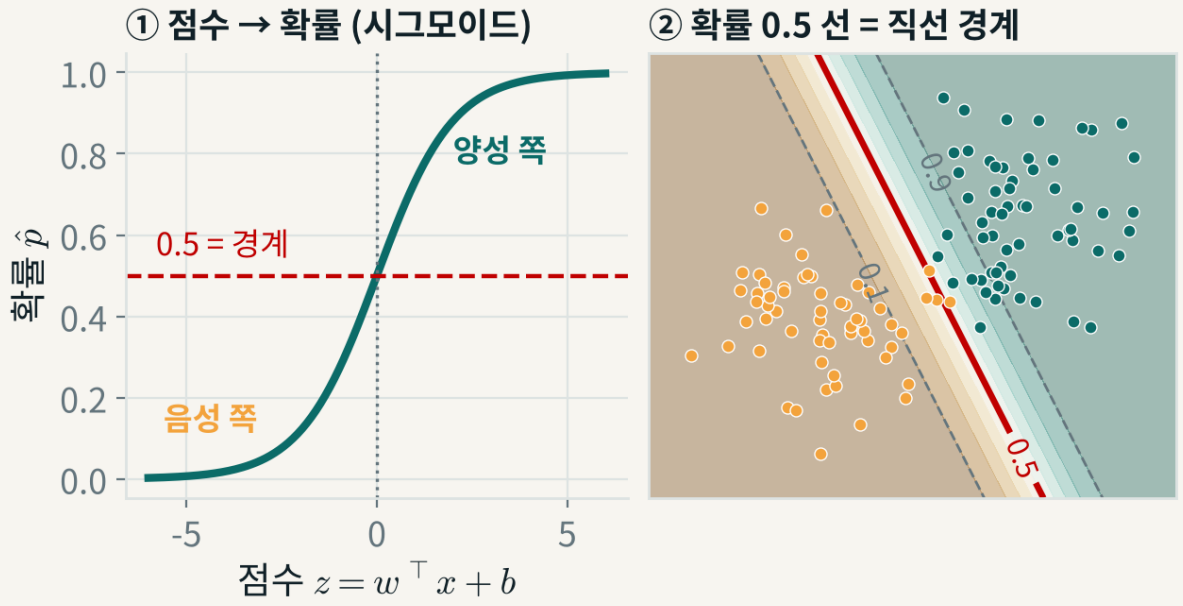
시그모이드 · 점수 z를 0~1 확률로

$$\hat{p} = \sigma(z) = \frac{1}{1+e^{-z}}, \qquad z = w_1 x_1 + w_2 x_2 + b$$

로그 오즈(log-odds) · 확률을 직선 점수로

$$\log \frac{\hat{p}}{1-\hat{p}} = z = w_1 x_1 + w_2 x_2 + b$$

- w: 각 특성이 점수에 주는 영향
- 확률 0.5 이상이면 양성
- 경계는 언제나 직선(평면)



빠르고 계수로 해석할 수 있어 분류 문제의 출발점(baseline)이 됩니다

경계가 직선이라 휘어진 패턴은 잡지 못합니다

KNN은 가장 가까운 이웃 k개의 다수결로 분류합니다

K-Nearest Neighbors — 학습 대신 자료를 통째로 기억했다가, 새 점이 오면 거리를 잰다

거리 · 유클리드 거리(Euclidean distance)

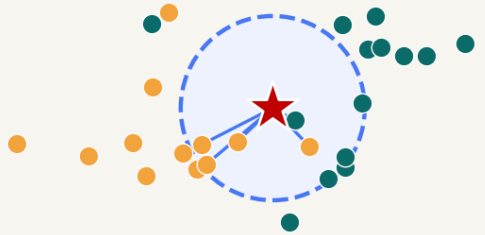
$$d(x, x') = \sqrt{\sum_j (x_j - x'_j)^2}$$

예측 · 이웃 k개 레이블의 최빈값

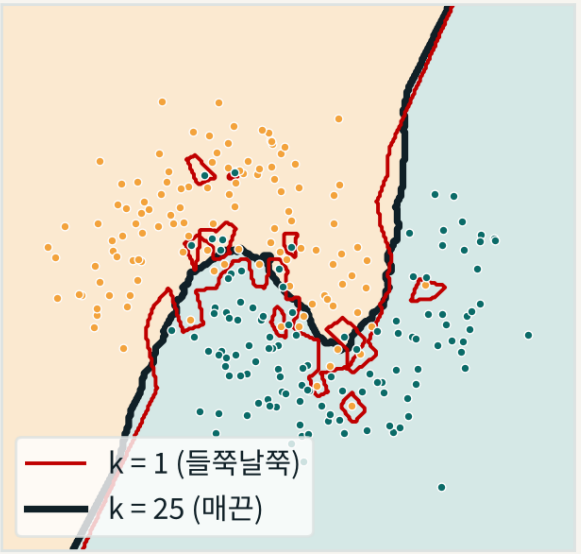
$$\hat{y} = \text{mode}\{\, y_i : i \in N_k(x) \,\}$$

- k가 작으면 들쭉날쭉(과적합)
- k가 크면 밋밋(과소적합)
- 특성 단위를 먼저 맞춘다(표준화)

① ★의 이웃 5개가 투표



② k가 경계의 모양을 정함



k는 교차검증으로 고르고, 특성은 반드시 표준화합니다

자료가 많으면 예측할 때마다 거리를 다 재야 해서 느려집니다

SVM은 두 집단 사이의 여백이 가장 넓은 경계를 찾습니다

Support Vector Machine — 경계에 가장 가까운 점(서포트 벡터)만 경계를 결정한다

최대 여백(maximum margin)

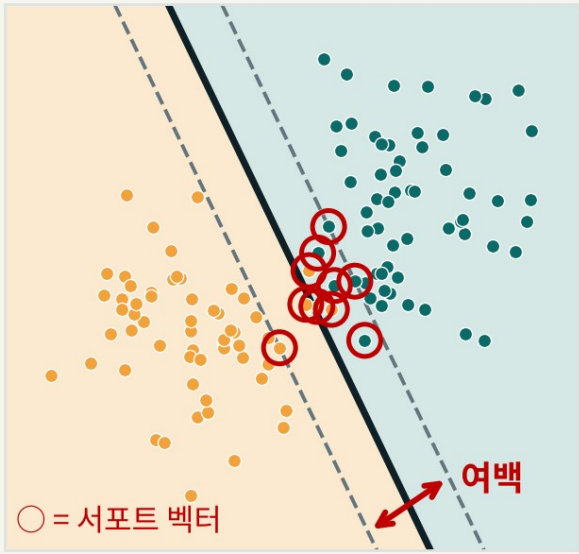
$$\max_{w,b} \frac{2}{\|w\|} \quad \text{s.t.} \quad y_i\,(w^\top x_i + b) \geq 1$$

RBF 커널 · 가까울수록 1에 가까운 유사도

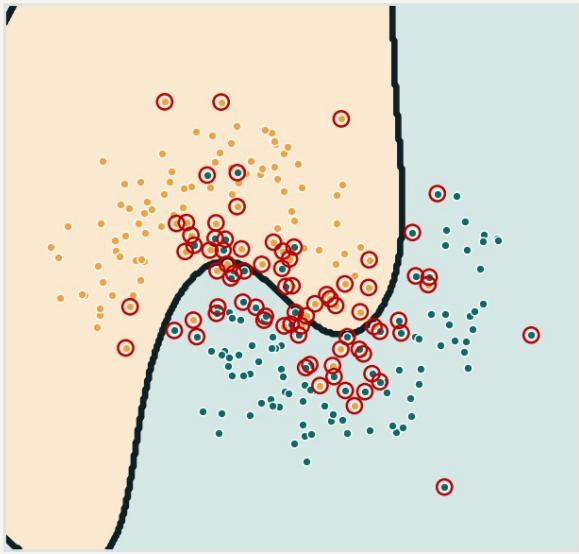
$$K(x, x') = \exp\left(-\gamma \,\|x - x'\|^2\right)$$

- 여백이 넓을수록 새 자료에 강함
- C: 오분류를 얼마나 허용할지
- 커널: 곡선 경계를 만드는 장치

① 여백이 가장 넓은 직선



② 커널(RBF)로 휘어진 경계



중간 규모 자료에서 정확하고, 커널로 직선과 곡선을 모두 다룹니다

자료가 크면 느리고, C·γ 튜닝과 표준화가 필요합니다

결정 트리는 예/아니오 질문을 이어 붙여 공간을 상자로 나눕니다

Decision Tree — 질문마다 불순도(Gini)를 가장 많이 줄이는 특성과 기준값을 고른다

지니 불순도(Gini) · 0이면 한 클래스만 남음

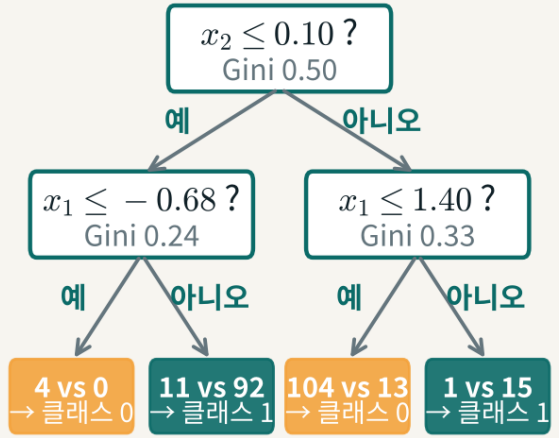
$$G = 1 - \sum_k p_k^2$$

예 · 주황 8개, 청록 2개가 모인 칸

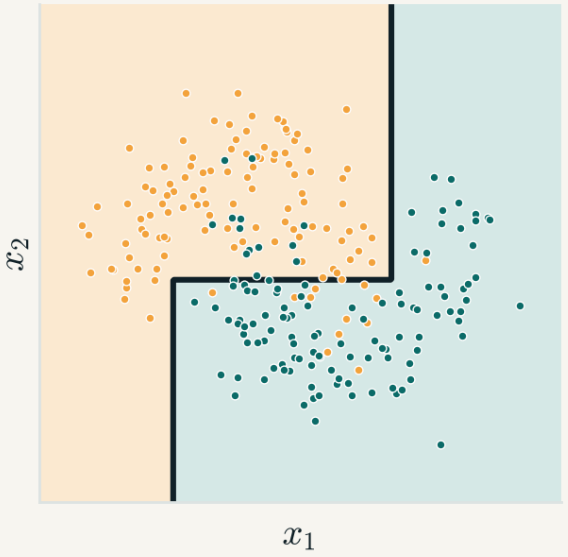
$$G = 1 - \left(0.8^2 + 0.2^2\right) = 0.32$$

- 질문 = 특성 하나 + 기준값
- 깊을수록 상세 → 과적합 위험
- if-then 규칙이라 설명이 쉽다

① 질문을 이어 붙인 트리



② 결과: 축에 나란한 상자



규칙으로 읽을 수 있어 설명이 쉽고, 전처리가 거의 필요 없습니다

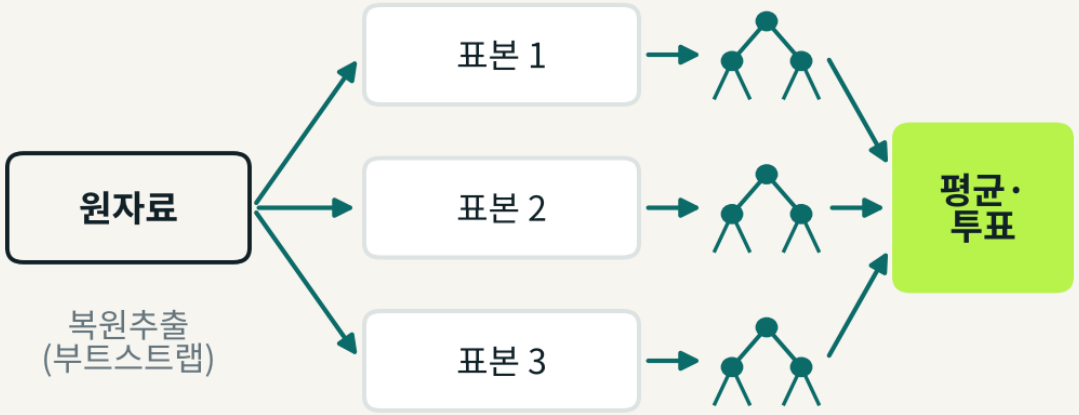
자료가 조금만 바뀌어도 트리 모양이 크게 달라질 만큼 불안정합니다

배깅은 트리를 나란히 평균하고, 부스팅은 오차를 차례로 고칩니다

랜덤 포레스트(Random Forest)는 배깅, 그래디언트 부스팅 트리(GBT)는 부스팅의 대표 모형

① 배깅 (Bagging) → 랜덤 포레스트

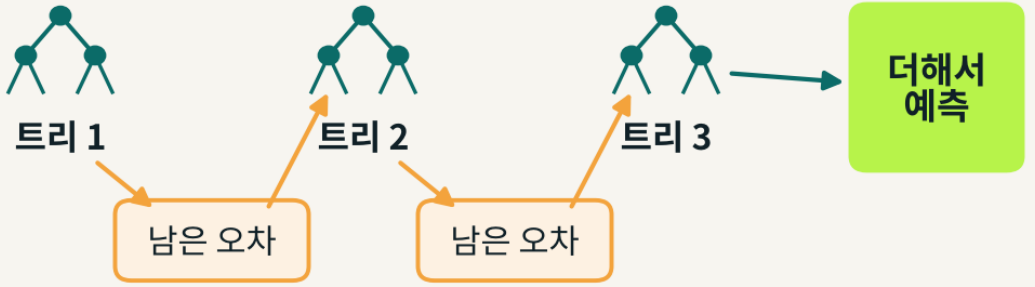
병렬: 트리들이 서로 독립



$$\hat{f}(x) = \frac{1}{B}\sum_{b=1}^{B} f_b(x)$$

② 부스팅 (Boosting) → 그래디언트 부스팅

순차: 다음 트리가 앞의 오차를 학습



작은 학습률 η로 조금씩 고친다

$$F_m(x) = F_{m-1}(x) + \eta\, h_m(x)$$

배깅은 분산(들쭉날쭉함)을, 부스팅은 편향(체계적 오차)을 줄입니다

랜덤 포레스트는 안정적이고 튜닝이 쉬우며, 부스팅은 더 정확한 편이나 조율이 필요합니다