이상치 탐지는 정상의 모습을 배운 뒤 벗어난 정도를 점수로 매깁니다

비지도 학습(unsupervised) — 사기·이상거래 레이블이 없어도 쓸 수 있다

LEVEL 1

도메인 기반 EDA

- 그림과 업무 규칙
- 불가능한 값 확인

LEVEL 2

일변량 규칙

- 터키 방법(IQR)
- z-점수 임계값

LEVEL 3 · 이번 자료

다변량 모형

- OCSVM · IF · LOF
- MCD · 오토인코더

01 · 경계

OCSVM, SVDD

02 · 고립

Isolation Forest

03 · 국소 밀도

LOF

04 · 복원 오차

오토인코더

변수를 하나씩 보면 조합으로만 이상한 거래를 놓칩니다

One-Class SVM은 정상 데이터를 특징 공간으로 옮겨 원점에서 떼어 냅니다

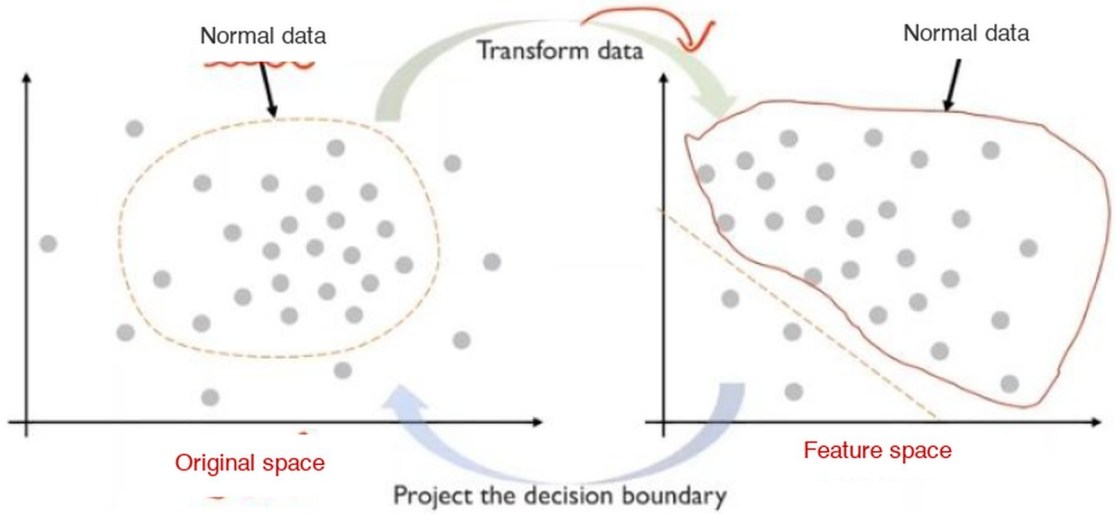
정상 관측치만으로 학습하는 SVM — 이상치가 아니라 정상의 영역을 배운다

세 단계

① 커널 φ로 특징 공간에 옮긴다

② 정상 데이터와 원점을 초평면으로 가른다

③ 경계를 원래 공간에 투영한다

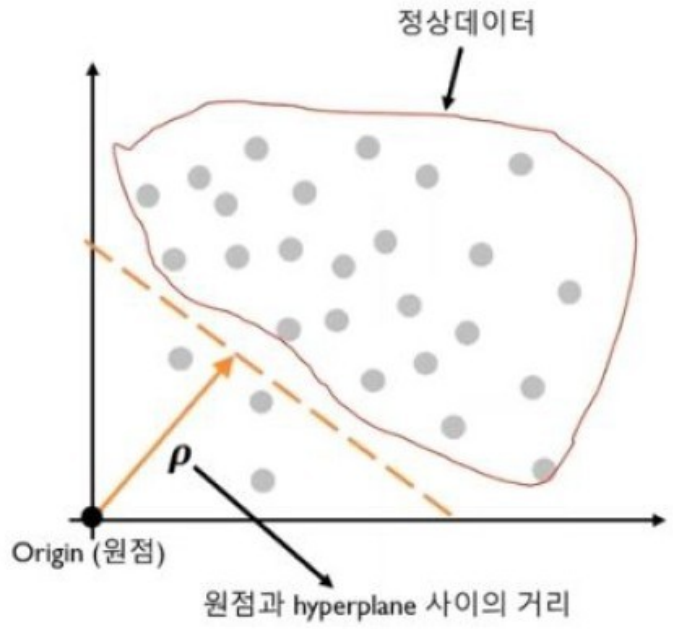


특징 공간의 직선 경계가 원래 공간에서는 정상 데이터를 감싸는 곡선이 됩니다

사기 레이블이 없어도 정상 거래만으로 학습할 수 있습니다

초평면은 원점에서 최대한 멀리 두고, 넘어가는 점은 일부만 허용합니다

Schölkopf et al.(2001) · 원점과 초평면 사이의 거리(여백)를 최대화한다



목적함수와 제약

$$\min_{w,\xi,\rho} \ \tfrac{1}{2}\|w\|^2 + \tfrac{1}{\nu n}\sum_{i=1}^{n}\xi_i - \rho$$
$$\text{s.t.} \ \ w\cdot\phi(x_i) \geq \rho - \xi_i, \quad \xi_i \geq 0$$

판정 · +1 정상, −1 이상

$$f(x) = \text{sign}\left(w\cdot\phi(x) - \rho\right), \qquad \text{margin} = \frac{\rho}{\|w\|}$$

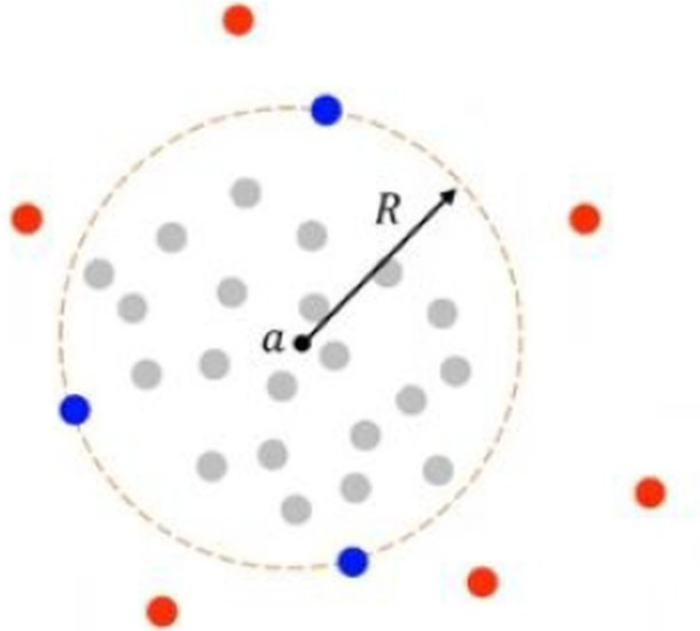
- $\frac{1}{2}\|w\|^2$ — w를 작게 — 여백이 넓고 경계가 매끄럽다
- $-\rho$ — ρ를 크게 — 평면을 원점에서 밀어낸다
- $\frac{1}{\nu n}\sum\xi_i$ — **넘어간 점의 벌점 — ν가 그 비율의 상한**

w는 작게, ρ는 크게 할수록 여백이 넓어집니다 — 일반 SVM과 같은 원리입니다

경계를 넘어간 소수의 점(여유변수 ξ)이 이상치입니다

SVDD는 정상 데이터를 가장 작은 초구로 감싸고 밖의 점을 이상치로 봅니다

Support Vector Data Description · 중심 a, 반지름 R, 초구 밖으로 나간 거리 ξ



목적함수 · 초구는 작게, 밖으로 나간 거리에는 벌점

$$\min_{R,a,\xi} \; R^2 + C\sum_{i=1}^{n}\xi_i$$
$$\text{s.t.} \;\; \|\phi(x_i) - a\|^2 \le R^2 + \xi_i, \quad \xi_i \ge 0$$

쌍대 문제의 승수 α가 각 관측치의 위치를 알려 준다

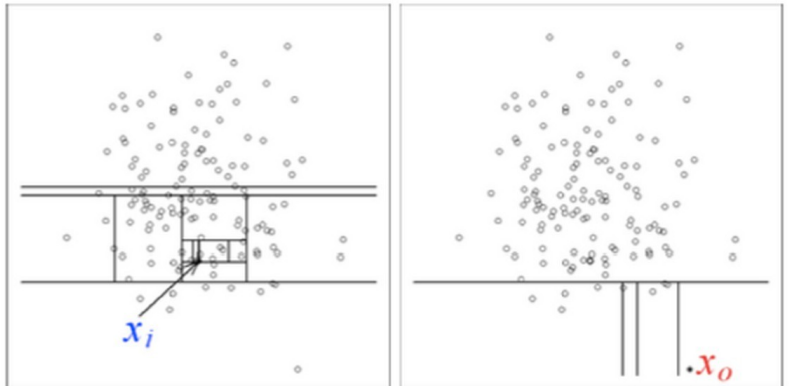
■	$\alpha_i = 0$	초구 안 — 정상
■	$0 < \alpha_i < C \;\Rightarrow\; \xi_i = 0$	초구 위 — 서포트 벡터
■	$\alpha_i = C \;\Rightarrow\; \xi_i > 0$	**초구 밖 — 서포트 벡터, 이상치**

C가 크면 거의 모든 점을 안에 두고, 작으면 초구가 작아져 이상치가 늘어납니다

RBF 커널에서는 OCSVM과 경계가 같습니다 — R 최소화 = ρ 최대화(OCSVM은 C = 1/νn)

Isolation Forest는 무작위 분할로 빨리 고립되는 점을 이상치로 봅니다

무작위 변수를 골라 [최솟값, 최댓값]에서 무작위로 자르며 iTree를 키운다 — 레이블 불필요



왼쪽 x_i(무리 속 정상)는 여러 번, 오른쪽 x_o(외딴 점)는 몇 번 만에 고립

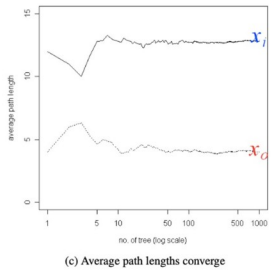
s ≈ 1	평균 경로가 훨씬 짧다 — 이상치
s ≈ 0.5	평균과 비슷하다 — 정상

이상 점수 · h(x): 고립까지 경로 길이

$$s(x, n) = 2^{-E[h(x)]/c(n)}$$

c(n) · 평균 경로 길이(정규화)

$$c(n) = 2H(n-1) - \frac{2(n-1)}{n} \approx 2\ln n - 1$$



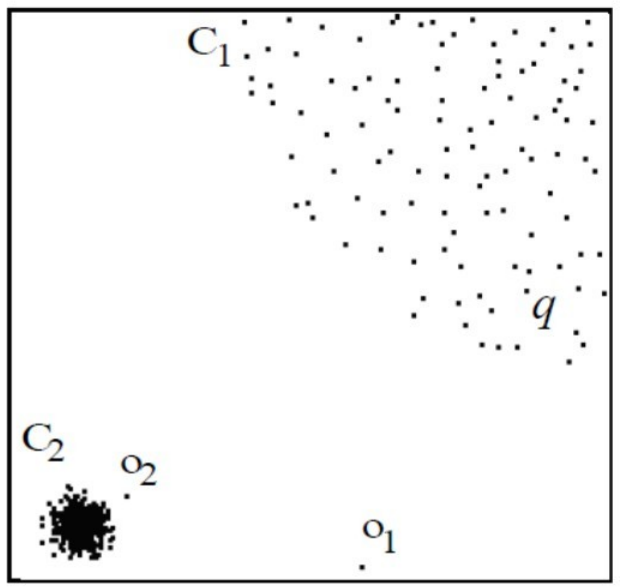
(c) Average path lengths converge

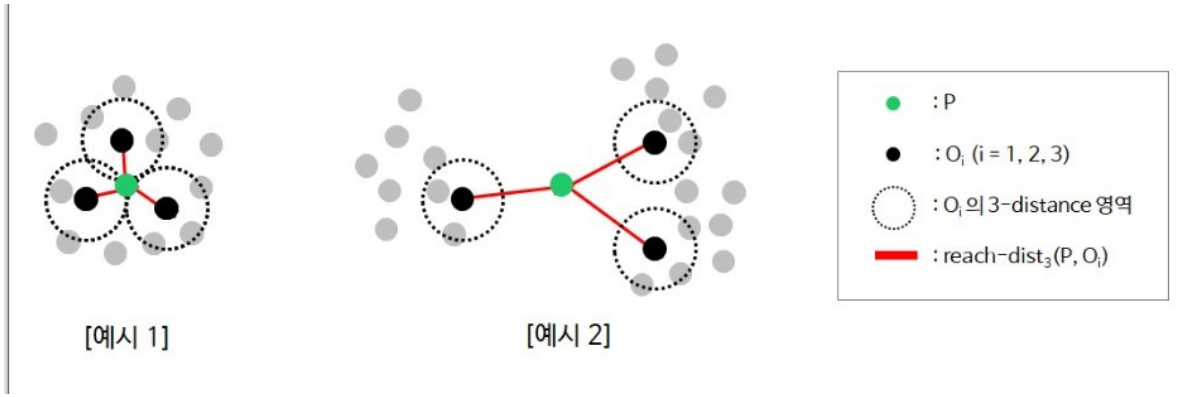
표본 256개면 c ≈ 10: 4번 만에 고립되면 s ≈ 0.76, 10번이면 s ≈ 0.5입니다

트리가 100개를 넘으면 평균 경로가 안정되고(정상 12~13, 이상 약 4), 대용량에도 빠릅니다

LOF는 절대 거리가 아니라 이웃 대비 밀도로 국소 이상치를 찾습니다

Local Outlier Factor(Breunig et al., 2000) · 성긴 군집 C1, 밀집 군집 C2, 이상치 후보 O1·O2





도달가능 거리 · k-거리 이상

$$\mathrm{reach}_k(p,o) = \max\{d_k(o),\ d(p,o)\}$$

국지적 밀도(lrd) · 도달거리 평균의 역수

$$\mathrm{lrd}_k(p) = \frac{|N_k(p)|}{\sum_{o\in N_k(p)} \mathrm{reach}_k(p,o)}$$

녹색 p에서 이웃까지 도달거리가 길면[예시 2] p의 밀도(lrd)는 낮아집니다

전역 거리 기준으로는 O1만 잡히고, 밀집 군집 C2 옆의 O2는 놓칩니다

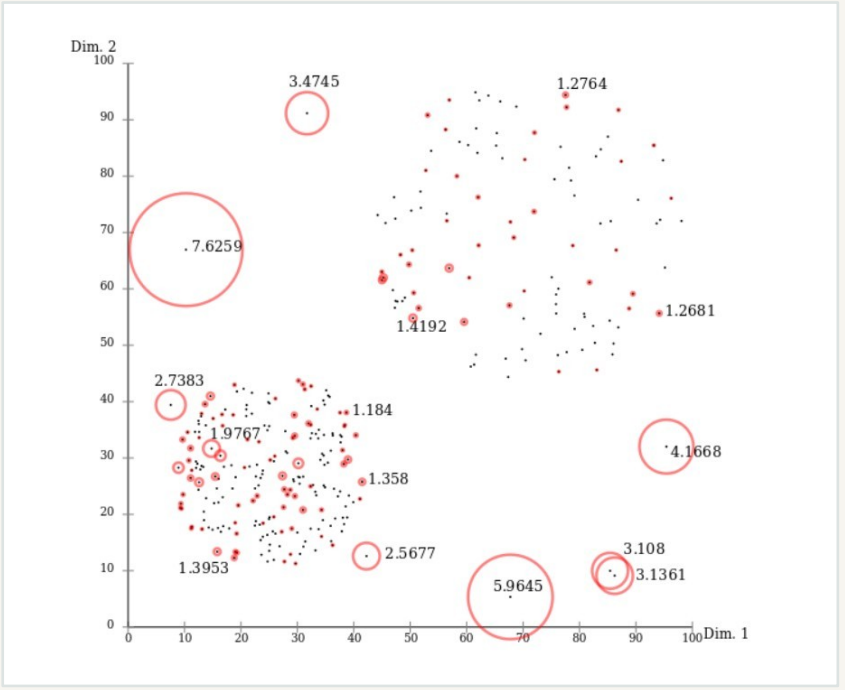
LOF는 이웃의 밀도를 자신의 밀도로 나눈 값이며, 1보다 클수록 이상치입니다

p의 밀도가 낮고 이웃 o의 밀도가 높을수록 LOF가 커진다 · 그림 숫자 = 각 점의 LOF

LOF · 이웃 밀도의 평균 ÷ p의 밀도

$$\mathrm{LOF}_k(p) = \frac{1}{|N_k(p)|} \sum_{o \in N_k(p)} \frac{\mathrm{lrd}_k(o)}{\mathrm{lrd}_k(p)}$$

LOF < 1	이웃보다 밀집 — 정상
LOF ≈ 1	이웃과 비슷한 밀도 — 정상
LOF ≫ 1	**이웃보다 성김 — 이상치**

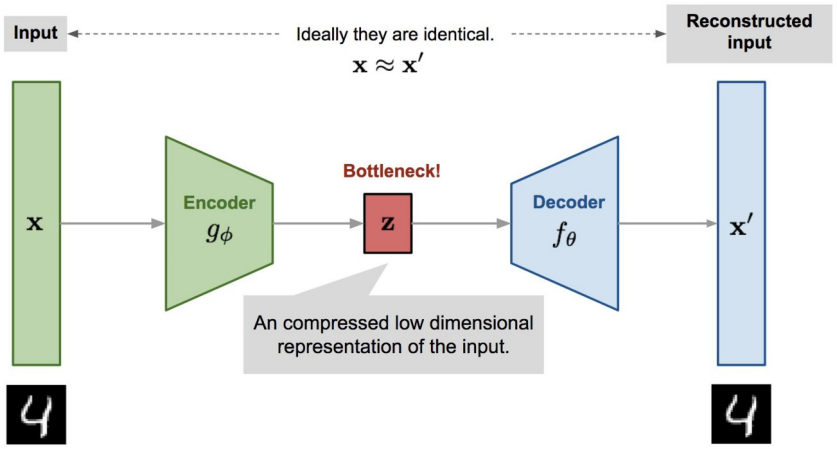


외딴 점은 LOF 2.5~7.6, 군집 안의 점은 1 근처에 머뭅니다

sklearn의 negative_outlier_factor_는 −LOF — 더 음수일수록 이상합니다

정상 데이터로만 학습한 오토인코더는 이상치를 제대로 복원하지 못합니다

인코더 g가 입력을 병목(bottleneck) z로 압축하고, 디코더 f가 원래 입력으로 복원한다

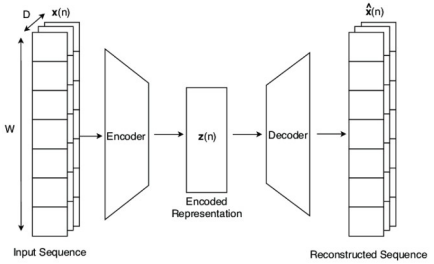


복원 오차와 임계값 τ

$$e(x) = \|x - f_\theta\big(g_\phi(x)\big)\|^2 > \tau \;\Rightarrow\; \text{outlier}$$

다섯 단계

1 정상·이상 데이터를 나눈다
2 정상 데이터만으로 학습한다
3 정상은 잘 복원된다
4 이상치는 복원이 안 된다
5 오차가 τ를 넘으면 이상치



LSTM 오토인코더(오른쪽 아래)는 같은 방법을 시계열 구간(window)에 적용합니다

학습 중 이상치를 본 적이 없으므로, 복원 오차가 τ를 넘는 거래를 이상치로 표시합니다

네 방법은 '정상'을 서로 다르게 정의합니다

자료에서 정상이 어떤 모습인지에 맞춰 방법을 고른다

OCSVM · SVDD

경계 밖

판정	경계 밖
조절	ν · C

Isolation Forest

쉽게 고립

판정	s ≈ 1
조절	트리 수

LOF

국소적으로 성김

판정	LOF ≫ 1
조절	k

오토인코더

복원이 어려움

판정	오차 > τ
조절	τ

scikit-learn은 네 방법 모두 predict에서 이상치를 −1, 정상을 +1로 돌려줍니다

레이블 없이 쓰지만, 걸러진 거래는 반드시 도메인 지식으로 확인합니다

※ 실습 코드: OneClassSVM · IsolationForest · LocalOutlierFactor(sklearn), LSTM 오토인코더 예제 github.com/cran2367