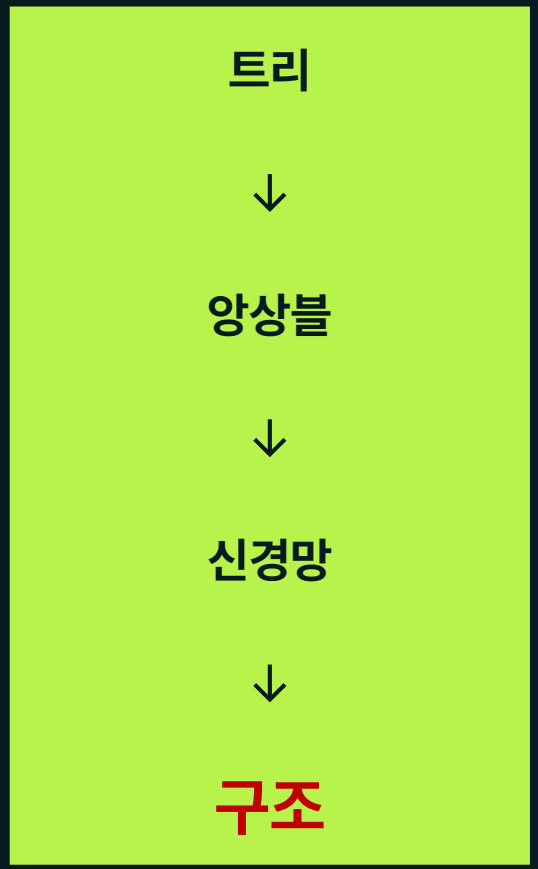
트리, 신경망
그리고 비지도학습

7–9주차 · 요약과 치트 시트



금융머신러닝 · QRM3007

CONTENTS

목차

01	트리와 앙상블	**7주차** 지니 · 배깅 · 부스팅 · 중요도 · iForest
02	신경망	**8주차** 뉴런 · XOR · 경사하강법 · 역전파 · AE
03	비지도학습	**9주차** K-평균 · PCA · 마르첸코–파스투르 잡음 제거
04	치트 시트	**7–9주차** 수식 · 다이얼 · 탐지기 · 도구 고르기

유연한 학습기 하나는 깨지기 쉽다 — 다양하고 절제된 팀은 그렇지 않다

01

트리와 앙상블

7주차 · 나무 한 그루, 숲, 이어달리기 팀, 그리고 고립 탐지기

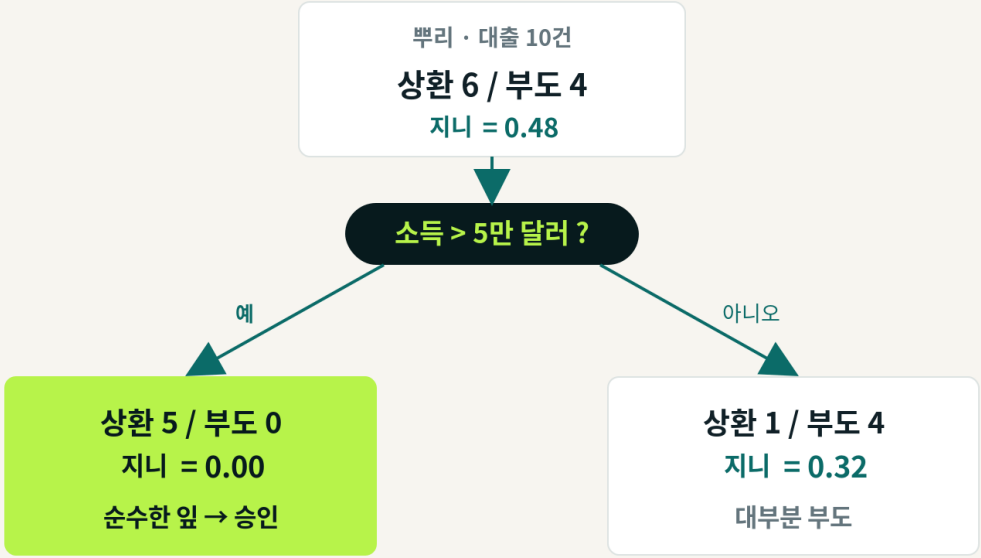
트리는 순도를 가장 많이 높이는 분할을 고른다

대출 10건, 상환 6 · 부도 4 — "소득 > 5만 달러?"는 좋은 질문인가?

지니 불순도 — 0이면 순수

$$G = 1 - \sum_k p_k^2$$



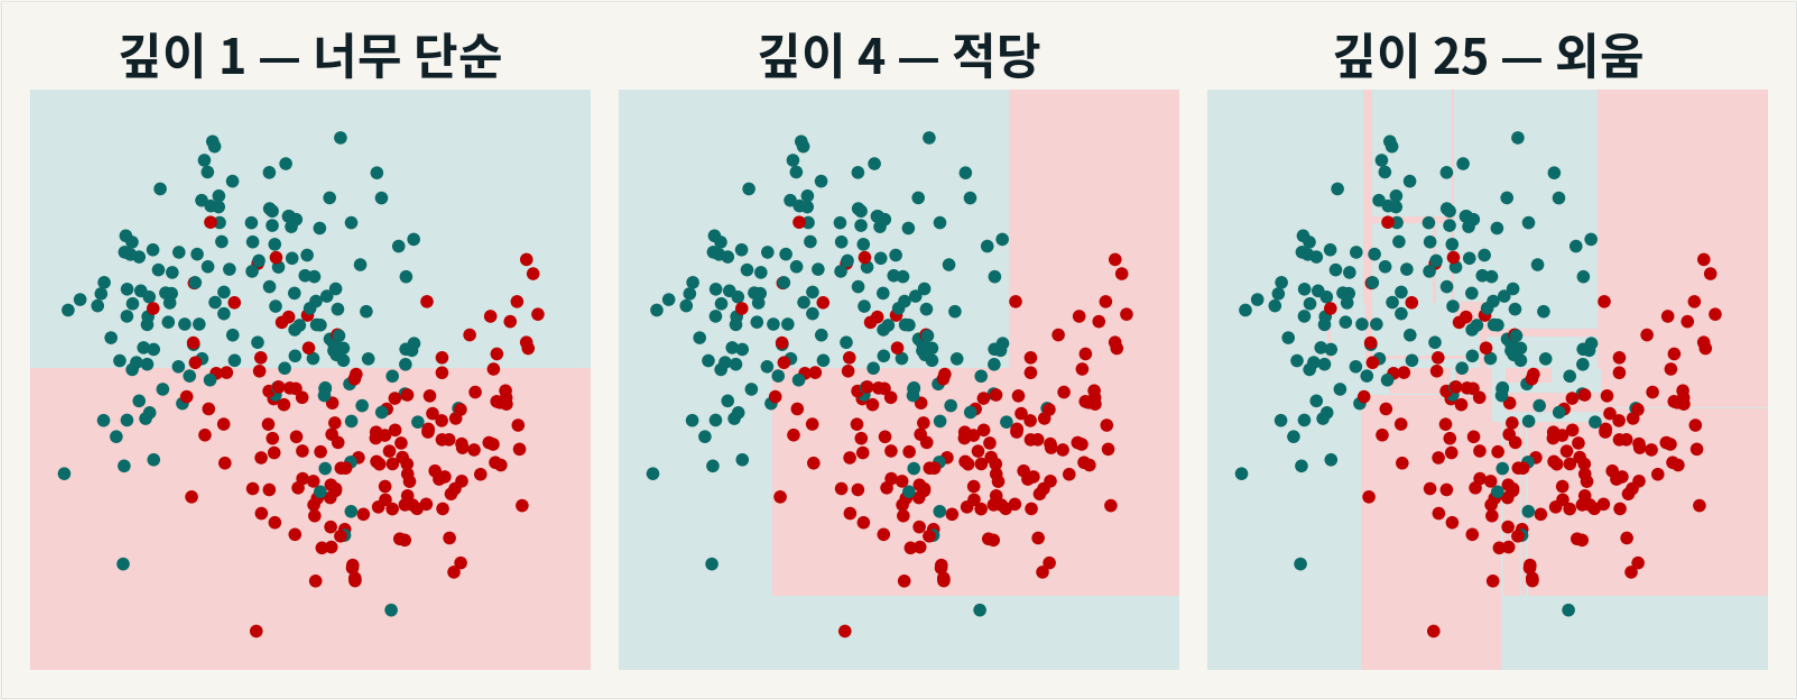


분할 후 가중 = 0.16 · 이득 = 0.48 − 0.16 = 0.32

질문 하나로 지니가 0.48 → 0.16으로 떨어진다. 트리는 가장 많이 떨어뜨리는 분할을 남긴다.

트리가 깊을수록 경계가 촘촘해진다 — 결국 외워 버릴 때까지

잡음 섞인 같은 점 300개를 깊이 1, 4, 25인 트리로 나눈 결과



깊이 25는 튀는 점마다 섬을 판다 — 학습 데이터에선 완벽, 밖에선 취약하다.

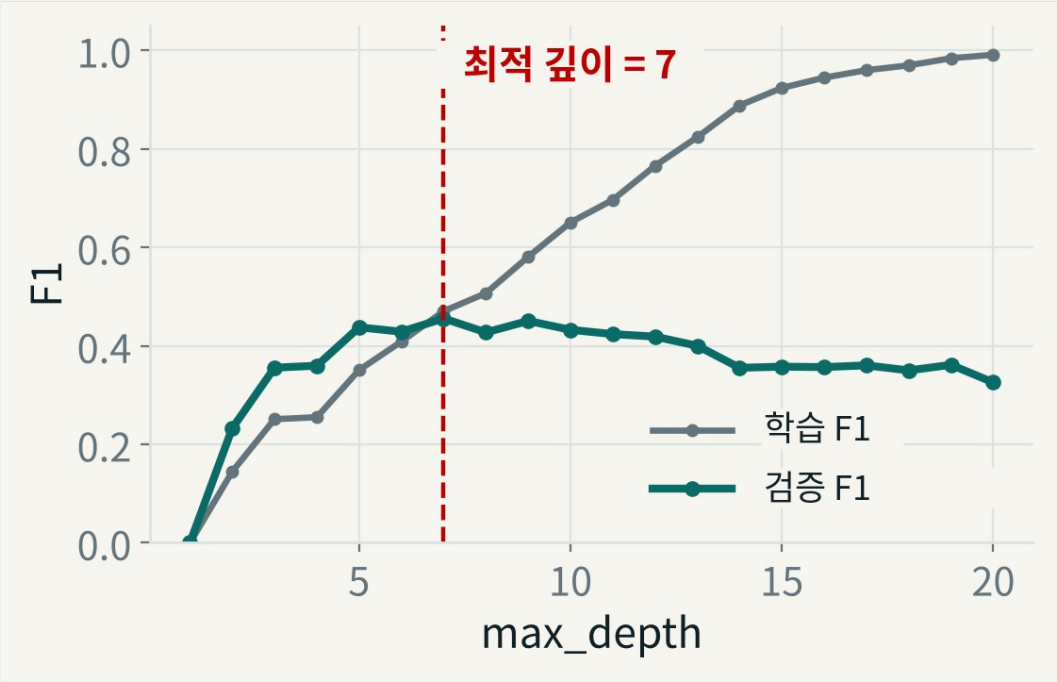
깊이는 트리의 복잡도 다이얼이다

max_depth별 학습 F1과 검증 F1 — 합성 데이터 2만 행, 양성 1%

조절 손잡이

- max_depth: 질문의 수
- min_samples_leaf: 너무 작은 잎 금지

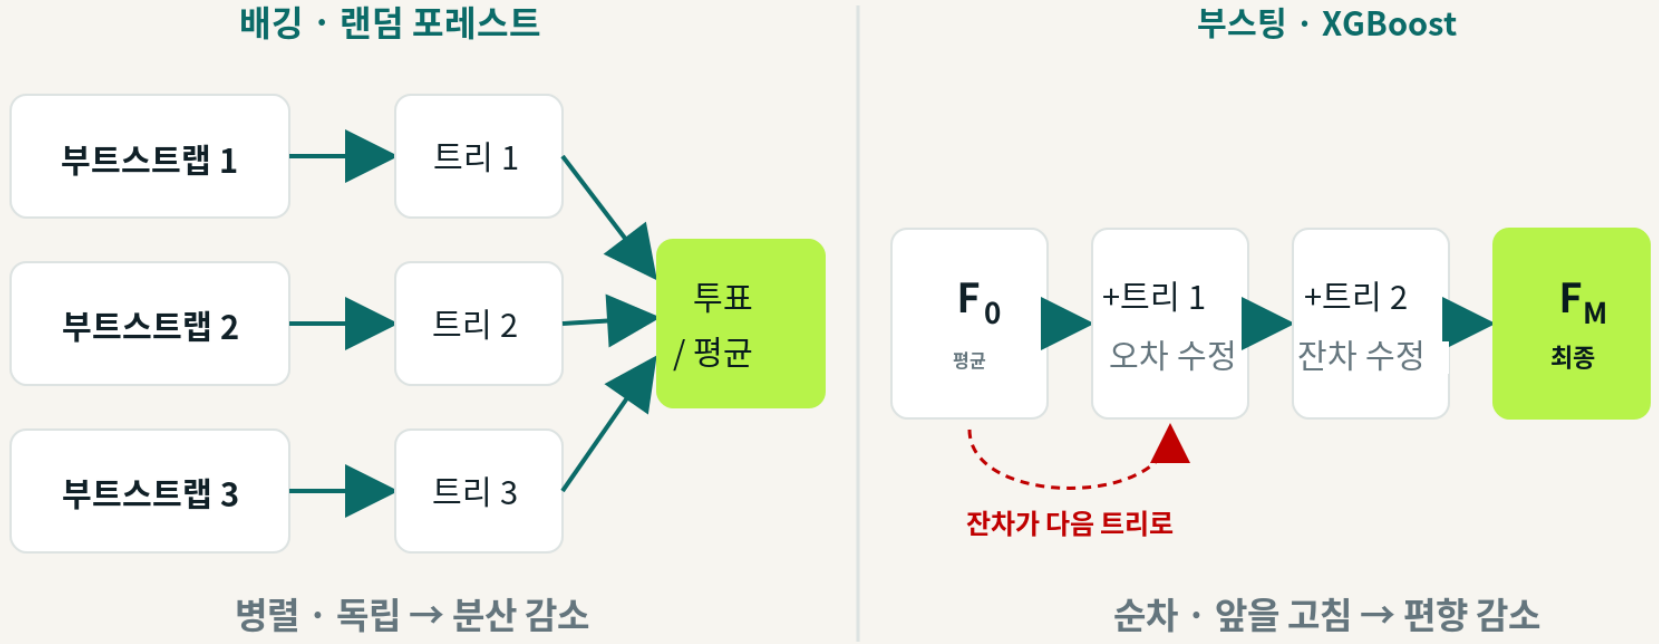
검증 F1은 깊이 7에서 정점



학습 F1은 깊이와 함께 계속 오르고 검증 F1은 꺾인다 — 길들인 트리도 여전히 흔들린다.

숲은 나란히 투표하고, 부스팅은 차례로 고친다

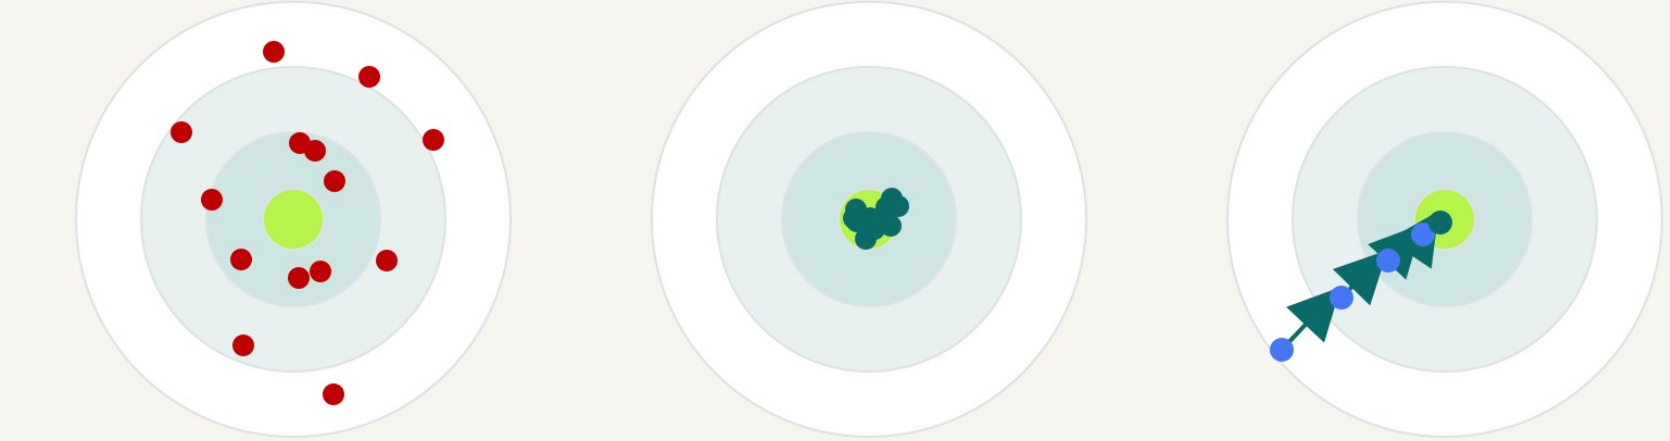
배깅 = 행 부트스트랩 + 무작위 변수 부분집합 · 부스팅 = 잔차를 향한 작은 걸음



위원회와 이어달리기 팀 — 둘 다 나무 한 그루를 이긴다.

숲은 흔들림을 없애고, 부스팅은 체계적 빗나감을 없앤다

점 = 서로 다른 표본으로 학습한 모형의 예측 · 과녁 중앙 = 참값



깊은 나무 한 그루
편향 낮음 · 분산 높음

랜덤 포레스트
평균이 흔들림을 없앰

부스팅
걸음이 편향을 걷어 냄

배깅은 분산을, 부스팅은 편향을 겨눈다 — 둘 다 깊은 나무 한 그루를 이긴다.

평균은 트리끼리 의견이 다를 때만 오차를 상쇄한다

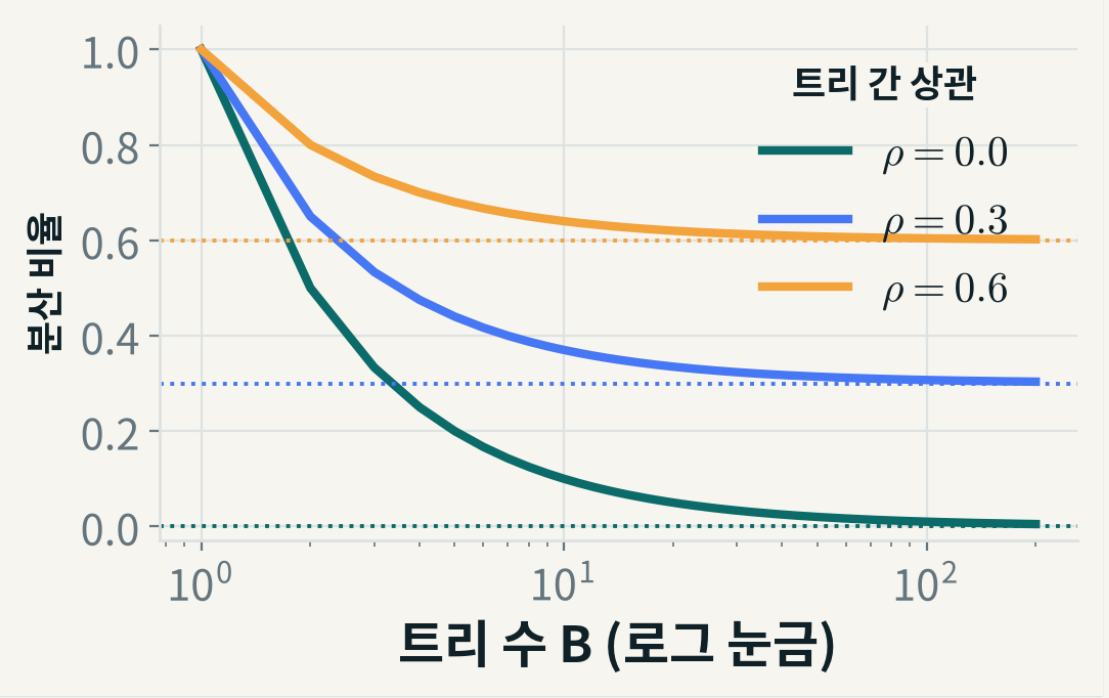
트리 B그루 평균의 분산(트리 하나 대비) — 트리 간 상관 세 수준

숲 평균의 분산

$$\mathrm{Var}\left[\hat{f}_{\mathrm{bag}}\right] = \rho\,\sigma^2 + \frac{1-\rho}{B}\,\sigma^2$$

상관이 바닥을 정한다

무작위 행 + 무작위 변수가 바닥을 낮춘다



트리를 더해도 줄어드는 건 둘째 항뿐 — 정말 값어치 있는 건 다양성이다.

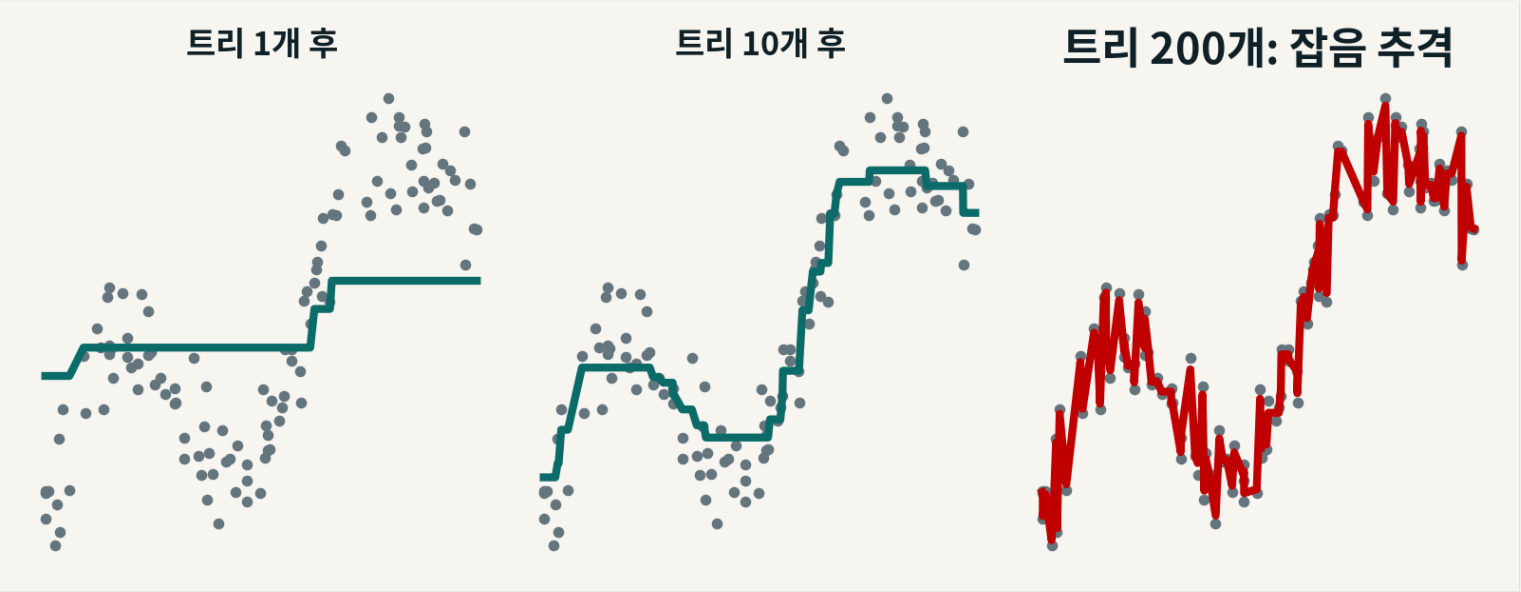
부스팅은 남은 오차에 작은 보정을 더한다

잡음 섞인 곡선에 깊이 2 트리, 걸음 0.3으로 적합한 그래디언트 부스팅

부스팅 갱신

$$F_m(x) = F_{m-1}(x) + \eta\, h_m(x)$$

이전 모형
에 작은 걸음을 더해
남은 오차 쪽으로



트리마다 남은 오차의 일부를 고친다. 장난감 예제에서 오차는 1.00 → 0.25 → 0.06으로 녹는다.

트리가 너무 많으면 잡음을 쫓는다 — 학습률과 트리 수는 검증 데이터로 맞춘다.

배깅은 분산을, 부스팅은 편향을 줄인다

	랜덤 포레스트 (배깅)	부스팅 (XGBoost)
트리를 만드는 방식	나란히, 서로 독립	차례로, 앞의 실수를 고침
주로 줄이는 것	**분산 (흔들림)**	**편향 (체계적 빗나감)**
주요 손잡이	n_estimators, max_features	learning_rate, n_estimators, depth
성격	너그럽고 과적합이 어렵다	날카롭다 — 지켜봐야 한다
이럴 때 꺼낸다	튼튼한 기준 모형이 필요할 때	정확도를 마지막 한 방울까지 짜야 할 때

숲으로 무난한 기준 모형을 세우고, 남은 정확도는 부스팅이 쫓게 한다.

아이솔레이션 포레스트는 무작위 자르기 몇 번 만에 고립되는 점을 잡는다

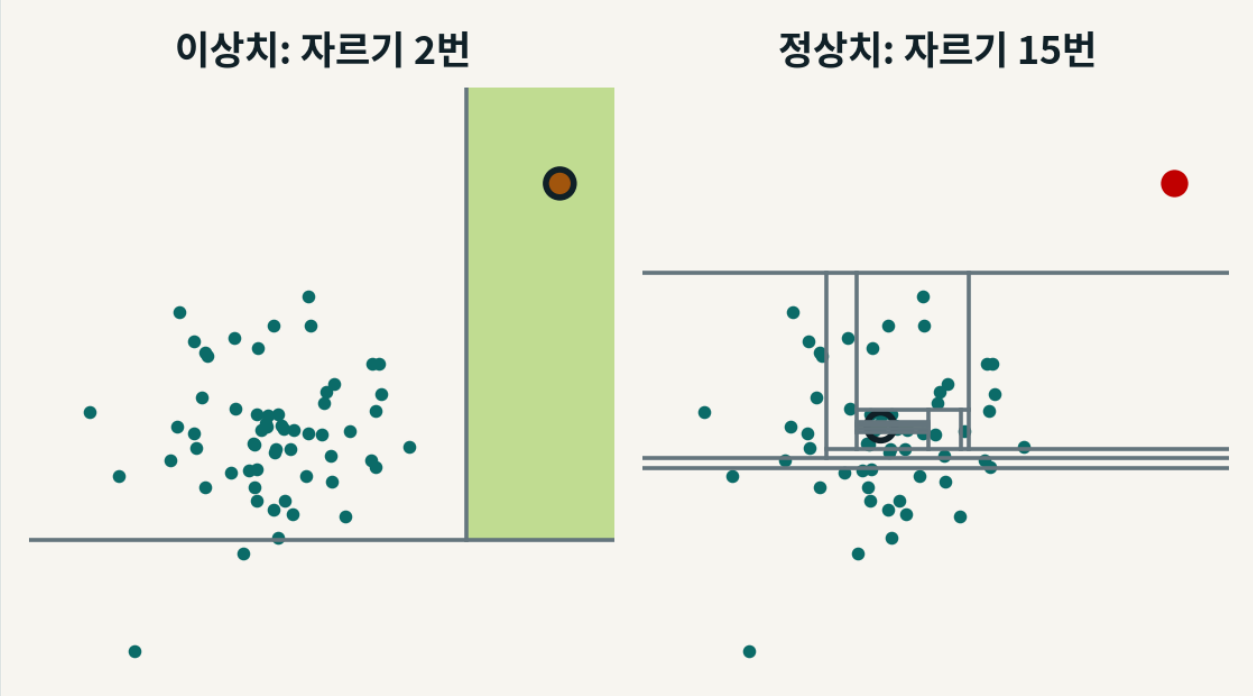
동그라미 친 점이 홀로 남을 때까지 축을 무작위로 자른다 — 이상치 탐지기 3번, 레이블 불필요

이상치 점수 (h: 필요한 자르기 횟수)

$$s(x, n) = 2^{-\mathbb{E}[h(x)] \,/\, c(n)}$$

자르기 적음 → 점수 1 근처 → 이상

자르기 많음 → 점수 0.5 미만 → 정상



거리도 레이블도 없이 자르기만 — 수백만 건의 거래에도 충분히 빠르다.

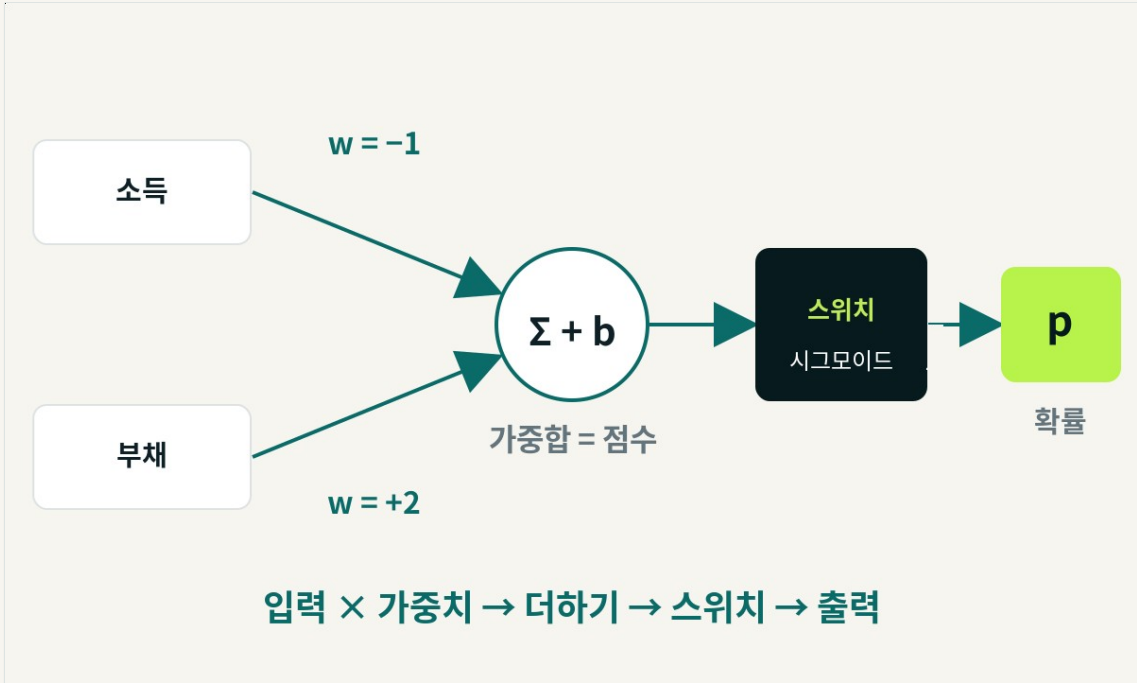
02

신경망

8주차 · 뉴런, 깊이, 경사하강법으로 배우기, 그리고 오토인코더

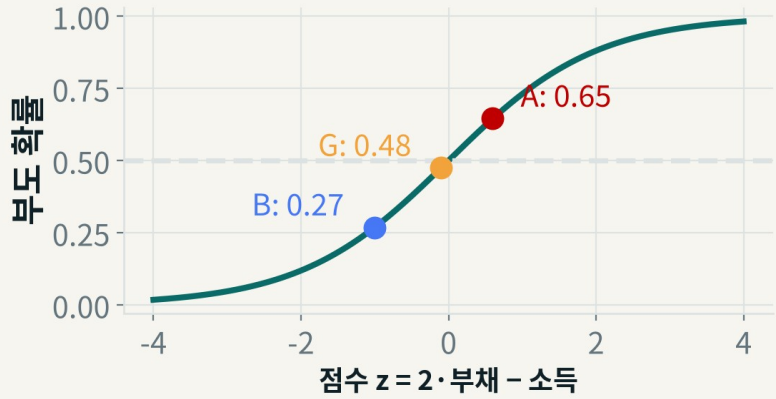
시그모이드를 단 뉴런 하나가 곧 로지스틱 회귀다

신용점수 뉴런: (소득, 부채)에 가중치 (−1, +2), 편향 0



뉴런: 가중합, 그다음 스위치

$$\hat{y} = f\left(\mathbf{w}^\top \mathbf{x} + b\right)$$



신청자 A는 +0.6점 → 부도 위험 65%. 힘은 뉴런을 여럿 쌓는 데서 나온다.

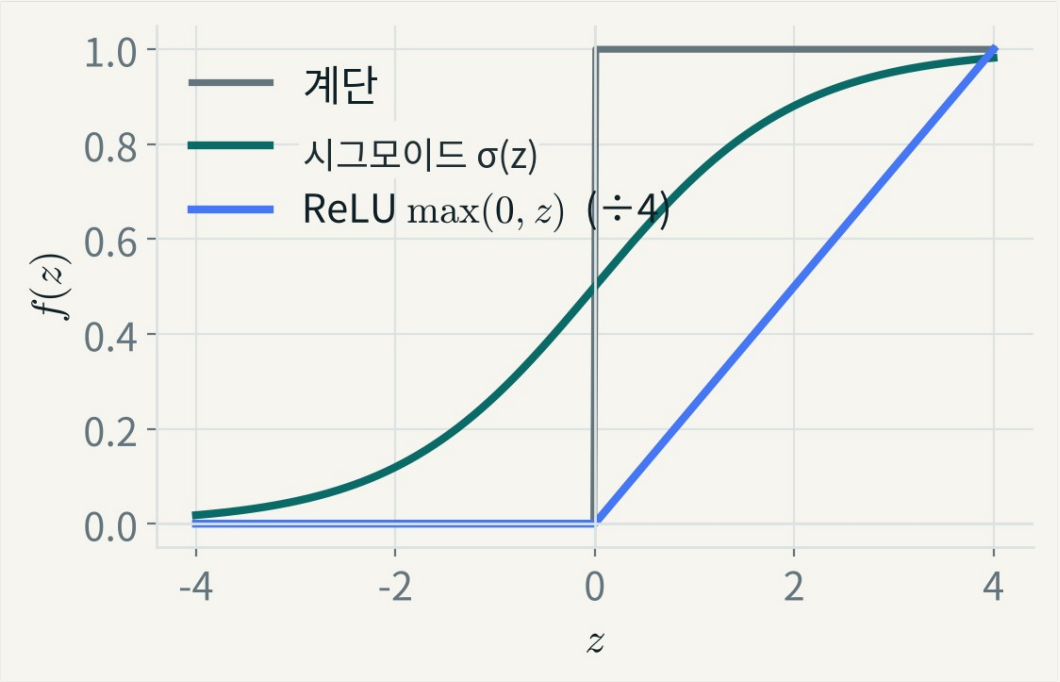
비선형 활성화가 있어야 깊이가 쓸모 있다

같은 입력 범위에서 본 계단 · 시그모이드 · ReLU

왜 스위치인가

- ReLU는 양수는 통과, 음수는 0으로
- 시그모이드는 확률로 눌러 담는다

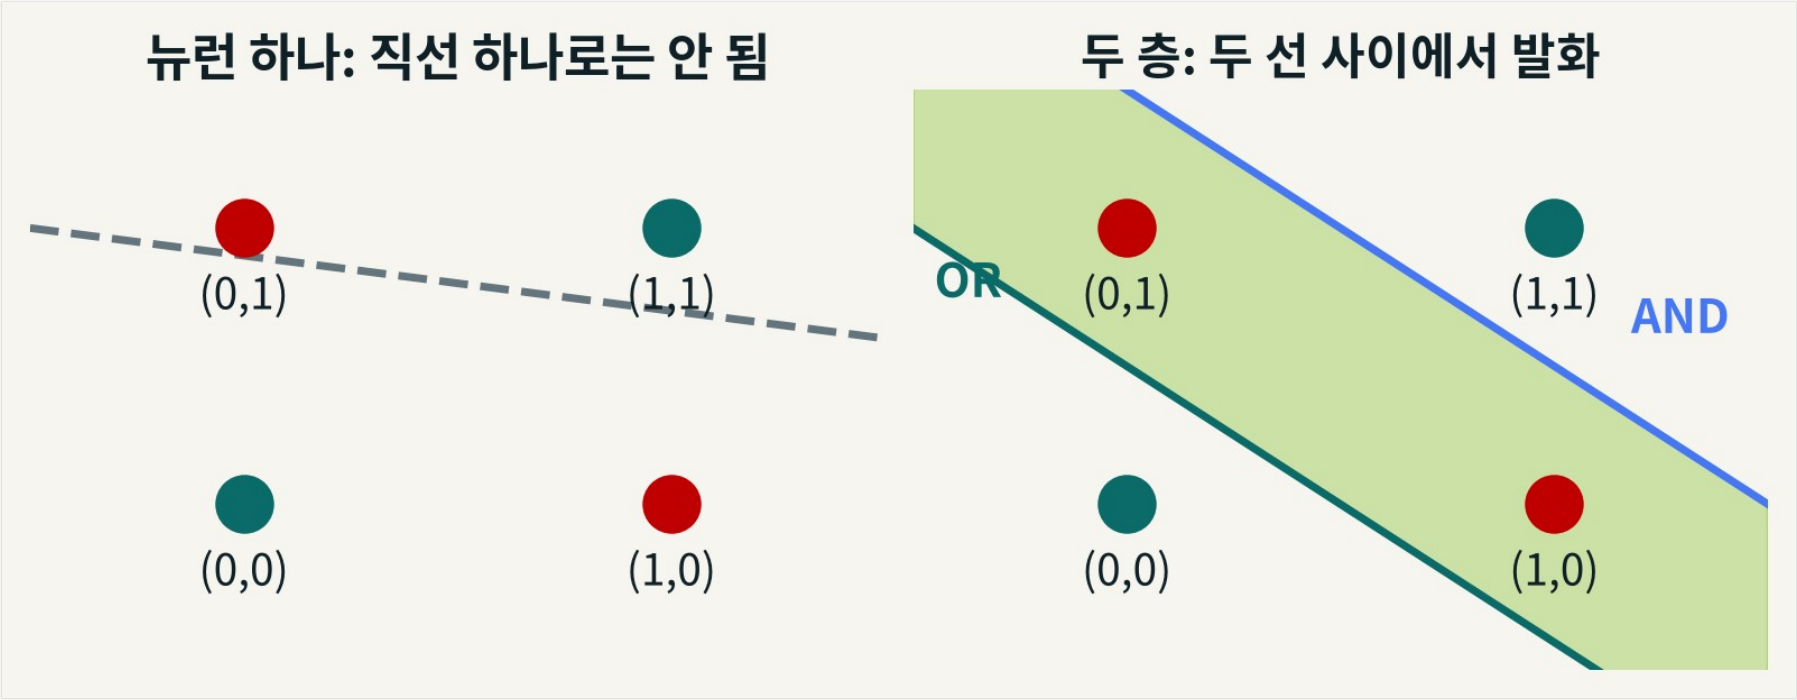
스위치가 없으면 10층도 직선 하나



층마다 그림을 한 번씩 굽힌다. 굽힘이 쌓이면 풍부한 경계를 그린다.

두 층이면 뉴런 하나로는 못 푸는 XOR을 푼다

단서가 정확히 하나일 때만 발화 — 빨강 = 발화. 1층은 OR과 AND 선을 긋고, 2층은 그 사이 띠만 남긴다



뉴런 하나는 선 하나를 긋고, 깊이는 굽힘을 더한다 — 1969년의 불평에 대한 답이다.

경사하강법은 학습률만큼 한 걸음씩 내리막을 걷는다

오차 $(w-3)^2$, $w=0$에서 출발 — 별이 골짜기

학습 걸음

$$w \leftarrow w - \eta \frac{\partial E}{\partial w}$$

기울기를 느끼고,
내리막으로 한 걸음,
반복



작은 걸음: 꾸준히 내려감. 딱 맞으면: 한 번에 도착. 너무 크면: 지나쳐 튕겨 나감.

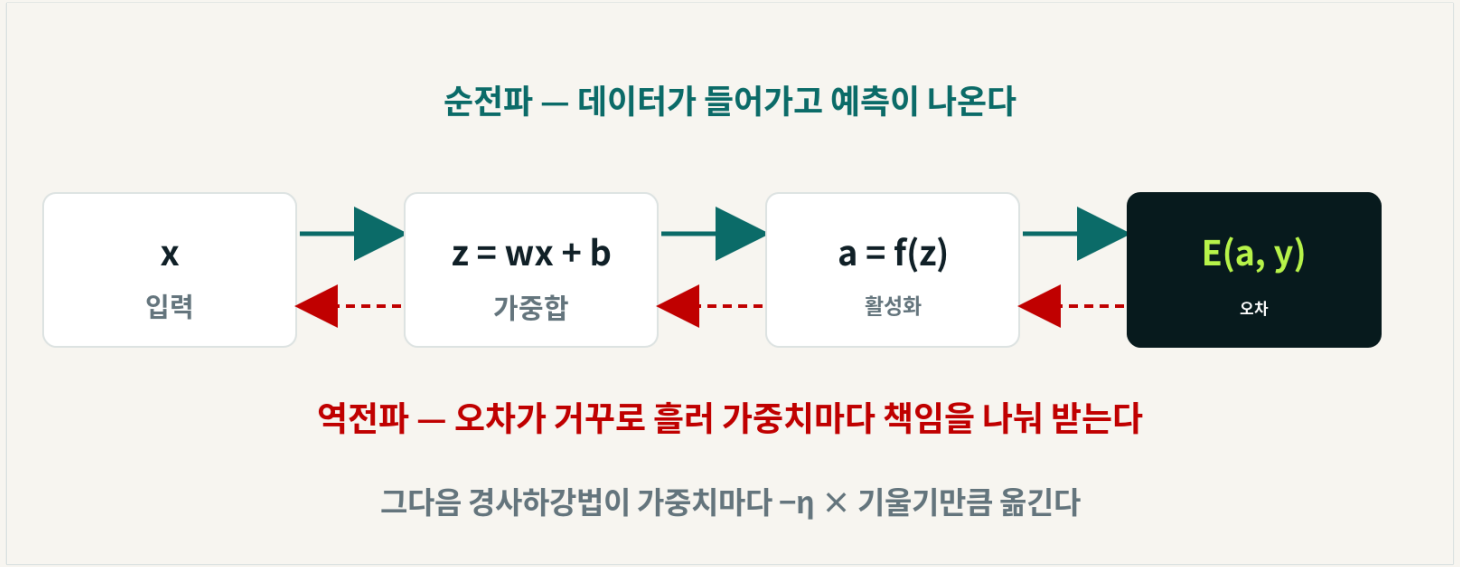
학습 손실이 튀다가 폭발하면 학습률을 줄인다.

역전파는 연쇄법칙으로 책임을 거꾸로 나눈다

순전파로 예측을 만들고, 역전파로 모든 가중치에 기울기를 준다

가중치 하나의 연쇄법칙

$$\frac{\partial E}{\partial w} = \frac{\partial E}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial w}$$



역전파 덕에 여러 층의 학습이 가능해졌다. 계산은 라이브러리가 해 준다.

빅데이터와 GPU가 이를 오늘의 딥러닝으로 만들었다.

깊은 신경망은 데이터가 많아야 한다 — 얇고 잡음 많은 표에는 단순한 모형이 낫다

데이터가 이렇다면	꺼낼 도구	이유
작고 잡음 많은 표 데이터	**XGBoost 또는 선형 모형**	**표본 효율적, 튼튼함, 설명 가능**
텍스트: 뉴스, 공시, 채팅	**신경망 → LLM**	**학습된 언어 표현**
이미지: 문서, 차트	**깊은 신경망 (CNN)**	**층이 모서리 → 모양 → 사물을 쌓는다**
울타리를 칠 '정상'이 풍부함	**오토인코더 (4번)**	**정상의 비선형 핵심을 배운다**

금융 데이터는 대개 얇고 잡음 많은 표다 — 거기선 아직도 XGBoost가 자주 이긴다.

오토인코더는 다시 만들지 못하는 것을 잡는다

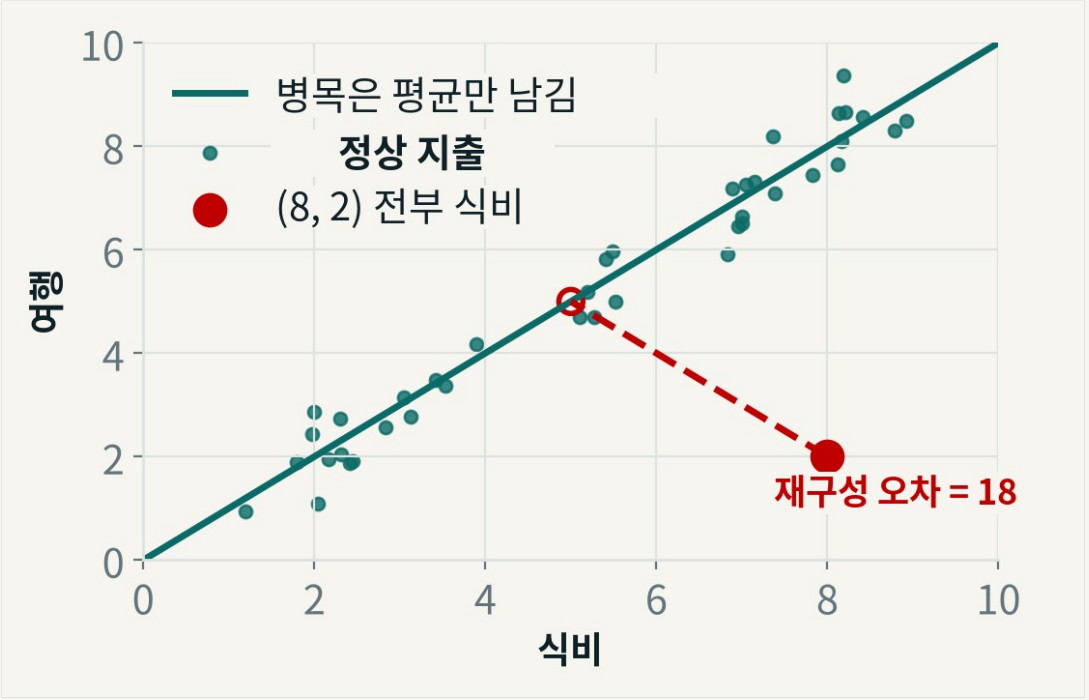
정상 데이터로만 학습 — 이상치 탐지기 4번. 정상 지출은 대각선 위에 놓인다

재구성 오차

$$e(\mathbf{x}) = \left\| \mathbf{x} - g\left(f(\mathbf{x})\right) \right\|^2$$

압축 → 재구성 → 비교

오차가 크면 = 이상



병목이 너무 넓으면 복사기: 이상치도 완벽히 재구성돼 탐지기가 눈이 먼다.

너무 좁으면 아무것도 안 맞는다. 정상이 겨우 맞을 때까지 조인다.

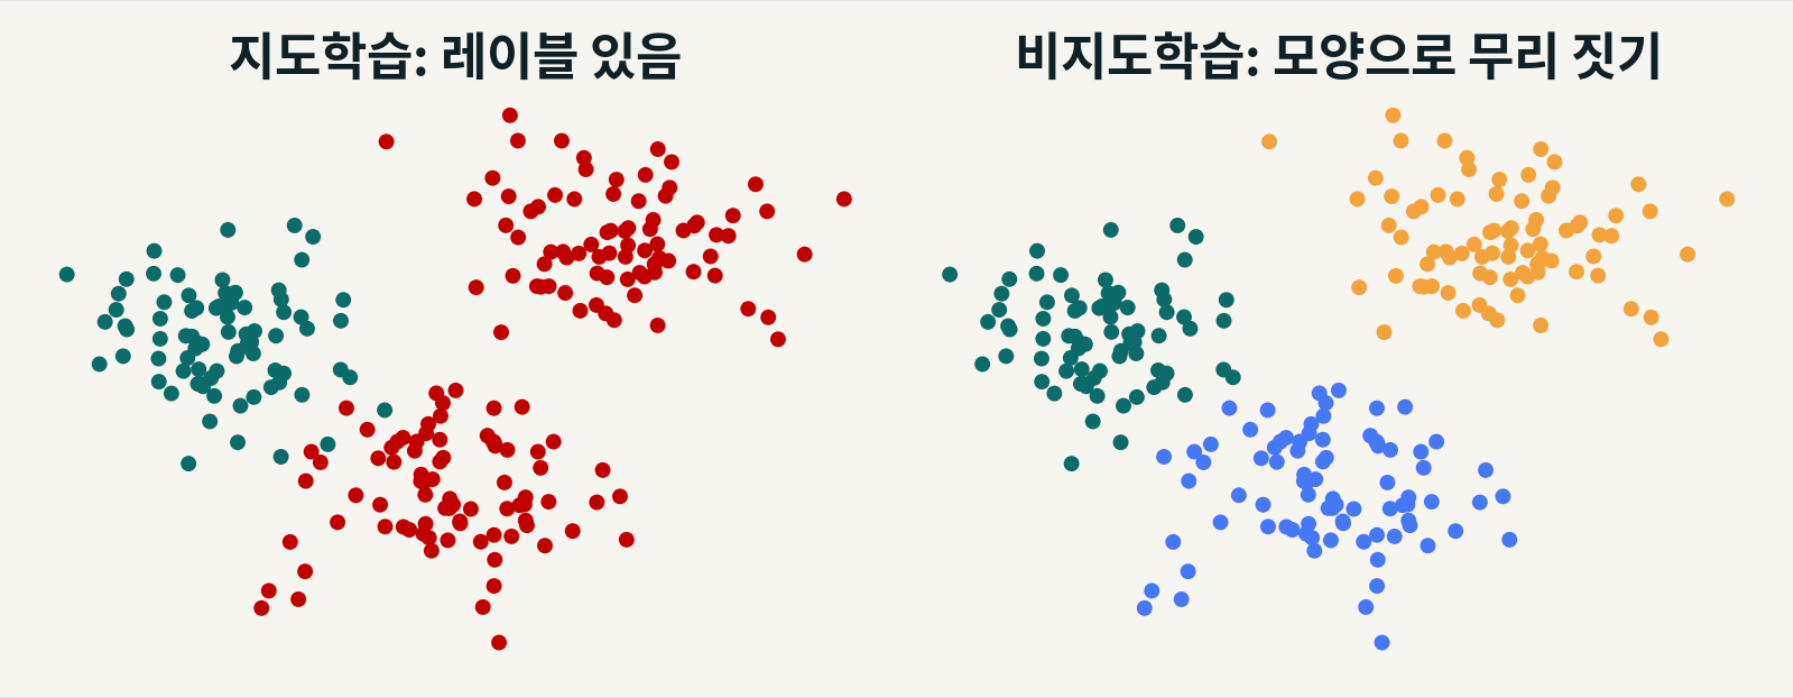
03

비지도학습

9주차 · 묶고, 압축하고, 잡음을 걷어 낸다 — 정답지 없이

레이블이 없으면 목표가 예측에서 구조로 바뀐다

같은 종류의 데이터: 왼쪽은 답이 주어지고, 오른쪽은 알고리즘이 무리를 찾는다



여기엔 F1이 없다: 구조가 말이 되고 쓸모 있는지로 판단한다.

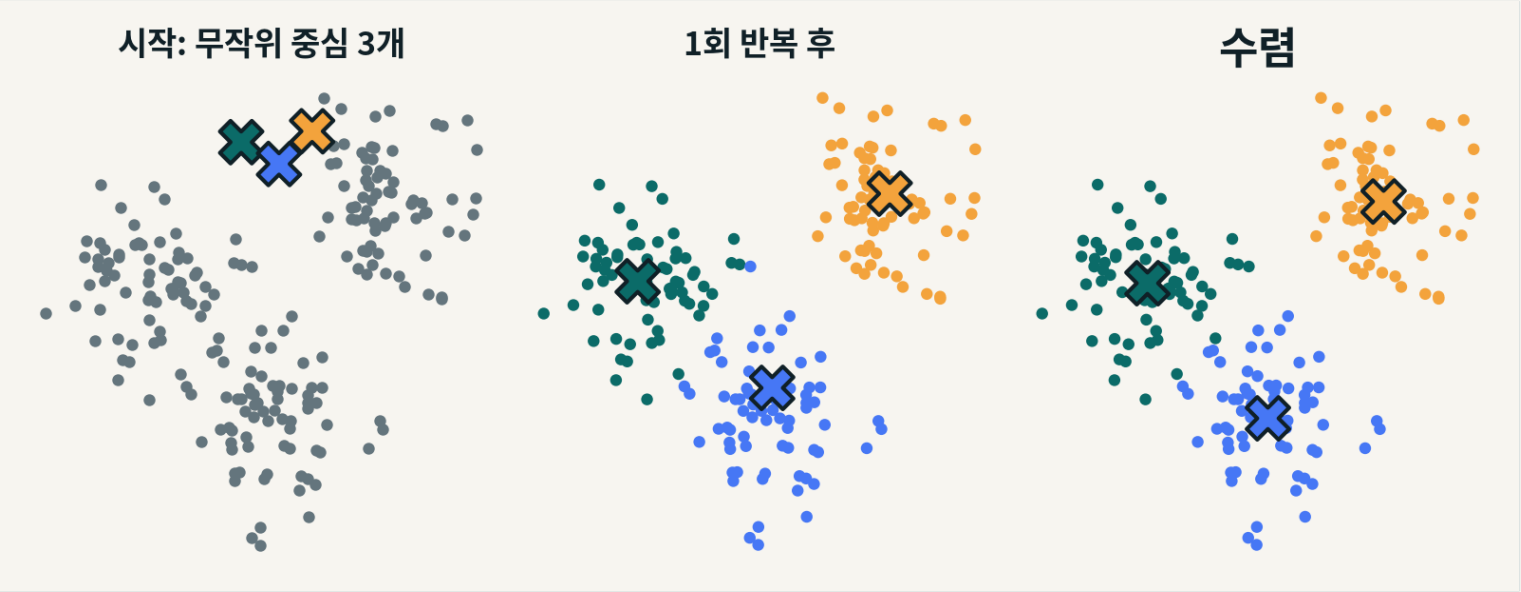
K-평균은 배정과 갱신을 번갈아 하며 더 움직이지 않을 때까지 돈다

점마다 가장 가까운 중심에 배정하고, 중심을 무리의 평균으로 옮기고, 반복

목적함수

$$J = \sum_{k=1}^{K} \sum_{i \in C_k} \|x_i - \mu_k\|^2$$

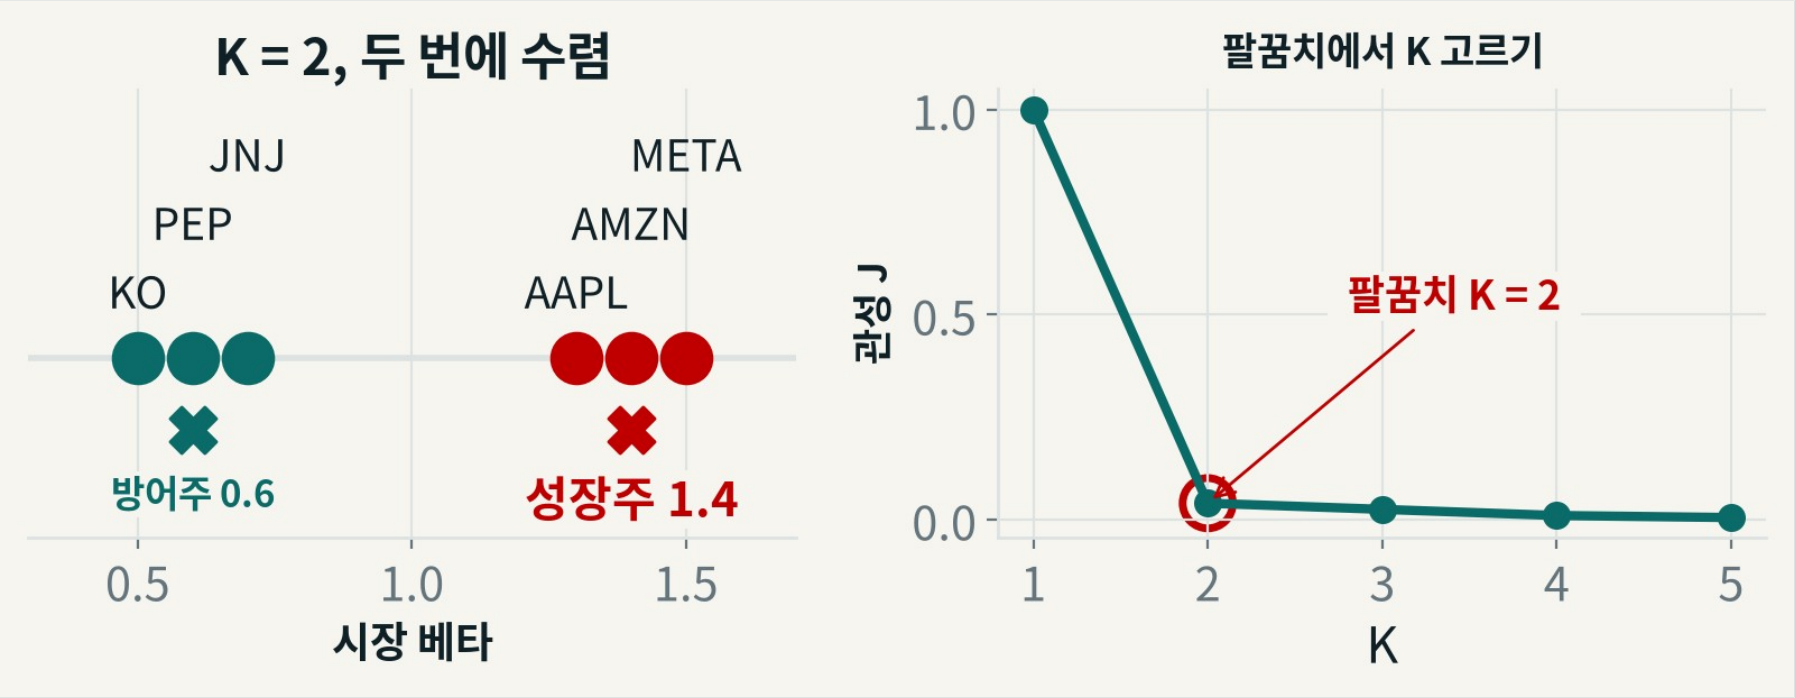
모든 점을 자기 중심에
가깝게
K는 직접 정해야 한다



한 바퀴마다 전체 거리는 줄기만 한다 — 그래서 중심이 자리를 잡는다.

K는 내가 고른다 — 팔꿈치가 멈출 곳을 알려 준다

시장 베타 기준 종목 6개, K = 2, 시작 중심 0.5와 1.5



관성은 K = 2에서 1.00 → 0.04로 떨어진 뒤 평평해진다: 방어주 대 성장주, 레이블 없이 찾았다.

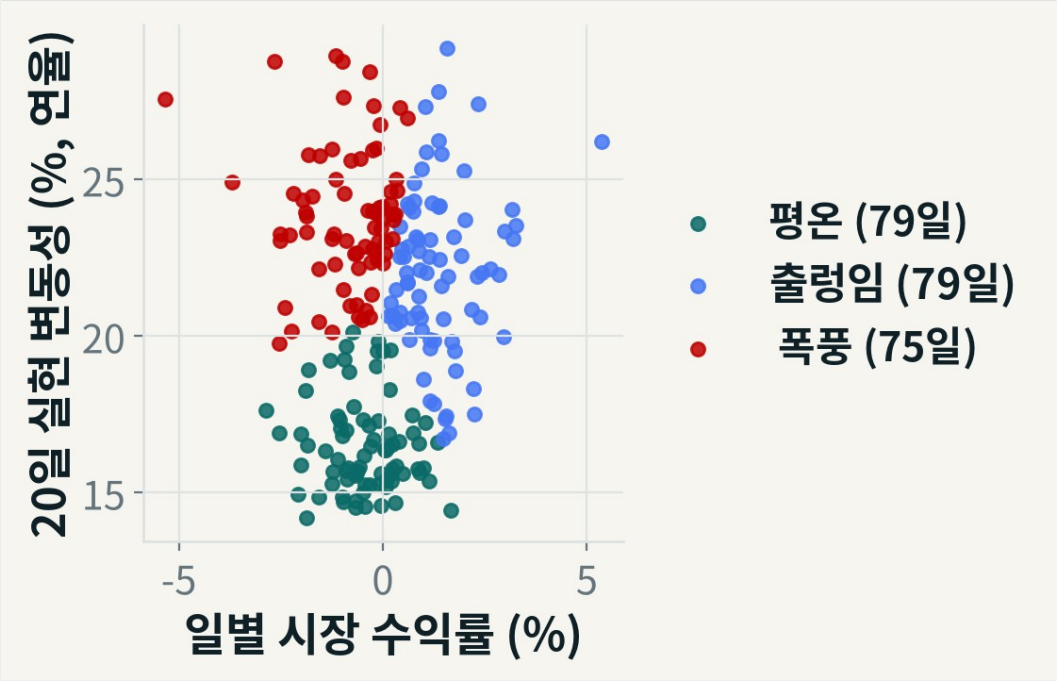
종목 대신 날을 묶으면 시장 국면이 드러난다

일별 (시장 수익률, 20일 실현 변동성)에 K-평균, K = 3 — 강의용 모의 패널

만드는 법

- 하루에 한 행
- 아무도 위기를 정의하지 않는다
- 폭풍 땐 규모를 줄인다

같은 알고리즘, 새 축



평온한 날로 학습한 모형은 폭풍에 무너진다 — 국면 군집이 언제 바꿀지 알려 준다.

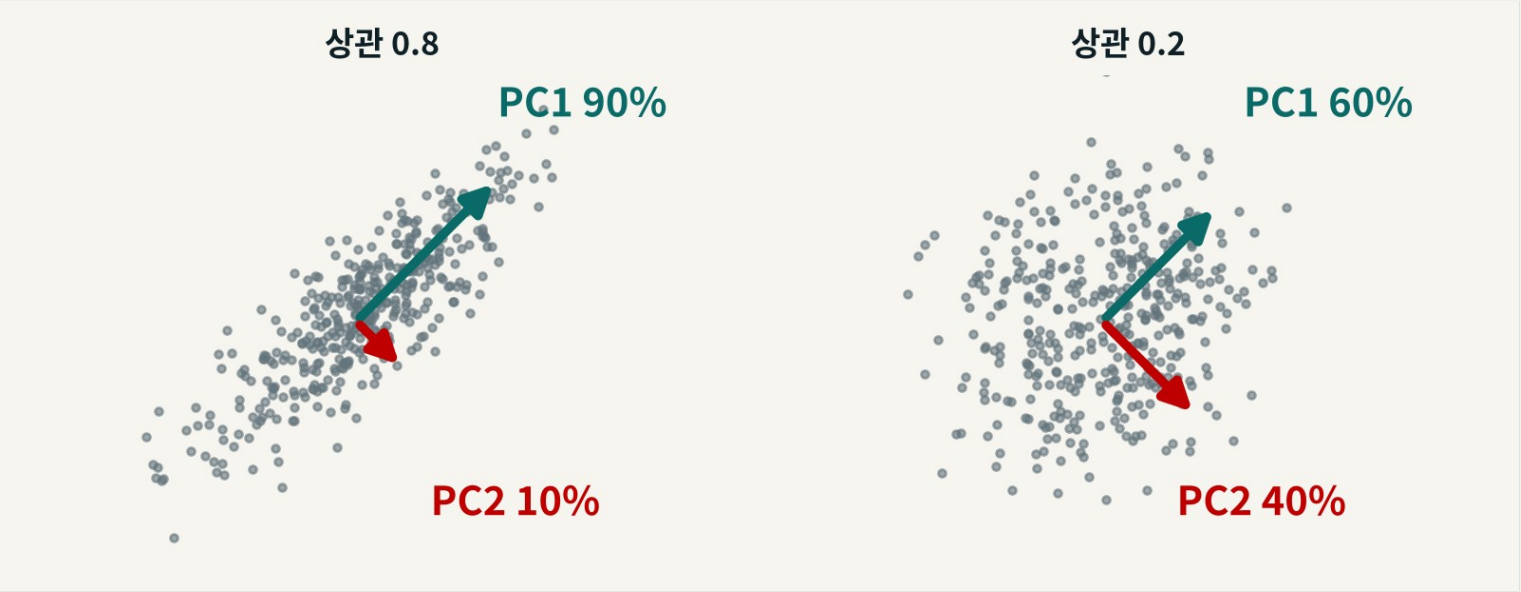
PCA는 퍼짐이 가장 큰 방향을 남긴다

두 종목: 상관이 강할수록 한 방향이 더 많이 담는다

방향과 그 몫

$$\Sigma v_k = \lambda_k v_k, \qquad \text{share}_k = \frac{\lambda_k}{\sum_j \lambda_j}$$

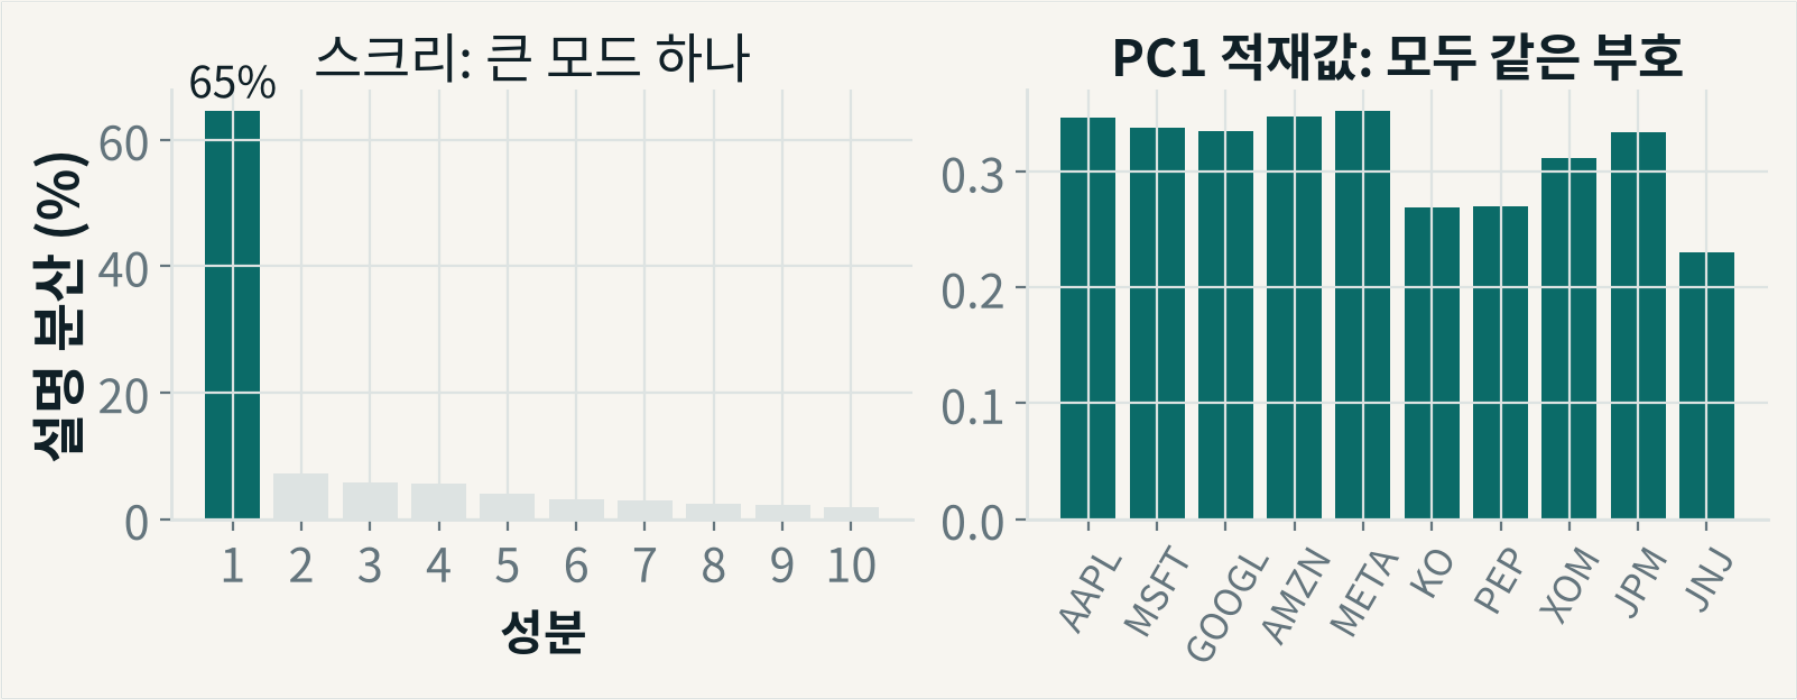
큰 고윳값 =
퍼짐이 크다
위의 몇 개만 남긴다



상관 0.8 → PC1이 90%, 0.2면 60%뿐. 변수들이 함께 움직일 때 압축이 값을 한다.

종목 패널에서 PC1은 시장 전체가 함께 움직이는 것이다

종목 10개 강의용 모의 패널, 252일

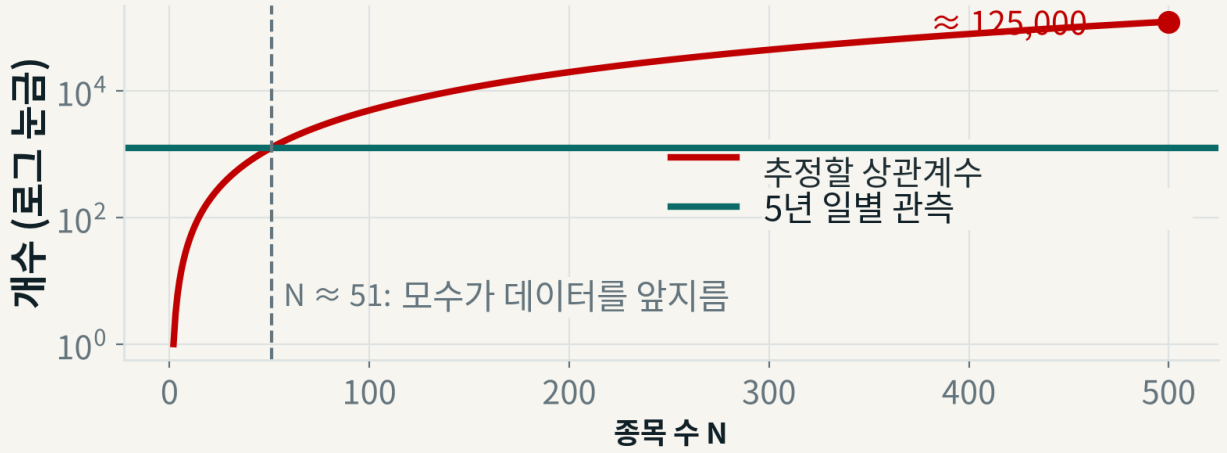


PC1이 65%를 설명하고 적재값은 모두 같은 부호, 나머지 꼬리는 잡음이다.

종목이 500개면 상관계수 하나하나가 거의 근거 없이 선다

추정할 상관계수 수 대 5년 치 일별 관측

종목 수	상관 쌍	거래일 (5년)	쌍당 일수
500	≈ 125,000	1,260	≈ 0.01



날것의 상관행렬은 대부분 통계적 신기루다 — 그리고 최적화기는 그것을 쫓는다.

마르첸코–파스투르 경계 아래의 고윳값은 잡음이다

종목 10개 강의용 모의 패널의 상관 고윳값, T = 252일

잡음 띠 (종목 N개, T일)

$$\lambda_{\pm} = \left(1 \pm \sqrt{N/T}\right)^2$$

같은 고윳값 2.5

강의 패널 1.44 → 신호

대형 펀드 2.66 → 잡음

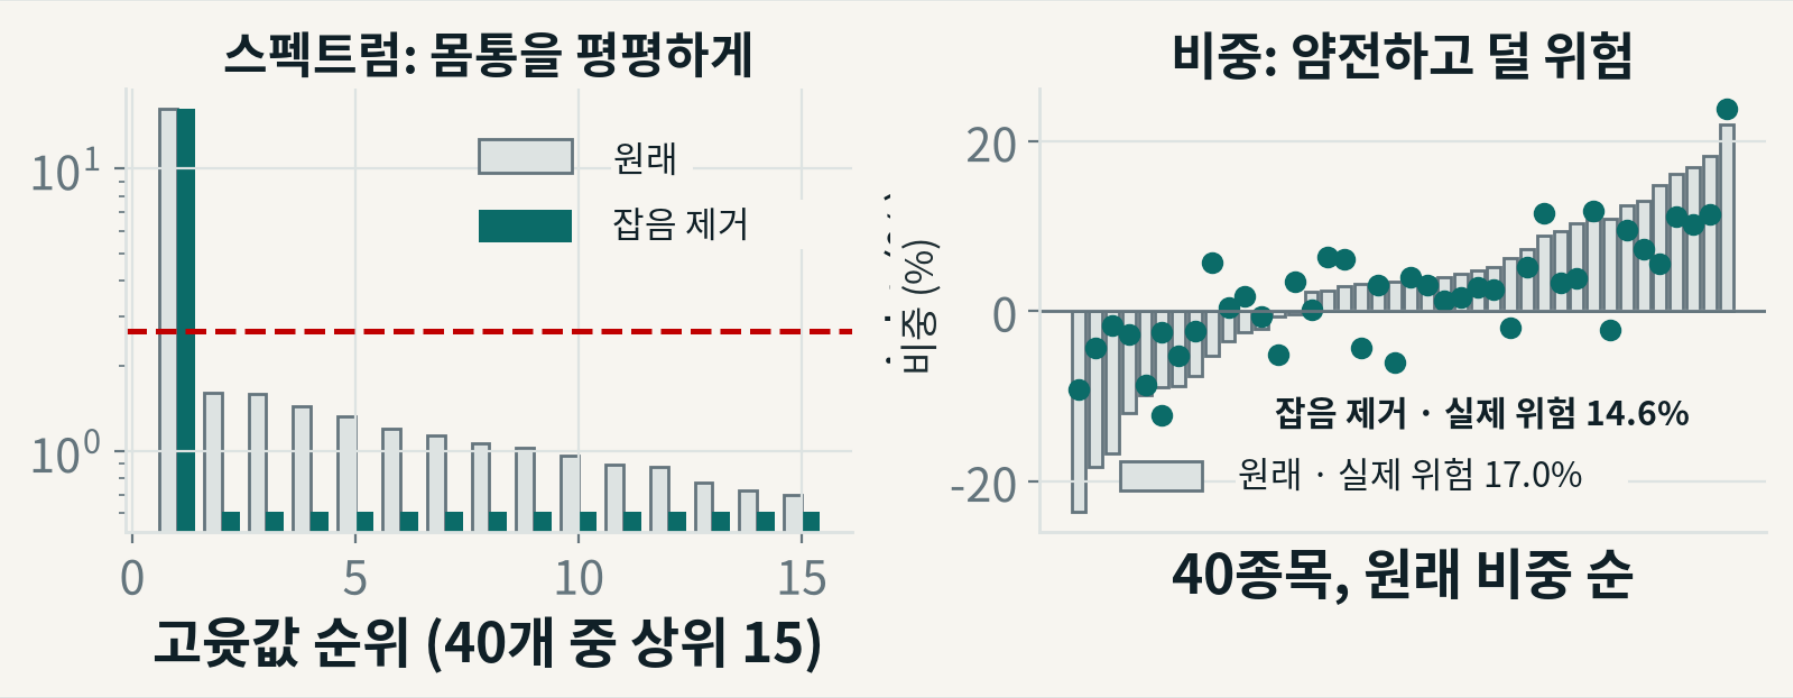


고윳값 10개 중 1개(6.46)만 경계 1.44를 넘는다 — 시장 모드다.

같은 기간에 종목을 늘리면 경계가 올라간다: 어제의 신호가 무리 속에 묻힌다.

최적화기가 보기 전에 스펙트럼의 잡음을 걷어 낸다

모의 40종목 × 100일: 대각화 → 경계 아래 고윳값 평평하게 → 재구성 → 최적화



더 상식적인 비중, 더 낮은 실제 위험(17.0% → 14.6%) — 11주차 HRP · NCO에 이것을 넣는다.

04

치트 시트

7–9주차 · 핵심 수식, 다이얼, 탐지기, 그리고 도구 고르기

핵심 수식, 7–8주차

지니 불순도 (7주)

$$G = 1 - \sum_k p_k^2$$

숲의 분산 (7주)

$$\mathrm{Var}\left[\hat{f}_{\mathrm{bag}}\right] = \rho\,\sigma^2 + \frac{1-\rho}{B}\,\sigma^2$$

부스팅 갱신 (7주)

$$F_m(x) = F_{m-1}(x) + \eta\, h_m(x)$$

뉴런 (8주)

$$\hat{y} = f\left(\mathbf{w}^\top \mathbf{x} + b\right)$$

경사하강 한 걸음 (8주)

$$w \;\leftarrow\; w - \eta\,\frac{\partial E}{\partial w}$$

오토인코더 재구성 오차 (8주)

$$e(\mathbf{x}) = \left\| \mathbf{x} - g\left(f(\mathbf{x})\right) \right\|^2$$

순수한 분할 · 다양한 트리 · 작은 보정 · 조심스러운 걸음

핵심 수식, 9주차

K-평균 목적함수

$$J = \sum_{k=1}^{K} \sum_{i \in C_k} \|x_i - \mu_k\|^2$$

PCA

$$\Sigma v_k = \lambda_k v_k, \qquad \text{share}_k = \frac{\lambda_k}{\sum_j \lambda_j}$$

마르첸코–파스투르 잡음 경계

$$\lambda_{\pm} = \left(1 \pm \sqrt{N/T}\right)^2$$

잡음 제거 규칙

$$\tilde{\lambda}_k = \bar{\lambda}_{\text{noise}} \quad \text{if } \lambda_k \le \lambda_+$$

K는 팔꿈치로 · PCA는 위의 고윳값 · 최적화 전에 MP 경계

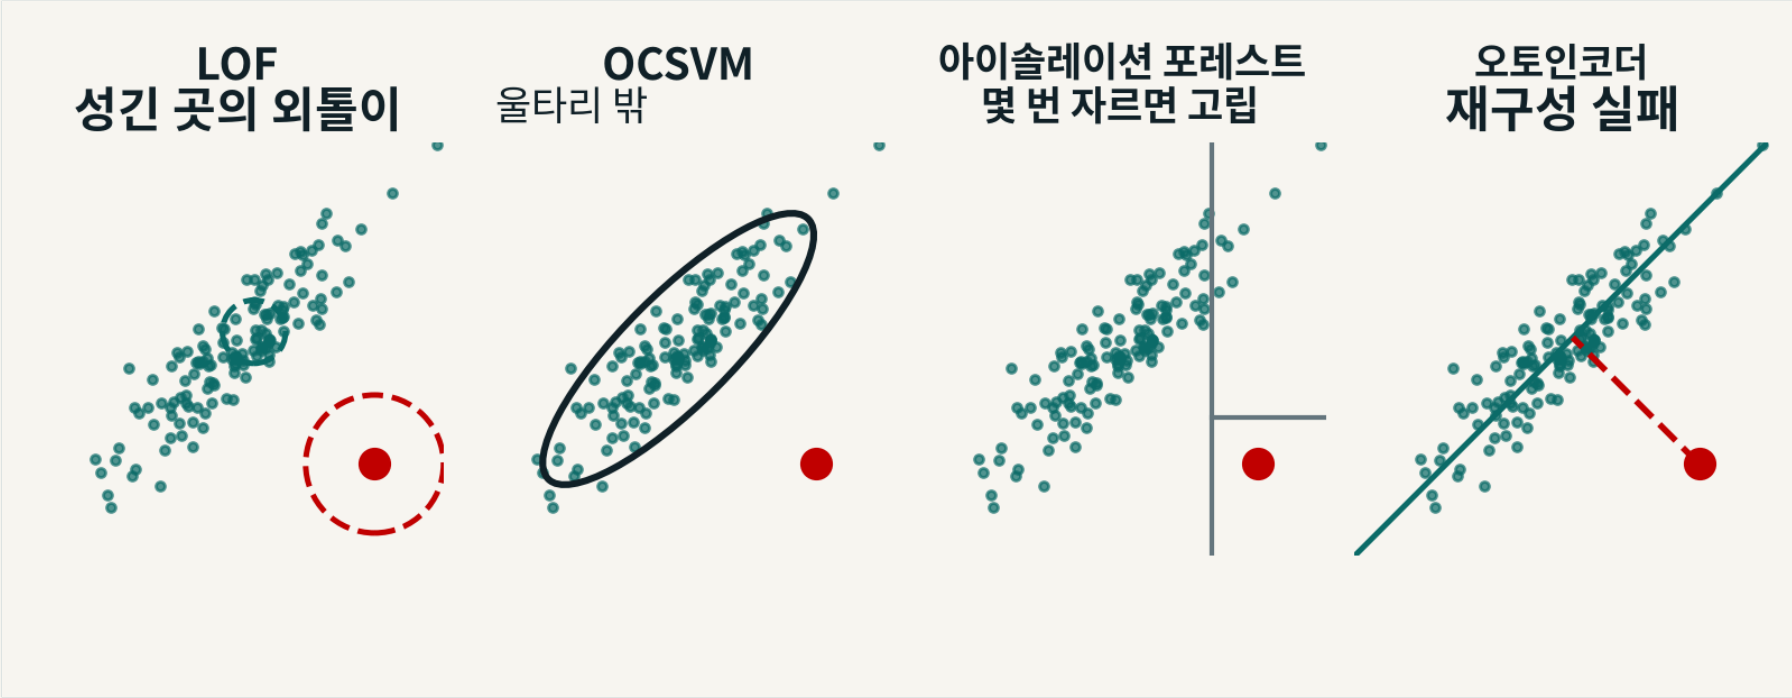
U자 곡선 하나, 의상은 여럿: 유연함은 증거로 값을 치러야 한다

다이얼	주차	너무 작으면	너무 크면
max_depth (트리)	**7**	**실제 구조를 놓친다**	**대출 하나에 잎 하나**
학습률	**7–8**	**학습이 기어간다**	**지나쳐서 발산**
병목 크기	**8**	**경보가 끊이지 않는다**	**복사기, 탐지기 눈멂**
K (군집 수)	**9**	**다른 것끼리 뭉뚱그림**	**잡음이 제 동아리를 차림**
남기는 성분 수	**9**	**신호를 버린다**	**잡음을 남긴다**

검증 데이터로 다이얼을 돌려 본다 — 레이블이 없으면 팔꿈치를 읽는다.

이상치 탐지기 넷은 '이상함'을 네 가지로 본다

같은 데이터, 같은 빨간 점 — LOF (5주) · OCSVM (6주) · 아이솔레이션 포레스트 (7주) · 오토인코더 (8주)



최고의 탐지기는 하나가 아니다 — 은행은 여럿을 돌려 서로의 사각지대를 메운다.

실전 사기 탐지 시스템은 거르고, 점수 매기고, 설명하는 단계를 쌓는다

7–8주차 도구마다 파이프라인 안에 자리가 있다

1단계 · 빠른 거르기

iForest + OCSVM

확실히 정상인 건 통과

→

2단계 · 날카로운 모형

XGBoost

사기 확률

→

3단계 · 설명

SHAP (14주)

금액 + 위치 + 시각

빠르게 거르고 → 날카롭게 점수 매기고 → 분명하게 설명한다.

증상에 맞는 도구를 고른다

증상	도구
감독 당국이 거절 한 건을 단계별로 추적해야 한다	얕은 트리 하나
튼튼한 기준 모형이 빨리 필요하다	랜덤 포레스트
레이블 없는 1,000만 행, 점심까지 이상치를	아이솔레이션 포레스트
학습 손실이 튀다가 폭발한다	학습률을 낮춘다
최적화기가 극단적인 비중을 쏟아 낸다	공분산의 잡음부터 걷어 낸다

먼저 진단하고, 그다음 도구를 꺼낸다.

나무 한 그루는 외운다.

다양한 팀은 일반화한다.

최적화하기 전에 구조를 정리한다.

트리 · 신경망 · 구조
7–9주차