비지도학습
묶기, 줄이기, 걸러내기

정답이 없을 때 구조 찾기

원 수익률

↓

그룹

↓

소수 팩터

↓

깨끗한 행렬

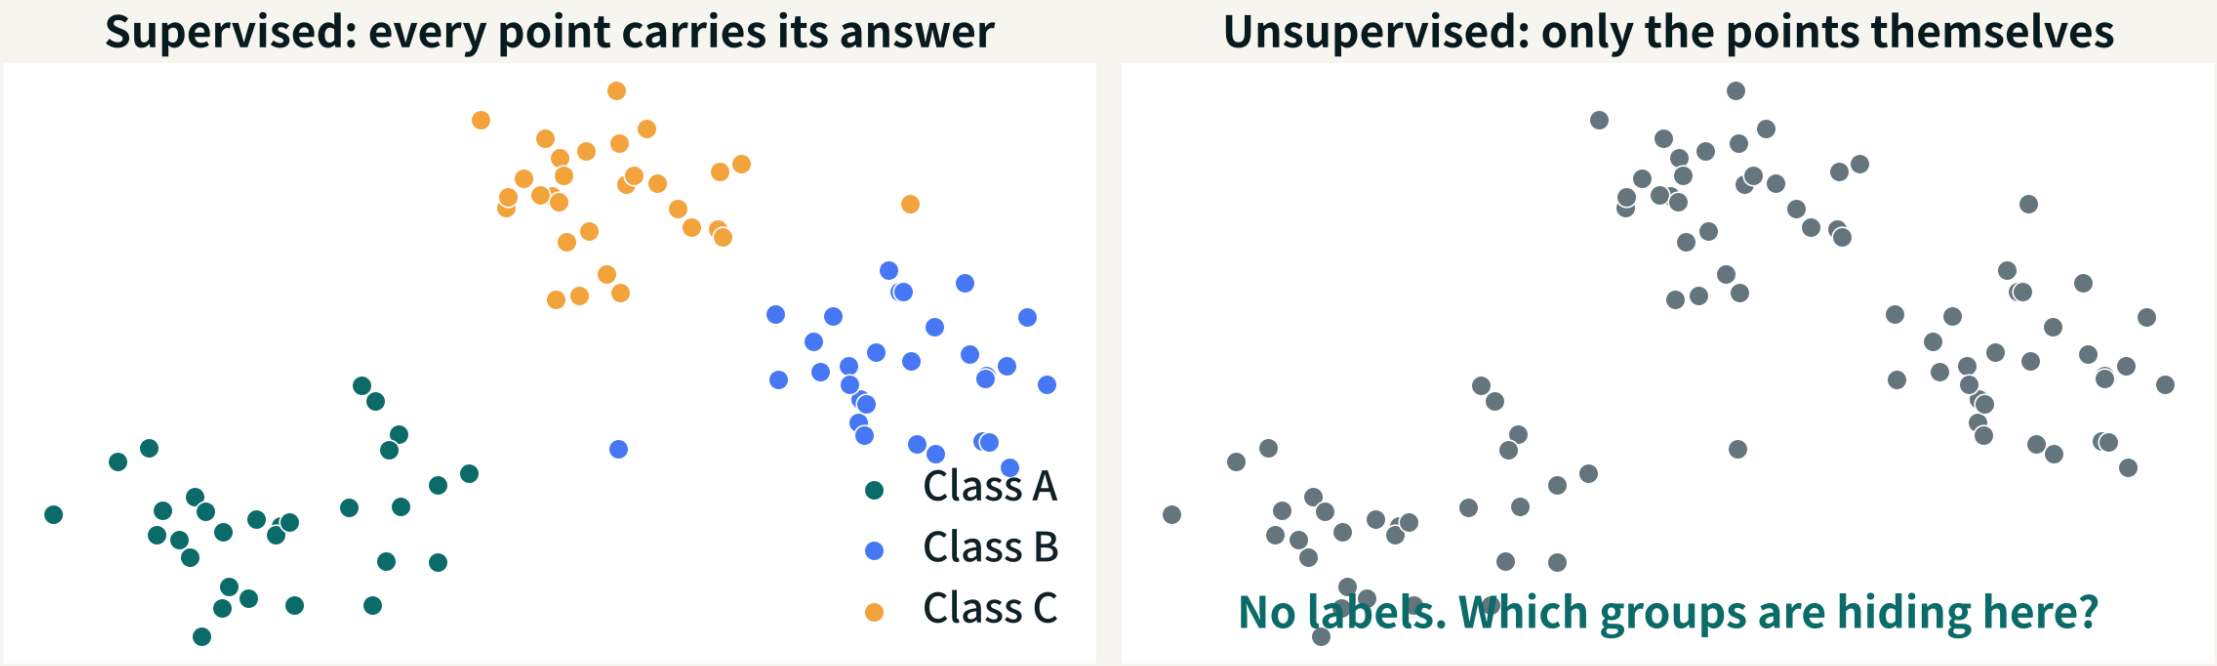
금융 머신러닝 · 9단원

세 가지 일과 실습 하나

01	그룹 찾기	**행을 묶는다** K-평균 · 계층적 군집 · DBSCAN
02	특성 줄이기	**열을 압축한다** 차원의 저주 · PCA · t-SNE
03	잡음 걸러내기	**상관행렬을 고친다** 추정 격차 · 마르첸코–파스투르 · 잡음 제거
04	Claude Code로 만들기	**프롬프트 세 개로 모든 그림을** 어디서 · 입력 · 출력 · 피드백

비지도학습은 정답 없이 작동한다

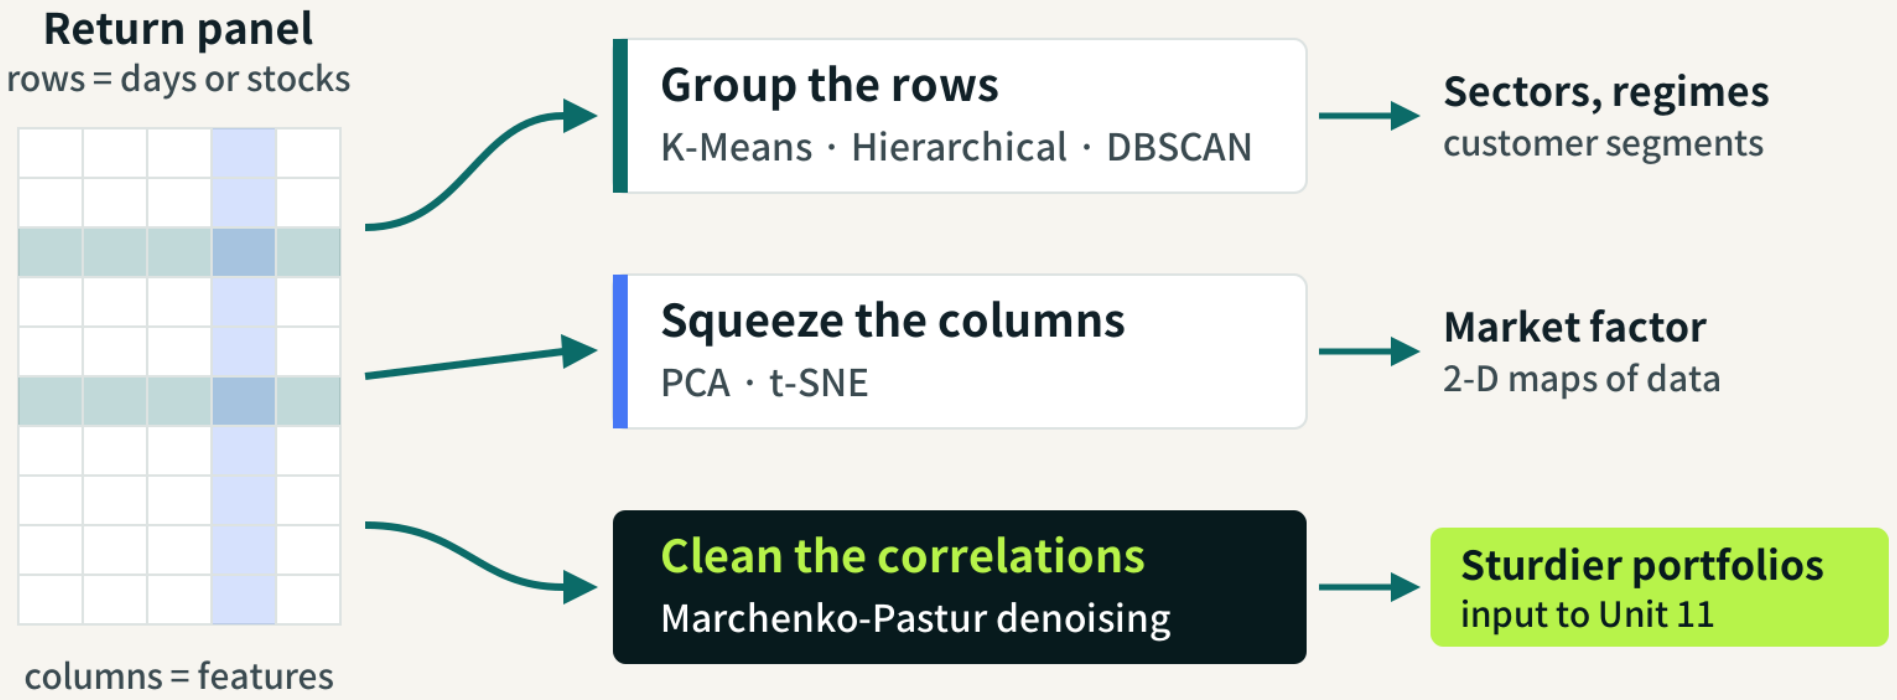
같은 점, 두 상황: 레이블이 있을 때(왼쪽)와 없을 때(오른쪽)



※ 여기에는 정확도 점수가 없다. 결과는 구조가 말이 되고 쓸모가 있는지로 판단한다.

도구마다 데이터의 다른 부분을 다룬다

행은 묶고, 열은 압축하고, 상관행렬은 걸러낸다



01

그룹 찾기

K-평균 · 계층적 군집 · DBSCAN

K-평균은 각 그룹 중심까지의 거리를 최소화한다

중심(centroid) = 그룹의 평균점, K = 직접 정하는 그룹 수

최소화하는 것

$$J = \sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

중심을 갱신하는 법

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

단계 A

배정

가장 가까운 중심에 붙는다

단계 B

갱신

그룹 평균으로 옮긴다

멈춤

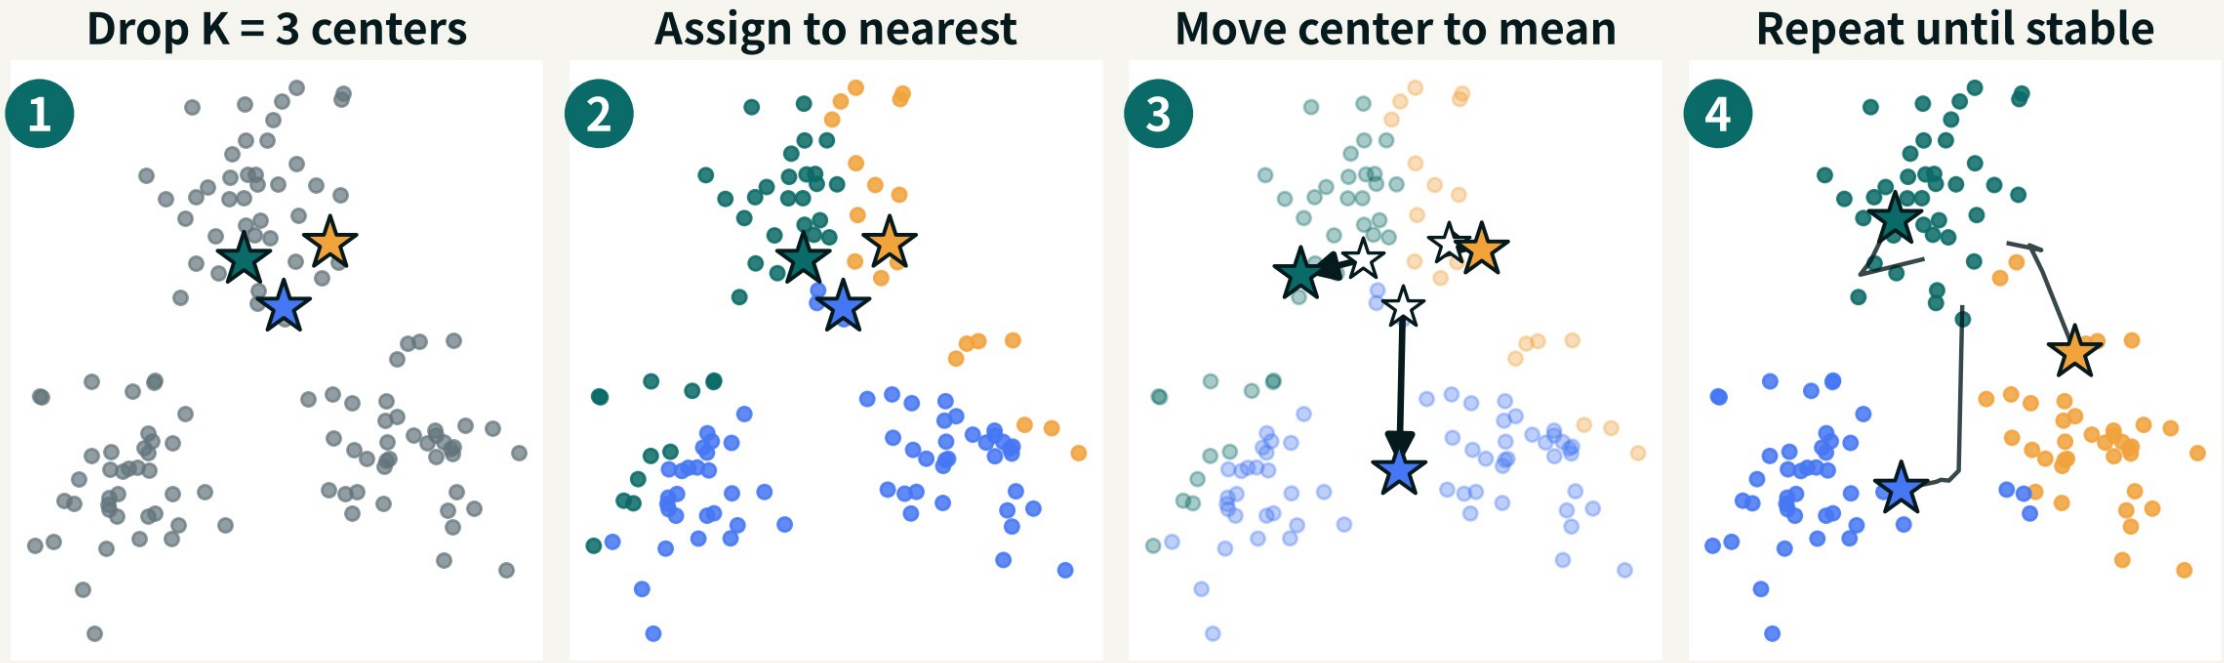
수렴

그룹을 바꾸는 점이 없다

두 단계 모두 J를 낮추기만 하므로 반복은 반드시 멈춘다.

K-평균은 변화가 없을 때까지 두 동작을 번갈아 한다

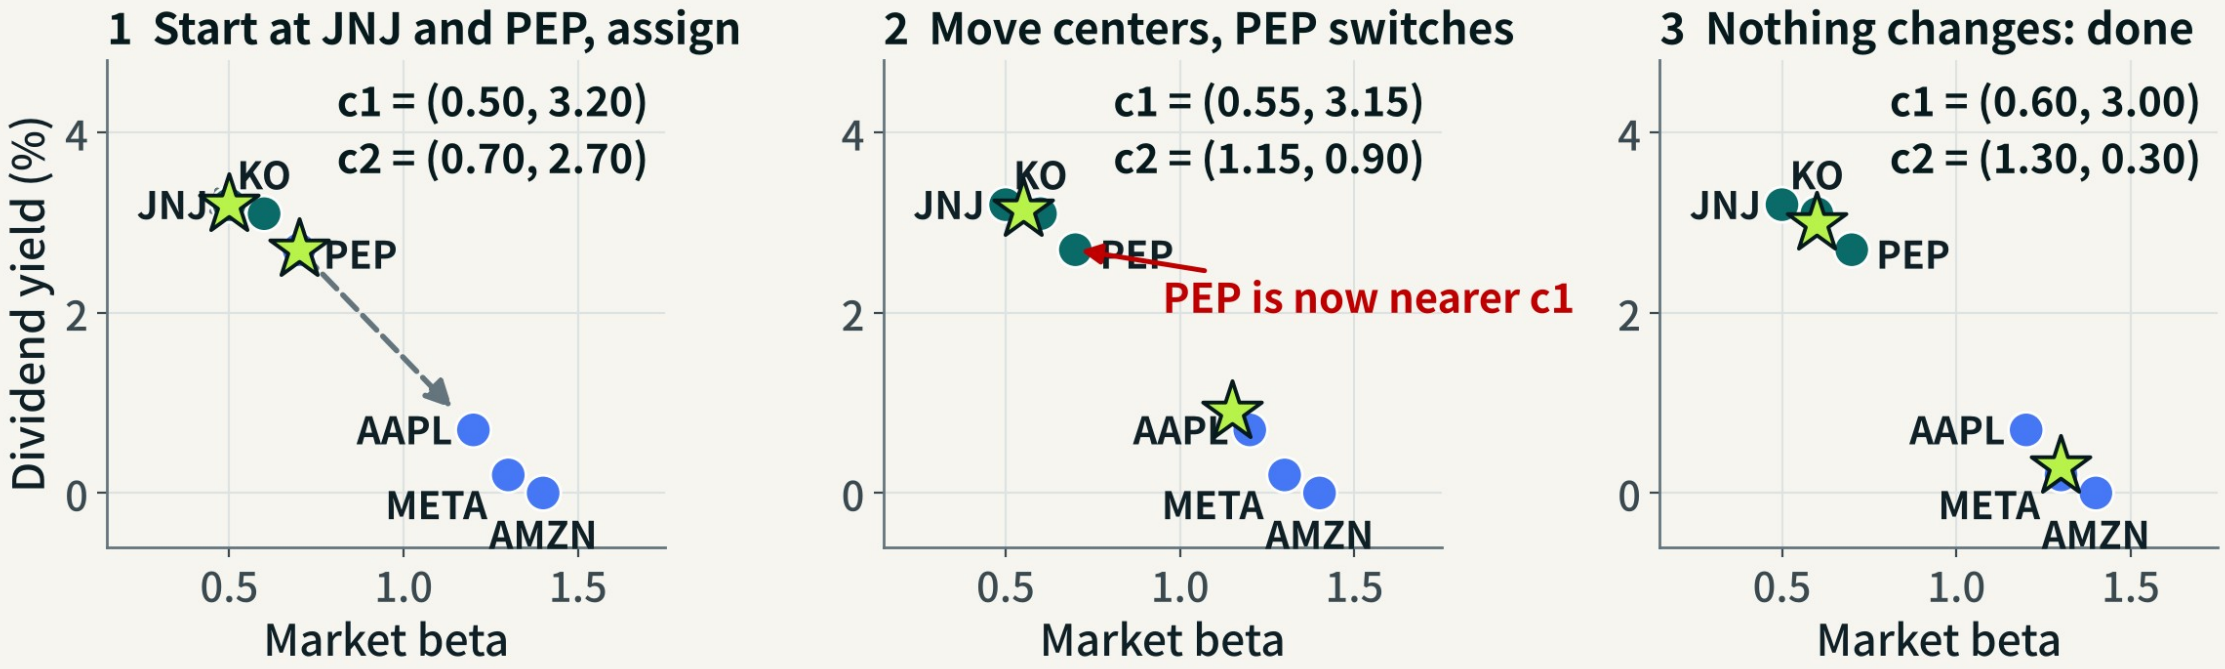
숨은 그룹 셋이 있는 2차원 모의 데이터, 일부러 나쁜 출발점



※ 패널 4는 각 중심의 이동 경로다. 실제로는 10번 다시 시작해(n_init = 10) J가 가장 작은 결과를 쓴다.

여섯 종목을 두 특성으로 방어주와 성장주로 나눈다

시장 베타와 배당수익률(%). K = 2, 시작 중심은 JNJ와 PEP 위치



※ 2단계: PEP의 제곱거리는 c1까지 0.23, c2까지 3.44이므로 그룹을 옮긴다. 예시 수치.

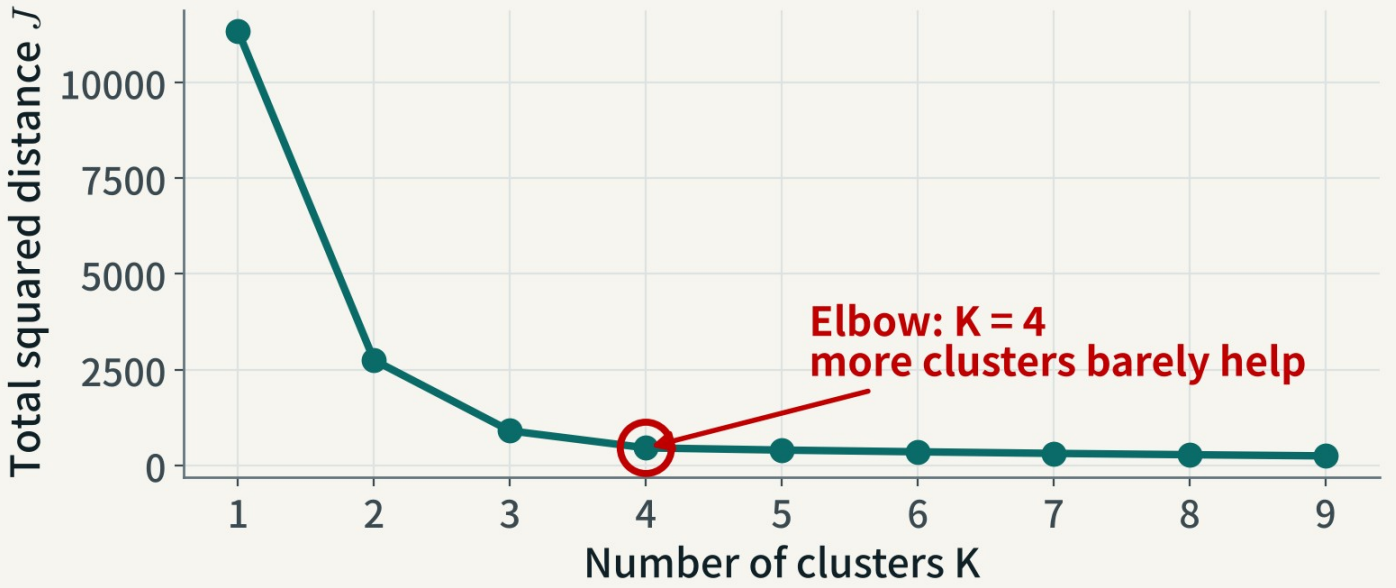
엘보는 그룹을 더 늘려도 이득이 없는 K를 고른다

K가 늘면 J는 늘 줄어든다. 최솟값이 아니라 꺾이는 곳을 본다

곡선 읽기

- K가 너무 적으면: 뭉침
- K가 너무 많으면: 잡음까지 쪼갬
- 꺾이는 곳: 실제 그룹

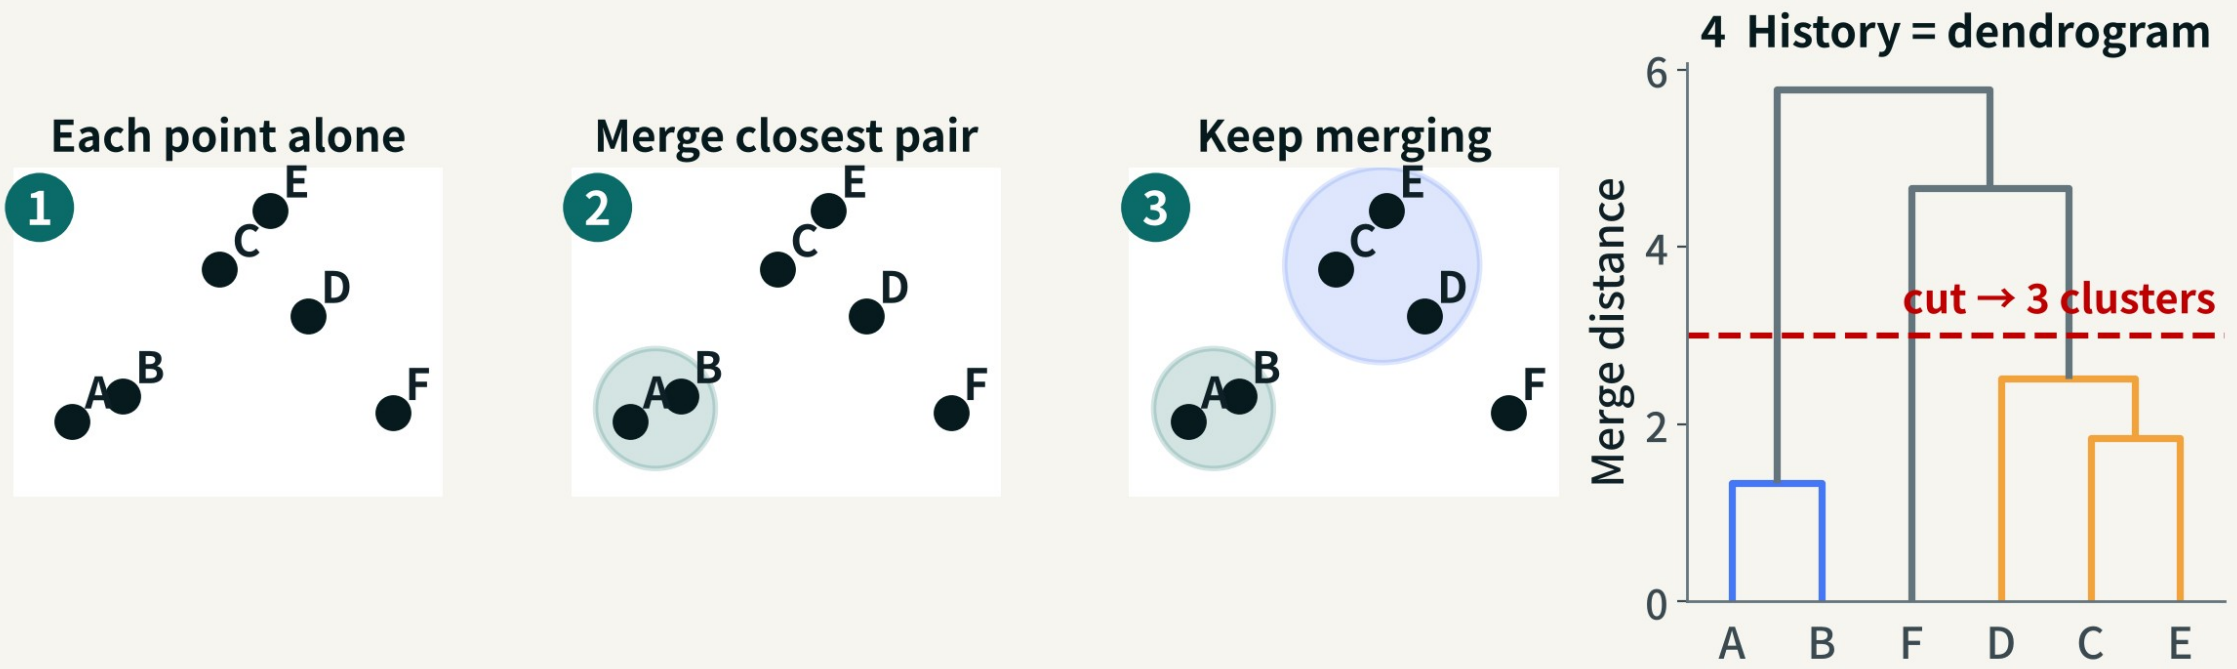
엘보 + 상식



※ Simulated data with four true groups

계층적 군집은 가장 가까운 그룹을 차례로 합친다

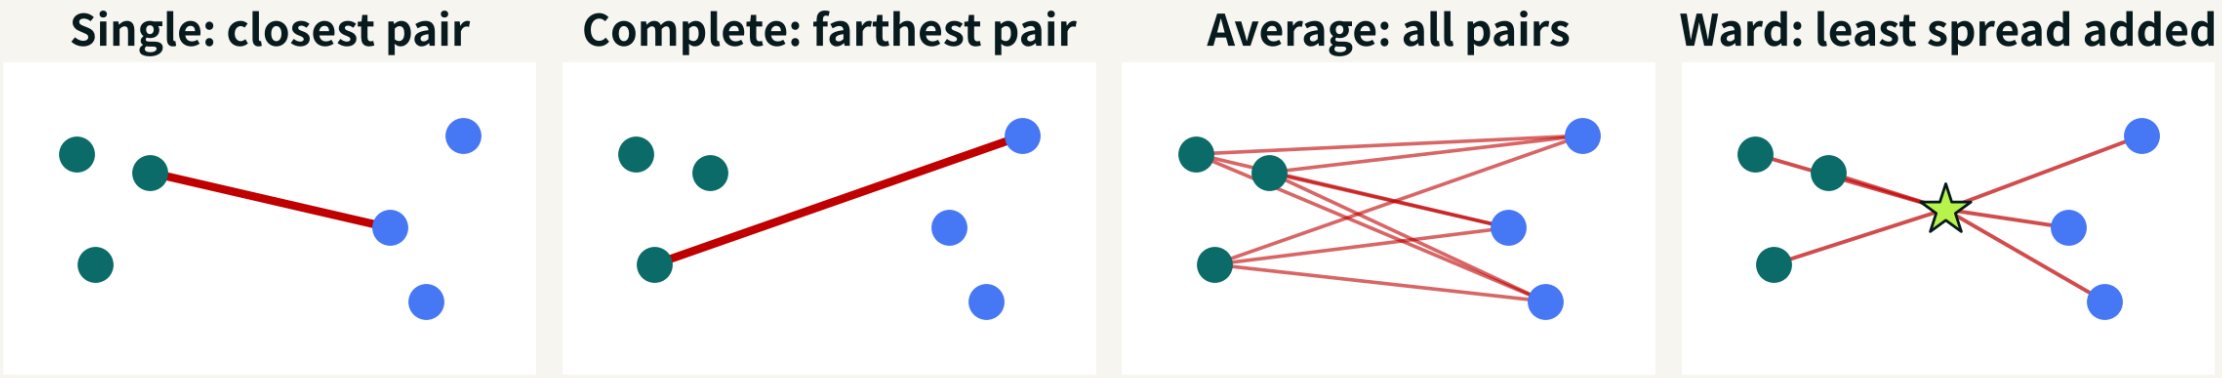
병합형(상향식): 점 N개에서 시작해 그룹 하나가 남을 때까지 합친다



※ 각 연결의 높이 = 두 그룹이 합쳐진 거리. 나무를 잘라 군집 수를 정한다.

연결 규칙이 두 그룹 사이 거리를 정한다

점 사이 거리는 재기 쉽지만 그룹 사이에는 규칙이 필요하다. 빨간 선이 각 규칙이 재는 것이다



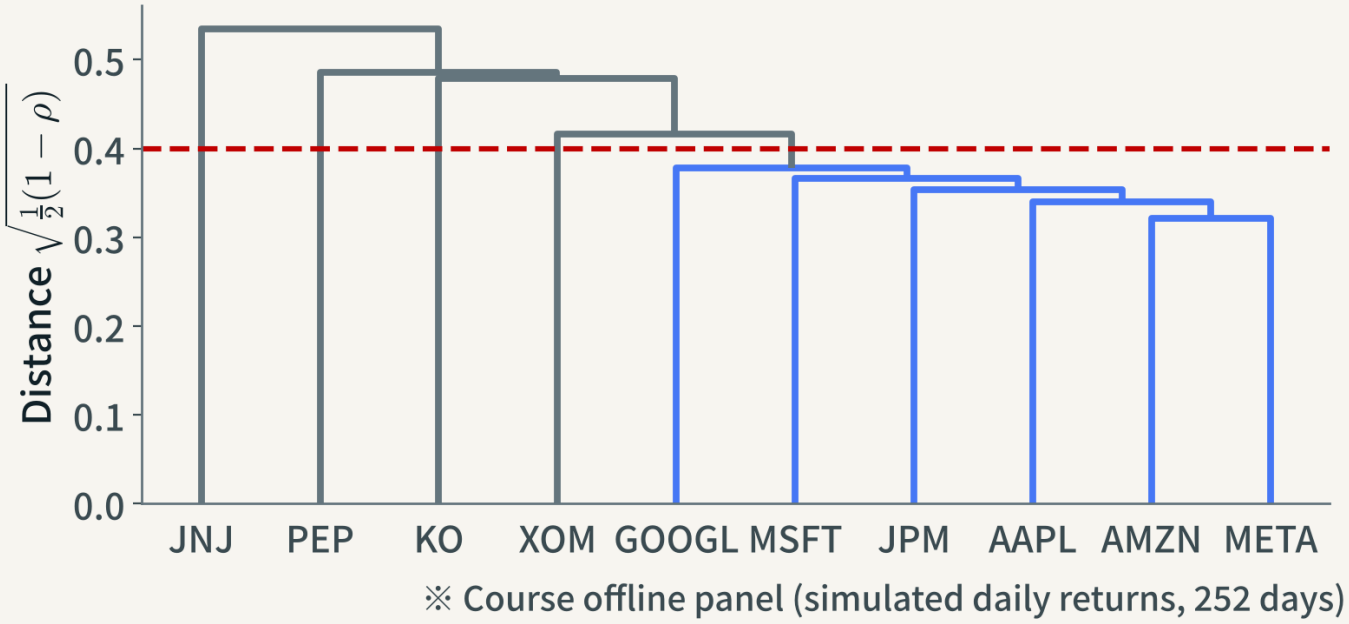
※ 단일 연결은 긴 사슬을 만들고, 완전 연결은 그룹을 촘촘히 유지하며, Ward가 보통 기본값이다.

상관 거리로 수익률 패널을 종목 계보도로 바꾼다

함께 움직이는 종목이 가까이 놓인다. López de Prado(2016)는 11단원 HRP에서 이 거리를 쓴다

상관 거리

$$d_{ij} = \sqrt{\frac{1}{2}\left(1 - \rho_{ij}\right)}$$



ρ = 1이면 거리 0, ρ = −1이면 거리 1.

나무를 자르면 업종과 비슷한 그룹이 나타난다.

DBSCAN은 밀집한 영역을 군집으로 본다

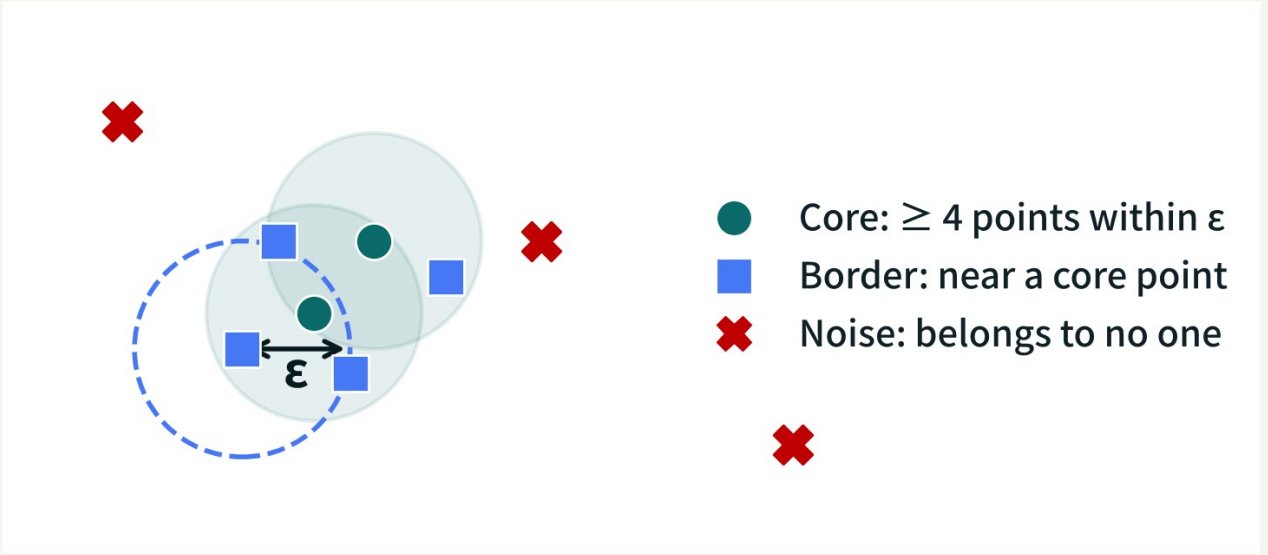
잡음을 고려한 밀도 기반 공간 군집(Ester 외, 1996)

점 p의 ε-이웃

$$N_\varepsilon(p) = \{\, q : \|p - q\| \le \varepsilon \,\}$$

핵심점 규칙

$$|N_\varepsilon(p)| \ge \text{minPts} \;\Rightarrow\; p \text{ is a core point}$$

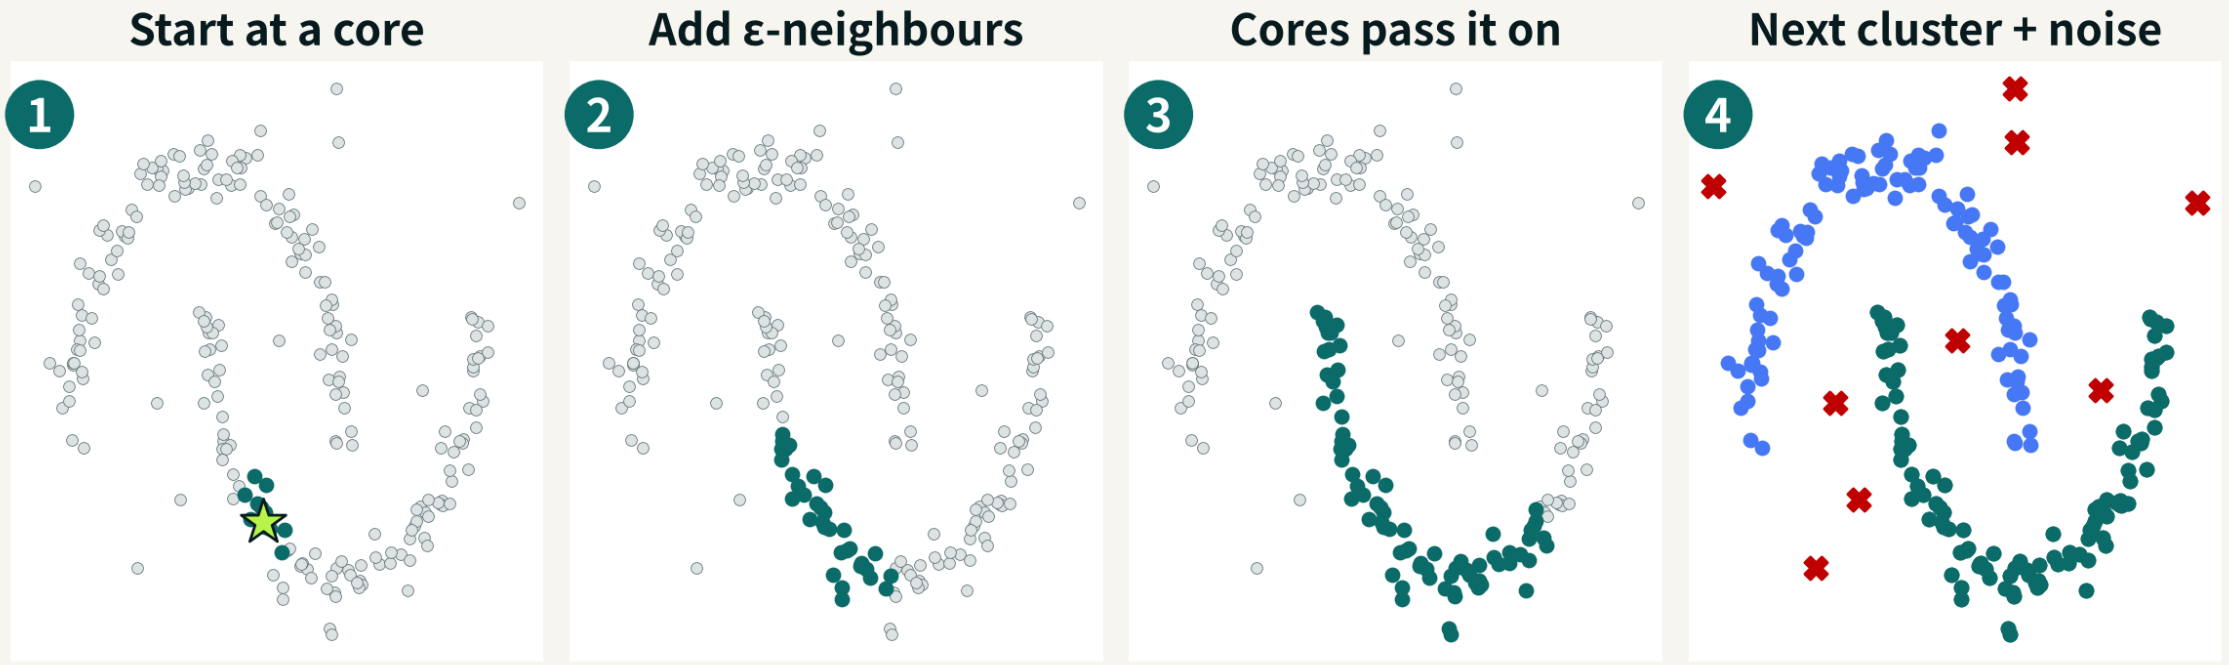


※ minPts = 4 (the point itself counts)

손잡이는 ε과 minPts 두 개. 정할 K가 없다.

DBSCAN 군집은 핵심점에서 핵심점으로 자란다

맞물린 반달 두 개와 흩어진 이상치, ε = 0.2, minPts = 5

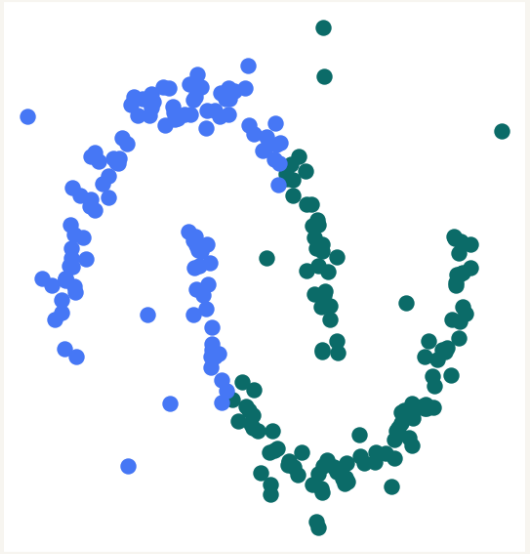


※ 어떤 핵심점에서도 닿지 않는 점은 잡음(−1)으로 표시한다. 금융에서는 이상한 날, 이상한 거래.

알고리즘마다 보는 군집 모양이 다르다

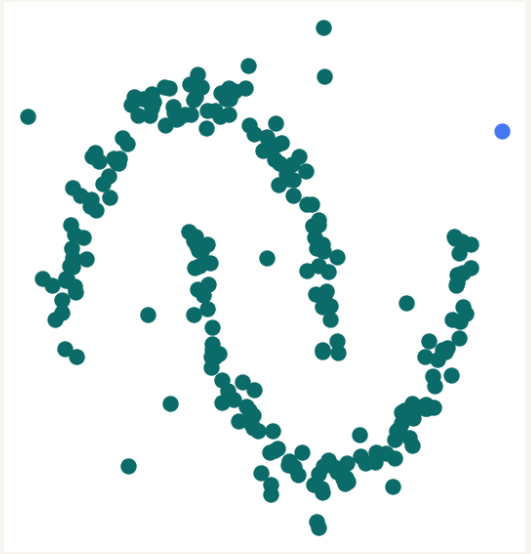
같은 데이터, 세 알고리즘. 색 = 군집, 빨간 X = 잡음

K-Means (K = 2)



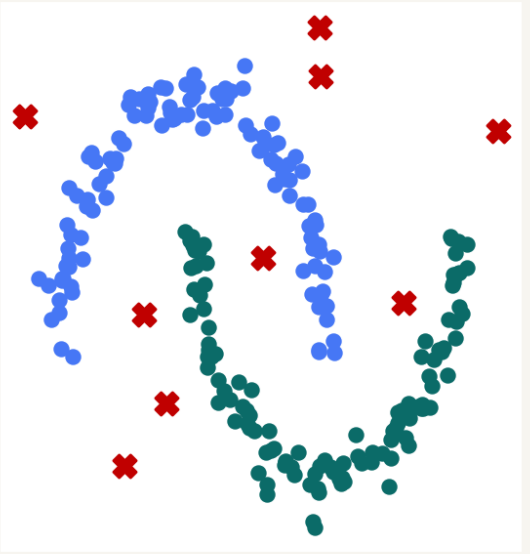
Cuts straight through the moons

Hierarchical (single linkage)



Follows the chain, but noise sticks

DBSCAN (ε = 0.2, minPts = 5)



Right shapes and noise flagged

미리 아는 것에 따라 군집 방법을 고른다

목표는 같고, 그룹의 모양과 수에 대한 가정이 다르다

방법	K를 정하나?	찾는 모양	이상치	금융 활용
K-평균	예	둥근 덩어리	억지로 편입	국면, 세그먼트
계층적	나중에 자름	그룹의 나무	억지로 편입	종목 나무, HRP
DBSCAN	아니오(ε, minPts)	밀집한 어떤 모양이든	표시	이상한 날, 사기 탐지

어떤 방법도 늘 옳지는 않다.

그룹이 경제적으로 말이 되는지 확인한다.

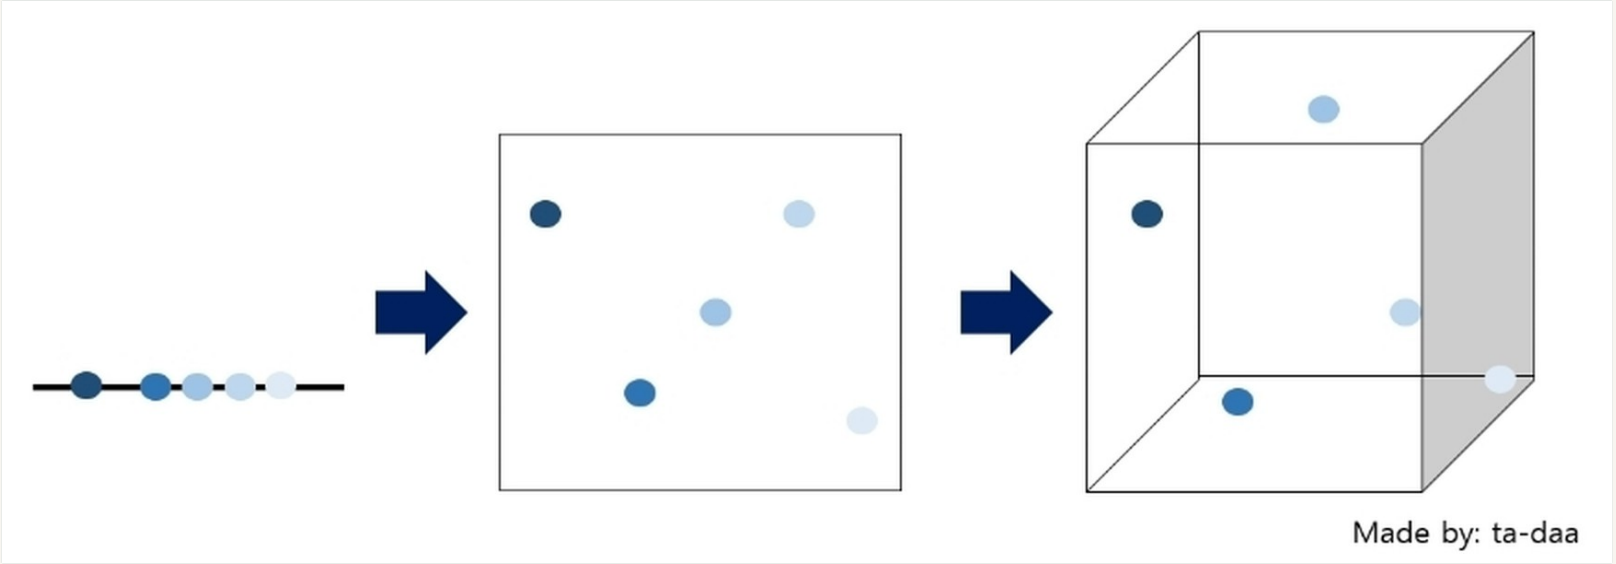
02

특성 줄이기

차원의 저주 · PCA · t-SNE

같은 점 다섯 개가 차원이 늘 때마다 듬성해진다

차원의 저주: 선 → 사각형 → 정육면체, 데이터는 그대로



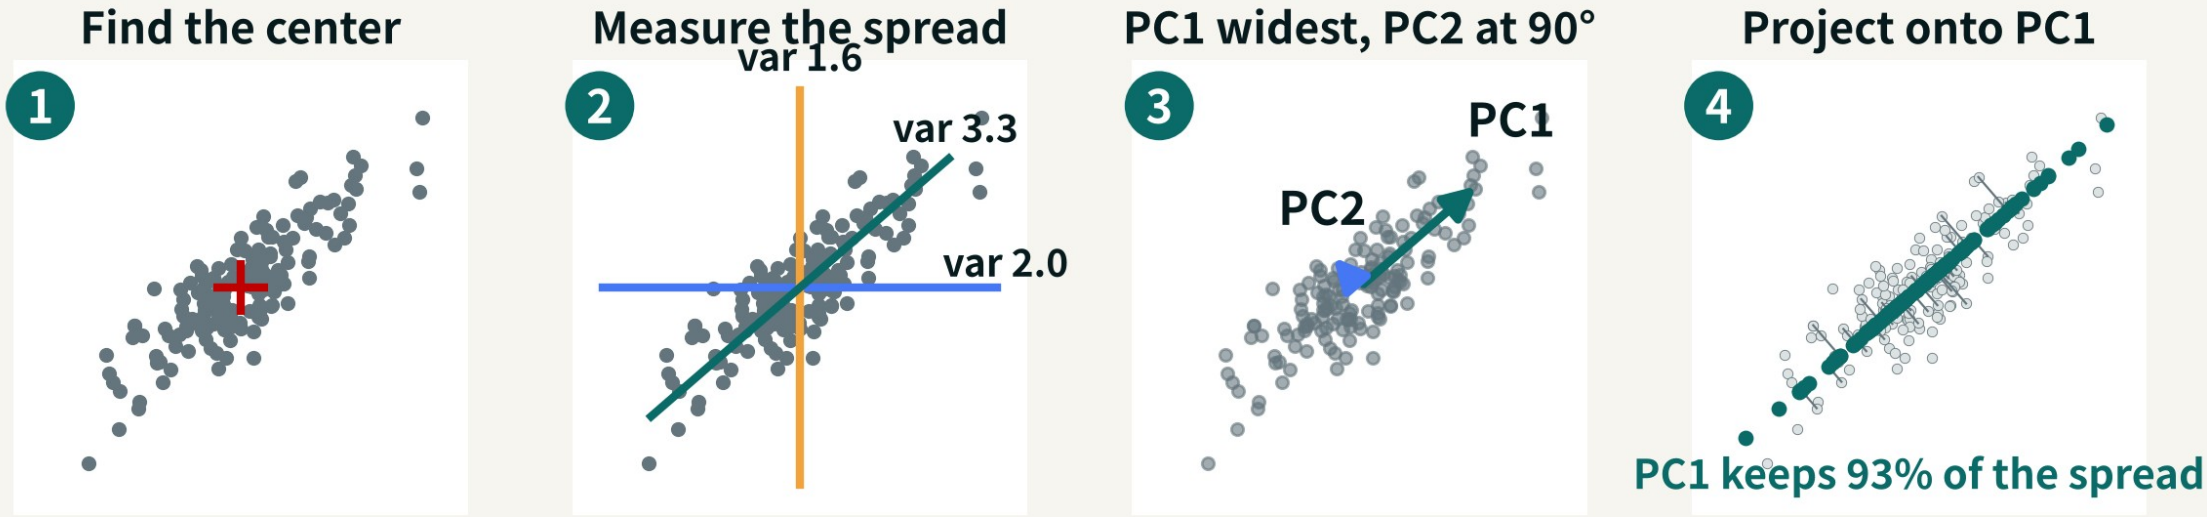
1차원: 붐빈다　　2차원: 틈　　3차원: 빈 공간

특성이 하나 늘 때마다 빈 공간이 곱으로 늘어 거리가 의미를 잃는다.

군집과 KNN이 고생한다. 정보가 있는 축만 남긴다.

PCA는 축을 가장 넓게 퍼진 방향으로 돌린다

상관된 두 특성에 대한 주성분 분석



※ 퍼짐 = 분산. 새 축은 각각 원래 특성의 가중 혼합이다.

상관이 한 성분이 실을 수 있는 양을 정한다

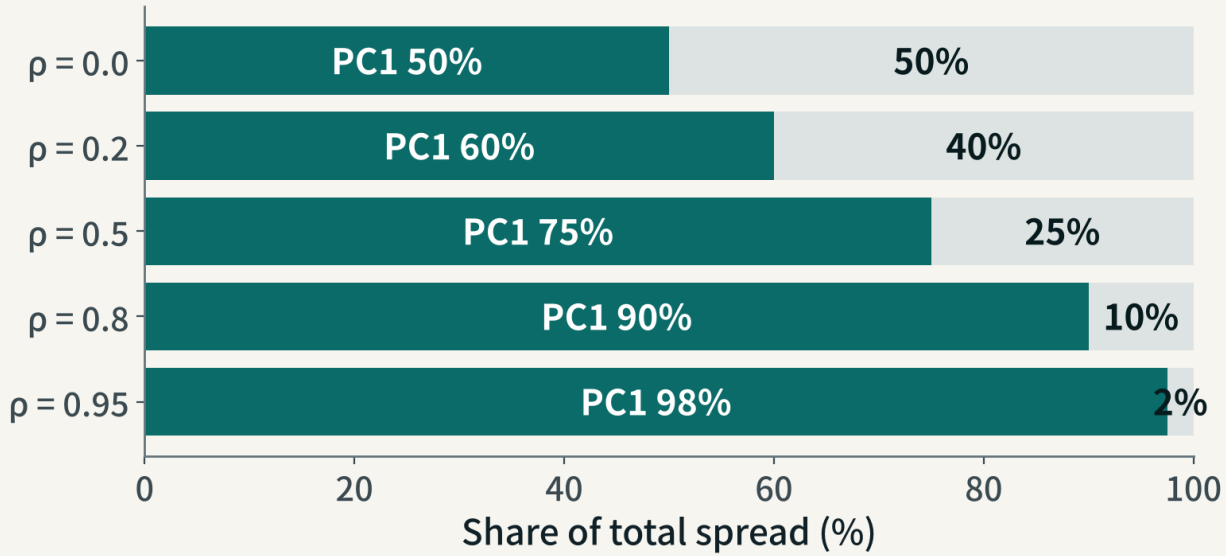
고유벡터 v = 방향, 고윳값 λ = 그 방향의 퍼짐

한 줄로 보는 PCA

$$\Sigma v_k = \lambda_k v_k, \qquad \text{share}_k = \frac{\lambda_k}{\sum_j \lambda_j}$$

상관 ρ인 두 종목

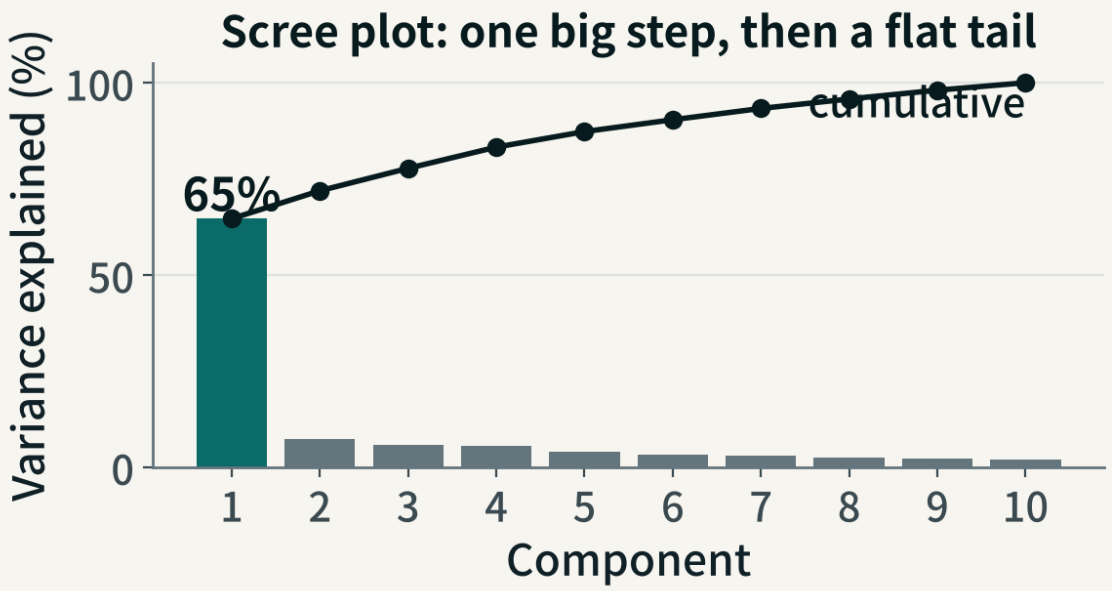
$$\begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \Rightarrow \lambda_{1,2} = 1 \pm \rho$$

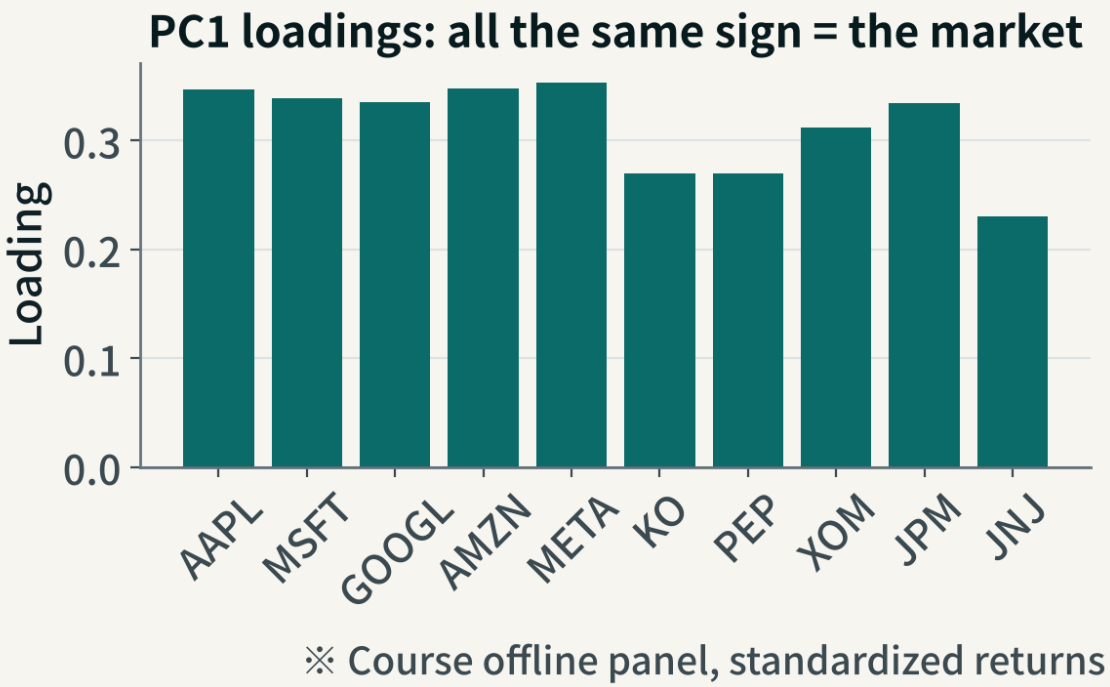


특성끼리 상관이 있을 때만 압축이 이득이다.

주식 수익률에서는 첫 성분이 시장이다

표준화한 일별 수익률 10개에 대한 PCA



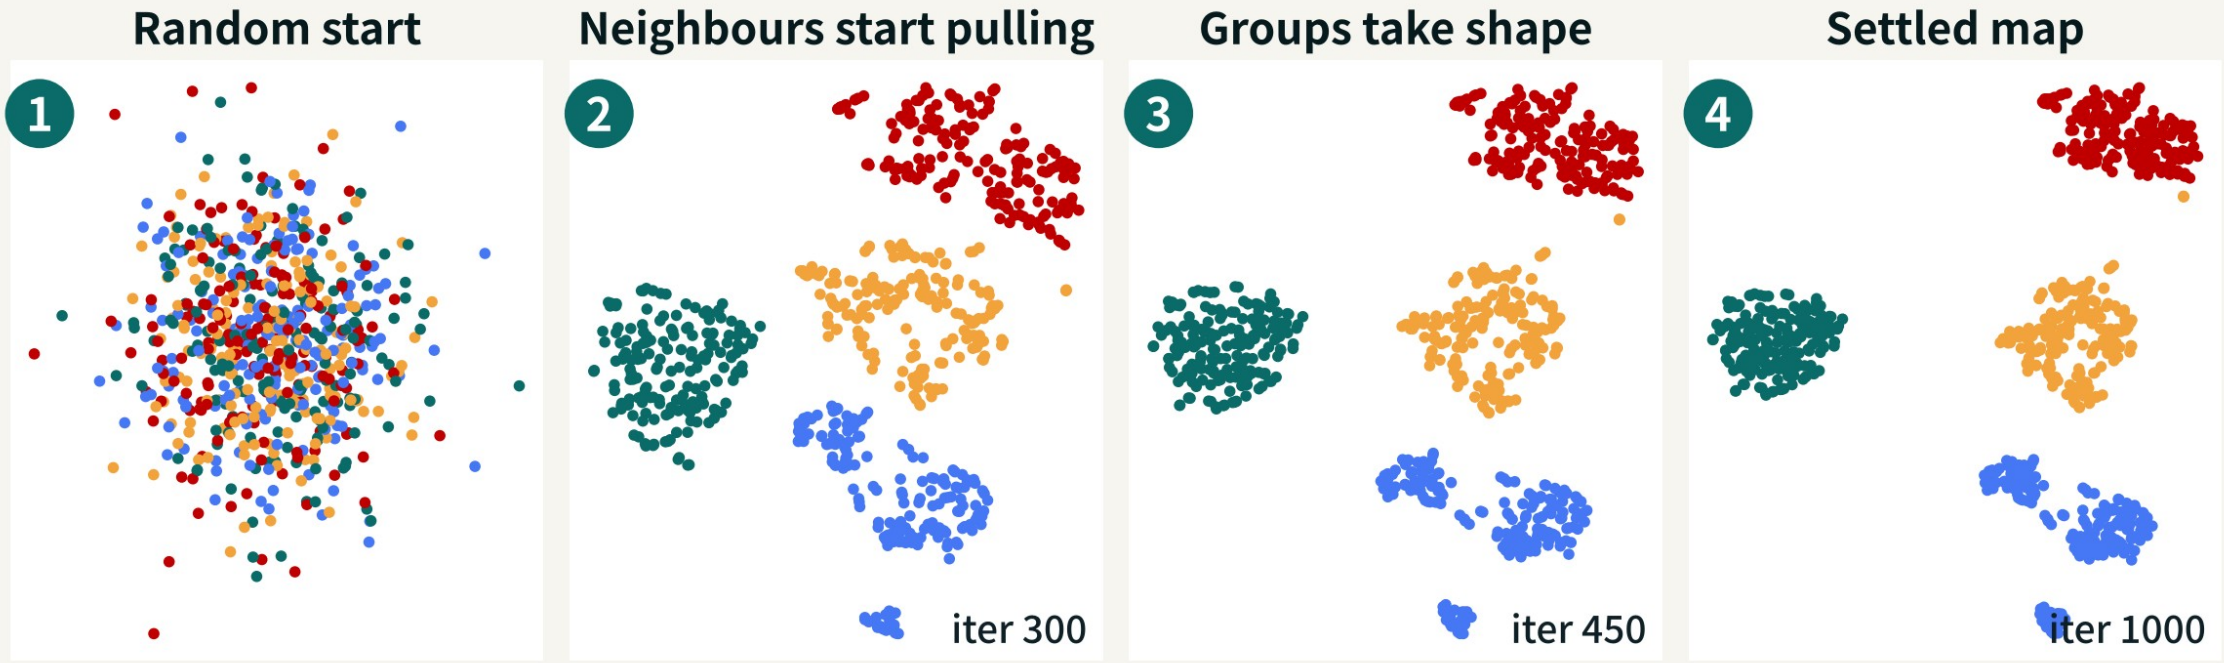


※ Course offline panel, standardized returns

※ 여기서는 PC1이 약 65%를 설명한다. 뒤 성분은 업종 기울기, 그다음은 잡음이다.

t-SNE는 2차원 지도 위에서 이웃끼리 끌어당긴다

64픽셀 손글씨 숫자(0, 1, 4, 7)에 대한 t-분포 확률적 이웃 임베딩



※ 색은 실제 숫자에서 왔고 지도를 확인하는 데만 쓴다. t-SNE는 이 색을 보지 않는다.

t-SNE는 두 공간의 이웃 확률을 맞춘다

van der Maaten & Hinton(2008). x = 원래 점, y = 지도 위 위치

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}$$

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}$$

$$\mathrm{KL}(P \,\|\, Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

퍼플렉시티는 대략 각 점이 챙기는 이웃 수다.

쉬운 말로

① p: 데이터에서 누가 가까운가

② q: 지도에서 누가 가까운가

③ KL: 둘이 다르면 벌점

σ는 퍼플렉시티로 정한다

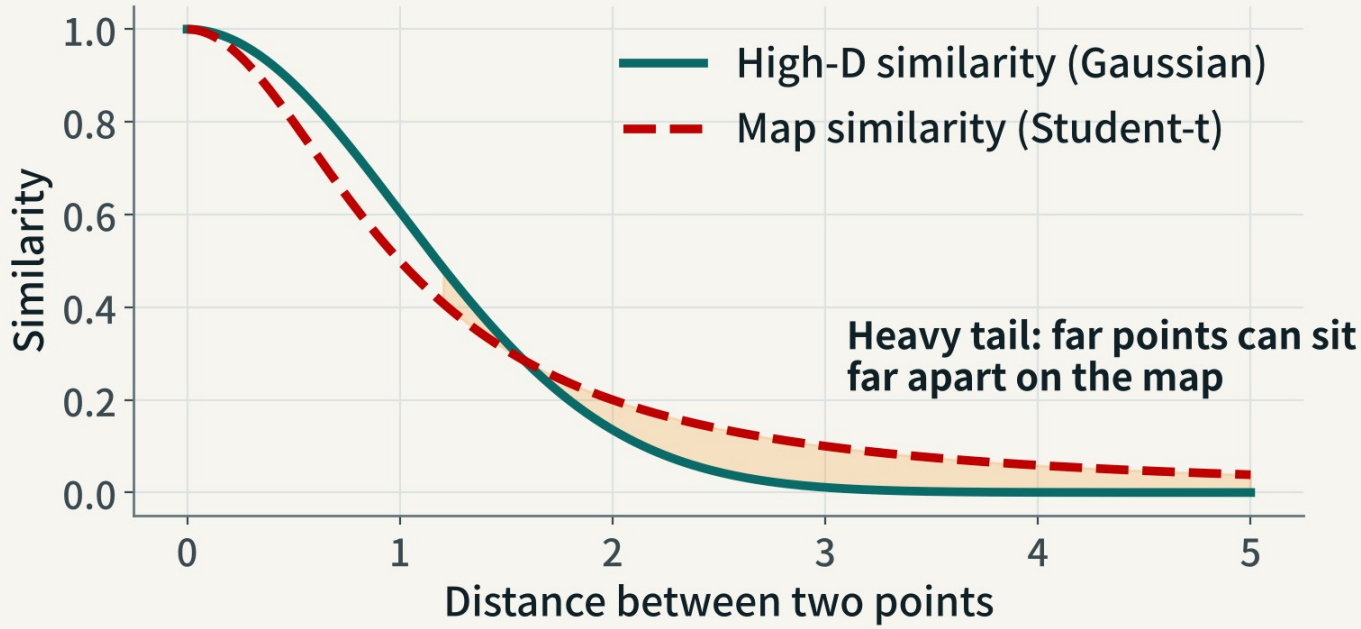
꼬리가 두꺼운 지도 커널이 군집을 떼어 놓는다

각 공간에서 거리에 따른 유사도

밀집 문제

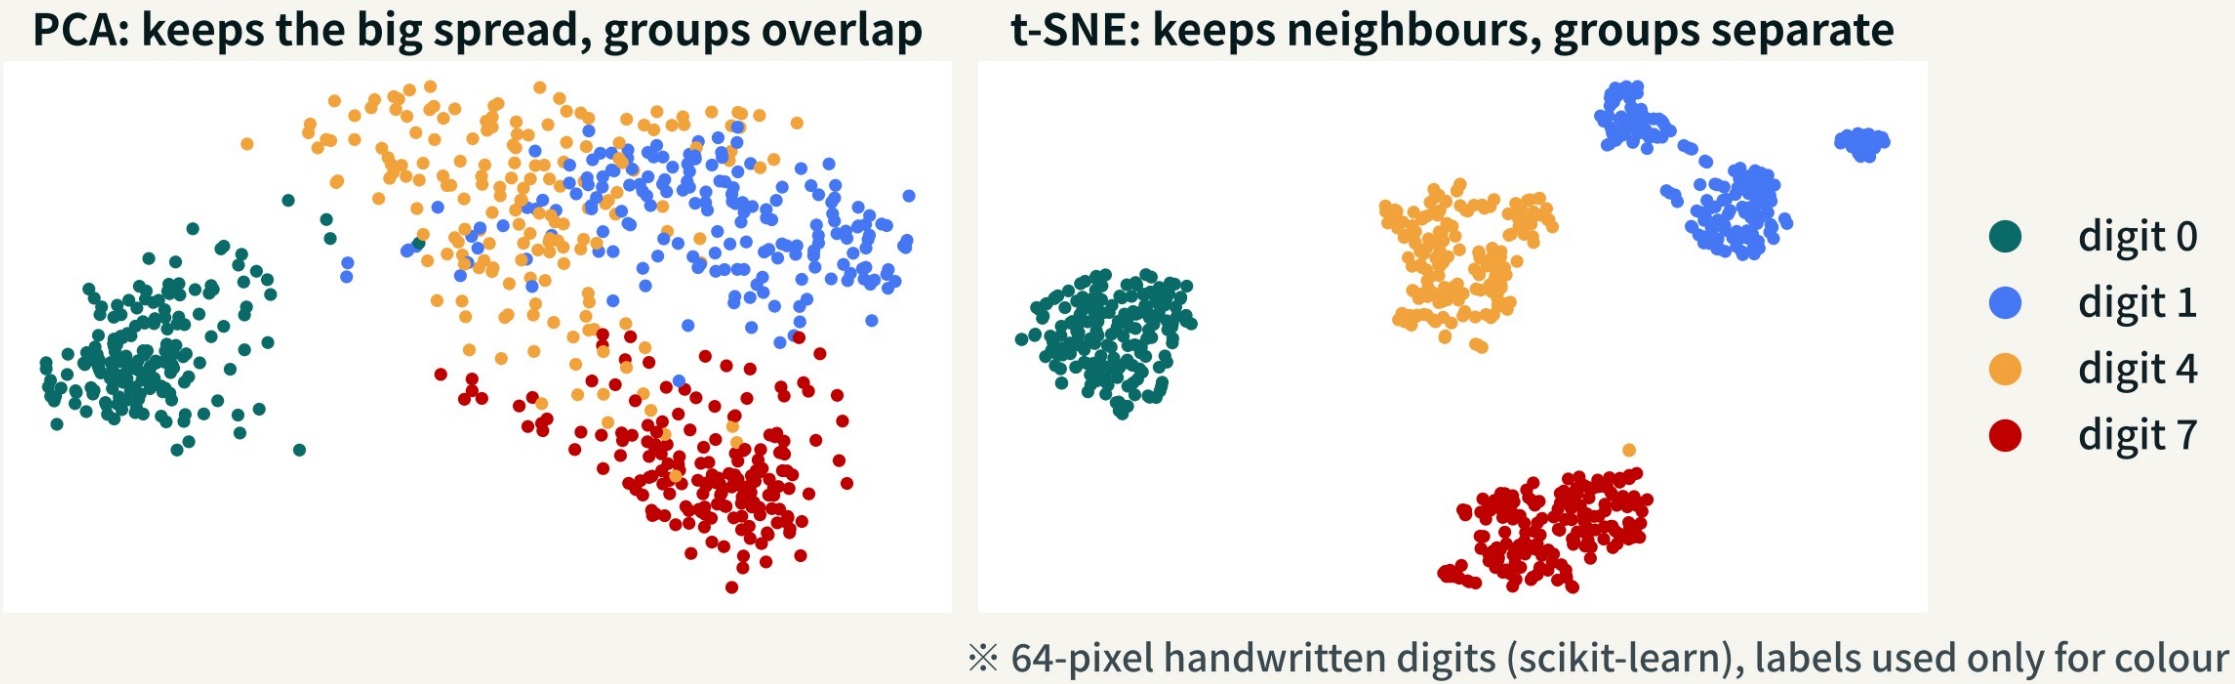
- 2차원은 자리가 좁다
- 가우스는 몰아넣는다
- 두꺼운 꼬리는 풀어 준다

깨끗하게 떨어진 섬



PCA는 전체 퍼짐을, t-SNE는 가까운 이웃을 지킨다

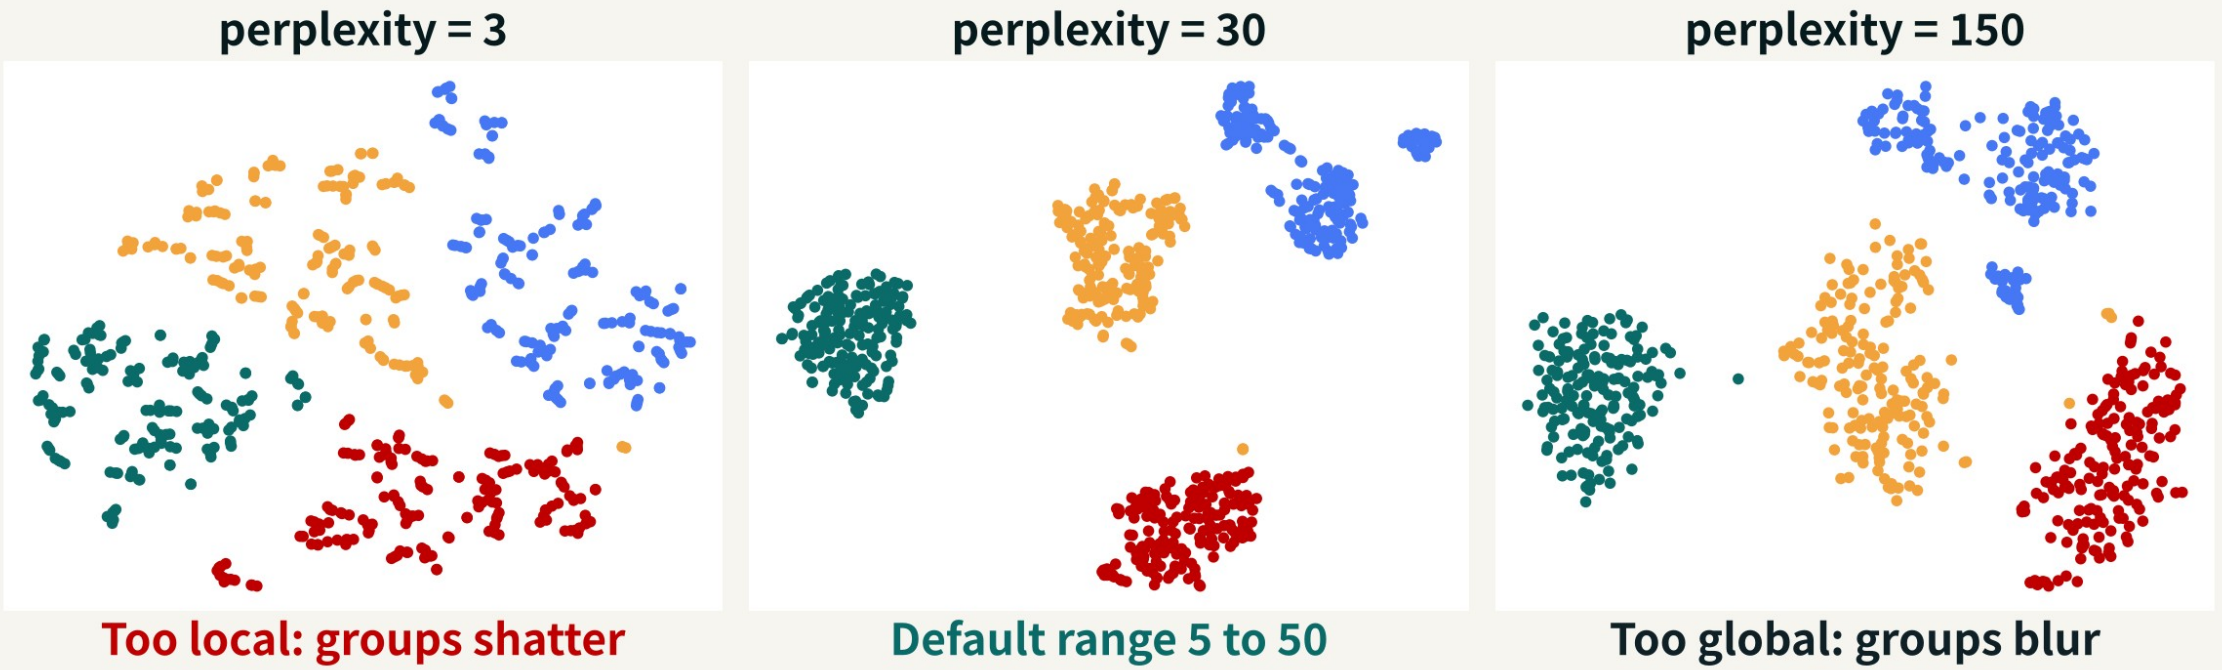
같은 64차원 숫자를 2차원으로 압축



※ 모델 입력을 압축할 때는 PCA, 구조를 들여다볼 때는 t-SNE를 쓴다.

퍼플렉시티는 각 점이 고려하는 이웃 수를 정한다

같은 데이터, 퍼플렉시티 값 셋



※ t-SNE 지도에서 군집 크기와 군집 사이 간격은 의미가 없다. 모델 입력으로 쓰지 않는다.

실무에서는 PCA로 먼저 압축하고 t-SNE로 지도를 그린다

특성이 많을 때의 표준 순서: t-SNE는 느리고 잡음 방향에 민감하다

원 특성 → 표준화 → PCA로 ~50 → t-SNE로 2차원 → 다시 돌려 확인

왜 표준화

단위를 맞춘다

한 특성이 지배하지 않게

왜 PCA 먼저

더 빠르고 깨끗하게

잡음 방향을 버린다

왜 다시 돌리나

모양이 움직일 수 있다

시드·퍼플렉시티를 바꾼다

매번 다시 돌려도 남는 섬만 믿는다.

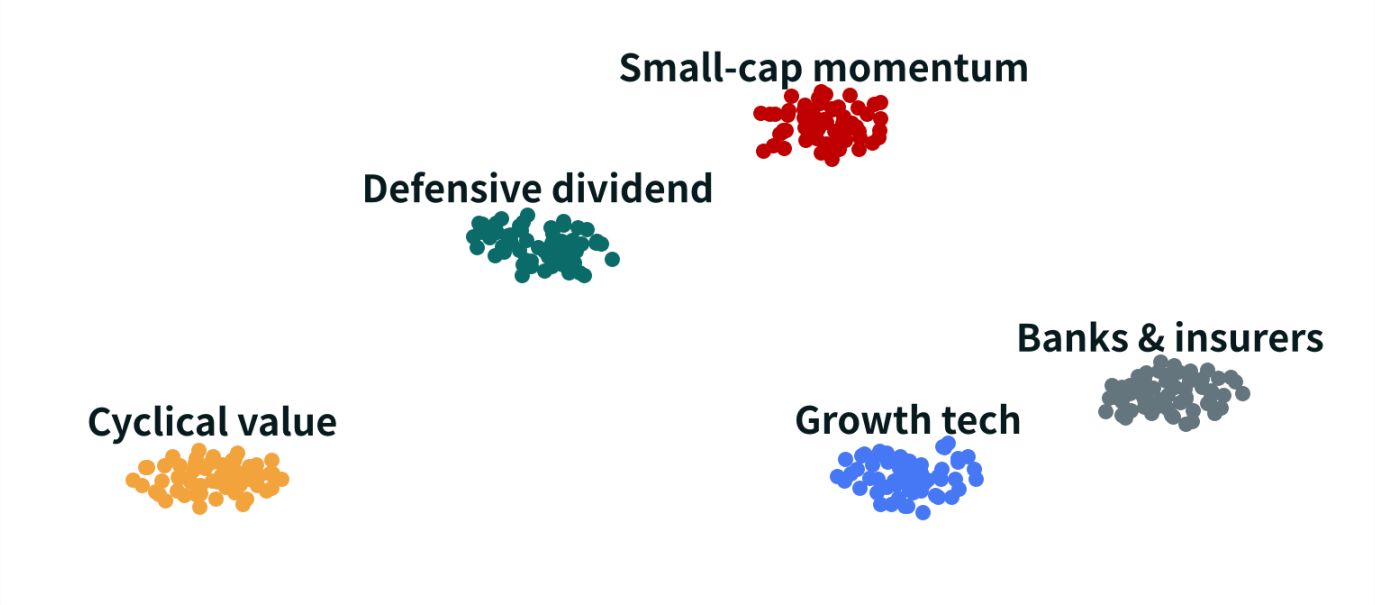
종목 특성 지도로 스타일 그룹을 한눈에 본다

가치·모멘텀·변동성·수익성 등 특성 30개로 각 종목을 기술

쓰는 법

- 섬 = 비슷한 스타일
- 업종과 비교
- 군집으로 확인

증명이 아니라 탐색



※ Simulated: 300 stocks × 30 characteristics → standardize → PCA 10 → t-SNE

03

잡음 걸러내기

추정 격차 · 마르첸코–파스투르 · 잡음 제거

큰 상관행렬은 증거보다 미지수가 많다

5년 일별 이력을 가진 전형적인 기관 투자 유니버스

종목 수 N	상관 쌍	거래일 T	쌍당 일수
500	**~125,000**	**1,260**	**≈ 0.01**

추정할 쌍

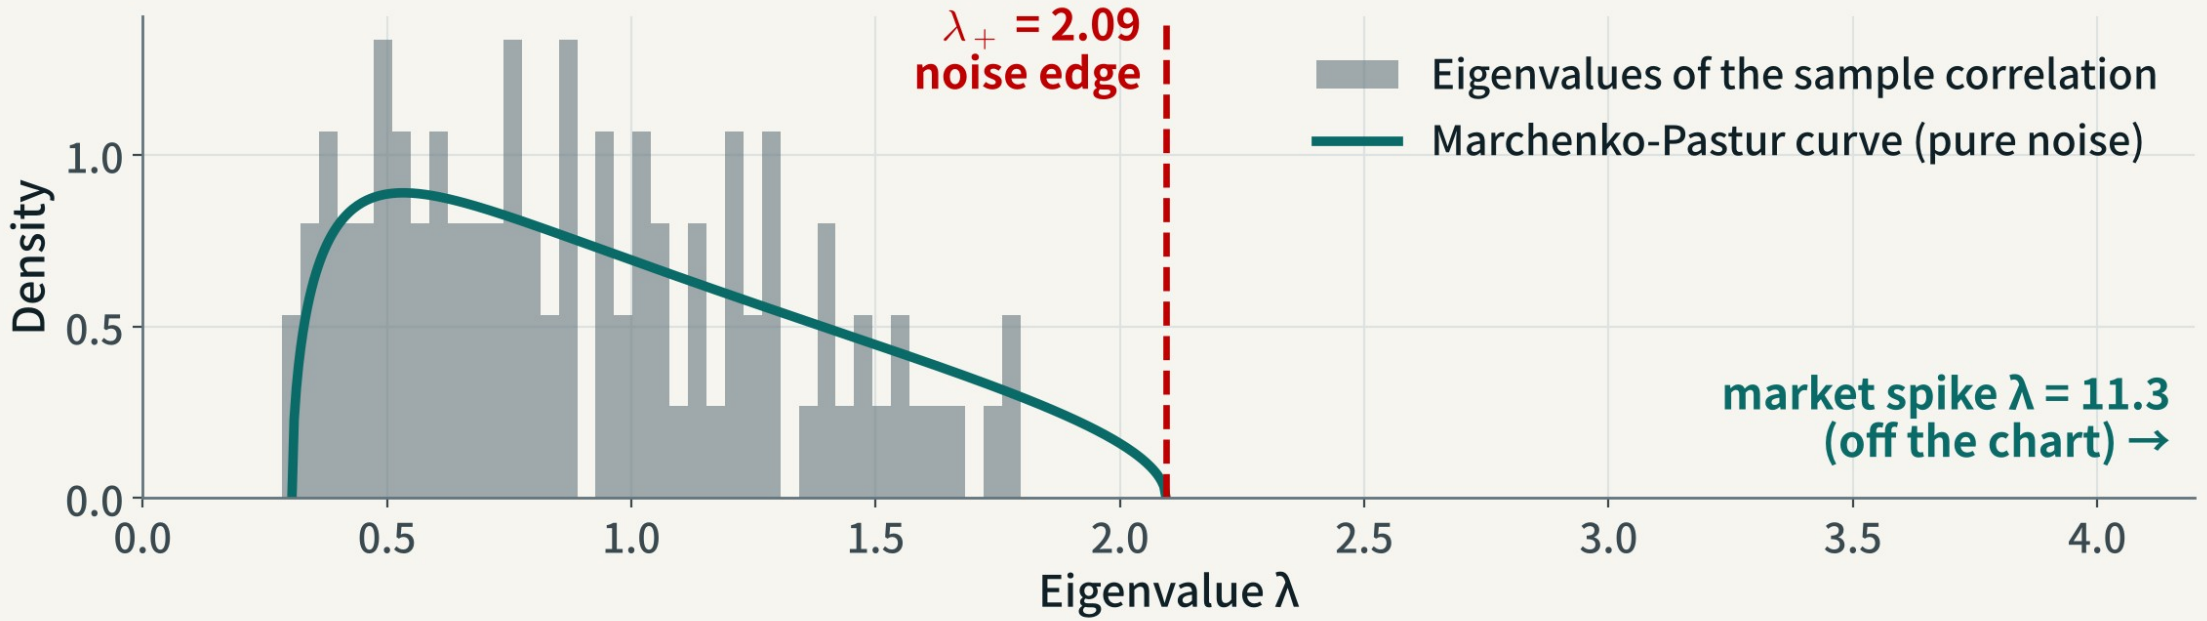
$$\frac{N(N-1)}{2} = \frac{500 \times 499}{2} \approx 125{,}000$$

측정한 상관 대부분은 신기루다.

최적화기는 그것을 좇아 깨지기 쉬운 포트폴리오를 만든다.

순수 잡음은 예측 가능한 덩어리를 채우고, 실제 팩터는 그 밖으로 솟는다

마르첸코–파스투르 법칙: 순수 잡음으로 만든 상관행렬의 고윳값 분포



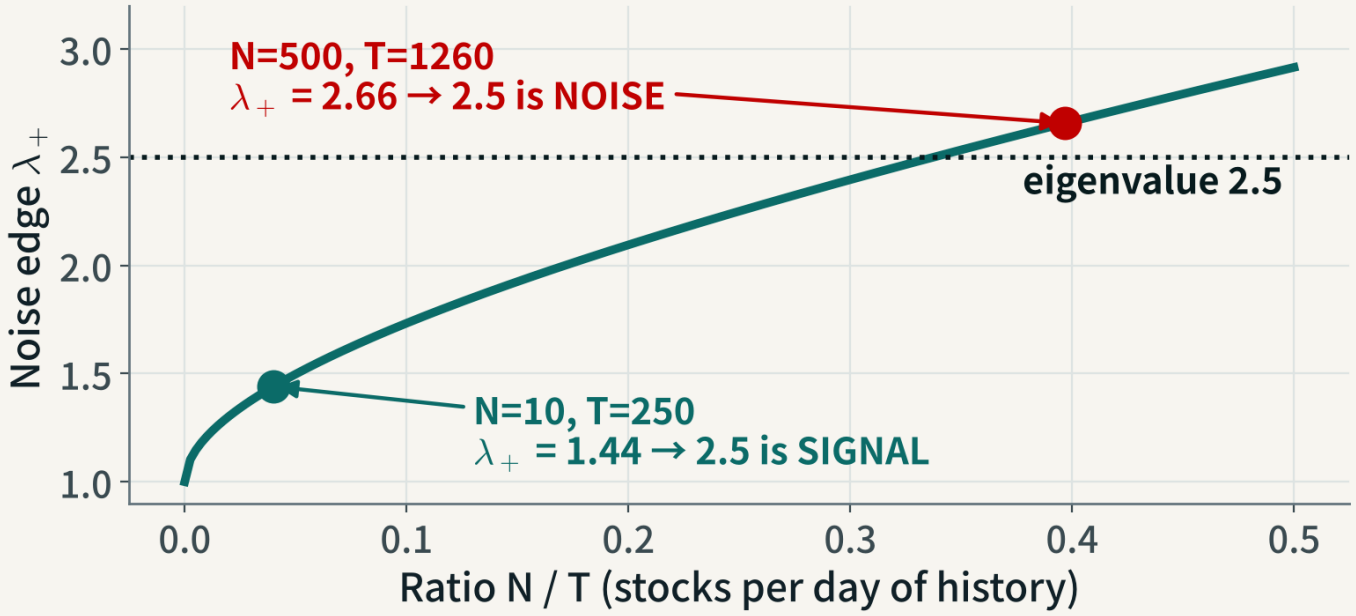
※ 종목끼리 전혀 무관해도 덩어리는 나타난다. 솟은 것만 구조다.

같은 고윳값도 신호일 수도 잡음일 수도 있다

N = 종목 수, T = 일수. 경계 아래 고윳값은 잡음

마르첸코–파스투르 잡음 경계

$$\lambda_+ = \left(1 + \sqrt{N/T}\right)^2$$



종목이 많거나 이력이 짧으면 경계가 올라간다.

2.5는 10종목에서는 신호지만 500종목에서는 잡음이다.

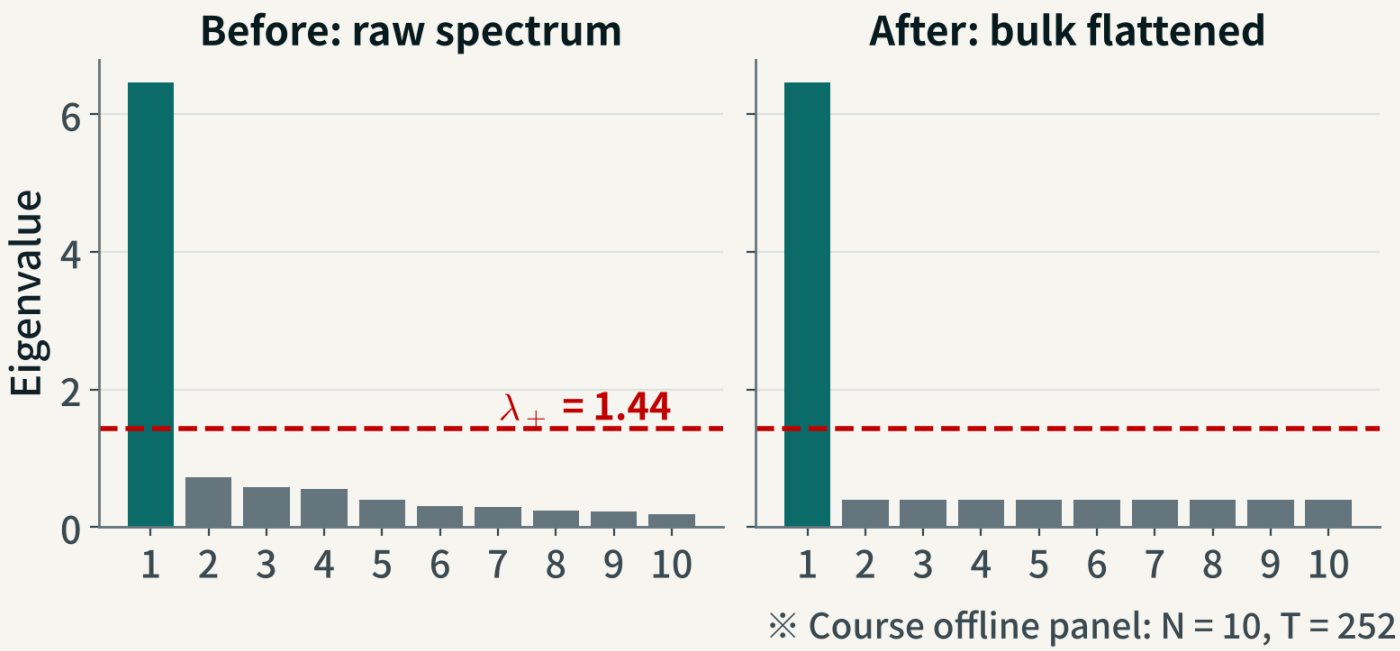
잡음 제거는 덩어리를 평평하게 하고 신호는 남긴다

과정 패널에 적용한 López de Prado의 세 단계

순서

- 1 고윳값을 모두 구한다
- 2 경계 아래 → 평균으로
- 3 행렬을 다시 만든다

최적화(11단원)



최소분산 포트폴리오는 역공분산이 좌우한다

전역 최소분산(GMV) 포트폴리오: 전액 투자, 예측 위험 최소(Markowitz)

GMV 비중

$$w^* = \frac{\Sigma^{-1}\mathbf{1}}{\mathbf{1}^\top\Sigma^{-1}\mathbf{1}}$$

설정

50종목, 120일

시장 1 + 업종 5

원본

표본 공분산

추정한 그대로

잡음 제거

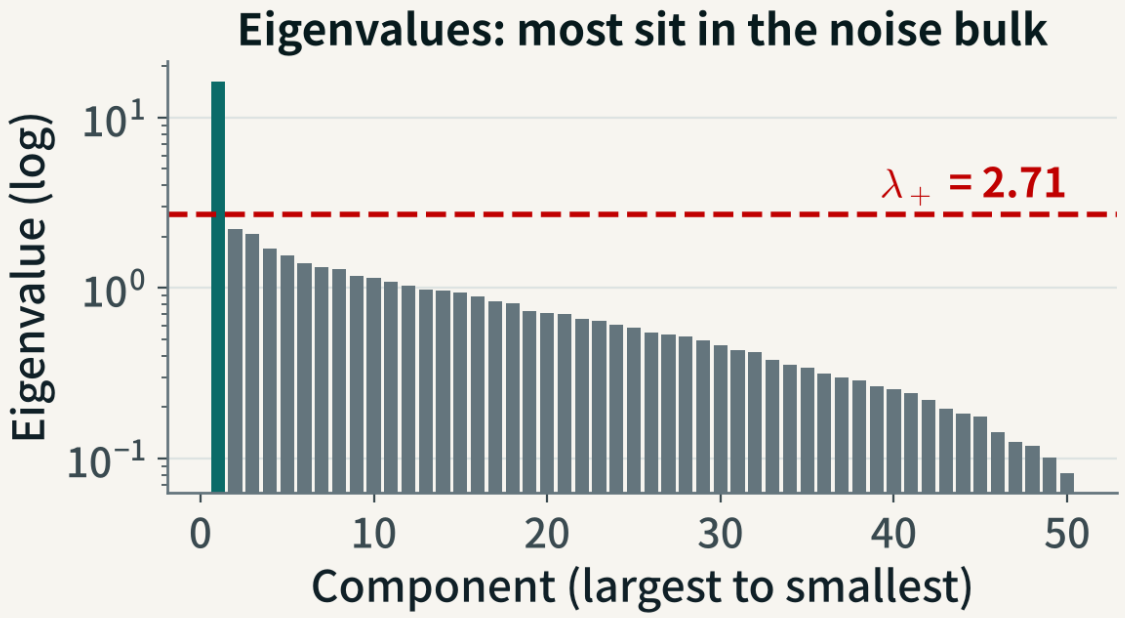
MP로 정리

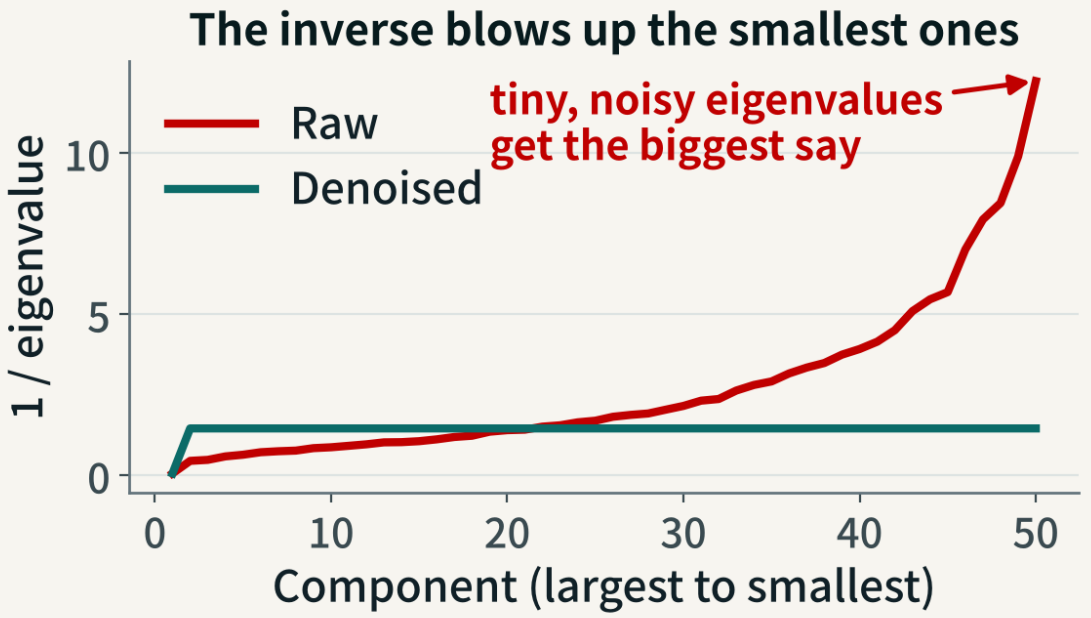
변동성은 같고 상관은 깨끗하게

역행렬은 행렬의 추정 오차를 모두 키운다.

잡음 낀 행렬을 뒤집으면 아주 작은 고윳값이 큰 베팅이 된다

Σ^{-1}은 고윳값마다 나누므로 가장 작고 잡음 많은 것이 비중을 지배한다



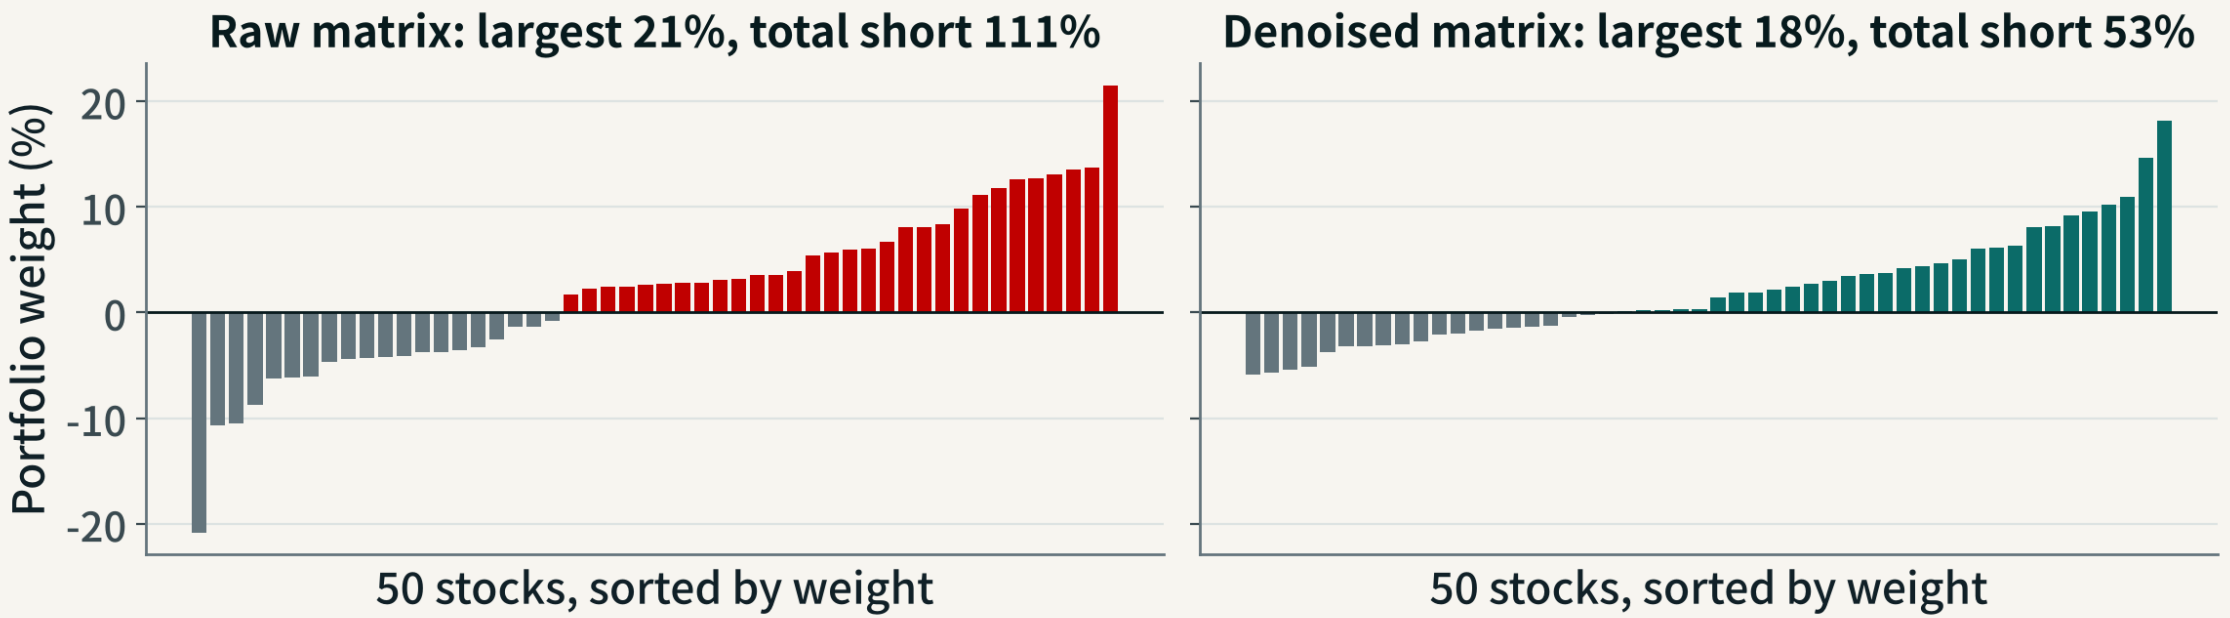


※ Simulated: 50 stocks, 120 days, 1 market + 5 sector factors

※ 잡음 제거는 덩어리를 평균으로 맞추므로 어떤 잡음 방향도 지나친 발언권을 갖지 못한다.

잡음 제거는 극단적인 매수·매도 포지션을 누그러뜨린다

같은 120일 표본에서 구한 GMV 비중, 원본 대 잡음 제거(전형적인 한 번)



※ Minimum-variance weights from one 120-day sample; grey bars are short positions

※ 원본 비중은 잡음에 베팅한다. 있지도 않은 상관을 이용하려고 공매도가 100%를 넘는다.

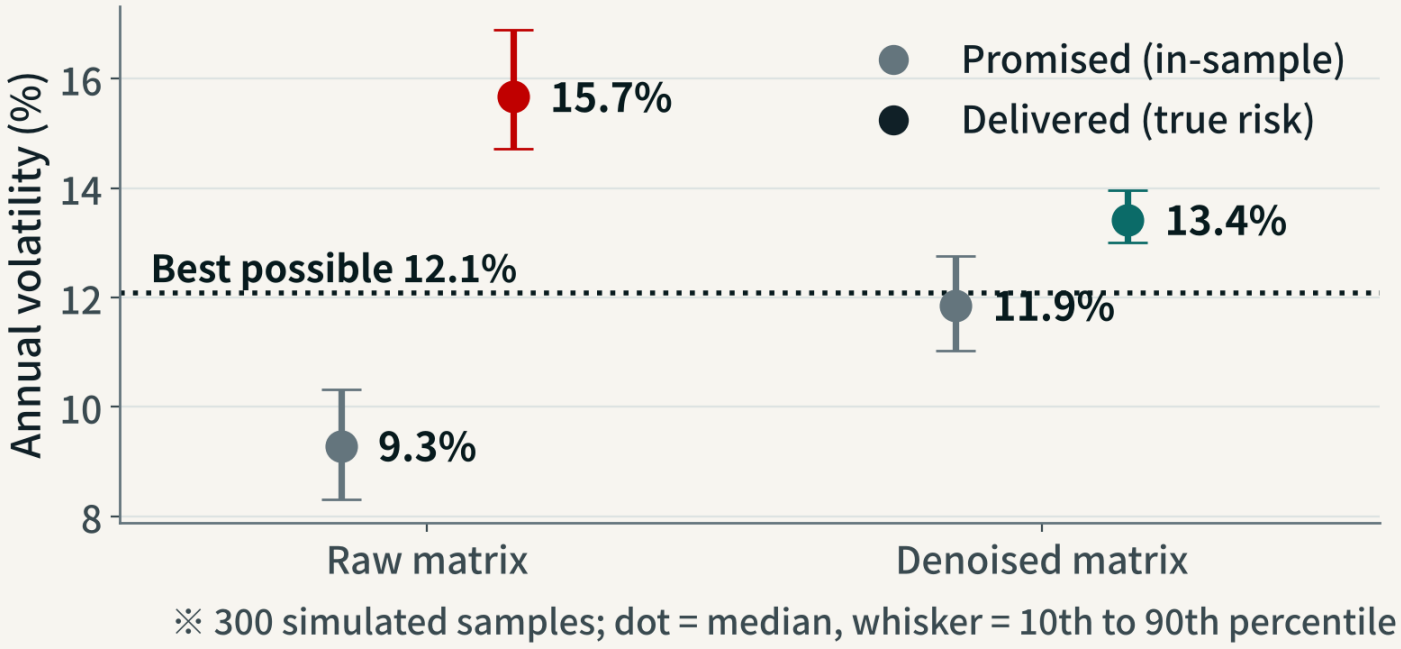
잡음 제거 포트폴리오가 위험이 더 낮고 약속을 지킨다

약속 = 최적화기가 보고한 위험, 실현 = 그 비중의 실제 위험

300회 중앙값

- 원본: 9.3 → 15.7%
- 잡음 제거: 11.9 → 13.4%
- 최선: 12.1%

같은 데이터, 정직한 위험



도구 여섯 개로 비지도학습 도구함 전체를 덮는다

한 줄씩: 하는 일과 꼭 정해야 할 손잡이 하나

K-평균

가장 가까운 중심

손잡이: K(엘보)

계층적 군집

병합 나무

손잡이: 연결 규칙, 자르는 높이

DBSCAN

밀집 영역

손잡이: ε, minPts

PCA

가장 넓은 축

손잡이: 주성분 개수

t-SNE

이웃 지도

손잡이: 퍼플렉시티

MP 잡음 제거

덩어리를 평평하게

손잡이: N / T(주어짐)

04

Claude Code로 만들기

프롬프트 세 개로 이 덱의 모든 그림을 재현한다

작업은 Claude Code가 하고, 여러분은 결과를 확인한다

Claude 데스크톱 앱의 Code 탭. 프롬프트를 붙여 넣고 결과를 읽는다

Code 탭 열기 → **프롬프트 붙여 넣기** → **Claude가 실행** → **그림 읽기** → **이유 묻기**

Claude가 하는 일

내려받기, 코드 작성, 실행

오류도 스스로 고친다

여러분이 하는 일

붙여 넣고 확인

말이 되는가?

규칙

모든 줄을 설명받는다

시키기만 말고 이유를 묻는다

프롬프트 1은 열 종목을 세 가지 방법으로 묶는다

K-평균, 엘보, 덴드로그램, DBSCAN을 다룬다

어디서	입력	출력	피드백
Code 탭	이 프롬프트	PNG 그림 4장	실제 업종과 맞나?

yfinance로 AAPL, MSFT, GOOGL, AMZN, META, KO, PEP, XOM, JPM, JNJ의 2020~2024년 일별 수익률을 내려받아라. 10종목을 세 가지 방법으로 군집하라: (1) K를 1부터 8까지 바꾼 K-평균과 엘보 그림, (2) 상관 거리와 평균 연결로 계층적 군집을 하고 덴드로그램 그리기, (3) k-거리 그림에서 eps를 골라 DBSCAN. 그림은 모두 PNG로 저장하고 열어서 보여 줘라. 마지막에 세 문장으로 답하라: 그룹이 실제 업종과 맞는가, 혼자 동떨어진 종목은 무엇인가? 실패하면 스스로 고쳐서 다시 돌려라.

프롬프트 2는 PCA로 수익률을 압축하고 t-SNE로 숫자를 지도에 그린다

스크리 그림, PC1 적재값, PCA 대 t-SNE, 퍼플렉시티를 다룬다

어디서	입력	출력	피드백
Code 탭	이 프롬프트	PNG 그림 4장	PC1=시장?

같은 10종목 수익률을 표준화하고 PCA를 돌려라. 누적 분산을 함께 표시한 스크리 그림과 PC1 적재값 막대그래프를 그리고, PC1이 시장 팩터처럼 움직이는지 말해 줘라. 그다음 scikit-learn의 손글씨 숫자(0, 1, 4, 7만)를 불러와 숫자별로 색을 칠한 PCA 지도와 t-SNE 지도를 나란히 그려라. 마지막으로 퍼플렉시티 3, 30, 150에서 t-SNE를 그려라. 그림은 모두 저장하고 열어서 보여 주고, 각각 쉬운 문장 하나로 설명하라.

프롬프트 3은 최적화 전에 상관행렬의 잡음을 걸러낸다

고윳값, 마르첸코–파스투르 경계, 전후 비중을 다룬다

어디서	입력	출력	피드백
Code 탭	이 프롬프트	표 + 차트 2장	비중이 더 건전한가?

10종목 수익률의 상관행렬과 모든 고윳값을 구하라. 종목 수 N과 일수 T로 마르첸코–파스투르 경계를 계산하고, 경계 위 고윳값이 몇 개인지 세고, 나머지는 평균으로 바꾼 뒤 대각선이 1인 상관행렬로 다시 만들어라. 경계를 점선으로 넣어 전후 고윳값을 그려라. 원본 행렬과 잡음 제거 행렬에서 구한 최소분산 포트폴리오 비중을 나란히 출력하고, 어느 쪽 비중이 더 건전해 보이는지와 그 이유를 세 문장으로 설명하라.

행을 묶는다.

열을 압축한다.

행렬을 걸러낸다.

레이블 없이 찾은 구조도
경제적으로 말이 되어야 한다.