정직한 백테스트
과거 성과에 속지 않는 법

과거에 잘 벌었다는 전략이 실제로도 그럴지 확인한다



금융 머신러닝 · 10주차

이번 주는 네 단계에 보충 절 하나로 진행합니다

기본 지식에서 출발해 핵심 개념, 사례, 정리 순서로 읽는다

01	기본 지식	**백테스트를 읽기 위한 재료** 수익률·변동성, 훈련과 시험, 과적합
02	누출과 중복	**결정 당시 알 수 있던 정보만 쓴다** 흔한 실수, purging·embargo·walk-forward
02+	라벨과 교차검증	**무엇을 맞히고 어떻게 시험하나** 3중 장벽·메타 라벨링, K-fold·Purged CV·CPCV
03	운과 다중검정	**많이 시도하면 우연한 승자가 나온다** 샤프비율, 우연의 최고 샤프, DSR
04	사례와 정리	**실제로 어떤 일이 있었나** 발표 후 수익 감소, 생존 편향, 요인 동물원

시험지를 여러 번 고치면 점수는 올라도 실력은 늘지 않습니다

01

기본 지식

백테스트 결과를 읽기 위해 먼저 알아야 할 개념을 정리한다

백테스트 지표는 세 가지 재료로 만들어집니다

수익률, 초과수익률, 변동성 — 이 장의 모든 지표가 이 셋에서 나온다

RETURN

수익률

- 가격이 일정 기간에 몇 % 변했는지 나타냅니다.

EXCESS RETURN

초과수익률

- 무위험수익률을 넘어서 번 부분입니다.

VOLATILITY

변동성

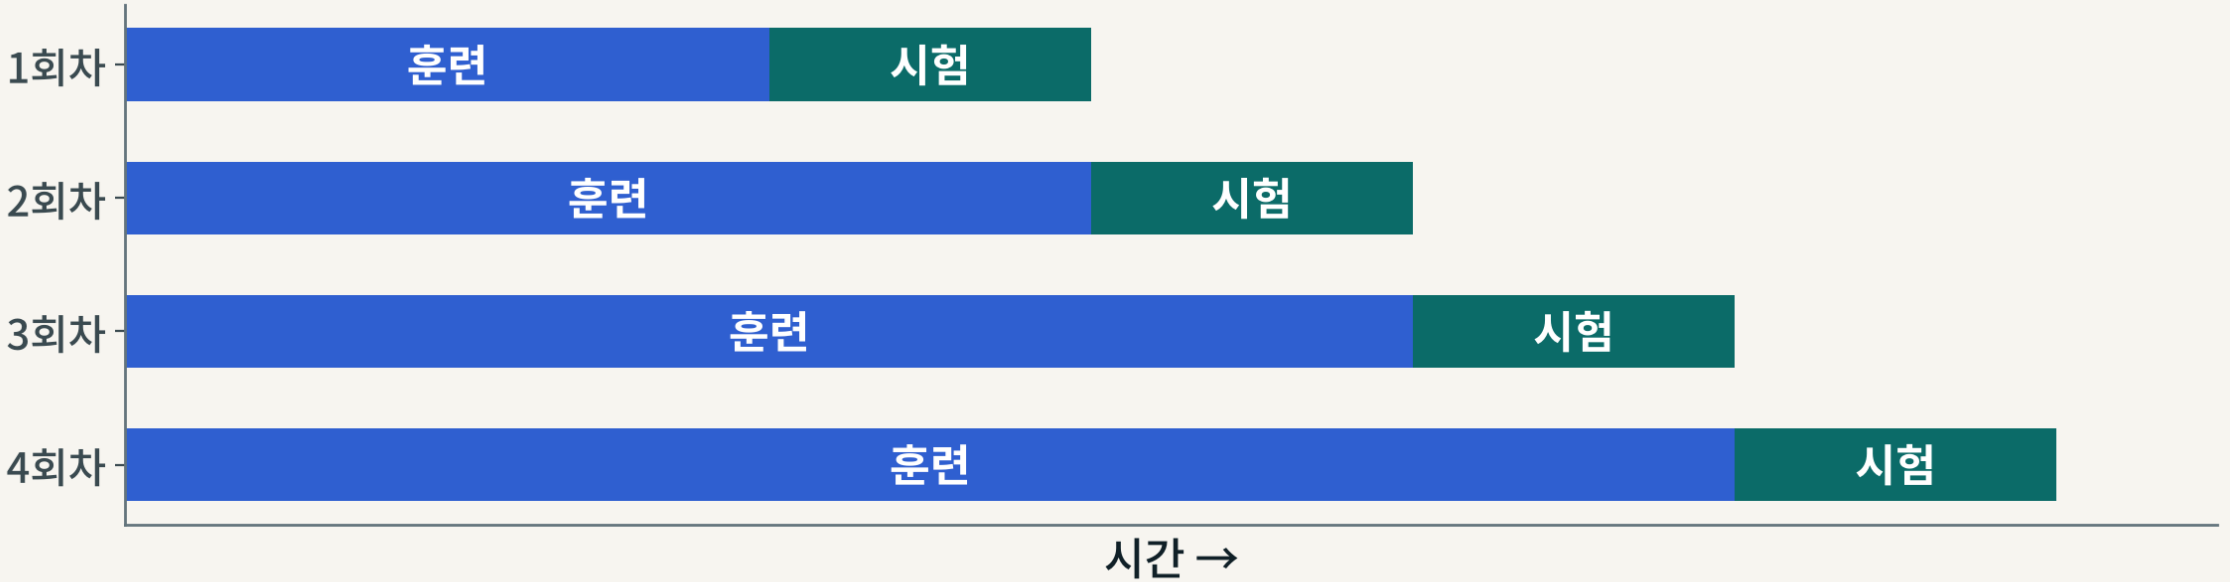
- 수익률이 평균에서 흔들리는 정도이며 표준편차로 잽니다.

샤프비율은 초과수익률을 변동성으로 나눈 값입니다

단위 기간(일·월·연)을 섞으면 숫자가 틀립니다

검증은 과거로 배우고 미래로 시험하는 일입니다

훈련 구간(training)·시험 구간(test)·표본 밖(out-of-sample)의 관계



※ 매 회차 과거로만 훈련하고 바로 다음 구간으로 시험한다 (확장 창 예시)

시험 구간은 모델이 한 번도 보지 못한 미래여야 합니다

표본 안 성과만으로는 실력과 운을 구분할 수 없습니다

과적합은 과거의 잡음까지 외운 상태입니다

과적합(overfitting) — 훈련 자료에는 잘 맞고 새 자료에는 맞지 않는다

SIGNAL

신호

- 여러 기간에 반복되는 패턴입니다.
- 미래에도 남을 가능성이 있습니다.

배우고 싶은 것

NOISE

잡음

- 그 기간에만 생긴 우연입니다.
- 미래에는 사라집니다.

외우면 안 되는 것

모델이 복잡하고 시도가 많을수록 잡음을 신호로 착각하기 쉽습니다

02

누출 · 중복 · 운

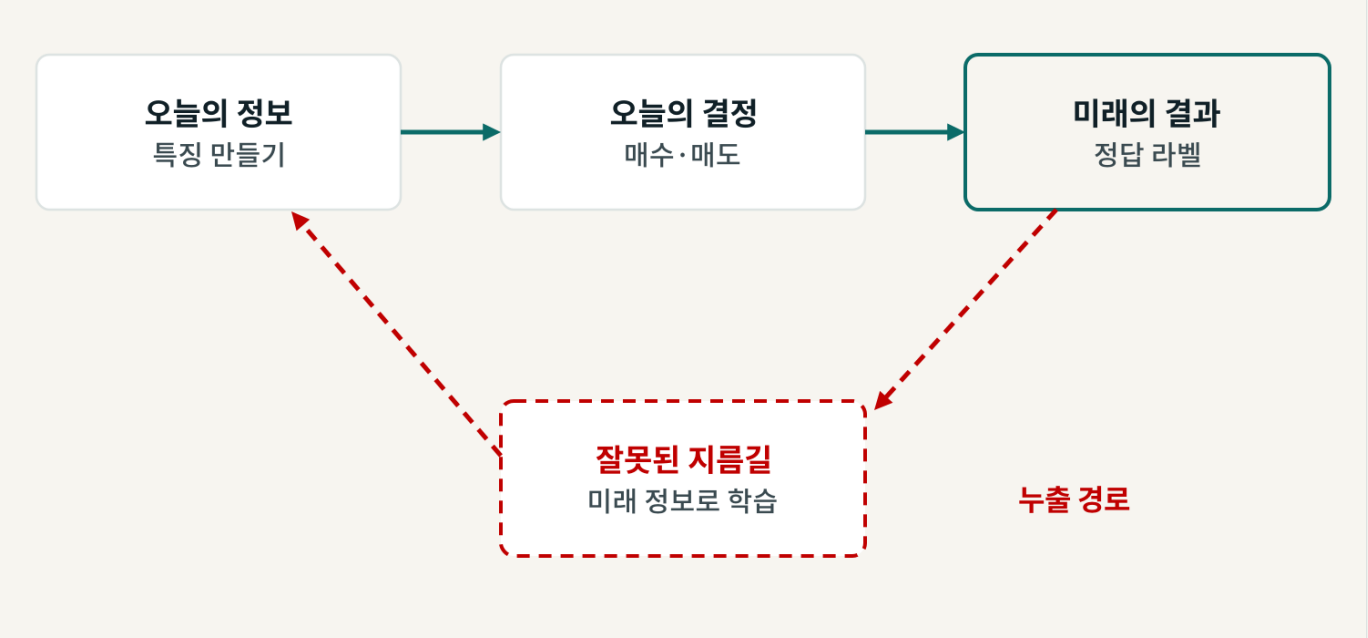
원문의 핵심 개념 — 정보의 시점, 라벨 구간, 시도 횟수

백테스트는 결정 당시 알 수 있던 정보만 써야 합니다

백테스트(backtest)는 과거 데이터를 시간 순서대로 재생해 보는 모의시험이다

미래 정보 누출 (Leakage)

- 장 마감 뒤 나온 실적을 그날 오전 판단에 쓰면 미래를 훔쳐본 것입니다.
- 전체 기간의 평균과 표준편차로 표준화한 뒤 나누어도 누출이 생깁니다.



표준화 기준은 훈련 자료에서만 배웁니다

모델을 복잡하게 만들기 전에 정보의 시점부터 확인합니다

흔한 실수 네 가지는 모두 성과를 부풀립니다

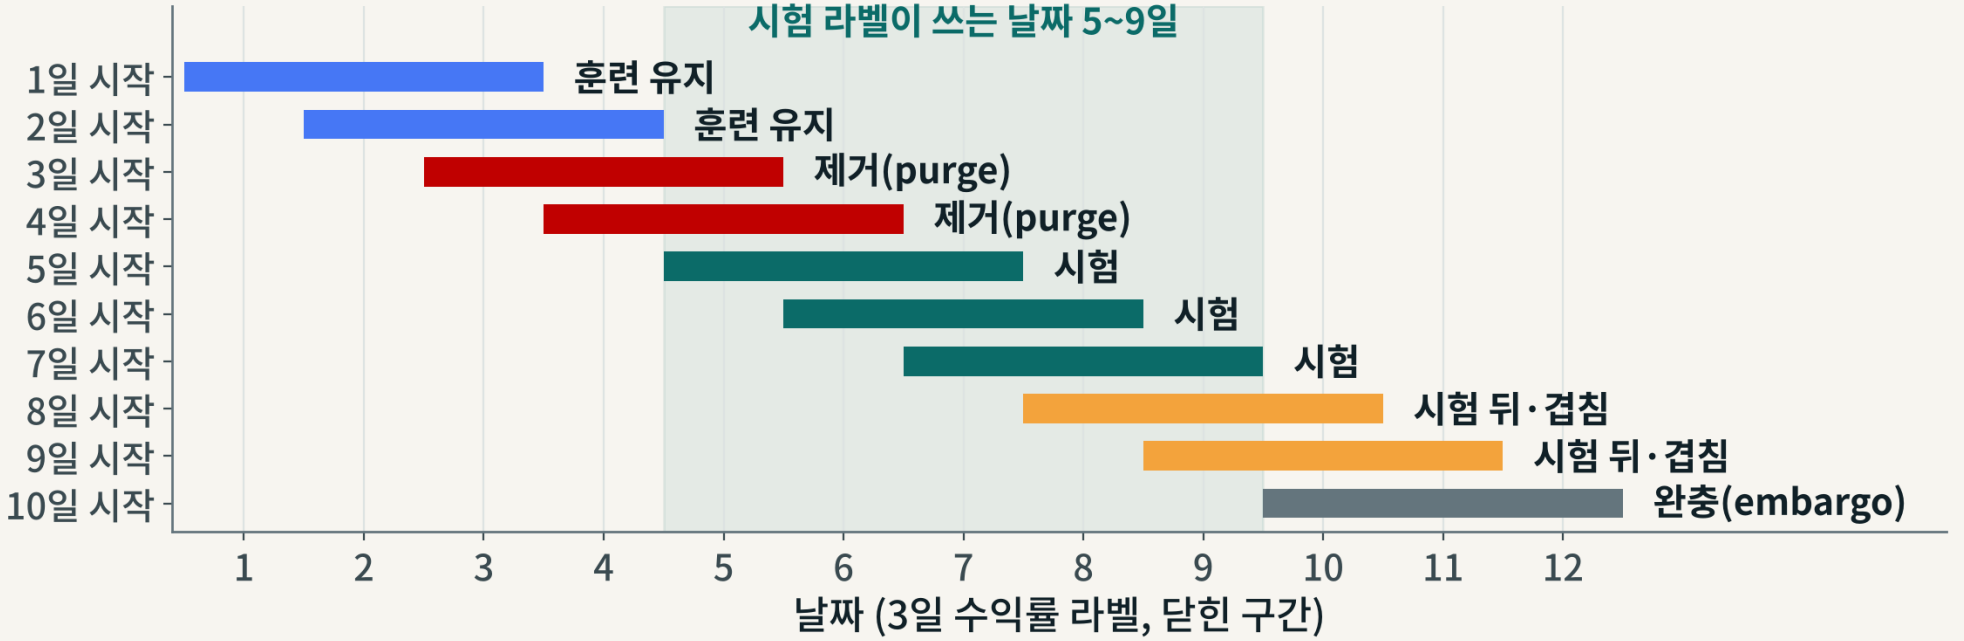
왼쪽 실수가 왜 점수를 올리는지, 어떻게 고치는지를 한 줄씩 읽는다

흔한 실수	왜 성과가 부풀려지는가	고치는 방법
시간 자료를 무작위로 섞음	**미래 국면으로 과거를 맞힐 수 있다**	**과거로 훈련하고 미래로 시험한다**
살아남은 종목만 사용	**상장폐지된 실패 종목이 빠진다**	**당시 투자 가능했던 종목을 쓴다**
전체 자료로 전처리	**시험 기간의 특성이 훈련에 스며든다**	**각 훈련 구간 안에서만 적합한다**
시험 결과를 보고 수정	**시험지가 사실상 훈련 자료가 된다**	**개발용 검증과 최종 시험을 나눈다**

시험지를 여러 번 고치면 점수는 올라도 실력은 늘지 않습니다

날짜를 나눠도 정답 구간은 겹칠 수 있습니다

3일 수익률 라벨, 시험 표본 시작일 5~7일, 끝점을 포함하는 닫힌 구간 기준



시험 라벨은 5~9일을 쓰므로 3·4일에 시작한 훈련 표본과 겹칩니다

표본 시작일이 아니라 각 표본의 전체 구간을 비교합니다

중복 제거와 시간 순서는 서로 다른 제약입니다

Purged CV라는 이름이 '항상 과거로만 훈련한다'는 뜻은 아니다

PURGING

중복 제거

- 시험 표본의 정보·라벨 구간과 겹치는 훈련 표본을 지웁니다.

EMBARGO

완충 구간

- 시험 구간 뒤 일부 표본을 훈련에서 더 뺍니다.
- 길이는 자료와 정보 이용 구간에 맞춥니다.

WALK-FORWARD

전진 검증

- 과거로 훈련하고 이후 기간으로 시험합니다.
- 실거래의 시간 순서를 재현하기 좋습니다.

일부 Purged CV는 시험 구간 뒤 자료도 훈련에 씁니다

※ 원문 보완: 원문 13쪽 날짜 예시는 시작일 중심의 단순화이므로 그대로 일반화하지 않는다

샤프비율은 수익을 흔들림으로 나눈 값입니다

샤프비율(Sharpe ratio)은 같은 기간 단위로 계산해야 한다

정의

$$SR = \frac{\text{평균 초과수익률}}{\text{초과수익률의 표준편차}}$$

예: 월 평균 초과수익률 1%, 월 변동성 2%

$$\text{월 샤프 } \frac{1\%}{2\%} = 0.5 \quad \Longrightarrow \quad \text{연율화 } 0.5\sqrt{12} \approx 1.73$$

연율 환산은 독립·안정 분산 가정 아래의 계산입니다. 자기상관이 강하면 그대로 쓰지 않습니다

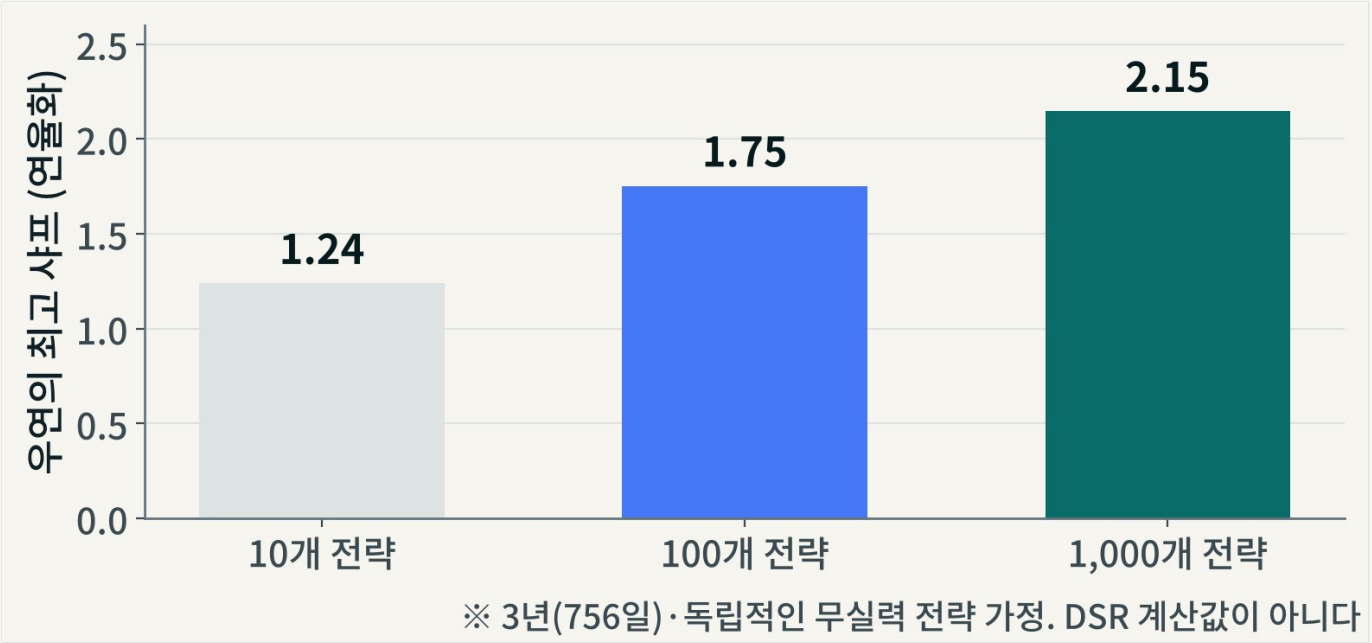
※ 원문 8쪽은 분산을 5로 나눈 교육용 계산이다. 표본 표준편차(분모 4)를 쓰면 값이 달라진다

많이 시도하면 우연히 좋은 전략도 나옵니다

무실력 전략도 시도 횟수가 늘면 최고 샤프가 올라간다

다중검정 (Multiple testing)

- 동전 던지기 전략 1,000개 중 우연히 연승하는 전략이 생깁니다.
- 5% 유의수준 검정 1,000개면 모두 무효여도 약 50개가 유의해 보입니다.



우승 전략의 점수만 발표하면 실력이 과장됩니다

기대 개수 50에는 독립성이 필요 없지만, 우승 점수의 분포에는 중요합니다

우연의 최고 샤프 근사는 직관용 기준입니다

3년(756일) 자료로 1,000번 시도하면 무실력 전략도 약 2.15까지 나온다

원문의 직관용 근사식

$$\text{우연의 최고 샤프 근사} \approx \sqrt{252}\,\frac{\sqrt{2\ln N}}{\sqrt{T}}, \qquad N = \text{시도 횟수},\ \ T = \text{일별 관측 수}$$

근사식의 한계

- 독립적인 무실력 실험을 가정한 직관용 값이며 DSR 자체가 아닙니다.

DSR (Deflated Sharpe Ratio)

- 탐색 횟수, 표본 길이, 왜도·첨도, 시도 간 의존성을 감안해 관측 샤프를 평가합니다.

DSR 0.95를 '실력이 있을 사후확률 95%'로 읽지 않습니다

02+

라벨과 교차검증

무엇을 맞힐지(라벨)와 어떻게 시험할지(교차검증)를 보완한다

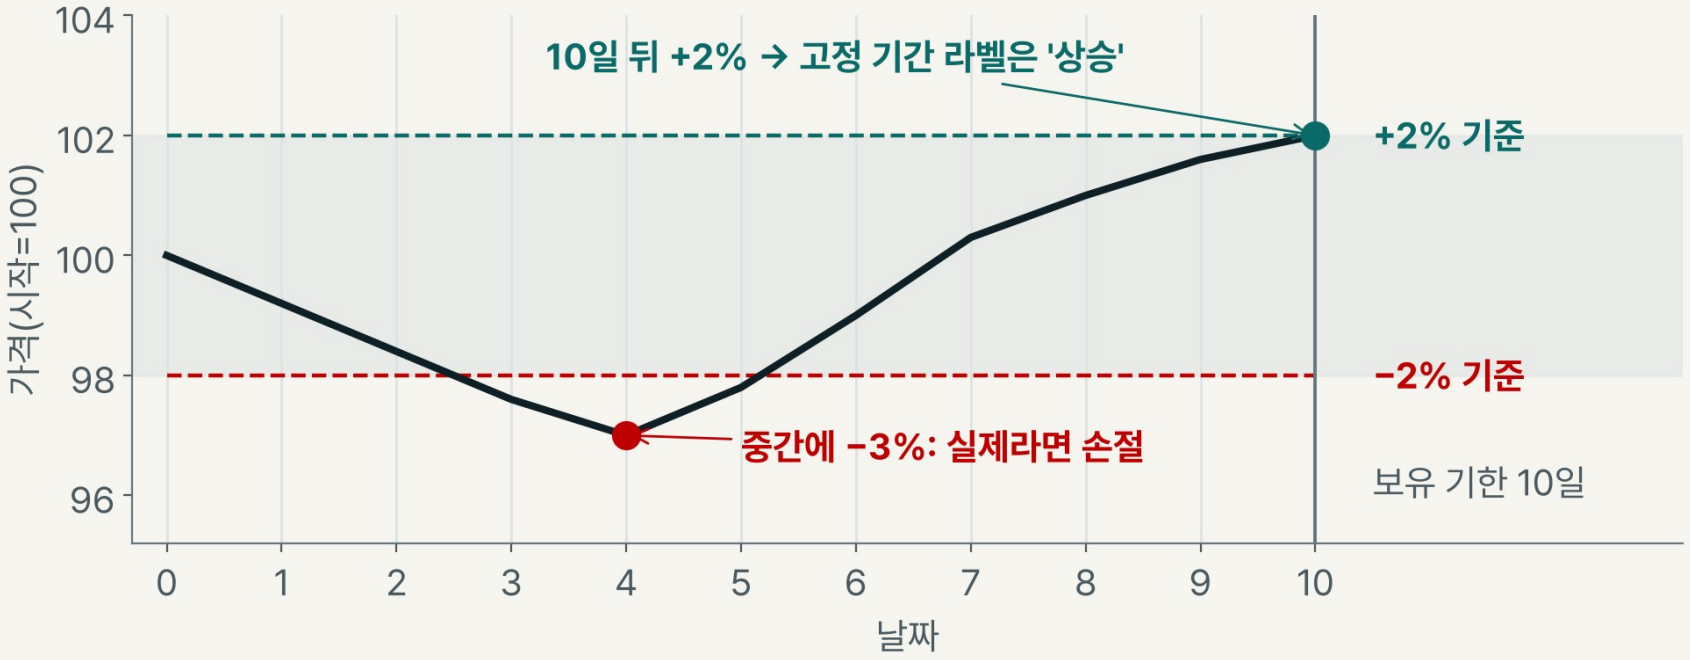
새로 나오는 말 일곱 개를 먼저 정리합니다

이 절에서 쓰는 용어 — 처음 나올 때 이 뜻으로 읽는다

라벨(label)	모델이 맞혀야 할 정답. 예: 앞으로 오를지(+1) 내릴지(−1)
고정 기간 라벨	정해진 기간(예: 10일) 뒤 수익률만 보고 정답을 붙이는 방식
3중 장벽 라벨	위 벽(이익 실현)·아래 벽(손절)·세로 벽(보유 기한) 중 먼저 닿은 벽으로 정답을 정하는 방식
메타 라벨링	1차 모델이 정한 방향을 따를지 말지를 2차 모델이 다시 맞히는 방식
K-fold 교차검증	자료를 K묶음으로 나눠 한 묶음씩 돌아가며 시험에 쓰는 검증
Purged K-fold	시험 라벨 구간과 겹치는 훈련 표본을 지우고(purge) 시험 뒤 완충 구간(embargo)을 두는 K-fold
CPCV	조합 제거 교차검증(Combinatorial Purged CV). 여러 묶음 조합으로 시험해 백테스트 경로를 여러 개 만든다

고정 기간 라벨은 가는 길을 보지 않습니다

10일 뒤 수익률만 보면 중간의 손절·이익 실현이 사라진다



10일 뒤 +2%라 '상승'이지만, 실제 거래라면 4일째 −3%에서 손절됐습니다

고정 임계값(±2%)은 변동성이 커지거나 작아져도 그대로입니다

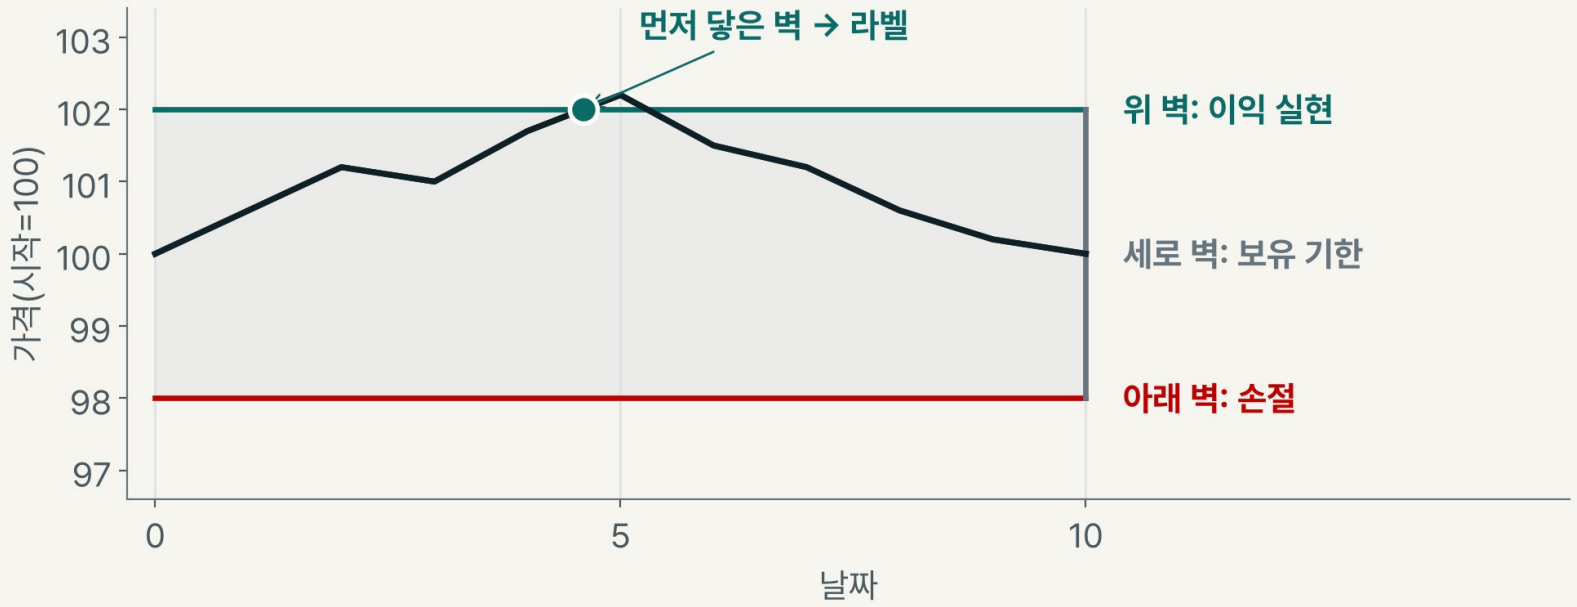
3중 장벽은 먼저 닿은 벽으로 정답을 정합니다

López de Prado(2018) 3장 — 실제 거래의 이익 실현·손절·보유 기한을 그대로 옮긴다

위 벽: 이익 실현 기준

아래 벽: 손절 기준

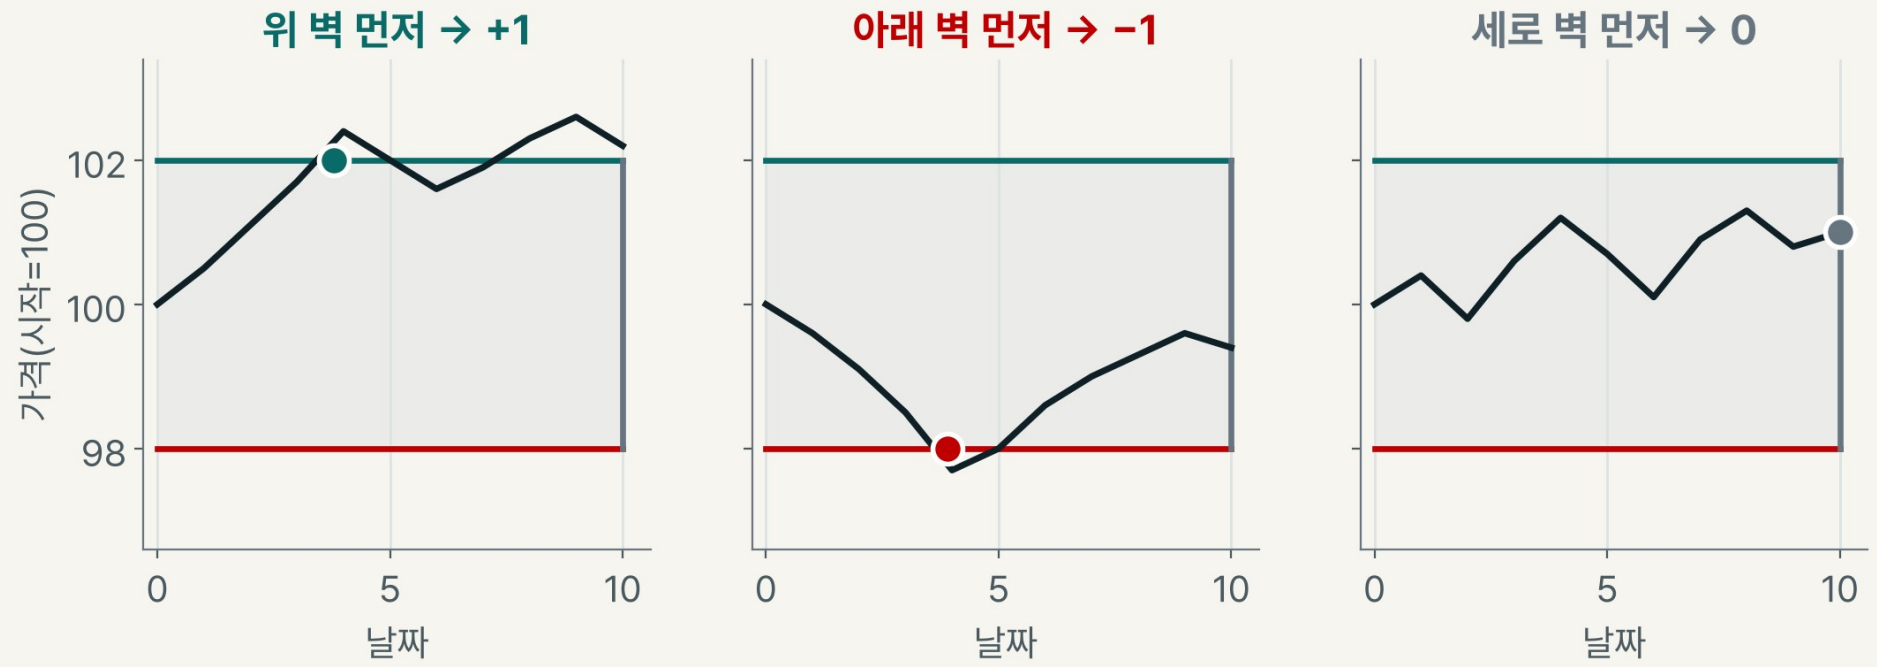
세로 벽: 보유 기한



벽의 높이는 그때의 변동성 배수로 정합니다 — 조용한 장에서는 좁게, 거친 장에서는 넓게

결과는 세 갈래로 나뉩니다

같은 벽 세 개, 다른 가격 경로 — 먼저 닿은 벽이 라벨이 된다

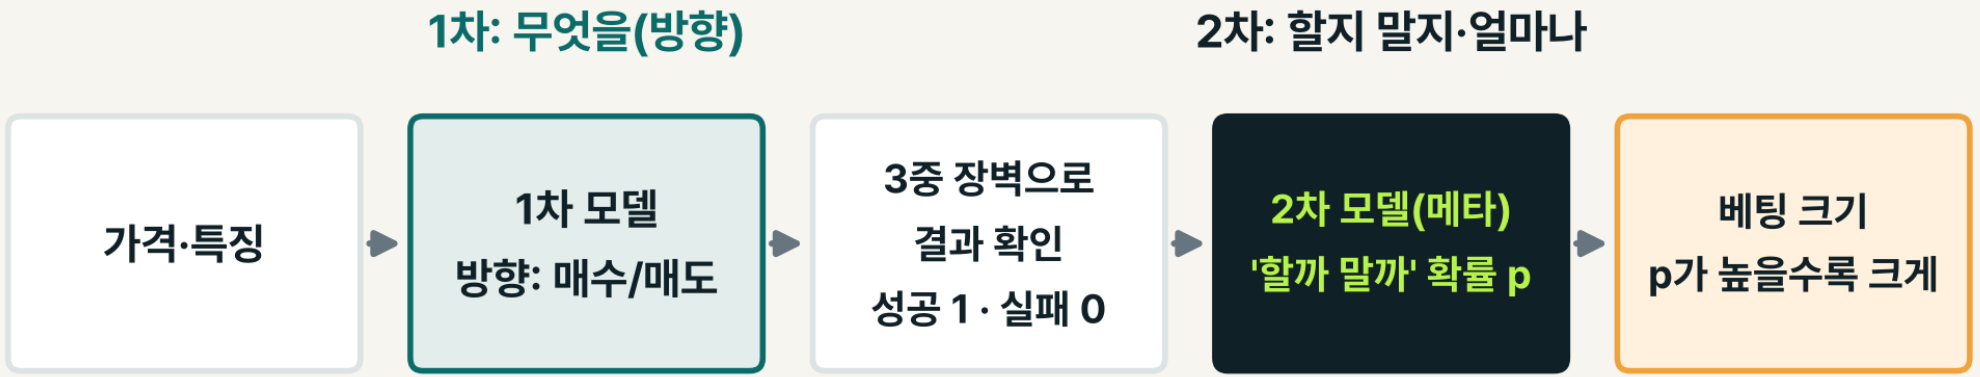


위 벽 +1 · 아래 벽 −1 · 세로 벽 0

세로 벽에 닿았을 때 0으로 둘지, 그때 수익률의 부호로 둘지는 설계 선택입니다

메타 라벨링은 '방향'과 '할지 말지'를 나눕니다

1차 모델은 방향을 정하고, 2차 모델은 그 신호를 따를 확률을 낸다



3중 장벽 결과로 1차 신호의 성공(1)·실패(0)를 라벨로 붙여 2차 모델을 훈련합니다
2차 모델의 확률 p는 거래 여부와 베팅 크기에 함께 씁니다

메타 라벨링은 정밀도를 올리고 재현율을 조금 내줍니다

1차 신호를 걸러 맞을 가능성이 높은 거래만 남긴다(예시 수치)

정밀도(precision)

거래한 것 중 맞은 비율

재현율(recall)

맞힐 수 있던 것 중 실제로 거래한 비율



1차 모델은 놓치지 않게(재현율 높게), 2차 모델은 틀린 신호를 거르게(정밀도 높게) 맡깁니다

일반 K-fold는 금융 자료에서 시험 정보를 흘립니다

K-fold 교차검증 — 묶음을 돌아가며 시험에 쓰고 나머지로 훈련한다





무작위로 섞은 K-fold: 시험 날짜 바로 옆 날이 훈련에 들어간다

이웃 날짜끼리 닮고(자기상관) 라벨 구간이 겹쳐, 시험의 정답이 훈련에 섞입니다

무작위로 섞으면 시험일 바로 옆 날이 훈련에 들어가 더 심해집니다

Purged K-fold는 겹치는 표본을 지우고 완충을 둡니다

López de Prado(2018) 7장 — 제거(purging)와 완충(embargo)



시험 라벨 구간과 겹치는 훈련 표본을 지우고, 시험 직후 일부 표본도 뺍니다

완충 길이는 정보가 퍼지는 기간에 맞춥니다 — 원문 예시는 전체 표본의 약 1%

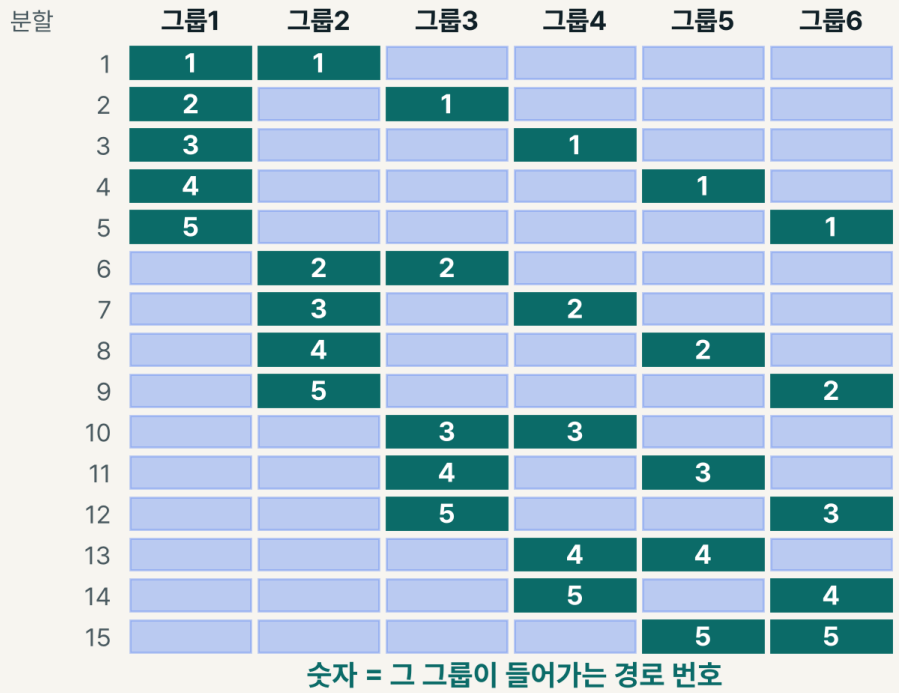
CPCV는 묶음 조합마다 시험해 경로를 여러 개 만듭니다

N=6개 그룹 중 k=2개씩 시험 → C(6,2)=15번 나누기

분할 수: C(N, k) = C(6, 2) = 15

그룹마다 시험에 C(N−1, k−1) = 5번 등장

경로 수: φ = k/N · C(N, k) = 5



분할	그룹1	그룹2	그룹3	그룹4	그룹5	그룹6
1	1	1				
2	2		1			
3	3			1		
4	4				1	
5	5					1
6		2	2			
7		3		2		
8		4			2	
9		5				2
10			3	3		
11			4		3	
12			5			3
13				4	4	
14				5		4
15					5	5

숫자 = 그 그룹이 들어가는 경로 번호

각 분할에서도 제거(purge)와 완충(embargo)은 그대로 적용합니다

CPCV는 백테스트 한 줄이 아니라 분포를 줍니다

같은 번호를 이어 붙이면 표본 밖 예측으로만 된 백테스트 경로가 5개 나온다

	그룹1	그룹2	그룹3	그룹4	그룹5	그룹6
경로 1	분할 1	분할 1	분할 2	분할 3	분할 4	분할 5
경로 2	분할 2	분할 6	분할 6	분할 7	분할 8	분할 9
경로 3	분할 3	분할 7	분할 10	분할 10	분할 11	분할 12
경로 4	분할 4	분할 8	분할 11	분할 13	분할 13	분할 14
경로 5	분할 5	분할 9	분할 12	분할 14	분할 15	분할 15

→ 경로별 샤프 → 분포로 본다

그룹마다 시험 예측을 한 번씩 이어 붙인 백테스트 한 줄

경로 5개 → 샤프비율 5개 → '이 전략의 샤프는 어느 범위인가'를 봅니다

walk-forward는 경로가 하나뿐이라, 그 한 줄이 운인지 실력인지 가리기 어렵습니다

네 가지 검증 방법을 한 표로 비교합니다

무엇을 지키고, 결과로 무엇을 얻는가

방법	시간 순서	라벨 중복	결과
무작위 K-fold	섞인다	그대로 샌다	점수 하나(부풀려짐)
Purged K-fold + embargo	부분적	지운다	점수 하나
Walk-forward	지킨다	경계에서 지워야 함	경로 하나
CPCV	부분적	지운다	경로 여러 개 → 분포

실거래 순서를 재현할 때는 walk-forward, 과적합 위험을 볼 때는 CPCV를 함께 씁니다

확장 절의 핵심을 질문 네 개로 확인합니다

질문 하나에 답 하나

고정 기간 라벨의 약점은?	가는 길(손절·이익 실현)을 무시하고, 임계값이 변동성을 따라가지 않습니다.
3중 장벽 라벨은 무엇으로 정하나?	위·아래·세로 벽 중 먼저 닿은 벽. 벽 높이는 변동성 배수입니다.
메타 라벨링의 2차 모델은 무엇을 맞히나?	1차 신호를 따를지(1) 말지(0). 확률로 베팅 크기도 정합니다.
CPCV가 walk-forward보다 나은 점은?	경로가 여러 개라 샤프비율을 분포로 보고 과적합을 가늠할 수 있습니다.

※ 출처: López de Prado, M.(2018), Advances in Financial Machine Learning, 3장·7장·12장. 그림의 가격 경로와 건수는 설명용 예시

03

사례로 보는 함의

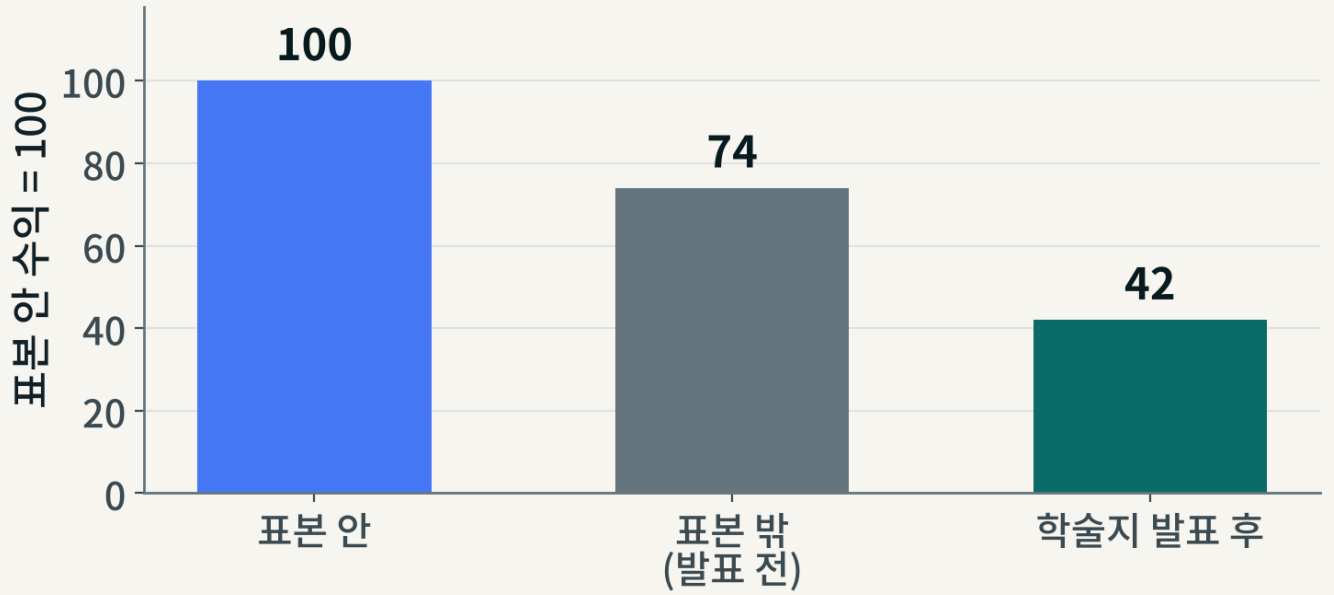
학계와 업계에서 실제로 관찰된 일을 살펴본다

학술지에 발표된 신호도 발표 뒤에는 수익이 크게 줄었습니다

McLean·Pontiff(2016, Journal of Finance) — 주식 수익률 예측변수 97개 추적

무엇을 봤나

- 논문의 표본 기간이 끝난 뒤 약 26% 줄었습니다.
- 논문이 발표된 뒤에는 약 58% 줄었습니다.



※ McLean · Pontiff(2016), 97개 예측변수의 평균. 26% · 58% 감소를 지수로 표시

일부는 과적합, 일부는 투자자들이 따라 한 결과입니다

백테스트 성과는 앞으로 받을 성과의 상한으로 읽습니다

살아남은 것만 보면 과거가 실제보다 좋아 보입니다

생존 편향(survivorship bias) — 실패한 표본이 자료에서 사라지는 문제

폭격기 일화

- 2차 대전 때 돌아온 폭격기의 총탄 자국만 보면 엉뚱한 곳을 보강하게 됩니다.
- 돌아오지 못한 비행기의 정보가 빠져 있습니다.

펀드 자료

- 청산된 펀드가 자료에서 빠지면 평균 성과가 부풀려집니다.

지수 구성 종목

- 현재 종목으로 과거를 재생하면 상장폐지 종목이 빠집니다.

백테스트에는 당시 투자할 수 있었던 전체 종목을 씁니다

수백 개의 요인이 보고된 것은 다중검정의 대표 사례입니다

요인 동물원(factor zoo) — 많이 시도하면 우연히 유의한 요인이 나온다

Harvey·Liu·Zhu (2016)

- 300개가 넘는 수익률 요인이 보고되었다고 정리했습니다.
- 새 요인에는 t값 3.0 이상의 더 높은 기준을 제안했습니다.

버터와 S&P 500

- Leinweber는 방글라데시 버터 생산량으로 S&P 500을 잘 '설명'해 보였습니다.
- 자료를 뒤지면 엉뚱한 관계도 찾아집니다.

교훈

- 시도 횟수를 기록하고 공개합니다.
- 경제적 이유가 있는 가설부터 검증합니다.

우승 전략의 점수만 보지 말고 몇 번 시도했는지를 함께 봅니다

04

정리

핵심 질문과 답으로 이번 주를 마무리한다

이번 주 핵심은 '정보·중복·운' 세 가지 점검입니다

이번 주 내용을 질문 하나에 답 하나로 확인한다

확인 질문	답
시간순으로만 나누면 검증이 완벽한가?	아닙니다. 라벨 중복, 전처리 누출, 시험 재사용도 확인합니다.
샤프가 높으면 실력이 있는가?	시도 횟수, 자료 길이, 비용, 누출을 확인해야 판단할 수 있습니다.
Purging과 walk-forward는 같은가?	다릅니다. 하나는 중복 제거, 하나는 시간 순서 제약입니다.
DSR 0.95는 실력 확률 95%인가?	아닙니다. 정한 가정 아래의 통계적 증거로 읽습니다.

정직한 검증이 화려한 모델보다 먼저입니다

WHEN DID YOU KNOW IT?

HOW MANY TIMES DID YOU TRY?

THEN TRUST THE SHARPE.

결정 당시의 정보와
시도 횟수를 함께 보고합니다.