META-LABELING

메타 레이블링

신호의 방향은 1차 모델이, 거래 여부와 크기는 2차 모델이 정한다

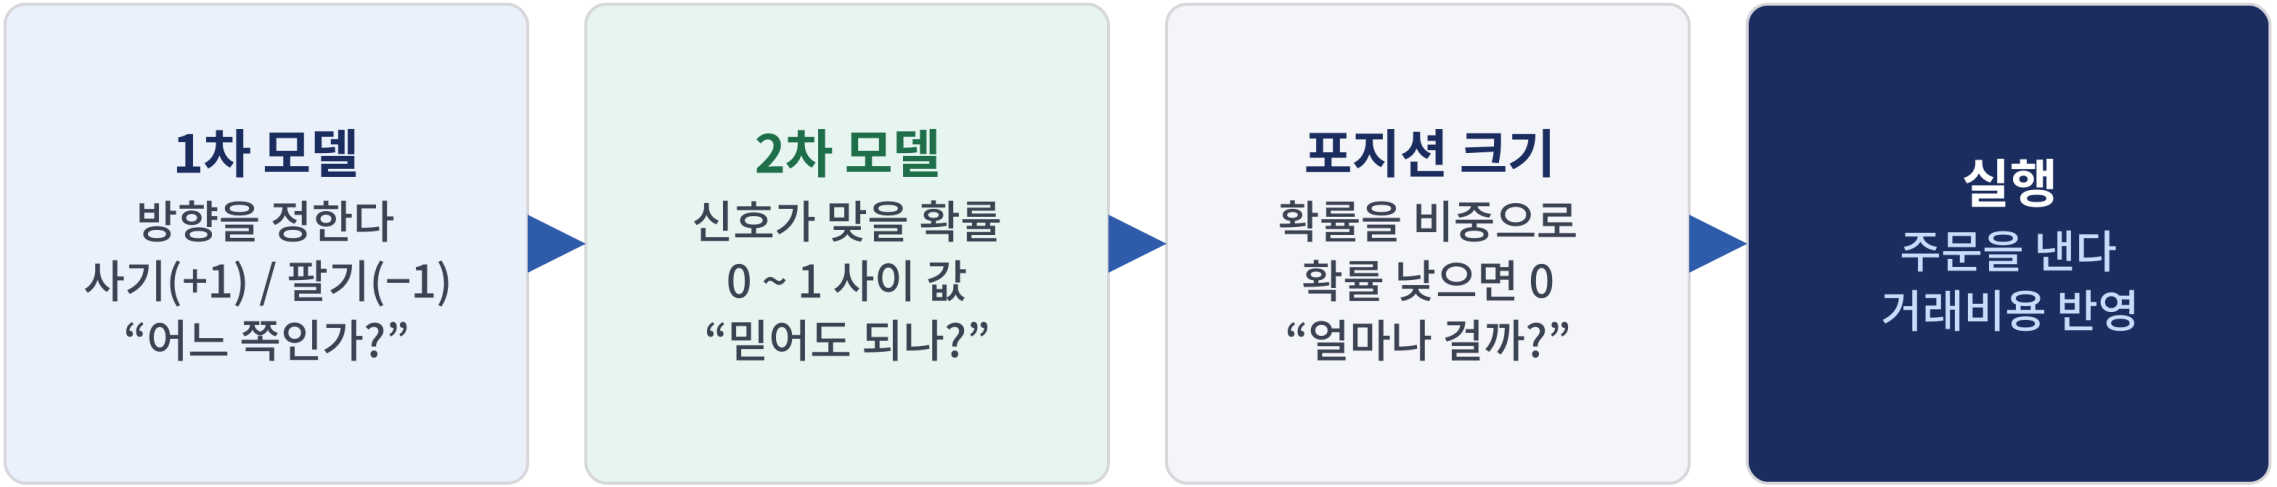
Meta-Labeling — Triple Barrier, Precision·Recall, Calibration and Bet Sizing

하나의 예 — 신호 100개 중 40개만 이익인 1차 모델 — 를 처음부터 끝까지 따라가며
삼중 배리어 레이블, 메타 레이블, 확률 보정, 포지션 크기 결정, 최신 연구까지 다룬다.

메타 레이블링은 방향 결정과 크기 결정을 두 모델로 나눈다

1차 모델은 어느 쪽으로 걸지를, 2차 모델은 걸어도 되는지와 얼마나 걸지를 정한다 (López de Prado, 2018)

방향(side)은 1차 모델이, 할지 말지와 크기(size)는 2차 모델이 정한다



1차 모델은 무엇이든 된다 — 이동평균 교차, 재정거래 규칙, 펀더멘털 퀀트, 다른 머신러닝 모델

1차 모델은 신호를 넓게 잡고, 2차 모델은 그중 진짜를 가려낸다

공항 보안 검색에 빗대 보면 — 탐지견이 짖은 가방만 검사관이 열어 본다

1차 모델 = 탐지견

의심스러우면 일단 짖는다
놓치는 가방이 거의 없다(재현율↑)
헛짖는 일도 많다(정밀도↓)

→

2차 모델 = 검사관

개가 짖은 가방만 열어 본다
진짜인지 아닌지 가려낸다
헛짖음을 걸러 정밀도를 올린다

검사관은 개가 짖지 않은 가방은 보지 않는다 — 2차 모델은 새 신호를 만들지 않는다

01

PART 1 · 기본 지식

레이블과 삼중 배리어

머신러닝에 줄 정답을 금융 데이터에서 어떻게 만드는가

고정 기간 레이블은 시기마다 다른 변동성을 반영하지 못한다

레이블(label) = 지도학습 모델에 주는 정답. 금융에서는 '이 거래가 이익이었나'가 정답이다

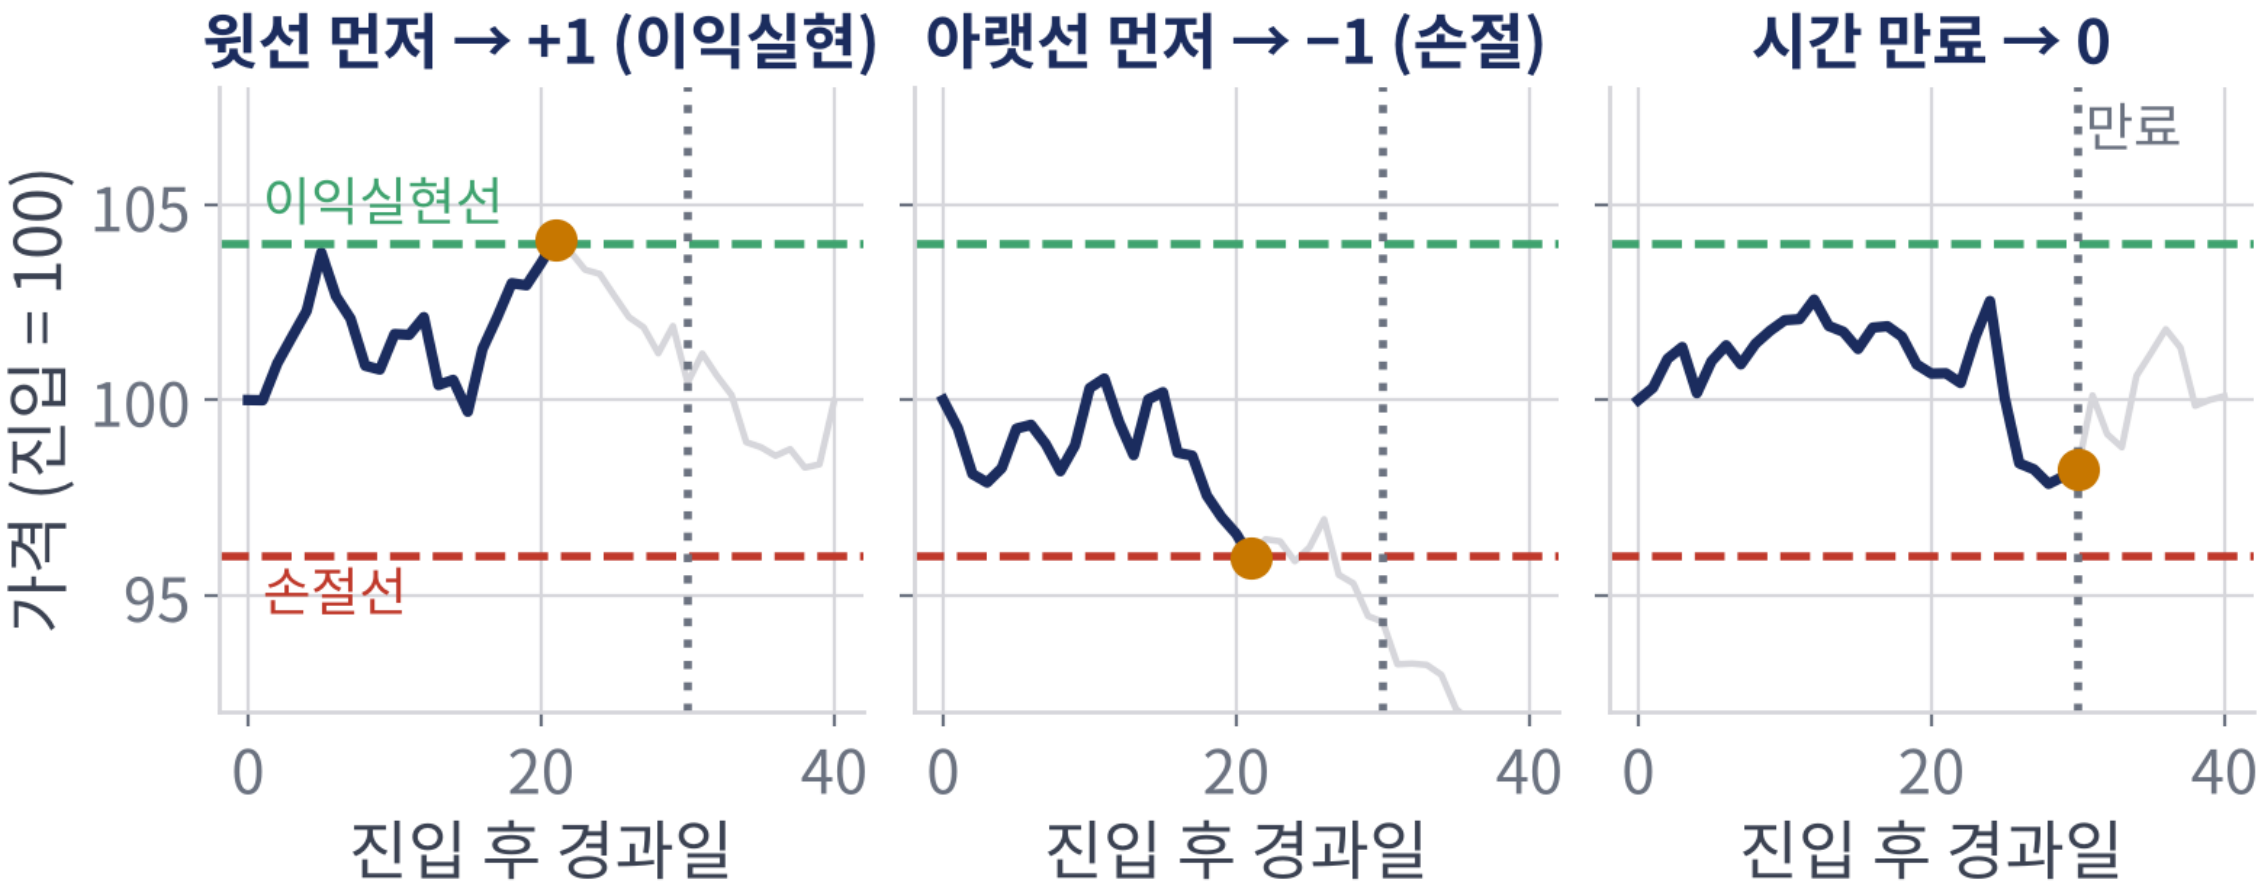
가장 단순한 방법의 문제

- '10일 뒤 수익률이 +1% 넘으면 1'처럼 기간과 문턱을 고정하기 쉽다
- 잔잔한 시기의 1%와 출렁이는 시기의 1%는 의미가 전혀 다르다
- 기간 중간에 손절선을 넘었다가 회복한 거래도 이익으로 기록된다



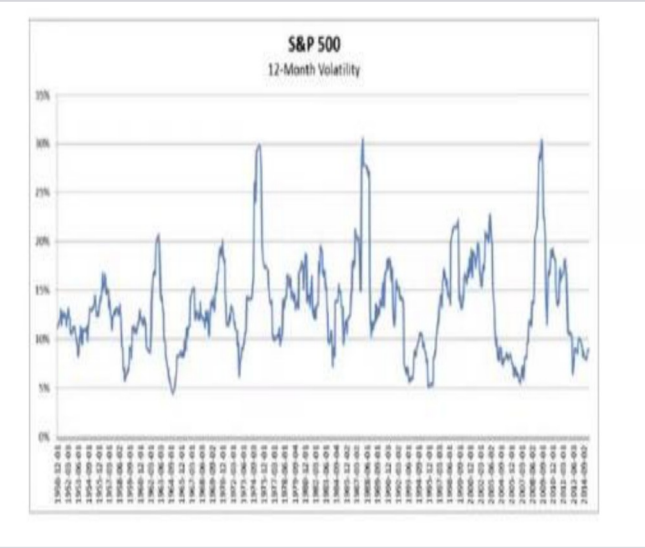
삼중 배리어는 세 선 중 먼저 닿는 선으로 결과를 정한다

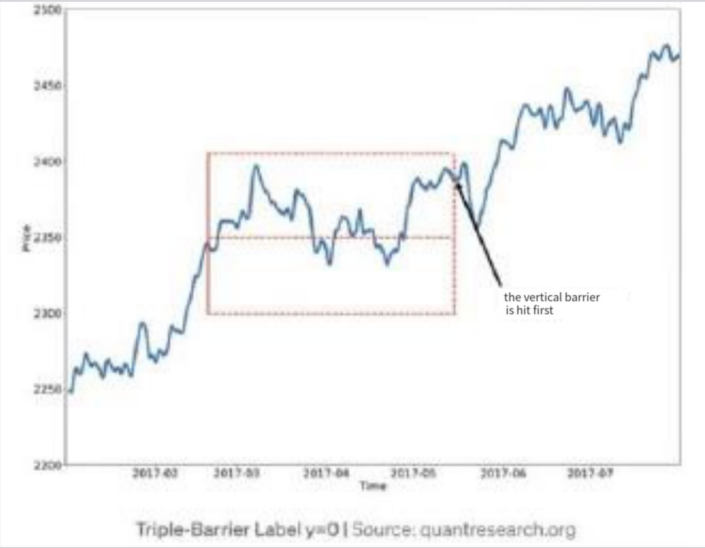
위: 이익실현선(수평), 아래: 손절선(수평), 오른쪽: 보유 기한(수직) — triple barrier



배리어 폭은 그때그때의 변동성에 맞춰 정한다

왼쪽: S&P 500의 12개월 변동성(5~30%), 오른쪽: 실제 가격에 그린 배리어 상자 (quantresearch.org)





왜 변동성에 맞추나

- 변동성은 시기마다 여섯 배까지 달라진다. 폭을 '일별 변동성의 몇 배'로 정하면 어느 시기든 같은 난이도의 목표가 된다
- 오른쪽 그림의 빨간 상자가 한 거래의 세 배리어다. 가격이 상자를 처음 벗어나는 곳에서 결과가 정해진다

02

PART 2 · 원리

메타 레이블링의 원리

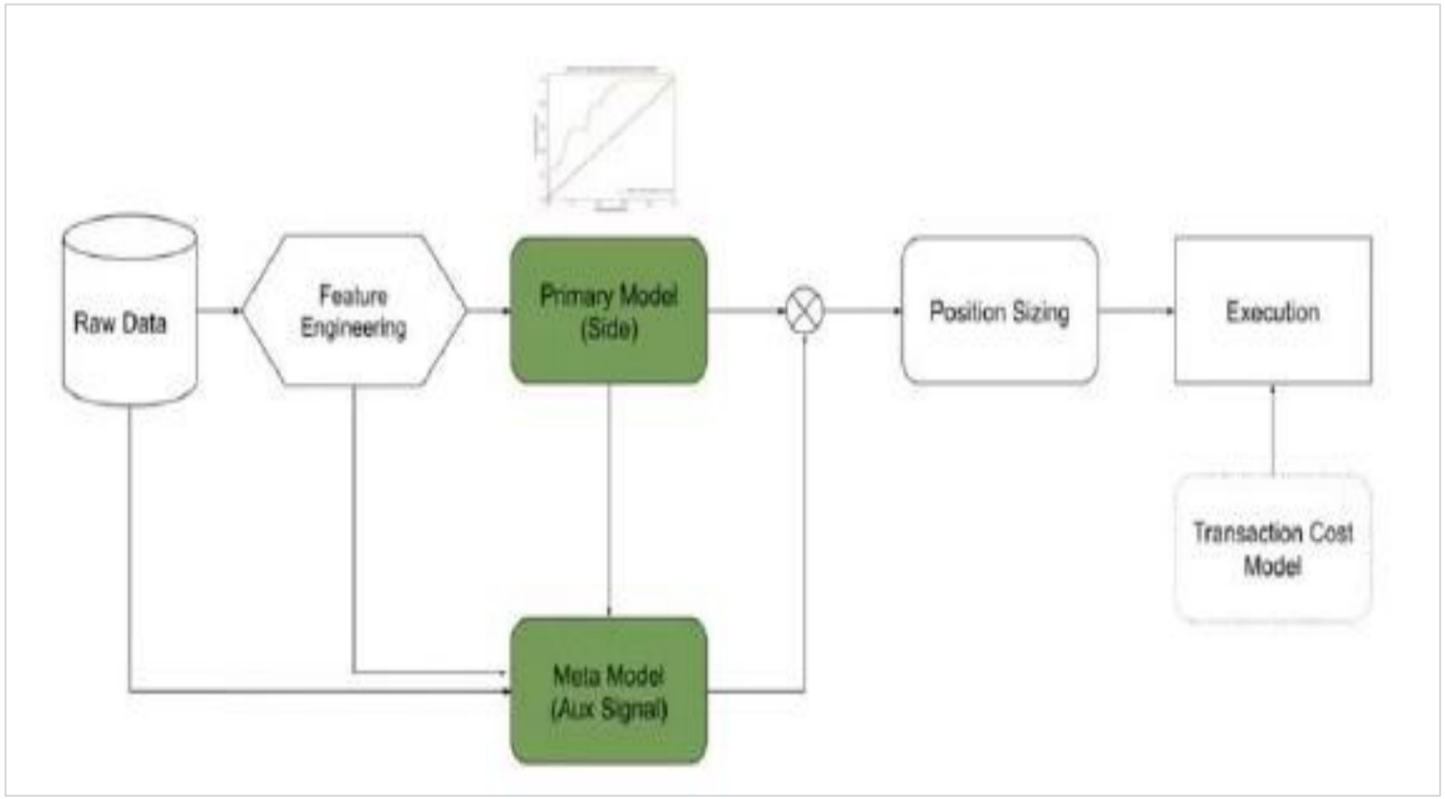
두 번째 모델은 '이 신호가 맞을까'만 배운다

2차 모델은 1차 신호가 맞았는지를 예측한다

트레이드할 것인가 말 것인가 — 원 안의 ⊗는 1차 방향과 2차 판단을 곱한다는 뜻이다

역할 나누기

- 1차 모델(Primary, side): 사기 +1, 팔기 −1 중 하나를 낸다
- 2차 모델(Meta, aux signal): 그 신호가 맞을지(1) 틀릴지(0)를 낸다
- 1차 모델은 재정거래, 기술적 분석, 전통 퀀트, ML 모델 무엇이든 된다



메타 레이블은 1차 방향대로 거래했을 때 이익이면 1이다

같은 '윗선 먼저'라도 사기 신호면 이익(1), 팔기 신호면 손실(0)이다 — 방향과 결과를 함께 본다

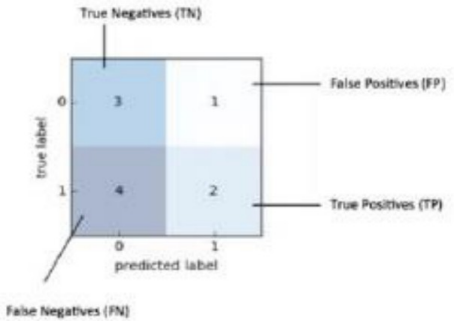
신호	1차 방향	배리어 결과	거래 손익	메타 레이블
①	사기 +1	윗선 먼저(가격↑)	이익	1
②	사기 +1	아랫선 먼저(가격↓)	손실	0
③	팔기 −1	아랫선 먼저(가격↓)	이익	1
④	팔기 −1	윗선 먼저(가격↑)	손실	0
⑤	사기 +1	시간 만료(거의 제자리)	손익 ≤ 0	0

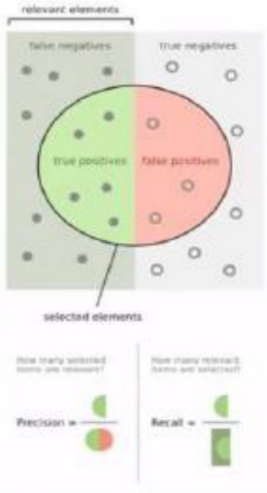
정밀도는 거래의 질을, 재현율은 기회를 놓치지 않는 정도를 잰다

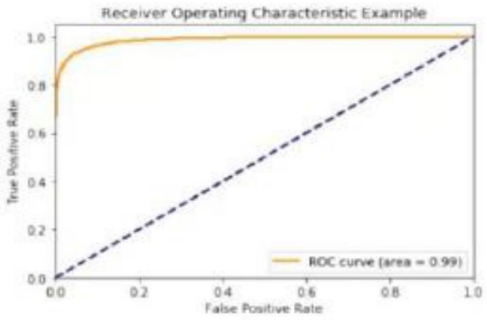
TP: 거래했고 이익, FP: 거래했는데 손실, FN: 거래 안 했는데 이익이었던 신호

$$\text{정밀도 (precision)} = \frac{\text{거래한 신호 중 실제 이익}}{\text{거래한 신호 수}} = \frac{TP}{TP+FP}$$

$$\text{재현율 (recall)} = \frac{\text{실제 이익 신호 중 거래한 것}}{\text{실제 이익 신호 수}} = \frac{TP}{TP+FN}$$

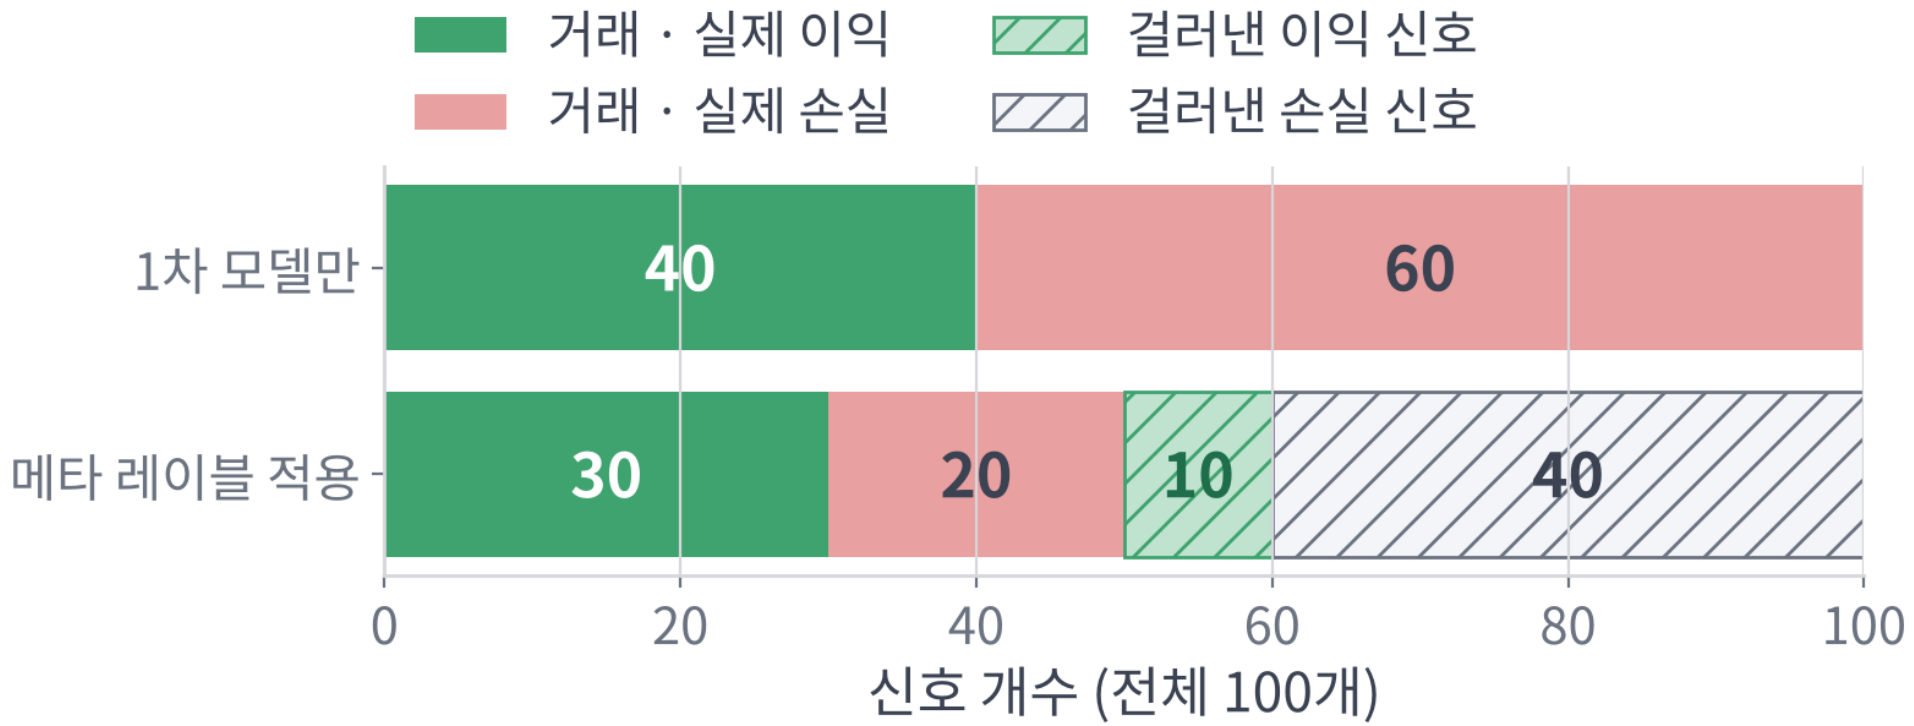






메타 레이블링은 재현율을 조금 내주고 정밀도를 크게 얻는다

예: 1차 모델 신호 100개 중 40개가 이익 — 2차 모델이 50개를 남기고 50개를 거른다 (※ 예시)



남긴 50개 중 30개가 이익(정밀도 60%), 이익 신호 40개 중 30개를 지켰다(재현율 75%)

1차 모델은 재현율을, 2차 모델은 정밀도를 맡는다

메타 레이블의 작동 원리 — 한 모델로 둘 다 잡으려 하지 않는다

1차 모델: 높은 재현율

- 정밀도가 낮아도 괜찮다. 이익 기회를 거의 놓치지 않게 문턱을 낮춘다
- 예에서 신호 100개, 그중 이익 40개 — 정밀도 40%

2차 모델: 정밀도 개선

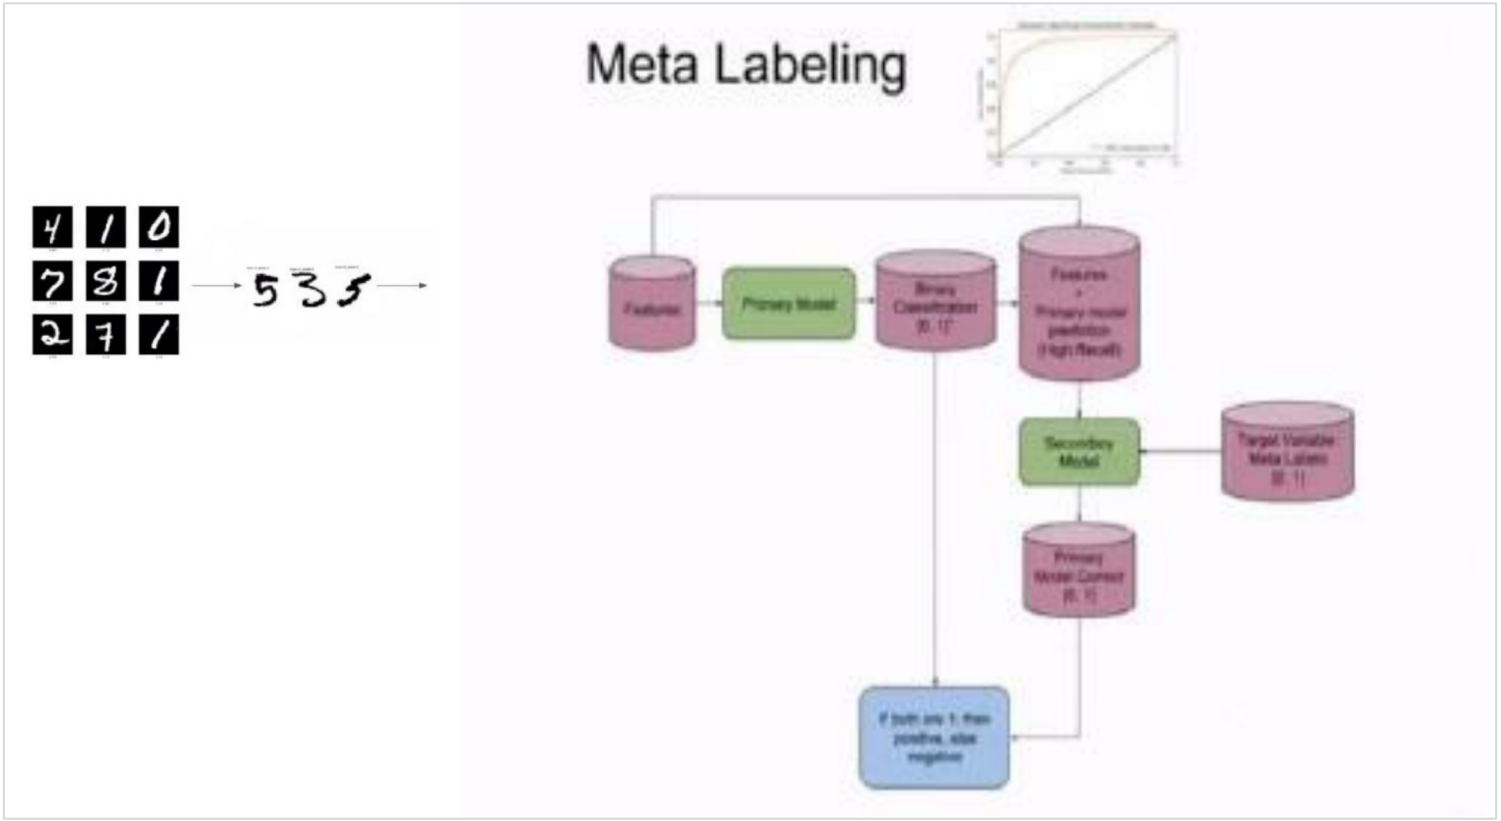
- 1차 모델이 '거래하자(Positive)'고 한 신호에만 메타 레이블을 학습한다
- 손실 신호를 걸러 정밀도를 60%로 올리고, 그 과정에서 이익 신호 10개를 놓친다

손글씨 숫자 분류로 먼저 구조를 익힌다

메타 레이블 구조 예제 — 2차 모델이 '1차 모델이 맞았나'를 배운다

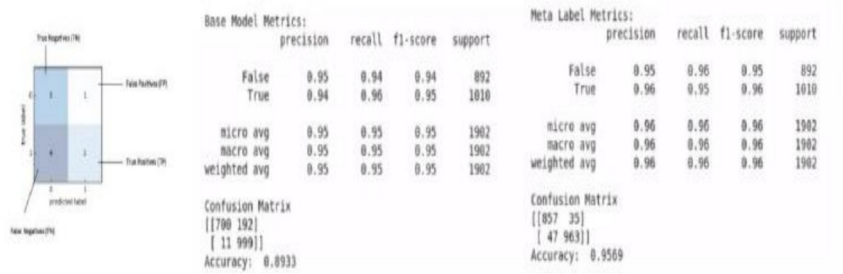
흐름

- 1차 모델이 특성으로 이진 분류(0/1)를 한다
- 특성 + 1차 예측을 2차 모델의 입력으로, '1차가 맞았나 (0/1)'를 레이블로 쓴다
- 둘 다 1이면 양성, 아니면 음성으로 최종 판정한다



메타 레이블은 거짓 양성을 192개에서 35개로 줄였다

혼동행렬 [[TN, FP],[FN, TP]] — 왼쪽: 1차 모델, 오른쪽: 메타 레이블 적용 (검증 1,902개)



※ 아래 표는 혼동행렬 기준이다. 캡처의 Base Model 리포트(정밀도·재현율 0.94~0.96)는 표본 수(892/1,010)가 같은데도 혼동행렬(정확도 0.8933)과 맞지 않아, 다른 예측으로 계산한 값으로 보인다.

지표 (혼동행렬에서 계산)	1차 모델	메타 레이블 적용
거짓 양성 FP (헛짚음)	192	35
거짓 음성 FN (놓침)	11	47
정밀도 TP/(TP+FP)	999/1,191 = 83.9%	963/998 = 96.5%
재현율 TP/(TP+FN)	999/1,010 = 98.9%	963/1,010 = 95.3%
정확도	89.3%	95.7%

정밀도가 조금만 올라도 위험 지표는 크게 좋아진다

볼린저 밴드 1차 모델 + 메타 모델, 표본 외 구간 2018-01-04 ~ 2019-01-28 (※ 표 수치는 원문 캡처 기준)

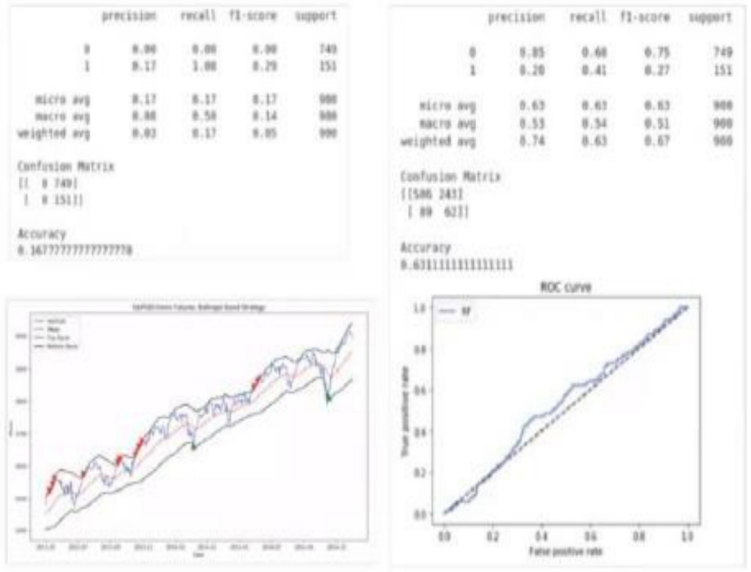


Table 1: Out-of-sample (2018-01-04 : 2019-01-28)

	Primary Model	Meta Model
Annual return		
Cumulative returns	19.7%	39.6%
Annual volatility	95.0%	56.7%
Sharpe ratio	0.65	0.82
Calmar ratio	0.29	0.96
Max drawdown	-61.9%	-36.8%
Daily value at risk	-11.7%	-7.0%

표본 외 성과	1차	메타
누적 수익률	19.7%	39.6%
연 변동성	95.0%	56.7%
샤프 비율	0.65	0.82
칼마 비율	0.29	0.96
최대 낙폭	−61.9%	−36.8%
일별 VaR	−11.7%	−7.0%

거래 정밀도는 17% → 20%에 그쳤지만, 손실 거래를 걸러 낙폭과 변동성이 크게 줄었다

03

PART 3 · 포지션 크기

확률을 포지션 크기로

2차 모델의 확률은 거래 여부뿐 아니라 얼마나 걸지도 알려 준다

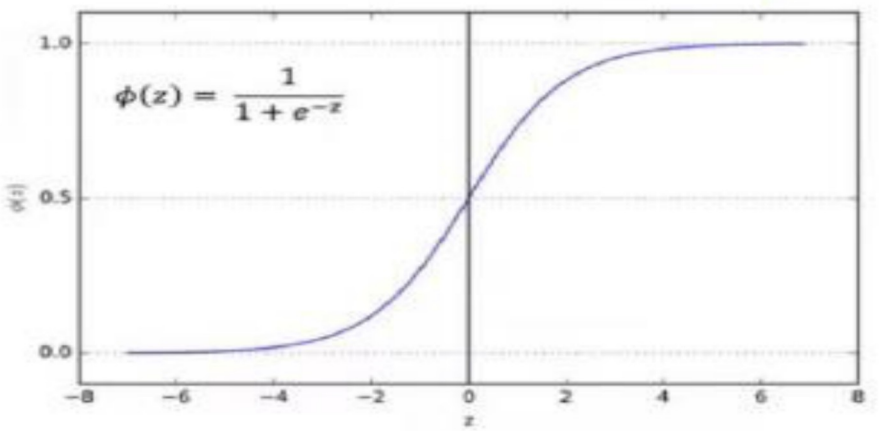
2차 모델의 출력은 0과 1 사이의 확률이어야 쓸모가 있다

로지스틱(시그모이드) 함수 φ(z)는 모델 점수 z를 확률로 바꾼다

$$\phi(z) = \frac{1}{1+e^{-z}}$$

잘 보정된 분류기

- 모델 점수 z가 클수록 확률이 1에, 작을수록 0에 가까워진다
- predict_proba가 0.8인 표본들은 실제로 약 80%가 양성이어야 한다
- 그래야 '확률 0.8'을 '이길 확률 80%'로 읽고 베팅 크기를 정할 수 있다



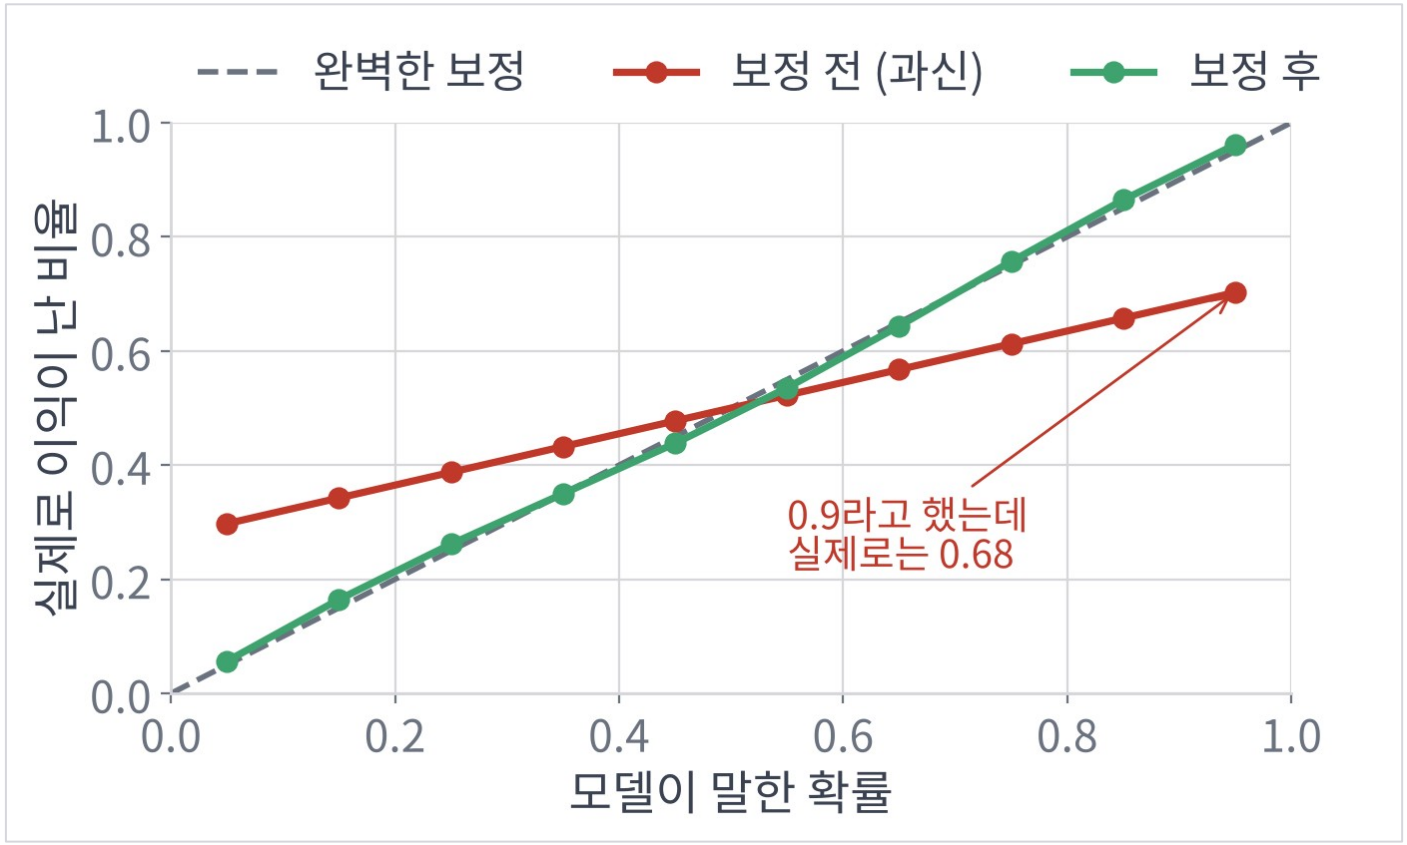
Example: a well calibrated (binary) classifier should classify the samples such that a predict_proba value of 0.8 should be approximately a 80% frequency of the positive class.

모델이 말한 확률은 실제 빈도와 어긋나기 쉬워 보정이 필요하다

확률 보정(calibration) 곡선 — 대각선에 붙을수록 말한 확률과 실제 빈도가 같다 (※ 예시 데이터)

두 가지 보정 방법

- 플랫 스케일링(Platt scaling): 시그모이드 하나를 덧씌운다. S자로 휜 곡선에 맞는다
- 등위 회귀(isotonic regression): 계단 모양 단조 함수로 맞춘다. 데이터가 많을 때 좋지만 과적합할 수 있다
- 보정은 학습에 쓰지 않은 데이터로 한다



켈리 공식은 이길 확률과 배당으로 최적 베팅 비중을 구한다

켈리의 법칙(Kelly criterion) — 장기 자산 성장률을 가장 크게 하는 베팅 비중

$$\underbrace{f^*}_{\text{최적 베팅 비중}} = \frac{\beta p - q}{\beta} \qquad \beta: \text{ 배당(이익액/손실액)}, \quad p: \text{ 이길 확률}, \quad q = 1 - p$$

$$\beta = 1 \ (\text{이익} = \text{손실}) \ \Rightarrow \ f^* = p - q = 2p - 1$$

$$\text{투자 설정}: \ f^* = \frac{p}{\text{손실률}} - \frac{q}{\text{이익률}}$$



메타 레이블과의 연결

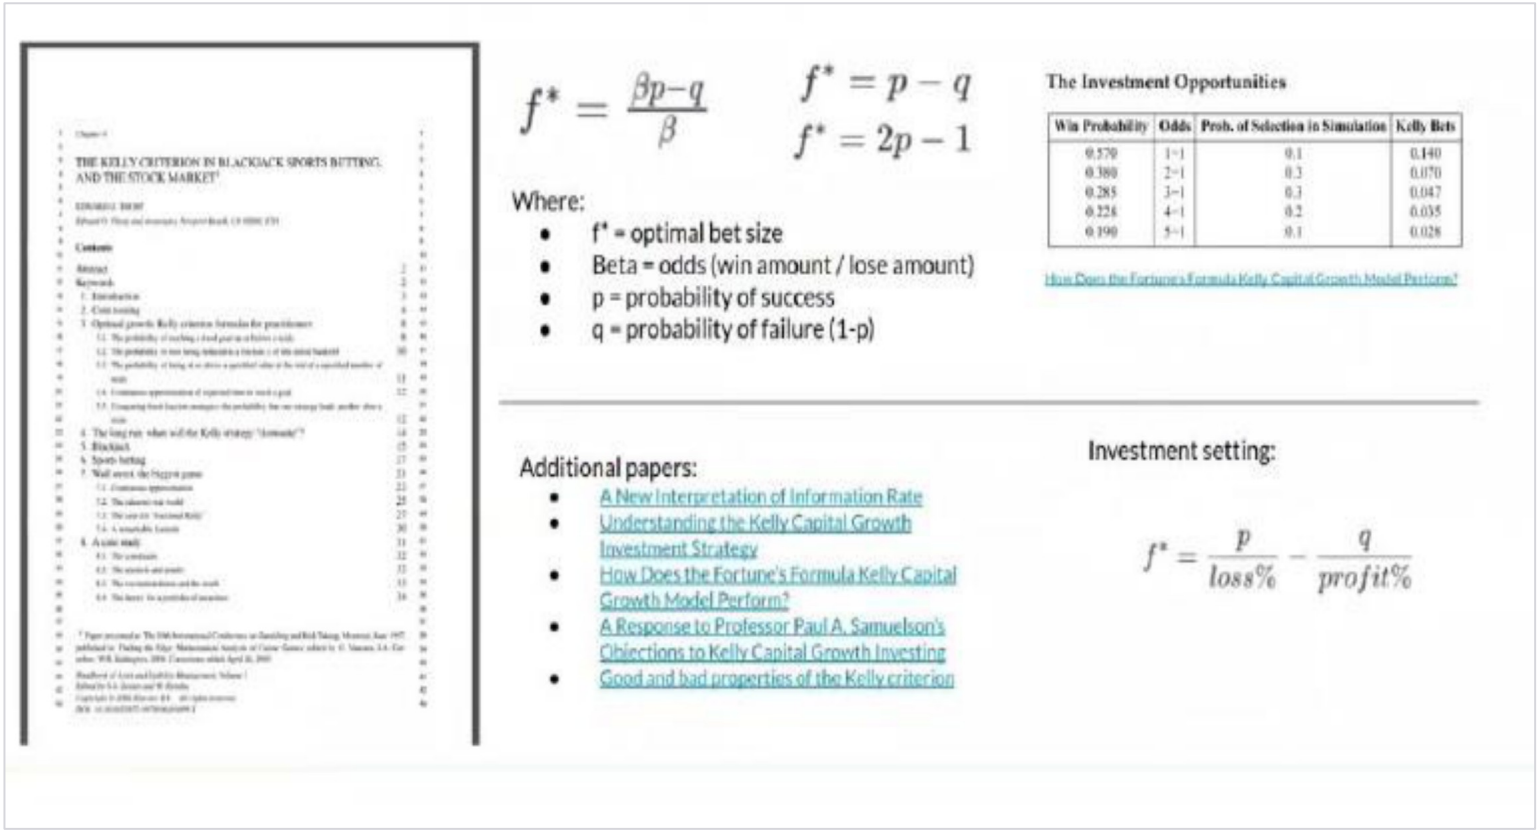
- 2차 모델의 확률을 p 자리에 넣는다. 배당이 1이면 확률 0.5 이하에서는 거래하지 않는다
- 확률 0.6이면 배당 1에서 자본의 20%를 건다

켈리 공식은 블랙잭에서 주식시장으로 건너왔다

Thorp의 논문(The Kelly Criterion in Blackjack, Sports Betting, and the Stock Market)

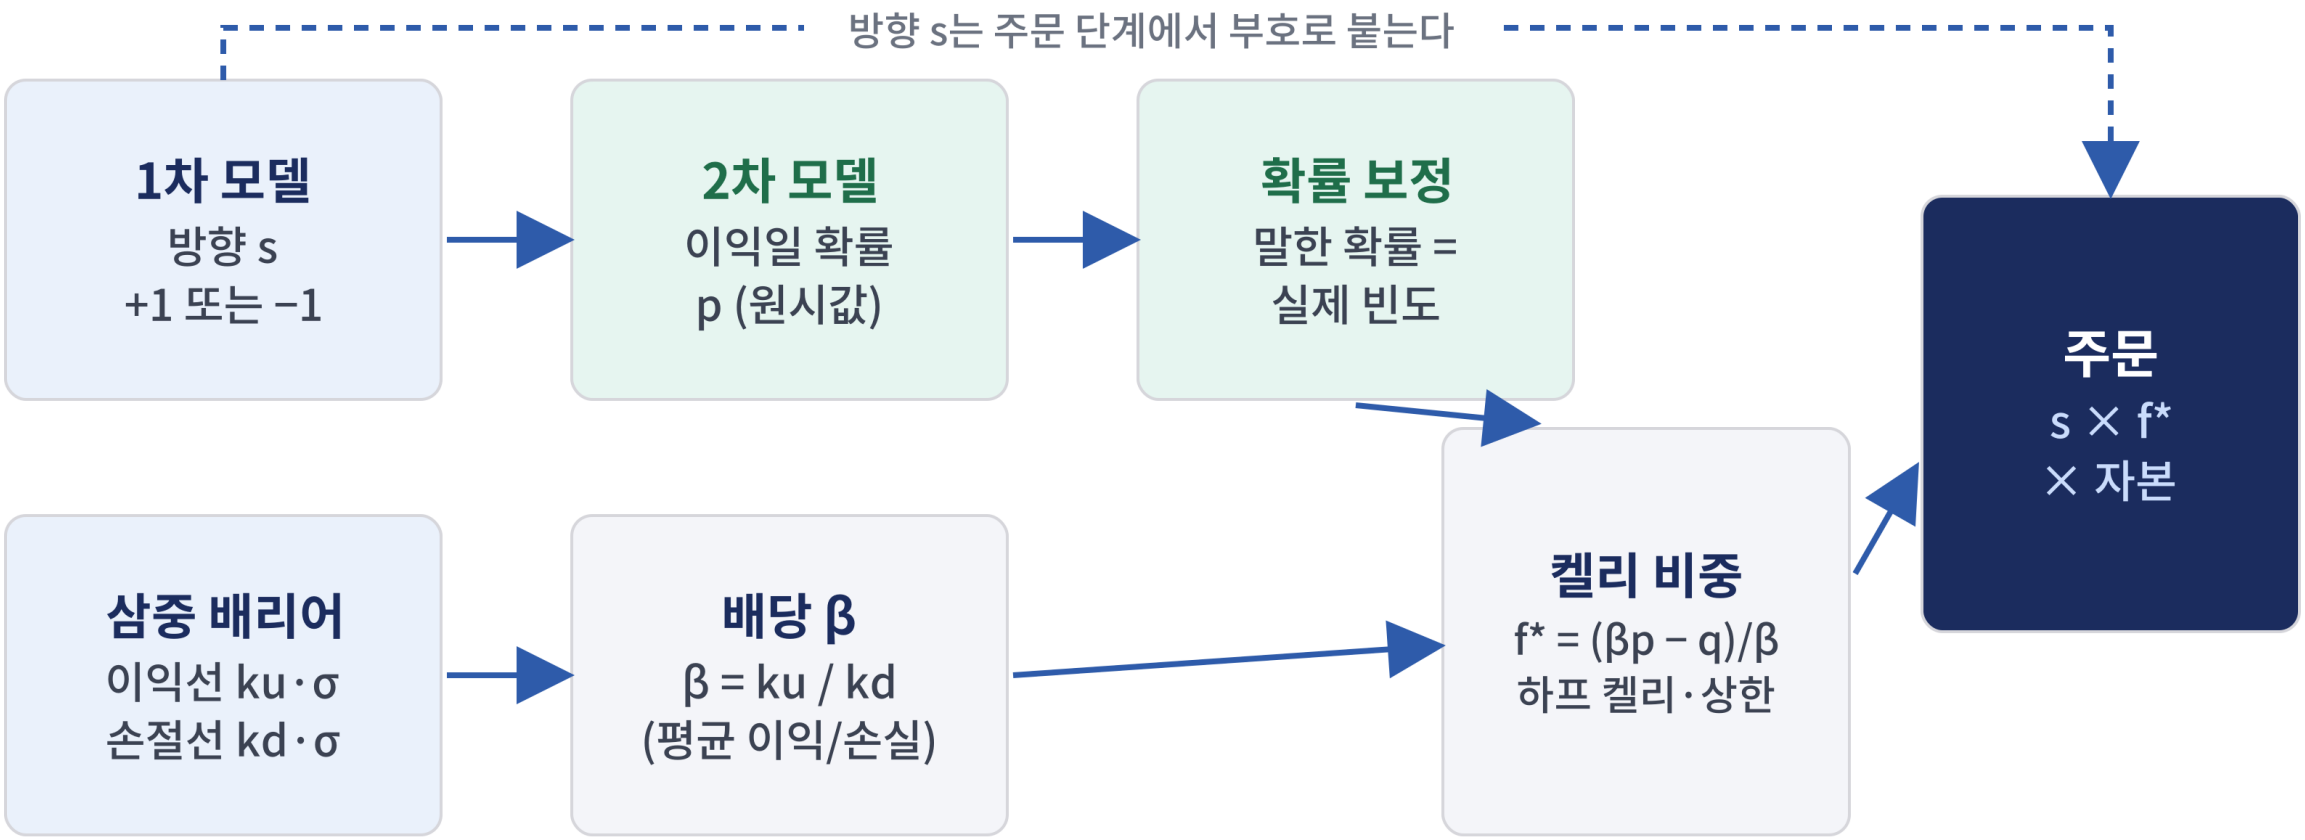
표 읽기

- 승률 0.570·배당 1:1이면 켈리 비중 0.140이다 (2×0.570 − 1)
- 배당이 커질수록 승률이 낮아도 베팅 가치가 생긴다
- 실무에서는 추정 오차 때문에 켈리의 절반 이하만 건다



2차 모델의 확률이 켈리 공식의 승률 자리에 들어간다

1차 모델은 부호를, 삼중 배리어는 배당을, 2차 모델은 승률을 준다 — 셋이 모여 주문 크기가 된다



켈리 비중은 확률과 배당으로 정하고, 방향은 부호로 붙인다

켈리 공식의 각 기호가 메타 레이블링 파이프라인의 어느 단계에서 나오는지 대응시킨다

$$f^* = \frac{\beta \overbrace{p}^{\text{2차 모델 확률}} - \overbrace{(1-p)}^{q}}{\underbrace{\beta}_{\text{배당}}}$$

$$\text{주문} = \underbrace{s}_{\text{1차 방향 } (\pm 1)} \times f^* \times \text{자본}$$

p ← 2차 모델

- 보정한 2차 모델 확률을 그대로 쓴다
- q = 1 − p는 신호가 틀릴 확률이다

β ← 삼중 배리어

- 이익 한 번의 크기를 손실 한 번의 크기로 나눈 값이다
- 배리어 폭을 정할 때 이미 정해진다

s ← 1차 모델

- 켈리 비중은 크기만 정한다
- 사기·팔기 방향은 1차 모델의 부호로 붙인다

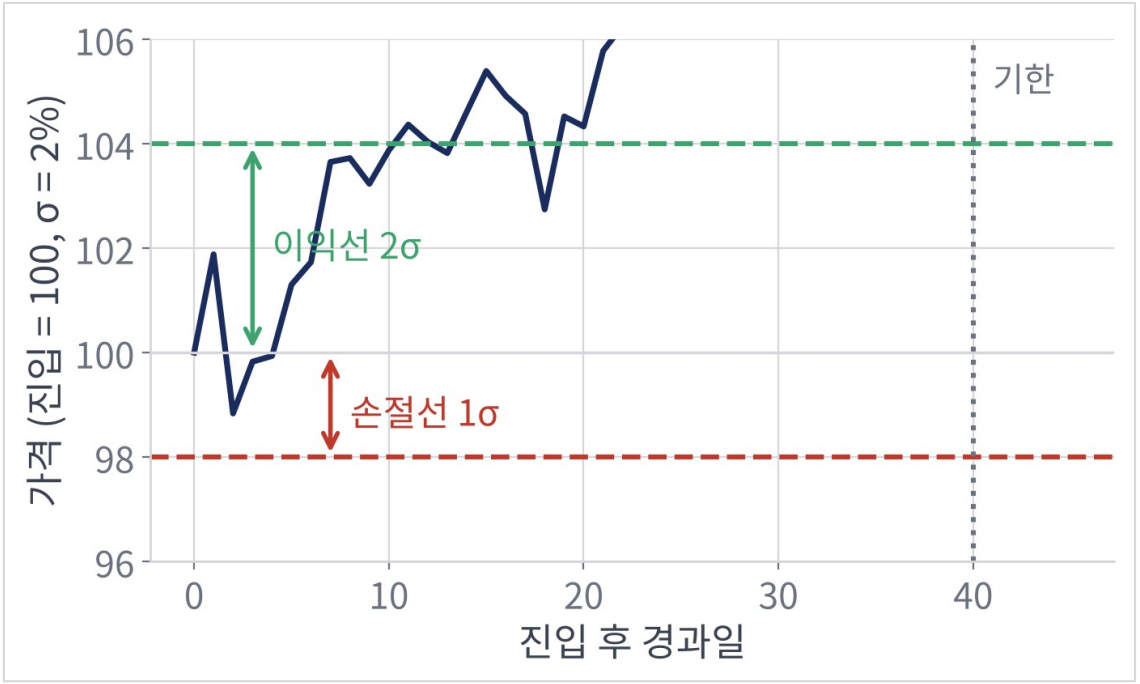
배당 β는 삼중 배리어의 폭에서 나온다

변동성 σ의 몇 배로 선을 긋느냐가 곧 이길 때와 질 때의 크기 비율이다

$$\beta = \frac{\text{이익실현 폭}}{\text{손절 폭}} = \frac{k_u \sigma}{k_d \sigma} = \frac{k_u}{k_d}$$

예

- 이익선 2σ, 손절선 1σ면 배당은 2다
- 대칭(1σ, 1σ)이면 배당 1이고 켈리 비중은 2p − 1이 된다
- 배당이 정해져야 2차 모델의 확률이 비중으로 바뀐다

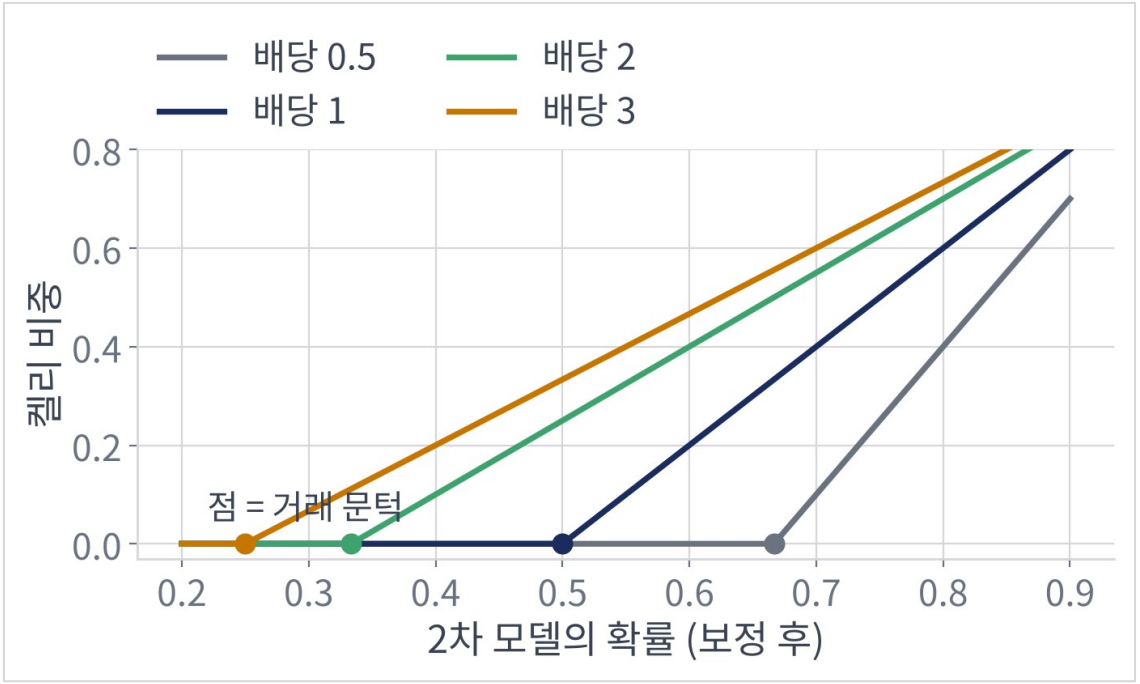


배당이 클수록 낮은 확률에서도 거래할 가치가 생긴다

켈리 비중이 0보다 클 조건에서 거래 문턱이 나온다 — 거래 여부와 크기는 하나의 규칙이다

$$f^* > 0 \iff \beta p - (1-p) > 0 \iff p > \frac{1}{1+\beta}$$

배당 β	거래 문턱 1/(1+β)	확률 0.6일 때 비중
0.5	0.67	0 (거래 안 함)
1	0.50	20%
2	0.33	40%
3	0.25	47%



문턱 아래 신호는 2차 모델이 거르고, 위 신호는 확률이 높을수록 크게 건다

숫자 예

앞의 예에서 확률 0.6인 신호에는 자본의 20%를 건다

대칭 배리어(배당 1)와 비대칭 배리어(배당 2)에서 2차 모델 확률별 켈리 비중

2차 모델 확률	배당 1: 켈리	배당 1: 하프 켈리	배당 2: 켈리	배당 2: 하프 켈리
0.40	0 (거래 안 함)	0	10.0%	5.0%
0.45	0 (거래 안 함)	0	17.5%	8.8%
0.55	10.0%	5.0%	32.5%	16.3%
0.60	20.0%	10.0%	40.0%	20.0%
0.70	40.0%	20.0%	55.0%	27.5%

읽는 법

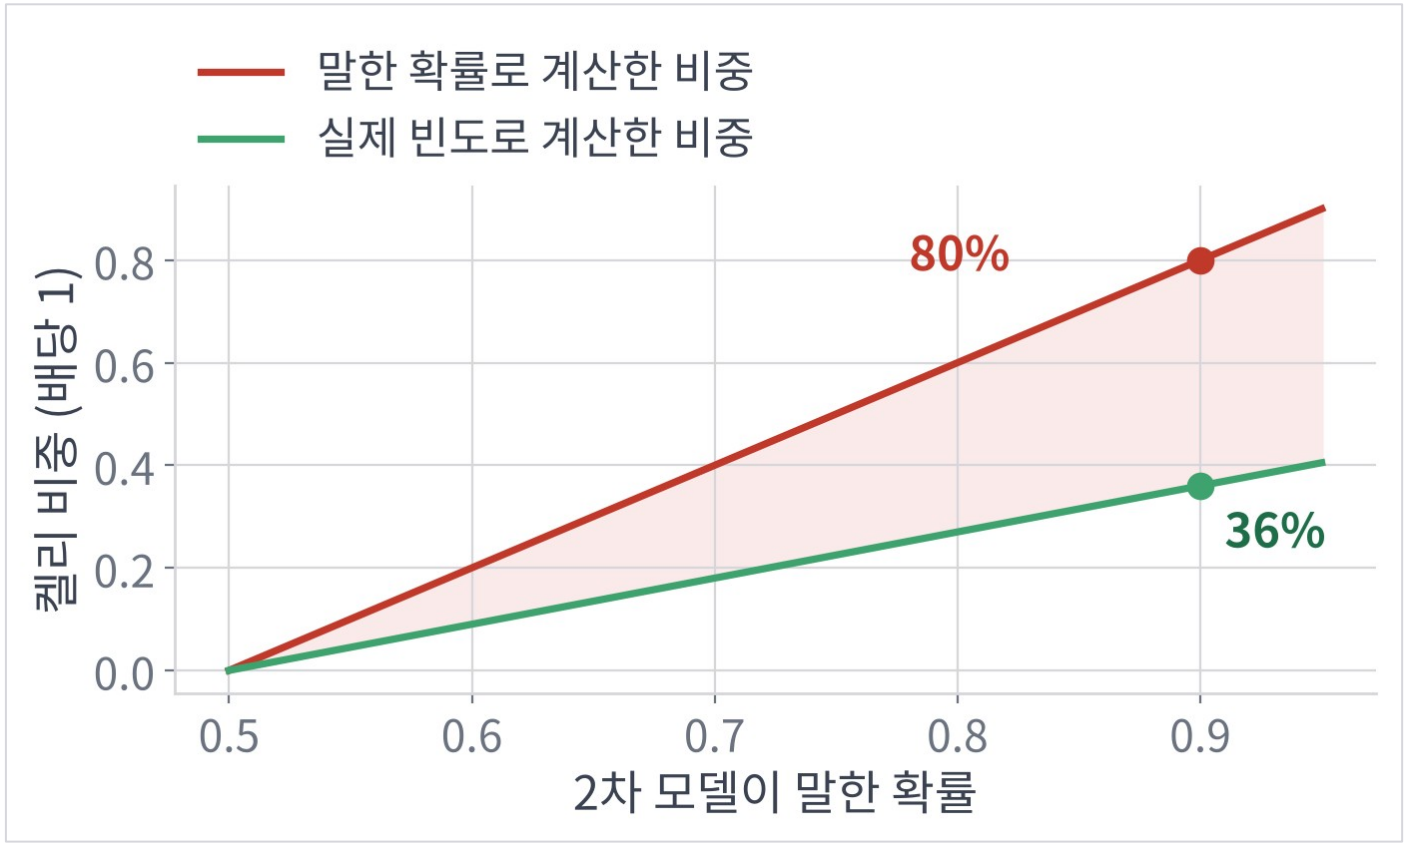
- 같은 확률 0.45라도 배당 1이면 거르고, 배당 2면 17.5%를 건다
- 실무에서는 하프 켈리 열을 쓰고 종목당 비중 상한을 따로 둔다

보정하지 않은 확률을 넣으면 켈리는 과신한 만큼 더 건다

앞의 보정 곡선 예 — 0.9라고 말했지만 실제 빈도는 0.68인 모델 (※ 예시 데이터)

무엇이 일어나나

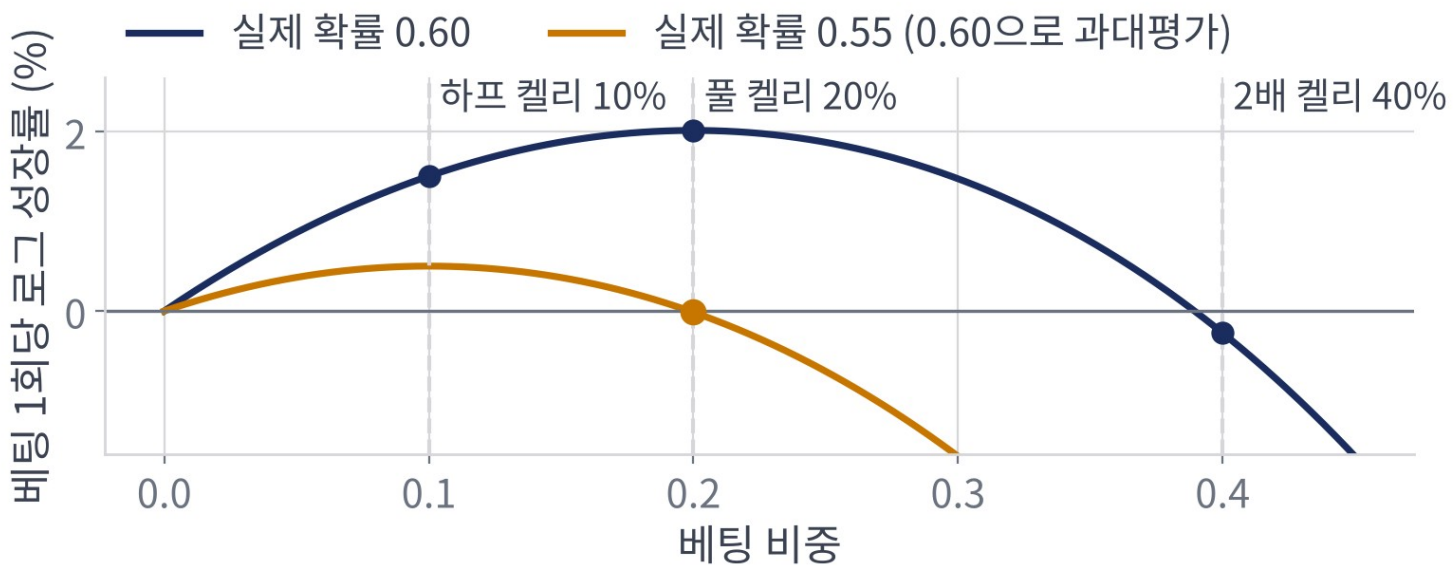
- 말한 확률 0.9로 계산하면 비중 80%, 실제 빈도 0.68로 계산하면 36%다
- 빨간 면적만큼 매번 과하게 건다
- 그래서 2차 모델의 확률은 켈리에 넣기 전에 반드시 보정한다



확률을 조금만 과대평가해도 풀 켈리의 성장률은 0이 된다

켈리 비중은 장기 로그 성장률 g(f)를 최대로 하는 f다 (Thorp) — 확률 0.6, 배당 1

$$\underbrace{g(f)}_{\text{1회당 로그 성장률}} = p\ln(1+\beta f) + q\ln(1-f)$$

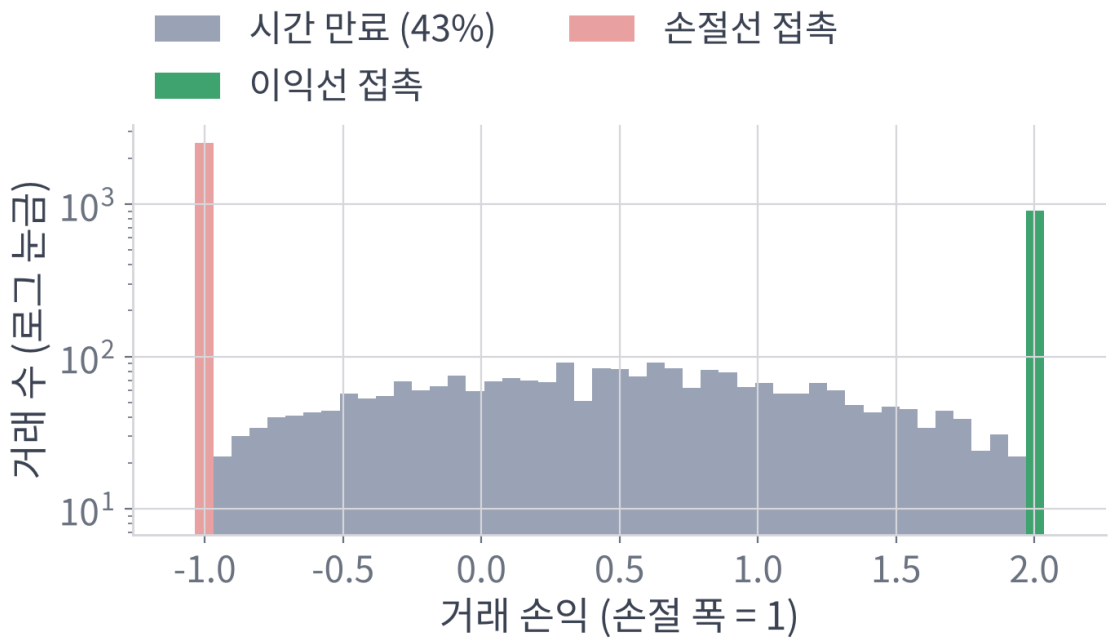


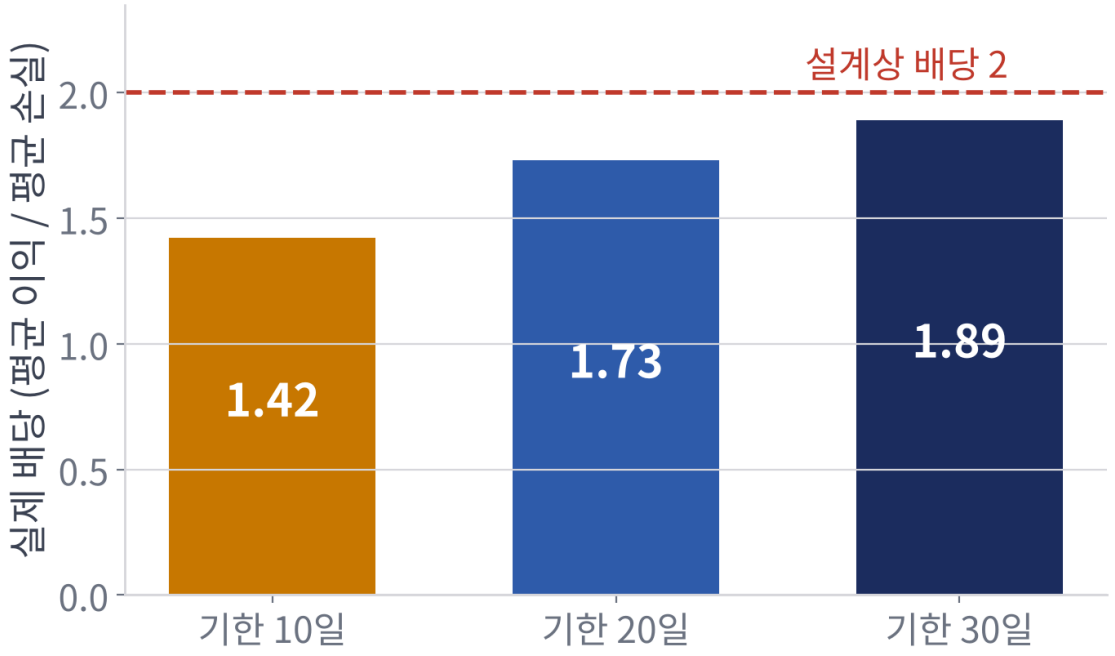
숫자로 보면

- 풀 켈리 20%: 회당 2.01%
- 하프 켈리 10%: 1.50%, 성장의 75%를 위험 절반으로 얻는다
- 2배 켈리 40%: −0.24%로 자산이 준다
- 실제 확률이 0.55인데 0.60으로 믿고 20%를 걸면 성장률 0

시간 만료 거래가 많을수록 실제 배당은 설계보다 작아진다

이익선 2σ·손절선 1σ(설계상 배당 2), 무작위 가격 경로 6,000개 모의실험 (※ 예시 데이터, 일별 표준편차 = 손절폭의 0.5배)





기한 10일이면 거래의 43%가 선에 닿지 않고 작은 손익으로 끝나, 실제 배당이 1.42에 그친다

배당은 설계값이 아니라 학습 구간의 실제 손익으로 다시 잰다

배당을 잘못 넣으면 2차 모델 확률이 맞아도 비중이 틀린다

$$\hat{\beta} = \frac{\text{학습 구간의 평균 이익}}{\text{학습 구간의 평균 손실}}$$

확률 0.45 신호	넣은 배당	켈리 비중
설계값을 넣으면	2.00	17.5%
실제값(기한 10일)을 넣으면	1.42	6.3%

실무 처방

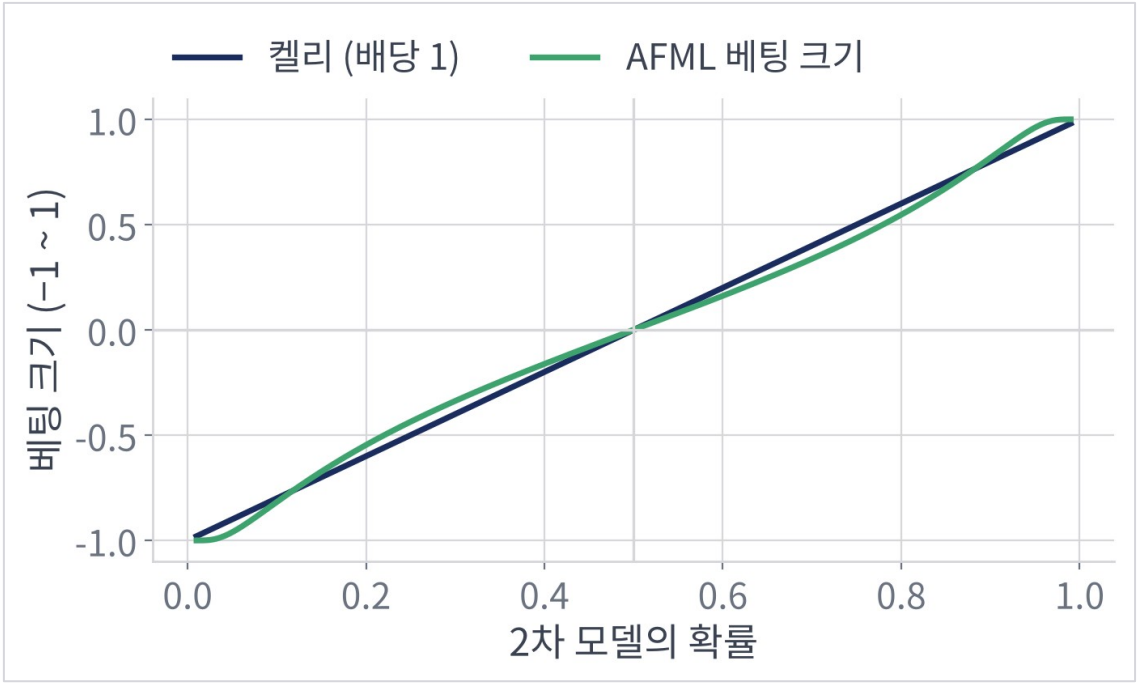
- 설계값을 쓰면 같은 신호에 세 배 가까이 과하게 건다
- 기한을 늘리면 실제 배당이 설계값에 가까워지지만 자금이 오래 묶인다

AFML의 베팅 크기 공식은 켈리 직선에 가까운 S자 곡선이다

López de Prado(2018) 10장 — 2차 모델 확률을 검정통계량 z로 바꾼 뒤 정규분포 누적함수 Φ에 넣는다

$$z = \frac{p - \frac{1}{2}}{\sqrt{p(1-p)}} \qquad \underbrace{m}_{\text{베팅 크기}} = 2\,\Phi(z) - 1$$

확률	켈리 2p − 1	AFML m
0.55	10.0%	8.0%
0.60	20.0%	16.2%
0.70	40.0%	33.7%



차이

- 확률 0.5 근처에서 켈리보다 조금 더 보수적이다
- AFML은 여기에 활성 베팅 평균과 크기 이산화를 덧붙인다

정리

2차 모델의 확률은 다섯 단계를 거쳐 주문이 된다

메타 레이블링에서 켈리 베팅까지의 실무 순서

① 보정

학습에 쓰지 않은 데이터로 확률을 보정한다

② 배당 추정

배리어 폭으로 정하되, 실제 평균 이익·손실로 다시 잰다

③ 비중과 문턱

$f^* = (\beta p - q)/\beta$, 확률이 $1/(1+\beta)$ 이하면 거래하지 않는다

④ 축소와 상한

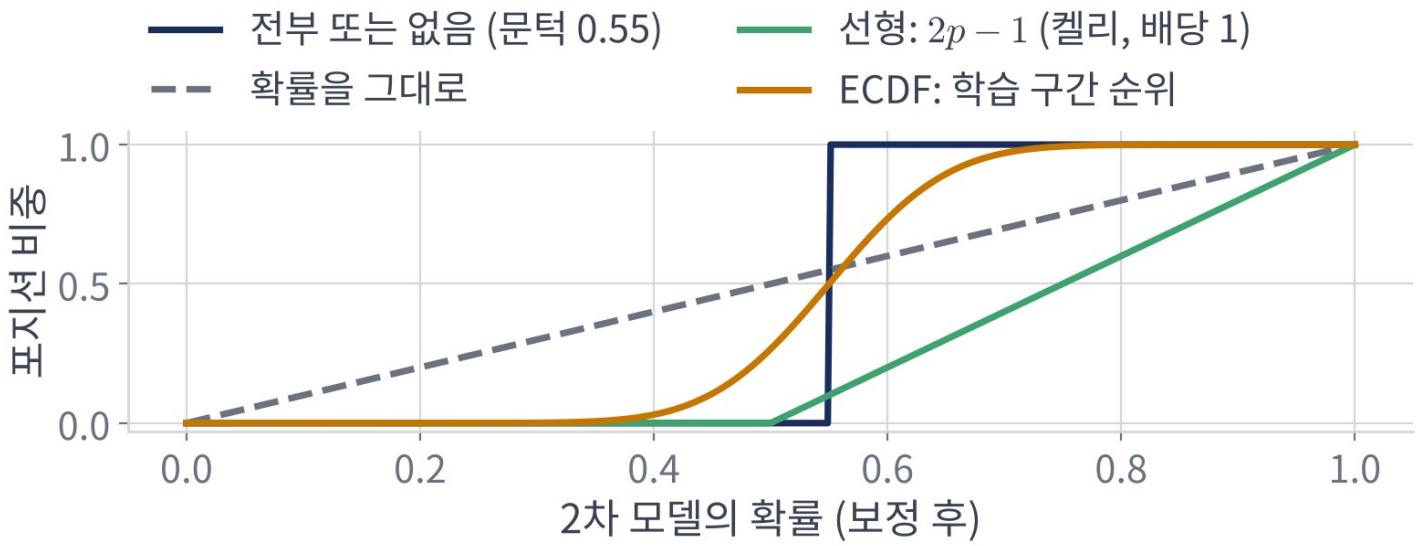
하프 켈리 이하로 줄이고 종목당 상한을 둔다

⑤ 방향 곱

1차 모델의 부호를 곱해 사기·팔기 주문을 낸다

확률을 비중으로 바꾸는 방법은 여러 가지다

Meyer·Barziy·Joubert(2023)가 비교한 포지션 크기 결정 방법 (※ ECDF 곡선은 예시)



방법

- 전부 또는 없음: 문턱 이상이면 전액
- 확률 그대로: p를 비중으로
- 선형: 학습 구간 최소·최대로 정규화(구간이 0.5~1이면 2p−1)
- ECDF: 학습 구간에서의 순위
- SOPS: 샤프 비율을 최대화하는 시그모이드
- 보정은 고정 규칙에 특히 중요하다

04

PART 4 · 구현

메타 레이블 구현

mlfinlab 함수 세 개로 삼중 배리어와 메타 레이블을 만드는 일을 Claude Code에게 시킨다

메타 레이블은 다섯 단계로 만든다

이벤트를 고르고, 기한을 붙이고, 첫 접촉을 찾고, 레이블을 매기고, 2차 모델을 학습한다

입력: 종가(close), 일별 변동성(target), 이익실현·손절 폭(pt_sl), 1차 모델의 방향(side)



함수 이름은 mlfinlab 기준 — 『Advances in Financial Machine Learning』 Snippet 3.4·3.6·3.7을 구현한 것이다

add_vertical_barrier로 각 이벤트의 보유 기한을 만들게 시킨다

각 이벤트에서 정해진 기간 뒤의 첫 가격 바 시각을 찾는다 — Snippet 3.4, 결과는 get_events의 t1 인자(선택)

[입력] 프롬프트 · Claude Code (Code 탭)

```
meta-label-lab 폴더에서 다음을 해 줘.
1. yfinance로 SPY 일봉 종가를 2015-01-01부터
   2024-12-31까지 받아 close로 저장해.
2. 일별 변동성(지수가중 표준편차, span=100)을 구하고
   그 평균을 문턱으로 대칭 CUSUM 필터를 돌려
   t_events를 뽑아.
3. add_vertical_barrier(t_events, close, num_days=10)로
   수직 배리어 t1을 만들어 줘.
4. mlfinlab을 쓸 수 없으면 AFML Snippet 3.4를
   같은 이름의 함수로 구현해.
5. t_events와 t1의 앞 5행과 개수를 보여 줘.
```

검토할 것

- t1이 모두 이벤트 시각보다 뒤인가?
- 간격이 달력일 10일 이상인가? 주말이면 다음 거래일로 밀린다
- 표본 끝의 이벤트는 t1이 없어 개수가 줄었는가?

get_events에 1차 방향을 넘겨 메타 레이블용 이벤트를 만들게 시킨다

pt_sl은 이익실현·손절 폭(0이면 끈다), target은 폭의 기준, min_ret은 최소 목표, side_prediction은 1차 방향 — Snippet 3.6

[입력] 프롬프트 · Claude Code (Code 탭)

```
이어서 get_events로 메타 레이블용 이벤트를 만들어 줘.
1. 1차 모델은 20일·50일 이동평균 교차로 해.
   t_events 시점의 방향(사기 +1, 팔기 −1)을
   side_prediction으로 넘겨.
2. target은 앞에서 구한 일별 변동성으로 해.
3. pt_sl=[2, 1]: 이익실현 2σ, 손절 1σ로 해.
4. min_ret=0.005: 이보다 작은 목표는 건너뛰어.
5. vertical_barrier_times는 앞의 t1을 써.
6. mlfinlab을 쓸 수 없으면 AFML Snippet 3.6을 구현해.
7. 결과를 events.csv로 저장하고
   앞 5행과 개수를 보여 줘.
```

검토할 것

- events에 t1, trgt, side 열이 있는가?
- pt_sl 순서가 맞는가? 0번이 이익실현, 1번이 손절
- side가 이벤트 시점까지의 가격만 썼는가?
- min_ret로 이벤트가 몇 개 줄었는가?

프롬프트 ③

get_bins로 0과 1의 메타 레이블을 만들게 시킨다

side가 없으면 bin ∈ {−1, 1}(가격 움직임), 있으면 bin ∈ {0, 1}(손익, 메타 레이블링) — Snippet 3.7

[입력] 프롬프트 · Claude Code (Code 탭)

```
이어서 메타 레이블을 만들고 2차 모델을 학습해 줘.
1. get_bins(events, close)로 bin ∈ {0, 1}을 만들어.
   mlfinlab을 쓸 수 없으면 AFML Snippet 3.7을 구현해.
2. 특성은 일별 변동성, 20일 수익률, 1차 방향으로 해.
3. 시간순으로 앞 70% 학습, 뒤 30% 검증으로 나누고
   보유 기간이 경계에 겹치는 표본은 학습에서 빼.
4. 2차 모델은 랜덤 포레스트(트리 500개)로 학습해.
5. predict_proba를 베팅 크기에, 1차 방향을 부호에 써.
6. 1차 모델만 쓸 때와 정밀도·재현율을 표로 비교해 줘.
```

검토할 것

- bin에 0과 1만 있는가?
- 학습·검증 구간의 보유 기간이 겹치지 않는가?
- 정밀도는 오르고 재현율은 내려갔는가?
- 부호가 2차 모델이 아니라 1차 방향에서 왔는가?

05

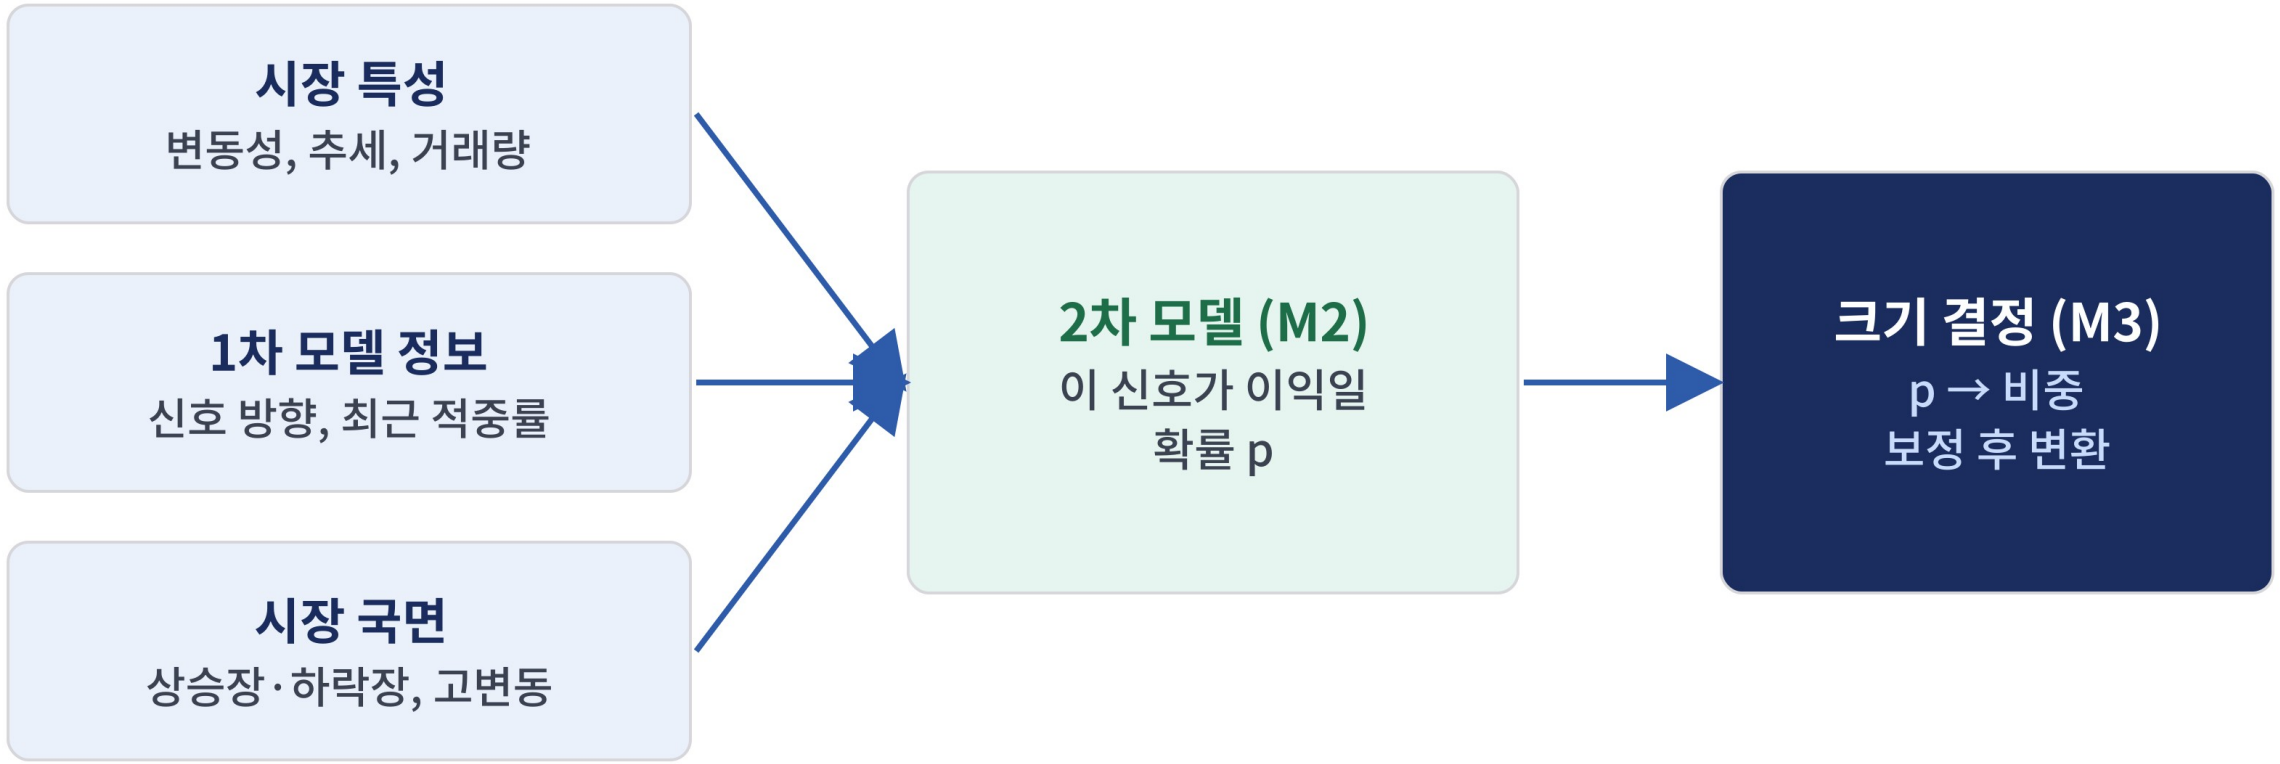
PART 5 · 최신 연구

최신 연구와 사례

2022년 이후 메타 레이블링 연구가 정리한 틀과 실험 결과

2차 모델은 시장 상태와 1차 모델의 성적을 함께 본다

Joubert(2022)의 3단계 틀 — M1이 방향을, M2가 이익 확률을, M3가 크기를 정한다



최신 연구

2차 모델을 여러 개로 나누는 구조도 있다

Meyer·Joubert·Alfeus(2022), 「Meta-Labeling Architecture」

롱·숏 분리

사기 신호와 팔기 신호에 2차 모델을 따로 둔다. 특성도 따로 고른다

순차형 (SMLA)

2차 모델을 사슬로 잇고, 앞 모델의 출력을 다음 모델이 받는다

조건부 (CMLA)

시장 국면마다 전담 2차 모델을 두고 결과를 합친다

역 메타 레이블링

2차 모델의 특성 중요도로 1차 모델을 고친 뒤 다시 적용한다

언제 나누나

- 롱과 숏의 성격이 다르거나, 시장 국면에 따라 1차 신호의 품질이 크게 바뀔 때 2차 모델을 나눈다

최신 연구

시장 국면이 여럿이고 비선형일수록 앙상블 2차 모델이 유리하다

Thumm·Barucca·Joubert(2023), 「Ensemble Meta-Labeling」

배깅형

- 단순한 모델(선형판별, 퍼셉트론, 의사결정트리)을 부트스트랩 표본으로 여럿 학습해 투표·가중 결합한다
- 분산과 과적합을 줄인다

부스팅형

- 같은 종류의 모델을 순서대로 학습해 앞 모델의 오류를 고친다
- 편향을 줄이고 비선형 상호작용을 잡는다

결론

- 데이터가 여러 시장 국면에 걸치고 패턴이 비선형일수록 앙상블의 이득이 크다. 결합 방식(투표·가중·스태킹)도 모델 선택의 기준이 된다

메타 레이블 필터는 낙폭을 줄였지만 손실 전략을 살리지 못했다

RSI 1차 모델 + 랜덤 포레스트 2차 모델, EURUSD 1시간 봉, 표본 외 2022~2024

방식	거래 수	승률	손익비	총손익(pips)	최대 낙폭(pips)
RSI만	576	49.3%	0.93	−625	−1,392
메타 레이블 필터	121	43.0%	0.72	−577	−593
필터 + 확률 크기	121	43.0%	0.72	−86	−96

무엇이 일어났나

- 확률 0.55 미만 신호를 걸러 거래의 79%를 없앴다
- 2차 모델의 표본 외 정확도는 48%로 동전 던지기보다 못했다

교훈

- 낙폭 감소는 예측력이 아니라 노출 감소에서 왔다
- 1차 모델에 우위가 없으면 2차 모델도 살리지 못한다

주의

메타 레이블링의 성과는 1차 모델과 검증 방식에 달려 있다

실무에서 자주 놓치는 네 가지

새 신호를 만들지 않는다

- 2차 모델은 1차 신호를 거를 뿐이다. 1차 모델이 놓친 기회는 되살리지 못한다

레이블이 겹친다

- 보유 기간이 겹치는 레이블은 서로 독립이 아니다. 교차검증 때 겹치는 구간을 지운다(purged k-fold)

확률을 보정한다

- 보정하지 않은 확률을 켈리 공식에 넣으면 과신만큼 과하게 건다

비용을 넣어 평가한다

- 거래를 거르면 비용도 준다. 정밀도가 아니라 비용 차감 후 성과로 비교한다

1차 모델은 방향을, 2차 모델은 거래와 크기를 정한다

메타 레이블링에서 기억할 세 가지

1

삼중 배리어로 레이블을 만든다

변동성에 맞춘 이익실현·손절선과 보유 기한 중 먼저 닿는 선이 결과다

2

1차 모델이 기회를 넓게 잡고, 2차 모델이 그중 진짜를 고른다

예에서 정밀도는 40%에서 60%로 올랐고, 재현율은 75%를 지켰다. 손실 거래는 60개에서 20개로 줄었다

3

보정한 확률로 크기를 정한다

배당 1이면 켈리 비중은 2p − 1. 1차 모델에 우위가 있어야 전체가 산다

이 강의의 참고문헌

- López de Prado, M. (2018). Advances in Financial Machine Learning. Wiley. — 3장 삼중 배리어·메타 레이블, 10장 베팅 크기
- Joubert, J. F. (2022). Meta-Labeling: Theory and Framework. Journal of Financial Data Science, 4(3), 31–44.
- Meyer, M., Joubert, J. F., & Alfeus, M. (2022). Meta-Labeling Architecture. Journal of Financial Data Science, 4(4), 10–24.
- Thumm, D., Barucca, P., & Joubert, J. F. (2023). Ensemble Meta-Labeling. Journal of Financial Data Science, 5(1), 10–26.
- Meyer, M., Barziy, I., & Joubert, J. F. (2023). Meta-Labeling: Calibration and Position Sizing. Journal of Financial Data Science, 5(2), 23–40.
- Thorp, E. O. The Kelly Criterion in Blackjack, Sports Betting, and the Stock Market.
- Njoroge, P. M. (2026.5). Meta-Labeling the Classics (Part 1): Filtering and Sizing RSI Trades. MQL5.