NLP · LLM · RAG
글 읽기와 근거 찾기

글을 숫자로 바꾸고, 다음 말을 고르고, 근거를 찾아 답한다



금융 머신러닝 · 12주차

이번 주는 네 단계로 진행합니다

기본 지식에서 출발해 핵심 개념, 사례, 정리 순서로 읽는다

01	기본 지식	**벡터와 생성의 원리** 벡터·차원, 생성 루프, 키워드와 의미 검색
02	핵심 개념	**토큰에서 RAG까지** 임베딩, 코사인 유사도, 소프트맥스, 어텐션, RAG
03	사례	**금융 문서와 AI의 실수** 금융 감성사전, RAG의 오답 지점, 가짜 판례
04	정리	**근거를 확인하는 습관** 확인 질문과 답

자연스러운 답변만으로 사실 확인이 끝나지 않습니다

01

기본 지식

언어모델을 이해하기 위한 기초 개념을 정리한다

벡터는 여러 숫자를 순서대로 묶은 목록입니다

임베딩을 이해하려면 벡터의 방향과 거리를 먼저 알아야 한다

VECTOR

벡터

- (1, 0)처럼 숫자를 묶은 것이며 방향과 길이가 있습니다.

DIMENSION

차원

- 묶인 숫자의 개수입니다. 실제 임베딩은 수백 차원 이상입니다.

SIMILARITY

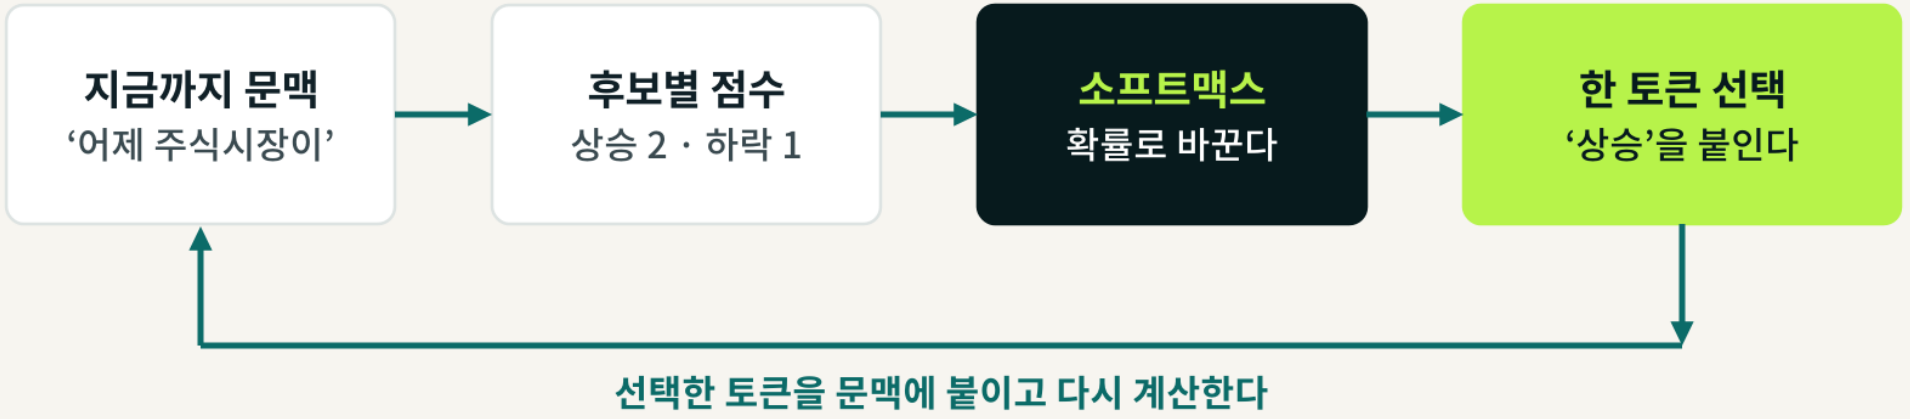
유사성

- 방향이 비슷할수록 의미가 비슷하다고 봅니다.

그림은 2차원이지만 같은 원리가 고차원에서도 쓰입니다

LLM은 한 토큰을 고르고 다시 계산하는 일을 반복합니다

생성(generation)은 다음 토큰 예측을 이어 붙이는 과정이다



긴 답변도 한 조각씩 이어 붙인 결과입니다

그럴듯한 문장과 사실인 문장은 다릅니다

키워드 검색과 의미 검색은 서로 다른 강점이 있습니다

RAG의 검색 단계에서 어떤 방식을 쓸지 고를 때의 기준

KEYWORD · TF-IDF

키워드 검색

- 같은 단어가 나오면 잘 찾습니다.
- 표현이 다르면 놓칠 수 있습니다.

숫자·고유명사에 강함

SEMANTIC · EMBEDDING

의미 검색

- 표현이 달라도 뜻이 비슷하면 찾습니다.
- 정확한 숫자 일치에는 약할 수 있습니다.

바꿔 말한 질문에 강함

두 방식을 함께 쓰고 검색 결과를 따로 평가합니다

02

토큰에서 RAG까지

원문의 핵심 개념 — 임베딩, 유사도, 생성, 어텐션, RAG

컴퓨터는 글을 먼저 숫자로 바꾸어야 읽을 수 있습니다

사람은 '금리 인상'을 읽으면 대출과 경기를 떠올리지만 컴퓨터는 그렇지 않다

NLP

자연어 처리

- 자연어를 처리하는 기술 전체를 가리키는 넓은 이름입니다.

LLM

대규모 언어모델

- 많은 언어 자료로 학습한 큰 언어모델입니다.

RAG

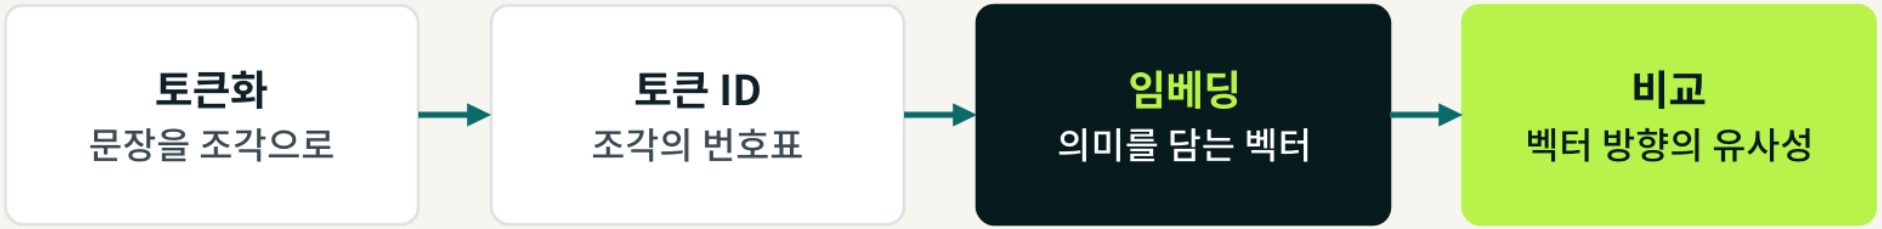
검색 증강 생성

- 모델이 답하기 전에 외부 문서를 찾아 넣어 주는 시스템 구성입니다.

NLP는 분야, LLM은 모델, RAG는 시스템 구성 방식입니다

토큰, 토큰 ID, 임베딩은 서로 다른 단계입니다

도서관 비유: 번호표는 책을 식별하고, 주제 지도는 비슷한 내용을 가까이 놓는다



번호 100과 101이 가까워도 뜻이 가까운 것은 아니다

의미가 비슷하면 가까운 방향에 놓일 수 있다

한 토큰이 반드시 한 단어는 아닙니다

번호가 가깝다고 뜻이 가까운 것은 아닙니다 — 의미 비교에는 임베딩을 씁니다

코사인 유사도는 두 벡터의 방향을 비교합니다

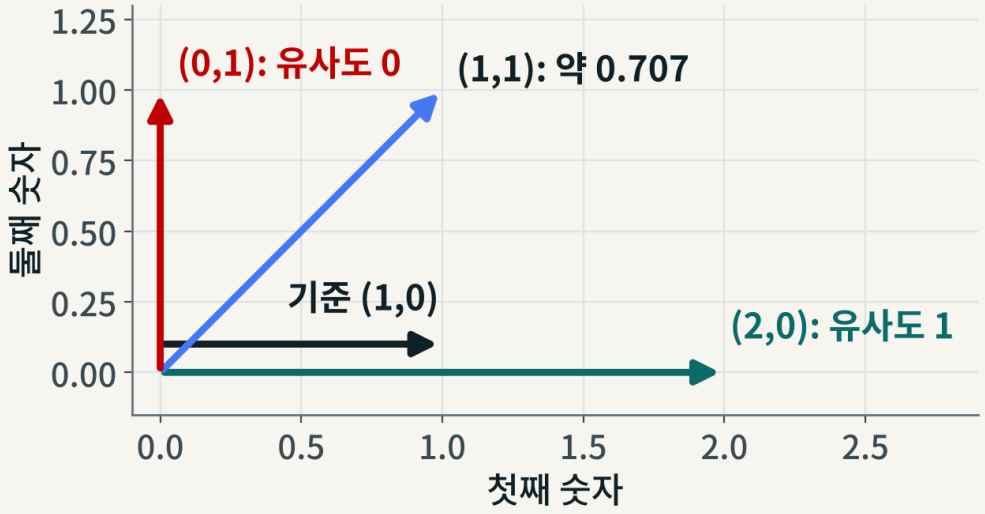
벡터의 길이가 아니라 방향이 얼마나 같은지를 본다

코사인 유사도 (Cosine similarity)

$$\cos(a, b) = \frac{a \cdot b}{\|a\| \, \|b\|}$$

주의

- 유사도는 정답 확률이 아닙니다.
- '증가했다'와 '증가하지 않았다'는 단어가 비슷해도 뜻이 반대입니다.



※ 길이가 달라도 방향이 같으면 유사도는 1이다

왕−남자+여자≈여왕은 일부 임베딩에서 관찰된 직관 예시일 뿐 법칙이 아닙니다

LLM은 다음 토큰의 확률을 계산해 한 조각씩 이어 붙입니다

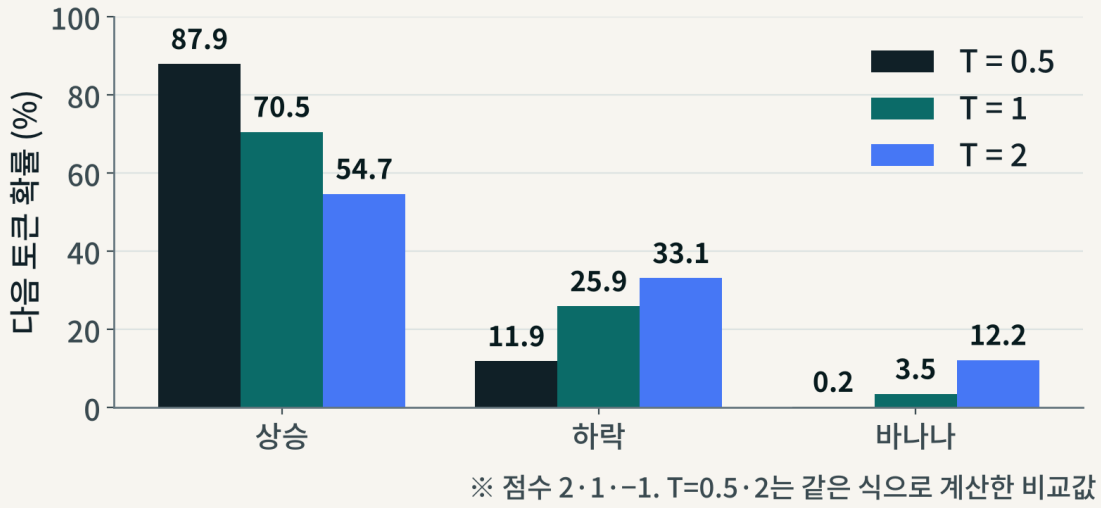
'어제 주식시장이 ___' 뒤 후보 점수: 상승 2, 하락 1, 바나나 −1

소프트맥스 (Softmax)

$$P_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}, \qquad z = \text{후보 점수}, \quad T = \text{temperature}$$

T = 1이면

- 상승 70.5%, 하락 25.9%, 바나나 3.5%입니다.
- T를 낮추면 높은 점수에 몰리고 높이면 선택이 퍼집니다.



※ 점수 2·1·−1. T=0.5·2는 같은 식으로 계산한 비교값

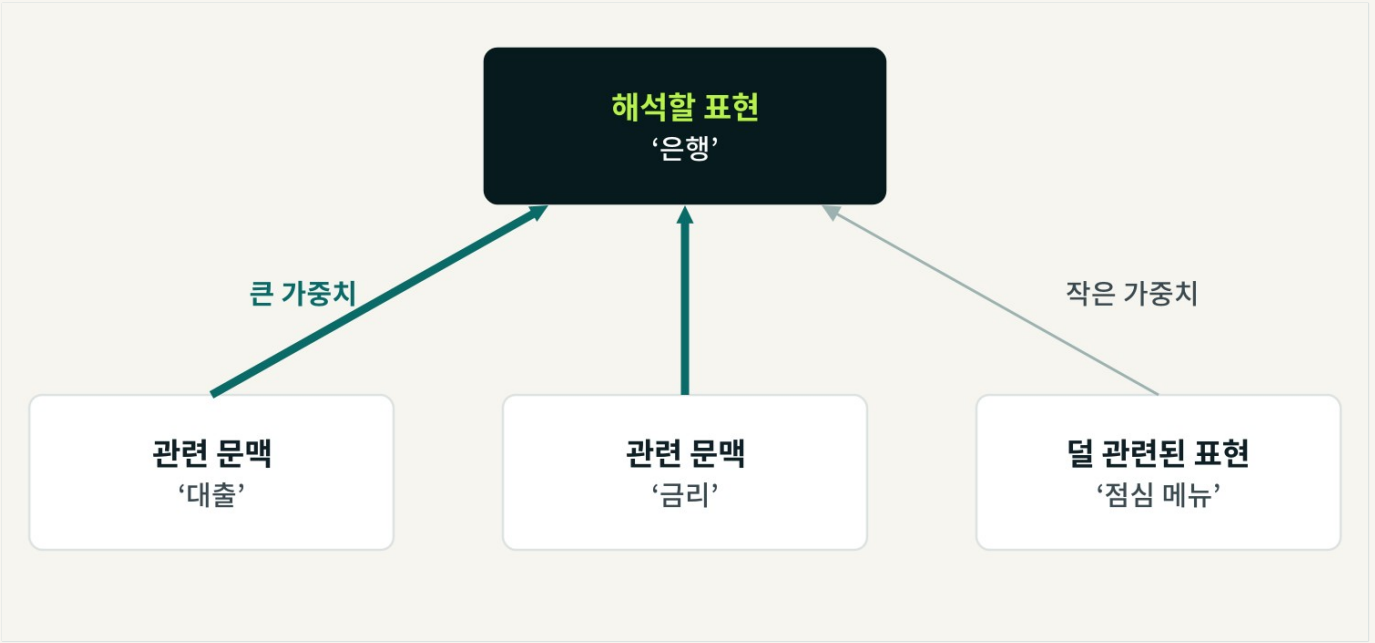
낮은 temperature가 사실성을 보장하지는 않습니다

어텐션은 해석에 필요한 문맥을 골라 가중해 모읍니다

‘은행이 대출 금리를 바꿨다’에서 ‘은행’을 해석하는 경우

어텐션 (Attention)

- 각 토큰을 표현할 때 다른 토큰의 정보를 가중해 모읍니다.
- 실제로는 학습된 query·key·value 벡터와 여러 층·헤드를 씁니다.

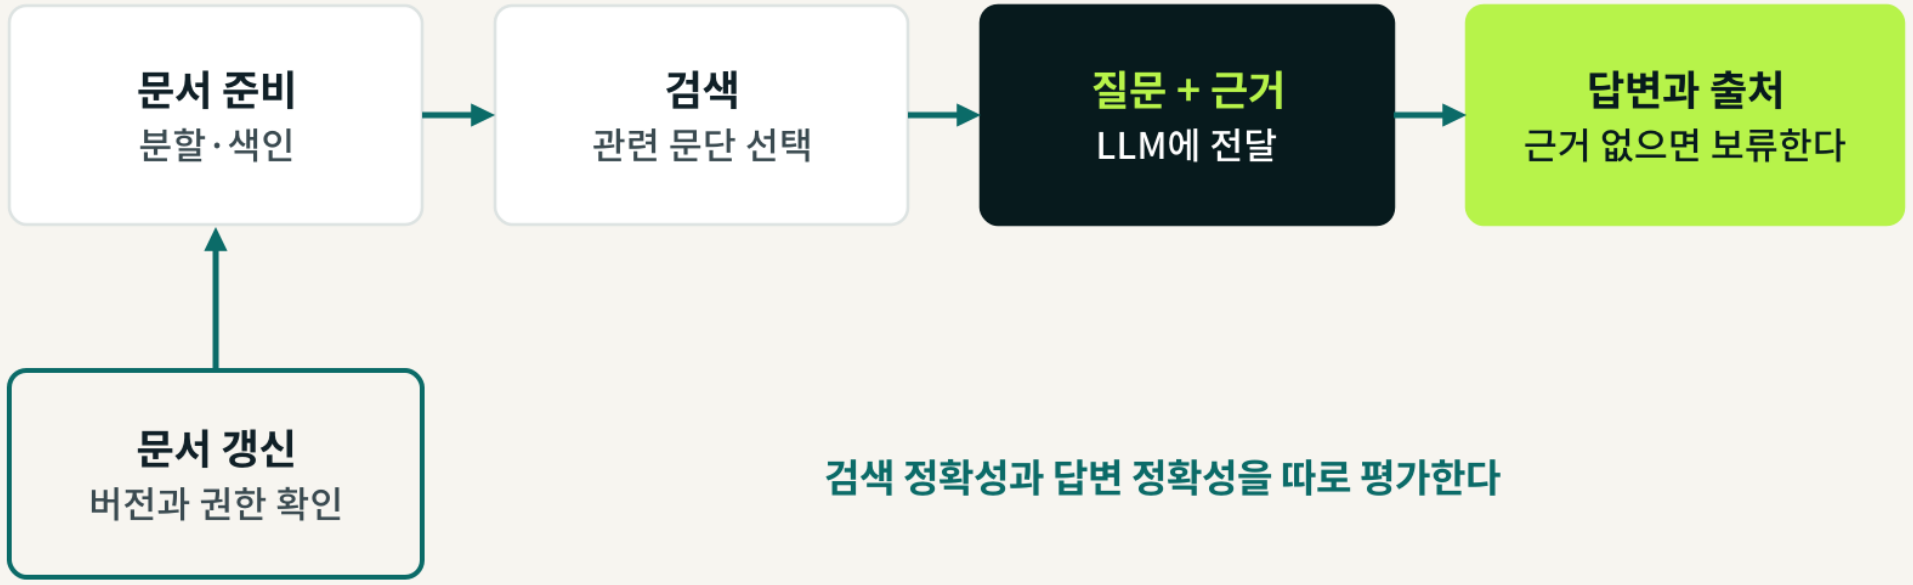


문맥의 어디를 얼마나 참고할지 계산합니다

가중치가 크다고 그 토큰이 현실의 원인이거나 판단의 완전한 설명인 것은 아닙니다

RAG는 관련 문서를 펼쳐 놓고 답하는 방식입니다

기억만으로 시험을 보는 대신 관련 교재를 찾아 펴 놓는 것과 같다



답변에는 문서명, 페이지, 기준일을 연결합니다

검색 결과에 답이 없으면 '제공된 자료에서 확인 불가'라고 답하게 설계합니다

RAG도 틀린 문서를 찾거나 단위를 놓치면 틀립니다

기업 분기보고서로 '이번 분기 영업이익은?'에 답하는 흐름

단계	금융 예시	확인할 것
자료 준비	**기업의 분기보고서**	**연결인지 별도인지, 기간과 버전은 맞는가**
검색	**'이번 분기 영업이익은?'**	**관련 표와 단위가 함께 검색되는가**
답변 생성	**표의 수치를 설명**	**원·백만원·억원을 혼동하지 않는가**
근거 확인	**페이지와 해당 문장 제시**	**원문이 실제로 주장을 뒷받침하는가**

사내 문서를 쓴다고 개인정보·접근 권한 문제가 자동으로 해결되지는 않습니다

검색 실습과 전체 RAG를 구분해서 읽습니다

원문 31~32쪽 실습은 TF-IDF와 코사인 유사도로 비슷한 문서를 찾는다

원문 실습 = RETRIEVER

검색까지

- TF-IDF는 단어 출현 특성을 수치화한 표현입니다.
- 학습된 의미 임베딩과는 다릅니다.

검색 문장 출력은 retriever 실습입니다

전체 RAG

검색 + 생성

- LLM이 근거로 답을 생성해야 완성됩니다.
- 모델을 다시 학습시키지 않습니다.

추가 학습과는 다른 절차입니다

모델이 출처를 써 줘도 그 출처가 숫자와 주장을 뒷받침하는지 확인합니다

03

사례로 보는 함의

금융 문서와 AI가 실제로 틀린 지점을 살펴본다

일반 감성사전은 금융 문서의 단어를 잘못 읽습니다

Loughran·McDonald(2011, Journal of Finance) — 미국 기업 연차보고서(10-K) 분석

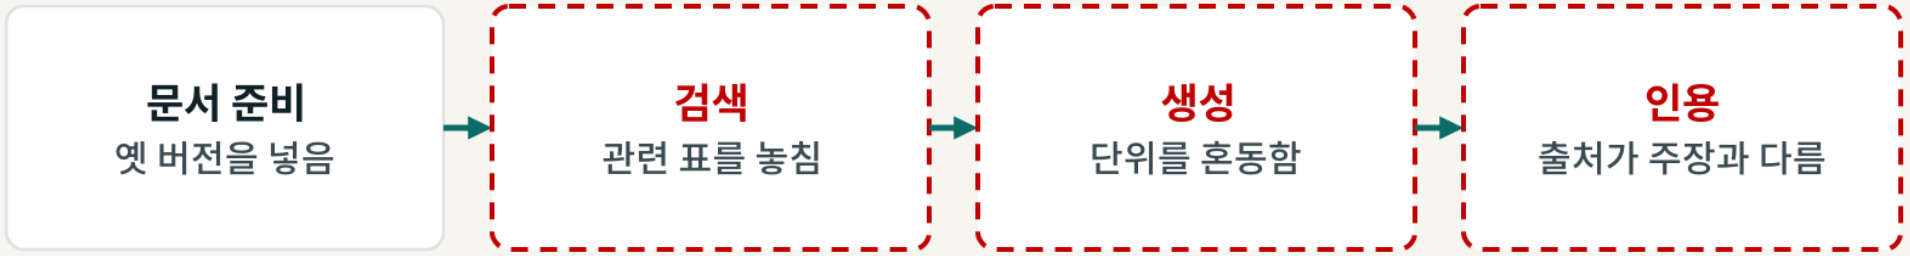
단어	일반 사전의 분류	금융 문서에서의 실제 의미
liability (부채)	**부정적 단어**	**재무상태표의 중립적 회계 용어**
tax (세금)	**부정적 단어**	**기업 활동의 일상적 항목**
cost (비용)	**부정적 단어**	**손익계산서의 기본 항목**
capital (자본)	**부정적 단어**	**재무 구조를 설명하는 중립 용어**

일반 사전의 부정어 약 4분의 3이 10-K에서는 부정적 의미가 아니었습니다

금융 텍스트에는 금융 문서로 검증한 사전과 모델을 씁니다

RAG의 오답은 네 단계 가운데 한 곳에서 생깁니다

문서 준비 → 검색 → 생성 → 인용 — 어디서 틀렸는지 찾아야 고칠 수 있다



각 단계마다 따로 점검해야 오답의 원인을 찾을 수 있다

오답이 나오면 먼저 검색된 문단에 답이 있었는지 확인합니다

검색이 맞았는데 답이 틀렸다면 생성 단계를 고칩니다

출처가 그럴듯해도 실제 문서를 확인해야 합니다

Mata v. Avianca(2023, 미국) — AI가 만든 판례 인용이 법정에 제출된 사건

무슨 일이 있었나

- 변호사가 ChatGPT가 만든 존재하지 않는 판례를 인용해 제출했습니다.
- 법원은 제재를 부과했습니다.

금융에 옮기면

- 공시 숫자를 인용할 때 원문 페이지와 단위를 대조합니다.

설계 원칙

- 근거가 없으면 '확인 불가'라고 답하게 합니다.

출처 표기는 확인의 시작이지 끝이 아닙니다

04

정리

핵심 질문과 답으로 이번 주를 마무리한다

글을 숫자로 읽되, 답은 근거로 확인합니다

이번 주 내용을 질문 하나에 답 하나로 확인한다

확인 질문	답
토큰 ID가 가까우면 뜻도 가까운가?	아닙니다. 의미 비교에는 임베딩 벡터를 씁니다.
유사도가 높으면 정답인가?	아닙니다. 유사도는 방향의 비교이지 정답 확률이 아닙니다.
RAG는 모델을 다시 학습시키는가?	일반적인 RAG는 검색한 내용을 입력 문맥에 넣을 뿐입니다.
모델이 출처를 쓰면 사실인가?	출처가 실제로 존재하고 주장을 뒷받침하는지 확인해야 합니다.

검색 정확성과 답변 정확성을 따로 평가합니다

TEXT BECOMES NUMBERS.

ANSWERS NEED SOURCES.

CHECK THE PAGE.

근거가 없으면
‘확인 불가’가 정답입니다.