강화학습
예측에서 행동으로

‘무엇이 일어날까’에서 ‘지금 무엇을 할까’로 질문을 바꾼다



금융 머신러닝 · 13주차

이번 주는 네 단계로 진행합니다

기본 지식에서 출발해 핵심 개념, 사례, 정리 순서로 읽는다

01	기본 지식	**세 가지 학습 방식** 지도·비지도·강화학습, 반복 갱신
02	핵심 개념	**상태·행동·보상·정책** 할인계수, 탐험과 활용, Q-learning, 집행 비용
03	사례	**게임과 시장의 차이** AlphaGo, 집행 알고리즘 사고, 고전 최적 집행
04	정리	**보상 설계와 검증** 확인 질문과 답

예측이 정확해도 행동의 비용까지 따져야 좋은 정책입니다

01

기본 지식

강화학습이 다른 학습 방식과 무엇이 다른지 정리한다

강화학습은 정답 대신 보상으로 배우는 방식입니다

머신러닝의 세 가지 학습 방식 비교

SUPERVISED

지도학습

- 정답이 붙은 자료로 배웁니다.
- 예: 내일 수익률 예측

UNSUPERVISED

비지도학습

- 정답 없이 구조를 찾습니다.
- 예: 비슷한 종목 묶기

REINFORCEMENT

강화학습

- 행동하고 받은 보상으로 배웁니다.
- 예: 주문 나누기

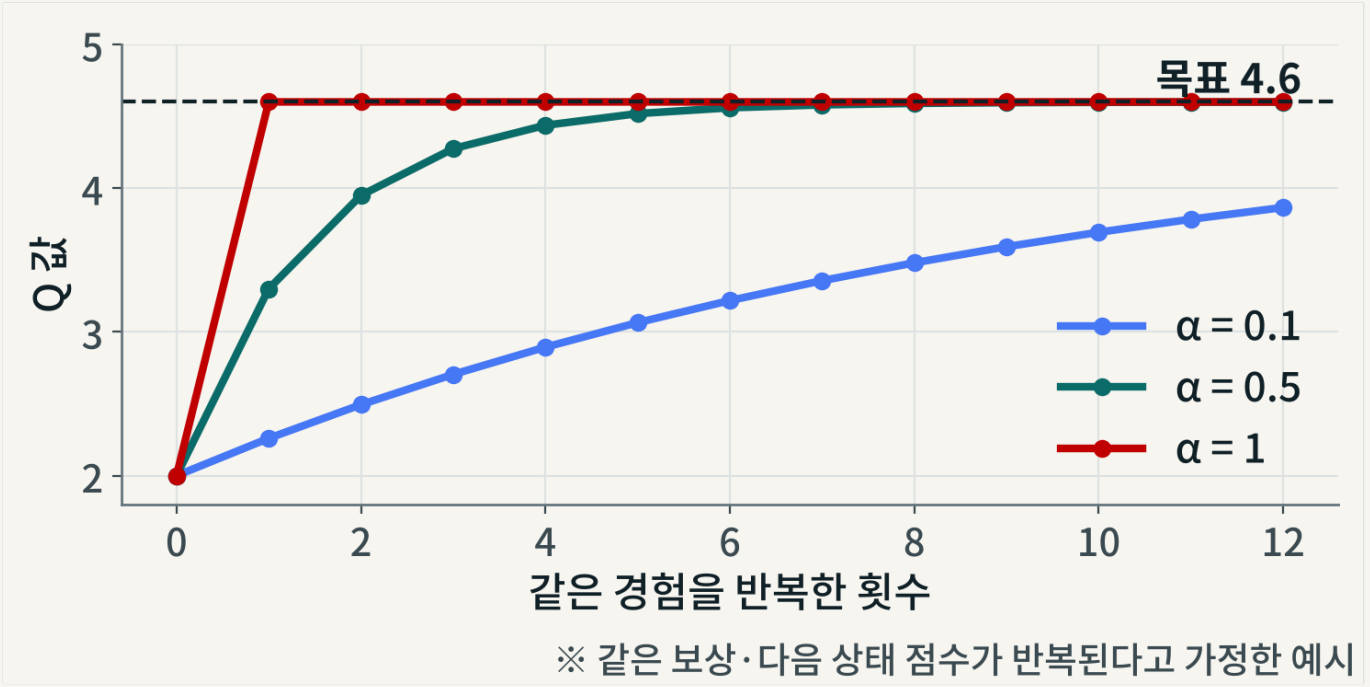
강화학습에서는 내 행동이 다음에 볼 자료를 바꿉니다

같은 경험을 반복하면 Q 값은 목표로 다가갑니다

본편의 Q-learning 예시(목표 4.6)를 여러 번 반복한 경우

학습률 α의 역할

- α=1이면 한 번에 목표로 갑니다.
- α가 작으면 천천히 다가가 흔들림이 줄어듭니다.



α는 속도와 안정성의 균형입니다

02

상태 · 행동 · 보상

원문의 핵심 개념 — 할인계수, 탐험, Q-learning, 주문 집행

강화학습은 답을 맞히는 대신 행동을 고릅니다

게임에서 길을 고르고 점수를 받으며 배우듯 행동의 결과로 전략을 고친다

SUPERVISED

지도학습

- 내일 가격이 얼마일지를 묻습니다.
- 정답과 예측의 차이로 배웁니다.

무엇이 일어날까?

REINFORCEMENT

강화학습

- 지금 얼마를 사고 다음엔 어떻게 할지를 묻습니다.
- 행동의 결과로 정책을 고칩니다.

무엇을 할까?

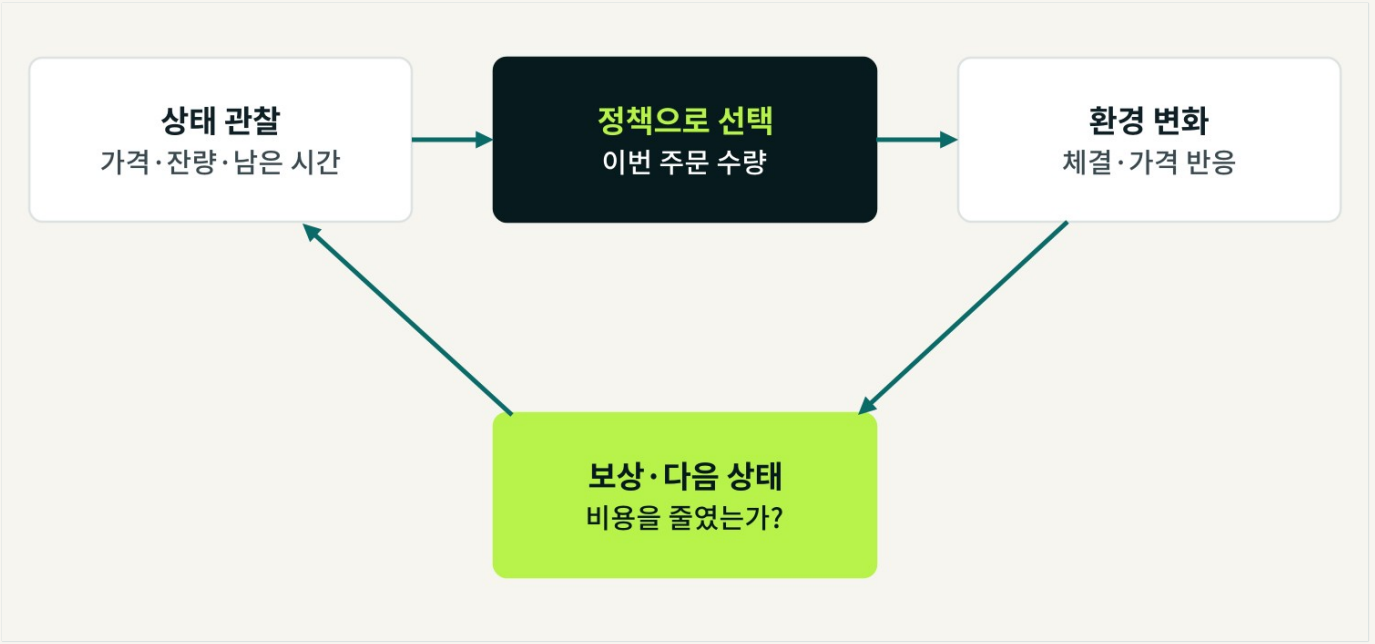
시장에서는 실험을 반복할 수 없어 모의환경을 쓰고, 그 환경이 틀리면 정책도 실패합니다

지금의 행동이 다음 상태를 바꾸는 순환 구조입니다

대량 주문을 나누어 집행하는 프로그램을 예로 든다

핵심

- 큰 주문을 내면 내가 사려는 가격 자체가 움직일 수 있습니다.
- 그래서 여러 시점의 결과를 함께 평가합니다.



예측과 달리 행동이 환경에 영향을 줍니다

여섯 용어를 주문 집행 사례 하나로 정의합니다

왼쪽 용어를 대량 주문 분할 문제에 대응시킨다

용어	쉬운 뜻	주문 집행 예시
에이전트 Agent	**행동을 고르는 주체**	**주문 분할 프로그램**
상태 State	**현재 알고 있는 상황**	**남은 수량, 남은 시간, 호가**
행동 Action	**지금 선택할 일**	**100주 또는 500주 주문**
보상 Reward	**방금 선택의 평가**	**집행 비용의 음수**
정책 Policy	**상황별 행동 규칙**	**유동성이 많으면 더 주문**
환경 Environment	**행동을 받아 반응하는 세계**	**시장 또는 시장 시뮬레이터**

할인계수에 따라 최선의 행동이 바뀝니다

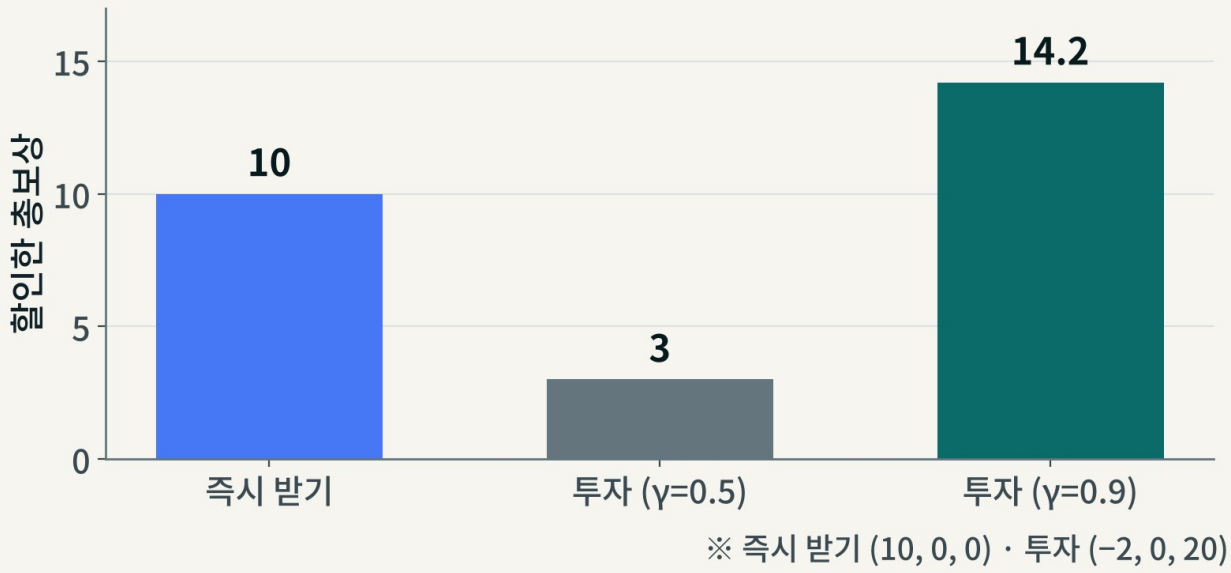
즉시 받기 (10, 0, 0)와 투자 (−2, 0, 20) 가운데 하나를 고른다

할인된 누적 보상 (Return)

$$G_t = r_t + \underbrace{\gamma}_{\text{할인계수}} r_{t+1} + \gamma^2 r_{t+2} + \cdots$$

읽는 법

- γ=0.5면 투자 가치는 3이라 즉시 받기가 낫습니다.
- γ=0.9면 14.2가 되어 선택이 바뀝니다.



γ는 미래 보상을 얼마나 중시하는지이며 시장 금리와 반드시 같지 않습니다

탐험과 활용을 섞어야 더 좋은 선택을 발견합니다

ε-greedy: 확률 ε로 무작위 행동, 나머지는 현재 최고 점수의 행동 (행동 2개, ε=0.2)

A가 더 좋아 보일 때 (무작위 탐험에 A도 포함)

$$P(A) = 0.8 + \frac{0.2}{2} = 0.9, \qquad P(B) = 0.1$$

활용 (Exploitation)

- 늘 가던 식당만 가면 새 식당을 놓칩니다.

탐험 (Exploration)

- 새 식당만 가면 아는 좋은 곳을 못 씁니다.

탐험이 '나쁜 행동만 고르기'라는 뜻은 아닙니다

Q-learning은 상황·행동별 점수표를 조금씩 고칩니다

기존 점수 2, 관측 보상 1, 다음 상태 최고 점수 4, γ=0.9, α=0.5

갱신식

$$Q(s,a) \leftarrow Q(s,a) + \underbrace{\alpha}_{\text{학습률}} \Big[\underbrace{r + \gamma \max_{a'} Q(s',a')}_{\text{새 목표}} - \underbrace{Q(s,a)}_{\text{기존 점수}} \Big]$$

$$2 + 0.5\,(4.6 - 2) = 3.3, \qquad \text{새 목표} = 1 + 0.9 \times 4 = 4.6$$

α는 반영 속도, γ는 미래 중시 정도, ε은 탐험 빈도로 서로 다른 조절 장치입니다

종료 상태에서는 이후 보상을 0으로 놓고, 상태가 너무 크면 근사모형이 필요합니다

대량 주문은 시장 충격과 기다림 비용 사이에서 나누어 집행합니다

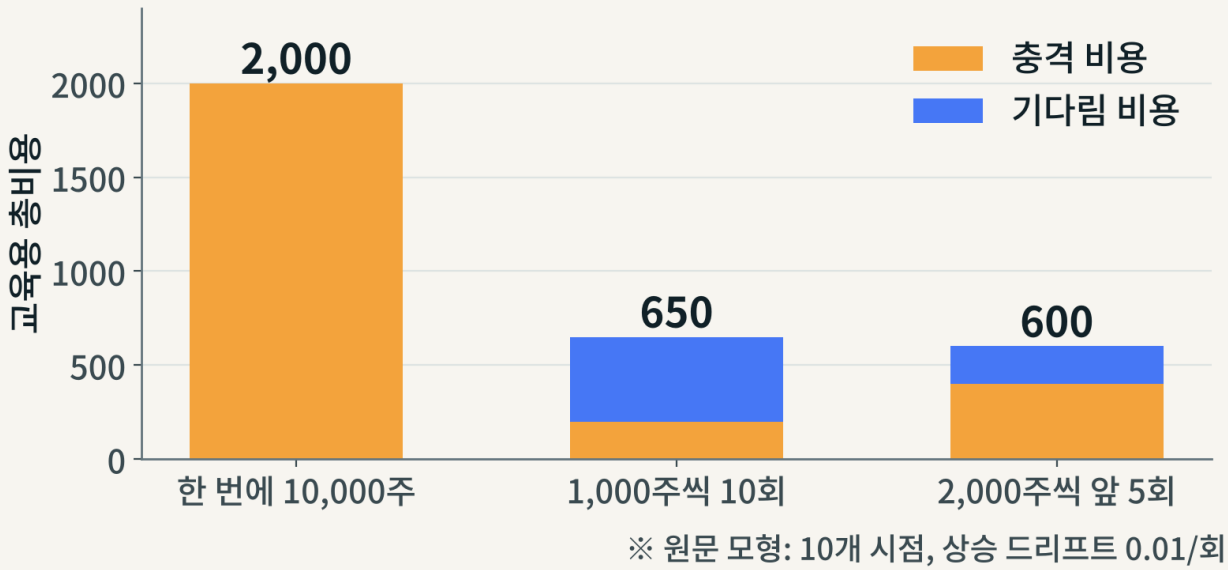
10,000주를 10개 시점 i=0,…,9에 집행하는 원문의 교육용 비용 모형

총비용 (q는 시점별 주문량)

$$C = \sum_{i} \left(\underbrace{0.00002\, q_i^2}_{\text{충격 비용}} + \underbrace{0.01\, i\, q_i}_{\text{기다림 비용}} \right)$$

읽는 법

- TWAP는 시간별 균등 분할입니다.
- RL은 남은 시간과 수량에 적응하는 정책을 배울 수 있습니다.



※ 원문 모형: 10개 시점, 상승 드리프트 0.01/회

이 표는 정해진 세 스케줄의 계산이지 RL이 최적 정책을 학습했다는 증거가 아닙니다

좋은 보상을 정해야 좋은 행동을 배웁니다

보상에서 빠진 것을 에이전트는 무시하는 쪽으로 학습한다

수익만 보상

과도한 레버리지

- 위험을 반영하지 않으면 레버리지를 키웁니다.

비용 미차감

잦은 매매

- 거래비용을 빼지 않으면 쓸데없이 자주 거래합니다.

미집행 벌점 없음

주문 회피

- 미집행 수량에 불이익이 없으면 주문 자체를 피합니다.

실전 후보는 같은 조건에서 TWAP 같은 단순 기준과 비교합니다

모의환경의 높은 수익만으로 실전 준비가 끝나지 않습니다

03

사례로 보는 함의

강화학습의 성공과 시장에서의 위험을 살펴본다

게임에서의 성공이 시장에서의 성공을 보장하지는 않습니다

AlphaGo(2016) — 이세돌 9단과의 대국에서 4승 1패

게임

- 규칙이 고정되어 있습니다.
- 같은 상황을 무한히 시뮬레이션할 수 있습니다.

시장

- 규칙과 참가자가 계속 바뀝니다.
- 내 주문이 가격을 움직입니다.

그래서

- 모의환경이 현실을 얼마나 닮았는지부터 검증합니다.

모의환경에서 훌륭한 정책도 환경이 틀리면 실전에서 실패합니다

집행 알고리즘의 오작동은 몇 분 만에 큰 손실을 냅니다

Knight Capital(2012년 8월 1일) — 잘못 배포된 주문 시스템 사고

무슨 일이 있었나

- 약 45분 동안 의도하지 않은 대량 주문이 나갔습니다.
- 약 4억 4천만 달러의 손실을 냈습니다.

보상 설계와의 연결

- 행동에 한도가 없으면 잘못된 행동이 무한히 반복됩니다.

운영 원칙

- 주문 한도, 비상 정지, 배포 전 검증을 둡니다.

학습한 정책에도 사람이 정한 안전장치가 필요합니다

고전적 최적 집행과 강화학습 집행은 장단점이 다릅니다

Almgren·Chriss(2000) — 시장 충격과 가격 위험의 균형을 수식으로 푼 고전 모형

CLASSICAL

고전적 최적 집행

- 가정이 명확해 결과를 설명하기 쉽습니다.
- 가정이 맞지 않으면 성과가 떨어집니다.

명확함

REINFORCEMENT

강화학습 집행

- 남은 시간·수량·유동성에 적응합니다.
- 시뮬레이터 품질에 크게 의존합니다.

적응력

강화학습 정책은 같은 조건에서 TWAP과 고전 모형을 이겨야 채택합니다

04

정리

핵심 질문과 답으로 이번 주를 마무리한다

행동의 결과까지 평가해야 좋은 정책입니다

이번 주 내용을 질문 하나에 답 하나로 확인한다

확인 질문	답
예측이 정확하면 좋은 정책인가?	**비용과 행동이 환경에 미치는 효과까지 고려해야 합니다.**
모의환경 수익이 높으면 실전 준비가 끝났나?	**미사용 기간, 현실적 체결·비용, 위험 제약에서 다시 검증합니다.**
α, γ, ε은 무엇이 다른가?	**반영 속도, 미래 중시 정도, 탐험 빈도로 서로 다른 장치입니다.**
집행 비교표는 RL 학습 결과인가?	**아닙니다. 정해진 세 스케줄을 계산한 결과입니다.**

보상에서 빠진 것을 에이전트는 무시하는 쪽으로 배웁니다

PREDICTION IS NOT ACTION.

REWARD WHAT YOU WANT.

LIMIT WHAT CAN GO WRONG.

보상과 안전장치를
함께 설계합니다.