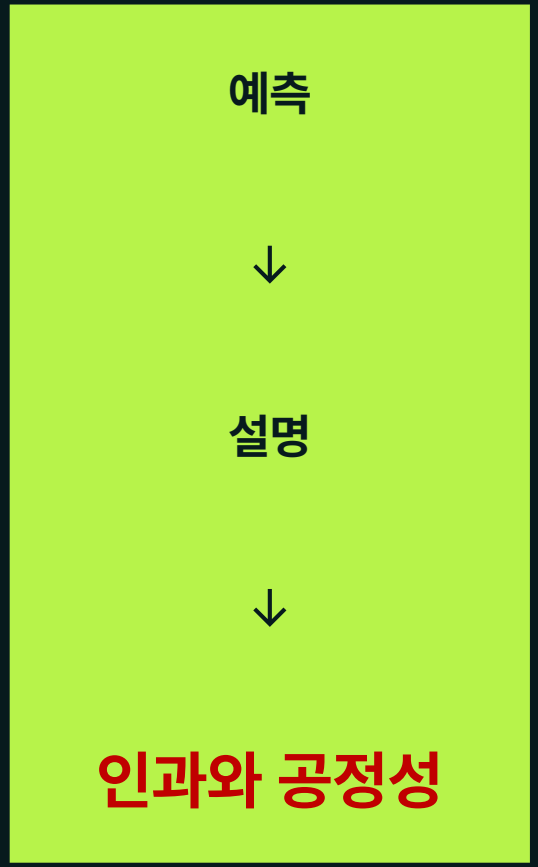
인과 · 설명 · 공정성
예측을 믿기 전의 질문

예측, 모델 설명, 인과효과를 서로 다른 질문으로 구분한다



금융 머신러닝 · 14주차

이번 주는 네 단계로 진행합니다

기본 지식에서 출발해 핵심 개념, 사례, 정리 순서로 읽는다

01	기본 지식	**상관과 인과, Shapley 값의 출발** 교란변수, 협력 게임과 공의 분배
02	핵심 개념	**세 질문의 구분** 교란, 무작위 실험, SHAP, 집단별 지표, 대리변수
03	사례	**평균이 숨기는 것** 버클리 입학 통계, 채용 도구, 신용카드 한도
04	정리	**개입 효과에는 그에 맞는 근거** 확인 질문과 답

정확한 예측과 개입 효과는 구분해야 합니다

01

기본 지식

상관·인과·설명의 기본 개념을 정리한다

상관과 인과는 다른 말입니다

함께 움직인다는 사실만으로는 무엇이 무엇을 바꾸는지 알 수 없다

CORRELATION

상관

- 두 변수가 함께 움직이는 정도입니다.

CAUSATION

인과

- 하나를 바꾸면 다른 하나가 바뀌는 관계입니다.

CONFOUNDER

교란변수

- 둘 모두에 영향을 주는 제3의 변수입니다.

우산 판매량으로 비를 예측할 수 있어도 우산을 팔아 비를 내리게 할 수는 없습니다

Shapley 값은 협력 게임에서 공을 나누는 방법에서 왔습니다

Lloyd Shapley(1953)의 게임이론 — 본편의 부채·소득 예시로 본 계산 순서

배경

- 여러 사람이 함께 낸 성과를 나누는 문제에서 출발했습니다.
- Lundberg·Lee(2017)가 SHAP으로 머신러닝에 옮겼습니다.



넣는 순서별 추가 기여를 평균합니다

SHAP의 공평함은 수학적 배분의 성질이지 사회적 공정성이 아닙니다

02

예측 · 설명 · 인과

원문의 핵심 개념 — 교란, 실험, SHAP, 집단별 지표

예측, 모델 설명, 인과효과는 서로 다른 질문입니다

우산 판매량으로 비를 예측할 수 있어도 우산을 팔아 비를 오게 할 수는 없다

질문	무엇을 알아내는가	대표 접근
무엇이 일어날까?	**미래 결과의 예측**	**예측모형**
모델은 왜 그렇게 말했나?	**입력 특징의 예측 기여**	**SHAP 등 설명 도구**
내가 바꾸면 결과가 달라질까?	**개입의 인과효과**	**실험과 인과추론**

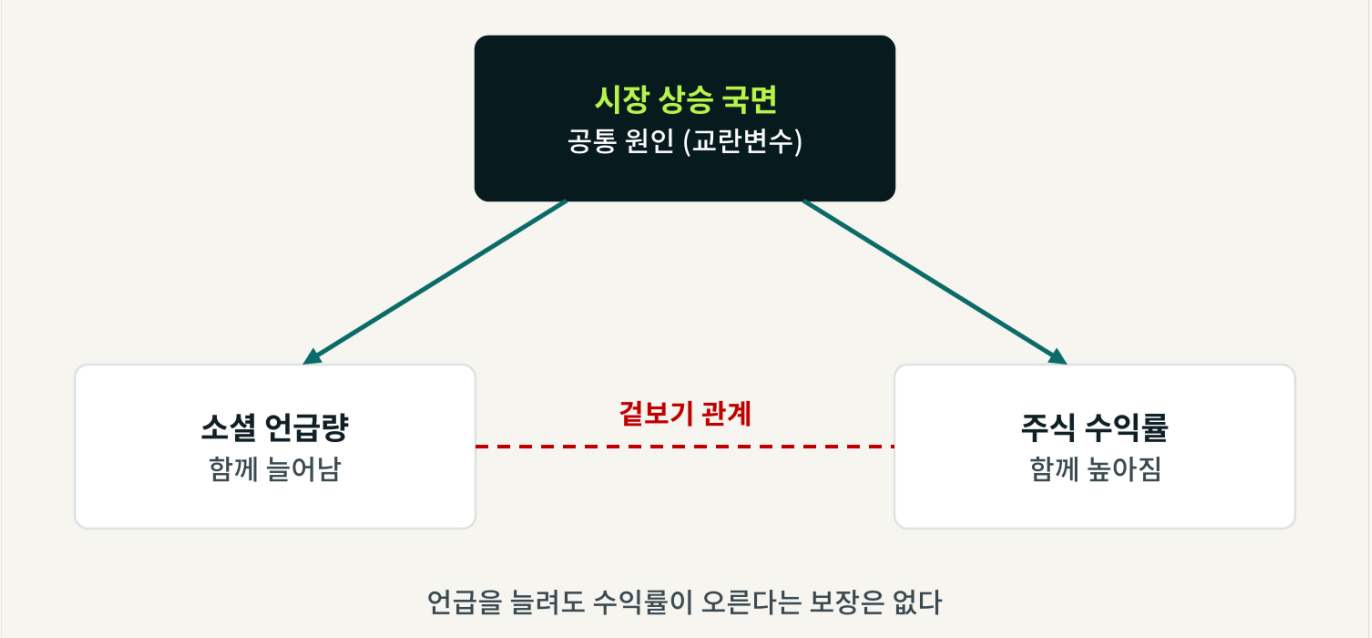
정확한 예측과 개입 효과는 구분해야 합니다

함께 움직이는 두 변수에 공통 원인이 있을 수 있습니다

공통 원인을 교란변수(confounder)라고 부른다

예

- 상승장이 소셜 언급을 늘리고 수익률도 높였습니다.
- 언급량과 수익률은 같은 원인의 결과일 뿐입니다.



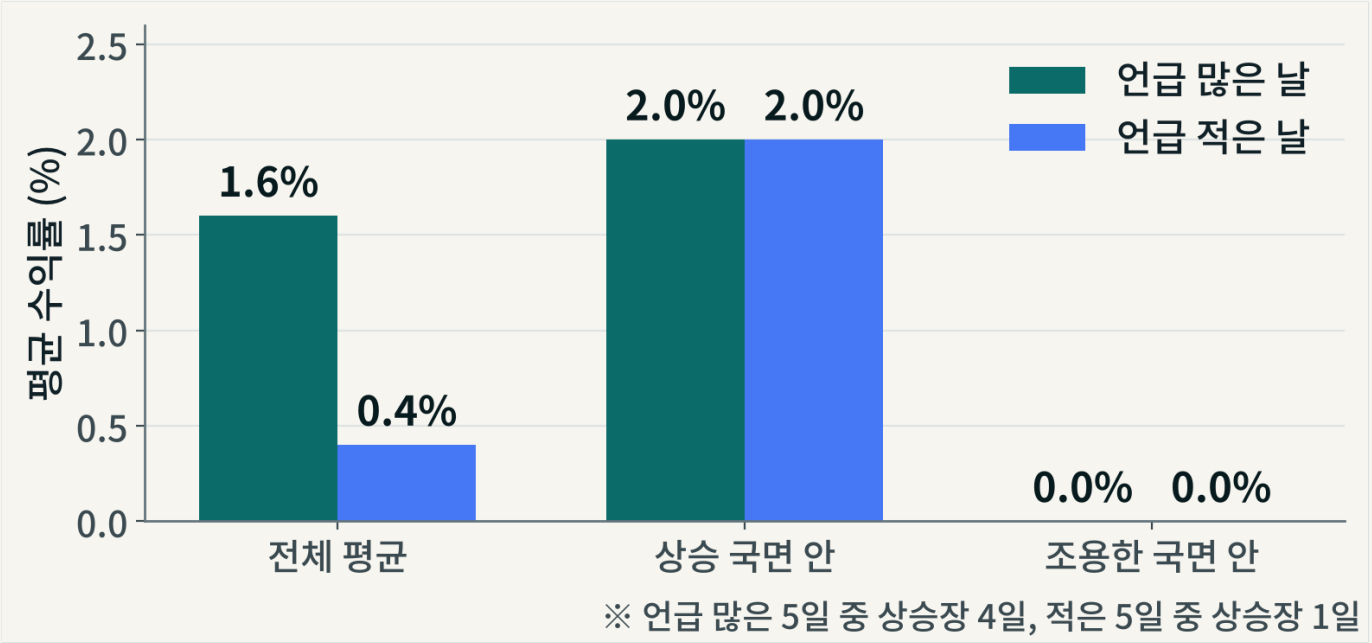
상관만으로 개입 효과를 말하지 않습니다

전체 평균의 차이가 시장 국면 구성에서 나올 수 있습니다

언급 많은 날 1.6%, 적은 날 0.4% — 차이 1.2%포인트

국면 안으로 들어가면

- 상승 국면 안에서는 두 집단 모두 2%입니다.
- 조용한 국면 안에서는 모두 0%입니다.



차이는 상승장 일수의 구성에서 나왔습니다

원인을 알려면 비교 가능한 반대 상황이 필요합니다

고객에게 안내 문자를 보냈을 때 구매가 늘었는지 알고 싶은 경우

무작위 실험

한쪽에만 문자 발송

- 평균적으로 비교 가능성을 높입니다.
- 표본 크기와 실험 준수를 확인합니다.

유한 표본에서 완전히 같지는 않습니다

관측자료 인과추론

실험이 어려울 때

- 금리 결정처럼 무작위 배정이 어렵습니다.
- 관측되지 않은 교란이 없다는 가정이 필요합니다.

변수를 많이 넣는다고 증명되지 않습니다

개입 효과를 주장할 때는 그에 맞는 근거가 필요합니다

SHAP는 예측값을 특징별 기여로 공평하게 나눕니다

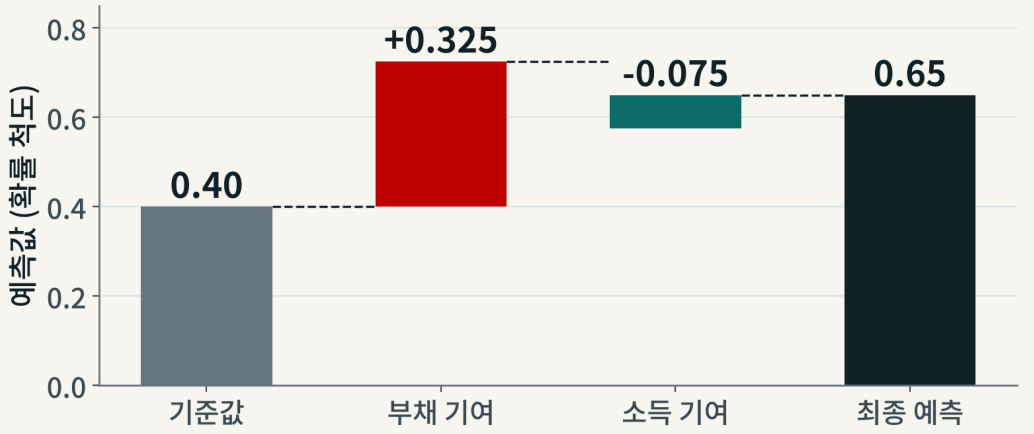
기준값 0.40, 부채만 0.70, 소득만 0.30, 둘 다 0.65 — 특징이 먼저 올 때와 나중 올 때를 평균

Shapley 값

$$\phi_{\text{부채}} = \frac{(0.70 - 0.40) + (0.65 - 0.30)}{2} = 0.325$$

$$\phi_{\text{소득}} = \frac{(0.30 - 0.40) + (0.65 - 0.70)}{2} = -0.075$$

$$\text{기준값} + \phi_{\text{부채}} + \phi_{\text{소득}} = 0.40 + 0.325 - 0.075 = 0.65$$



※ 0.40 + 0.325 − 0.075 = 0.65 — 모델 계산의 분해이지 인과효과가 아니다

부채 정보는 이 모델의 예측을 올리고, 소득 정보는 내리는 방향으로 작용했습니다

부채를 줄이면 위험이 32.5%포인트 준다는 인과 주장이 아닙니다

SHAP 값을 읽을 때 네 가지를 함께 확인합니다

SHAP는 모델의 계산을 설명할 뿐 현실의 원인이나 사회적 공정성을 증명하지 않는다

인과

- 모델 계산의 분해이지 개입 효과가 아닙니다.

기준값

- 배경 자료와 설명 방식에 따라 달라집니다.

척도

- 로그오즈 기여를 확률 %포인트로 읽지 않습니다.

상관된 특징

- 배분 방식에 따라 해석이 달라집니다.

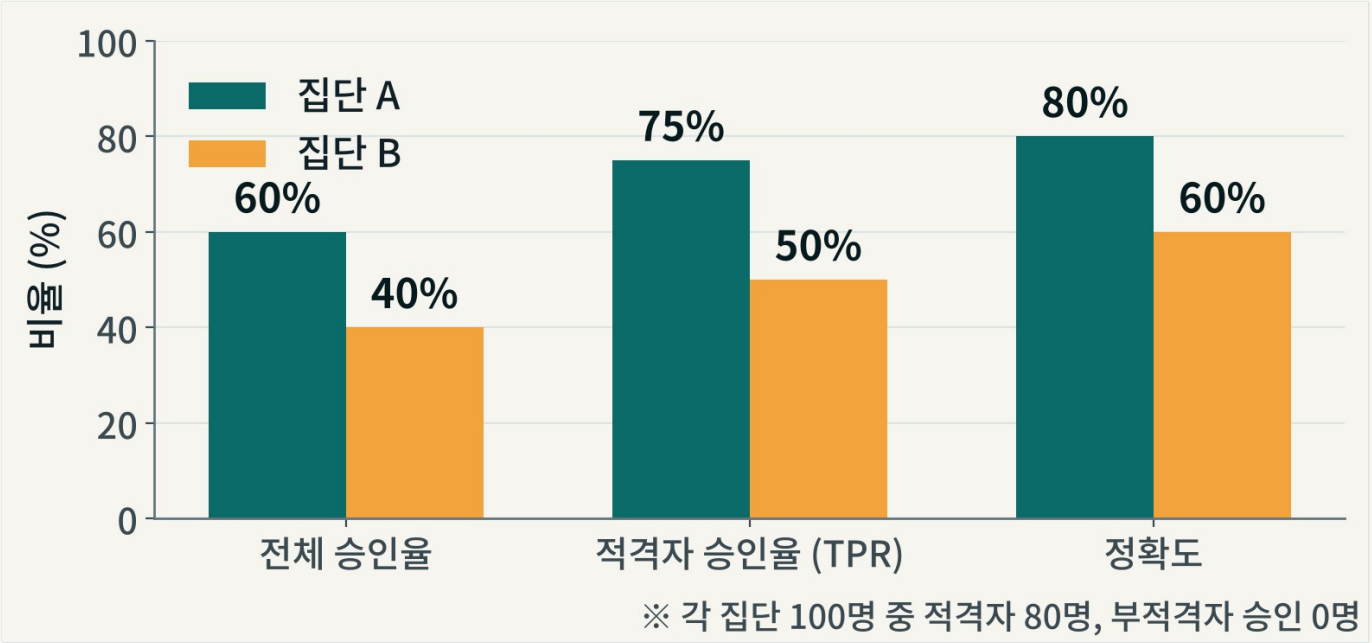
수학적 배분의 공평함과 사회적 공정성은 다른 개념입니다

전체 평균 점수가 집단 간 차이를 숨길 수 있습니다

두 집단 각 100명 중 적격자 80명. A는 적격자 60명, B는 40명을 승인했다

분모가 다르다

- 승인율은 모든 사람이 분모입니다.
- TPR은 적격자만 분모입니다.



TPR 차이 25%포인트가 드러납니다

승인율 균형, 기회 균형, 확률 보정은 서로 다른 기준이며 동시에 맞추기 어렵습니다

민감한 열을 지워도 그 정보는 다른 변수에 남을 수 있습니다

성별 같은 열을 제거해도 대리변수(proxy)가 그 속성과 연관될 수 있다

대리변수 후보

- 우편번호, 학교, 소비 특성이 속성을 대신할 수 있습니다.

함께 점검할 것

- 변수와 집단의 관련성, 집단별 오류율, 변수를 뺐을 때의 변화를 봅니다.

한계

- SHAP만으로 대리변수 문제를 완전히 판정할 수 없습니다.

전체 정확도가 같아도 집단별 누락·오경보·기회 차이는 남을 수 있습니다

03

사례로 보는 함의

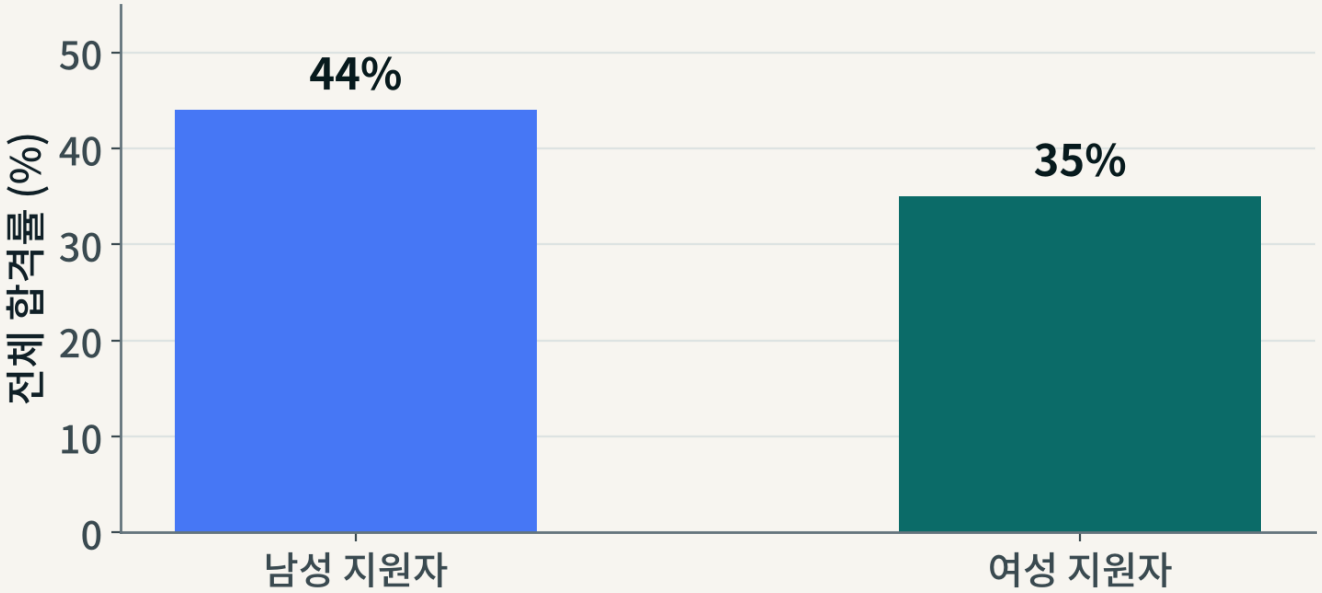
평균과 모델이 무엇을 숨길 수 있는지 살펴본다

전체 합격률 차이가 학과 구성에서 나온 사례가 있습니다

UC 버클리 대학원 입학(1973) — 심슨의 역설(Simpson's paradox)

학과별로 나누면

- 여성 지원자는 경쟁률이 높은 학과에 더 많이 지원했습니다.
- 학과 안에서는 차이가 작거나 반대였습니다.



※ Bickel 외(1975, Science). 학과별로 나누면 차이가 대부분 사라졌다

전체 평균만 보면 원인을 잘못 짚습니다

본편의 '시장 국면' 예시와 같은 구조입니다

민감한 열을 빼도 차이는 다른 변수로 들어올 수 있습니다

대리변수(proxy)와 설명 가능성이 문제가 된 보도 사례

채용 도구 (2018 보도)

- Amazon은 과거 이력서로 학습한 도구가 'women's' 같은 단어에 불리하게 작동해 폐기했다고 보도되었습니다.

신용카드 한도 (2019)

- Apple Card 한도의 성별 차이 의혹으로 뉴욕주 금융감독청이 조사했습니다.
- 2021년 공정대출법 위반은 찾지 못했다고 발표했습니다.

교훈

- 집단별 오류율과 판단 근거를 설명할 수 있어야 합니다.

위법이 아니어도 설명하지 못하면 신뢰를 잃습니다

공정성 기준은 여러 개이며 동시에 맞추기 어렵습니다

본편의 대출 승인 예시에 적용한 세 기준

기준	무엇을 같게 하나	본편 예시에서
승인율 균형	집단별 전체 승인 비율	A 60%, B 40%로 다릅니다
기회 균형	적격자 가운데 승인 비율(TPR)	A 75%, B 50%로 다릅니다
예측 보정	같은 점수의 실제 적격 비율	점수 자료가 있어야 점검합니다

어떤 기준을 쓸지는 오류의 비용과 목적에 따라 정하고 밝힙니다

04

정리

핵심 질문과 답으로 이번 주를 마무리한다

예측·설명·인과는 서로 다른 근거가 필요합니다

이번 주 내용을 질문 하나에 답 하나로 확인한다

확인 질문	답
SHAP 값이 크면 실제 원인인가?	아닙니다. 모델이 그 특징을 예측에 어떻게 반영했는지 보여 줍니다.
전체 정확도가 같으면 공정한가?	집단별 누락·오경보·기회 차이가 남을 수 있습니다.
민감한 열을 지우면 해결되나?	대리변수가 남을 수 있어 집단별 오류를 따로 봅니다.
변수를 많이 넣으면 인과가 증명되나?	아닙니다. 식별 가정이나 실험 같은 근거가 필요합니다.

개입 효과를 주장할 때는 그에 맞는 근거를 함께 제시합니다

PREDICT.

EXPLAIN.

THEN ASK WHY.

평균 뒤에 숨은 집단과
원인을 따로 확인합니다.