MBA · 재직자 과정 · 통합 강의

금융 AI의 공정성

정의 · 측정 · 완화 · 거버넌스

Algorithmic Fairness in Financial AI — 무시하기에서 반사실적 공정성까지

II판 — 직관 예제와 시각 자료를 보강했다.
대출·신용·보험·상품 추천에서 "공정하다"는 말이 무엇을 뜻하는지, 어떻게 재고 어떻게 고치며 누가 책임지는지를 다룬다.
2026년 10월 기준 규제(EU AI Act 연기, 한국 AI 기본법 시행, 미국 Reg B 개정)를 반영했다.

OVERVIEW

이 강의는 세 가지 주장을 따라간다

공정성은 하나의 숫자가 아니라 선택해야 하는 기준의 묶음이다

1

보호속성을 지운다고 차별이 사라지지 않는다

우편번호·학교·이름 같은 프록시가 속성을 되살린다. 차별은 변수 목록이 아니라 결과로 측정한다.

2

공정성 정의는 서로 충돌하므로 고르는 일이 필요하다

기저율이 다르면 보정과 오류율 균등을 동시에 만족할 수 없다. 어떤 피해를 막을지가 정의를 정한다.

3

측정·완화·감사를 승인 절차에 넣어야 지속된다

집단별 지표를 모델 카드에 싣고 관문을 둔다. 2026년 규제는 이 기록을 요구하는 방향으로 움직인다.

오늘의 질문: "누구에게, 어떤 오류를, 얼마나 같게 할 것인가?"

01

PART 1 · 기본 지식

공정성 문제의 구조

정의 → 혼동행렬 지표 → 편향의 원천 → 대표 사례

알고리즘 공정성은 결과의 집단 간 격차를 다룬다

Algorithmic Fairness — 모형 자체가 아니라 데이터와 사용 방식에서 편향이 생긴다는 전제

**같은 자격을 가진 사람이 소속 집단 때문에 다른 결정을 받는다면,
그 모형은 정확해도 공정하지 않다.**

왜 금융에서 특히 문제인가

- 대출·한도·보험료는 생활 기회를 직접 바꾼다
- 과거 차별이 학습 데이터에 그대로 남아 있다
- 자동 결정이라 한 번의 편향이 대규모로 복제된다

용어 정리

- 보호속성 A: 성별·인종·나이 등 차별 금지 사유
- 레이블 Y: 실제 결과(상환=1, 연체=0)
- 예측 $\hat{Y}$: 모형의 결정(승인=1, 거절=0)

모든 공정성 지표는 혼동행렬의 세 비율에서 나온다

TP=상환자 승인, FN=상환자 거절, FP=연체자 승인, TN=연체자 거절

$$\underbrace{\text{TPR} = \frac{TP}{TP + FN}}_{\text{자격자 중 승인 비율}} \qquad \underbrace{\text{FPR} = \frac{FP}{FP + TN}}_{\text{비자격자 중 승인 비율}} \qquad \underbrace{\text{PPV} = \frac{TP}{TP + FP}}_{\text{승인자 중 실제 상환 비율}}$$

	승인 ($\hat{Y}$=1)	거절 ($\hat{Y}$=0)
실제 상환 (Y=1)	TP — 기회를 준 사람	FN — 기회를 빼앗긴 사람
실제 연체 (Y=0)	FP — 손실을 낸 사람	TN — 바르게 걸러낸 사람

어느 칸이 누구의 피해인가

- FN은 신청자의 피해다
- FP는 금융회사의 손실이다
- 어느 칸을 같게 할지가 정의를 가른다

두 종류의 오류는 비용을 치르는 사람이 다르다

화재경보기와 대출 심사를 나란히 놓으면 FP와 FN의 무게가 보인다

	화재경보기	대출 심사
FP (잘못된 양성)	불이 없는데 울린다 — 헛걸음	갚지 못할 사람을 승인 — 회사 손실
FN (잘못된 음성)	불이 났는데 조용하다 — 큰 피해	갚을 사람을 거절 — 신청자의 기회 박탈
누가 비용을 지나	거주자 전체	FP는 회사, FN은 신청자 개인

핵심

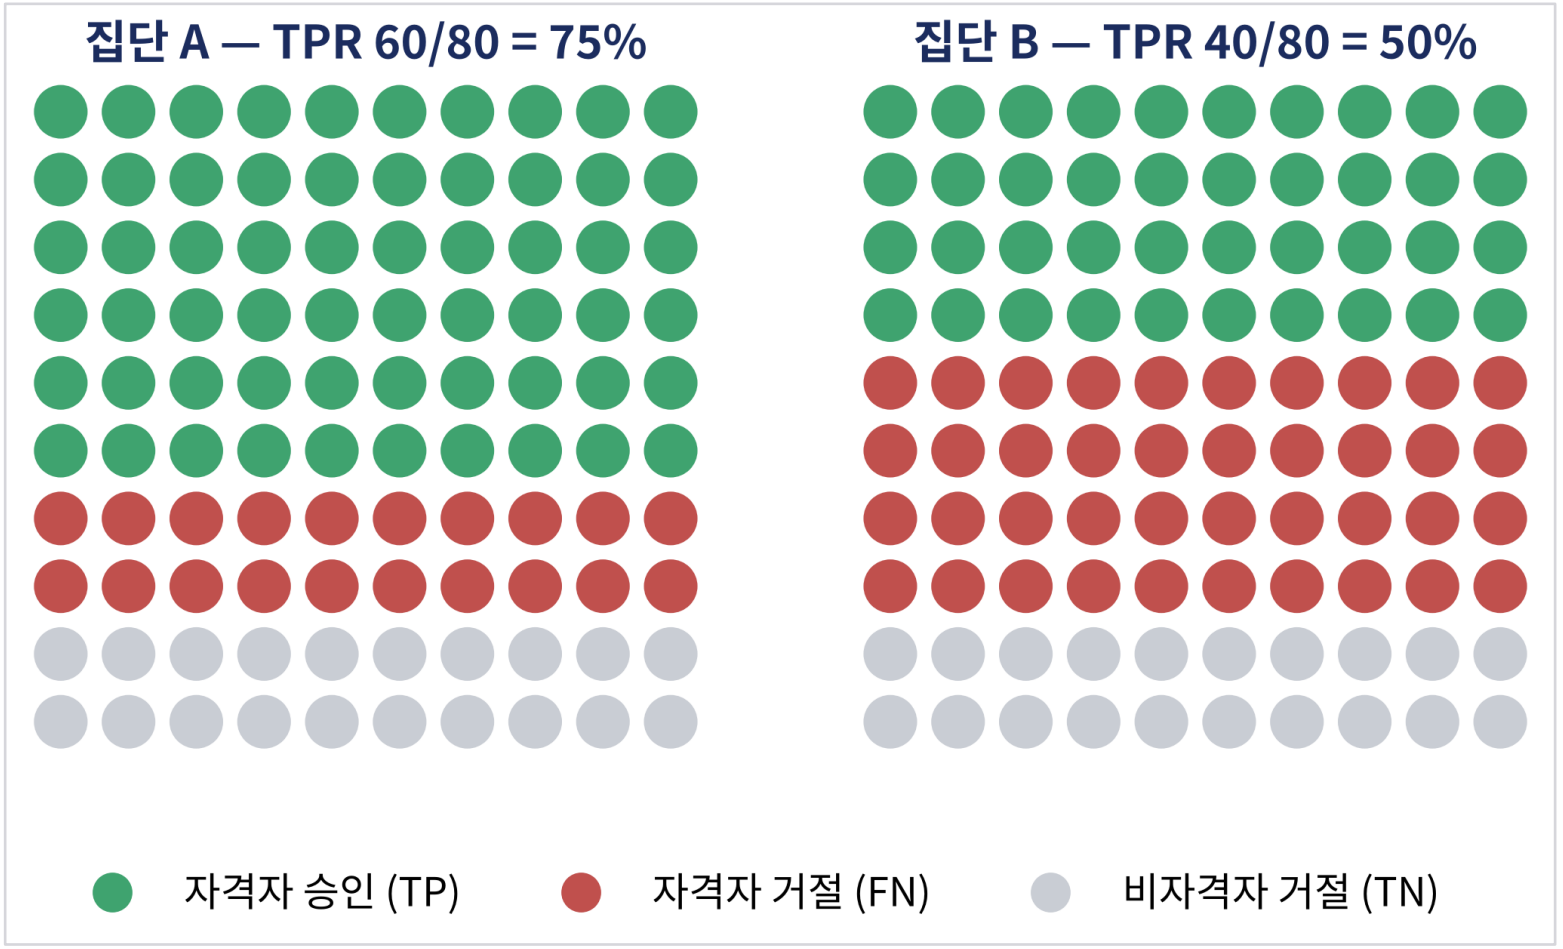
- FN이 몰리는 집단을 보면 기회 균등, FP까지 보면 근본적 공정이다.

점 100개로 그리면 같은 자격의 다른 대우가 보인다

두 집단 각 100명, 실제 상환 가능자 80명으로 같다 (FML 14주차 예제)

읽는 법

- 점 하나 = 한 사람
- 초록 = 기회 받음
- 빨강 = 기회 잃음
- B의 빨강이 두 배



편향은 데이터가 만들어지는 네 단계에서 들어온다

Suresh & Guttag(2021)의 분류를 금융 사례에 맞춰 정리했다

원천	무슨 일이 생기나	금융 예시
역사적 편향 (Historical)	과거 차별이 레이블에 남는다	과거 대출 거절 기록이 정답으로 학습된다
대표성 편향 (Representation)	특정 집단 표본이 적다	신용이력이 짧은 청년·이민자 데이터 부족
측정 편향 (Measurement)	같은 특성을 다르게 잰다	대안 데이터가 일부 집단만 포괄한다
집계 편향 (Aggregation)	하나의 모형을 모두에게 쓴다	소득 구조가 다른 자영업자에게 직장인 모형 적용
프록시 (Proxy)	중립 변수가 속성을 대신한다	우편번호·학교·이름이 인종·성별을 드러낸다

대표 사례 다섯 건이 공정성 논쟁의 축을 보여 준다

최신 검증 결과를 반영했다 — Apple Card는 2021년 감독당국 조사에서 위반 없음으로 결론났다

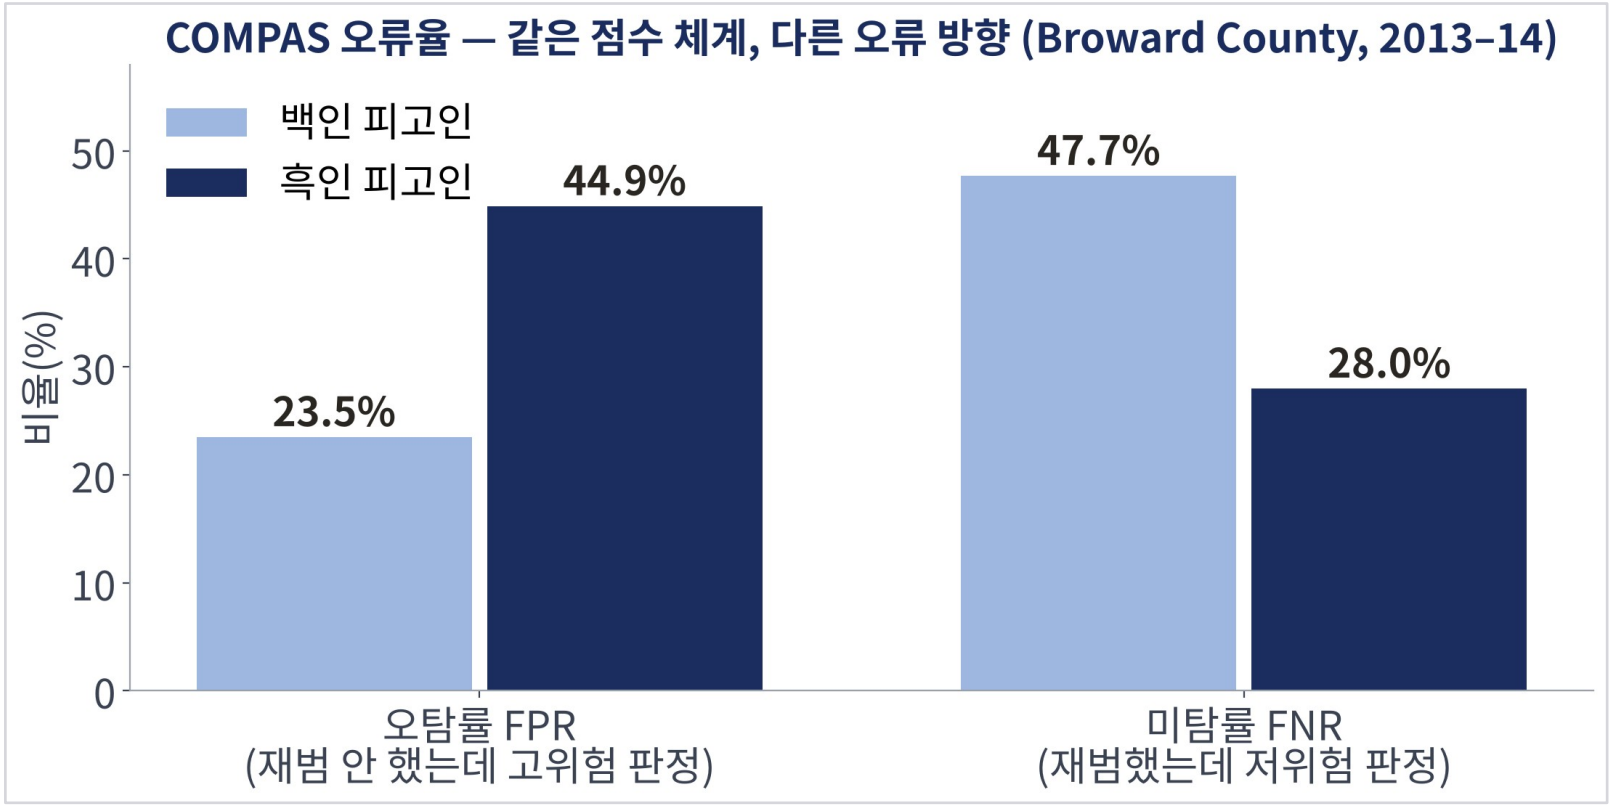
사례	무엇이 문제였나	교훈
Amazon 채용 (2014–18)	남성 위주 이력서로 학습, '여성' 단어에 감점	변수를 지워도 패턴이 남는다
COMPAS (2016)	흑인 피고인 오탐률 45% vs 백인 23%	오류율과 보정이 충돌한다
Apple Card (2019–21)	부부 간 한도 차이 논란, 성별 변수 없음	위반 없음 — 설명 부족이 신뢰를 잃게 했다
Earnest (2025)	학교별 부도율 변수가 차별적 영향	프록시 점검 없이 쓰면 제재 대상
LLM 모기지 실험 (2024–25)	동일 서류에 인종만 바꿔도 승인 차이	범용 LLM도 감사해야 한다

COMPAS는 정확도가 같아도 오류의 방향이 달랐다

ProPublica가 플로리다 Broward 카운티 피고인 1만여 명의 2년 재범을 추적한 결과다

읽는 법

- 정확도 59% vs 63%
- 흑인: 과잉 고위험
- 백인: 과소 저위험
- 점수 자체는 보정됨



두 진영은 서로 다른 공정성 정의로 말하고 있었다

ProPublica는 오류율 균등을, 개발사 Northpointe는 점수 보정을 기준으로 삼았다

ProPublica의 주장

- 재범 안 한 흑인이 고위험으로 찍힐 확률이 두 배다
- FPR·FNR이 집단마다 다르므로 불공정하다

Northpointe의 반론

- 같은 점수면 재범률이 인종과 무관하게 같다
- 점수가 보정돼 있으므로 공정하다

둘 다 수치로는 맞다. 재범 기저율이 집단마다 다르면 두 기준은 동시에 성립할 수 없다(→ 불가능성 정리).

Apple Card 조사는 위반이 아니라 설명 부족을 지적했다

2019년 11월 SNS 문제 제기 → 2021년 3월 뉴욕주 금융감독청(NYDFS) 결론

20배

제기자가 주장한 부부 간 한도 차이

약 40만

NYDFS가 분석한 뉴욕주 신청자 수

위반 없음

성별 의도 차별·차별적 영향 모두 불인정

무엇이 한도를 갈랐나

- 배우자 개인의 신용점수·부채·소득
- 공동명의 자산은 반영되지 않았다

강의의 교훈

- 성별 변수가 없어도 의심은 생긴다
- 거절·한도 사유를 설명할 수 있어야 한다

Earnest 합의는 프록시 변수가 제재 대상임을 보여 준다

2025년 7월 매사추세츠 법무장관과 학자금 대출사 Earnest의 250만 달러 합의

지적된 관행	왜 문제인가	합의 조건
학교별 평균 부도율(Cohort Default Rate) 변수	흑인·히스패닉 신청자에게 불리한 결과	변수 사용 중단
영주권 미보유자 자동 거절(Knockout Rule)	출신국 관련 차별 위험	규칙 폐지
모형의 차별적 영향 테스트 부재	위험을 알 수 없는 상태로 운영	연례 공정대출 테스트·보고
부정확한 거절 사유 통지	신청자가 이유를 알 수 없음	AI 거버넌스 조직·문서화

회사는 혐의를 부인했으나 합의했다. 새 AI 법 없이 기존 소비자보호법만으로 제재가 가능했다.

범용 LLM도 대출 심사에서 인종에 따라 다르게 답했다

Bowen·Price·Stein·Yang — 2022년 HMDA 실제 신청서 1,000건으로 6,000건의 실험용 신청서를 만들었다

+120점

흑인 신청자가 같은 승인율을 받는 데 더 필요한 신용점수(GPT-4 Turbo)

+30점

같은 금리를 받는 데 더 필요한 점수

≈ 0

"편향 없이 판단하라" 지시 후 승인 격차

무엇을 보여 주나

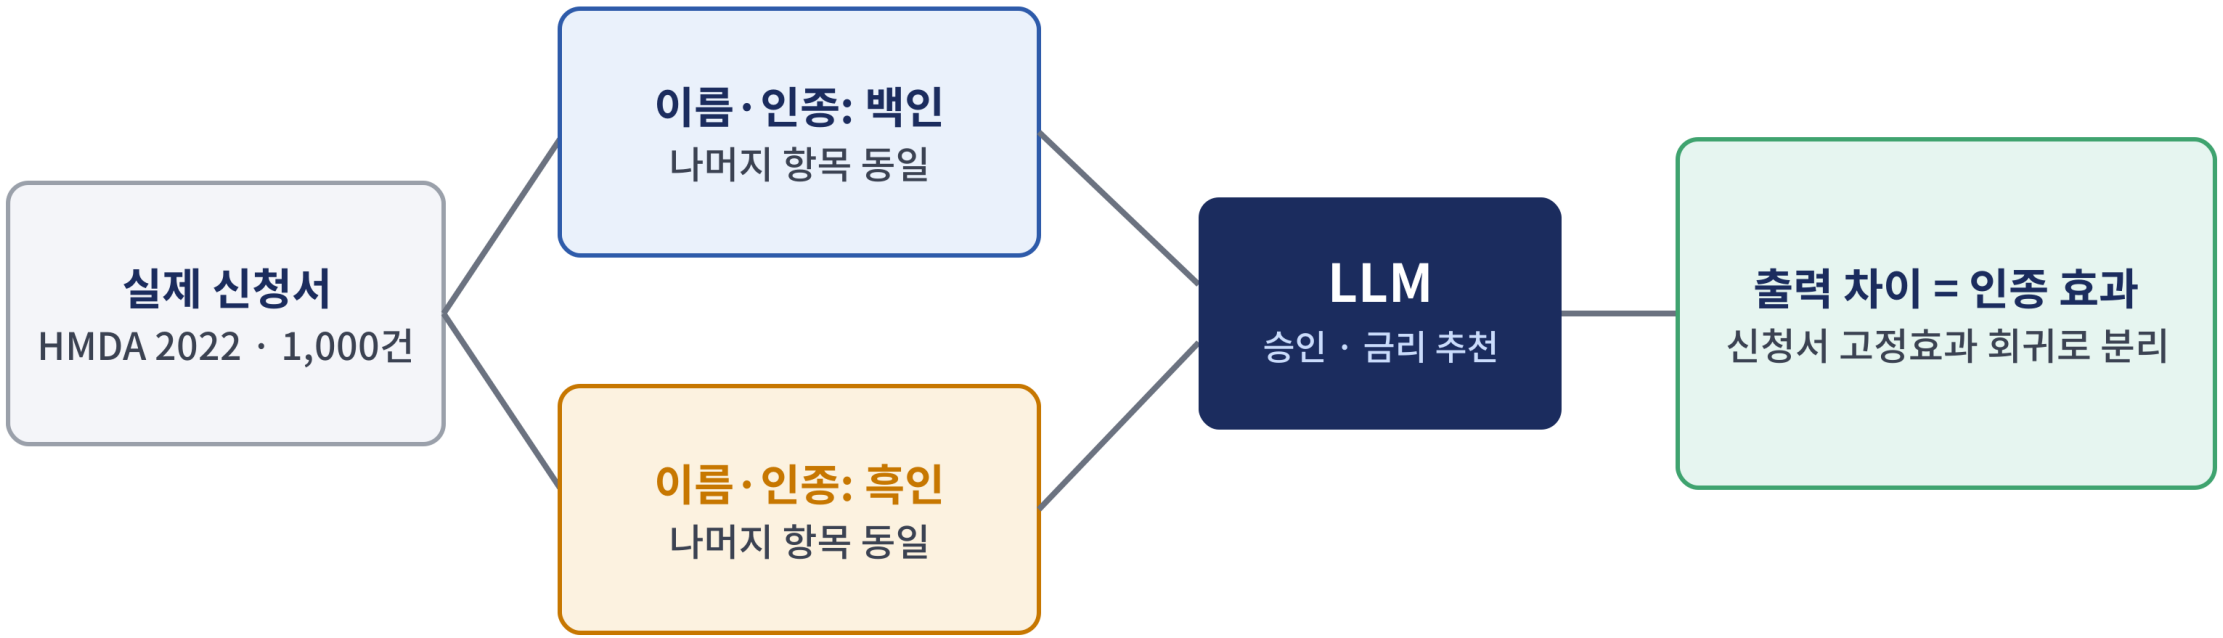
- 이름만으로도 인종 신호가 전달된다
- 저신용·고위험 신청서에서 격차가 크다

실무 시사점

- LLM 상담·추천도 감사 대상이다
- 지시문 완화는 대체가 아닌 보완이다

감사 설계는 서류를 고정하고 인종 신호만 바꾼다

같은 신청서를 두 벌로 만들어 출력 차이를 비교하면, 그 차이는 인종 신호에서만 나온다



같은 서류에 인종 신호만 바꾸는 감사(audit study) 설계 — 금융회사가 자체 LLM에 그대로 적용할 수 있다

02

PART 2 · 공정성 정의

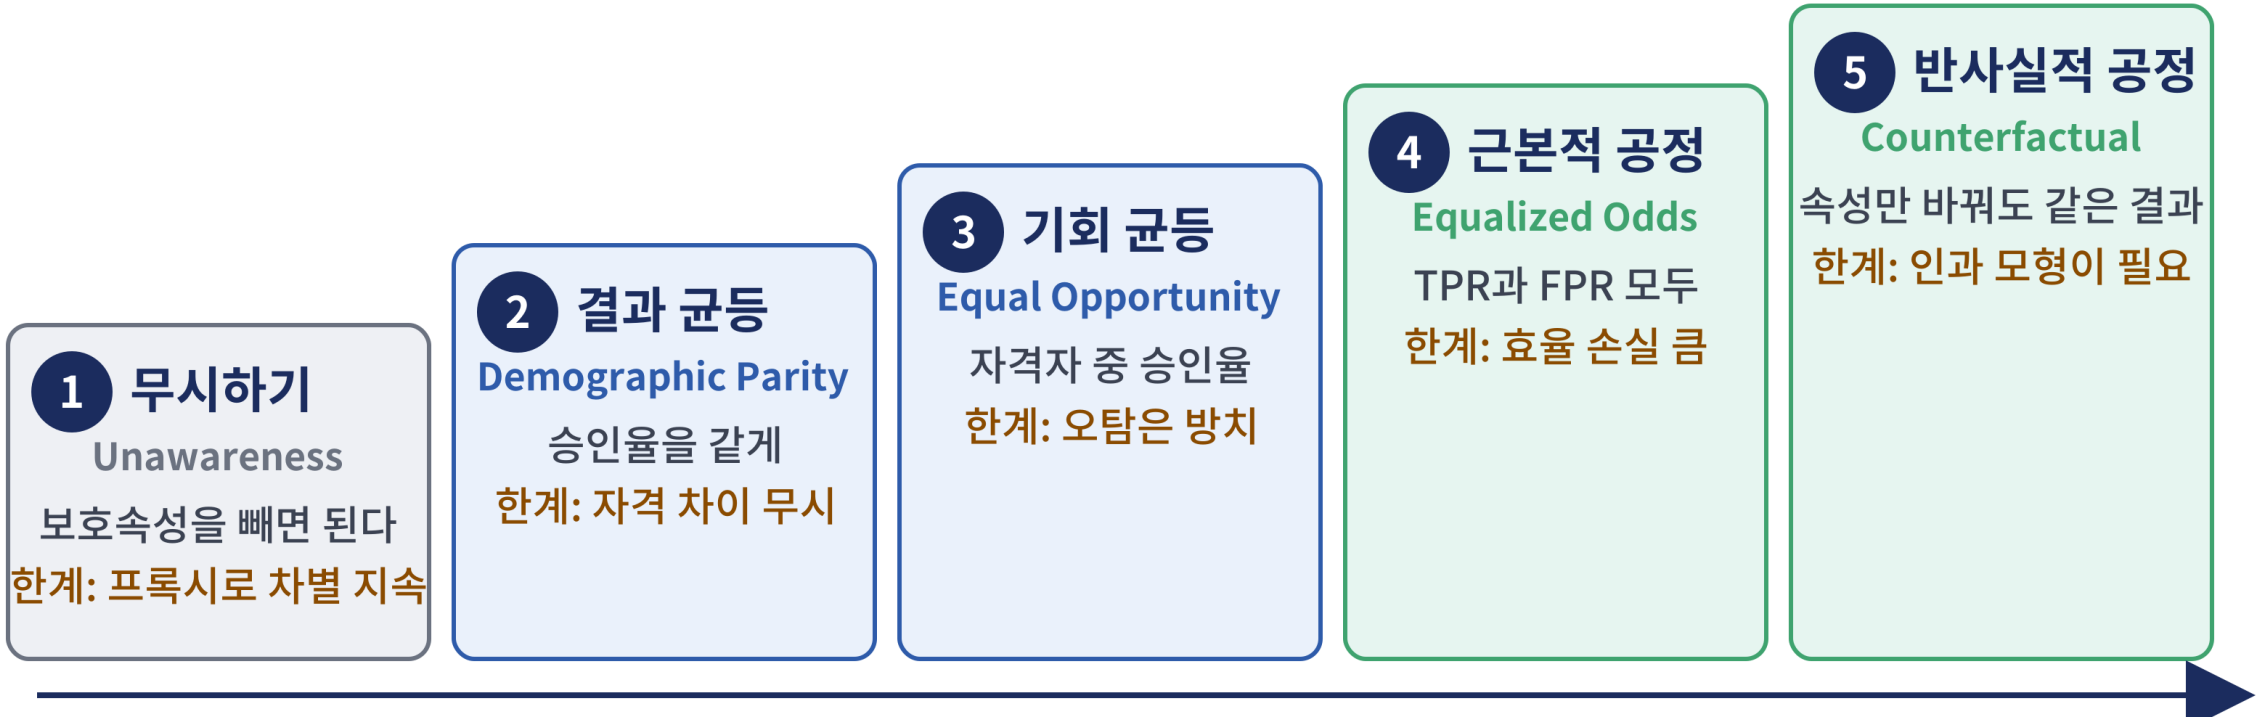
공정성 5단계 사다리

무시하기 → 결과 균등 → 기회 균등 → 근본적 공정 → 반사실적 공정

공정성 정의는 다섯 단계로 정교해진다

단계가 오를수록 더 많은 데이터(실제 결과)와 인과 지식(무엇이 무엇을 만드는가)이 필요하다

요구 수준이 높아질수록 데이터와 인과 지식이 더 필요하다



각 단계는 서로 다른 질문에 답한다

원전의 키 비유: "키는 재지 말고 그냥 서라"에서 "성별과 무관하게 같은 결과"까지

단계	던지는 질문	철학적 기반	구현 난이도
1 무시하기	보호속성을 안 쓰면 공정한가?	형식적 평등	낮음
2 결과 균등	집단별 승인율이 같은가?	결과의 평등	낮음
3 기회 균등	자격자 중 승인율이 같은가?	능력주의	중간
4 근본적 공정	자격자·비자격자 모두 같은가?	절차적 정의	높음
5 반사실적 공정	속성만 바꿔도 결과가 같은가?	인과적 정의	매우 높음

원전은 4단계까지였고, 반사실적 공정성은 근본적 공정에 속하지 않는 별도 단계로 추가했다.

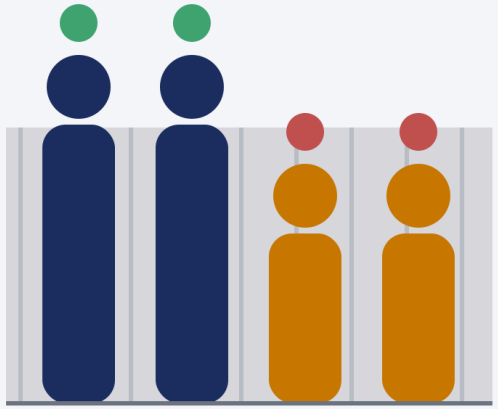
원전의 키 비유는 네 단계의 차이를 한눈에 보여 준다

담장 너머 경기를 보는 장면 — 담장을 넘는 키가 '자격', 경기가 보이는 것이 '혜택'이다

네이비·주황 = 두 집단, 초록 점 = 경기가 보인다(혜택), 빨강 점 = 안 보인다 — 원전의 키 비유

1 무시하기

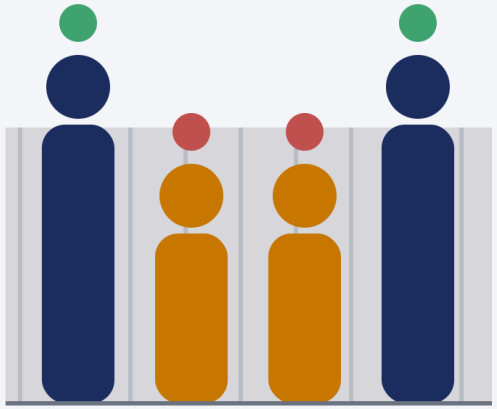
"키는 재지 말고 그냥 서라"



작은 사람은 담장에 가린다

2 결과 균등

"남녀 비율을 맞춰 세운다"



비율은 맞지만 일부는 못 본다

3 기회 균등

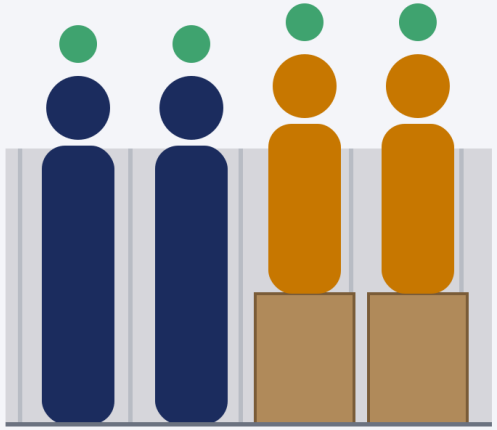
"볼 수 있는 사람 중 반반"



담장을 넘는 사람 중에서 반반

4 근본적 공정

"누구나 같은 결과가 나오게"



받침대로 모두 같은 결과

각 정의는 일상의 익숙한 규칙과 닮았다

강의에서 먼저 일상 사례로 감을 잡고 수식으로 넘어간다

정의	일상 비유	금융에서의 질문
결과 균등	동아리 정원을 학과별로 똑같이 나눈다	집단별 승인율이 같은가?
기회 균등	커트라인을 넘은 학생은 학과와 무관하게 같은 확률로 뽑는다	갚을 사람의 승인율이 같은가?
근본적 공정	공항 검색의 적발률과 오적발률이 국적과 무관하게 같다	TPR과 FPR이 모두 같은가?
보정	'비 올 확률 70%'가 어느 동네에서든 실제로 70%다	같은 점수의 상환율이 같은가?
개인 공정	1점 차이 두 학생은 비슷한 학점을 받는다	비슷한 고객이 비슷한 결정을 받는가?
반사실적 공정	이름만 바꾼 이력서에 같은 회신이 온다	속성만 바꿔도 결정이 같은가?

보호속성을 지워도 프록시가 차별을 되살린다

Fairness through Unawareness — 입력에서 A만 뺄 뿐, 결과의 독립(Ŷ ⊥ A)은 보장하지 않는다

$$\hat{Y} = f(X), \quad A \notin X \qquad \text{그러나} \quad X \not\perp A \Rightarrow \hat{Y} \not\perp A$$

겉보기 중립 변수	대신 드러내는 것	확인 방법
우편번호	거주지 분리에 따른 인종	집단 레이블과의 상관
직업군·학교	성별·사회경제적 배경	SHAP 기여도 확인
앱 사용 시간·기기	가족 구성·소득 수준	변수 제거 후 격차 변화

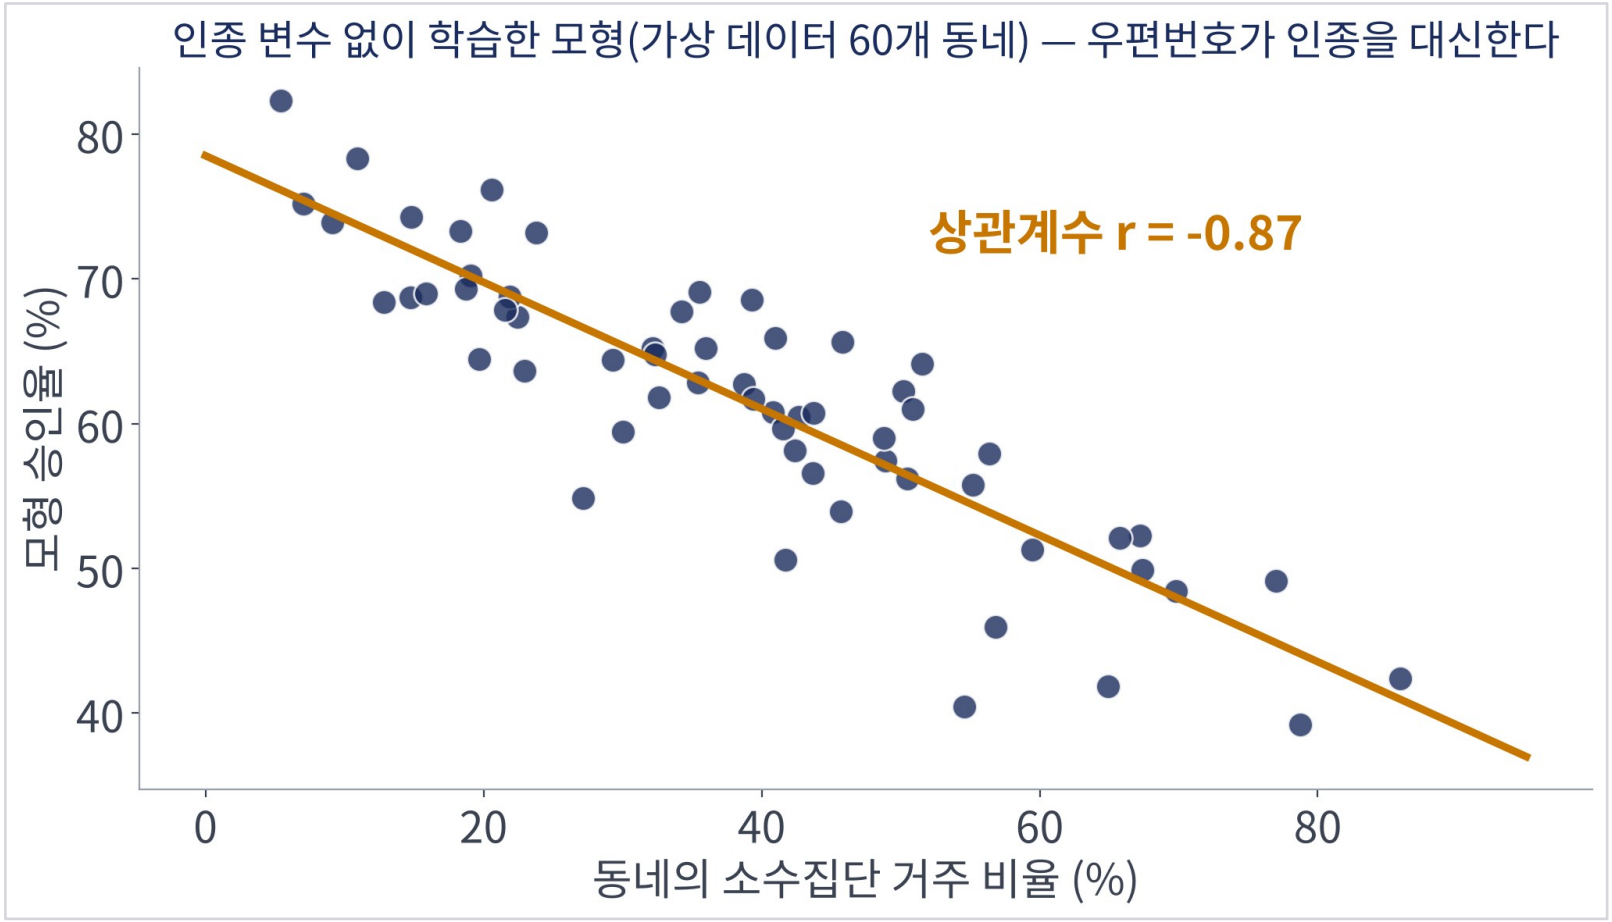
검사는 이름이 아니라 기능으로 한다. "열 이름이 race인가"가 아니라 "모형이 race처럼 행동하는가"를 본다.

우편번호 하나로 승인율이 인종을 따라간다

인종 변수를 빼고 학습한 모형의 동네별 승인율 (가상 데이터 60개 동네)

읽는 법

- 점 하나 = 한 동네
- 오른쪽일수록 소수집단
- 승인율이 떨어진다
- 변수 삭제로 못 막음



결과 균등은 집단별 승인율을 같게 맞춘다

Demographic Parity(Statistical Parity) — 실제 자격 Y를 보지 않는다

$$P(\hat{Y} = 1 \mid A = \text{집단 0}) = P(\hat{Y} = 1 \mid A = \text{집단 1})$$

원전 예: 남녀 대출 승인

- 남성 1,000명 중 700명 승인(70%)
- 여성 800명 중 400명 승인(50%)
- 두 집단을 60%로 맞추는 것이 목표

장점과 한계

- 자격 데이터 없이도 쓸 수 있다
- 할당·포용 정책과 잘 맞는다
- 자격 차이를 무시해 역차별 논란을 부른다

기회 균등은 상환할 사람에게 같은 기회를 준다

Equal Opportunity(Hardt·Price·Srebro 2016) — 자격자(Y=1) 안에서만 승인율을 비교한다

$$P(\hat{Y}=1 \mid \underbrace{Y=1}_{\text{실제 상환}}, A=0) = P(\hat{Y}=1 \mid Y=1, A=1)$$

원전 예: 자격자 수가 다를 때

- 남성 자격자 700명, 여성 500명
- 두 집단 모두 자격자의 90% 승인
- 승인 수는 630명 vs 450명으로 달라진다

결과 균등과 무엇이 다른가

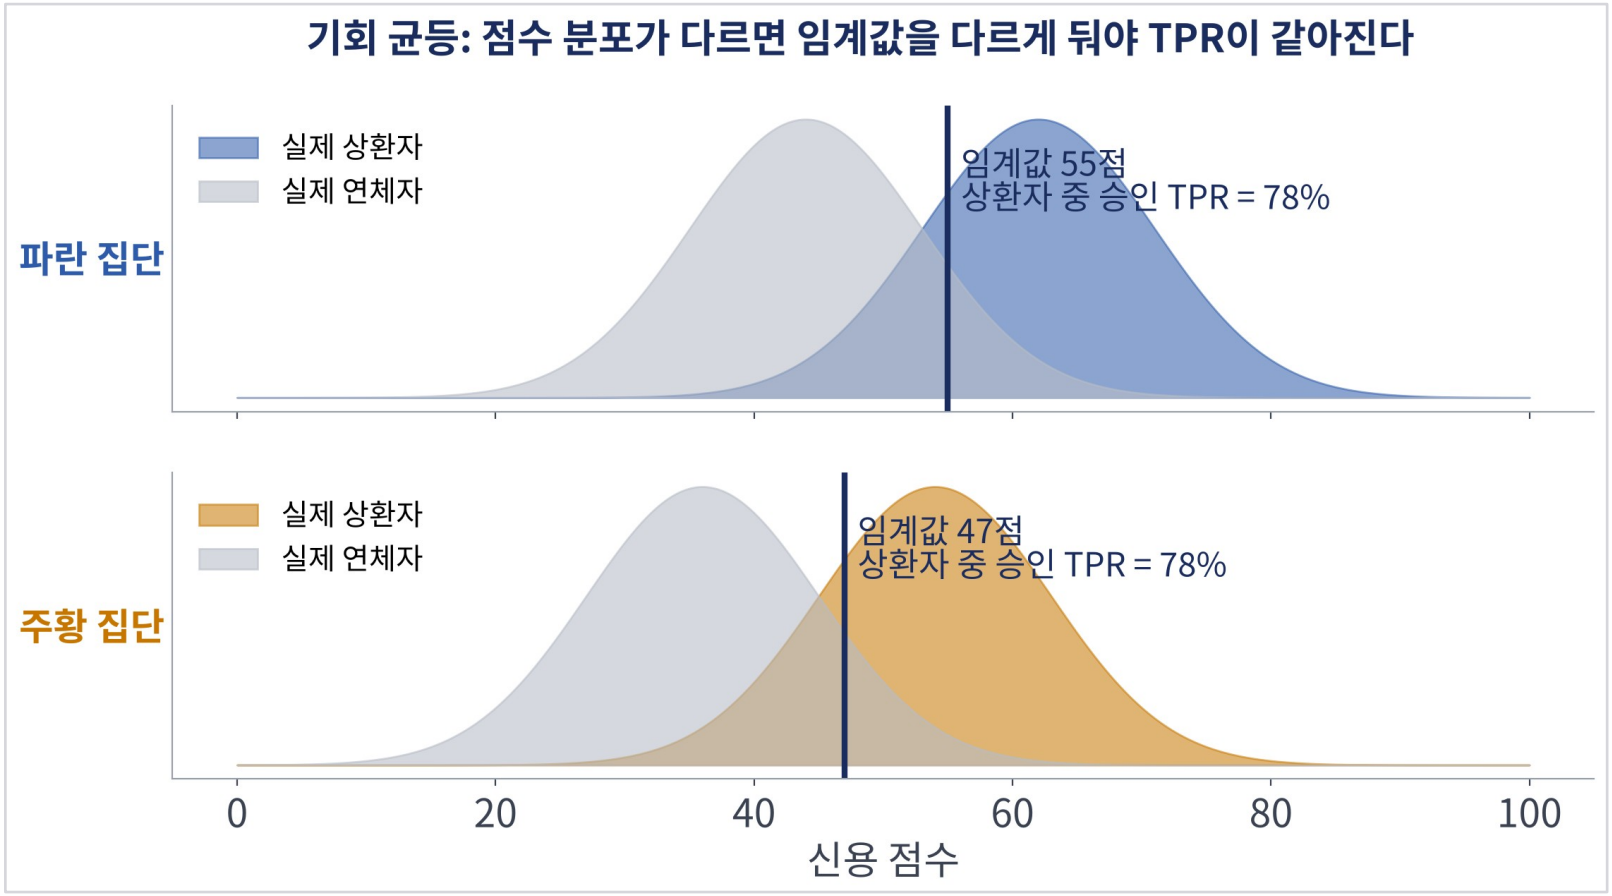
- 승인율 전체가 아니라 자격자 중 비율을 본다
- 효율 손실이 작아 금융권 주류 기준이다
- 비자격자 오탐(FPR)은 제약하지 않는다

집단별 임계값을 달리해야 TPR이 같아진다

원전 대출 승인 그래프(Google 'Attacking Discrimination' 시뮬레이션)를 재현한 분포다

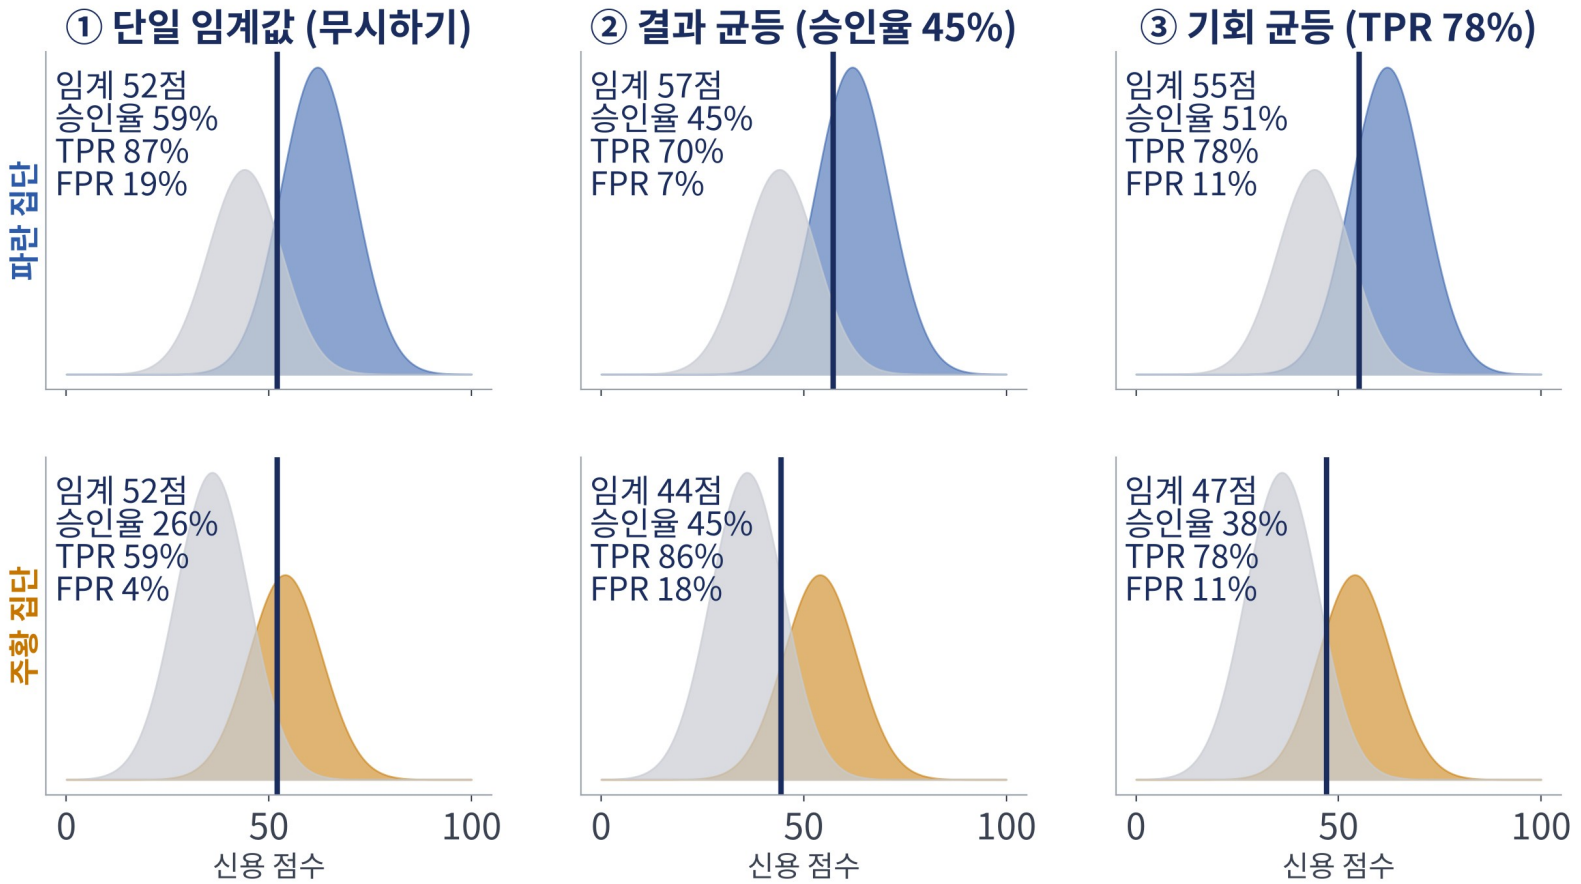
읽는 법

- 색: 실제 상환자
- 회색: 실제 연체자
- 세로선: 임계값
- 두 집단 TPR 78%



같은 점수 분포에 세 정책을 적용하면 결과가 이렇게 갈린다

단일 임계값은 주황 집단 TPR 59%, 결과 균등은 승인율 45%로 맞추고, 기회 균등은 TPR 78%로 맞춘다



색 = 실제 상환자, 회색 = 실제 연체자 (가상 분포 · 파란 집단 상환 비율 60%, 주황 집단 40%)

근본적 공정은 모든 사람에게 같은 오류율을 요구한다

Equalized Odds — TPR과 FPR을 함께 맞춘다. 기회 균등보다 엄격하다

$$P(\hat{Y} = 1 \mid Y = y, A = 0) = P(\hat{Y} = 1 \mid Y = y, A = 1), \quad y \in \{0, 1\}$$

→ TPR$(y = 1)$과 FPR$(y = 0)$이 두 집단에서 모두 같다

원전 예	남성 (상환 700 · 연체 300)	여성 (상환 600 · 연체 400)
TPR (상환자 승인)	90% → 630명	90% → 540명
FPR (연체자 승인)	20% → 60명	20% → 80명
전체 승인율	69%	62%

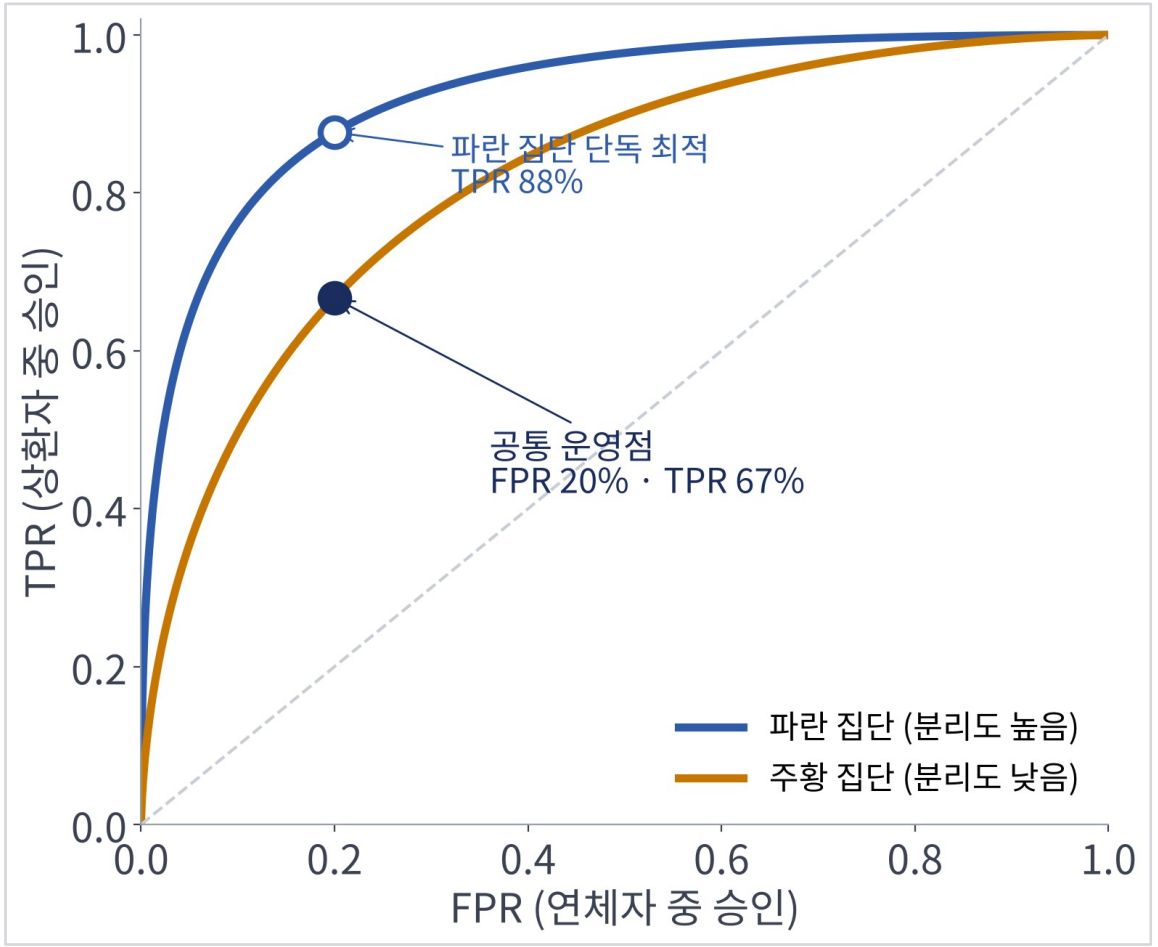
오류율이 같아도 승인율은 69% 대 62%로 다르다. 근본적 공정과 결과 균등은 함께 성립하지 않는다.

근본적 공정은 두 ROC 곡선이 만나는 점에서만 가능하다

Hardt 등(2016) — 분리도가 다르면 성능이 나쁜 집단의 곡선에 맞춰야 한다 (가상 분포)

읽는 법

- 곡선 = 임계값 전 범위
- 같은 FPR 20%에서
- TPR 88% vs 67%
- 맞추려면 무작위화



예측 동등과 보정은 승인 결정의 신뢰도를 같게 한다

Predictive Parity·Calibration — 결정을 받은 쪽이 아니라 결정을 내린 쪽의 시각이다

$$\underbrace{P(Y=1 \mid \hat{Y}=1, A=0) = P(Y=1 \mid \hat{Y}=1, A=1)}_{\text{예측 동등(Predictive Parity): PPV가 같다}} \qquad \underbrace{P(Y=1 \mid S=s, A=a) = s}_{\text{보정(Calibration)}}$$

의미

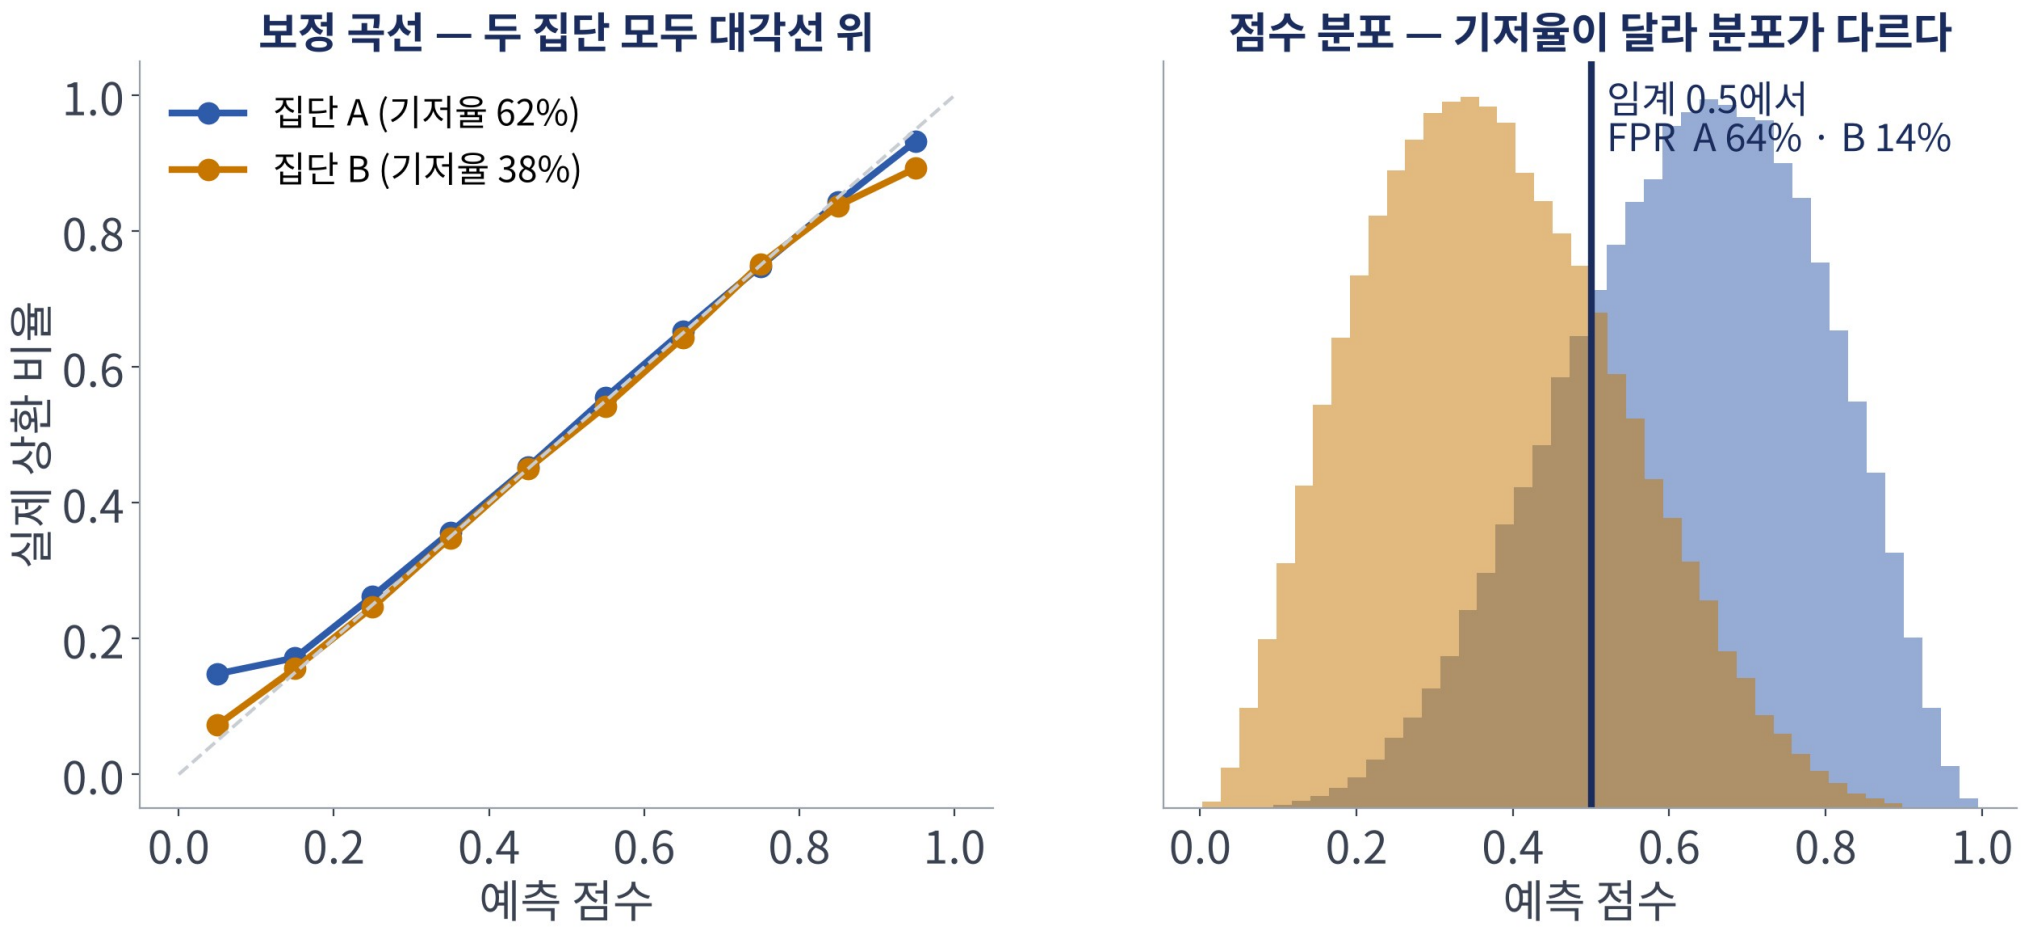
- 승인된 사람의 상환 확률이 집단과 무관하다
- 점수 0.7이면 누구든 70%가 상환한다

누가 선호하나

- 가격 결정·위험 관리 부서
- COMPAS 개발사의 공정성 기준

점수가 완벽히 보정돼도 오탐률은 크게 다를 수 있다

가상 데이터 — 두 집단 모두 보정 곡선이 대각선 위인데, 임계 0.5에서 FPR은 64% 대 14%다



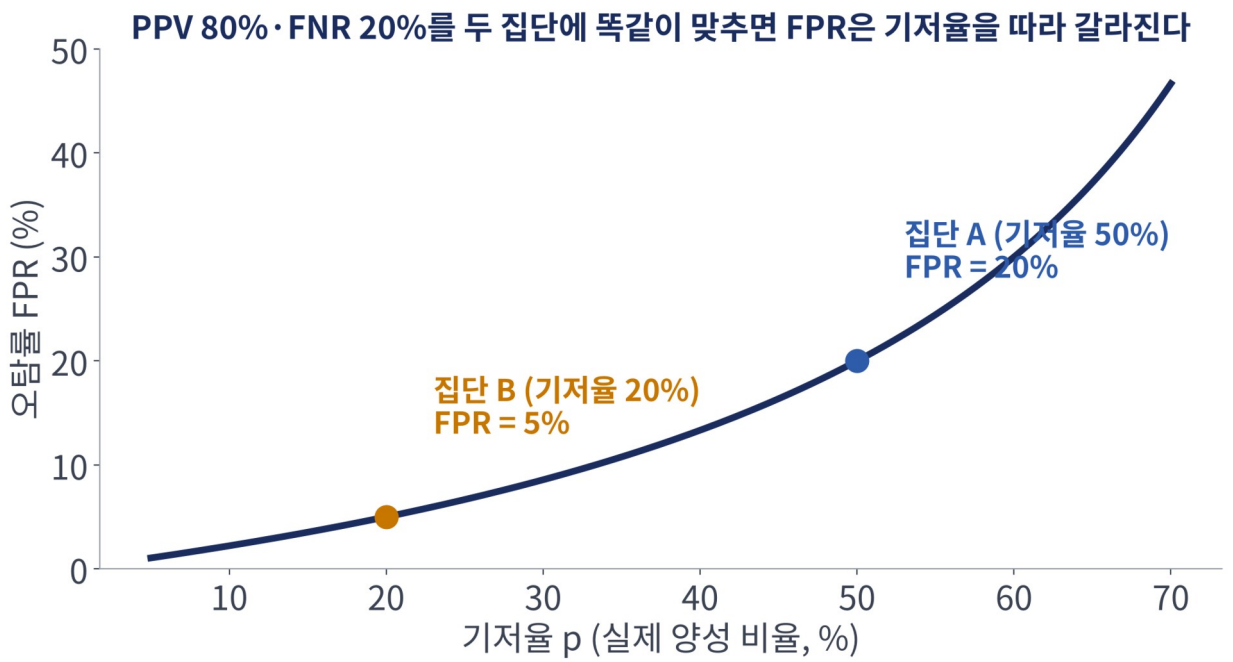
기저율이 다르면 보정과 오류율 균등은 함께 성립하지 않는다

Chouldechova(2017)·Kleinberg 등(2016) — 기저율 p는 집단의 실제 양성 비율이다

$$\mathrm{FPR} = \underbrace{\frac{p}{1-p}}_{\text{기저율}} \cdot \frac{1-\mathrm{PPV}}{\mathrm{PPV}} \cdot (1-\mathrm{FNR})$$

식이 말하는 것

- PPV·FNR을 맞추면 FPR이 갈린다
- 기저율이 같을 때만 모두 성립한다



반사실적 공정성은 같은 사람의 다른 정체성을 상상해 비교한다

Counterfactual Fairness(Kusner 등 2017) — 인과 모형에서 보호속성 A에 개입(A←a′)한다

$$P\left(\hat{Y}_{A\leftarrow a}(U)=y \mid X=x, A=a\right)=P\left(\hat{Y}_{A\leftarrow a'}(U)=y \mid X=x, A=a\right) \quad \forall\, y,\, a'$$

같은 사람(U)을 두고 보호속성만 바꿔 다시 계산해도 결과가 같아야 한다

근본적 공정과의 차이

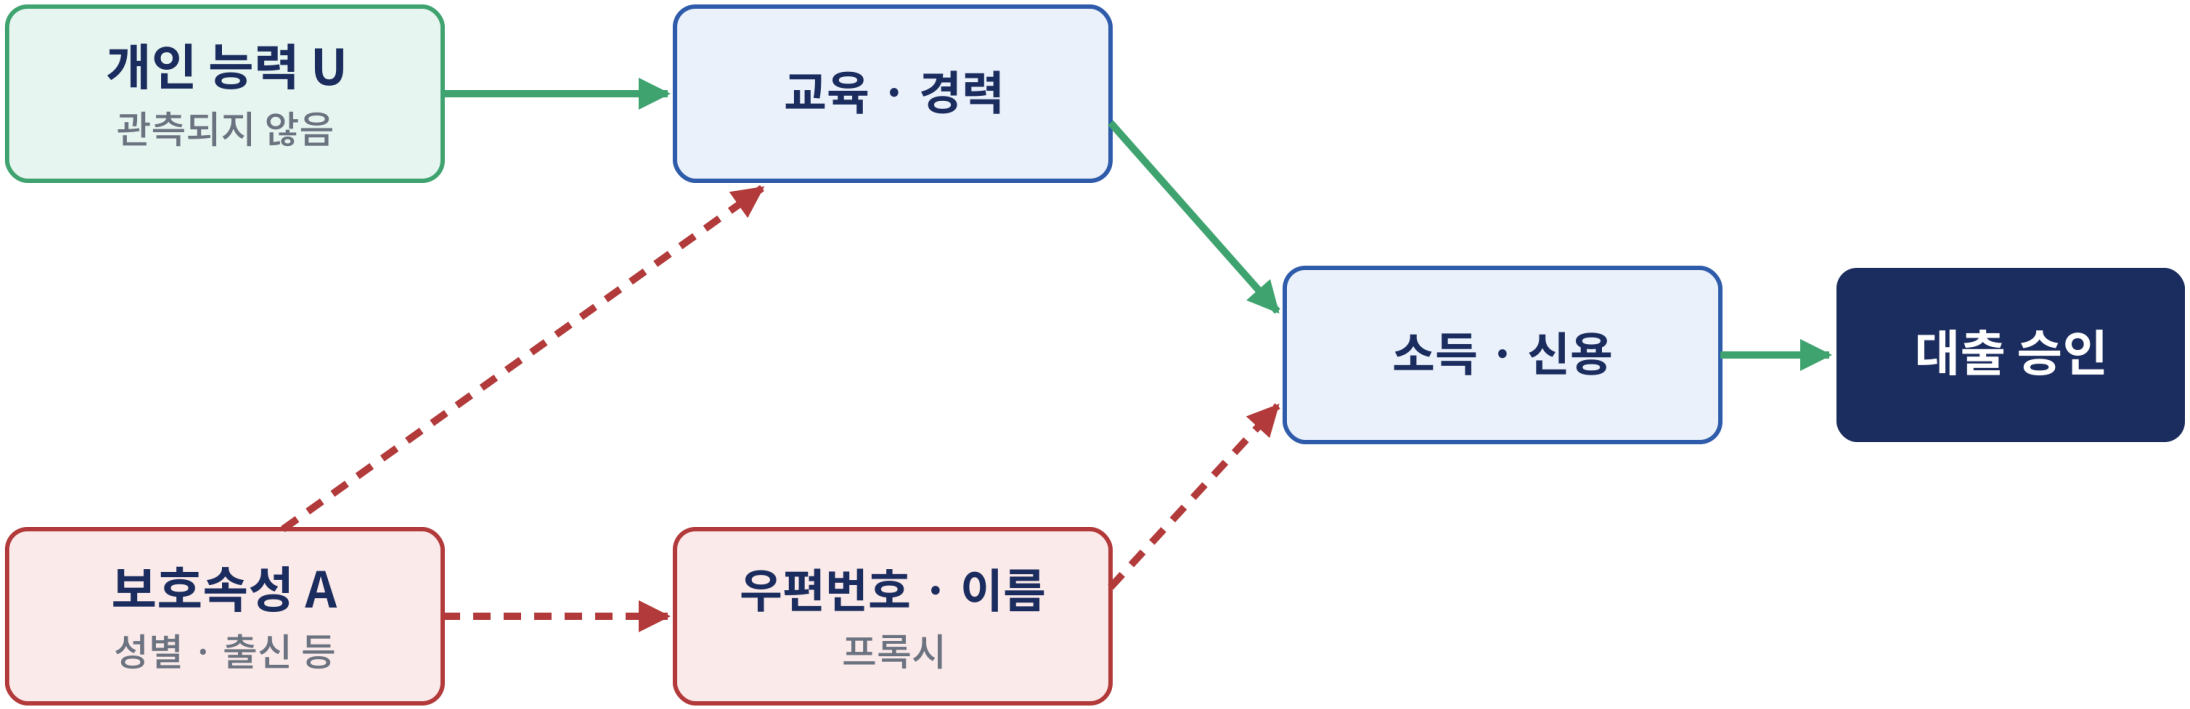
- 집단 평균이 아니라 개인 단위로 본다
- 어떤 경로가 차별인지 인과 그래프로 정한다

구현의 어려움

- 관측되지 않는 능력 U를 추정해야 한다
- 인과 그래프가 틀리면 결론도 틀린다

인과 그래프는 보존할 경로와 끊을 경로를 나눈다

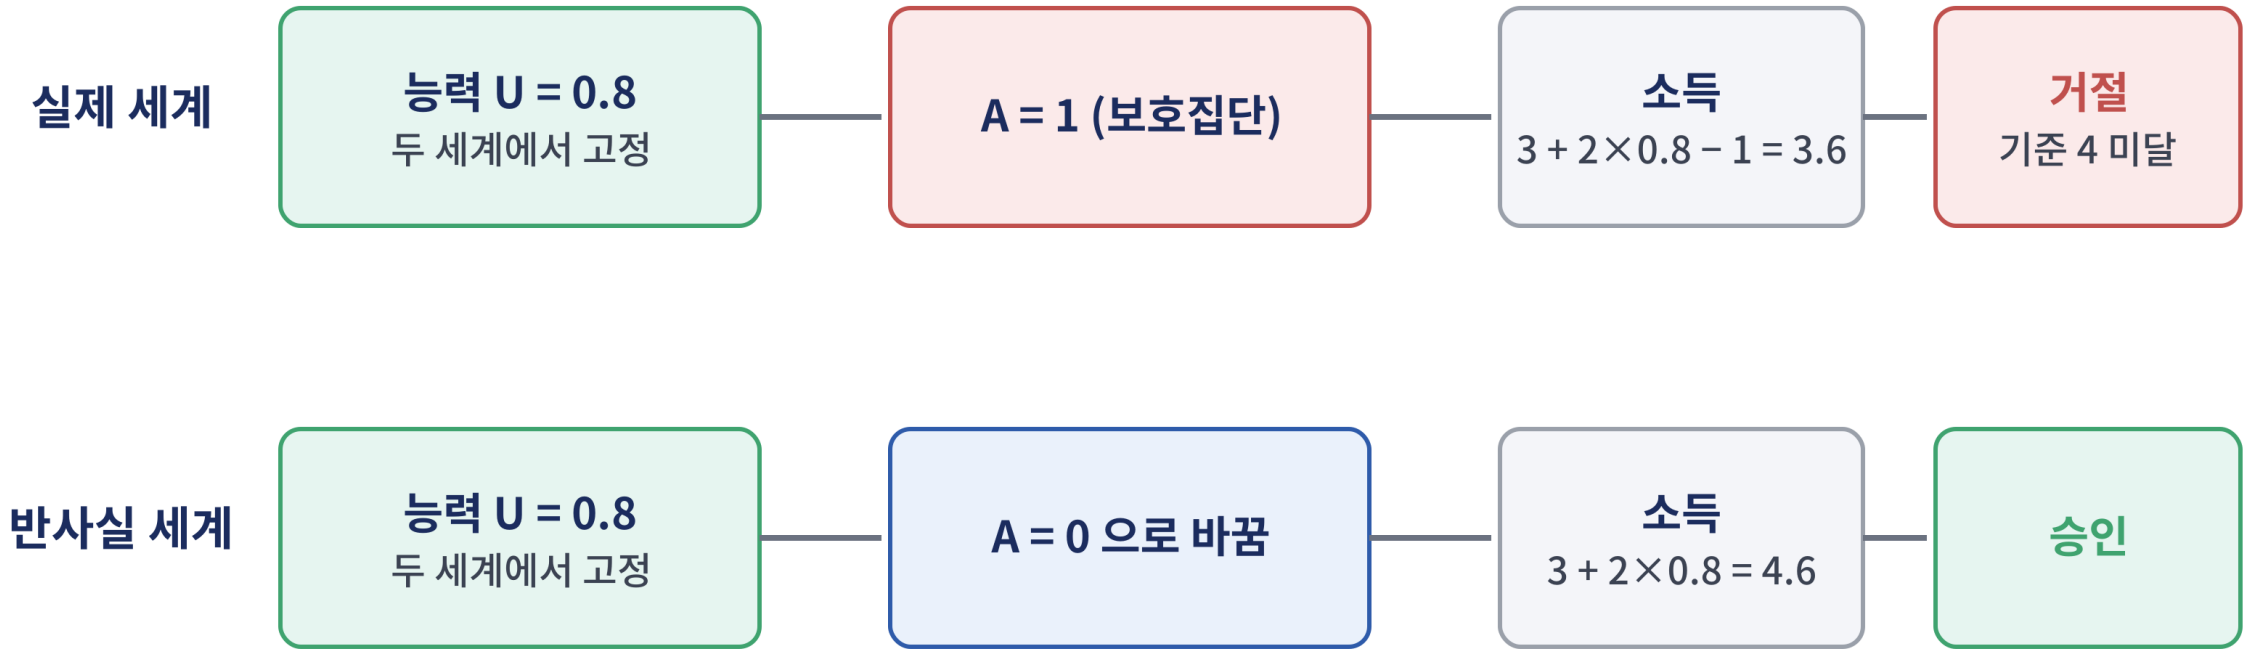
능력이 소득·신용을 통해 승인에 이르는 길은 남기고, 속성이 프록시를 거쳐 들어오는 길은 막는다



초록 실선은 보존할 경로(능력 → 자격), 빨강 점선은 끊어야 할 경로(속성 → 프록시·기회 차단)이다

반사실 계산은 같은 사람을 두 세계에 세워 본다

가상 모형: 소득 = 3 + 2U − A, 소득 4 이상이면 승인 (계산 과정은 워크북 8)



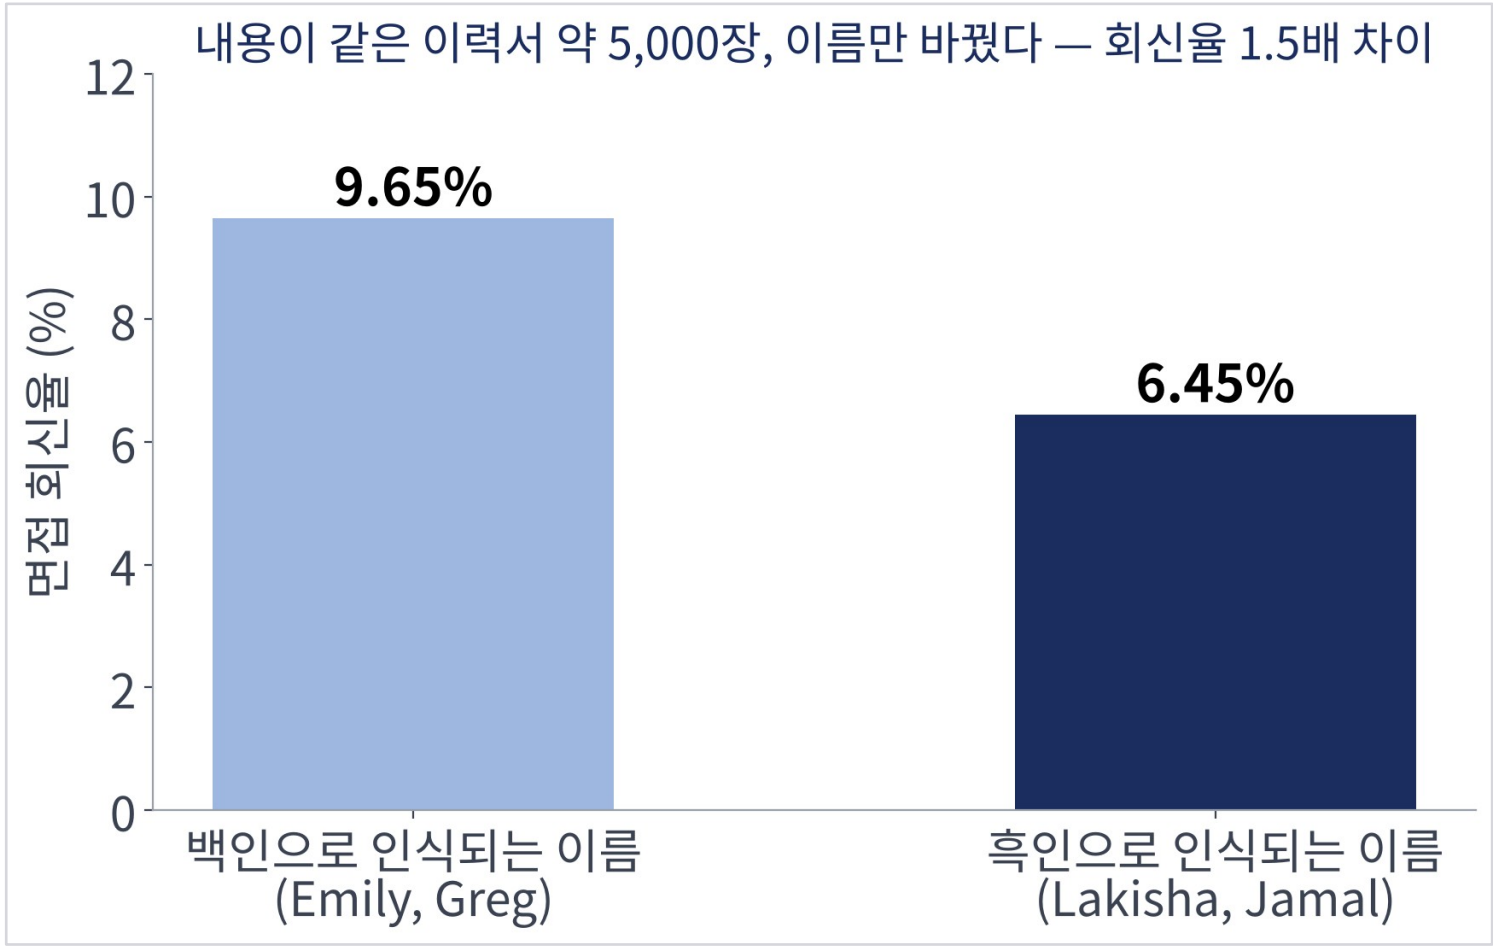
같은 사람(U 고정)인데 속성만 바꾸자 결정이 뒤집혔다 → 반사실적으로 불공정, 인간 재심 대상

이름만 바꾼 이력서 실험은 반사실 질문의 현실판이다

Bertrand·Mullainathan(2004, AER) — 보스턴·시카고 구인 광고 1,300여 건에 가상 이력서를 보냈다

강의 포인트

- 서류 내용은 동일
- 이름만 바꿈
- 회신 9.65% vs 6.45%
- AI도 같은 방식 감사

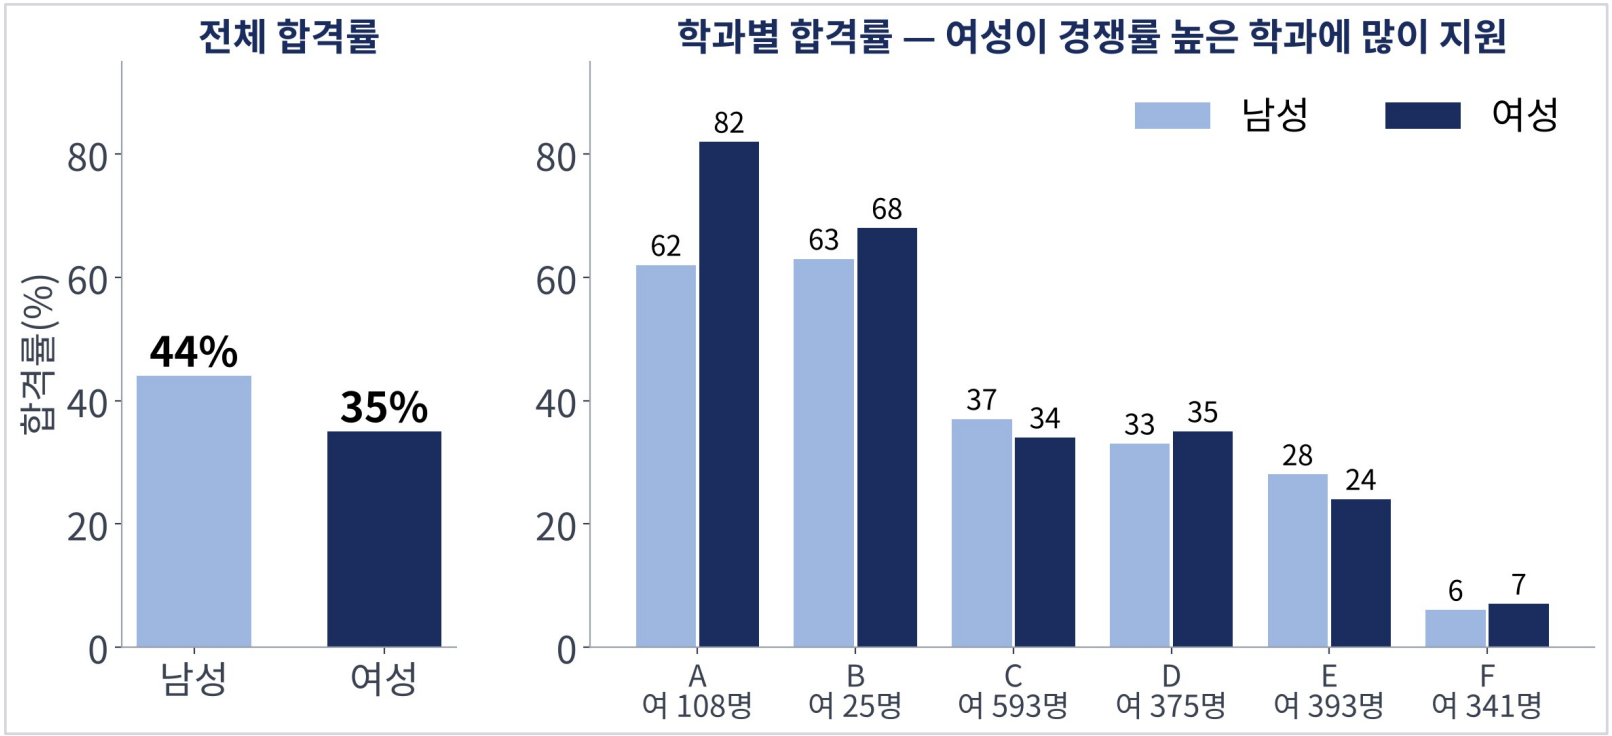


버클리 대학원 입시는 집계가 차별을 만들어 낸 사례다

Bickel 등(1975, Science) — 원전의 '2021년' 표기는 1973년 자료로 바로잡았다

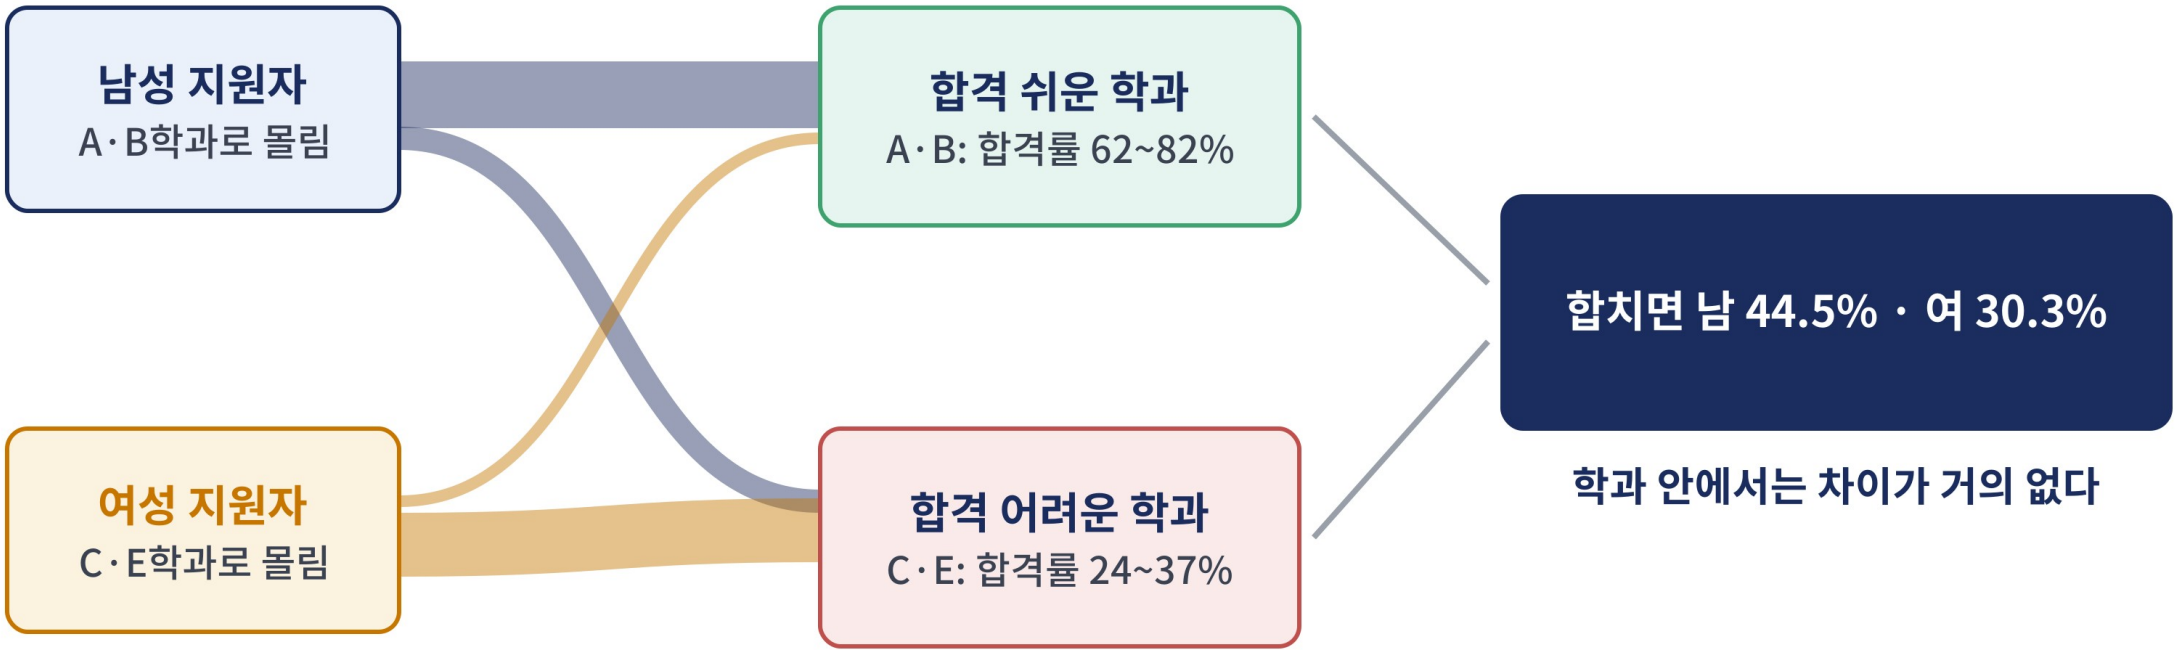
반사실적 질문

- 전체 44% 대 35%
- 학과별 격차 미미
- 학과 선택이 원인
- 경로를 나눠 본다



지원 경로를 그리면 집계 격차의 원인이 드러난다

여성 지원자가 합격률 낮은 학과로 몰린 흐름이 전체 합격률 격차를 만들었다



선 굵기 = 지원자 수 (Bickel 등 1975, 6개 주요 학과)

상품 추천에는 개인 공정성과 노출 공정성이 추가된다

원전 '금융상품 추천 모델 전략'의 세 지표 — 개인·그룹·노출 공정성 중 두 가지를 수식으로 정리했다

$$\underbrace{D\big(M(x), M(x')\big)}_{\text{결과의 차이}} \leq L \cdot \underbrace{d(x, x')}_{\text{사람 간 유사도}}$$

$$\text{노출}(G) = \frac{1}{|G|} \sum_{i \in G} \sum_{k} \frac{P(i\text{가 } k\text{위})}{\log_2(1+k)}, \qquad \frac{\text{노출}(G_0)}{\text{효용}(G_0)} = \frac{\text{노출}(G_1)}{\text{효용}(G_1)}$$

개인 공정성 (Dwork 2012)

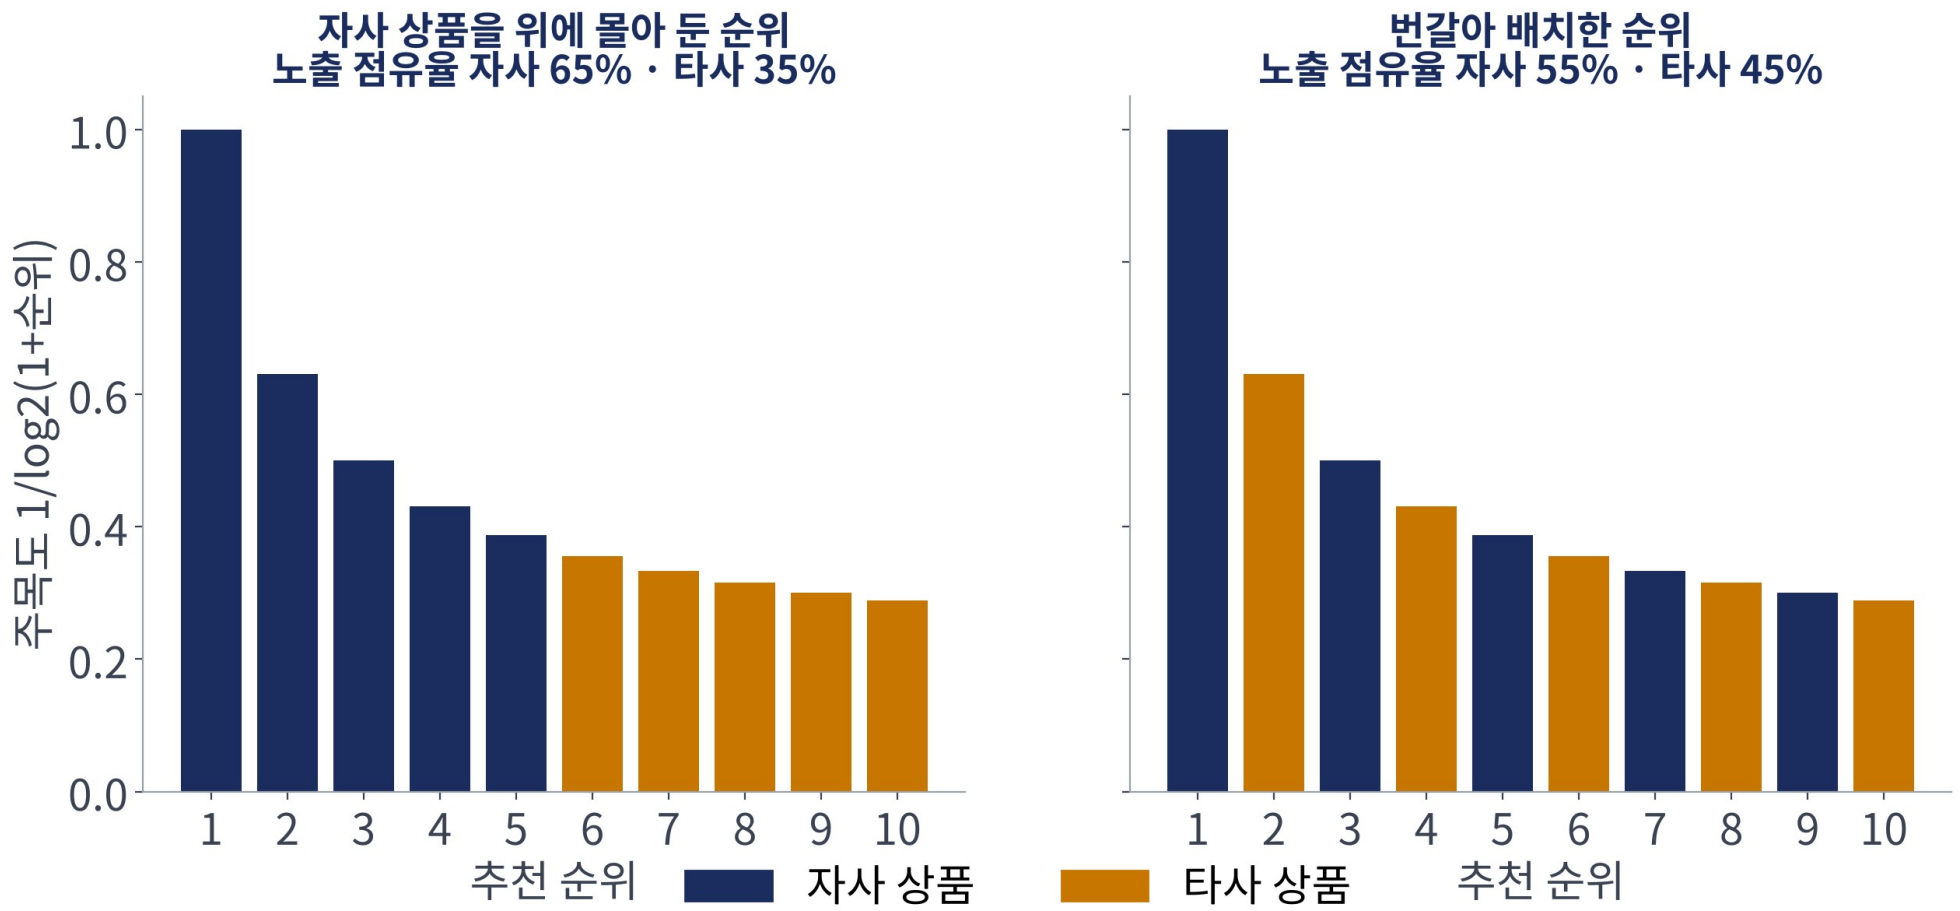
- 비슷한 고객은 비슷한 추천을 받아야 한다
- 유사도 d를 누가 정하느냐가 핵심 쟁점이다

노출 공정성 (Singh·Joachims 2018)

- 상위 노출은 효용에 비례해 나눈다
- 자사 상품만 위에 올리는 편향을 잡는다

위쪽 다섯 칸을 차지하면 노출의 3분의 2를 가져간다

자사·타사 상품 각 5개 — 순위별 주목도를 1/log2(1+순위)로 두고 노출 점유율을 계산했다



어떤 정의를 쓸지는 막으려는 피해가 정한다

원전의 단계별 ROI 수치는 출처를 확인할 수 없어 질적 기준으로 대체했다

막으려는 피해	우선 정의	금융 예시
자격 있는 사람이 기회를 잃는 것	기회 균등	대출·카드 승인
잘못된 고위험 낙인	근본적 공정	사기 탐지·연체 경보
점수의 의미가 집단마다 다른 것	보정·예측 동등	보험료·금리 산정
특정 집단의 접근 자체가 막히는 것	결과 균등	포용금융 상품 배분
개인이 속성 때문에 다르게 판정되는 것	반사실적 공정	고액 심사·이의 재심

03

PART 3 · 측정과 완화

격차를 재고 줄이는 방법

측정 지표 → 집단별 감사 → 전처리·처리 중·후처리 → 공정성 비용

실무 감사는 네 가지 격차 지표로 시작한다

DI=차별적 영향 비율, SPD=승인율 차, EOD=TPR 차, AOD=평균 오류율 차

$$\mathrm{DI} = \frac{P(\hat{Y}=1 \mid \text{보호집단})}{P(\hat{Y}=1 \mid \text{비보호집단})} \geq 0.8 \qquad \mathrm{SPD} = P(\hat{Y}=1 \mid \text{보호}) - P(\hat{Y}=1 \mid \text{비보호})$$

$$\mathrm{EOD} = \mathrm{TPR}_0 - \mathrm{TPR}_1 \qquad \mathrm{AOD} = \tfrac{1}{2}\left[(\mathrm{TPR}_0 - \mathrm{TPR}_1) + (\mathrm{FPR}_0 - \mathrm{FPR}_1)\right]$$

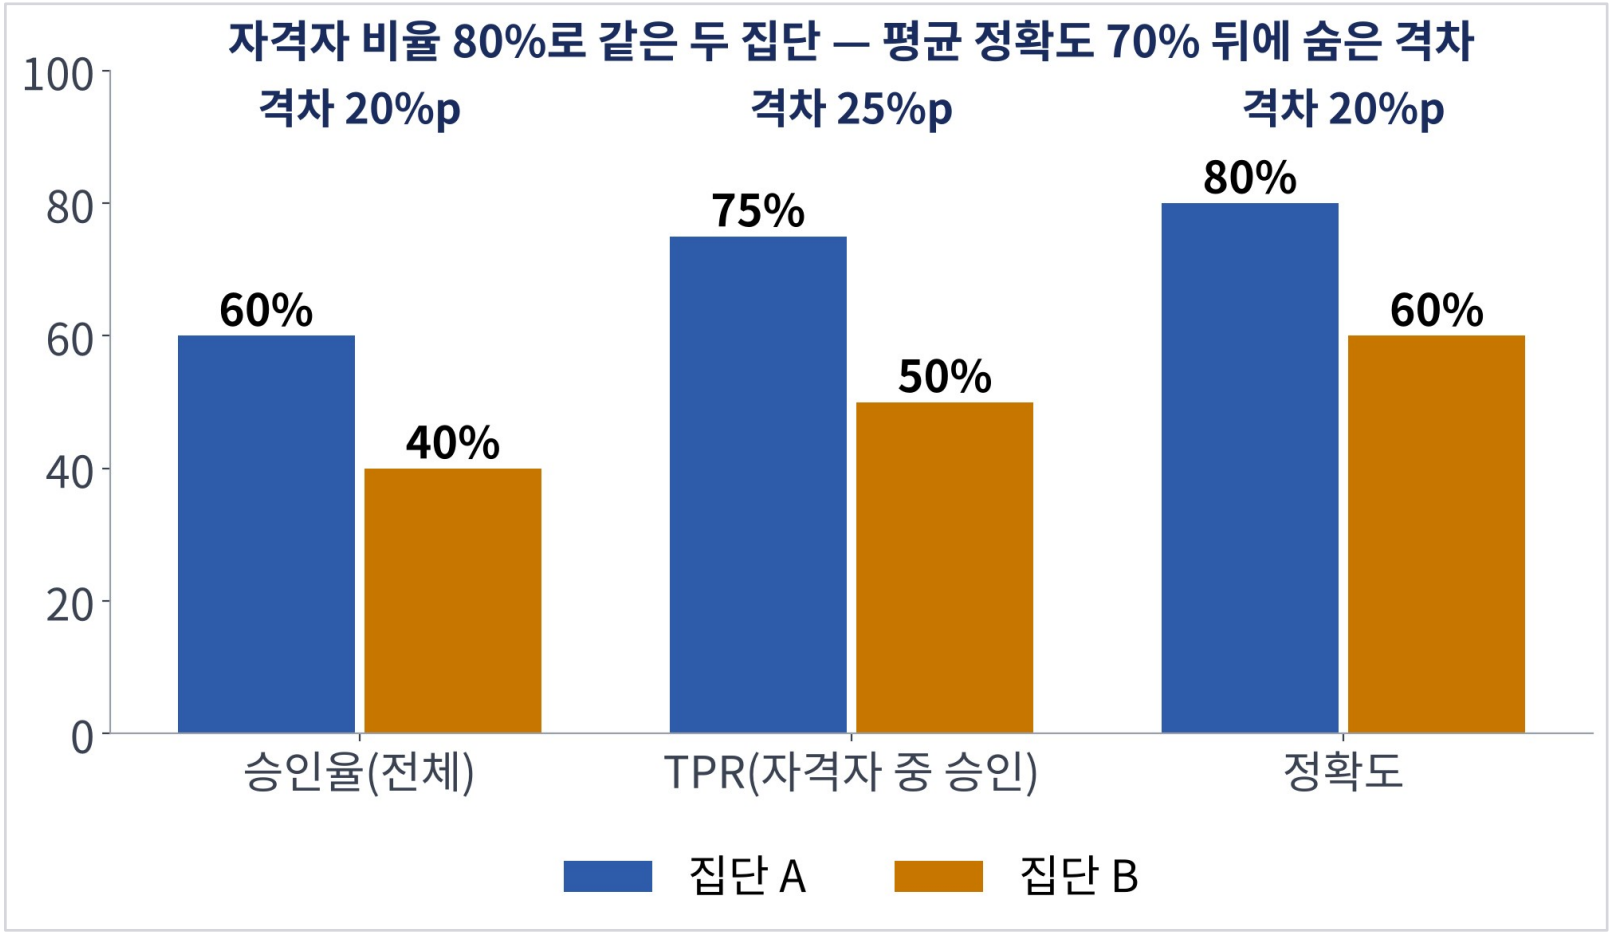
지표	통상 기준	원전 예 적용
DI (4/5 규칙)	0.8 이상	50% ÷ 70% = 0.71 → 기준 미달
SPD	|SPD| < 0.1	50% − 70% = −0.20
EOD	|EOD| < 0.05	자격자 승인율 차이

전체 정확도 하나는 집단 간 격차를 숨긴다

두 집단 각 100명, 자격자 80명으로 같다. 오탐은 0건인데도 기회 격차는 25%p다 (계산 과정은 워크북 1)

읽는 법

- 자격 비율 동일
- 승인 60 vs 40명
- 전체 정확도 70%
- 격차는 집단별로



편향 완화는 데이터·학습·결정의 세 지점에서 개입한다

Pre-processing · In-processing · Post-processing — 원전 8시간 커리큘럼의 기법을 정리했다

전처리 : $w_{a,y} = \dfrac{P(A=a)\,P(Y=y)}{P(A=a,\,Y=y)}$

전처리 (재가중·리샘플링)

모형을 바꾸지 않지만 프록시가 남을 수 있다

처리 중 : $\min_{\theta}\ \mathcal{L}_{\text{예측}}(\theta) + \lambda\big(|\Delta\mathrm{TPR}| + |\Delta\mathrm{FPR}|\big)$

처리 중 (공정성 정규화)

정확도와 균형을 조절하나 λ 선택과 재학습이 필요하다

후처리 : $\hat{Y} = \mathbf{1}\{\, s(x) > \tau_a \,\},\quad \tau_a$ 는 집단별 임계값

후처리 (집단별 임계값)

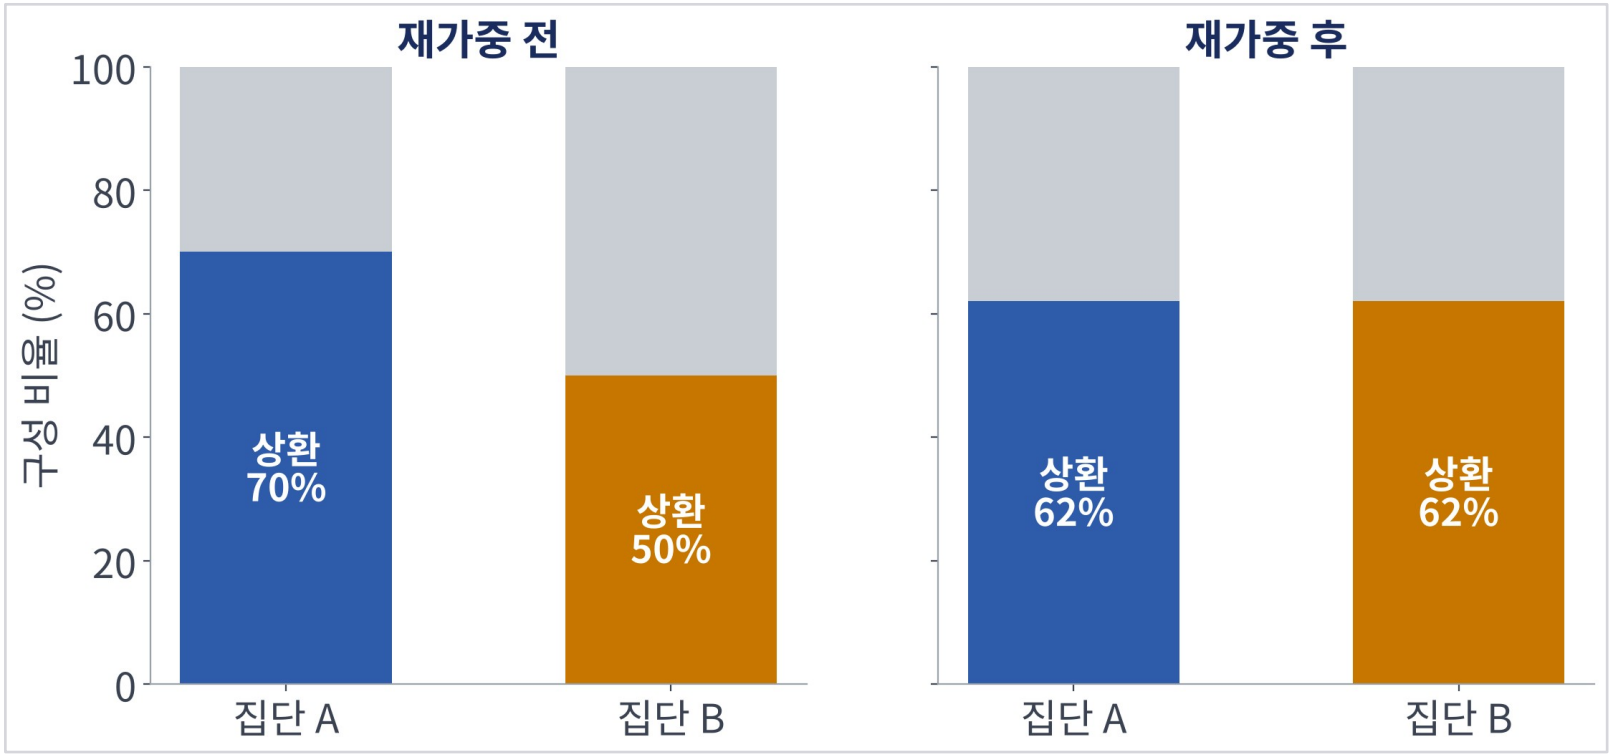
즉시 적용되지만 속성을 명시적으로 써야 한다

재가중 후 두 집단의 상환 비율이 같아진다

A 600명(상환 420), B 400명(상환 200)에 가중치를 주면 둘 다 62%가 된다 (계산 과정은 워크북 7)

읽는 법

- 색 = 상환 비율
- 전: 70% vs 50%
- 후: 62% vs 62%
- 인원은 그대로

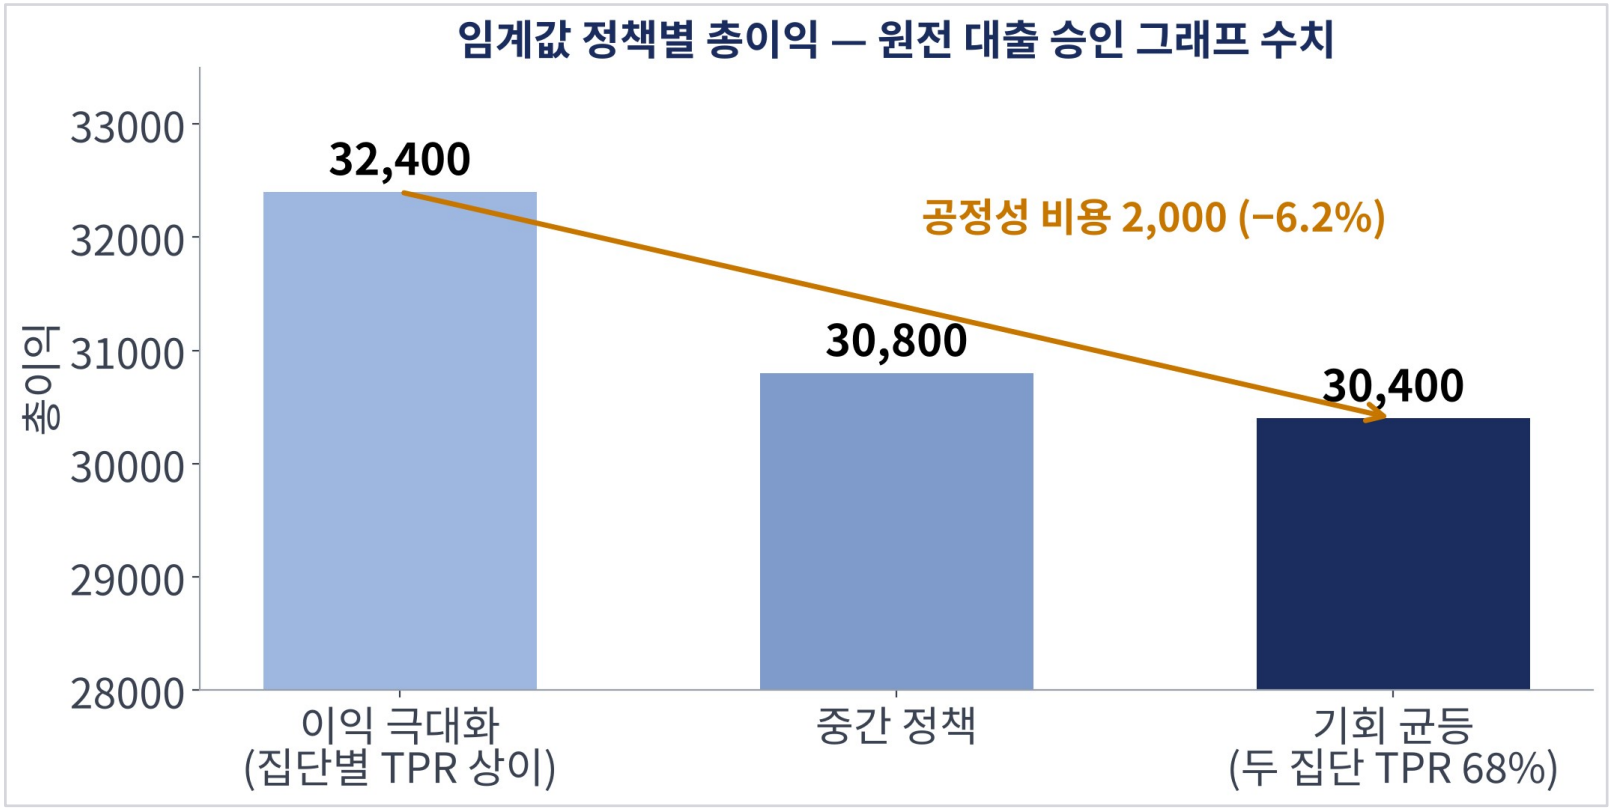


기회 균등의 비용은 이익의 약 6%였다

원전 대출 승인 그래프 세 장의 총이익 수치다 — 공정성을 높일수록 이익이 줄어드는 상충관계

해석

- 최대 이익 32,400
- 기회 균등 30,400
- 차이 2,000
- 규제·평판 비용과 비교

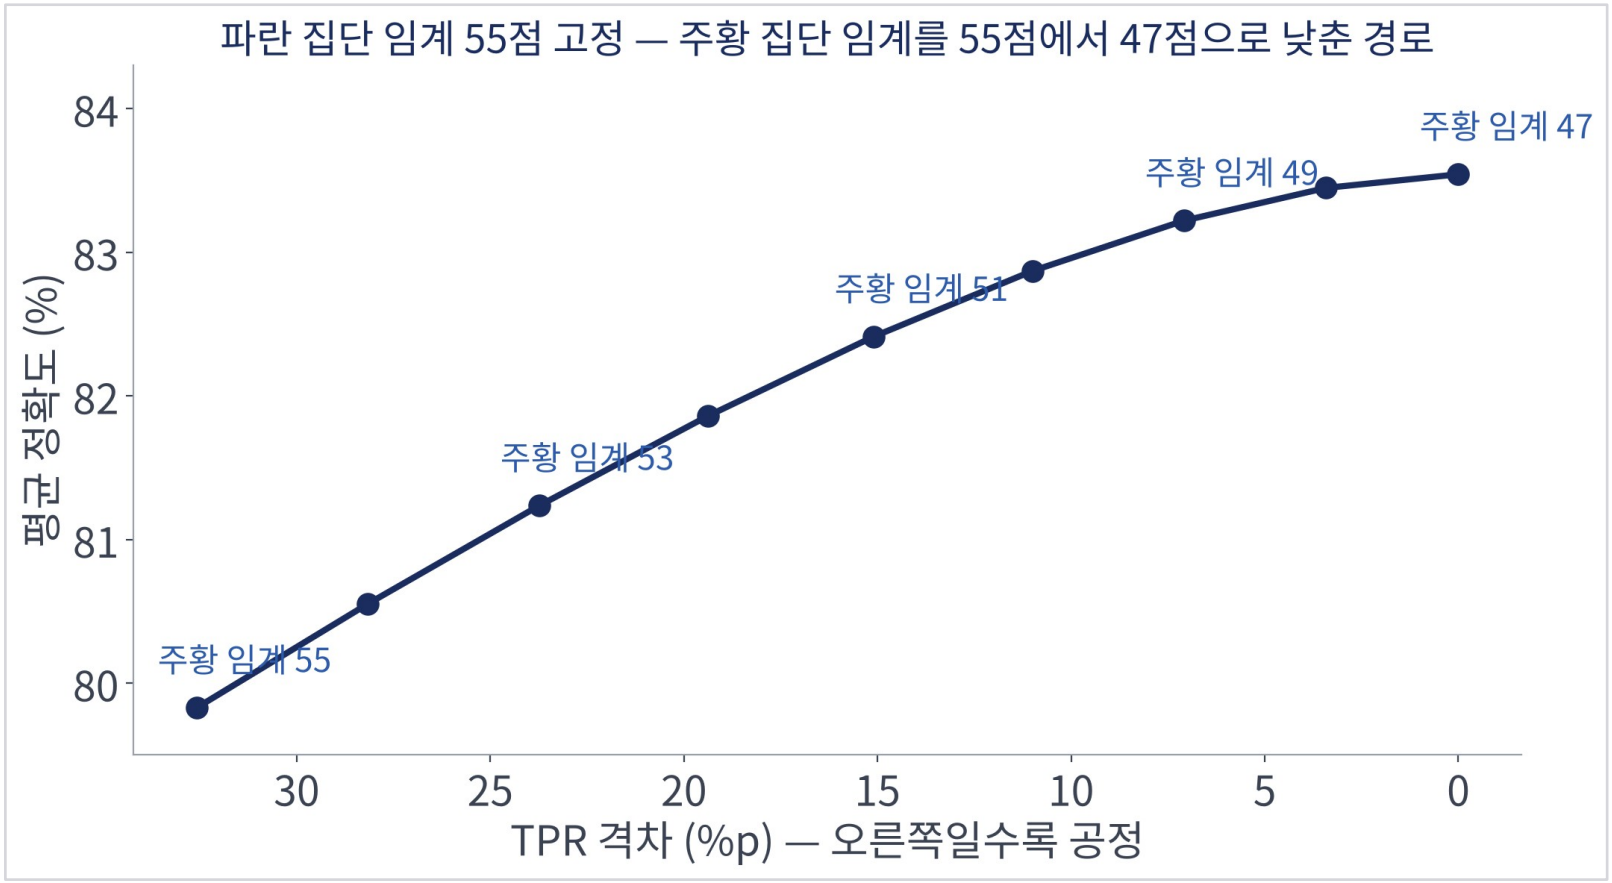


공정성 비용이 늘 있는 것은 아니다

세 정책 비교의 가상 분포에서 주황 집단 임계를 낮추자 TPR 격차가 줄면서 정확도도 올랐다

해석

- 격차 33%p → 0
- 정확도 79.8 → 83.5%
- 단일 기준이 오히려 비효율
- 비용은 실측으로 확인



04

PART 4 · 거버넌스와 규제

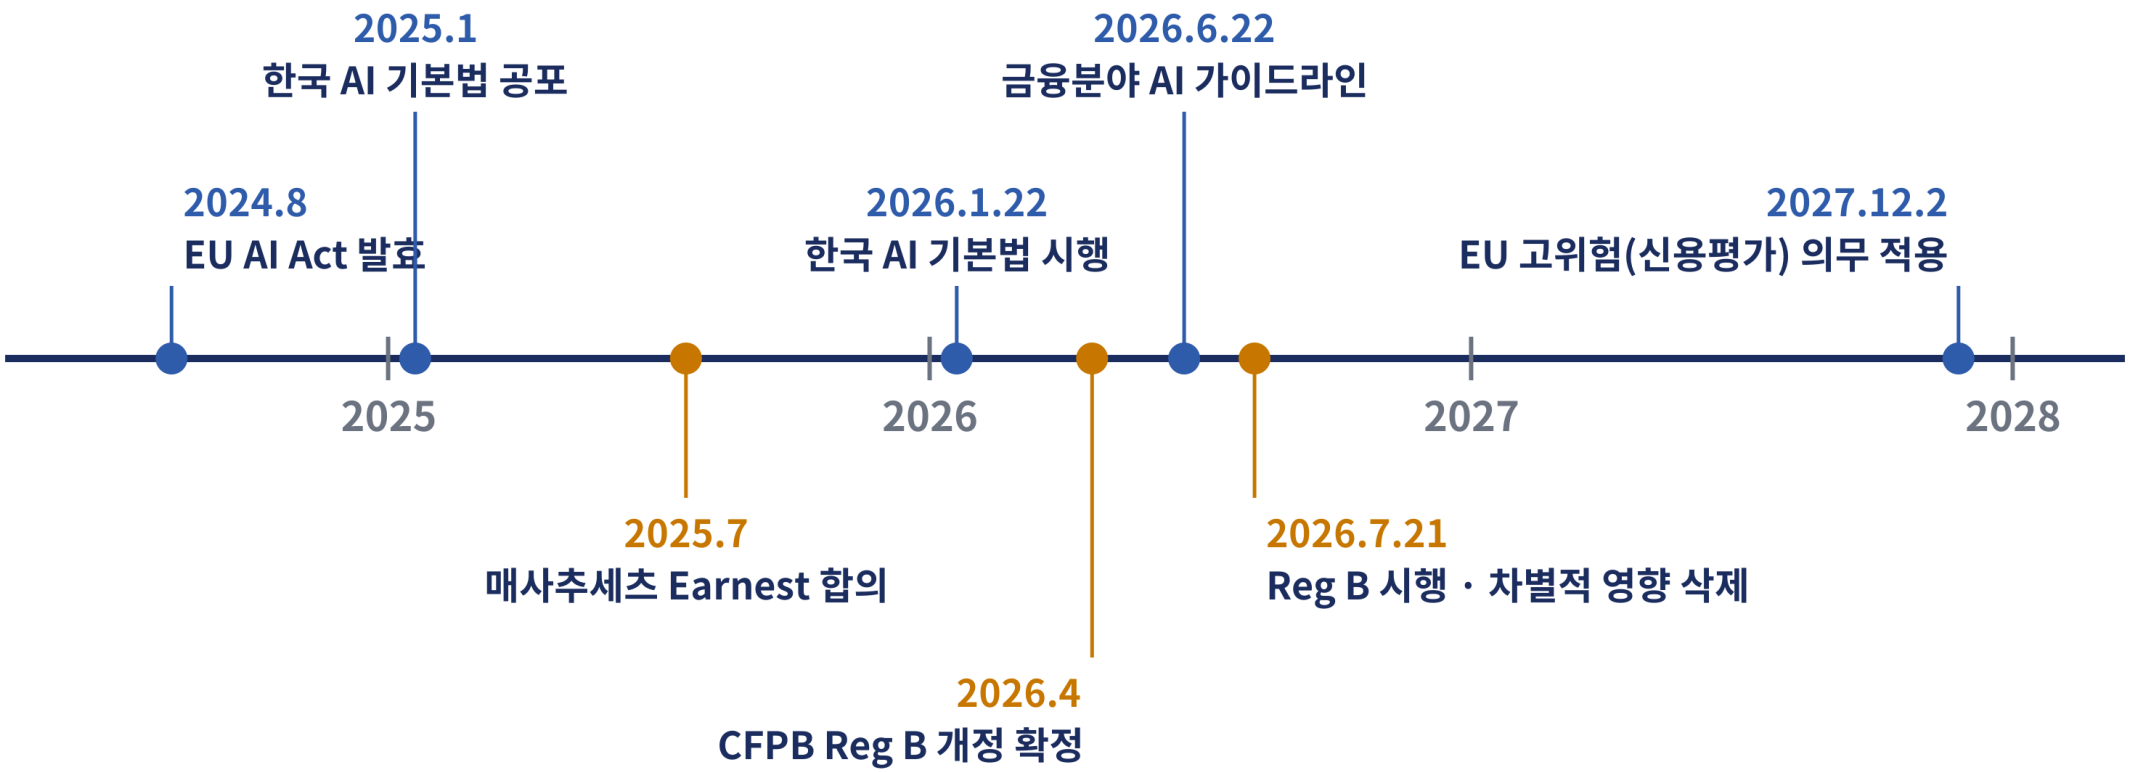
누가 책임지고 무엇을 기록하나

2026년 규제 지형 → 미국의 엇갈린 흐름 → 승인 관문 → 영향평가와 모니터링

2026년 규제는 지역마다 반대 방향으로 움직였다

한국·EU는 기록과 설명 의무를 늘리고, 미국 연방은 차별적 영향 책임을 축소했다 (2026년 10월 기준)

파랑 = 한국 · EU (규율 강화) 주황 = 미국 연방 · 주 (연방 후퇴, 주 강화)



신용평가 AI는 세 관할 모두에서 고위험 영역이다

원전의 EU 과징금(3,000만 유로·6%)은 최종 법률 기준으로 바로잡았다

관할	핵심 규정	공정성 관련 의무
EU	AI Act 부속서 III — 신용평가는 고위험	데이터 편향 관리·문서화·인간 감독, 2027.12.2 적용
한국	AI 기본법(2026.1.22 시행) — 대출 심사는 고영향 AI	위험관리·설명·영향평가 노력, 계도기간 1년 이상
한국 금융	금융분야 AI 가이드라인(2026.6.22)	7대 원칙, AI는 보조수단이고 최종 책임은 임직원
미국	CFPB Reg B 개정(2026.7.21)	ECOA의 차별적 영향 책임 삭제, 의도적 차별만 규율

EU 과징금: 금지 관행 최대 3,500만 유로·매출 7%, 고위험 의무 위반 최대 1,500만 유로·3%.

미국 연방은 물러섰지만 공정대출 위험은 남아 있다

2026년 4월 CFPB 최종 규칙 — 6만 4,500건의 의견 대부분이 반대했고 소송이 제기됐다

연방 차원에서 바뀐 것

- 통계적 결과 격차만으로는 ECOA 위반이 아니다
- 의도적 차별(disparate treatment)만 규율한다

여전히 남은 것

- 주택 대출은 공정주택법(FHA)이 차별적 영향을 인정한다
- 뉴저지·매사추세츠·캘리포니아 등 주법이 강화됐다

업계 조언은 "하던 대로 계속 감사하라(Stay the course)"로 모인다

모델 승인 절차의 모든 관문에 공정성 점검을 넣는다

원전 8시간 커리큘럼의 승인 프로세스와 3선 방어 체계(SR 11-7)를 결합했다

윤리 검토

개발 전

누가 피해를 입을 수 있는가를 먼저 묻는다

공정성 테스트

개발·검증

집단별 TPR·FPR·DI를 사전에 정한 허용치와 비교한다

독립 검증

2선 방어

모형위험관리 조직이 프록시와 가정을 반박한다

승인·배포

고위험은 이사회

인간 개입 경로와 거절 사유 설명을 갖춘다

상시 모니터링

3선·내부감사

격차 지표를 대시보드로 추적하고 재학습을 판단한다

관문마다 집단별 지표와 판단 근거를 남겨야 규제 대응과 내부 감사가 가능하다

영향평가와 거절 사유 설명이 신뢰의 최소 조건이다

원전의 AI 영향평가 7문항과 거절 사유 통지(Adverse Action) 예시다

영향평가 7문항

- 왜 AI가 필요한가?
- 어떤 데이터를 어디서 가져왔나?
- 모형은 어떻게 작동하나?
- 어떤 피해가 가능한가?
- 위험을 어떻게 줄이나?
- 누가 감시하나?
- 이의 제기는 어떻게 하나?

거절 사유 통지 예시

- DTI 45%가 기준 40%를 넘었다
- 신용이력이 2년으로 짧다
- 최근 연체 1회가 있었다
- 부채를 줄이고 6개월 뒤 재신청을 권한다

배포 전 세 개의 적신호를 확인한다

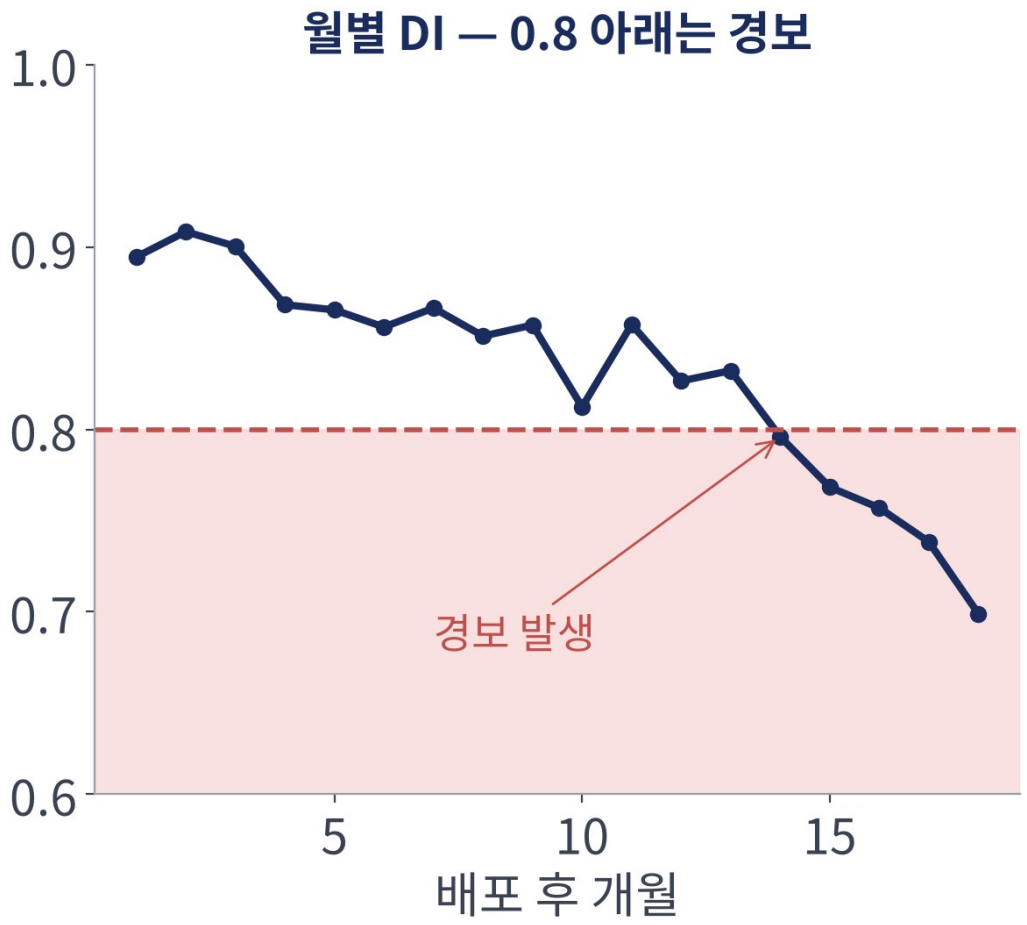
원전 FML 14주차의 배포 관문을 금융 공정성 점검표로 옮겼다

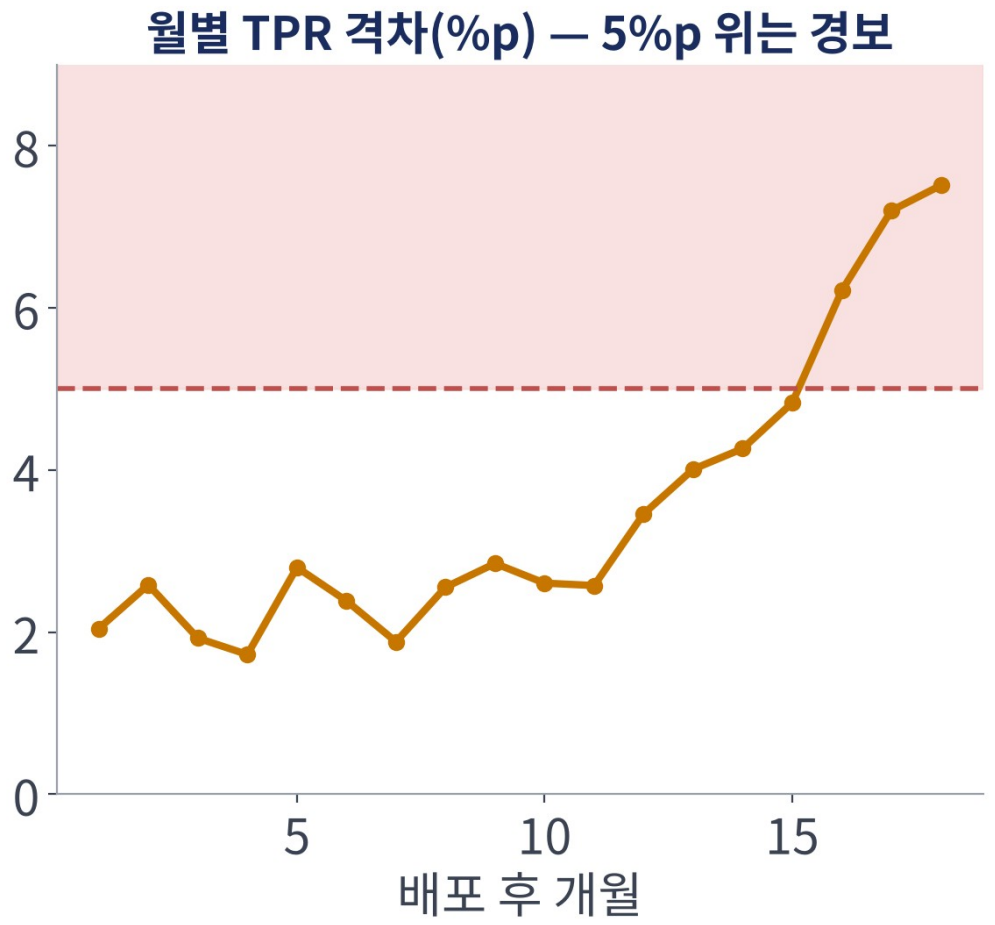
적신호	무엇을 확인하나	발견 시 조치
설명 불가	SHAP으로 결정 요인을 설명할 수 있는가	변수 정리·단순 모형 비교
격차 초과	집단별 TPR·FPR·DI가 허용치 안인가	완화 기법 적용 후 재검증
인과 불명	프록시가 결정을 이끄는지 확인했는가	변수 제거 실험·도메인 검토
분포 변화	배포 후 집단 구성·기저율이 바뀌었는가	PSI 경보·재학습

모델 카드에 두 격차(결과 균등·기회 균등)를 항상 함께 싣고, 허용치는 배포 전에 정한다.

배포 후에는 격차 지표를 월별로 추적한다

예시 데이터 — 신규 고객 유입으로 집단 구성이 바뀌자 DI가 0.8 아래로, TPR 격차가 5%p 위로 넘어갔다





토론 질문

Q1	기저율이 다른 두 집단에 하나의 신용 모형을 쓴다면 어떤 정의를 우선해야 하는가?	**정의 선택**
Q2	보호속성을 수집하지 않으면 격차를 어떻게 측정할 수 있는가?	**측정**
Q3	미국이 차별적 영향 책임을 없앤 뒤에도 한국 금융회사가 감사를 유지할 이유는 무엇인가?	**규제**
Q4	LLM 상담봇이 상품을 추천할 때 노출 공정성은 누가 점검해야 하는가?	**거버넌스**

SUMMARY

공정성은 정의를 고르고 기록하는 일이다

다음 시간: 워크북으로 각 지표를 손으로 계산해 본다

1

속성을 지우는 것이 아니라 결과를 집단별로 잰다

프록시는 늘 존재한다. 감사는 변수 목록이 아니라 승인율·TPR·FPR에서 한다.

2

정의 간 충돌은 수학적 사실이다

기저율이 다르면 보정과 오류율 균등은 함께 성립하지 않는다. 막을 피해를 먼저 정한다.

3

규제가 흔들려도 기록과 설명은 남겨야 한다

EU·한국은 의무를 늘렸고 미국 주법은 강화됐다. 모델 카드와 거절 사유가 방어선이다.

한 줄 요약: "누구의 어떤 오류를 같게 할지" 정하고, 그 선택을 문서로 남긴다

참고 자료

구분	자료
정의·이론	Hardt·Price·Srebro(2016) · Kusner 등(2017) · Dwork 등(2012) · Chouldechova(2017) · Kleinberg 등(2016)
사례	ProPublica(2016) COMPAS 분석 · NYDFS(2021) Apple Card 보고서 · Bickel 등(1975) · Reuters(2018) Amazon · Bertrand·Mullainathan(2004) 이력서 실험
최신 연구	Bowen·Price·Stein·Yang(2025) LLM 모기지 심사 · Singh·Joachims(2018) 노출 공정성
규제	EU 2026/1744(Digital Omnibus) · 인공지능 기본법(2026.1.22) · 금융분야 AI 가이드라인(2026.6) · CFPB Reg B 최종 규칙(2026.4) · 매사추세츠 법무장관(2025.7)