워크북 · 손계산 수치예제

공정성 지표 손계산 워크북

본편 『금융 AI의 공정성』의 계산 과정 모음

계산기 없이 따라갈 수 있는 여덟 문제 — 혼동행렬에서 반사실적 판정까지

본편에서는 결과만 보였다. 여기서는 같은 숫자를 처음부터 다시 센다.
각 문제는 데이터 → 계산 → 해석 순서로 자체 완결되게 구성했다.

혼동행렬부터 세면 숨은 격차가 보인다

FML 14주차 예제 — 두 집단 각 100명, 자격자 80명으로 같고 비자격자 승인은 0명이다

칸	집단 A	집단 B	뜻
TP (자격자 승인)	60	40	기회를 받은 사람
FN (자격자 거절)	20	40	기회를 잃은 사람
TN (비자격자 거절)	20	20	바르게 걸러냄
FP (비자격자 승인)	0	0	손실 없음

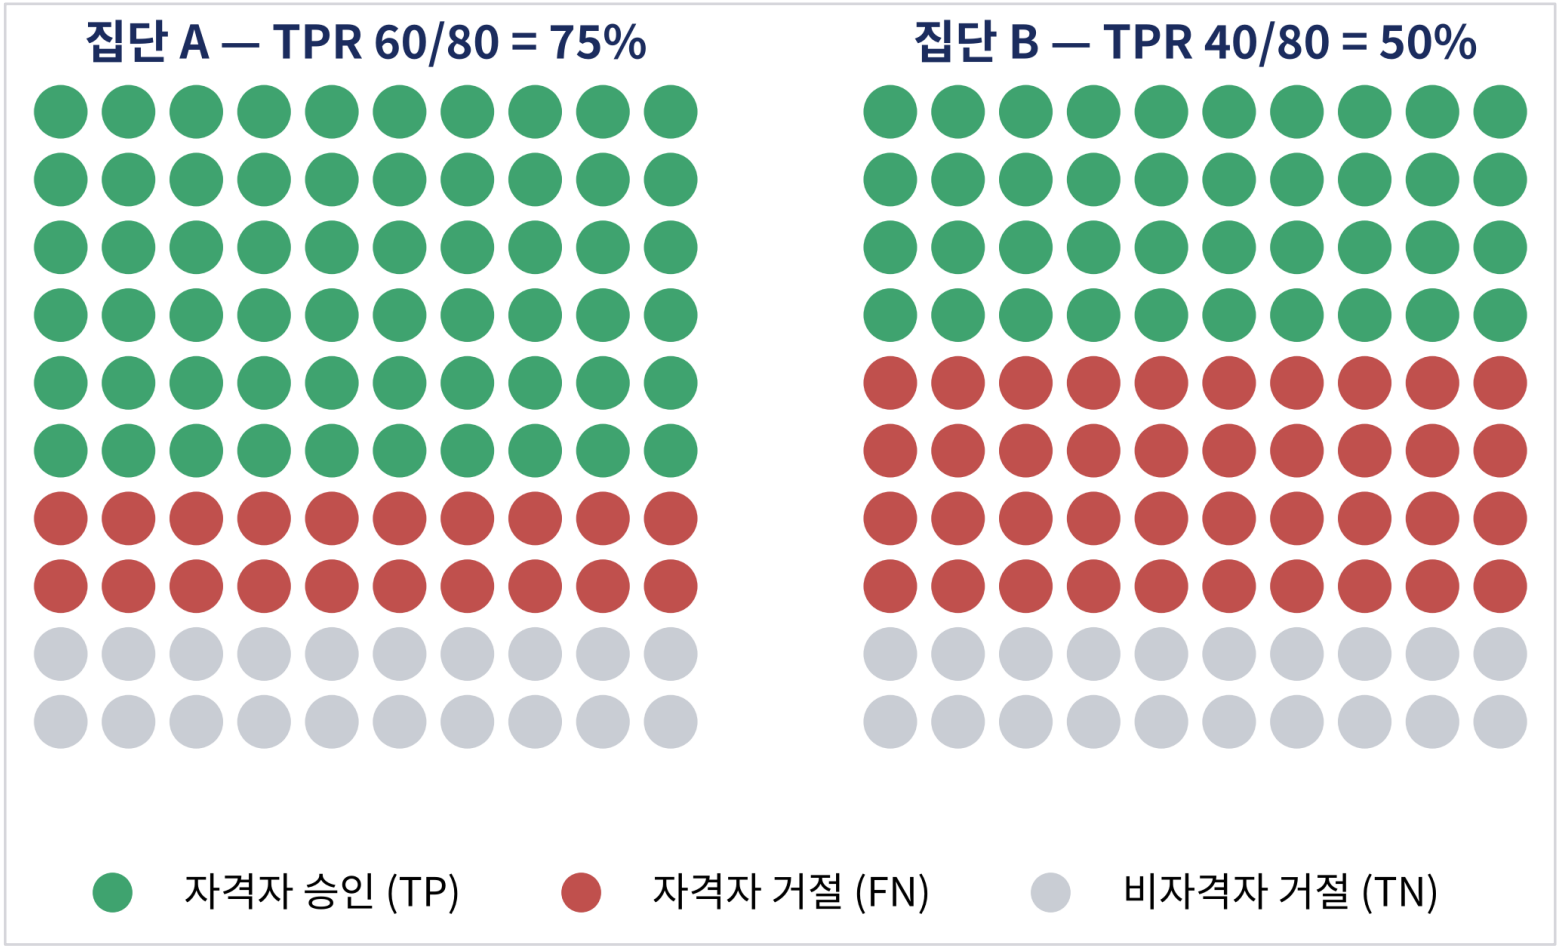
$$\text{집단 A}: \ \mathrm{TPR} = \frac{60}{60+20} = 75\%, \qquad \text{집단 B}: \ \mathrm{TPR} = \frac{40}{40+40} = 50\%$$

표의 숫자를 점 100개로 다시 그린다

초록은 기회를 받은 자격자, 빨강은 기회를 잃은 자격자, 회색은 바르게 거절된 비자격자다

세어 보기

- A 초록 60개
- A 빨강 20개
- B 초록 40개
- B 빨강 40개



평균 정확도 70%는 20%p와 25%p의 격차를 숨긴다

워크북 1의 표에서 승인율·TPR·정확도를 차례로 계산한다

지표	계산식	집단 A	집단 B	격차
승인율	(TP+FP) ÷ 100	60%	40%	20%p (결과 균등)
TPR	TP ÷ (TP+FN)	75%	50%	25%p (기회 균등)
정확도	(TP+TN) ÷ 100	80%	60%	20%p
합친 정확도	(80+60) ÷ 200	70%		

해석

- 오탐이 0건이라 '신중한' 모형처럼 보이지만, 같은 자격의 B 집단은 기회를 절반만 받는다.

남성 70%·여성 50% 승인은 4/5 규칙을 통과하지 못한다

원전 예 — 남성 1,000명 중 700명, 여성 800명 중 400명 승인

$$\mathrm{DI} = \frac{400/800}{700/1000} = \frac{0.50}{0.70} = 0.714 < 0.8$$

단계	계산	결과
① 승인율	700/1,000 · 400/800	70% · 50%
② SPD	50% − 70%	−0.20
③ 두 집단을 60%로	남성 600명 · 여성 480명	남성 100명 감소, 여성 80명 증가

결과 균등으로 맞추려면 자격과 무관하게 남성 100명을 거절하고 여성 80명을 더 승인해야 한다.

기회 균등을 맞춰도 승인율 격차는 남는다

원전 예 — 남녀 각 1,000명, 자격자는 남성 700명·여성 500명, 두 집단 TPR 90%

항목	남성	여성
자격자 중 승인 (TPR 90%)	700 × 0.9 = 630	500 × 0.9 = 450
전체 승인율	63%	45%
DI		45 ÷ 63 = 0.71

해석

- 기회 균등은 자격이 같은 사람끼리의 공정이다. 자격자 비율이 다르면 승인율은 자연히 갈린다.
- 두 기준을 동시에 요구하면 어느 한쪽을 포기해야 한다.

근본적 공정은 비자격자 승인 수까지 맞춘다

원전 예 — 남성 상환 700·연체 300, 여성 상환 600·연체 400, TPR 90%·FPR 20%

항목	남성	여성
상환자 승인 (TPR 90%)	700 × 0.9 = 630	600 × 0.9 = 540
연체자 승인 (FPR 20%)	300 × 0.2 = 60	400 × 0.2 = 80
총 승인	690명 (69%)	620명 (62%)
승인자 중 상환 (PPV)	630 ÷ 690 = 91.3%	540 ÷ 620 = 87.1%

TPR·FPR을 같게 해도 PPV는 91.3% 대 87.1%로 갈린다. 다음 문제가 이 현상의 일반 원리다.

PPV와 FNR을 맞추면 FPR이 네 배 차이 난다

각 1,000명, 기저율 A 50%·B 20%, 두 집단 모두 PPV 80%·FNR 20%로 맞춘다

$$\mathrm{FPR}_A = \frac{0.5}{0.5} \cdot \frac{0.2}{0.8} \cdot 0.8 = 0.20, \qquad \mathrm{FPR}_B = \frac{0.2}{0.8} \cdot \frac{0.2}{0.8} \cdot 0.8 = 0.05$$

항목	집단 A (양성 500)	집단 B (양성 200)
TP = 양성 × (1−FNR)	400	160
FP = TP × (1−PPV)/PPV	100	40
FPR = FP ÷ 음성	100 ÷ 500 = 20%	40 ÷ 800 = 5%

직접 센 결과가 식과 일치한다. 기저율이 다르면 세 지표를 모두 같게 할 방법은 없다.

학과별로는 공정해도 합치면 격차가 생긴다

버클리 1973년 6개 주요 학과 지원자 — 남성 2,691명, 여성 1,835명(Bickel 등 1975)

학과	남성 지원 · 합격률	여성 지원 · 합격률	차이
A	825명 · 62%	108명 · 82%	여성 +20%p
B	560명 · 63%	25명 · 68%	여성 +5%p
C	325명 · 37%	593명 · 34%	남성 +3%p
E	191명 · 28%	393명 · 24%	남성 +4%p
6개 학과 합계	약 1,198명 합격 · 44.5%	약 557명 합격 · 30.3%	남성 +14%p

여성은 합격률이 낮은 C·E학과에, 남성은 높은 A·B학과에 몰렸다. 학과 선택이 집계 격차를 만든다.

재가중은 집단별 상환 비율을 같게 보이도록 만든다

1,000명 — A 600명(상환 420), B 400명(상환 200). 전체 상환 비율 62%

$$w_{A,1} = \frac{0.6 \times 0.62}{0.42} = 0.886 \qquad w_{B,1} = \frac{0.4 \times 0.62}{0.20} = 1.24$$

칸	원래 인원	가중치	가중 인원
A · 상환	420	0.886	372
A · 연체	180	1.267	228
B · 상환	200	1.240	248
B · 연체	200	0.760	152

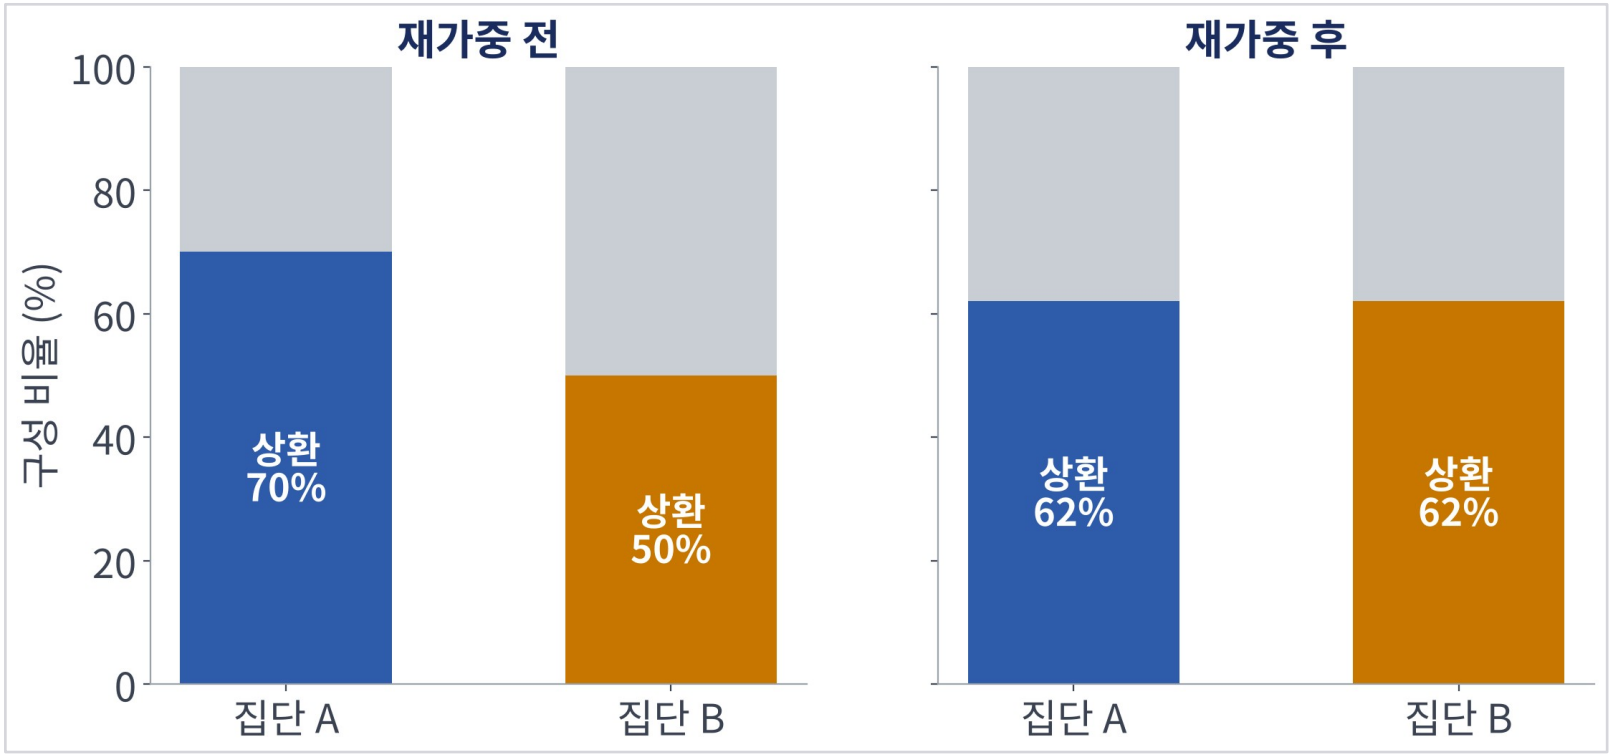
가중 후 A는 372 ÷ 600, B는 248 ÷ 400으로 두 집단 모두 상환 비율 62%가 된다.

가중 전후의 상환 비율을 막대로 비교한다

인원은 그대로 두고 학습에서 각 칸의 무게만 바꾼다

확인

- A 70% → 62%
- B 50% → 62%
- 전체 62% 유지



반사실적 계산은 같은 능력으로 속성만 바꿔 다시 판정한다

가상의 인과 모형 — 보호속성 A=1이면 소득이 1만큼 낮게 형성된다. U는 관측되지 않는 능력이다

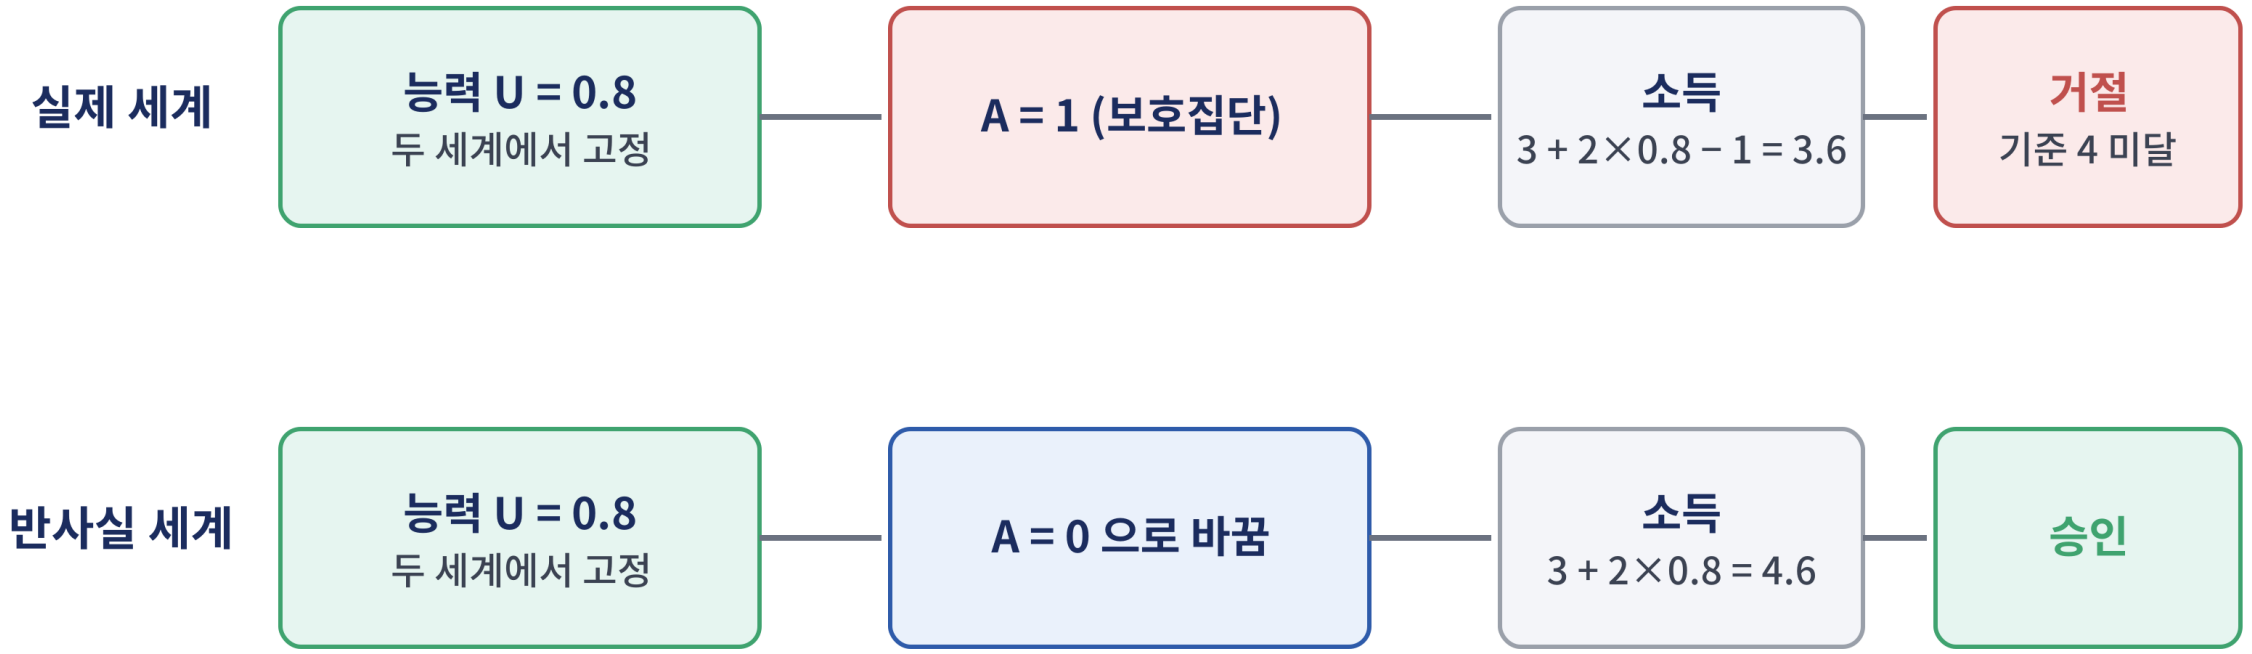
$$\text{소득} = 3 + 2U - 1 \cdot A, \qquad \text{승인} \iff \text{소득} \geq 4$$

단계	신청자 갑 (A=1)	신청자 을 (A=1)
관측 소득	4.5 → 승인	3.6 → 거절
능력 역산 U=(소득−3+1)/2	1.25	0.80
A=0이었다면 소득	3+2.5 = 5.5 → 승인	3+1.6 = 4.6 → 승인
판정	반사실적으로 공정	반사실적으로 불공정

을은 같은 능력으로 다른 집단에 속했다면 승인됐다. 이 경우 인간 재심 대상으로 넘긴다.

신청자 을의 두 세계를 나란히 놓는다

U는 0.8로 고정한 채 A만 1에서 0으로 바꾸자 소득이 3.6에서 4.6으로 오르고 결정이 뒤집혔다



같은 사람(U 고정)인데 속성만 바꾸자 결정이 뒤집혔다 → 반사실적으로 불공정, 인간 재심 대상

여덟 문제의 핵심 숫자

문제	핵심 결과	배운 점
1 혼동행렬	격차 20%p · 25%p, 평균 70%	집단별로 재야 보인다
2 DI	0.714	4/5 규칙 미달
3 기회 균등	승인율 63% 대 45%	기회 균등 ≠ 결과 균등
4 근본적 공정	PPV 91.3% 대 87.1%	오류율 균등 ≠ 예측 동등
5 불가능성	FPR 20% 대 5%	기저율이 다르면 충돌
6 심슨 역설	44.5% 대 30.3%	집계가 격차를 만든다
7 재가중	두 집단 62%	데이터 단계 완화
8 반사실	을만 판정이 바뀜	개인 단위 점검