설명 가능한 머신러닝

SHAP과 섀플리 값

모형의 예측을 특성별 기여도로 읽기

섀플리 값(Shapley value) · SHAP(SHapley Additive exPlanations)

게임이론의 공정 분배 규칙에서 신용평가 모형의 SHAP 플롯 아홉 가지까지.

섀플리 값

SHAP은 노벨상 수상자의 공정 분배 규칙에서 나왔다

Lloyd Shapley(1923–2016), 미국의 수학자이자 게임이론가

1953

함께 번 보수를 나누는 규칙인 섀플리 값을 제안

2012

안정적 배분과 시장 설계로 Alvin Roth와 노벨 경제학상 수상

2017

Lundberg와 Lee가 이를 ML 모형 설명 도구인 SHAP으로 발전

핵심 질문: 함께 낸 결과에서 각 기여자는 얼마를 받는 것이 공정한가?

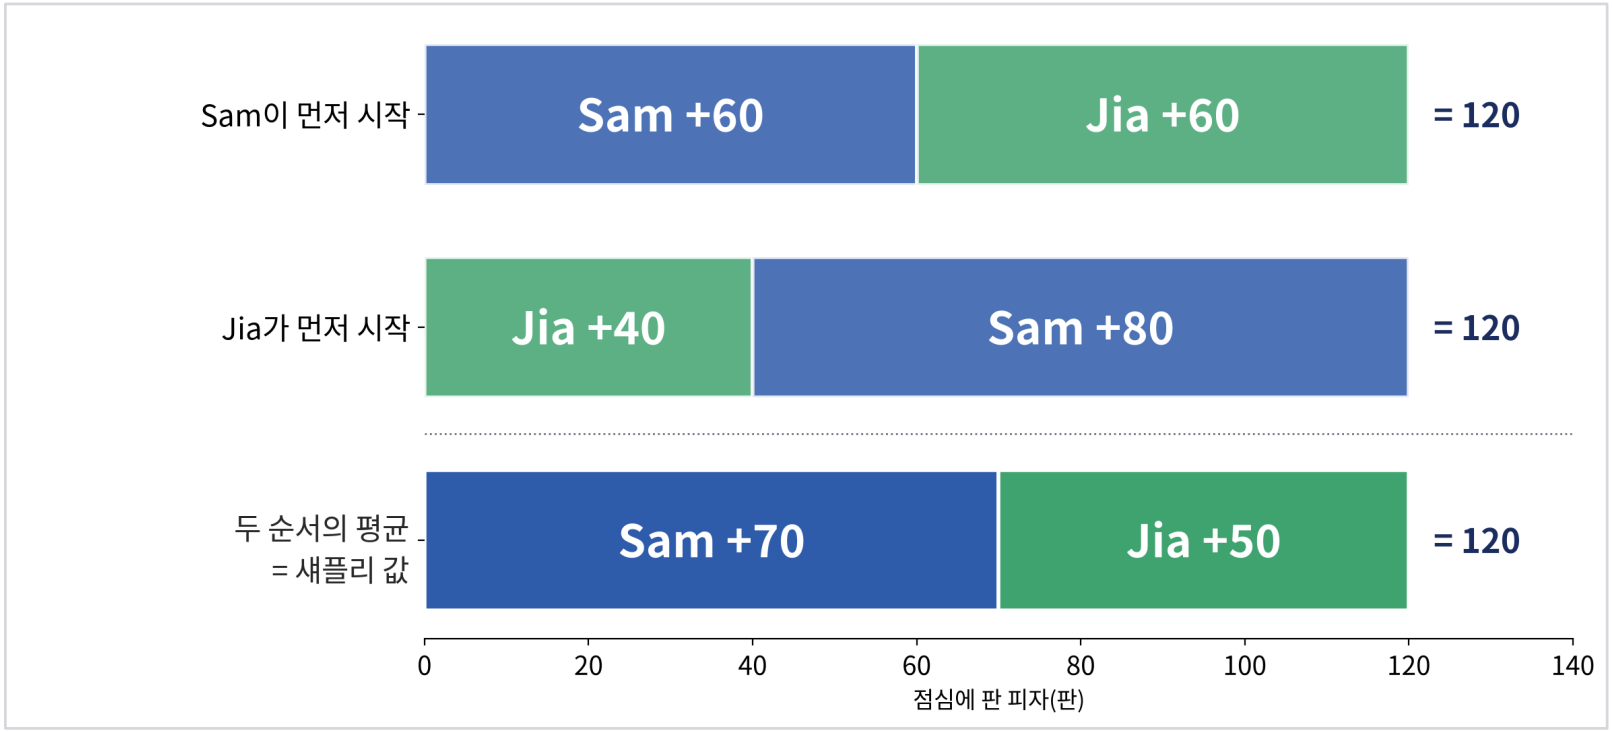
예제

각자의 몫은 두 가지 시작 순서의 평균이다

피자 가게: Sam 혼자 60판, Jia 혼자 40판, 둘이 함께 120판을 판다

읽는 법

- 함께하면 20판을 더 판다
- 나중에 합류한 쪽이 그 몫을 가져간다
- 평균하면 반씩 나뉜다
- 몫의 합은 정확히 120



특성은 직원, 예측값은 매출 역할을 한다

같은 규칙을 신용점수 모형에 적용하면 고객마다 특성별 몫이 나온다

피자 가게	신용점수 모형(SHAP)
직원(Sam, Jia)	특성(소득, 부채비율, 연체 …)
아무도 일하지 않음: 0판	특성 정보가 없을 때의 평균 예측: 592.7
함께: 120판	고객 B의 예측값: 520
몫: 70과 50	특성별 SHAP 값(연체 −57.2 …)
몫의 합은 120	SHAP 값의 합은 520 − 592.7 = −72.7

평균 예측에서 출발해 특성별 몫을 더하면 그 고객의 예측값이 된다

합성 데이터에 심어 둔 정답으로 SHAP의 해석을 검증한다

합성 고객 3,000명 · 목표 변수: 신용점수(300–900) · XGBoost 회귀 · TreeSHAP

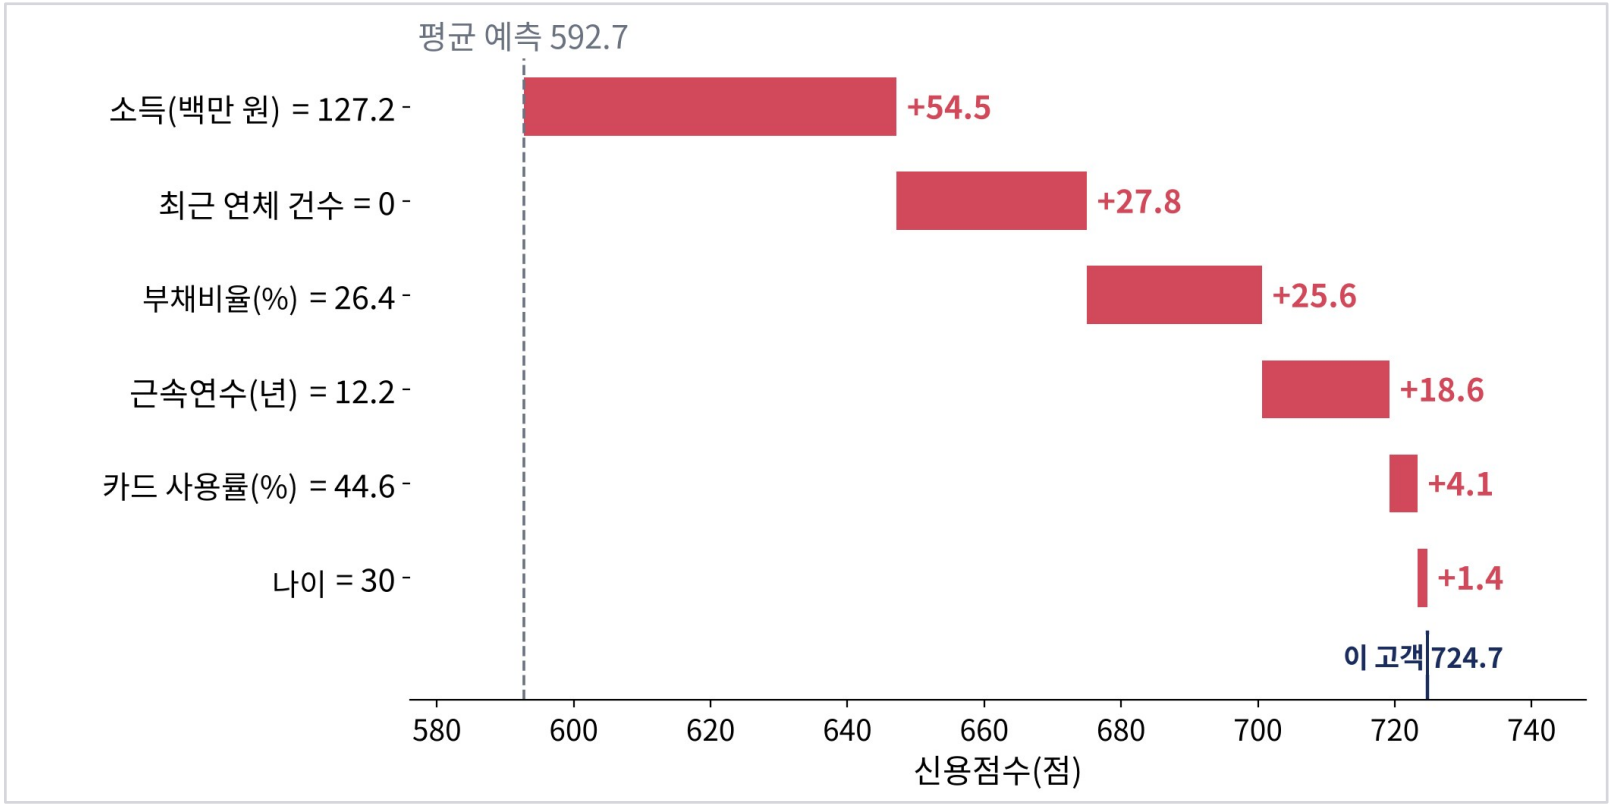
특성	범위	데이터에 심어 둔 관계
최근 연체 건수	0–6	건마다 큰 감점; 카드 사용률 감점도 가파르게 만든다
부채비율(%)	5–140%	감점이 커지고, 70% 위에서 더 가파르다
소득(백만 원)	15–200	가점이 커지되 증가폭은 줄어든다
카드 사용률(%)	0–100%	높을수록 감점
근속연수(년)	0–30	10년까지 가점, 그 뒤로는 평탄
나이	22–65	관계 없음(대조군)

고객 A: 다섯 특성이 모두 점수를 올렸다

워터폴 플롯 — 평균 592.7에서 예측값 724.7까지의 단계

읽는 법

- 점선: 출발점
- 빨강은 더하고, 파랑은 뺀다
- 막대 길이 = 몫
- 높은 소득: +54.5

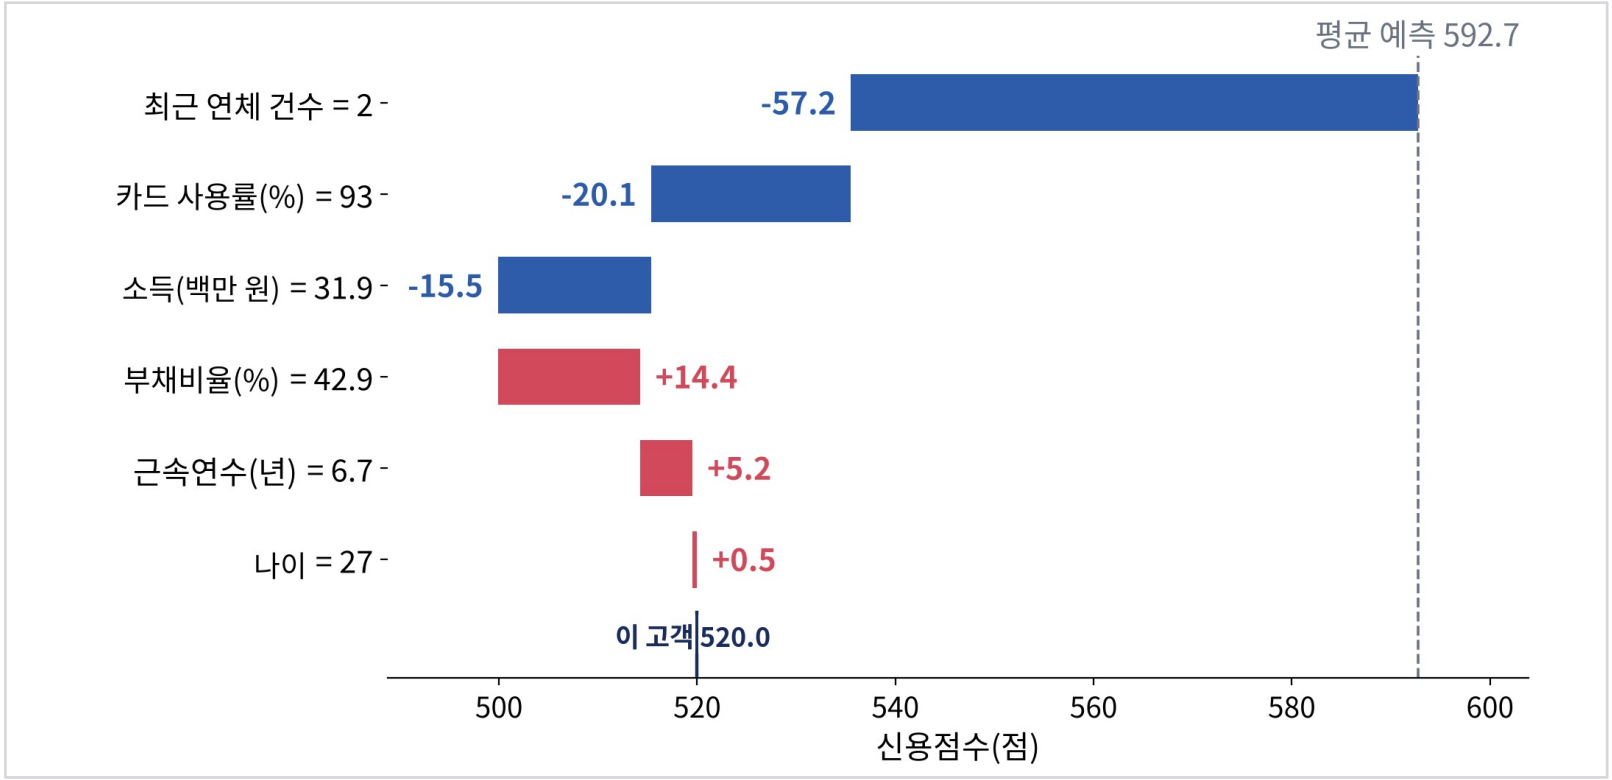


고객 B의 낮은 점수는 대부분 연체로 설명된다

예측값 520.0 = 평균 592.7 − 72.7

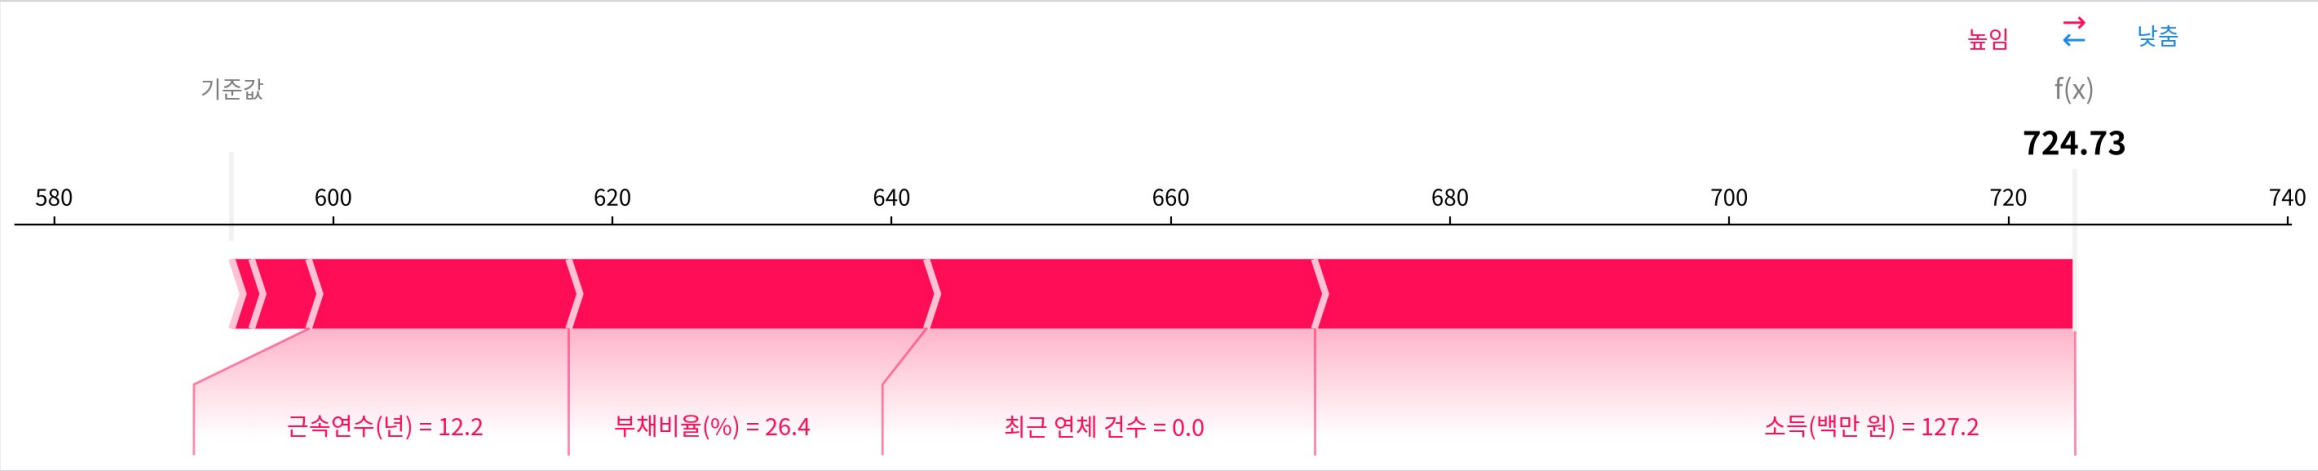
핵심 결과

- 연체 2건: −57.2
- 카드 사용 93%: −20.1
- 부채비율은 점수를 더한다
- 합계 정확히 −72.7



포스 플롯은 워터폴을 한 줄로 누른 것이다

포스 플롯 — 고객 A; 기준값(base value)은 평균 예측, f(x)는 이 고객의 예측값



읽는 법

- 빨간 화살표는 점수를 올린다
- 화살표가 넓을수록 기여가 크다

쓰는 경우

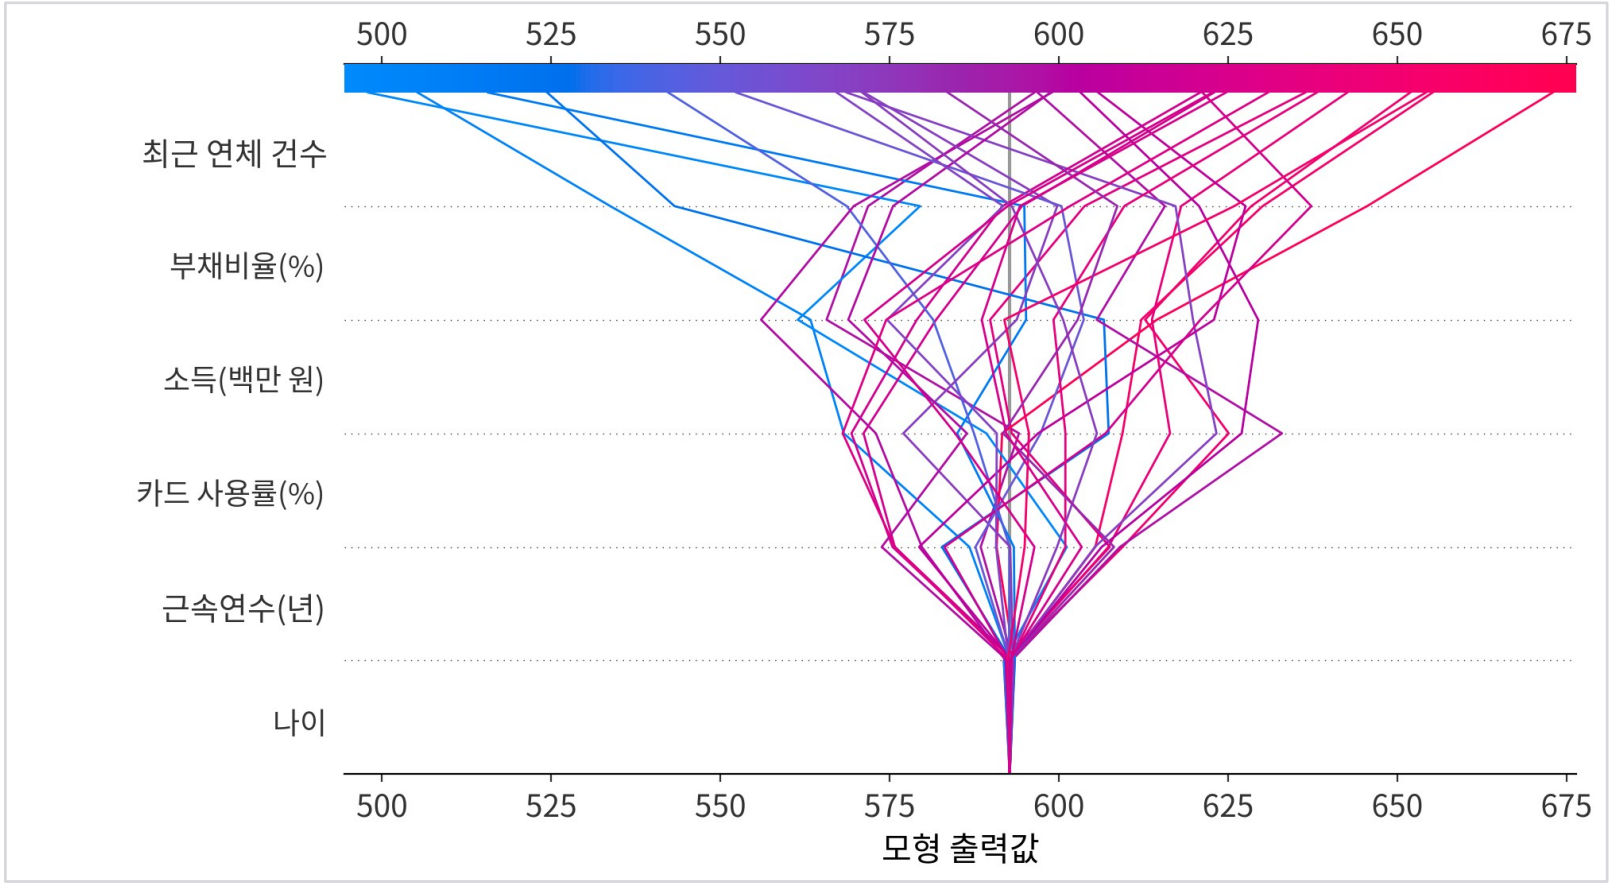
- 보고서 한 줄에 들어간다
- 세로로 쌓으면 여러 사례를 보여 준다

디시전 플롯은 여러 고객의 경로를 겹쳐 그린다

디시전 플롯 — 고객 30명, 아래에서 위로 특성을 하나씩 더한다

읽는 법

- 평균에서 출발
- 기여가 누적된다
- 위쪽 끝 = 예측값
- 연체에서 경로가 갈린다

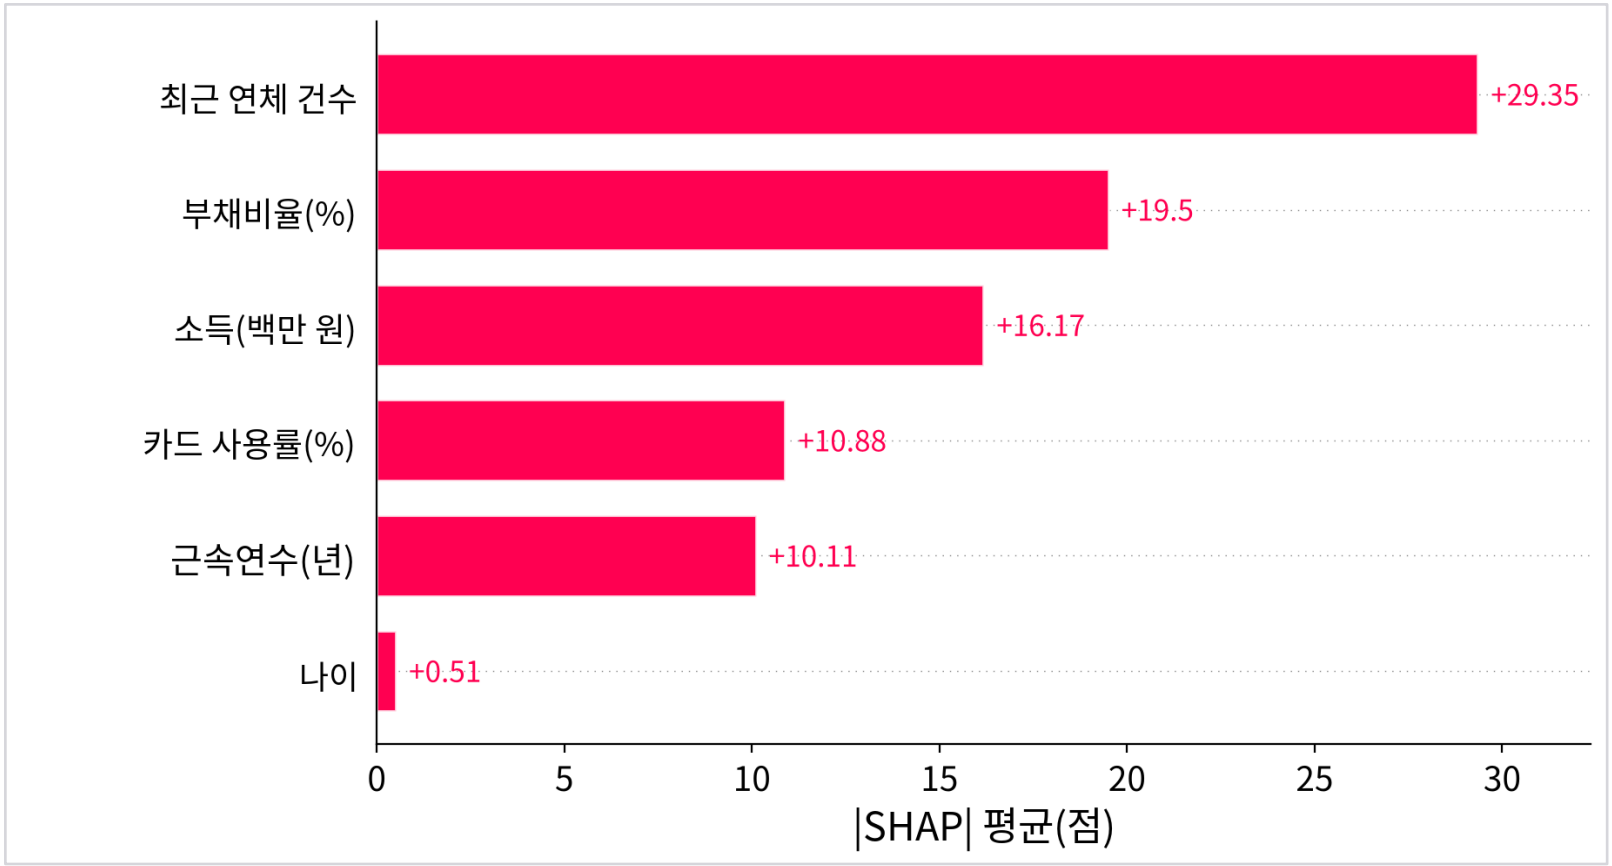


모형 전체로는 연체가 가장 중요하다

막대 플롯 — 고객 3,000명의 SHAP 절댓값 평균

읽는 법

- |SHAP| 평균 = 영향력
- 방향은 보이지 않는다
- 나이: 0.5, 무관
- 심어 둔 순서와 일치

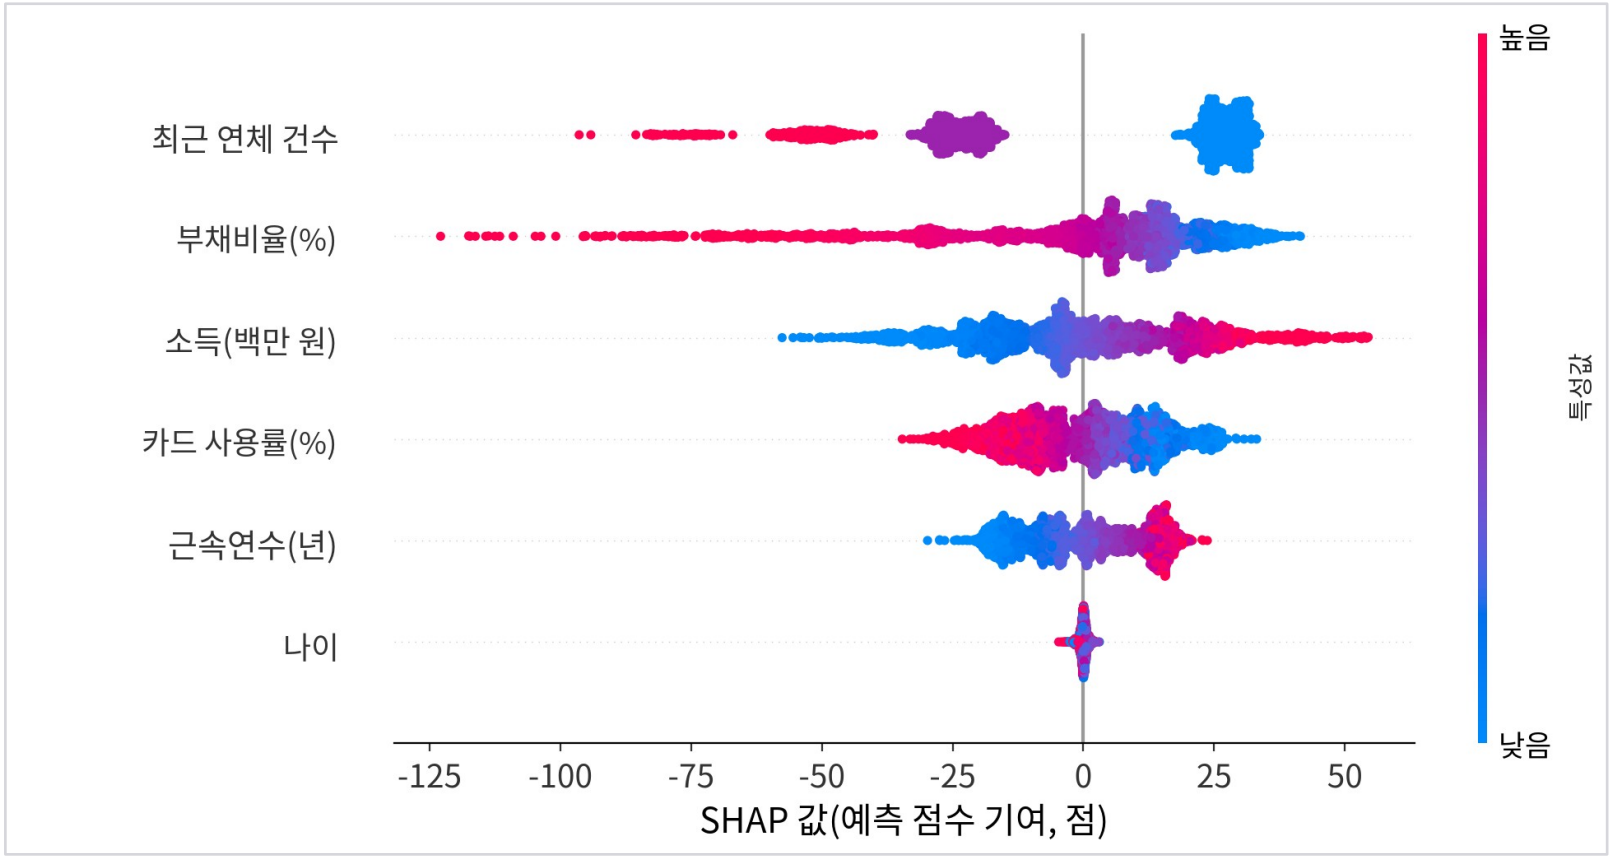


비스웜 플롯은 영향의 크기와 방향을 보여 준다

비스웜 플롯 — 점 하나가 고객 한 명, 색은 특성값

읽는 법

- 가로 위치 = SHAP
- 빨강 = 높은 값
- 왼쪽의 빨강 = 감점
- 넓게 퍼질수록 = 영향력

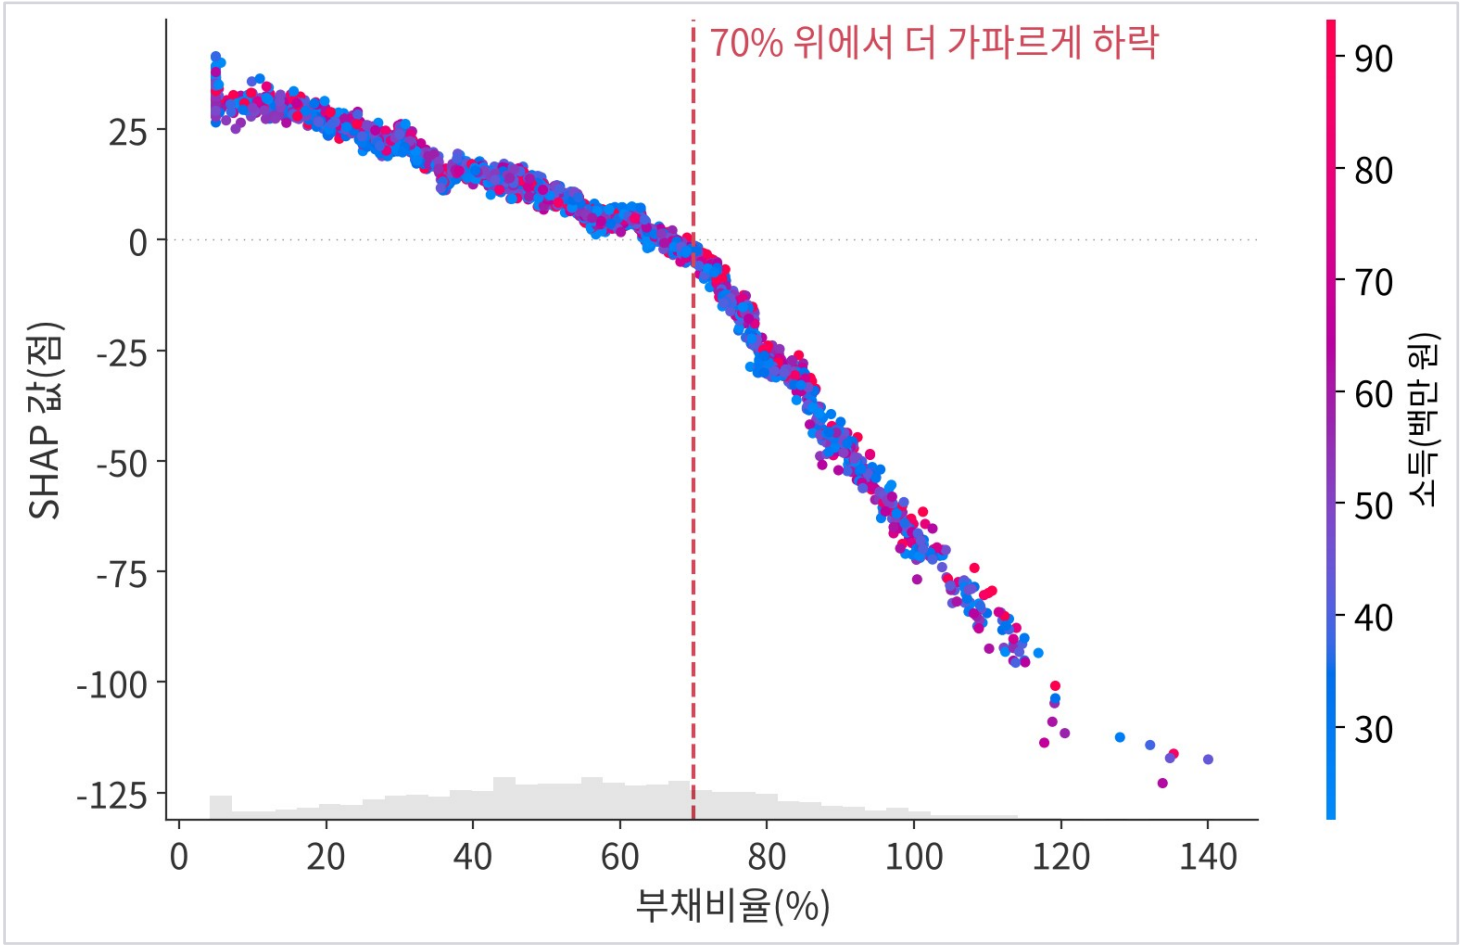


의존성 플롯이 부채비율 70%의 꺾임을 찾아낸다

의존성 산점도 — x는 부채비율, y는 그 SHAP 값

핵심 결과

- 70% 아래는 완만한 감점
- 그 위는 가파른 감점
- 선형 모형은 이를 놓친다
- 회색 막대: 분포

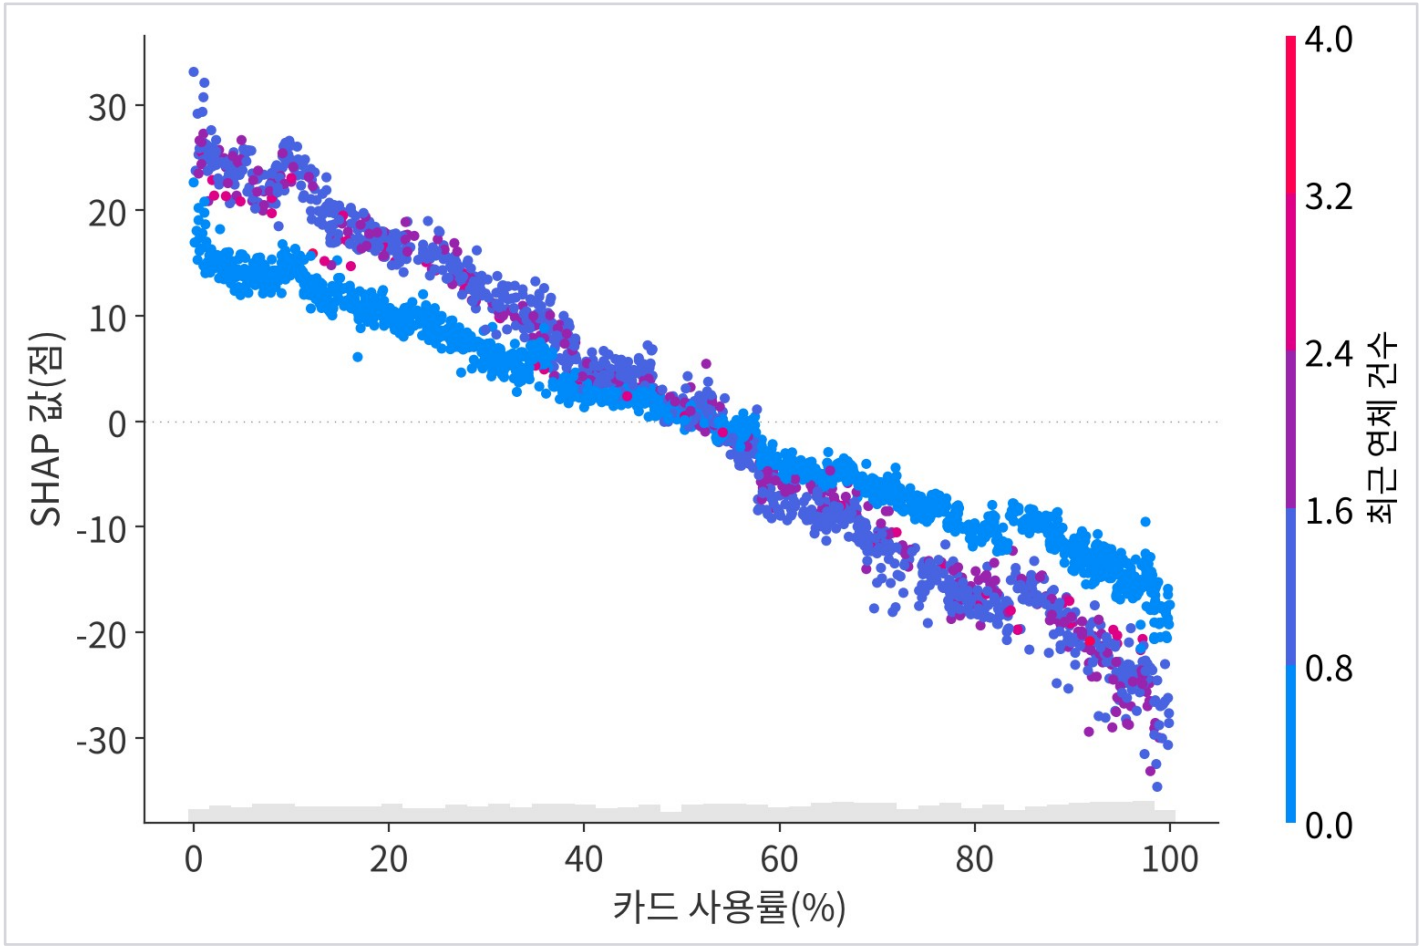


연체가 카드 사용률 감점을 가파르게 만든다

같은 산점도를 연체 건수로 색칠 — 색이 갈리면 상호작용 신호

핵심 결과

- 파랑(0)은 더 완만
- 보라/빨강은 더 가파름
- 두 띠로 갈라진다
- 심어 둔 효과를 찾았다

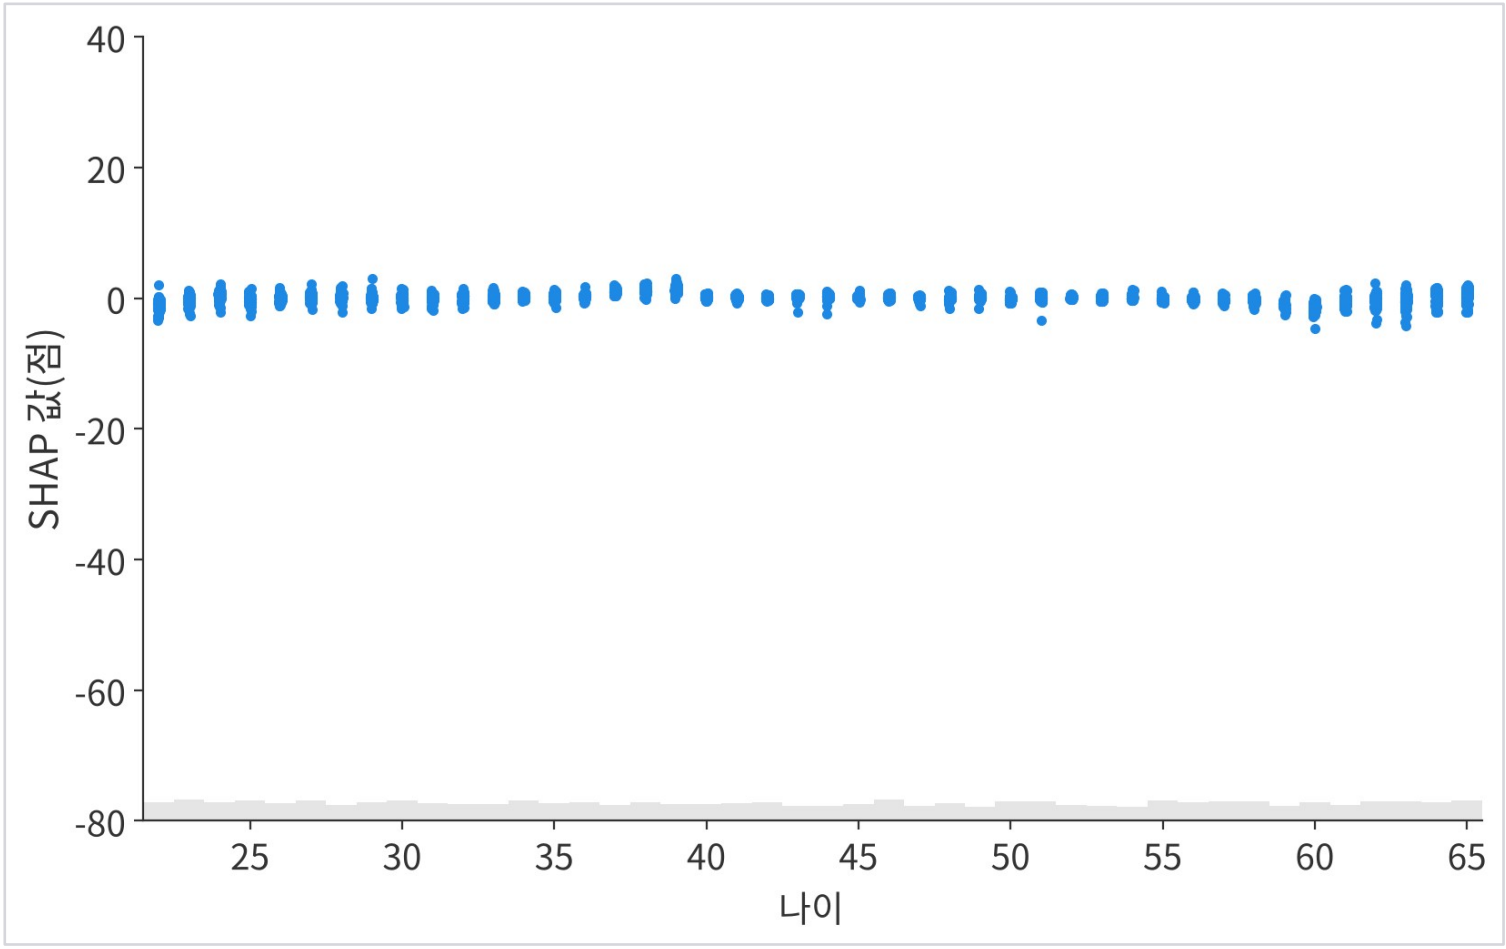


효과를 심지 않은 나이는 0 근처에 머문다

비교를 위해 y축 범위를 다른 플롯과 비슷하게 맞췄다

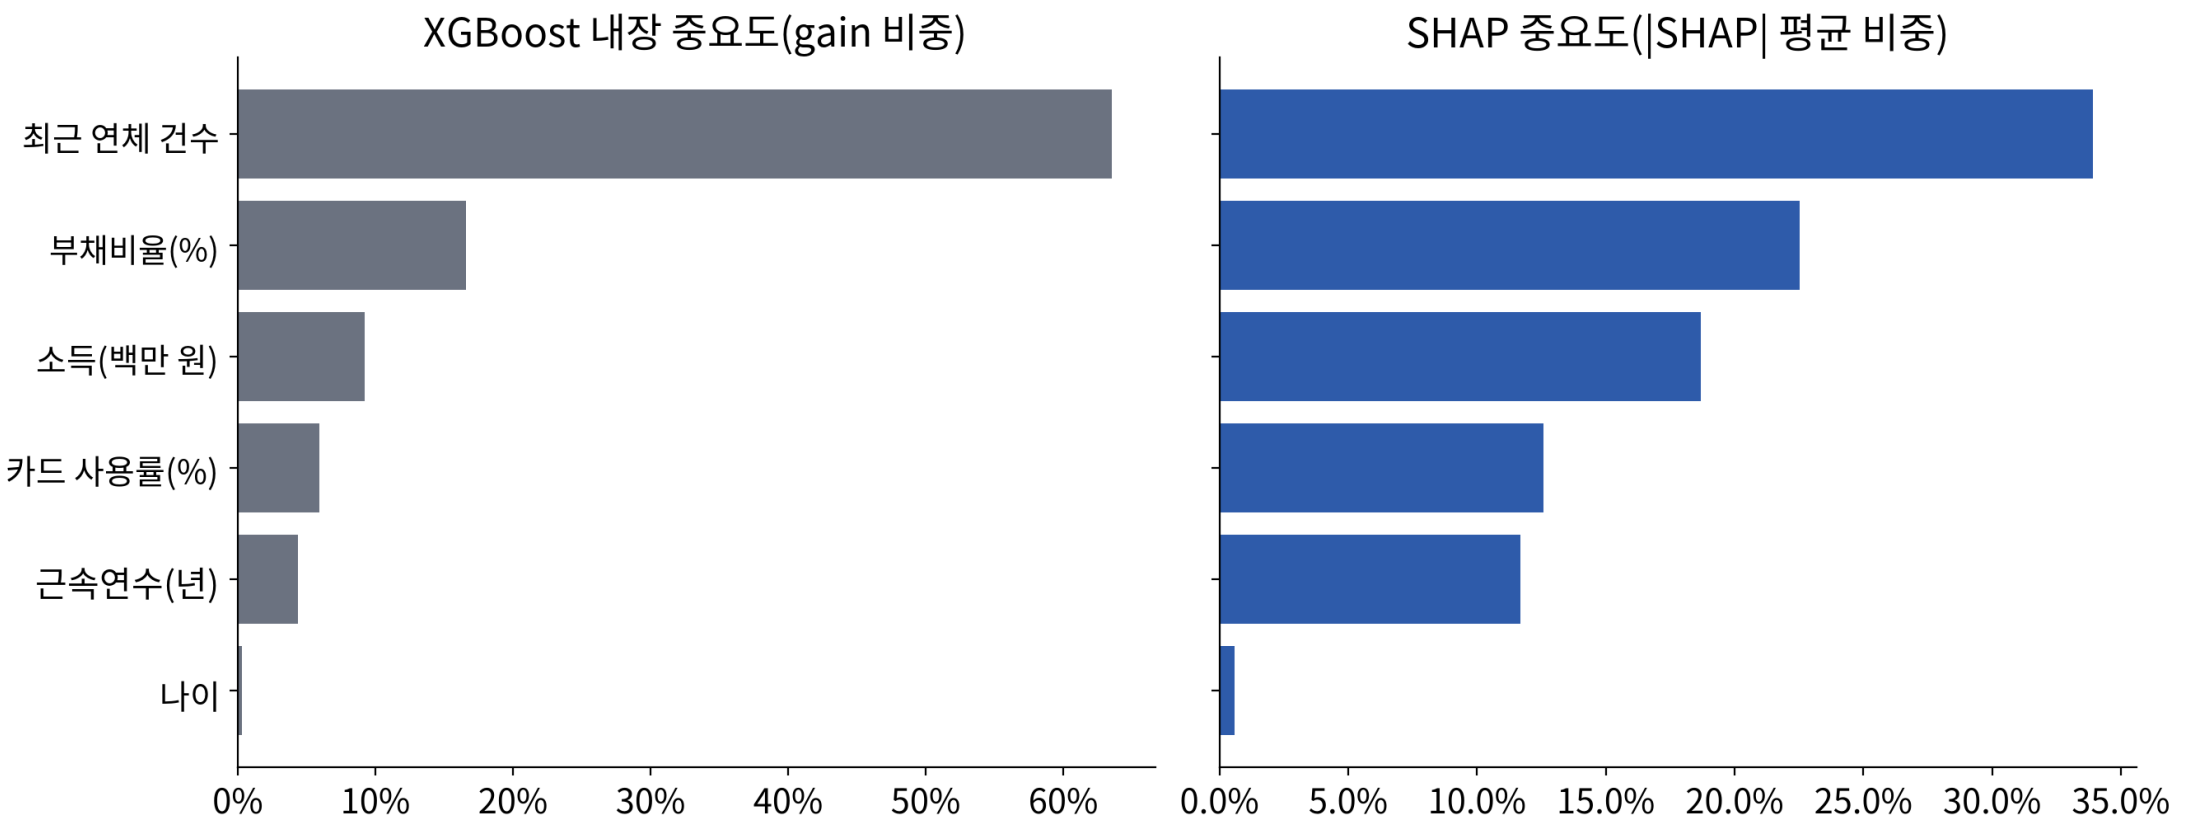
핵심 결과

- 잡음은 ±2 이내
- 효과가 없으면 몫도 없다
- 유용한 기준 점검



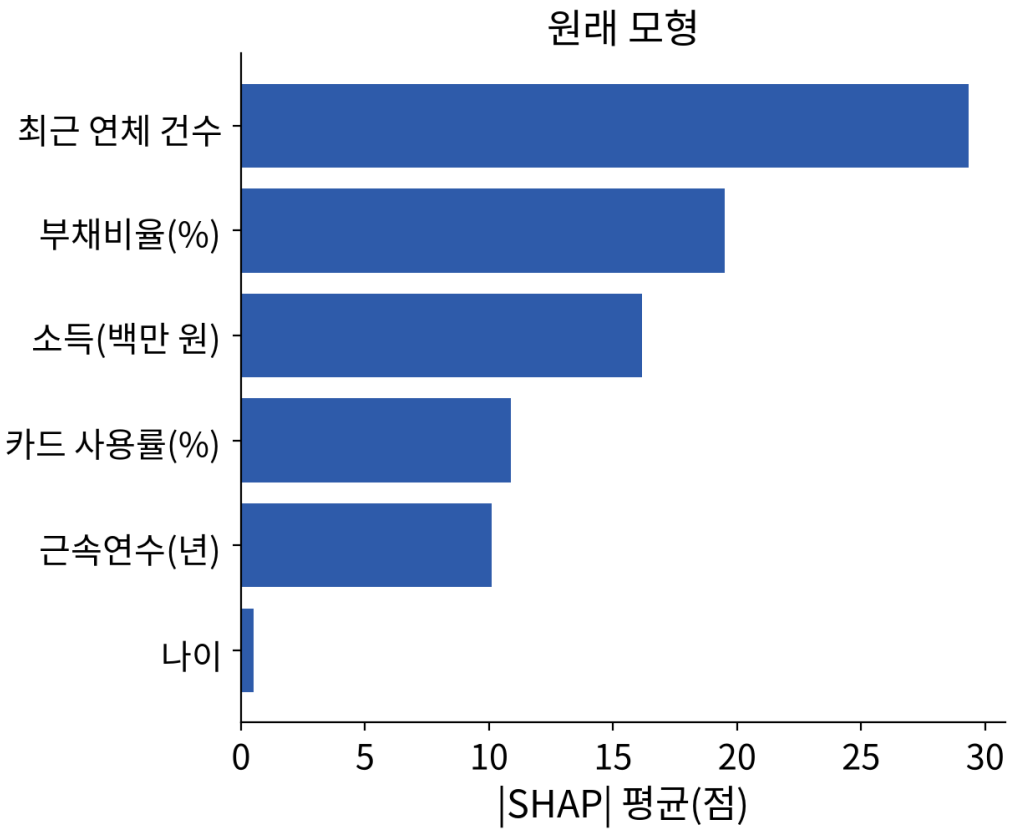
트리의 gain 중요도는 연체를 과대평가한다

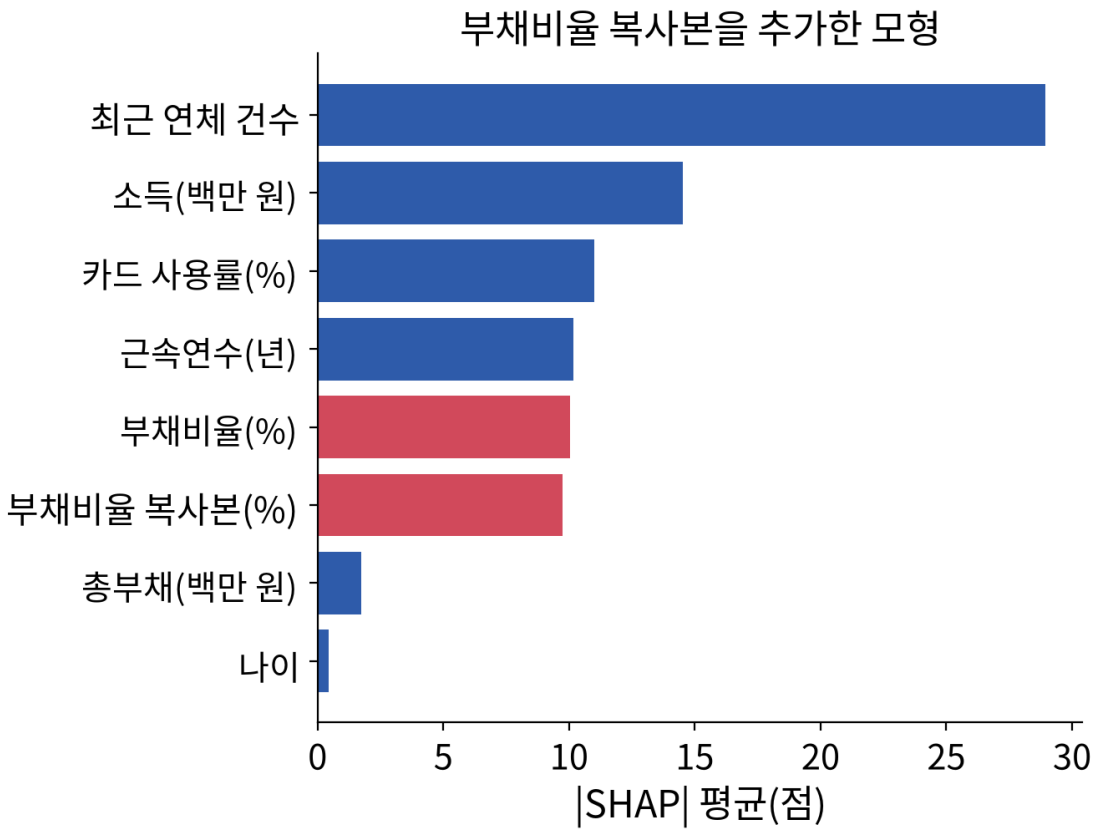
XGBoost gain은 연체에 63%를 주지만, SHAP은 34%를 주고 다른 특성의 몫도 보여 준다



거의 같은 특성은 SHAP 몫을 반씩 나눈다

부채비율에 잡음을 섞은 복사본을 넣고 재학습 — 19.5점이 10.0과 9.8로 나뉜다





주의

SHAP은 인과가 아니라 모형의 습관을 보여 준다

결과 해석의 세 가지 규칙

인과가 아니다

모형이 어떻게 계산하는지일 뿐

카드 사용률이 낮다고 상환 능력이 좋다는 증거는 아니다.
SHAP은 모형이 특성을 어떻게 쓰는지 설명한다.

"원인"이 아니라 "사유"

상관된 특성은 몫을 나눈다

중요도가 희석된다

비슷한 특성 여러 개가 각각 작아 보인다.
묶거나 하나만 남긴다.

19.5 → 10.0 + 9.8

기준값 = 배경 데이터

누구와 비교하는가?

배경 데이터를 바꾸면 평균과 모든 SHAP 값이 바뀐다.
기준 집단을 밝힌다.

전체 신청자인가, 승인자만인가?

고객 B의 워터폴이 거절 통지서가 된다

신용 실무: SHAP 감점 상위 항목을 골라 쉬운 문장으로 바꾼다

순위	SHAP 감점	고객 통지(예시)
1	최근 연체 2건(−57.2)	최근 연체로 점수가 낮아졌습니다.
2	카드 사용률 93%(−20.1)	한도 대비 카드 사용액이 많습니다.
3	소득 3,190만 원(−15.5)	소득이 심사 평균보다 낮습니다.

실무 포인트

- 긍정 요인(부채비율 +14.4)은 적지 않는다; 사유는 감점 상위 항목에서만 뽑는다.

SHAP은 예측을 읽을 수 있는 몫으로 바꾼다

1

섀플리 값 = 모든 합류 순서에 대한 평균 기여

몫의 합은 전체와 같고, 아무것도 더하지 않은 구성원은 0을 받는다.

2

사례 하나는 워터폴로, 모형 전체는 비스웜과 막대 플롯으로 읽는다

의존성 산점도는 꺾임과 상호작용 같은 형태를 드러낸다.

3

SHAP은 인과가 아니다

상관된 특성과 배경 데이터 선택이 결과를 바꾼다.