통합 강의 · XAI

설명가능한 머신러닝

SHAP·LIME·반사실 설명에서 금융 규제 대응까지

Explainable Machine Learning for Finance

과거 강의자료 열 가지의 XAI 내용을 중복 없이 하나로 묶고, 2026년 10월 기준 최신 연구와 규제로 보강했다.
손계산 수치예제는 별도 워크북 덱(XAI_Workbook)에 모았다.

설명가능성은 분해, 근사, 의무라는 세 얼굴을 가진다

강의 전체를 관통하는 결론을 먼저 제시한다

1

설명은 기여도 분해다

SHAP은 한 건의 예측값을 기준값과 특성별 기여도의 합으로 정확히 나눈다.

2

설명은 근사이며 서로 어긋날 수 있다

사후 설명은 모델의 근사다. 방법마다 결론이 다르고, 의도적으로 속일 수도 있다.

3

설명은 이제 규제 의무다

EU AI Act, GDPR 판례, AI 기본법, 금융분야 AI 가이드라인이 개별 설명을 요구한다.

핵심 질문: 모델이 왜 그렇게 판단했는지 고객, 감독당국, 개발자에게 각각 어떻게 말할 것인가

강의는 정의에서 출발해 도구, 사례, 규제의 순서로 나아간다

여덟 개 파트로 나누어 진행한다

파트	주제	핵심 도구와 질문
1	왜 설명가능성인가	정의와 분류, 설명의 네 단계, 세 청중
2	전역 설명	계수, 트리 중요도, 순열 중요도, 대리 모델, PDP·ALE
3	샤플리 값과 SHAP	공리, 가법성, 기준 분포, 추정기, 상호작용
4	SHAP 그래프 읽기	waterfall, beeswarm, scatter, decision plot
5	국소 대리·규칙·반사실	LIME, Anchors, 반사실 설명
6	딥러닝과 LLM	적분 그래디언트, 주의 가중치, 회로 추적
7	금융 적용 사례	신용평가, 사기 탐지, 자산가격 예측
8	한계와 규제	불일치 문제, 설명 조작, 2026년 규제 지형

01

PART 1 · 기본 개념

왜 설명가능성인가

정의와 분류, 설명의 깊이, 설명을 듣는 세 청중을 정리한다

해석가능성과 설명가능성은 서로 다른 개념이다

interpretability와 explainability를 구분한다

**해석가능성은 모델 구조 자체를 사람이 읽을 수 있는 정도이고,
설명가능성은 개별 판단의 근거를 사람에게 제시하는 능력이다.**

해석가능성 (interpretability)

- 선형회귀 계수, 얕은 의사결정트리
- 구조를 보면 판단 규칙이 드러난다
- 표현력이 제한되는 대가를 치른다

설명가능성 (explainability)

- 부스팅·신경망 같은 블랙박스에 사후 설명을 붙인다
- SHAP, LIME, 반사실 설명이 대표적이다
- 설명은 모델의 근사라는 점을 잊지 않는다

XAI 기법은 네 개의 축으로 분류된다

같은 SHAP도 쓰는 방식에 따라 국소 설명이 되기도 하고 전역 설명이 되기도 한다

분류 축	구분	예
범위	전역(global) 대 국소(local)	전체 중요도 순위 대 한 고객의 거절 사유
시점	모델 고유(intrinsic) 대 사후(post hoc)	로지스틱 계수 대 SHAP
대상	모델 특정 대 모델 무관(model-agnostic)	TreeSHAP 대 KernelSHAP·LIME
형태	기여도, 규칙, 반사실, 예시	SHAP, Anchors, DiCE, 프로토타입

이 강의는 '기여도 → 규칙 → 반사실'의 순서로 설명 형태를 넓혀 간다

설명은 결과, 재료, 기여도, 변화의 네 단계로 깊어진다

요리 프로그램 비유: AI 셰프가 케이크를 만든 이유를 어디까지 말해 주는가

1. 결과만

"맛있는 케이크 완성"

"대출이 거절되었습니다."
이유가 없어 신뢰가 낮다.

신뢰 낮음

2. 재료 목록

"밀가루·설탕·계란"

"소득과 신용점수를
고려했습니다."
무엇이 컸는지는 모른다.

신뢰 보통

3. 기여도

"밀가루 30%, 설탕 25%"

"소득이 가장 크게
기여했고, 연체가 점수를
낮췄습니다."

SHAP·LIME

4. 변화 시뮬레이션

"설탕을 줄이면?"

"기존 부채를 상환하면
승인 기준을 넘습니다."

반사실 설명

고객은 '왜 그런가'와 '어떻게 하면 되는가'를 함께 묻는다

금융에서 설명은 규제, 신뢰, 모델 개선의 세 가지 쓸모를 가진다

출처: 이전 강의안의 SHAP 가이드

규제 준수

자동화된 결정의 근거를 고객과 감독당국에 제시해야 한다. 모델 위험 관리 문서의 핵심 증빙이다.

PART 8에서 상세히

비즈니스 신뢰

"왜 이 고객을 차단했나?"라는 경영진 질문에 "신용점수, 새벽 거래, 고액 거래 때문"이라고 답할 수 있다.

사기 탐지 현장

모델 개선

기여가 거의 없는 특성을 걷어내고, 편향된 특성과 데이터 품질 문제를 찾아낸다.

PART 7에서 상세히

같은 판단이라도 청중에 따라 필요한 설명이 다르다

설명을 설계할 때는 누가 읽는지부터 정한다

청중	알고 싶은 것	알맞은 설명
고객	왜 거절됐나, 무엇을 바꾸면 되나	상위 사유 2~4개, 반사실 안내
감독당국	절차와 원칙, 공정성, 검증 기록	문서화, 전역 중요도, 검증 보고서
개발자·검증자	오류, 데이터 누수, 편향	의존도 그래프, 오탐·미탐 패턴 분석

한 장의 SHAP 그림을 세 청중에게 똑같이 내밀면 아무도 만족하지 않는다

02

PART 2 · 전역 설명

모델 고유 해석과 순열 중요도

모델 전체가 어떤 특성에 기대는지 먼저 본다

선형모형의 특성 중요도는 계수의 크기로 읽는다

출처: Big Data 5장 기계학습 슬라이드. 특성 j의 계수를 β_j, 표준편차를 σ(x_j)라 한다

$$\text{중요도}_j = \underbrace{|\beta_j|}_{\text{표준화한 경우}}$$

$$\text{중요도}_j = \underbrace{\sigma(x_j)\,|\beta_j|}_{\text{표준화하지 않은 경우}}$$

읽는 법

- 특성을 표준화했다면 계수 절댓값이 곧 중요도다
- 표준화하지 않았다면 표준편차를 곱해 단위를 맞춘다

함정

- 다중공선성이 높으면 계수가 불안정하다
- 특히 OLS에서 심하고, 릿지·라쏘는 덜하다

트리 모델의 기본 중요도는 학습 데이터에 기대어 편향될 수 있다

회귀 트리, 랜덤 포레스트, 부스팅에서 쓰는 세 가지 지표

지표	정의	주의할 점
분할 횟수	특성이 분할 변수로 쓰인 횟수	값의 종류가 많은 연속 변수를 과대평가한다
불순도 감소 (MDI)	분할할 때 예측 오차가 줄어든 양의 평균	학습 데이터 기준이라 과적합을 반영한다
OOB 순열 (랜덤 포레스트)	특성을 섞은 뒤 OOB 표본 오차의 증가	상관 특성끼리 중요도를 나눠 갖는다

OOB 순열 방식을 일반화한 것이 다음 장의 모델 무관 순열 특성 중요도다

순열 특성 중요도는 특성을 섞었을 때 늘어난 손실로 잰다

L은 손실 함수(제곱 오차, 1−R² 등), x_perm,j는 특성 j만 무작위로 섞은 데이터다

$$FI_j = \underbrace{L\left(y, \hat{f}(x_{\text{perm},j})\right)}_{\text{특성 } j\text{를 섞은 뒤 손실}} - \underbrace{L\left(y, \hat{f}(x)\right)}_{\text{원래 손실}}$$

절차

- 원래 데이터로 손실을 잰다
- 특성 j만 섞고 다시 잰다
- 늘어난 손실이 중요도다

장점과 한계

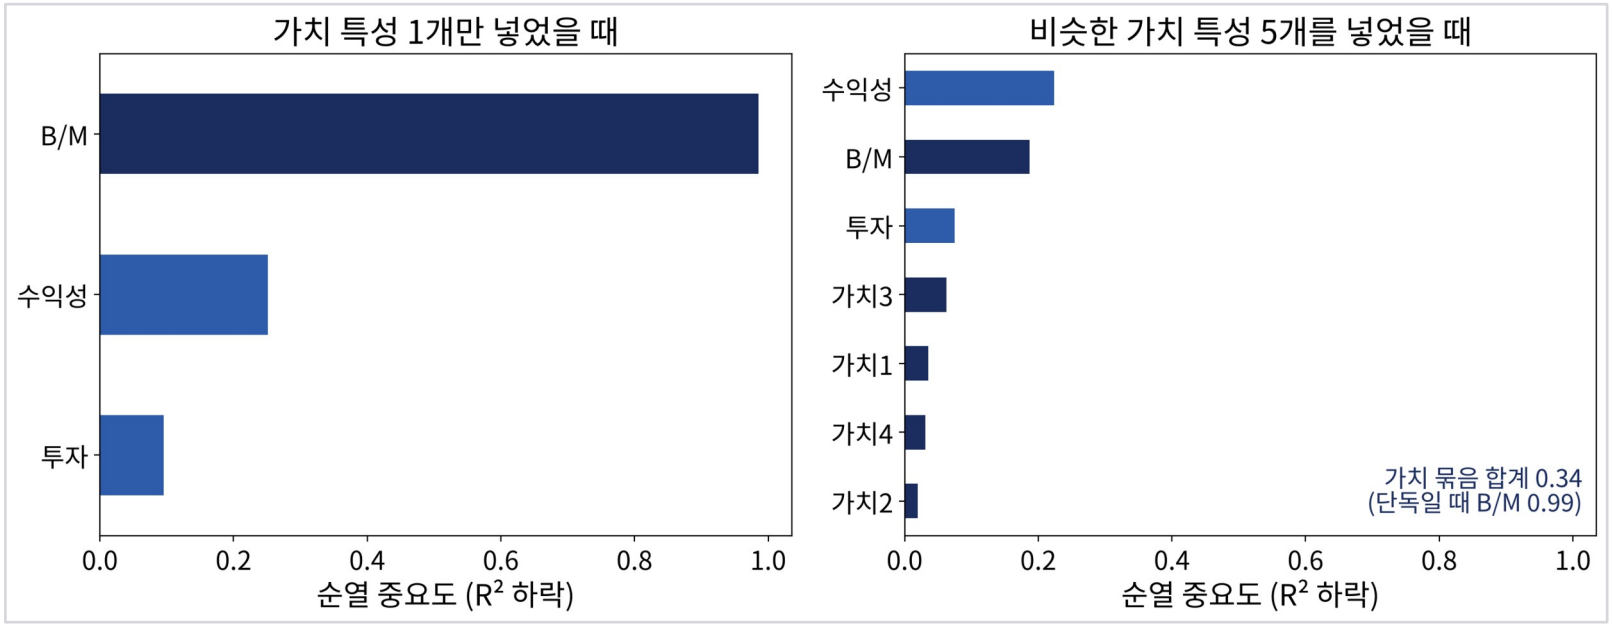
- 모델과 무관하고 계산이 단순하다
- 상관이 높은 특성은 과소평가된다
- 전역 중요도만 준다

비슷한 특성을 여럿 넣으면 중요도가 나뉘어 작아 보인다

합성 데이터 실험: 수익률 = B/M + 0.5×수익성 + 0.3×투자 + 오차, 랜덤 포레스트

대체 효과

- 원전 경고를 재현했다
- B/M 단독 0.99
- 가치 5개면 B/M 0.19
- 묶음 합계 0.34
- 상관 특성은 묶어서 집계



전역 대리 모델은 블랙박스의 예측을 다시 근사한다

global surrogate: 실제 타깃 대신 블랙박스 예측값을 타깃으로 학습한다

$$\underbrace{\hat{f}(x_i)}_{\text{블랙박스 예측}} = \underbrace{\hat{f}_{\text{대리}}(x_i)}_{\text{해석 가능한 대리 모델}} + \varepsilon_i$$

절차

- 블랙박스 예측값을 모은다
- OLS나 얕은 트리를 그 예측에 적합한다
- R^2로 대리 모델의 충실도를 확인한다

주의

- 대리 모델의 설명은 원래 모델의 설명이 아니다
- 충실도가 낮으면 해석 자체가 무의미하다

PDP는 평균 효과를, ALE는 국소 효과를 보여 준다

S는 관심 특성, C는 나머지 특성, z_k는 구간 경계, N_k는 구간 k에 속한 표본이다

$$\underbrace{\hat{f}_S(x_S)}_{\text{부분의존 함수}} = \frac{1}{n}\sum_{i=1}^{n} \hat{f}\left(x_S,\ x_C^{(i)}\right)$$

$$\hat{f}_{\mathrm{ALE}}(x) = \sum_{k=1}^{k(x)} \underbrace{\frac{1}{n_k}\sum_{i\in N_k}\left[\hat{f}\left(z_k, x_C^{(i)}\right) - \hat{f}\left(z_{k-1}, x_C^{(i)}\right)\right]}_{\text{구간 } k \text{ 안의 국소 변화 평균}}$$

부분의존도 (PDP)·ICE

- 다른 특성을 데이터 값으로 두고 관심 특성만 바꿔 평균한다
- 상관이 크면 비현실적인 조합을 만든다

누적 국소 효과 (ALE)

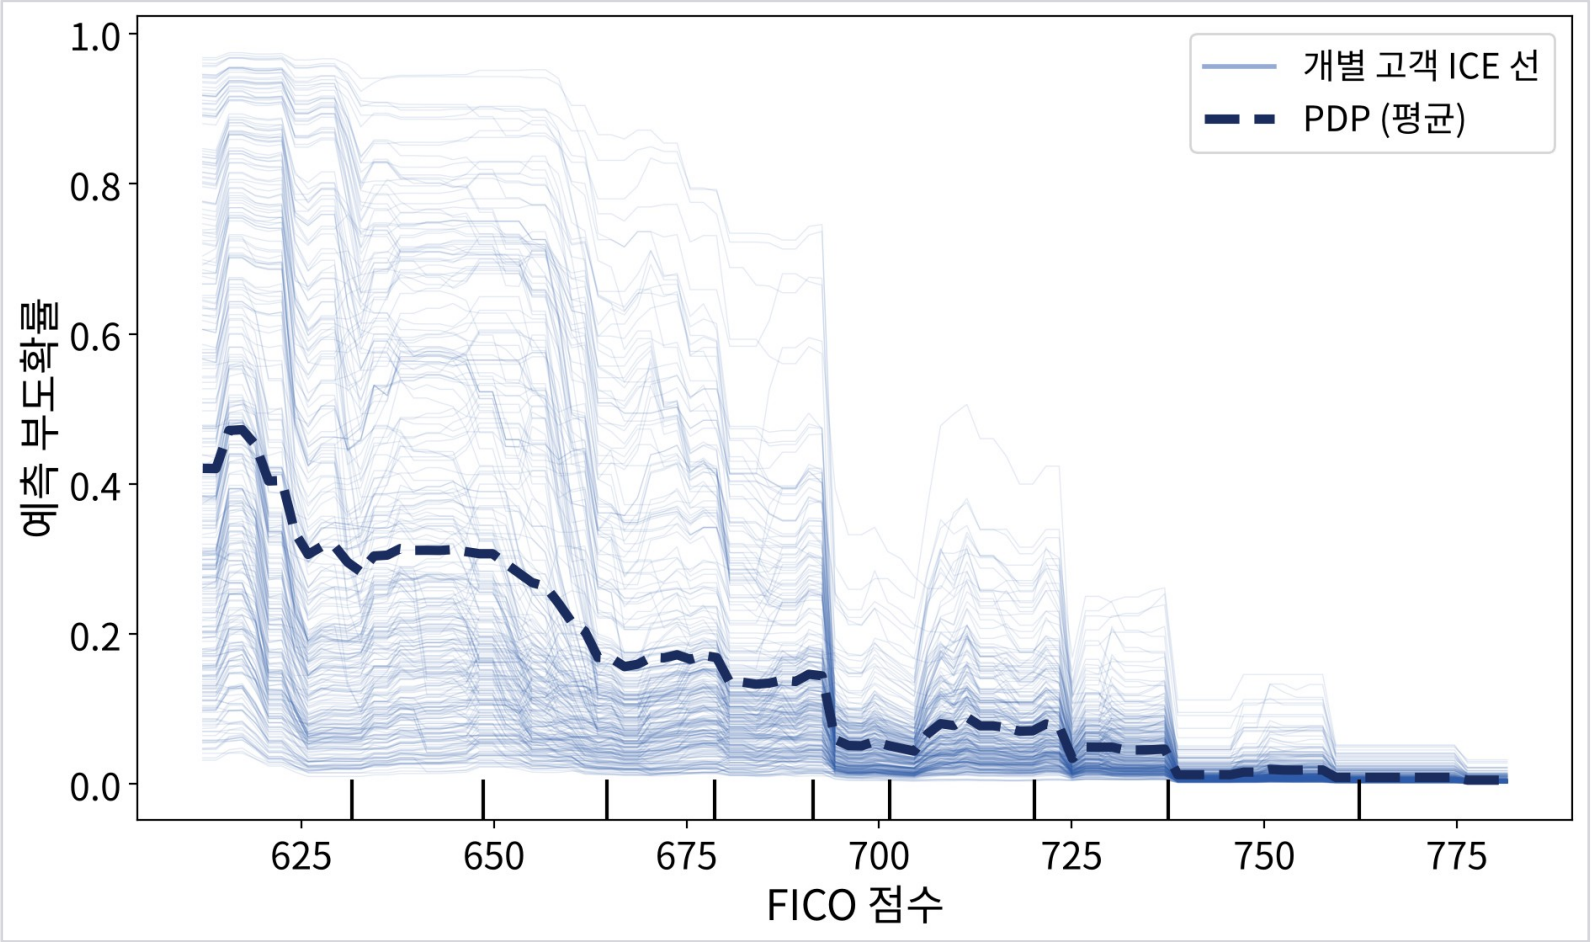
- 실제 데이터가 있는 구간 안에서만 변화를 잰다
- 상관 특성에 강하다 (Apley·Zhu, 2020)

ICE 선은 평균 PDP 뒤에 숨은 고객별 차이를 드러낸다

합성 대출 데이터, LightGBM 부도 모델 (AUC 0.87), FICO 점수에 대한 PDP와 ICE

읽는 법

- 굵은 점선이 평균 효과
- 얇은 선은 고객 한 명
- 점수 700 부근 급락
- 선이 엇갈리면 상호작용



03

PART 3 · 샤플리 값

샤플리 값과 SHAP

협력게임의 공정 배분이 어떻게 예측 설명이 되었는가

샤플리 값은 협력의 성과를 공정하게 나누는 게임이론의 해법이다

에피소드와 직관을 먼저 보고 수식으로 들어간다

에피소드

- 로이드 샤플리가 1953년 협력게임의 이익 배분 문제를 풀기 위해 제안했다
- 2012년 노벨경제학상을 받았다
- 60여 년 뒤 2017년 Lundberg·Lee가 머신러닝 설명의 표준으로 되살렸다

피자 주문 문제 (원전 예시)

- 셋이 각자 시키면 1만 원씩 3만 원, 함께 시키면 2만 5천 원이다
- 할인된 5천 원을 누구에게 얼마씩 돌려줄 것인가
- 각자가 합류하면서 늘린 몫을 모든 순서에 대해 평균하면 공정하다

플레이어를 특성으로 바꾸면 샤플리 값이 SHAP이 된다

같은 틀을 모델 성능(R^2) 분해에 쓰면 전역 중요도가 된다

게임이론	국소 설명 (SHAP)	전역 설명 (R^2 분해)
플레이어	특성	특성
연합 S의 가치 v(S)	S만 알 때의 예측 기대값	S만 쓴 모델의 R^2
배분 φ_i	특성 i의 SHAP 값	특성 i의 R^2 기여
전체 가치	예측값 − 기준값	전체 모델의 R^2

원전 Big Data 5장은 R^2를 가치로 쓰는 전역 용법을, 이전 강의안은 국소 용법을 다뤘다

샤플리 값은 모든 합류 순서에서 본 한계 기여의 가중평균이다

N은 전체 특성 집합, n은 특성 수, S는 특성 i를 뺀 부분집합이다

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \underbrace{\frac{|S|!\,(n - |S| - 1)!}{n!}}_{\text{순서 가중치}} \underbrace{\left[v(S \cup \{i\}) - v(S)\right]}_{\text{특성 } i\text{의 한계 기여}}$$

직관

- 특성이 무작위 순서로 한 명씩 합류한다고 본다
- i가 합류할 때 늘어난 몫을 모든 순서에 걸쳐 평균한다

계산 부담

- 부분집합이 2^n개라 정확 계산은 금방 불가능해진다
- 그래서 PART 3 후반의 추정기가 필요하다

R^2 분해형 샤플리 값도 같은 공식이다

원전 Big Data 5장 표기: K는 특성 수, C는 연합, V(C)는 연합 C를 쓴 모델의 R^2

$$SV_j = \frac{1}{K} \sum_{C \subseteq \tilde{K} \setminus \{j\}} \binom{K-1}{|C|}^{-1} \underbrace{\left(V(C \cup \{j\}) - V(C) \right)}_{\text{연합에 } j\text{를 더한 } R^2 \text{ 증가}}$$

읽는 법

- 연합 크기마다 평균을 내고, 크기 K개에 대해 다시 평균한다
- 앞 장의 순서 가중치와 같은 값이다

실무 함의

- 특성 수가 적은 OLS에서는 정확 계산이 가능하다
- 특성이 많으면 근사가 필요하다

샤플리 값은 네 가지 공리를 동시에 만족하는 유일한 배분이다

효율성이 SHAP의 가법성, 즉 '합이 맞는다'는 성질의 근거다

$$\sum_{i=1}^{n} \phi_i = v(N) - v(\varnothing)$$

공리	뜻
효율성	기여도의 합이 전체 가치와 기준값의 차이와 같다
대칭성	모든 연합에서 같은 몫을 더하는 두 특성은 같은 값을 받는다
더미	어떤 연합에도 기여하지 않는 특성은 0을 받는다
가법성	두 게임을 더하면 각 게임의 샤플리 값도 더해진다

SHAP은 예측값을 기준값과 기여의 합으로 나눈다

기준값 φ_0은 배경 데이터에서 본 평균 예측값이다

$$\hat{f}(x) = \underbrace{\phi_0}_{\text{기준값 } = E[\hat{f}(X)]} + \sum_{i=1}^{M} \underbrace{\phi_i}_{\text{특성 } i\text{의 SHAP 값}}$$

원전 사기 탐지 예시(정정본): 기준값 10%에서 출발해 네 특성의 기여를 더하면 85%가 된다

$$\underbrace{0.10}_{\text{기준값}} + \underbrace{0.10}_{\text{나이}} + \underbrace{0.05}_{\text{소득}} + \underbrace{0.30}_{\text{신용점수}} + \underbrace{0.30}_{\text{거래시간}} = \underbrace{0.85}_{\text{사기 확률}}$$

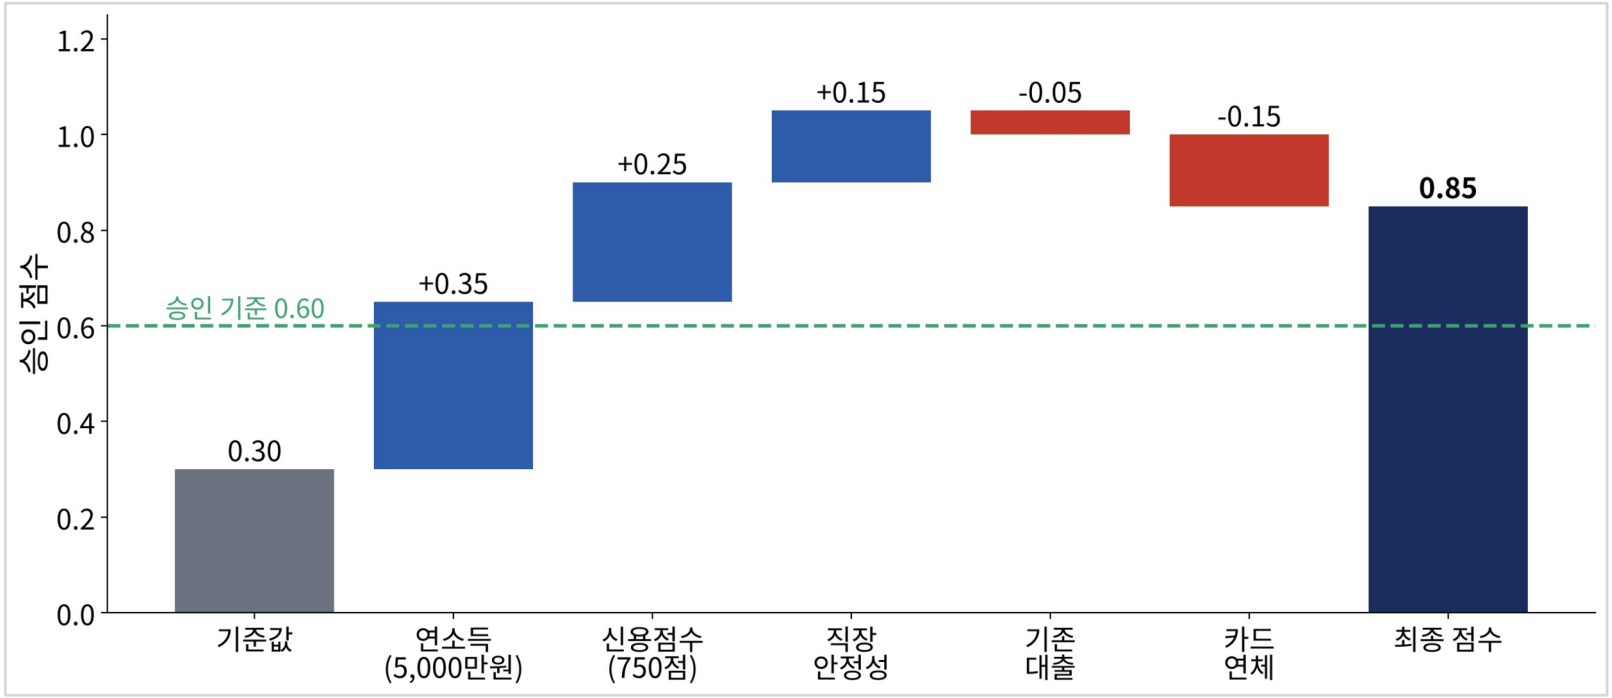
원전은 거래시간 기여를 +0.40으로 적어 합이 0.95였다. 85%와 맞도록 +0.30으로 바로잡았다

가상 고객의 승인 점수는 기준값 0.30에서 0.85까지 쌓인다

이전 강의안의 가상 사례 김철수 씨. 합계 0.30+0.35+0.25+0.15−0.05−0.15=0.85

고객에게 말할 것

- 승인 1위 사유는 연소득
- 감점 1위는 카드 연체
- 부채 상환 시 여유 확대
- 숫자는 가상 예시



빠진 특성을 어떻게 채우느냐에 따라 SHAP 값이 달라진다

'모델에 충실한가, 데이터에 충실한가'(Chen 외, 2020; Janzing 외, 2020)의 문제다

$$v_{\text{조건부}}(S) = E\left[\hat{f}(X) \,\middle|\, X_S = x_S\right]$$

$$v_{\text{개입}}(S) = E_{X_C}\left[\hat{f}(x_S, X_C)\right]$$

조건부 (관찰적) 방식

- 알려진 특성 값과 어울리는 나머지 값을 쓴다
- 데이터의 상관을 반영하지만 모델이 쓰지 않은 특성에도 기여가 생긴다

개입 (interventional) 방식

- 나머지 특성을 배경 데이터에서 독립적으로 가져온다
- 모델의 실제 작동에 충실하다
- TreeExplainer에 배경 데이터를 주면 이 방식이다

모델 구조에 맞는 추정기를 고르면 속도와 정확도를 함께 얻는다

shap 라이브러리의 주요 Explainer. T는 트리 수, L은 잎 수, D는 깊이다

추정기	대상 모델	정확도와 속도
TreeExplainer	랜덤 포레스트, XGBoost, LightGBM, CatBoost	정확값, 다항 시간 $O(TLD^2)$
KernelExplainer	모든 모델 (블랙박스)	가중 회귀로 근사, 느리고 표본에 따라 흔들린다
DeepExplainer	신경망 (TensorFlow, PyTorch)	DeepLIFT에 샤플리 값을 결합한 근사
LinearExplainer	선형·로지스틱 회귀	닫힌 해, 즉시 계산
Permutation·Partition	모든 모델 (기본 Explainer)	순열 근사, 상관 특성을 묶어 계산

선형 SHAP은 닫힌 해, Kernel SHAP은 가중 회귀다

M은 특성 수, |z′|는 켜진 특성 수다. 가중치는 아주 작거나 아주 큰 연합에 크다

$$\phi_i = \beta_i \left(x_i - E[x_i] \right)$$

$$\pi(z') = \frac{M - 1}{\binom{M}{|z'|} \, |z'| \, (M - |z'|)}$$

선형 SHAP

- 계수에 평균과의 차이를 곱한다
- 평균보다 높은 값이면 계수 방향으로 기여한다

Kernel SHAP

- 특성 부분집합을 표본으로 뽑아 예측한다
- 위 가중치로 선형회귀를 풀면 계수가 SHAP 값이다

shap 최신판에서는 SHAP 값의 반환 형식이 달라졌다

원전 강의 코드의 shap_values[1] 같은 리스트 색인은 새 버전에서 고쳐 써야 한다

버전	바뀐 점
0.45	다중 출력 SHAP 값을 리스트 대신 배열(표본×특성×클래스)로 반환
0.47	구형 bar plot 폐기, Explainer API 중심으로 정리
0.48	CoalitionExplainer와 Winter 값 추가
0.54.1	2026년 10월 16일 배포, 이 덱의 그림을 이 버전으로 그렸다

[출력] 권장 코드 · shap 0.54

```
explainer = shap.TreeExplainer(model)
sv = explainer(X_test)   # Explanation

sv.values.shape  # LightGBM 이진:
                 # (n, p) 로그오즈
                 # sklearn RF: (n, p, 2)

shap.plots.waterfall(sv[0])
shap.plots.beeswarm(sv)
```

SHAP 상호작용 값은 짝 효과를 따로 떼어 낸다

Lundberg 외(2020)의 TreeSHAP 상호작용 값. M은 특성 수다

$$\phi_{ij} = \sum_{S \subseteq N \setminus \{i,j\}} \frac{|S|!\,(M - |S| - 2)!}{2\,(M-1)!} \underbrace{\left[v(S \cup \{i,j\}) - v(S \cup \{i\}) - v(S \cup \{j\}) + v(S) \right]}_{\text{두 특성이 함께 있을 때의 추가 효과}}$$

읽는 법

- 대각 성분은 주효과, 비대각 성분은 짝 상호작용이다
- 주효과와 상호작용을 모두 더하면 예측값이 된다

최신 흐름: shapiq

- 세 특성 이상의 고차 상호작용을 다룬다
- Muschalik 외, NeurIPS 2024 라이브러리

04

PART 4 · 그래프 읽기

SHAP 그래프 읽기

원전 대화의 신용 모델과 같은 네 특성으로 실제 그래프를 그려 읽는다

SHAP 그래프마다 답하는 질문이 다르다

국소 그래프는 한 건을, 전역 그래프는 전체 패턴을 보여 준다

그래프	범위	답하는 질문
waterfall	국소	한 건의 예측이 기준값에서 어떻게 쌓였나
force	국소	예측을 올리는 힘과 내리는 힘은 무엇인가
beeswarm (summary)	전역	어떤 특성이 중요하고 값이 클 때 방향은 어디인가
bar	전역	평균 절대 SHAP 값의 순위는 어떤가
scatter (dependence)	전역	특성 값과 기여의 관계, 상호작용은 어떤가
decision	국소 여러 건	여러 건의 누적 경로가 어떻게 갈라지나

네 특성의 합성 대출 데이터로 LightGBM 부도 모델을 만들었다

원전 대화의 그림과 같은 특성 구성: DTI, FICO, 소득, 주택 보유

4,000건

합성 대출 표본 (테스트 30%)

18%

부도율

0.87

테스트 AUC

−2.40

기준값 (부도 로그오즈, 확률 약 8%)

단위 주의

- TreeExplainer의 기본 출력은 확률이 아니라 로그오즈다

가법성 검증

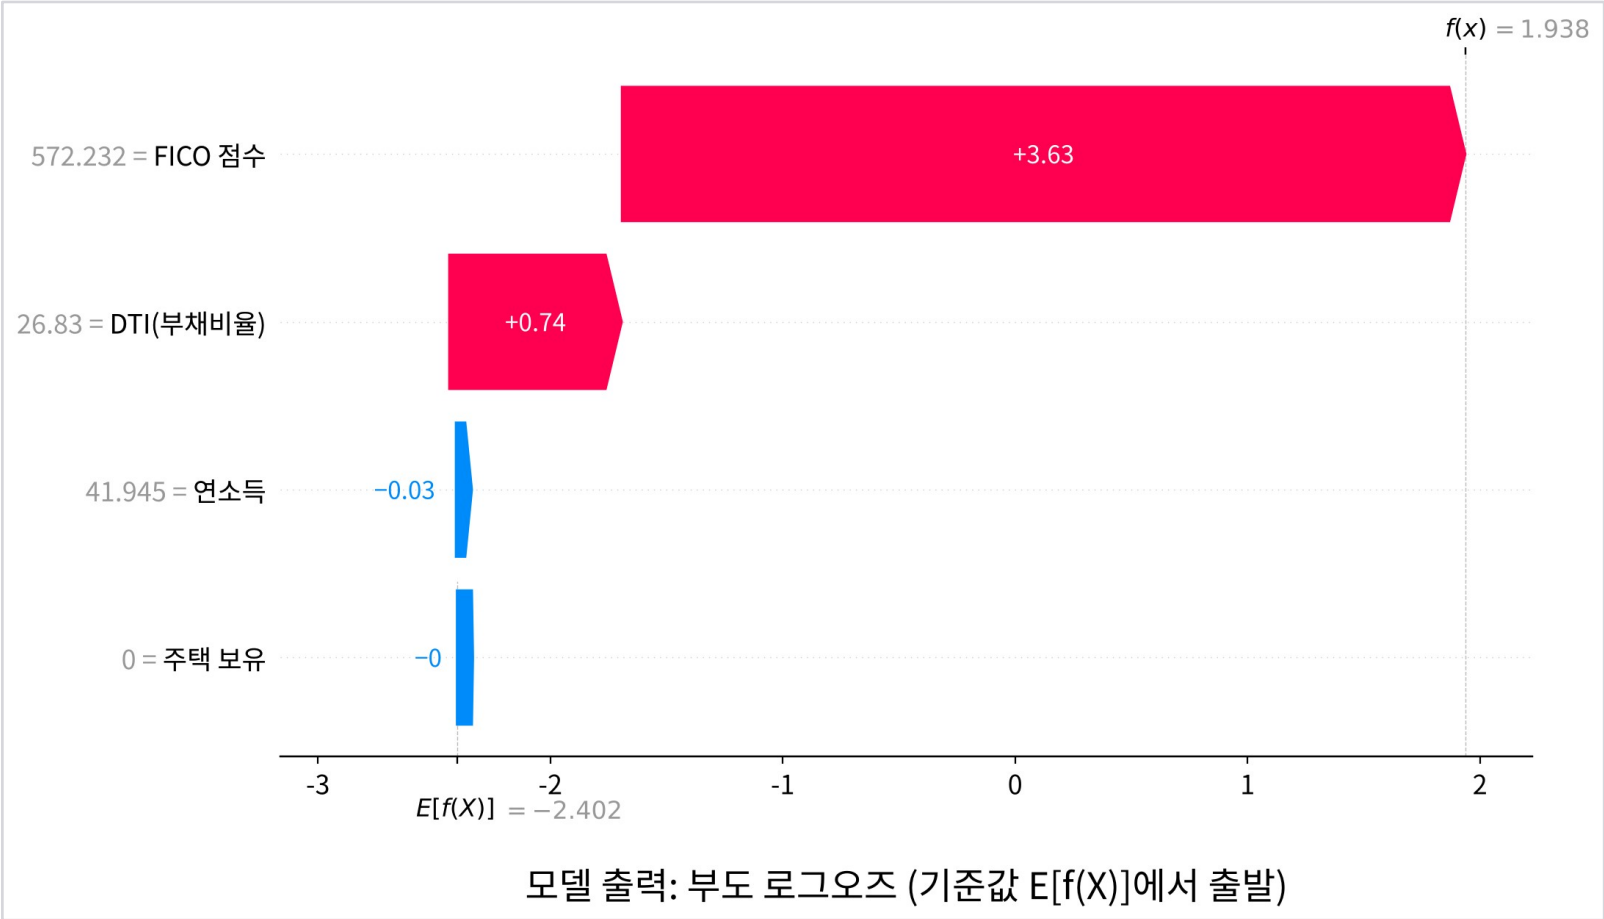
- 기준값과 SHAP 합이 예측 로그오즈와 소수점 14자리까지 일치했다

waterfall은 한 고객의 예측이 쌓이는 과정을 보여 준다

고위험 고객 1명: 기준값 −2.40에서 FICO +3.63, DTI +0.74가 더해져 1.94(부도확률 약 87%)

읽는 법

- 아래 E[f(X)]가 출발점
- 빨강은 위험 증가
- 파랑은 위험 감소
- 맨 위 f(x)가 예측값

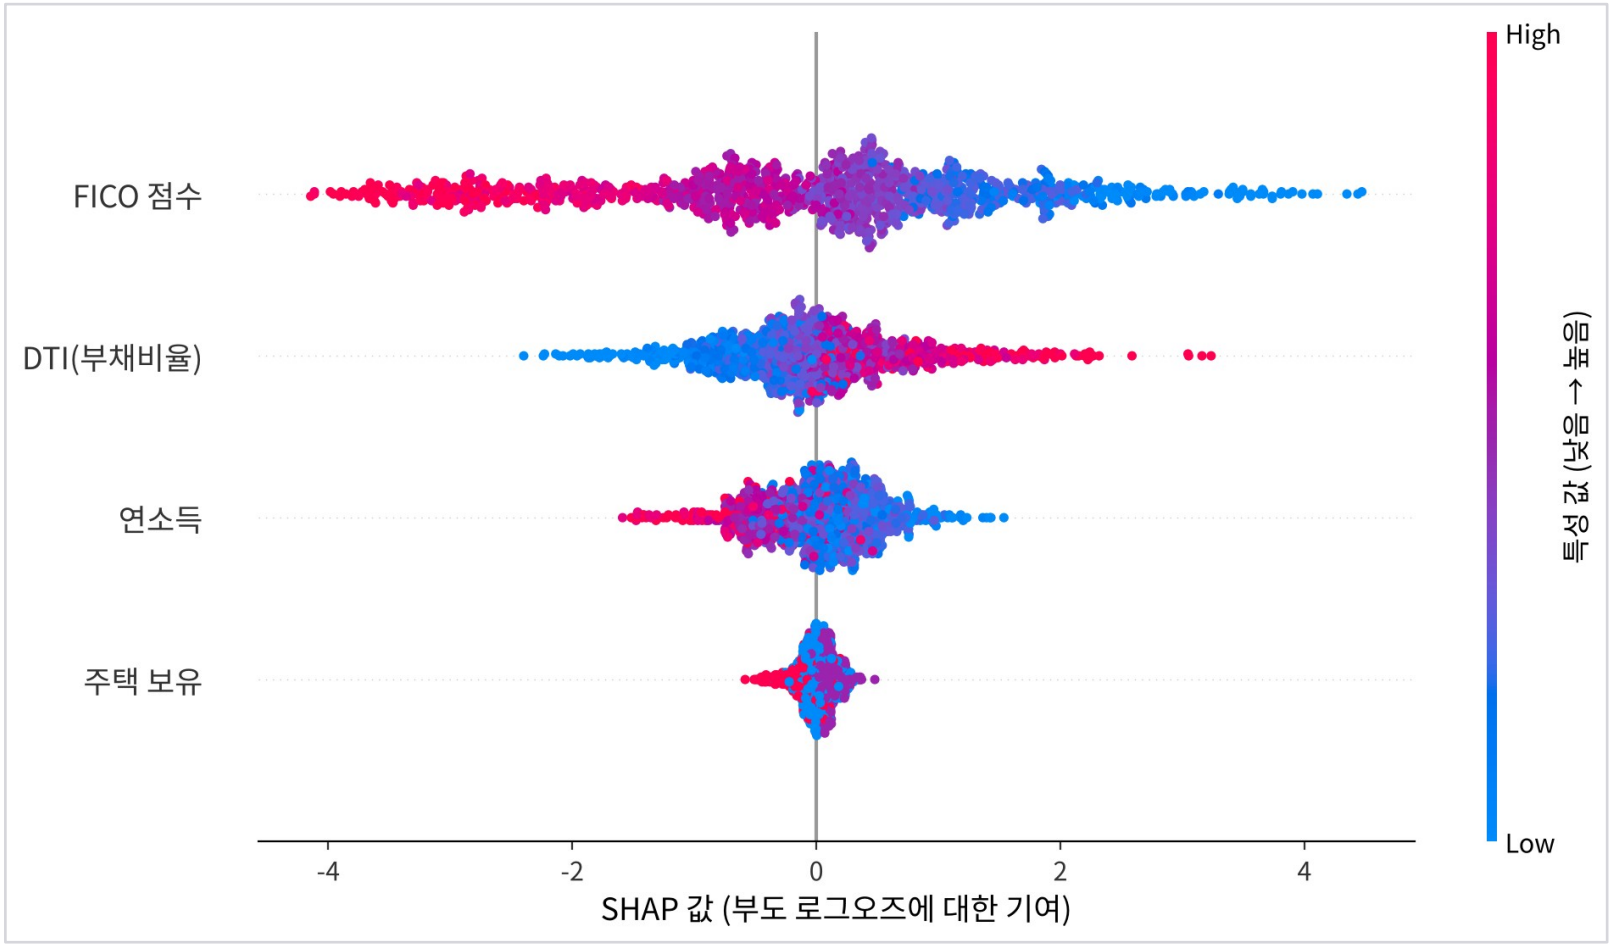


beeswarm은 중요도와 방향을 한 그림에 담는다

점 하나가 고객 한 명이고, 색은 특성 값의 크기, 가로 위치는 SHAP 값이다

읽는 법

- 위일수록 중요
- FICO가 낮으면(파랑) 오른쪽
- DTI가 높으면(빨강) 오른쪽
- 주택 보유는 영향 작음

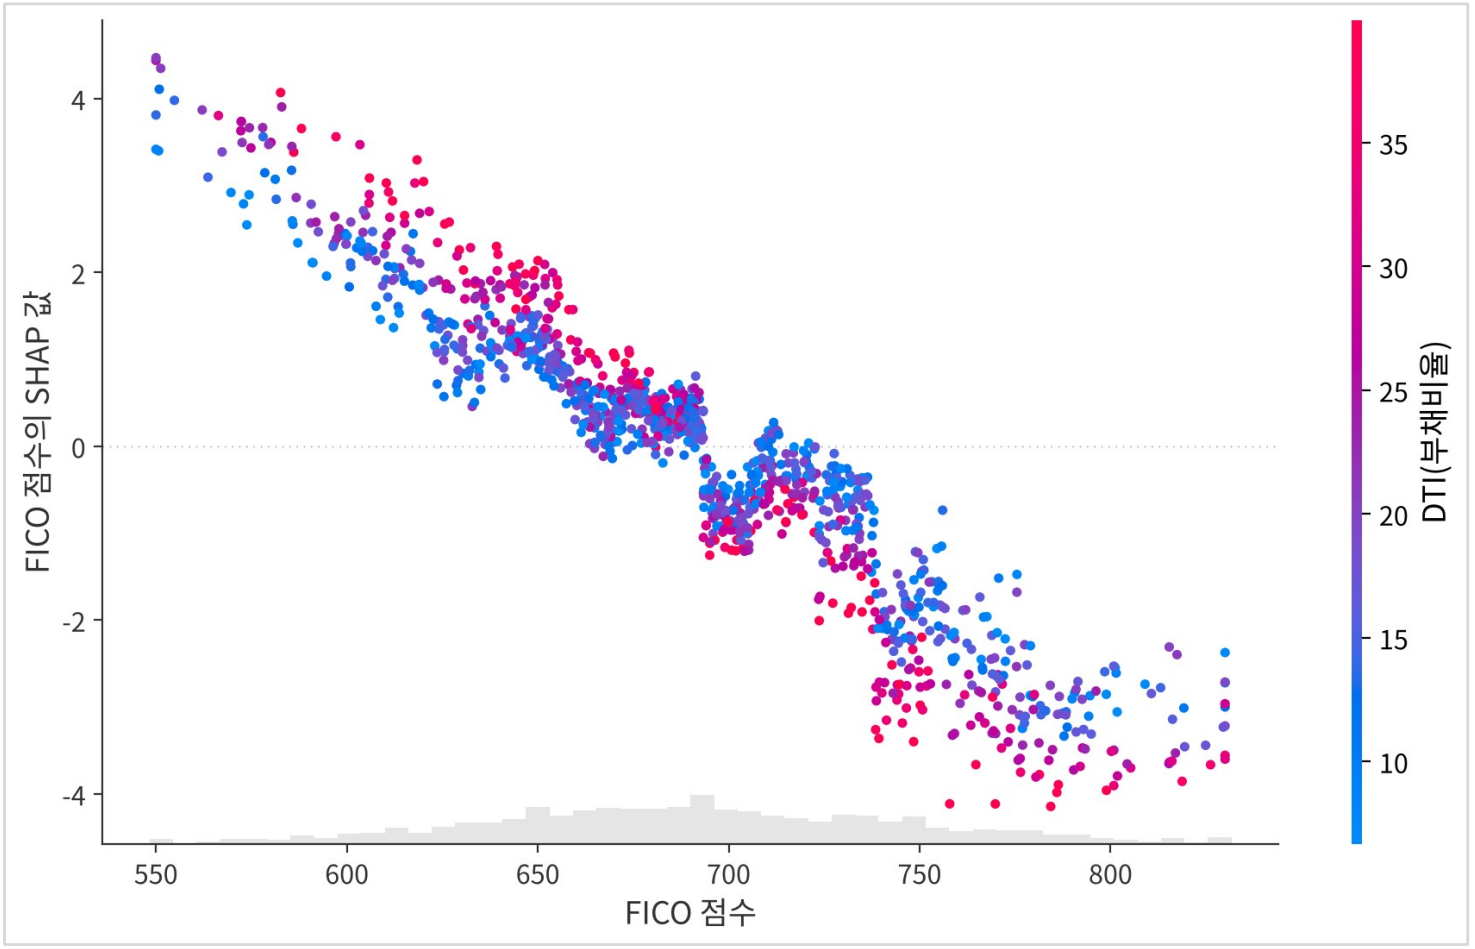


scatter는 특성 값과 기여의 관계와 상호작용을 드러낸다

FICO 점수의 SHAP 값, 색은 DTI. 데이터에 넣은 FICO×DTI 상호작용이 보인다

읽는 법

- 점수가 오를수록 위험 감소
- 같은 점수라도 색이 갈림
- 저점수에서 고DTI가 더 위
- 세로 퍼짐은 상호작용

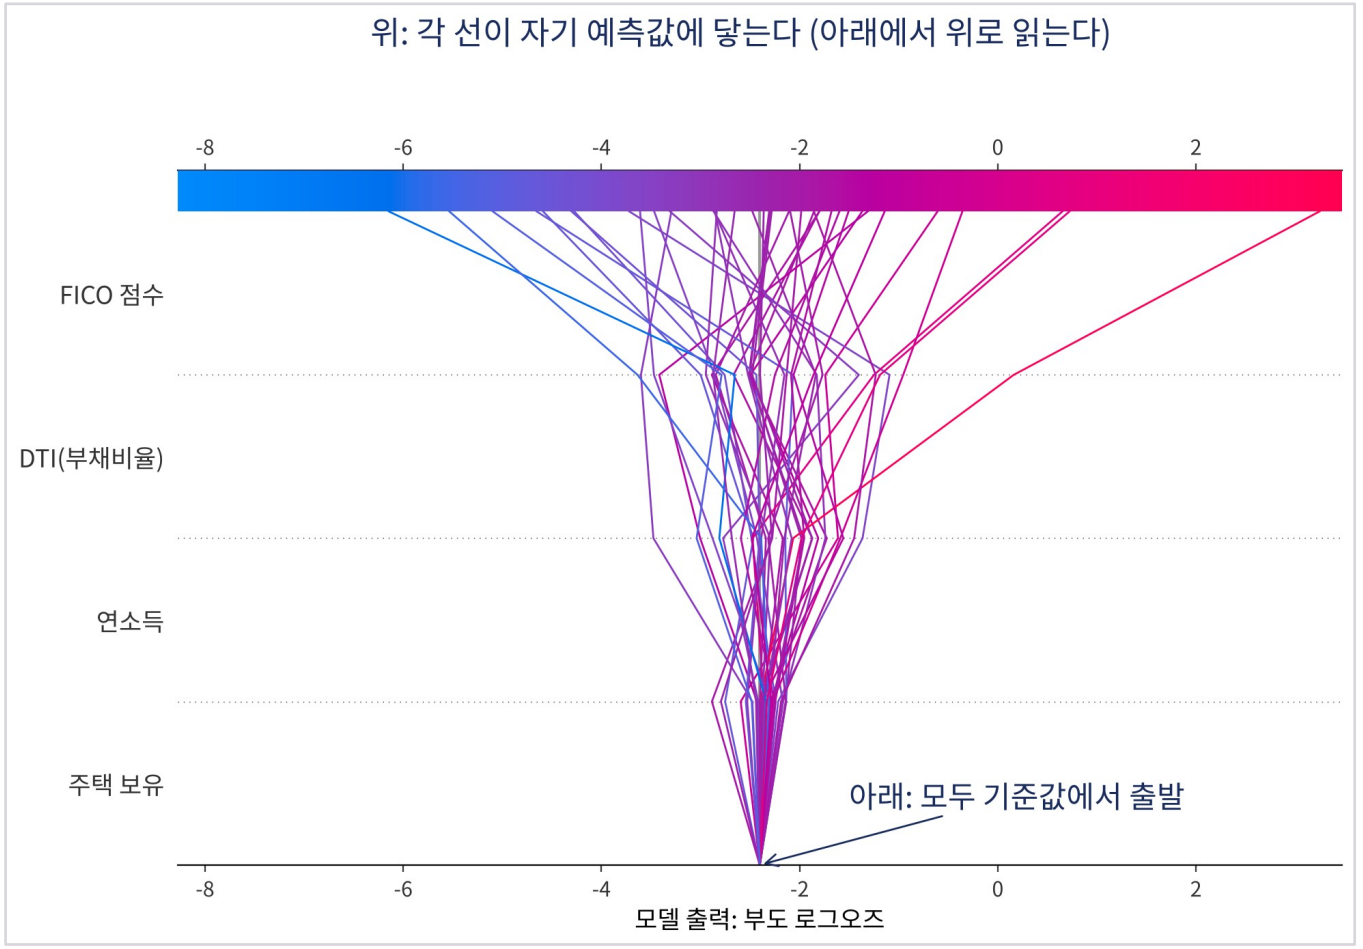


decision plot은 아래 기준값에서 출발해 위로 누적된다

고객 40명. 모든 선이 아래 기준값에서 모였다가 위로 올라가며 갈라져 각자의 예측값에 닿는다

읽는 법

- 아래에서 위로 읽는다
- 위쪽 특성일수록 중요
- 선이 꺾이는 폭이 기여
- 윗변이 최종 예측값



decision plot의 읽는 방향은 공식 문서로 확인해야 한다

2025년 7월 강의 준비 대화에서 실제로 혼선이 있었던 장면을 바로잡는다

당시의 혼선

- "위에서 아래로 읽는다"는 설명이 오갔다
- 질문자는 "밑에서 수렴하고 위가 분산돼 있다"고 관찰했다
- 질문자의 관찰이 맞았다

공식 문서의 설명

- 아래에서 모든 선이 기준값에 모인다
- 위에서 각 선이 자기 예측값에 닿는다
- 특성은 표시된 표본 기준 중요도 순으로 위에 놓인다

교훈: 그래프의 축과 읽는 방향은 기억이 아니라 공식 문서로 확인한다

05

PART 5 · 국소 설명

국소 대리 모형, 규칙, 반사실 설명

LIME, Anchors, 반사실 설명으로 설명의 형태를 넓힌다

LIME은 한 점 주변에서 블랙박스를 단순한 모델로 근사한다

g는 해석 가능한 모델, π_x는 x와 가까운 표본에 큰 가중치를 주는 함수다 (Ribeiro 외, 2016)

$$\xi(x) = \arg\min_{g \in G} \underbrace{L(\hat{f}, g, \pi_x)}_{\text{국소 충실도 손실}} + \underbrace{\Omega(g)}_{\text{복잡도 벌점}}$$

1. 교란 생성

원래 데이터 주변에 표본을 만든다

2. 예측

블랙박스로 각 표본을 예측한다

3. 가중치

원래 점과 가까울수록 크게 준다

4. 선형 모델

가중 회귀의 계수가 설명이다

출처: Day 4 교육 슬라이드의 4단계. 빠르지만 표본을 새로 뽑을 때마다 결과가 흔들릴 수 있다

Anchors는 예측을 고정하는 충분조건 규칙을 찾는다

A는 규칙, D(z|A)는 규칙을 만족하는 교란 표본의 분포, τ는 목표 정밀도다

$$\text{정밀도}(A) = E_{D(z|A)}\left[\mathbf{1}\{\hat{f}(z) = \hat{f}(x)\}\right] \geq \tau$$

예시 (이전 강의안)

- "신용점수 600 미만이고 연체 2회 이상이면 거절"
- 목표 정밀도 95%로 규칙을 찾는다
- 비전문가에게 가장 설명하기 쉽다

정밀도와 포괄도

- 정밀도는 규칙이 맞을 때 예측이 같은 비율이다
- 포괄도는 규칙이 적용되는 표본의 비율이다
- 둘은 서로 맞바꾸는 관계다

반사실 설명은 '무엇이 달랐다면 결과가 바뀌었는가'에 답한다

y'는 원하는 결과, d는 원래 고객과의 거리다 (Wachter 외, 2017)

$$x^* = \arg\min_{x'} \max_{\lambda} \underbrace{\lambda\left(\hat{f}(x') - y'\right)^2}_{\text{목표 결과 달성}} + \underbrace{d(x, x')}_{\text{원래 고객과의 거리}}$$

실무 조건

- 나이처럼 바꿀 수 없는 특성은 고정한다
- 바꾸는 특성은 적을수록 좋다
- DiCE처럼 여러 대안을 제시한다

왜 중요한가

- 고객이 실제로 할 수 있는 행동을 알려 준다
- CJEU 판결도 입력이 달랐다면 결과가 어떻게 달랐을지를 설명 수단으로 인정했다

네 가지 설명 기법은 근거와 쓰임이 서로 다르다

이전 강의 노트의 비교표를 통합했다. 측정 환경에 따라 달라지는 속도 수치는 뺐다

기준	SHAP	LIME	순열 중요도	반사실
이론 근거	샤플리 공리	국소 대리 회귀	성능 하락	최적화
범위	국소와 전역	국소	전역	국소
안정성	정확 추정기면 높다	표본마다 흔들린다	반복 평균이 필요하다	해가 여러 개다
주된 쓰임	사유 고지, 모니터링	빠른 점검	특성 선택	개선 안내

06

PART 6 · 딥러닝과 LLM

딥러닝, 시계열, LLM의 해석

그래디언트 기반 귀속에서 대규모 언어모델의 회로 추적까지

적분 그래디언트는 경로를 따라 그래디언트를 적분한다

x′는 기준 입력(예: 0 벡터), α는 0에서 1까지 움직이는 경로 변수다 (Sundararajan 외, 2017)

$$IG_i(x) = (x_i - x_i') \int_0^1 \frac{\partial \hat{f}\left(x' + \alpha(x - x')\right)}{\partial x_i} d\alpha$$

$$\sum_i IG_i(x) = \hat{f}(x) - \hat{f}(x') \quad \text{(완전성)}$$

원전: 딥헤징 강의 코드

- 순열 중요도와 평균 절대 그래디언트로 특성 중요도를 쟀다

보강

- 완전성 덕분에 SHAP처럼 합이 맞는다
- DeepSHAP은 DeepLIFT에 샤플리 값을 결합했다

주의 가중치는 유용한 단서이지만 그 자체로 설명은 아니다

e_t는 시점 t의 점수, T는 시계열 길이다

$$\alpha_t = \frac{\exp(e_t)}{\sum_{k=1}^{T} \exp(e_k)}$$

원전: 고급 강의노트

- 금융 시계열에서 어떤 시점과 뉴스에 주목했는지 보여 준다고 소개했다

보강: 학계의 논쟁

- Jain·Wallace(2019)는 주의 가중치가 예측 근거와 어긋날 수 있다고 보였다
- Wiegreffe·Pinter(2019)는 조건부로 유용하다고 반박했다

LLM 해석은 내부 특징과 계산 경로를 추적한다

희소 오토인코더(SAE)가 모델 내부 표현 x를 해석 가능한 특징 h로 분해한다

$$h = \mathrm{ReLU}(W_{\mathrm{enc}}x + b), \qquad \mathcal{L} = \underbrace{\|x - W_{\mathrm{dec}}h\|_2^2}_{\text{복원 오차}} + \underbrace{\lambda\|h\|_1}_{\text{희소성 벌점}}$$

회로 추적 (circuit tracing)

- Anthropic이 2025년 5월 귀속 그래프 생성 도구를 오픈소스로 공개했다
- Gemma-2-2b, Llama-3.2-1b 같은 공개 모델에서 쓸 수 있다

한계

- 귀속 그래프는 내부 단계의 일부만 드러낸다
- 금융 현장 규제 대응 수단으로는 아직 이르다

에이전트의 매매 결정은 근거를 구조화해 기록해야 추적할 수 있다

원전: 2026년 4월 주별 상세 강의노트의 XAI 리포트 스키마

[출력] 결정 근거 리포트 스키마 · XAIReport

ticker	종목
final_decision	최종 매매 결정
analyst_basis	애널리스트별 근거 4개
debate_summary	강세·약세 토론 요약
risk_basis	리스크 평가 근거
fund_manager_note	펀드매니저 승인 의견
data_sources	사용 데이터 출처
confidence	결정 확신도 0~1

쓸모

- 감독 대응과 투자위원회 보고에 결정 경로를 남긴다

주의

- LLM이 스스로 쓴 근거는 실제 계산 경로와 다를 수 있어 검증이 필요하다

07

PART 7 · 금융 사례

금융 적용 사례

신용평가, 사기 탐지, 자산가격 예측, 공정성

사기 탐지에서 SHAP은 예측에서 개선까지를 잇는다

이전 강의안의 FraudDetectionWithSHAP 구조를 단계로 정리했다

1. 예측

랜덤 포레스트가 이상거래 확률을 낸다

2. 분해

TreeSHAP으로 특성별 기여를 구한다

3. 검증

기준값과 SHAP 합이 예측과 0.001 안에서 맞는지 확인한다

4. 고지

상위 3요인을 고객 문장과 규제 보고서로 만든다

5. 개선

오탐·미탐 사례의 SHAP 패턴을 분석한다

고객용 문장에는 기술 변수명(amount_vs_avg 등) 대신 '평소 거래액 대비 비율' 같은 말을 쓴다

SHAP 진단표로 모델의 군살과 편향을 찾는다

이전 강의안의 analyze_shap_for_model_improvement. 기준값은 원전 예시 값이다

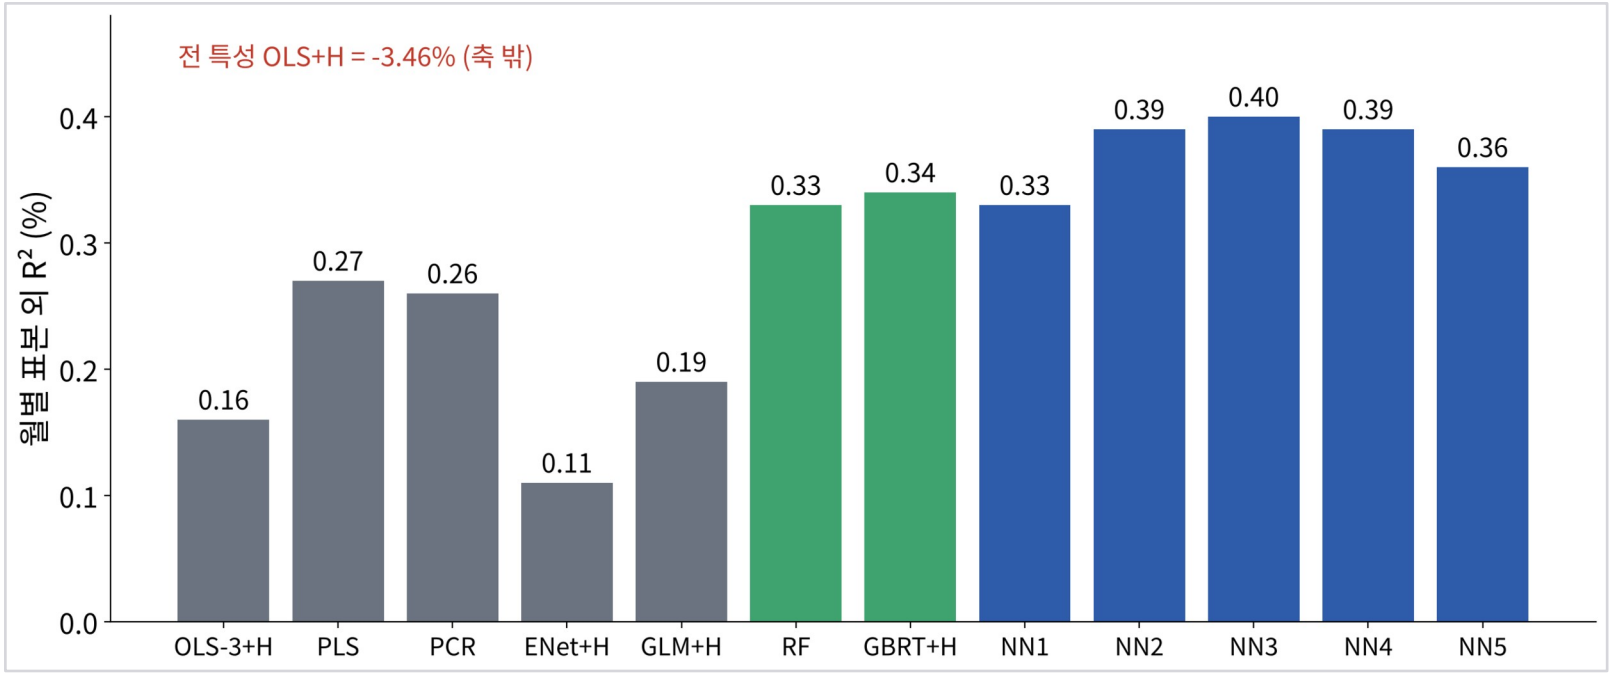
진단	SHAP 신호	조치
불필요 특성	평균 절대 SHAP 값이 0.01 미만	제거해 경량화하고 과적합을 줄인다
한쪽 쏠림	SHAP 값이 양수인 비율이 90% 초과	전처리와 인코딩을 다시 본다
중복 특성	두 특성의 SHAP 값 상관이 0.8 초과	하나를 빼거나 묶는다
오탐	정상 거래에서 큰 양의 기여를 낸 특성	임계값과 특성을 조정한다
미탐	사기 거래에서 음의 기여를 낸 특성	특성을 보강한다

주식수익률 예측에서 비선형 모델이 표본 외 설명력을 높였다

출처: Gu, Kelly, Xiu (2020) 표 1, 전체 표본 월별 표본 외 R^2(%). 원전 Big Data 5장 인용

핵심 발견

- 신경망 NN3 0.40%
- 트리 계열 0.33~0.34%
- 전 특성 OLS는 −3.46%
- 상위 신호는 모멘텀·유동성·변동성



차별이 없어도 설명하지 못하면 신뢰를 잃는다

이전 강의안의 Apple Card 사례를 감독당국 조사 결과로 바로잡는다

Apple Card (2019~2021)

- 2019년 부부 간 한도 차이로 성차별 논란이 일었다
- NYDFS는 2021년 약 40만 명 자료를 검토해 위반 증거가 없다고 밝혔다
- 다만 투명성 부족이 신뢰를 해쳤다고 지적했다

Amazon 채용 AI (2018)

- 과거 이력서로 학습한 모델이 여성 지원자를 불리하게 평가해 폐기되었다
- 우편번호처럼 보호 속성을 대신하는 대리 변수도 같은 위험을 만든다

SHAP 상위 사유에 대리 변수가 보이면 공정성 지표를 실제 결과로 따로 측정한다

08

PART 8 · 한계와 규제

한계와 함정, 그리고 2026년 규제 지형

설명을 믿기 전에 확인할 것과 지켜야 할 것

설명 기법끼리 결론이 엇갈리는 일은 현장에서 흔하다

Krishna 외 (2022), 데이터 과학자 25명 인터뷰. ‘불일치 문제(disagreement problem)’

88%

같은 예측에 여러 설명 기법을 함께 쓴다

84%

기법 간 불일치를 자주 겪었다

86%

불일치를 임시방편으로 풀거나 방법을 모른다 (사용자 연구)

불일치의 형태

- 상위 특성이 다르거나 순서와 부호가 다르다

대응

- 목적에 맞는 기법을 미리 정하고 문서화한다

교란 기반 설명은 의도적으로 속일 수 있다

Slack 외 (2020), 'Fooling LIME and SHAP', AIES 2020

**편향된 분류기를 감싸서, 설명용 교란 입력이 들어올 때만
무해한 모델처럼 답하게 만들 수 있다.**

원리 (스캐폴딩)

- 교란 표본은 실제 데이터 분포에서 벗어나 있다
- 분포 밖 입력을 가려내 그때만 다른 모델로 응답한다
- COMPAS 등 실제 데이터에서 LIME과 SHAP 모두 속았다

함의

- 교란 기반 설명만으로는 편향을 탐지할 수 없다
- 공정성은 실제 데이터 위 결과로 직접 측정한다
- 외부 모델은 설명과 함께 결과 분포도 받는다

SHAP을 쓸 때 빠지기 쉬운 함정은 다섯 가지다

원전 강의안들에 흩어져 있던 주의사항을 한 표로 모았다

함정	내용	대응
상관 특성	기여가 나뉘거나 뒤바뀐다	묶음으로 집계하고 계산 방식을 밝힌다
인과 착각	모델의 연관이지 세상의 인과가 아니다	개입 효과는 인과 분석으로 따로 본다
기준값 의존	배경 데이터가 바뀌면 값이 바뀐다	배경 표본을 문서화한다
출력 척도	로그오즈와 확률의 크기가 다르다	그림마다 단위를 밝힌다
근사 오차	Kernel SHAP 표본이 적으면 흔들린다	가법성을 점검하고 반복한다

해외 규제는 개별 결정의 근거 설명을 요구한다

EU와 미국의 주요 근거. 시점은 2026년 10월 기준이다

관할·근거	설명 관련 요구	현재 상태
EU AI Act	신용평가는 고위험(부속서 III). 영향받는 사람의 설명 요구권(제86조)	고위험 의무 적용이 2027년 12월 2일로 연기 (디지털 옴니버스)
GDPR 제15조 + CJEU C-203/22	실제 적용된 절차와 원칙을 이해할 수 있게 설명	2025년 2월 27일 판결
미국 ECOA·Regulation B	신용 거절 시 구체적인 주요 사유 고지	CFPB 해석 서한 2건은 2025년 5월 철회, 규정은 유지

국내도 자동화된 결정의 설명 요구가 자리 잡았다

AI 기본법은 2026년 1월 22일 시행, 금융분야 AI 가이드라인은 2026년 6월 22일 시행

근거	핵심 내용
AI 기본법	사람의 최종 판단 없이 자동 처리하는 대출 심사 등은 고영향 AI. 과태료 최대 3천만 원, 1년 이상 계도기간
개인정보보호법 제37조의2	완전히 자동화된 결정에 대해 정보주체가 설명을 요구하고 거부할 권리
신용정보법 제36조의2	자동화평가 결과에 대해 설명을 요구하고 이의를 제기할 권리
금융분야 AI 가이드라인 개정	거버넌스, 합법성, 보조수단성, 신뢰성, 금융안정성, 신의성실, 보안성의 7대 원칙

CJEU는 알고리즘 공개가 아니라 이해할 수 있는 설명을 요구했다

C-203/22 Dun & Bradstreet Austria, 2025년 2월 27일 판결의 실무 함의

하지 말 것

- 복잡한 수식이나 알고리즘을 통째로 건넨다
- 전 과정의 모든 단계를 나열한다
- 영업비밀을 이유로 일괄 거부한다

할 것

- 어떤 개인 데이터가 어떻게 쓰였는지 밝힌다
- 입력이 달랐다면 결과가 어떻게 달랐을지 보여 준다
- 영업비밀 다툼은 감독기관이나 법원이 형량한다

SHAP 상위 사유와 반사실 설명의 조합이 판결이 말한 설명 방식에 가장 가깝다

설명 문서에는 목적부터 한계까지 일곱 항목이 들어가야 한다

모델 위험 관리와 감독 대응을 함께 고려한 체크리스트

무엇을 설명하는가

- 사용 목적과 자동 결정의 범위
- 주요 요인과 영향 방향
- 설명 방법론과 선택 이유
- 배경 데이터와 출력 단위

어디까지 믿을 수 있는가

- 설명의 알려진 한계
- 대표 사례의 설명 예시
- 재학습할 때 다시 검토한 기록

설명 시스템은 세 단계로 나누어 도입한다

이전 강의안의 Phase 1~3 로드맵

1단계 · 상위 요인

Basic

SHAP 절댓값 상위 3요인을 고지한다.
가법성 검증을 자동화한다.

고객 문의 대응

2단계 · 가정 분석

What-if

"소득이 늘면?"을 시뮬레이션한다.
바꿀 수 없는 특성은 고정한다.

반사실 안내

3단계 · 자연어 설명

LLM 문장화

SHAP 결과를 문장으로 바꾼다.
숫자는 시스템이 채우고 LLM은
문장만 쓴다.

환각 방지

토론 질문

수업에서 다룬 원리로 판단을 정리해 본다

Q1	상관이 높은 소득 변수 두 개가 거절 사유 1·2위로 나뉘었다. 고객에게 무엇을 어떻게 고지하겠는가?	**상관 특성**
Q2	대출 모델의 SHAP 상위 사유에 '거주 지역'이 있다. 그 자체로 차별의 증거인가, 무엇을 더 확인하는가?	**공정성**
Q3	같은 고객에게 SHAP과 LIME의 1순위 사유가 다르다. 고지와 내부 보고에 각각 무엇을 쓰겠는가?	**불일치**
Q4	LLM 에이전트가 스스로 쓴 매매 근거 리포트를 감독 대응 자료로 쓸 수 있는가?	**자기 설명**

설명은 분해이자 근사이며 의무다

오늘 강의를 세 문장으로 정리한다

1 **분해**

샤플리 공리 덕분에 SHAP은 예측을 기준값과 기여의 합으로 정확히 나눈다.

2 **근사**

기준 분포, 상관, 기법 간 불일치, 조작 가능성을 알고 써야 한다.

3 **의무**

규제는 알고리즘 공개가 아니라 고객이 이해하고 행동할 수 있는 설명을 요구한다.

다음: 워크북에서 세 특성 샤플리 값과 순열 중요도를 손으로 계산한다

참고문헌과 원전

원전은 이 강의로 통합한 과거 강의자료다

- 원전: SHAP Analysis for Tree Models(2025.7), 금융 업무 자동화 강의안(2025.8), 금융 AI 가이드라인 강의노트(2025.10), Big Data 5장 기계학습 번역(2025.8), Day 4 교육 슬라이드(2025.6), 고급 강의노트(2025.8), 딥헤징 8주 강의(2025.8), 주별 상세 강의노트(2026.4)
- Shapley (1953); Lundberg·Lee (2017) NeurIPS; Lundberg 외 (2020) Nature Machine Intelligence; Ribeiro 외 (2016, 2018); Wachter 외 (2017); Sundararajan 외 (2017)
- Apley·Zhu (2020); Chen 외 (2020); Janzing 외 (2020); Muschalik 외 (2024) shapiq; Gu·Kelly·Xiu (2020) Review of Financial Studies
- Krishna 외 (2022) The Disagreement Problem; Slack 외 (2020) Fooling LIME and SHAP; Jain·Wallace (2019); Wiegreffe·Pinter (2019); Anthropic (2025) circuit tracing
- shap 공식 문서(decision plot), PyPI shap 0.54.1; Regulation (EU) 2026/1744; CJEU C-203/22; NYDFS Apple Card 보고 (2021.3); 아주경제·뉴데일리(2026) AI 기본법·금융분야 AI 가이드라인 보도