워크북 · 손계산

설명가능한 머신러닝 워크북

계산기 없이 따라가는 여섯 개의 수치예제

Hand-calculation Workbook for XAI

본편 덱(XAI_Lecture_Deck)의 수식을 작은 숫자로 직접 풀어 본다.
모든 예제는 검산 단계까지 포함한다.

여섯 개 예제로 본편의 핵심 수식을 손으로 확인한다

예제마다 설정, 계산, 검산의 세 단계로 진행한다

예제	주제	확인할 성질	본편 위치
1	세 특성 샤플리 값	순서 가중치, 효율성	PART 3
2	선형 SHAP	닫힌 해와 가법성	PART 3
3	순열 특성 중요도	섞기 전후 손실 차이	PART 2
4	Kernel SHAP 가중치	작은·큰 연합에 큰 가중치	PART 3
5	반사실 설명	가장 가까운 대안 찾기	PART 5
6	적분 그래디언트	완전성	PART 6

01

예제 1

세 특성의 샤플리 값

가상 부도 모델: A 연체 이력, B 부채비율, C 소득

여덟 개 연합의 예측 부도확률이 주어져 있다

v(S)는 특성 집합 S만 알 때의 예측값이다. 아무것도 모르면 기준값 0.10이다

연합 S	v(S)	연합 S	v(S)
∅ (기준값)	0.10	{A, B}	0.58
{A}	0.40	{A, C}	0.46
{B}	0.22	{B, C}	0.28
{C}	0.16	{A, B, C}	0.70

목표: 전체 증가분 0.70 − 0.10 = 0.60을 A, B, C에게 공정하게 나눈다

특성이 세 개면 순서 가중치는 1/3, 1/6, 1/3이다

|S|는 i를 뺀 연합의 크기다. 크기 1인 연합은 두 개라 각각 1/6씩 받는다

$$w(|S|) = \frac{|S|!\,(3-|S|-1)!}{3!} \Rightarrow\; w(0) = \frac{2}{6} = \frac{1}{3},\;\; w(1) = \frac{1}{6},\;\; w(2) = \frac{2}{6} = \frac{1}{3}$$

순서로 이해하기

- 세 특성의 합류 순서는 3! = 6가지다
- i가 맨 앞에 오는 순서는 2가지라 2/6
- i가 맨 뒤에 오는 순서도 2가지라 2/6

가중치 합 점검

- 1/3 + 1/6 + 1/6 + 1/3 = 1
- 크기 1 연합 두 개가 1/6씩 나눠 갖는다

연체 이력 A의 샤플리 값은 0.35다

네 연합 ∅, {B}, {C}, {B,C}에 A를 더했을 때의 증가분을 가중평균한다

$$\phi_A = \tfrac{1}{3}(0.40 - 0.10) + \tfrac{1}{6}(0.58 - 0.22) + \tfrac{1}{6}(0.46 - 0.16) + \tfrac{1}{3}(0.70 - 0.28)$$

$$= 0.10 + 0.06 + 0.05 + 0.14 = 0.35$$

순서	A의 한계 기여	순서	A의 한계 기여
A→B→C, A→C→B	0.40 − 0.10 = 0.30	C→A→B	0.46 − 0.16 = 0.30
B→A→C	0.58 − 0.22 = 0.36	B→C→A, C→B→A	0.70 − 0.28 = 0.42

순서 검산: (0.30 + 0.30 + 0.36 + 0.42 + 0.30 + 0.42) ÷ 6 = 2.10 ÷ 6 = 0.35

B는 0.17, C는 0.08이고 세 값의 합은 0.60이다

같은 가중치로 B와 C를 계산한 뒤 효율성 공리로 검산한다

$$\phi_B = \tfrac{1}{3}(0.12) + \tfrac{1}{6}(0.18) + \tfrac{1}{6}(0.12) + \tfrac{1}{3}(0.24) = 0.04 + 0.03 + 0.02 + 0.08 = 0.17$$

$$\phi_C = \tfrac{1}{3}(0.06) + \tfrac{1}{6}(0.06) + \tfrac{1}{6}(0.06) + \tfrac{1}{3}(0.12) = 0.02 + 0.01 + 0.01 + 0.04 = 0.08$$

$$\phi_A + \phi_B + \phi_C = 0.35 + 0.17 + 0.08 = 0.60 = v(\{A, B, C\}) - v(\varnothing) = 0.70 - 0.10$$

해석: 연체 이력이 증가분 0.60의 58%(0.35)를 설명한다. 고객 고지 1순위 사유다

02

예제 2

선형 SHAP

계수 × (값 − 평균)으로 바로 구한다

선형 모델에서는 SHAP 값을 한 줄로 계산한다

기준값 φ_0은 평균 입력에서의 예측값이다

$$\hat{f}(x) = 0.5 + 2x_1 - 1\,x_2, \qquad E[x_1] = 1,\ E[x_2] = 3, \qquad x = (2,\ 1)$$

$$\phi_1 = 2\,(2 - 1) = +2, \qquad \phi_2 = -1\,(1 - 3) = +2, \qquad \phi_0 = \hat{f}(E[x]) = 0.5 + 2 - 3 = -0.5$$

$$\phi_0 + \phi_1 + \phi_2 = -0.5 + 2 + 2 = 3.5 = \hat{f}(x) = 0.5 + 4 - 1$$

x_2는 왜 양수인가

- 계수는 음수지만 값이 평균보다 낮아 예측을 올렸다

교훈

- 계수의 부호만으로 기여 방향을 판단하지 않는다

03

예제 3

순열 특성 중요도

네 개 관측치로 섞기 전후의 손실을 비교한다

쓰이는 특성을 섞으면 손실이 늘고, 안 쓰이는 특성은 0이다

모델은 $f(x) = 2x_1$로 x_2를 쓰지 않는다. 손실은 평균제곱오차(MSE)다

관측치	x_1	x_2	y	원래 예측	x_1 섞은 값	섞은 뒤 예측	오차
1	1	5	2	2	2	4	+2
2	2	1	4	4	1	2	−2
3	3	4	6	6	4	8	+2
4	4	2	8	8	3	6	−2

$$FI_1 = \mathrm{MSE}_{\text{섞은 뒤}} - \mathrm{MSE}_{\text{원래}} = \frac{2^2 + 2^2 + 2^2 + 2^2}{4} - 0 = 4, \qquad FI_2 = 0 - 0 = 0$$

x_2를 섞어도 예측이 그대로라 중요도는 0이다

04

예제 4

Kernel SHAP 가중치

특성 네 개일 때 연합 크기별 가중치를 구한다

작은 연합과 큰 연합이 중간 연합보다 두 배 무겁다

π(z′) = (M−1) / [C(M,|z′|)·|z′|·(M−|z′|)]에 M = 4를 넣는다

$$M = 4: \quad \pi(1) = \frac{3}{4 \cdot 1 \cdot 3} = 0.25, \qquad \pi(2) = \frac{3}{6 \cdot 2 \cdot 2} = 0.125, \qquad \pi(3) = \frac{3}{4 \cdot 3 \cdot 1} = 0.25$$

왜 그런가

- 특성 하나만 켜거나 하나만 끈 연합은 그 특성의 효과를 가장 깨끗하게 보여 준다
- 크기 0과 4의 연합은 가중치가 무한대라 제약식으로 처리한다

실무 함의

- 표본 예산이 적을 때는 크기 1과 3의 연합부터 뽑는다
- shap의 KernelExplainer가 실제로 이렇게 표본을 고른다

05

예제 5

반사실 설명

거절된 고객에게 가장 가까운 승인 조건을 찾는다

예제 5

부채 1천만 원 상환이 더 가까운 반사실이다

가상 점수 모델. 소득과 부채의 단위는 천만 원이다. 소득 5, 부채 1.5인 고객

$$z = -2 + 0.5 \times \text{소득} - 1.0 \times \text{부채}, \qquad \text{승인 조건 } z \geq 0$$

$$z = -2 + 0.5(5) - 1.0(1.5) = -1.0 \;\Rightarrow\; \text{거절}$$

대안	바꾸는 값	필요한 변화	변화 크기
부채만 줄인다	−1.0 × 부채 = −0.5	1.5 → 0.5 (1천만 원 상환)	1.0
소득만 늘린다	0.5 × 소득 = 3.5	5 → 7 (2천만 원 증가)	2.0

거리가 같은 단위라면 변화가 작은 부채 상환이 더 가까운 반사실이다. 실무에서는 단위를 표준화한다

06

예제 6

적분 그래디언트

곱셈 모델에서 완전성을 확인한다

예제 6

적분 그래디언트의 합은 예측값의 변화와 정확히 같다

경로 x′ + α(x − x′) = (2α, 3α)에서 $\partial f/\partial x_1 = x_2 = 3\alpha$, $\partial f/\partial x_2 = x_1 = 2\alpha$

$$\hat{f}(x) = x_1 x_2, \qquad x = (2, 3), \qquad x' = (0, 0)$$

$$IG_1 = 2\int_0^1 3\alpha \, d\alpha = 2 \times 1.5 = 3, \qquad IG_2 = 3\int_0^1 2\alpha \, d\alpha = 3 \times 1 = 3$$

$$IG_1 + IG_2 = 6 = \hat{f}(2, 3) - \hat{f}(0, 0)$$

두 특성이 대칭으로 곱해지므로 6을 3과 3으로 똑같이 나눈다. 샤플리 값도 3과 3이다

여섯 예제가 확인한 세 가지 성질

본편으로 돌아가기 전에 정리한다

1

합이 맞는다

샤플리 값, 선형 SHAP, 적분 그래디언트 모두 예측의 변화를 남김없이 나눈다.

2

부호는 값과 평균의 관계에 달렸다

음의 계수라도 값이 평균보다 낮으면 예측을 올린다.

3

설명은 행동으로 이어진다

반사실 설명은 고객이 가장 적게 바꿔 결과를 바꾸는 길을 보여 준다.