설명가능 AI · XAI

설명가능한 머신러닝

금융 전문가의 관점에서 풀어본 샤플리 값과 SHAP

Explainable Machine Learning — Shapley Value · SHAP · XGBoost

점수만으로는 부족하다. 모델이 왜 그렇게 판단했는지 설명하고, 검증하고, 개선하는 법
원안 강의자료(2019)를 재구성하고 2026년 9월 기준 연구·규제 동향을 보강

이 강의의 세 가지 메시지

1

점수 뒤의 이유를 알아야 한다

사기 확률 0.5, 부도 확률 55%라는 숫자만으로는 고객 설명도, 모델 검증도, 개선도 할 수 없다

2

샤플리 값은 공정한 기여 배분의 유일한 해다

협력게임의 네 공리를 만족하는 배분은 하나뿐이고, SHAP은 이를 특성 기여도로 옮겼다

3

XGBoost 기본 중요도는 옵션마다 순위가 바뀐다

weight·cover·gain은 일관성이 없다. SHAP으로 전역·개별·상호작용·모니터링을 한 틀에서 본다

설명가능성 = 신뢰 · 검증 · 규제 대응의 공통 언어

강의 구성 — 일곱 개 파트

동기 → 기존 중요도의 한계 → 이론(샤플리) → 방법(SHAP) → 실습 → 심화 → 실무

파트	주제	핵심 질문
1	왜 설명가능성인가	잘 맞히는 모델도 엉뚱한 이유로 맞힐 수 있다 — 늑대·사기·대출 거절
2	기존 특성 중요도의 한계	XGBoost의 weight·cover·gain은 왜 서로 다른 순위를 내는가
3	샤플리 값	공정한 기여 배분을 수학적으로 어떻게 정의하는가
4	SHAP	샤플리 값을 모델 설명으로 옮기고, 빠르게 계산하는 법
5	XGBoost + SHAP 실습	요약도·의존도로 모델을 읽는다 (Adult 소득·가상 신용 데이터)
6	SHAP 심화	상호작용 값과 모델 모니터링 (사망률·수술시간 모델)
7	금융 실무와 한계	거절 사유·규제·SHAP의 함정·최신 동향

01

PART 1 · 동기

왜 설명가능성인가

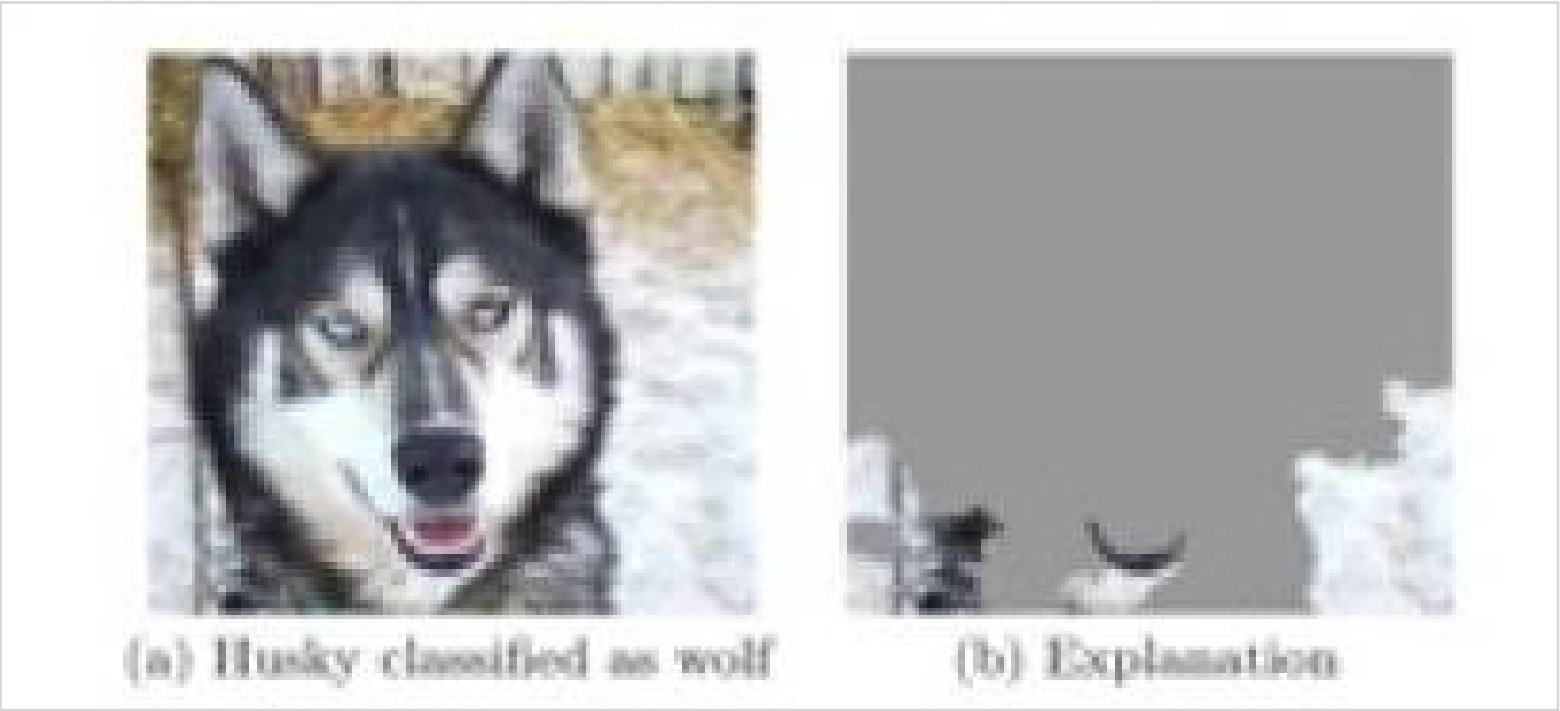
잘 맞히는 모델도 엉뚱한 이유로 맞힐 수 있다

설명가능성의 동기 ① 늑대와 허스키

머신러닝은 이들을 놀랍게 잘 분류했으나, 이유는 뜻밖의 곳에 있었다

에피소드 · LIME(2016)

- 연구진이 늑대 사진에만 눈(snow) 배경이 있도록 학습 이미지 20장을 일부러 골랐다
- 설명을 열어 보니 모델은 동물이 아니라 흰 눈을 보고 늑대라 판정했다
- 설명을 본 뒤 모델을 믿는다는 대학원생은 27명 중 10명 → 3명



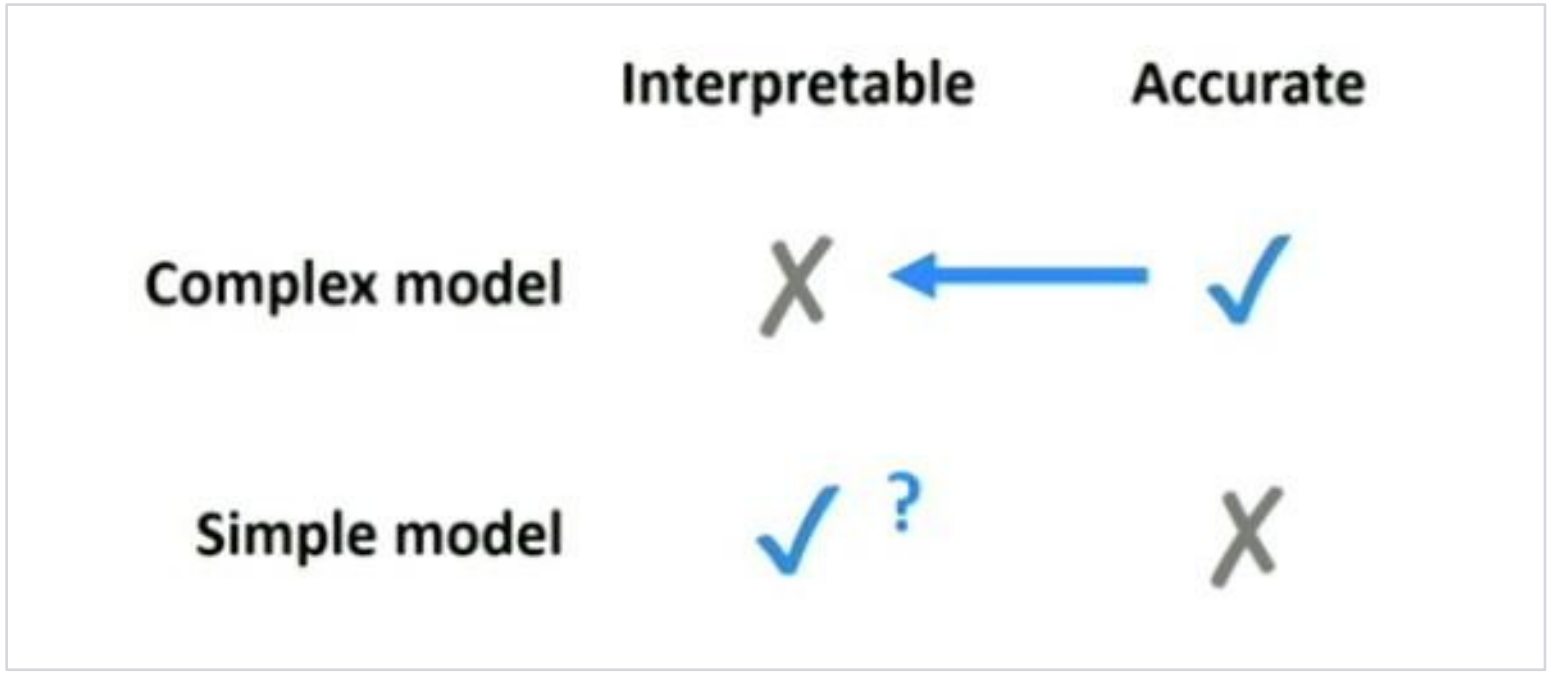
Ribeiro·Singh·Guestrin, “Why Should I Trust You?”, KDD 2016

설명가능성의 동기 ② 단순함 대 해석가능성

복잡한 모델은 예측력은 좋으나 블랙박스라 해석하기 어렵다

읽는 법

- 화살표: 정확한 복잡 모델에 해석가능성을 되찾아 주자는 것이 XAI의 목표
- 단순 모델의 "?": 변수가 수백 개인 로지스틱 회귀도 사실상 해석이 어렵다
- 반론도 있다: 고위험 결정엔 처음부터 해석 가능한 모델을 쓰라(Rudin, 2019) → Part 7



설명가능성의 동기 ③ 신용카드 사기 탐지

신용카드 사기의 확률은? 도대체 이 확률은 어디서 나오는 것인가?

현장의 질문

- 승인·거절은 결제 순간 초 단위로 결정된다
- 모델은 확률 하나만 내놓는다
- 조사팀·고객센터는 "왜 막았나?"에 답해야 한다

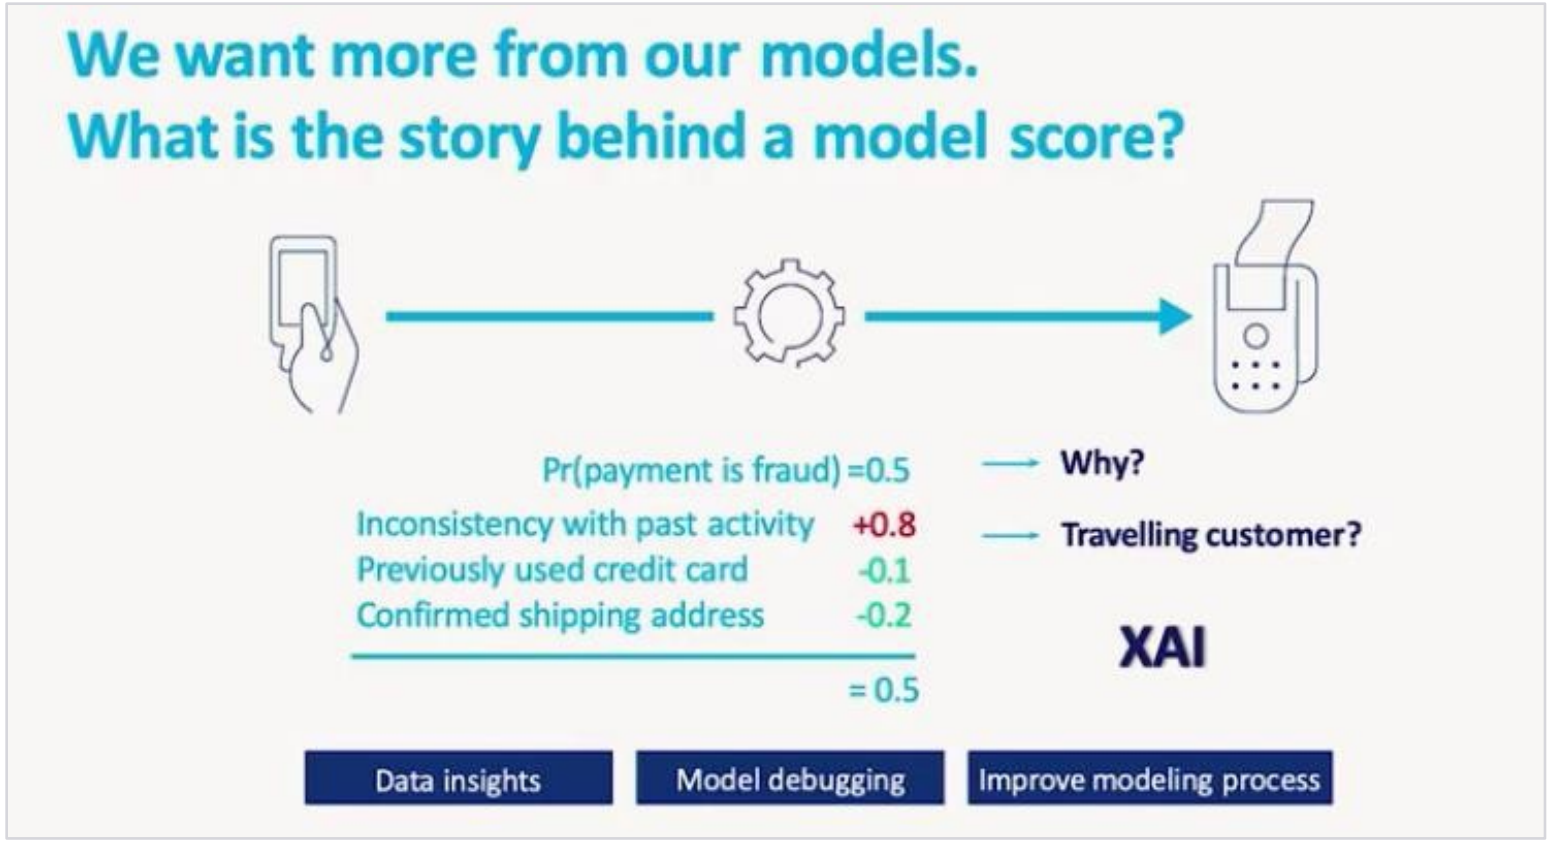


설명가능성의 동기 ④ 점수 뒤의 이야기

점수만 아는 것으로는 부족하다. 그 이유와 배경을 알아야 설명·검증·개선이 가능하다

XAI가 주는 것

- 분해: 과거 행동과 불일치 +0.8, 쓰던 카드 −0.1, 확인된 배송지 −0.2 → 합계 0.5
- 가장 큰 요인이 "과거와 다른 행동"이면 여행 중인 고객일 수 있다 → 오탐을 줄이는 규칙
- 세 가지 효용: 데이터 통찰 · 모델 디버깅 · 모델링 과정 개선

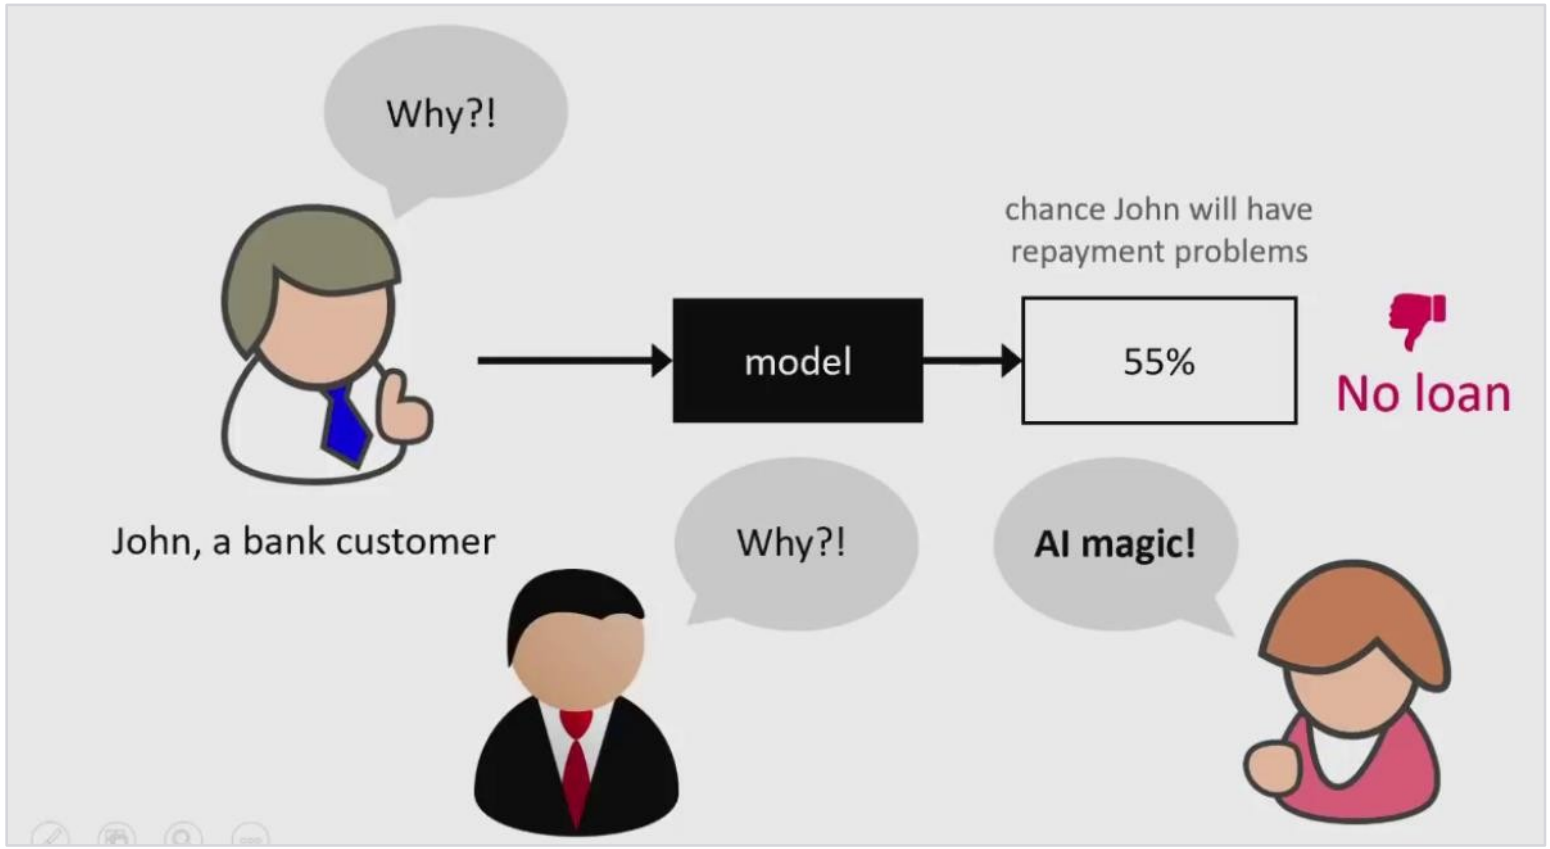


설명가능성의 동기 ⑤ 대출 거절을 어떻게 설명할까

유럽 GDPR은 자동화된 결정의 이유를 설명하라고 요구한다

쟁점

- 고객의 “왜 거절입니까?”에 “AI가 그랬습니다”는 답이 될 수 없다
- GDPR 제22조·제15조(1)(h): 자동화 결정에 대해 “관련 로직에 대한 의미 있는 정보”
- 거절 이유가 인종·성별 같은 차별 요인일 수도 있다 — 설명 없이는 확인할 수 없다



해석가능성의 정의와 분류

용어는 문헌마다 섞여 쓰이지만, 이 강의는 아래 구분을 따른다

구분	뜻	예
해석가능성 (interpretability)	사람이 모델 구조 자체를 이해할 수 있는 정도	선형회귀 계수, 얕은 트리
설명가능성 (explainability)	복잡한 모델의 판단을 사후에 이해 가능한 형태로 풀어내는 것	SHAP, LIME
전역(global) vs 국지(local)	모델 전체의 경향 vs 예측 한 건의 이유	특성 중요도 vs 한 고객의 거절 사유
내재적(intrinsic) vs 사후적(post-hoc)	모델 자체가 설명 vs 학습 후 별도 도구로 설명	GAM·EBM vs SHAP·PDP
모델 특화 vs 모델 무관(agnostic)	특정 구조를 이용 vs 입력·출력만 이용	TreeSHAP vs KernelSHAP·LIME

XAI 방법 지도

SHAP은 여러 방법 중 하나다 — 범위(전역·국지)와 모델 의존성으로 자리를 잡는다

방법	범위	모델	핵심 아이디어
순열 중요도	전역	무관	특성을 섞었을 때 성능이 얼마나 떨어지나
PDP · ICE	전역·개별	무관	특성 값을 바꿔 가며 평균·개별 예측 변화를 추적
ALE	전역	무관	상관된 특성에서 편향이 작은 PDP 대안
LIME	국지	무관	예측 주변을 단순한 선형 모델로 근사
SHAP	국지 → 전역	무관·특화	샤플리 값으로 기여 배분, 합이 예측값과 일치
반사실 설명	국지	무관	무엇이 달라졌다면 결과가 바뀌었나
EBM · GAM	전역	내재적	처음부터 가법 구조로 학습해 그대로 읽는다

케이스 · 애플카드 한도 논란 (2019–2021)

차별은 없었다는 결론에도 “블랙박스”라는 불신은 남았다

20배
한도 차이 주장 (2019.11 트윗)

약 40만 명
감독 당국이 검토한 뉴욕 신청자

위반 없음
뉴욕주 금융감독청 결론 (2021.3)

경과

- 한 창업자가 “아내 한도가 나의 1/20”이라 트윗, 애플 공동창업자도 비슷한 사례 제기
- 뉴욕주 금융감독청(NYDFS)이 발급사 골드만삭스 조사
- 같은 신용 특성의 남녀는 비슷한 결과 — 차별 증거 없음

교훈

- 보고서도 고객이 “블랙박스 알고리즘”에 불만을 느꼈다고 지적
- 개별 결정의 사유를 고객 언어로 설명하는 체계가 없으면 평판 비용이 생긴다
- 이후 심사 과정 안내와 이의 절차를 보강했다

NYDFS, Report on Apple Card Investigation (2021.3)

02

PART 2 · 기존 특성 중요도

XGBoost 기본 중요도의 한계

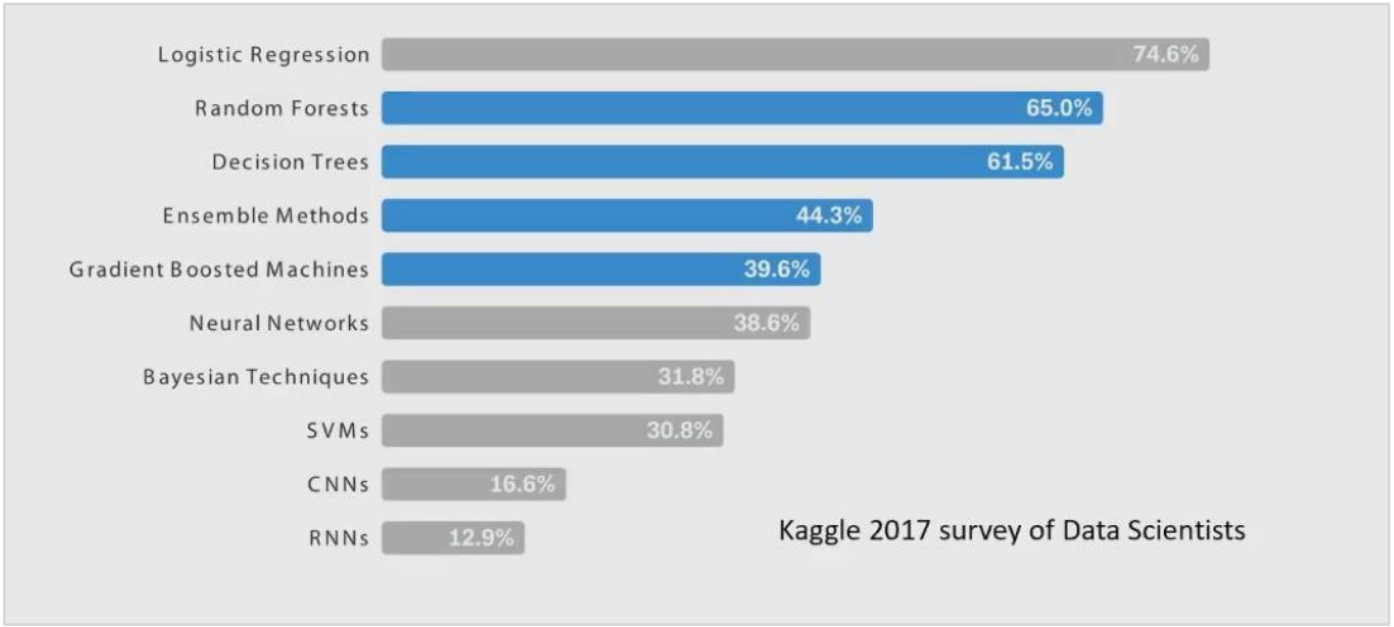
옵션을 바꾸면 순위가 바뀐다 — 무엇을 믿어야 하나

트리 모델은 가장 인기 있는 복잡한 모델

실무에서 가장 많이 쓰는 복잡한 모델은 트리 계열이다 — 그래서 트리 모델의 설명이 중요하다

읽는 법 · 보강

- 파랑 막대: 트리 계열(랜덤포레스트·의사결정트리·앙상블·GBM)
- 원 슬라이드 수치는 2017 Kaggle 공식 보고서(LR 63.5%·DT 49.9%·RF 46.3%)와 달라 특정 응답자 집단 기준으로 보인다
- 표 형식 데이터에선 지금도 트리 부스팅이 딥러닝보다 강하다 (Grinsztajn 외, NeurIPS 2022)



Kaggle, State of Data Science & ML Survey 2017

XGBoost 특성 중요도 — 세 가지 옵션

xgboost.plot_importance(model, importance_type=...)

옵션	정의	주의할 편향
가중치 (weight)	모든 트리에서 그 특성으로 데이터를 분할한 횟수	값이 많은 연속형 특성에 유리
커버리지 (cover)	그 특성의 분할을 통과한 훈련 표본 수(헤시안 합)의 평균	표본을 많이 가르는 분할만 크게 본다
개선도 (gain)	그 특성으로 분할할 때 얻은 평균 훈련 손실 감소	트리 아래쪽 분할을 과대평가하기 쉽다

실무 메모 · total_gain·total_cover(합계)까지 다섯 가지다. plot_importance 기본값은 weight, 사이킷런 API의 feature_importances_ 기본값은 gain — 무엇을 쓰느냐에 따라 보고서의 "중요 변수"가 달라진다

gain과 cover는 무엇을 재는가

XGBoost는 손실의 1차·2차 미분(G, H)으로 분할을 고른다 — 중요도도 여기서 나온다

$$\text{Gain} = \frac{1}{2}\left[\frac{G_L^2}{H_L+\lambda} + \frac{G_R^2}{H_R+\lambda} - \frac{(G_L+G_R)^2}{H_L+H_R+\lambda}\right] - \gamma$$

$$\text{Cover} = \sum_{i \in \text{node}} h_i, \qquad h_i = \frac{\partial^2 \ell(y_i, \hat{y}_i)}{\partial \hat{y}_i^2}$$

기호

- G, H: 노드 안 표본들의 1차 미분(gradient)·2차 미분(hessian) 합
- λ, γ: 잎 가중치·잎 개수에 대한 규제항

cover의 뜻

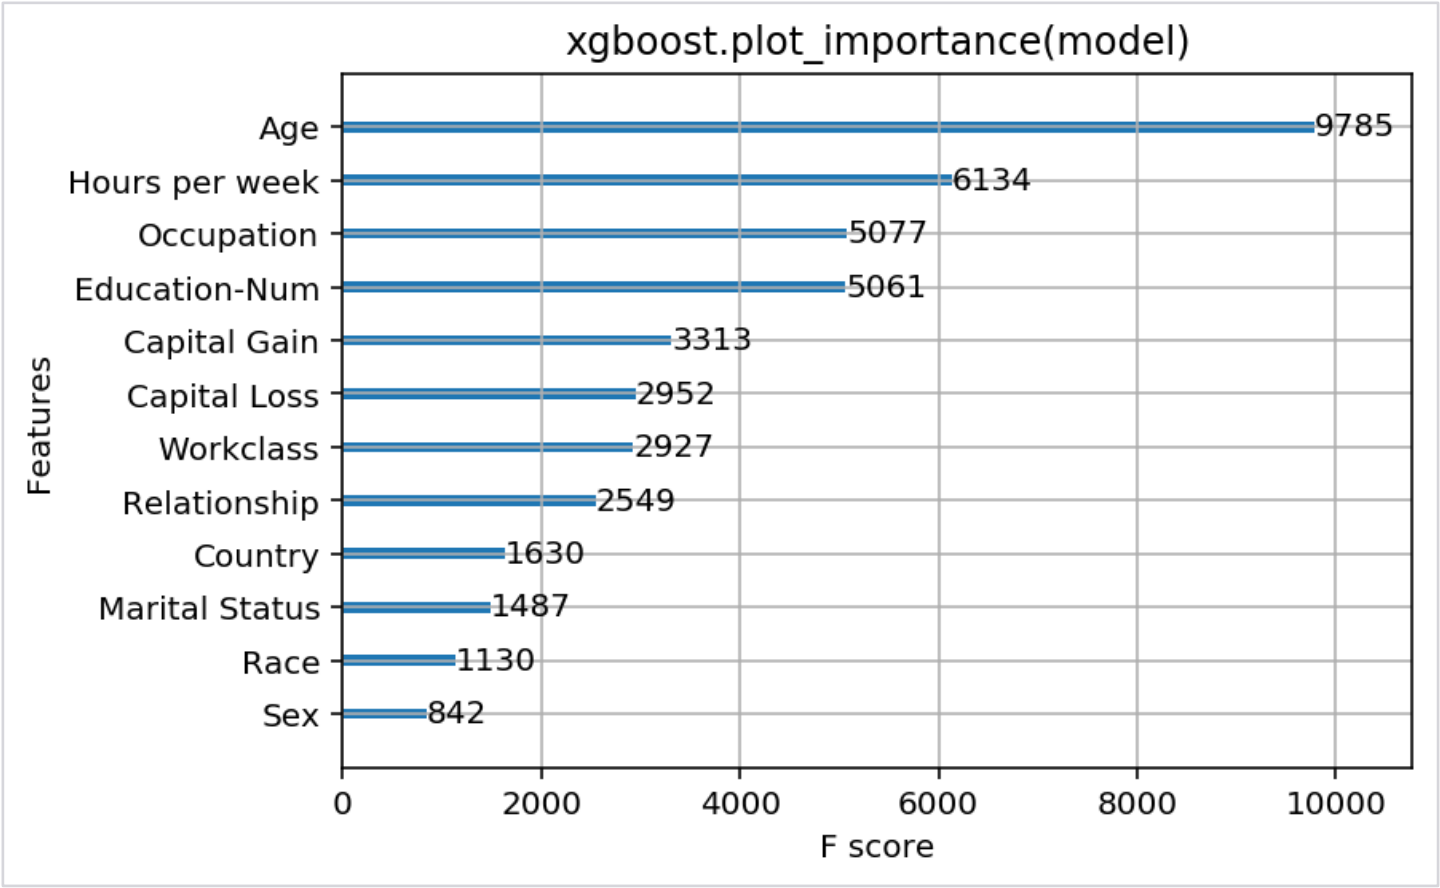
- 제곱오차면 h = 1 → cover = 표본 수
- 로지스틱이면 h = p(1−p) → 확신이 강한 표본은 덜 센다

글로벌 특성 중요도 척도 — XGBoost 기본값

UCI Adult 인구조사 데이터: 연소득 5만 달러 초과 여부를 예측하는 XGBoost 모델

무엇을 보나

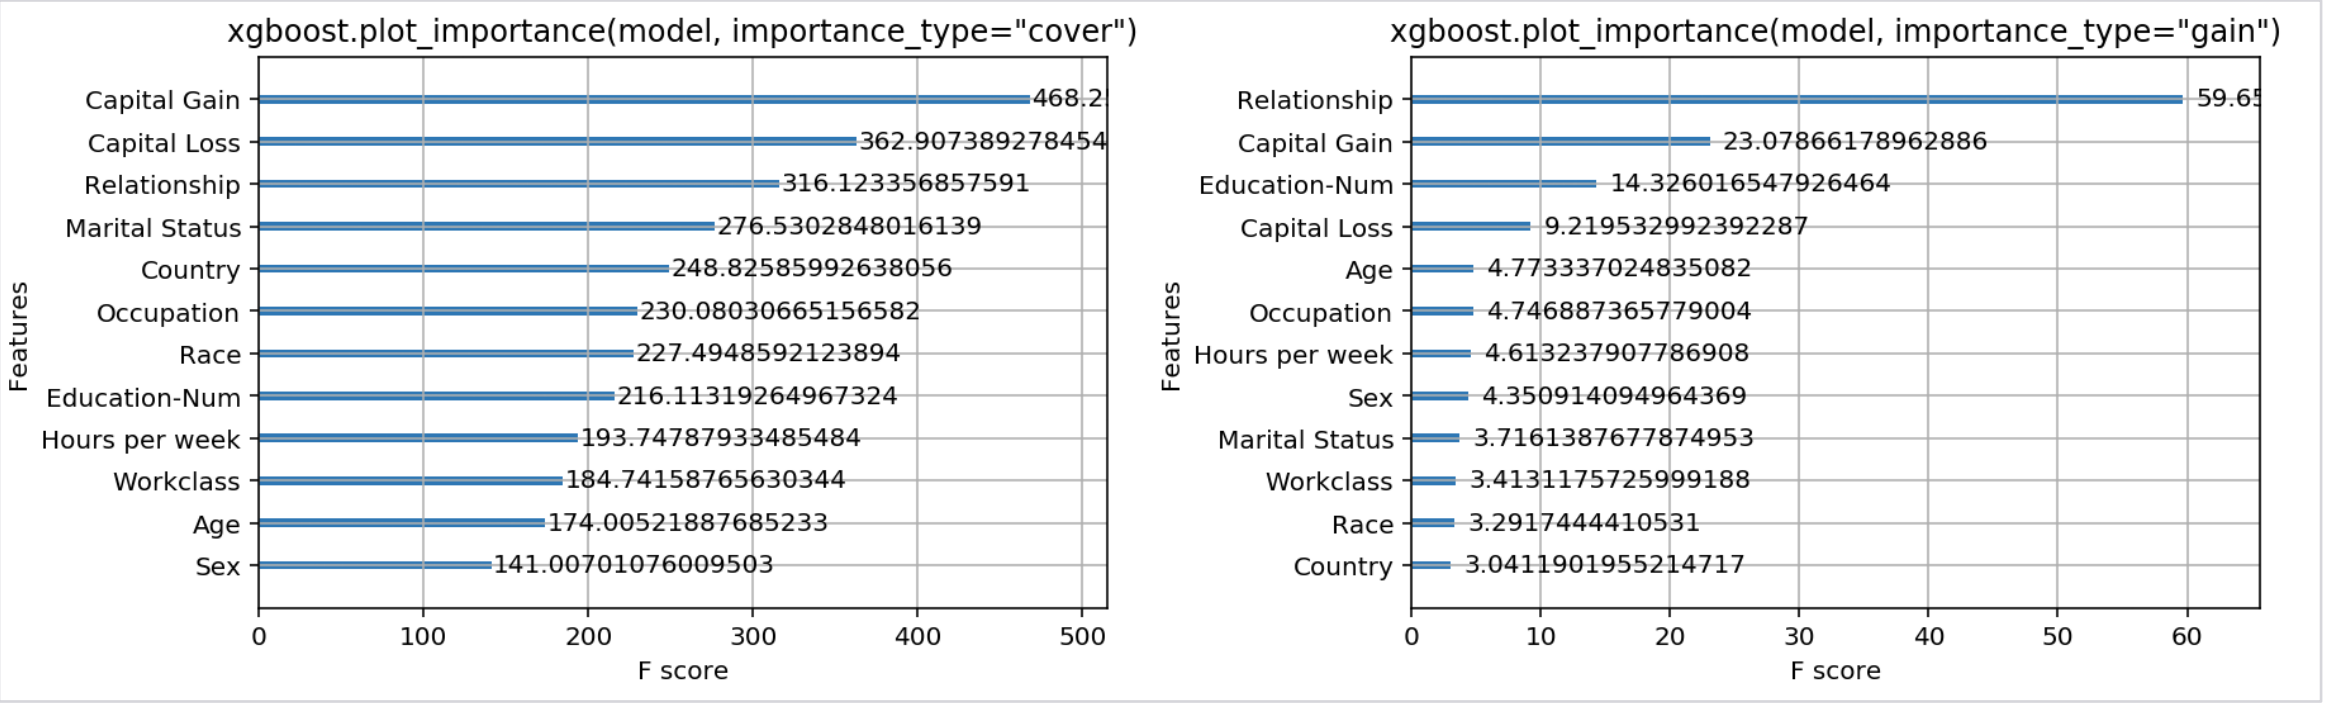
- plot_importance의 기본값은 weight(분할 횟수)
- Age가 압도적 1위, Sex가 최하위
- 정말 Age가 가장 중요한가? 옵션을 바꿔 보자



Lundberg, “Interpretable Machine Learning with XGBoost” (2018)

옵션에 따라 중요도의 순서가 달라진다

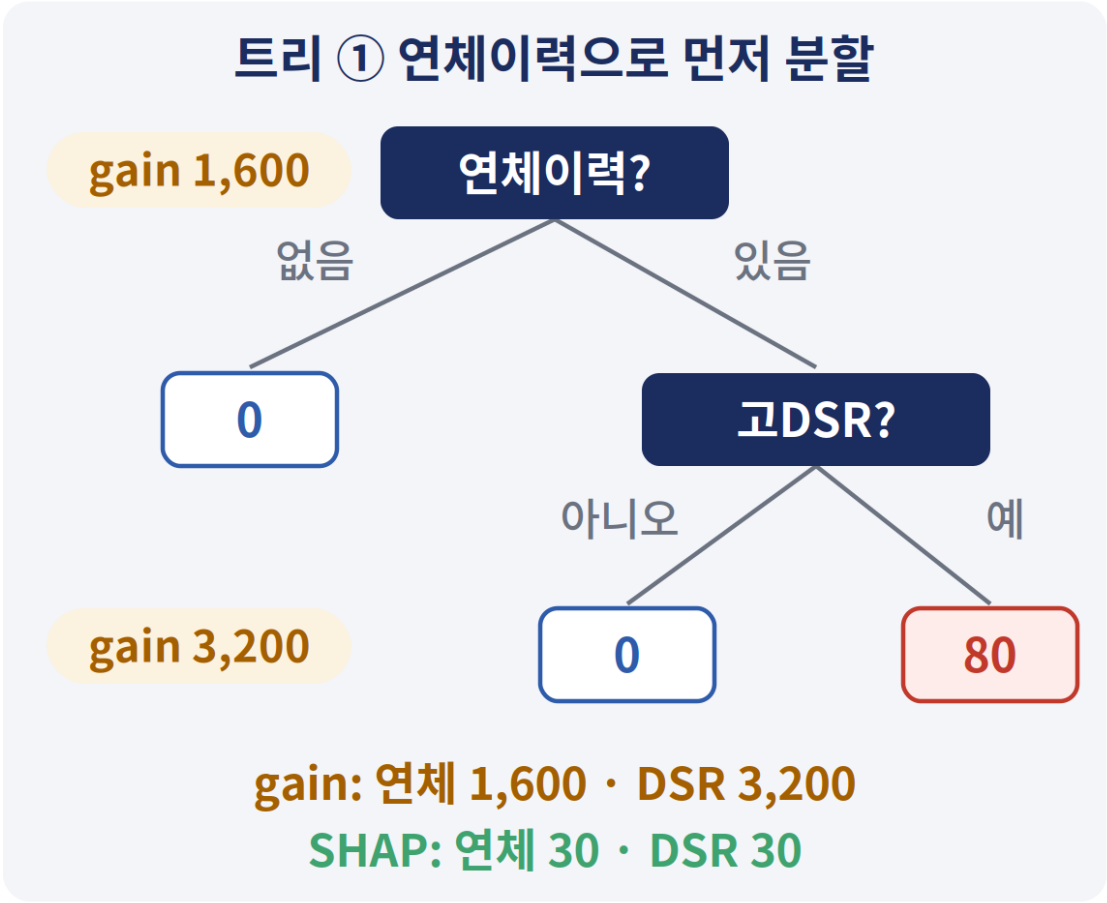
1위가 weight는 Age, cover는 Capital Gain, gain은 Relationship — 같은 모델인데 셋 다 다르다

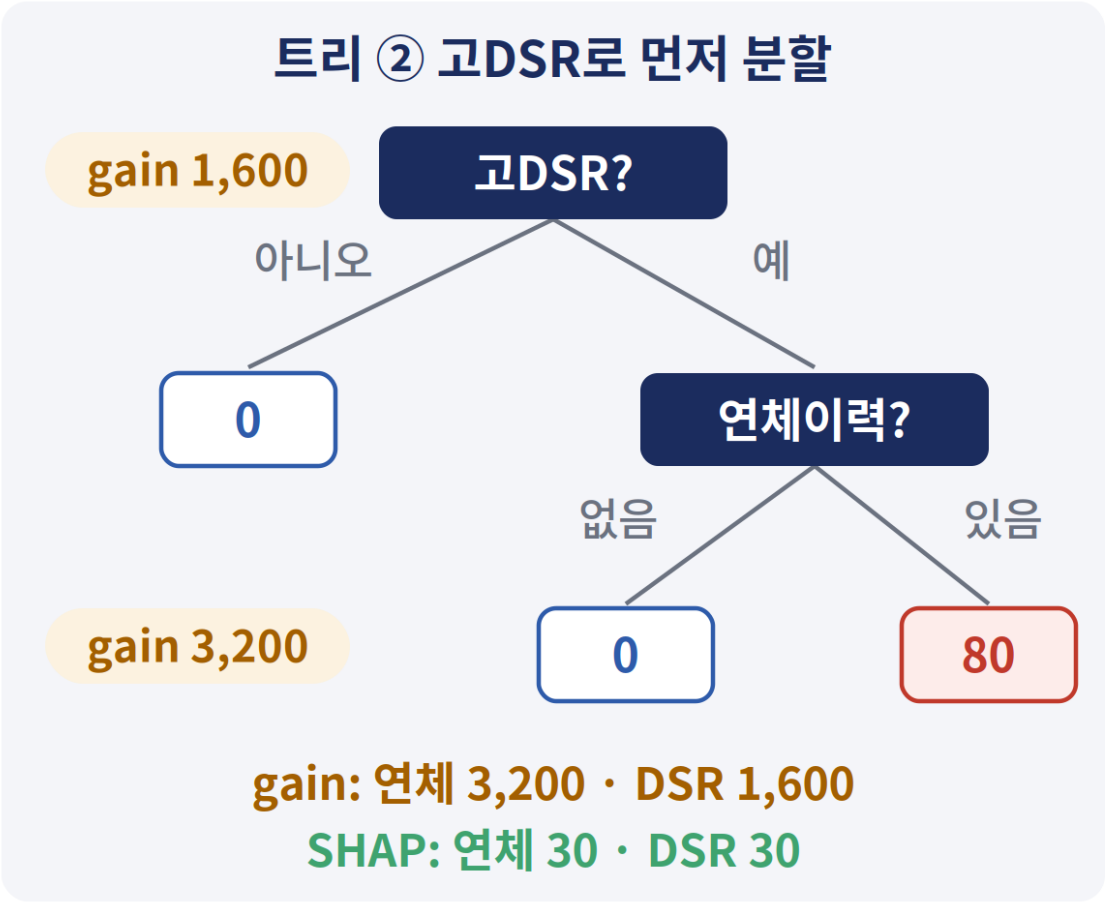


▶ 실망스럽게도 옵션에 따라 중요도의 순서가 달라진다 — 어느 것을 보고해야 하나?

왜 흔들리나 — 분할 순서만 바꿔도 gain이 뒤집힌다

둘 다 "연체 있음 AND 고DSR일 때만 80점"인 같은 함수 — gain은 순서를 따라가고 SHAP은 그대로다





좋은 중요도의 두 조건 — 일관성과 정확성

Lundberg(2018): weight·cover·gain은 일관성을 어기고, 샤플리 값(TreeSHAP)만 두 조건을 모두 지킨다

$$f'_x(S) - f'_x(S \setminus i) \;\geq\; f_x(S) - f_x(S \setminus i) \;\; \forall S \quad \Longrightarrow \quad \phi_i(f', x) \geq \phi_i(f, x)$$

일관성 (consistency)

- 모델이 어떤 특성에 더 의존하도록 바뀌면, 그 특성의 중요도는 줄어서는 안 된다

정확성 (local accuracy)

- 특성 기여도를 모두 더하면 기준값 대비 예측값 변화와 정확히 같아야 한다

고객(연체 있음·고DSR)	연체이력 SHAP	고DSR SHAP	예측 − 평균
모델 A: AND일 때만 80	30	30	80 − 20 = 60
모델 B: A + 고DSR만으로 +10	30	35 ↑	90 − 25 = 65

가상 신용 데이터로 재현 — 실험 설계

정답(참 모형)을 아는 데이터로 네 가지 중요도를 비교한다

실험 설계 (가상 데이터)

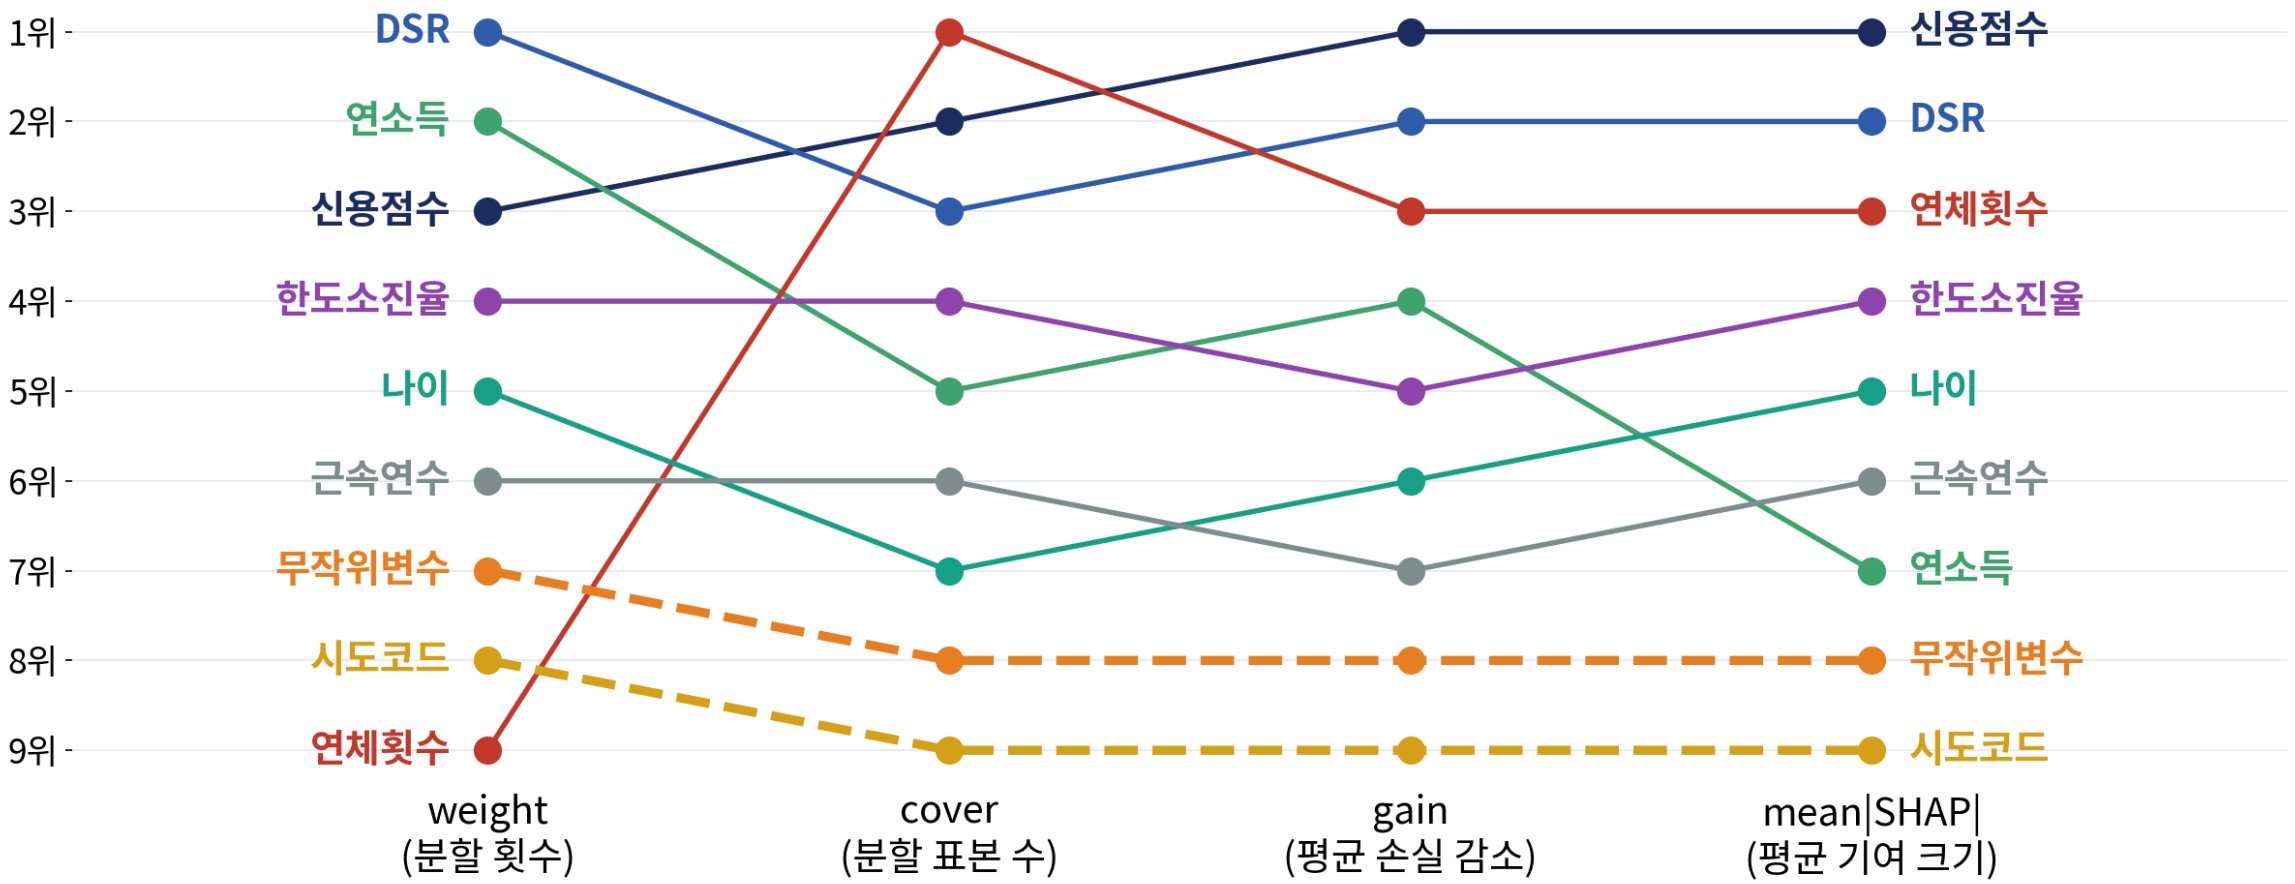
- 대출 3만 건, 로지스틱 참 모형에서 부도 생성 (부도율 12.7%)
- 참 모형 주요 요인: 신용점수·DSR·연체횟수·한도소진율, DSR 효과는 연소득 4천만 원 미만에서 1.8배
- 무작위변수·시도코드: 부도와 무관(정답 = 영향 0)
- XGBoost(트리 400개, 깊이 4) 학습 후 weight·cover·gain·mean|SHAP| 비교

관찰

- weight는 연체횟수(값이 0·1·2…뿐)를 9위로 — 중요해서가 아니라 분할할 기회가 적을 뿐이다
- cover는 같은 연체횟수를 1위로 올린다
- gain과 SHAP은 상위 순위가 비슷하다. 그러나 일관성이 보장되고 한 건씩 분해되는 것은 SHAP 뿐이다

같은 모델, 네 가지 순위

연체횟수: weight 9위 → cover 1위 → gain·SHAP 3위 (점선 = 부도와 무관한 변수)



03

PART 3 · 게임이론

샤플리 값 (Shapley Value)

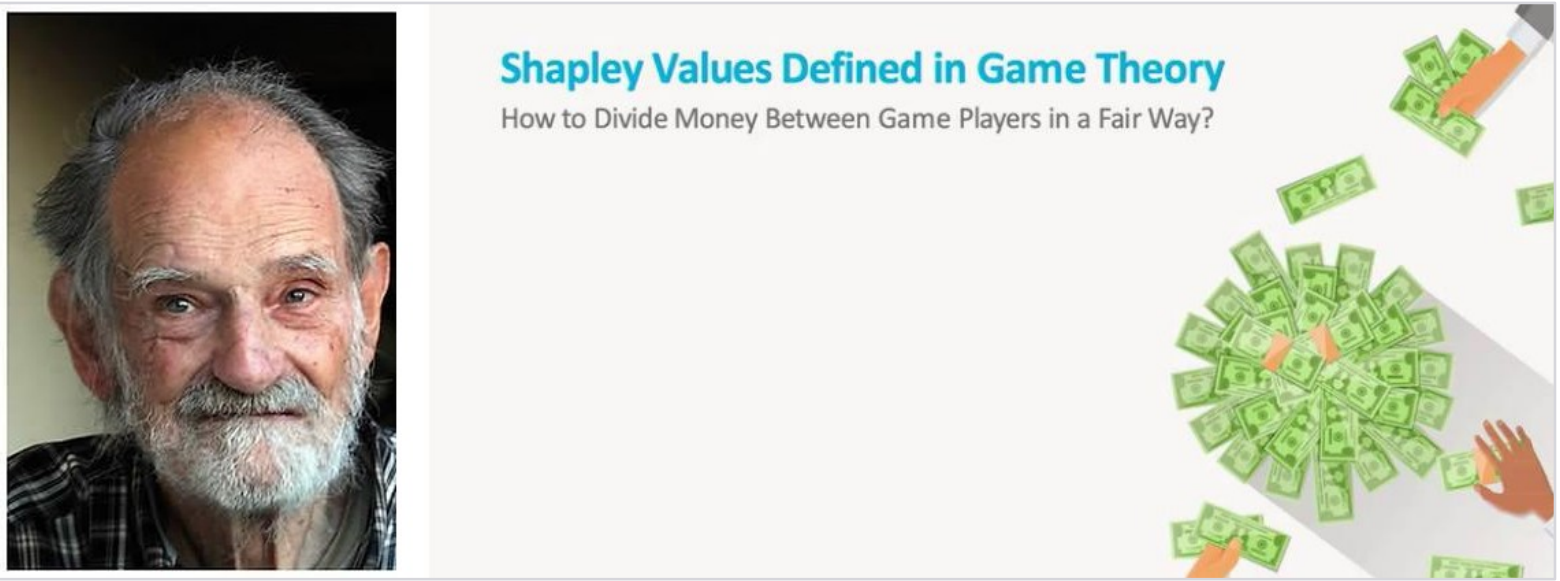
협력게임에서 각 플레이어의 공헌도를 공정하게 나누는 법

샤플리 값 — 게임이론에서 온 공정한 배분

협력게임에서 각 플레이어의 공헌도를 측정하는 값. 머신러닝에서는 플레이어가 특성이다

배경

- 로이드 섀플리(1923–2016), 1953년 논문 “A Value for n-Person Games”
- 2012년 노벨경제학상(앨빈 로스와 공동) — 안정적 배분 이론과 시장 설계
- 질문: 함께 번 돈을 각자에게 어떻게 공정하게 나눌까?



협력게임 ↔ 머신러닝 설명 — 용어 대응

개별 예측값과 평균 예측값의 차이를 특성들에게 “공정하게” 나눠 주는 문제로 바꿔 읽는다

협력게임	머신러닝 설명
플레이어 집합 N	특성(feature) 집합 — 신용점수, DSR, 소득 …
연합 S ⊆ N	값을 알고 있는 특성들의 부분집합
가치함수 v(S)	S만 알 때의 예측 기댓값
나눌 총액 v(N) − v(∅)	이 고객의 예측값 f(x) − 평균 예측값 E[f(X)]
배분 φ(i)	특성 i의 기여도 = SHAP 값

샤플리 값 = 모든 합류 순서에서 특성 i가 더해 준 몫(한계기여)의 평균

샤플리 값의 정의

특성 i가 연합 S에 합류할 때 늘어나는 가치를, 가능한 모든 경우에 대해 가중평균한다

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!\,(n - |S| - 1)!}{n!} \Big[v\big(S \cup \{i\}\big) - v(S) \Big]$$

같은 값, 순서 평균 형태

$$\phi_i(v) = \frac{1}{n!} \sum_{\pi \in \Pi(N)} \Big[v\big(P_i^{\pi} \cup \{i\}\big) - v\big(P_i^{\pi}\big) \Big]$$

P: 순서 π에서 i보다 먼저 들어온 특성들의 집합

읽는 법

- 대괄호: i가 합류할 때의 한계기여(marginal contribution)
- 가중치: S 앞뒤 순서의 경우의 수 — 모든 합류 순서를 똑같이 대우
- 즉 n!개 순서에서 i의 한계기여를 평균한 값

공정성의 네 가지 공리

네 공리를 모두 만족하는 배분 규칙은 샤플리 값 하나뿐이다 (Shapley, 1953)

공리	뜻	신용평가로 읽으면
효율성 (efficiency)	기여도의 합 = 나눌 총액	기여도 합 = 이 고객 부도확률 − 평균 부도확률
대칭성 (symmetry)	역할이 같으면 몫도 같다	효과가 완전히 같은 두 변수는 같은 기여
더미 (null player)	아무 기여가 없으면 0	모델이 쓰지 않는 변수의 기여는 0
가법성 (additivity)	두 게임의 합을 나눈 몫 = 각 몫의 합	트리 400개의 SHAP = 트리별 SHAP의 합

$$\sum_{i=1}^{n} \phi_i = v(N) - v(\varnothing)$$

예제 ① 고객 A의 부도확률 30%를 나눠 보자

고객 A: 연체이력 있음 · DSR 높음 · 소득 높음 (가상 수치)

알고 있는 특성 S	예측 부도확률 v(S)
없음 (ø)	10%
연체이력	22%
DSR	16%
소득	8%
연체이력 + DSR	34%
연체이력 + 소득	19%
DSR + 소득	13%
세 특성 모두 (N)	30%

읽는 법

- v(ø) = 10%: 아무것도 모를 때 = 평균 고객
- v(N) = 30%: 모델이 고객 A에게 준 예측
- 나눌 몫: 30 − 10 = 20%p
- 소득을 알면 오히려 낮아진다(22% → 19%) — 기여가 음수일 수 있다

예제 ② 여섯 가지 합류 순서의 평균

각 순서에서 특성이 들어올 때 늘어난 부도확률(%p)을 적고, 열별로 평균한다

합류 순서	연체이력	DSR	소득
연체 → DSR → 소득	+12	+12	−4
연체 → 소득 → DSR	+12	+11	−3
DSR → 연체 → 소득	+18	+6	−4
DSR → 소득 → 연체	+17	+6	−3
소득 → 연체 → DSR	+11	+11	−2
소득 → DSR → 연체	+17	+5	−2

연체이력 φ

+14.5%p

DSR φ

+8.5%p

소득 φ

−3.0%p

합계 = 30 − 10

+20.0%p

문제는 계산량이다

특성 M개면 연합이 2^M개 — 그대로는 실무에 쓸 수 없다

$$\underbrace{O\left(T\,L\,2^{M}\right)}_{\text{brute force}} \longrightarrow \underbrace{O\left(T\,L\,D^{2}\right)}_{\text{TreeSHAP}}$$

문제

- 특성 30개면 연합 약 10억 개(2^30)
- 설명 한 건마다 모델을 수억 번 평가해야 한다
- T: 트리 수, L: 최대 잎 수, D: 최대 깊이

해법

- 샘플링 근사: KernelSHAP, 순열 샘플링
- 구조 활용: TreeSHAP은 트리를 따라가며 정확한 값을 다항식 시간에 계산
- XGBoost 모델이면 수만 건도 몇 초

04

PART 4 · SHAP

SHAP — 샤플리 값으로 모델을 설명하다

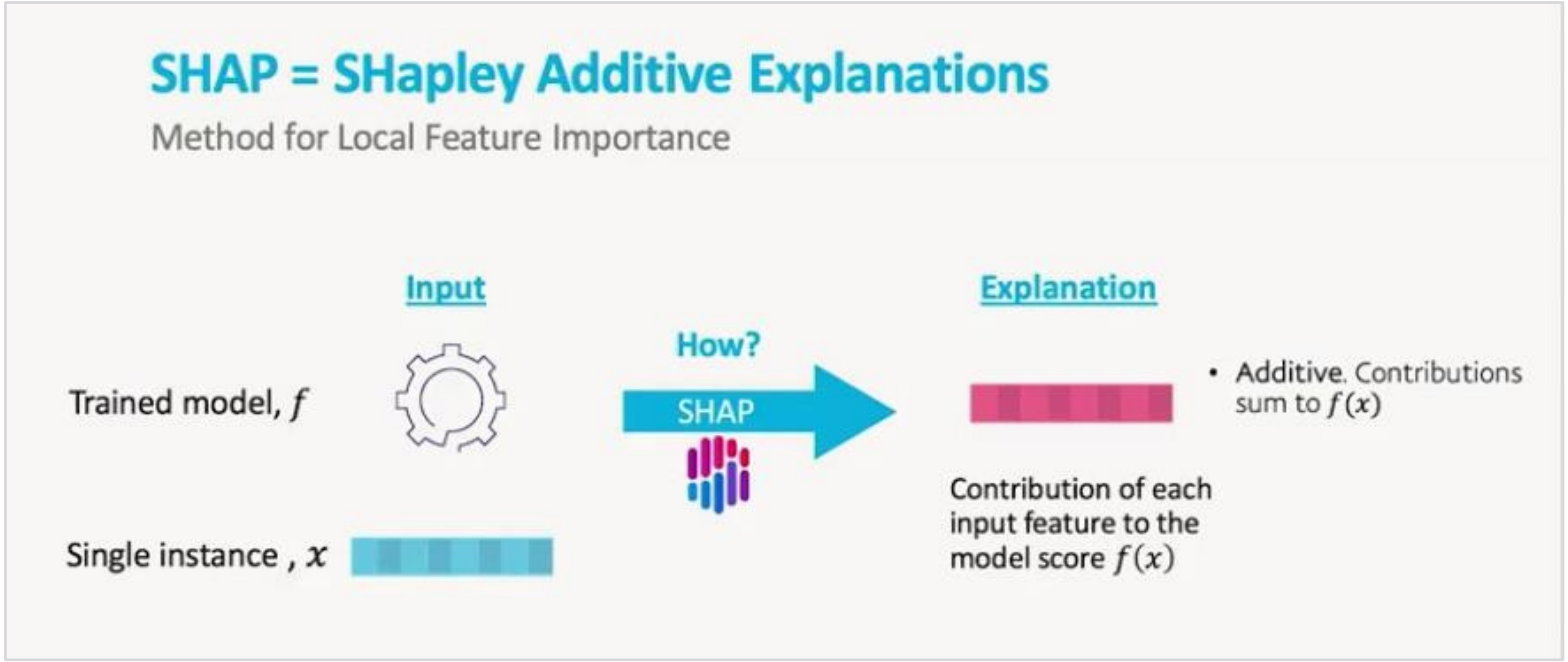
SHapley Additive exPlanations (Lundberg & Lee, NeurIPS 2017)

SHAP = SHapley Additive exPlanations

샤플리 값은 일관성과 가산성을 갖추고 있다. SHAP은 이를 기반으로 국지적 특성 중요도를 추출한다

구조

- 입력: 학습된 모델 f와 설명할 관측치 x 하나
- 출력: 특성별 기여도 벡터
- 가산성: 기준값에 기여도를 모두 더하면 f(x)



SHAP의 분해식과 세 가지 성질

예측값 = 평균 예측(기준값) + 특성별 기여도의 합

$$f(x) = \underbrace{\mathbb{E}\big[f(X)\big]}_{\phi_0 :\ \text{base value}} + \sum_{i=1}^{M} \phi_i(x)$$

$$g(z') = \phi_0 + \sum_{i=1}^{M} \phi_i \, z'_i, \qquad z' \in \{0,1\}^M$$

성질	뜻	근거
국지 정확성 (local accuracy)	기준값 + 기여도 합 = 예측값	효율성 공리와 같다
결측성 (missingness)	입력에 없는 특성의 기여 = 0	더미 공리에 대응
일관성 (consistency)	모델이 특성에 더 의존하면 기여는 줄지 않는다	세 성질을 만족하는 해는 샤플리 값뿐

“빠진 특성”은 어떻게 흉내 내나 — 가치함수 선택

v(S)를 정의하는 방법이 두 가지이고, 상관된 특성이 있으면 답이 달라진다

$$v_x(S) = \mathbb{E}\left[f(X) \mid X_S = x_S\right]$$

$$v_x(S) = \mathbb{E}_{X_{\bar{S}}}\left[f(x_S, X_{\bar{S}})\right]$$

관측적(조건부) — 데이터에 충실

- 나머지 특성을 x_S와 함께 나타나는 분포에서 채운다
- 상관 구조를 지키지만, 모델이 쓰지 않는 특성에도 기여가 새어 나간다
- TreeExplainer에 배경 데이터를 주지 않으면 쓰는 tree_path_dependent가 이에 가깝다

개입적(interventional) — 모델에 충실

- 배경 데이터(data=…)에서 나머지 특성을 통째로 바꿔 끼운다
- 모델이 실제로 쓰는 특성만 기여를 받는다
- 나이 22세·근속 30년 같은 비현실적 조합이 생길 수 있다

Chen·Janizek·Lundberg·Lee, “True to the Model or True to the Data?” (2020)

SHAP 추정기 가족

모델 종류에 맞춰 추정기를 고른다 — 트리 모델이면 TreeSHAP이 정답

추정기	대상 모델	방식	속도
TreeSHAP	XGBoost·LightGBM·CatBoost·랜덤포레스트	트리 구조로 정확 계산, $O(TLD^2)$	빠름
KernelSHAP	모든 모델	샤플리 가중치를 쓴 가중 선형회귀로 근사	느림
Linear · Exact	선형 모델 · 특성이 적은 모델	해석적 계산 · 완전 열거	빠름 · 소규모
DeepSHAP · GradientSHAP	신경망	DeepLIFT·기울기 기반 근사	중간

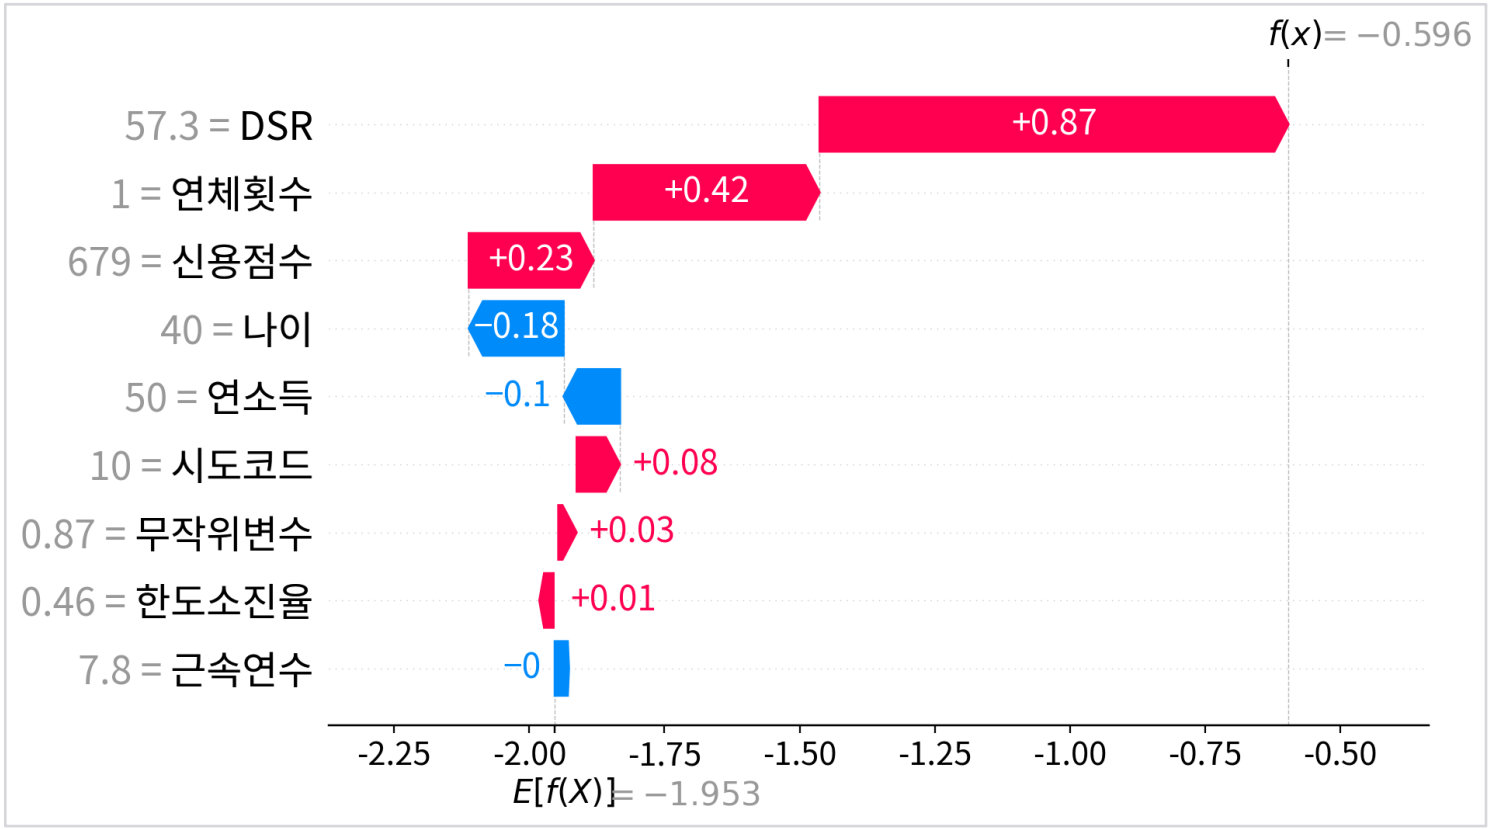
XGBoost·LightGBM은 SHAP을 내장한다 — predict(..., pred_contribs=True)

한 고객의 부도 예측을 분해하다 (워터폴)

가상 신용 모델 · 부도확률 35.5%로 거절된 고객 한 명 — 단위는 로그 오즈(log-odds)

읽는 법

- 아래 E[f(X)] = −1.953: 평균 고객(부도확률 12.4%)
- 빨강은 위험을 올린 요인, 파랑은 낮춘 요인
- 합산 f(x) = −0.596 → 부도확률 35.5%
- 시도코드 +0.08: 무관한 변수에도 작은 기여가 잡힌다 → 사유에서 뺄 변수 목록을 관리



05

PART 5 · 실습

XGBoost + SHAP으로 모델 읽기

요약도(beeswarm)와 의존도(scatter)로 전역 효과와 개별 효과를 함께 본다

코드 — 모델 학습부터 네 가지 그림까지

2026년 9월 기준 shap 0.52 · XGBoost 3.x의 권장 API

[코드] Python

```
import shap, xgboost as xgb
model = xgb.XGBClassifier(n_estimators=400, max_depth=4).fit(X, y)
explainer = shap.TreeExplainer(model)        # 트리 전용 정확 계산
sv = explainer(X)                            # Explanation 객체
shap.plots.beeswarm(sv)                      # 요약도 (구 summary_plot)
shap.plots.scatter(sv[:, "Age"], color=sv)   # 의존도 (구 dependence_plot)
shap.plots.waterfall(sv[0])                  # 한 건 분해
shap.plots.bar(sv)                           # 전역 중요도 = mean(|SHAP|)
```

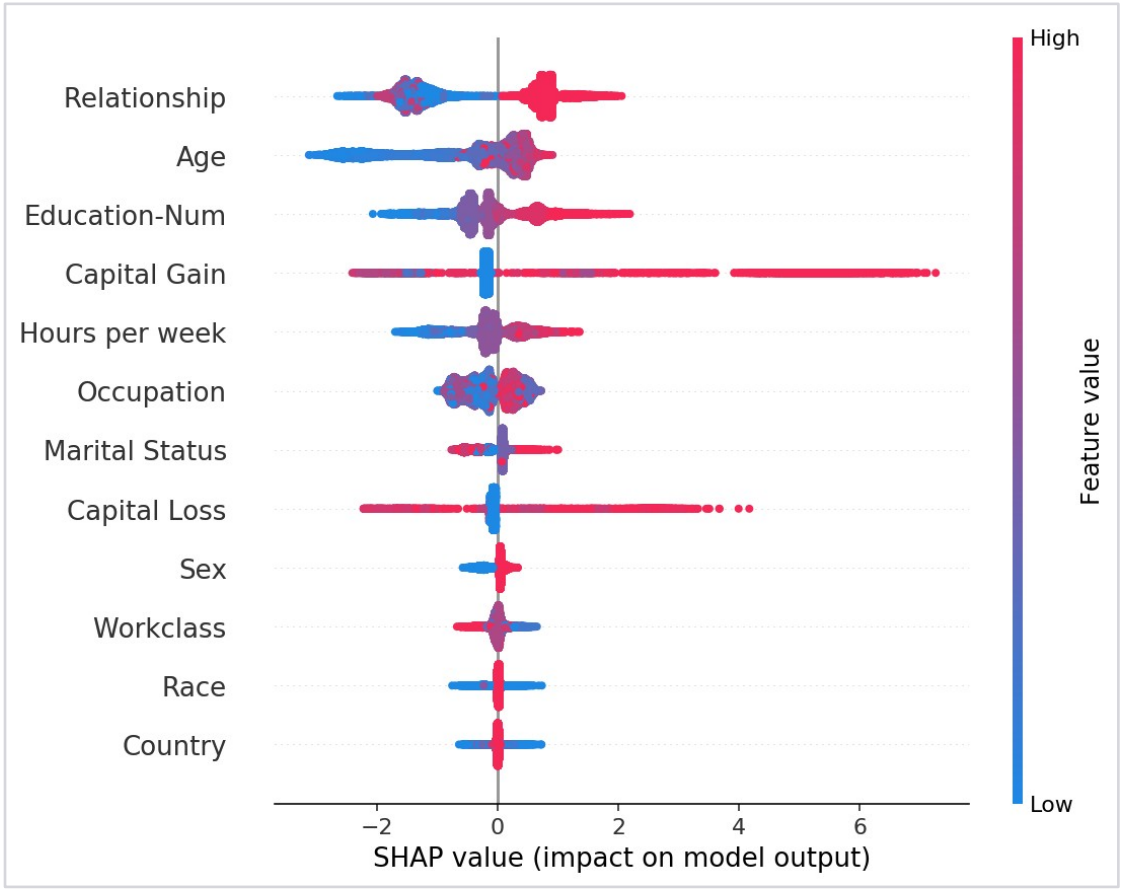
원안 코드 shap.TreeExplainer(model).shap_values(X) → summary_plot(...)도 동작하지만 레거시다. 새 API는 Explanation 객체 하나로 모든 그림을 그린다.

SHAP 값 — 요약도(summary plot)

SHAP 값은 일관성과 가산성을 모두 갖는다 — 전역 순위와 개별 분포를 한 그림에 담는다

읽는 법

- 점 하나 = 한 사람, 가로 위치 = 그 특성의 SHAP 값(로그 오즈)
- 색 = 특성 값(빨강 높음 · 파랑 낮음)
- 세로 순서 = mean(|SHAP|) 전역 순위: Relationship → Age → Education-Num
- Capital Gain: 대부분 0 근처지만 소수에게 매우 큰 + 효과 — 막대 중요도로는 안 보이는 분포



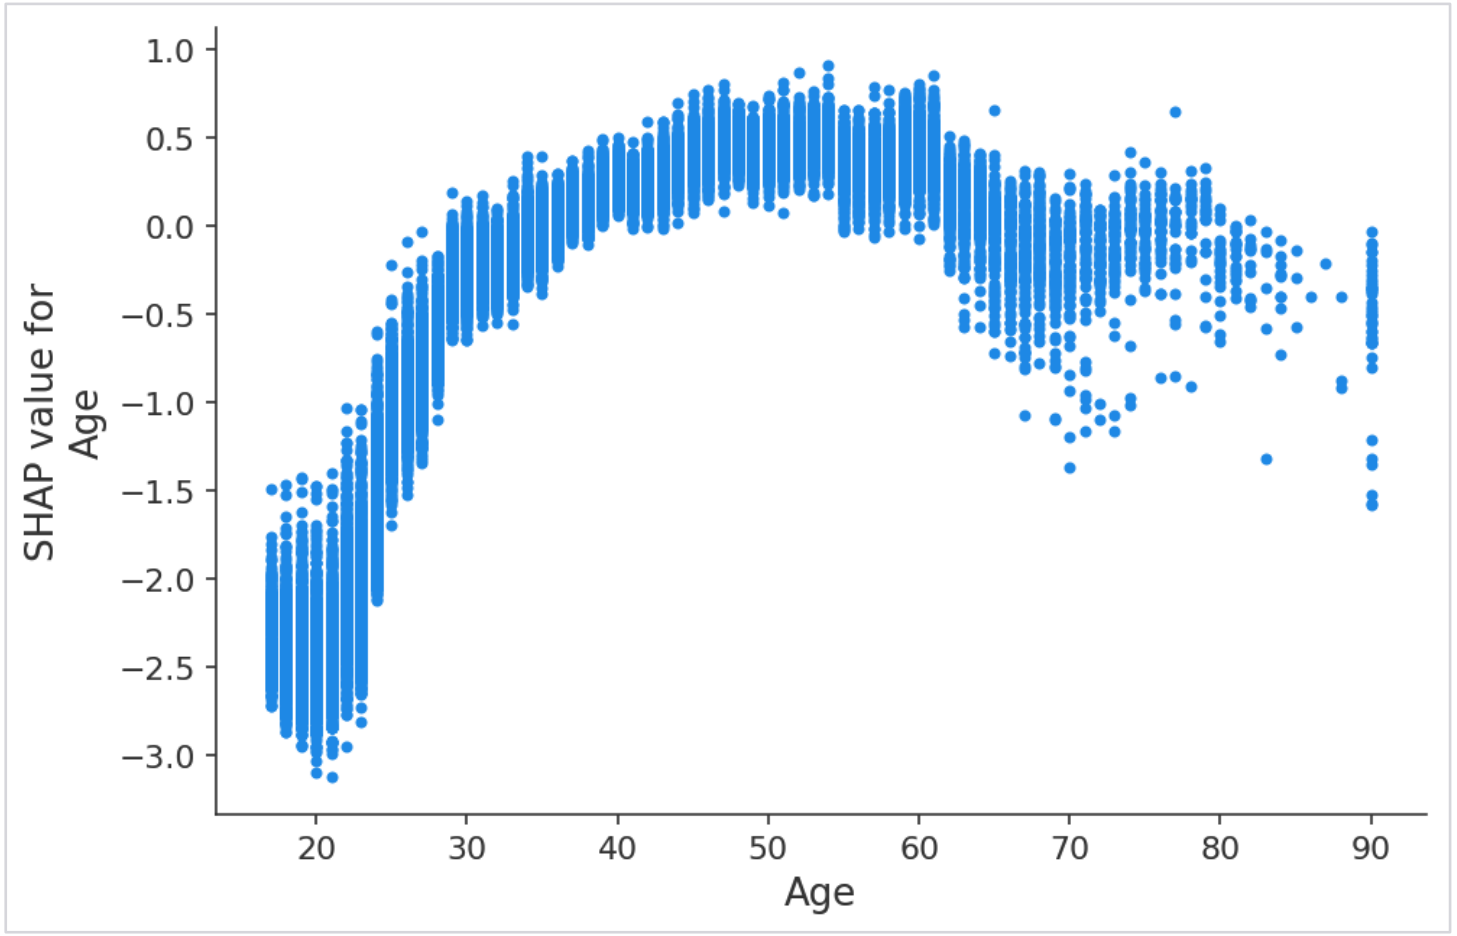
원안 코드: shap.summary_plot(shap_values, X)

특성과 SHAP 값 ① 나이(Age)

각 점은 데이터셋의 한 사람이다. 나이에 따라 소득 예측이 어떻게 달라지는지 본다

읽는 법

- y축: Age가 "연소득 5만 달러 초과"의 로그 오즈에 더한 기여분 (원안의 "로그 승산비 변화"보다 정확한 표현)
- 20대 초반은 −2 ~ −3: 오즈를 약 1/10로 낮춘다 (e^−2.3 ≈ 0.1)
- 40~60세에서 정점, 이후 완만히 하락
- 같은 나이의 세로 퍼짐 = 다른 특성과의 상호작용

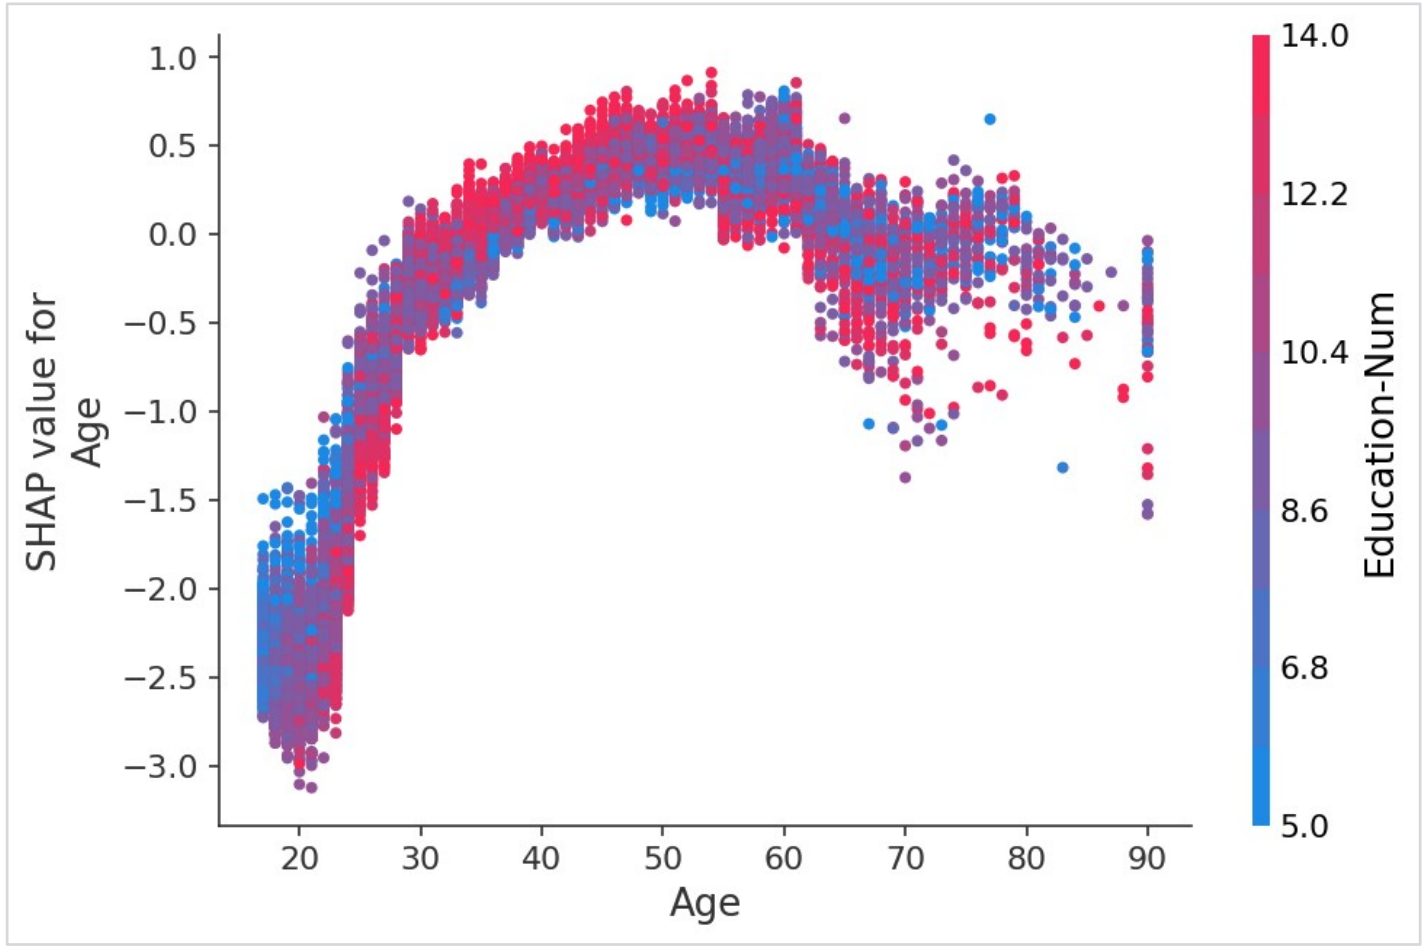


특성과 SHAP 값 ② 나이 × 교육연수

같은 그림에 교육연수(Education-Num, 고객이 마친 교육 연수)로 색을 입혔다

읽는 법

- 30~50대: 빨강(교육 연수가 긴 사람)이 대체로 위쪽 — 나이 효과가 더 커진다
- 70대 전후엔 빨강이 아래로 내려간 점도 보인다
- 색이 세로 퍼짐을 설명하면 두 특성의 상호작용 신호다

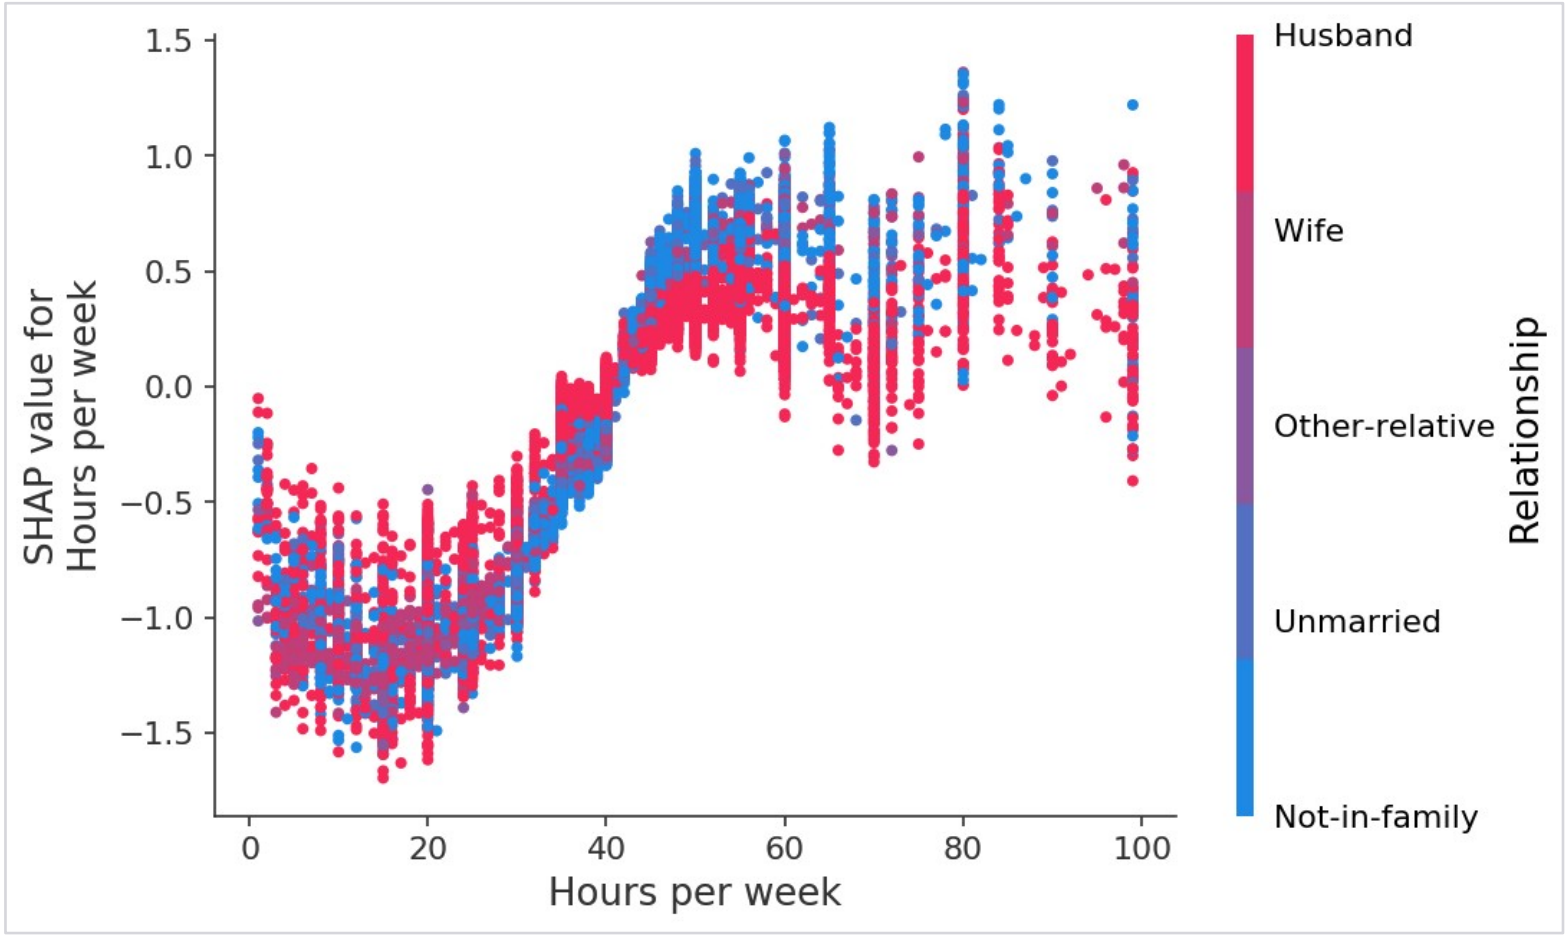


특성과 SHAP 값 ③ 주당 근로시간 × 가구 관계

주당 근로시간이 소득 예측에 주는 효과 — 가구 내 관계(Relationship)에 따라 달라진다

읽는 법

- 40시간 미만은 −, 40~50시간에서 +로 전환
- 50시간을 넘으면 효과가 더 늘지 않는다(포화)
- 40~60시간: 파랑(비가족·미혼)이 빨강(남편)보다 위 — 추가 근로의 효과가 가구 형태에 따라 다르다

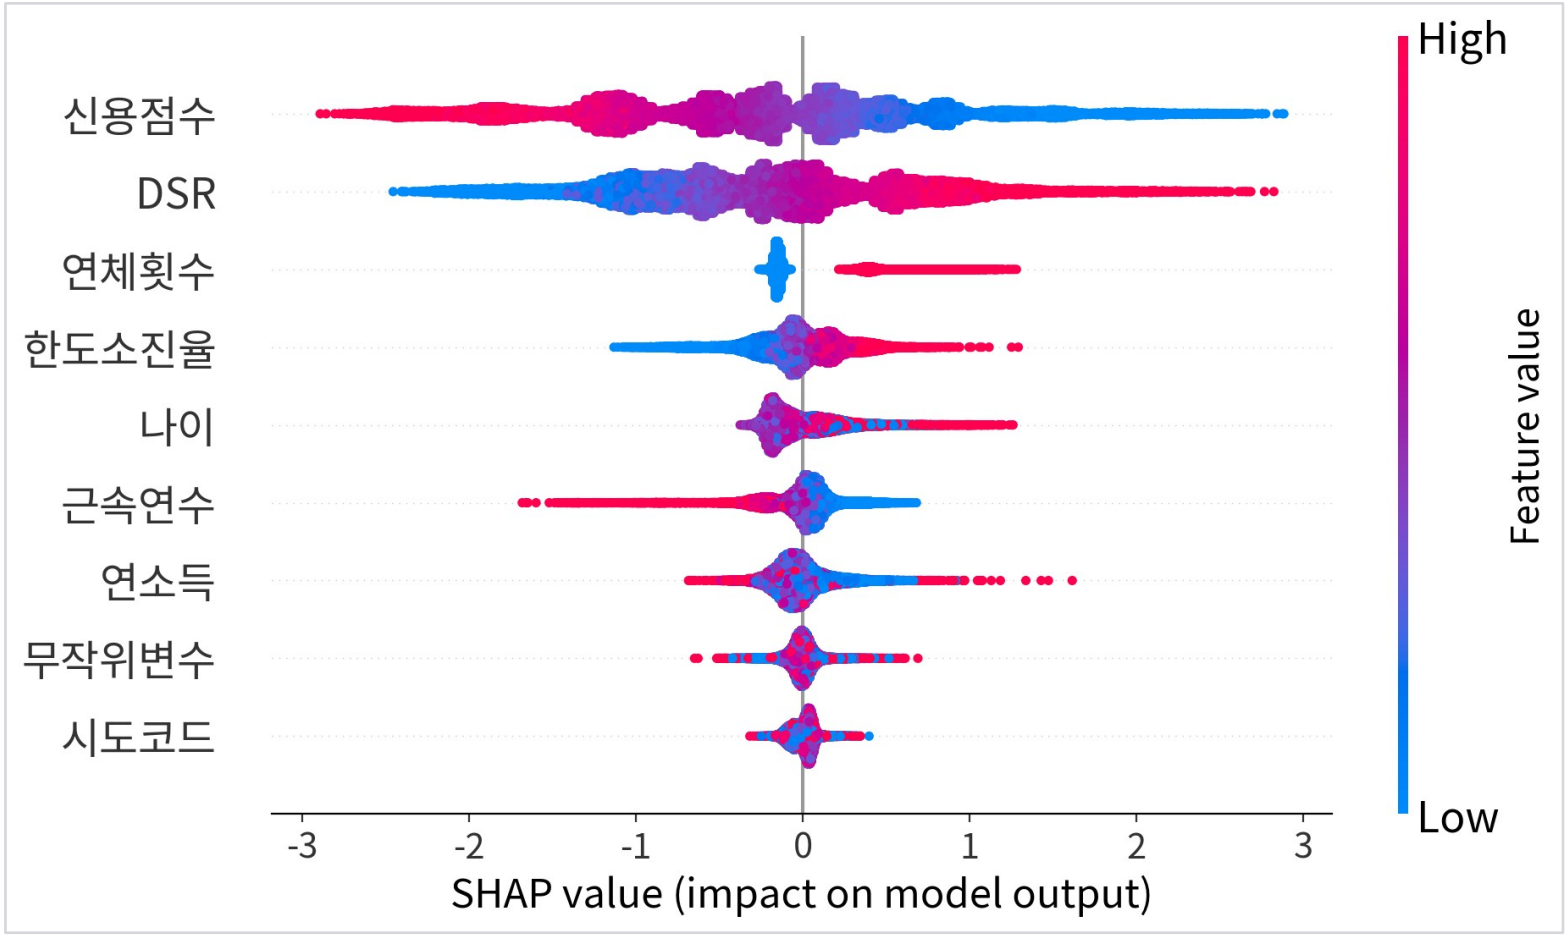


가상 신용 데이터의 요약도

정답을 아는 데이터에서 SHAP이 참 모형의 방향을 맞히는지 확인한다

확인할 점

- 신용점수: 낮을수록(파랑) 오른쪽 = 위험↑ — 참 모형과 같은 방향
- 연체횟수: 0이면 소폭 −, 1회 이상이면 뚜렷한 + (두 덩어리)
- 나이: 양 끝에서 + → 참 모형의 U자형 효과
- 무작위변수·시도코드: 0 근처에 몰림

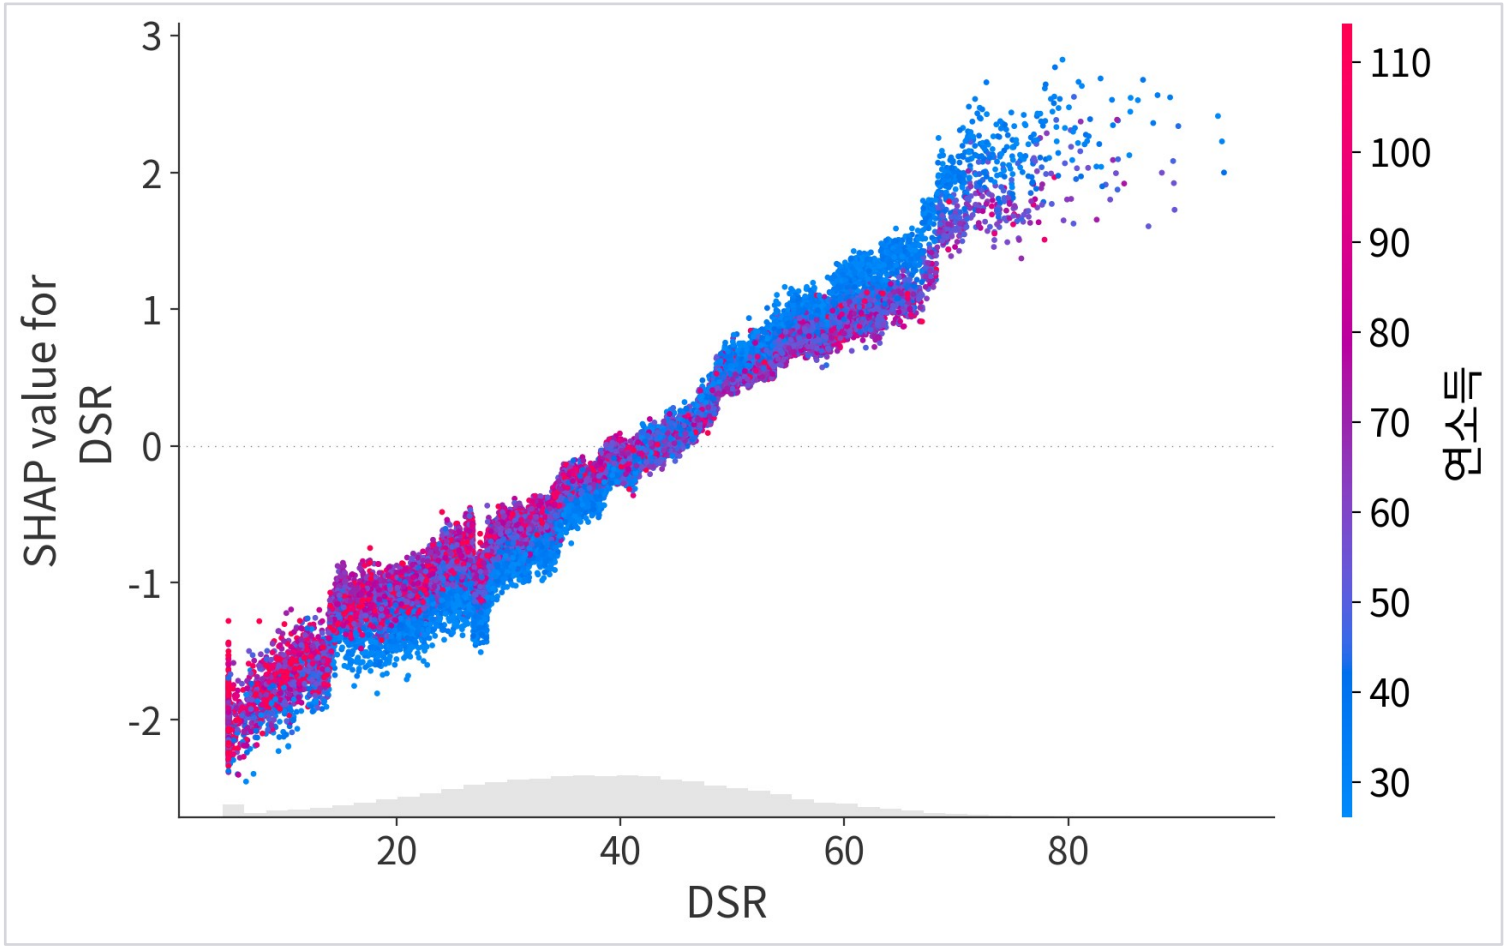


숨은 상호작용 찾기 — DSR × 연소득

참 모형은 연소득 4천만 원 미만에서 DSR 효과를 1.8배로 키웠다. SHAP 의존도가 이를 찾아낼까?

읽는 법

- DSR 40% 이상: 파랑(저소득)이 위 — 같은 DSR이라도 위험이 더 크다
- DSR 40% 미만: 파랑이 아래 — 기울기가 가팔라 양쪽으로 벌어진다
- 색으로 갈라지는 세로 퍼짐 = 숨은 상호작용



06

PART 6 · 심화

SHAP 심화 — 상호작용과 모니터링

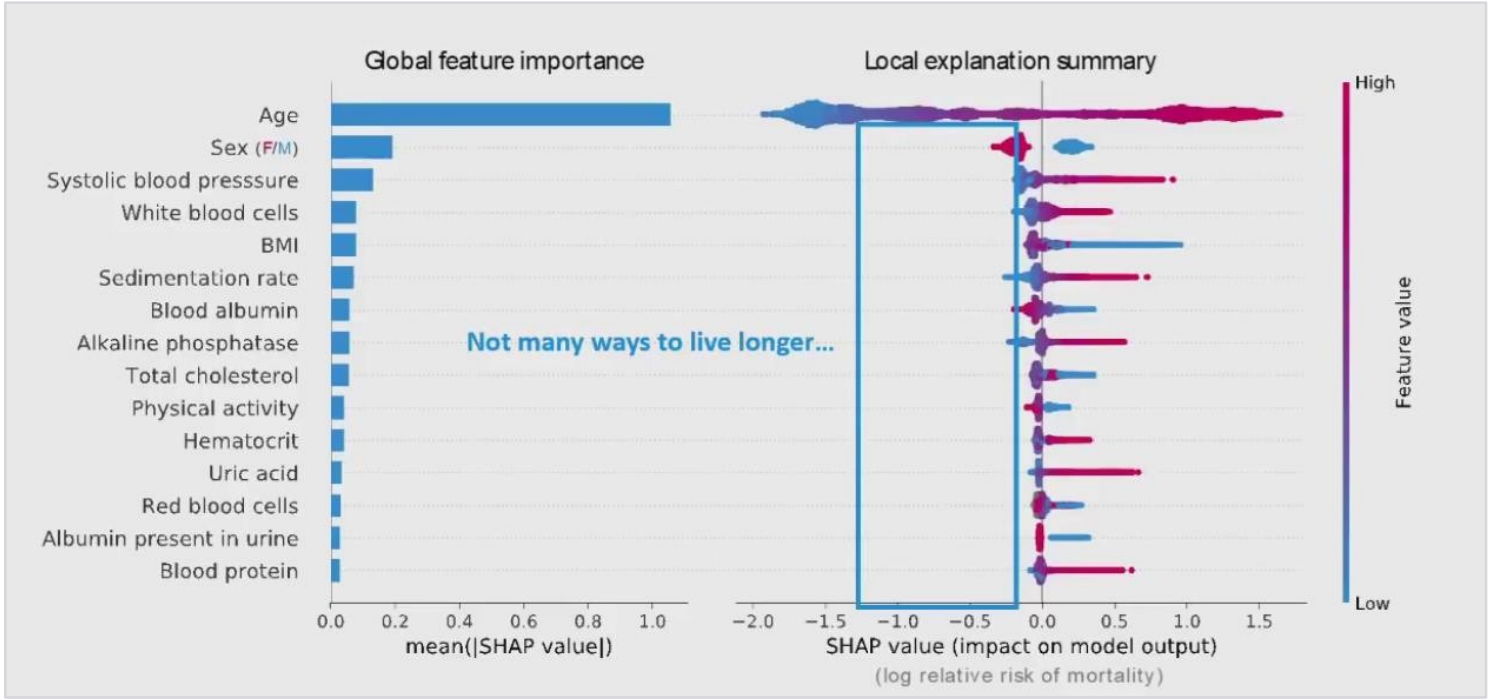
NHANES I 사망률 모델과 병원 수술시간 모델 (Lundberg 외, Nature Machine Intelligence 2020)

전역 중요도에서 보지 못한 것을 발견한다

각 개체마다 특성 기여도를 계산(로컬)하면, 평균 막대가 숨긴 분포가 보인다

읽는 법

- 데이터: NHANES I, 미국 성인 약 1만 4천 명 · 20년 사망 추적
- 왼쪽 막대 = 오른쪽 점들의 |SHAP| 평균
- "오래 사는 방법은 많지 않다": 위험을 낮추는 왼쪽 꼬리는 짧고, 올리는 오른쪽 꼬리는 길다
- 드물지만 큰 위험(고혈압 등)은 평균 중요도에 묻힌다

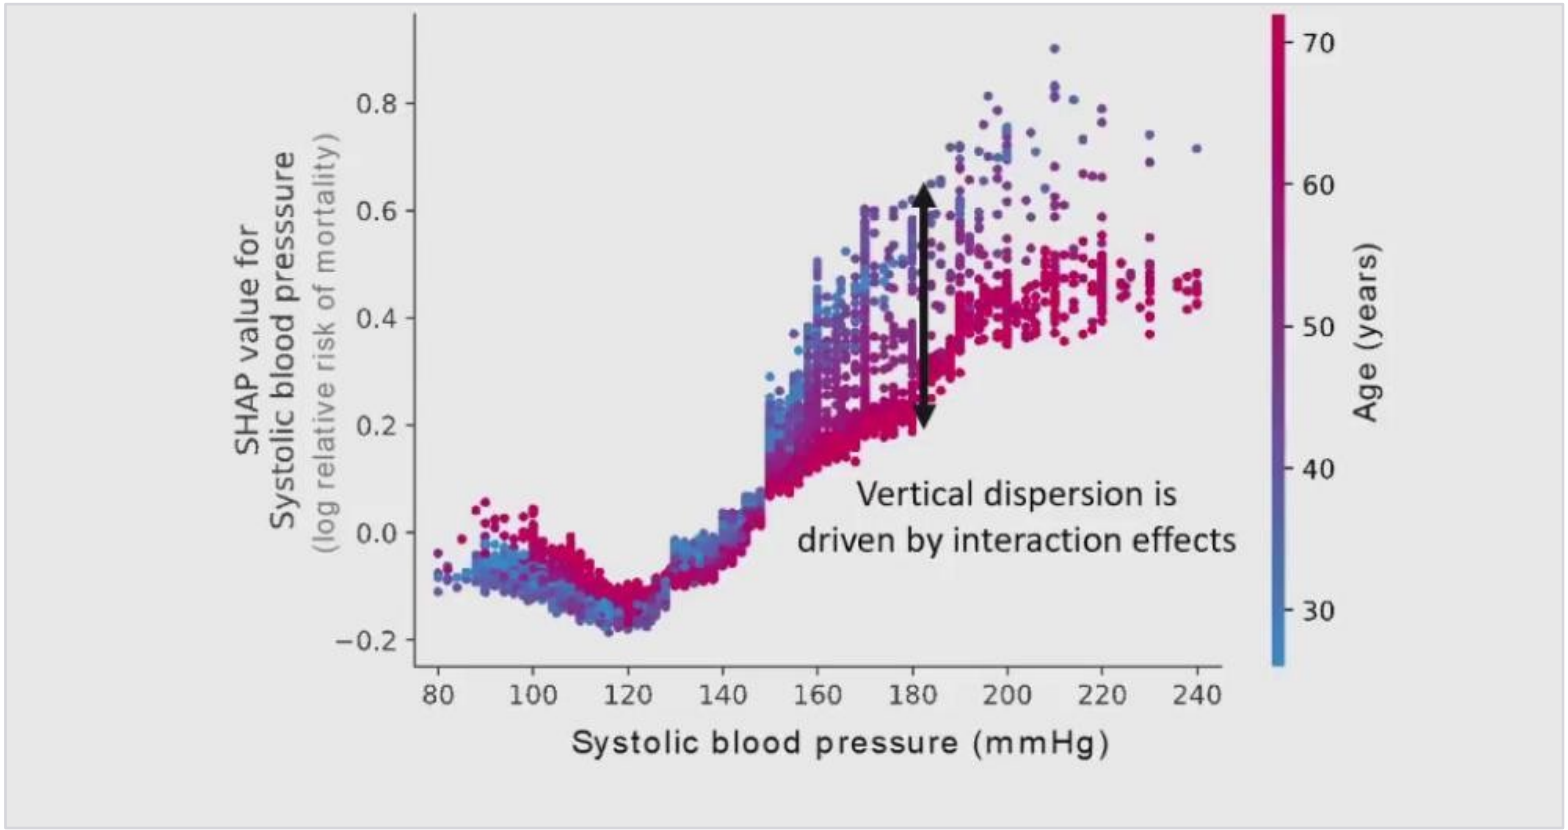


두 개의 특성을 같이 고려할 수 있다

수축기 혈압의 SHAP 값에 나이로 색을 입힌 의존도

읽는 법

- 120mmHg 부근이 가장 낮고, 그 위로는 혈압이 오를수록 위험 증가
- 같은 혈압에서 세로 퍼짐 = 나이와의 상호작용
- 160~180mmHg: 파랑(젊은 사람)이 위 — 이른 나이의 고혈압을 모델이 더 위험하게 본다

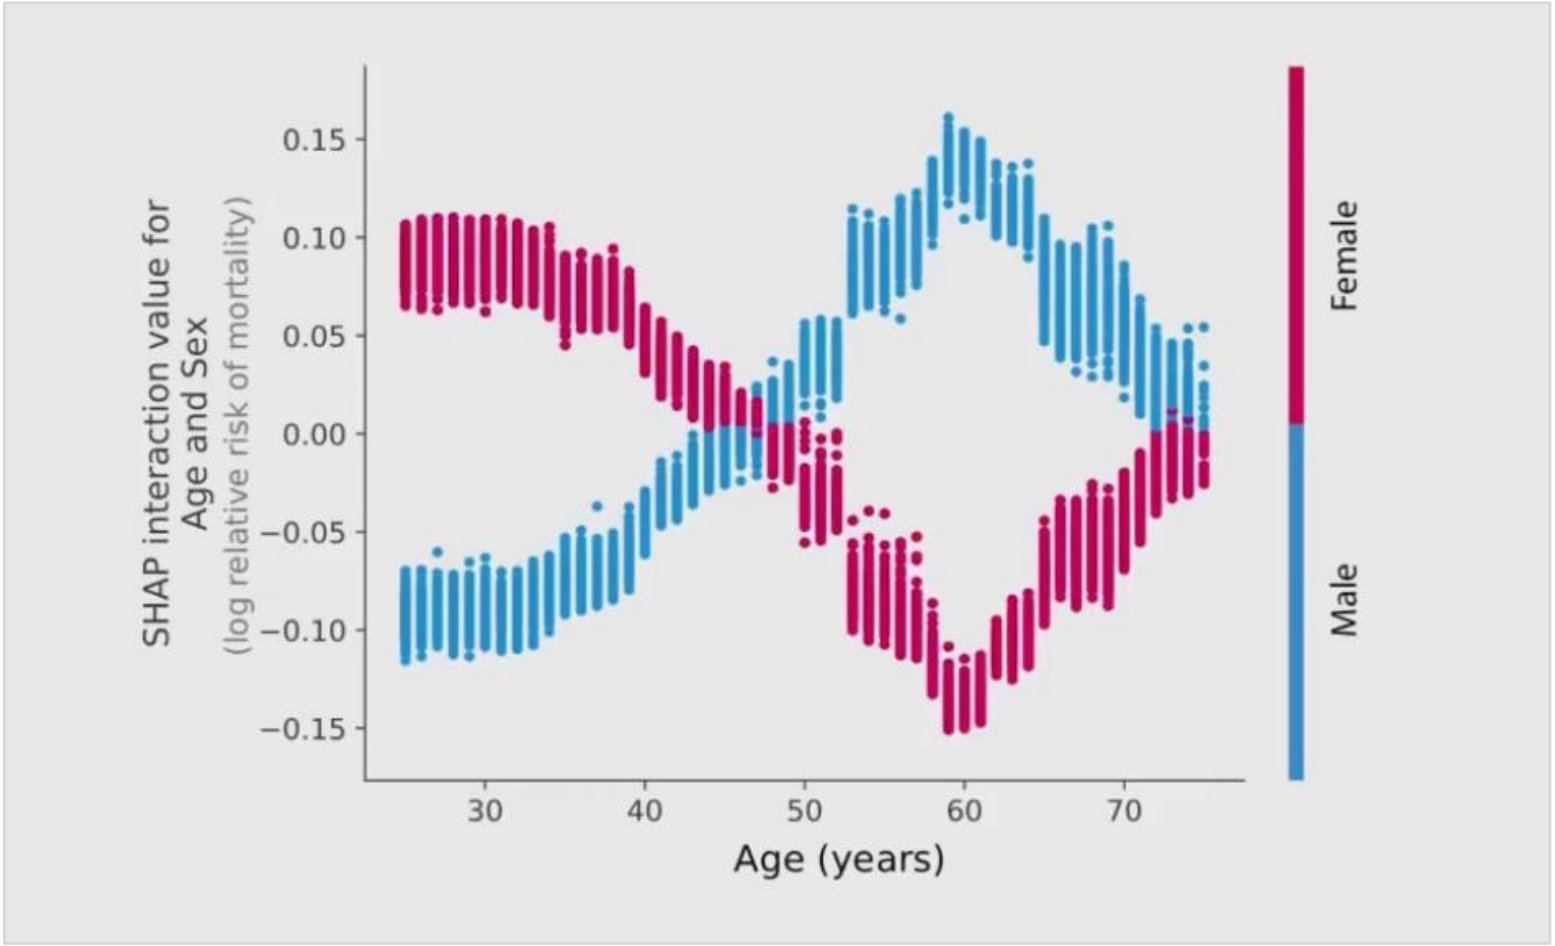


하나의 특성을 분해해서 동시에 고려한다

SHAP 상호작용 값: 나이 효과 중 성별과 얽힌 부분만 떼어 낸다

읽는 법

- 젊을 때: 여성 +, 남성 −
- 60세 부근: 남성이 + 최대, 여성이 − 최대 — 방향이 뒤집힌다
- 이 몫을 빼면 나이의 순수한 주효과(main effect)가 남는다



SHAP 상호작용 값의 정의

샤플리 상호작용 지수를 쓰면 기여도를 주효과와 쌍별 상호작용으로 정확히 나눌 수 있다

$$\Phi_{i,j} = \sum_{S \subseteq N \setminus \{i,j\}} \frac{|S|!\,(M - |S| - 2)!}{2\,(M-1)!}\,\nabla_{ij}(S)$$

$$\nabla_{ij}(S) = v(S \cup \{i,j\}) - v(S \cup \{i\}) - v(S \cup \{j\}) + v(S), \qquad \phi_i = \Phi_{i,i} + \sum_{j \neq i} \Phi_{i,j}$$

읽는 법

- ∇: i와 j가 함께 있을 때만 생기는 추가분
- Φ(i,i)는 주효과, 나머지는 쌍별 상호작용

코드

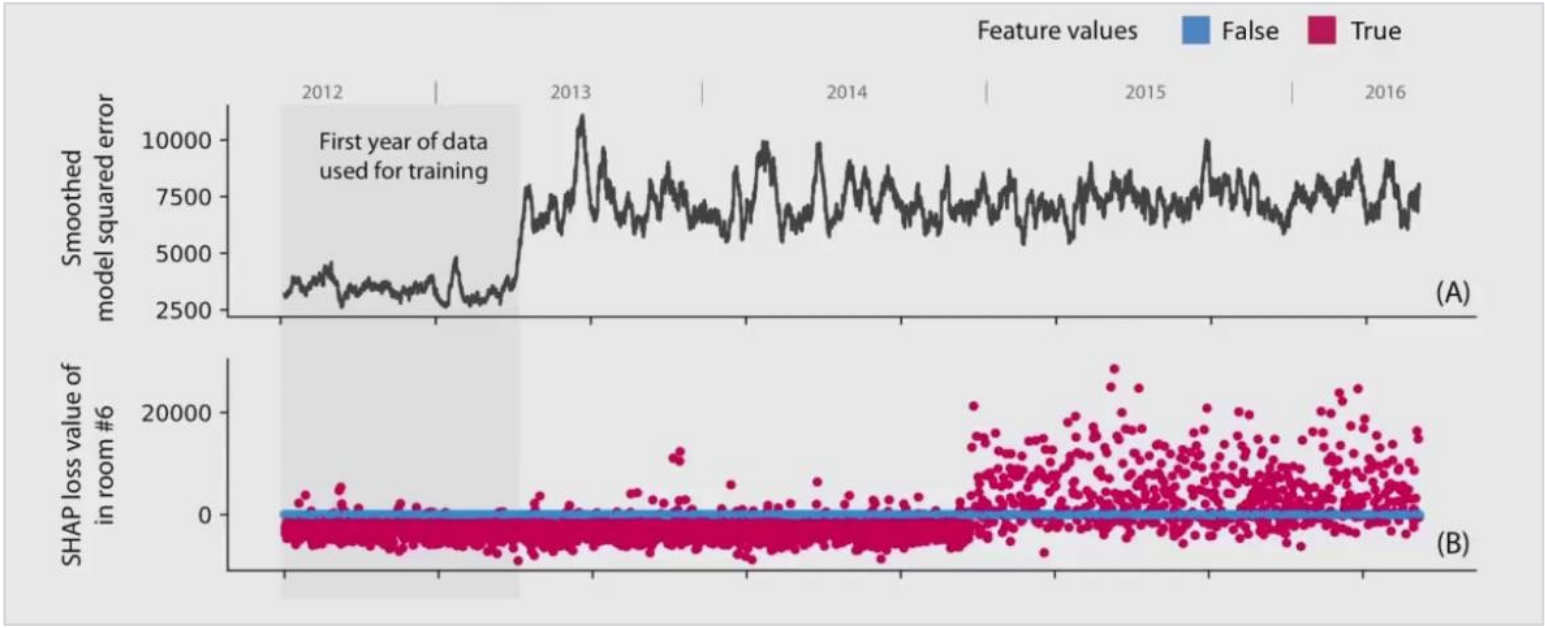
- explainer.shap_interaction_values(X)
- XGBoost: pred_interactions=True

시간에 따른 모델 모니터링 ①

병원 수술 소요시간 예측 모델 — 전체 오차 대신 특성별 SHAP 손실을 추적한다

무엇을 보나

- (A) 전체 손실: 학습 기간 뒤 오차가 커지지만 원인을 모른다
- (B) "6번 수술실" 특성의 SHAP 손실이 어느 시점부터 커진다
- 사실 연구진이 6번·13번 수술실 라벨을 일부러 바꿔 넣은 시험 — 전체 손실로는 안 보이던 오류를 찾았다

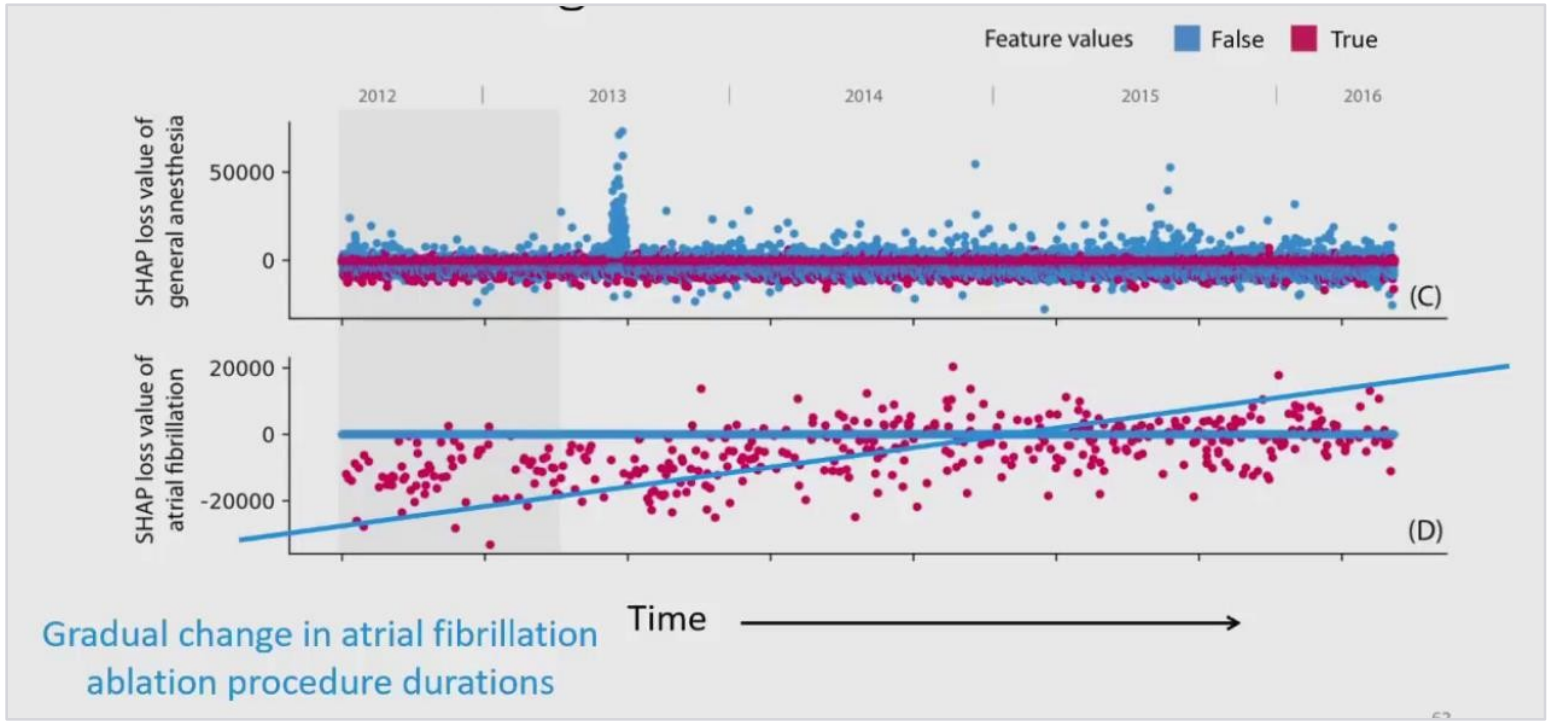


시간에 따른 모델 모니터링 ②

특성 단위로 문제의 원인과 시점을 짚어 낸다

무엇을 보나

- (C) 전신마취 특성: 2013년 초 급등 → 전자의무기록 설정 오류라는 실제 문제를 발견
- (D) 심방세동 특성: 서서히 이동 → 기술·인력 변화로 절제술 시간이 달라진 드리프트
- 원인 특성을 알면 재학습·데이터 수정 중 무엇을 할지 정할 수 있다



금융 모델 모니터링으로 옮기면

입력 분포 지표(PSI 등)는 "바뀌었다"만 알려 주고, SHAP 손실은 "성능을 얼마나 해쳤나"를 알려 준다

병원 사례	금융 모델의 대응 사례	실무 조치
라벨 뒤바뀜 (수술실 6·13)	지점·상품 코드 매핑 오류	특성별 SHAP 손실 경보
일시적 설정 오류 (전신마취)	외부 신용정보 공급 지연·결측	원천 데이터 점검 · 임시 규칙
점진적 드리프트 (심방세동)	금리·경기 변화로 DSR 효과 이동	재학습 · 챔피언-챌린저 비교

모니터링 = 무엇이 변했나(분포) + 무엇이 성능을 해쳤나(SHAP 손실)

07

PART 7 · 금융 실무

금융 실무 적용과 SHAP의 한계

거절 사유 · 규제 · 함정 · 최신 동향 (2026년 9월 기준)

SHAP으로 거절 사유 만들기

SHAP 값 → 표준 사유 코드 → 고객 안내문

① 기준 정하기

배경 데이터

기준값을 무엇으로 둘지 정하고 문서화한다

예) 최근 승인 고객

② 한 건씩 분해

TreeSHAP

거절 건마다 SHAP을 계산해 위험을 올린 요인만 추린다

예) DSR +0.87

③ 사유 코드 매핑

상위 3~4개

표준 문구로 바꾸고, 사유로 쓸 수 없는 변수는 뺀다

예) "DSR 과다"

④ 검증·기록

안정성·이력

비슷한 고객의 사유가 일관된지 점검하고 보관한다

예) 월별 사유 분포

SHAP은 판단 근거이지 인과가 아니다 — "이렇게 하면 승인"은 반사실 분석으로

규제 지형 ① 한국 (2026년 9월 기준)

신용 결정의 설명 의무는 이미 법에 있고, AI 기본법이 이를 넓혔다

근거	시행	설명 관련 요구
신용정보법 제36조의2	2020.8	자동화평가 여부·결과·주요 기준·기초정보 설명요구권, 정정·재산출 이의제기권
인공지능 기본법	2026.1.22	대출 심사는 고영향 AI(제2조 제4호) — 최종결과·주요 기준·학습 데이터 개요의 설명 방안 수립(제34조)
금융분야 AI 가이드라인 (개정)	2026.6	거버넌스·합법성·보조수단성·신뢰성·금융안정성·신의성실·보안성 7대 원칙, 위험 수준별 관리

금융위원회 보도자료 · 법제처 국가법령정보센터

규제 지형 ② EU · 미국 (2026년 9월 기준)

"이유를 설명하라"는 요구는 유지되고, 일정과 형식은 바뀌고 있다

지역	근거	핵심
EU	GDPR 제22조·제15조(1)(h) + 유럽사법재판소 판결	SCHUFA(2023): 신용점수도 자동화 결정 / D&B(2025): 실제 적용된 절차·원칙을 이해 가능하게
EU	AI Act (Reg. 2024/1689)	신용평가 = 고위험(부속서 III), 개별 결정 설명권(제86조) — 고위험 의무는 개정(2026/1744)으로 2027.12 적용
미국	ECOA · Reg B	거절 시 구체적 주요 사유 고지 (CFPB 해설 2022-03은 2025.5 철회, 법적 의무는 유지)
미국	SR 26-2 (2026.4)	SR 11-7을 대체한 모델 리스크 관리 지침 — 위험 기반 접근

SHAP의 한계와 함정

BIS(2025): 설명 기법은 부정확·불안정할 수 있다 — 설명이 신뢰를 대신하지는 못한다

함정	무엇이 문제인가	대응
상관된 특성	기여가 상관된 변수들(DSR·소득) 사이에서 임의로 나뉜다	변수 묶음 단위 SHAP, 가치함수 선택 명시
인과가 아니다	“DSR을 낮추면 승인”은 모델 기준일 뿐이다	반사실 설명·인과 분석을 따로
기준 분포 의존	배경 데이터가 바뀌면 값도 바뀐다	배경 데이터 고정·문서화
조작 가능성	설명만 그럴듯하게 꾸밀 수 있다 (Slack 외, AIES 2020)	독립 검증, 모델 자체 감사
불안정성	비슷한 고객끼리 사유가 달라질 수 있다	사유 안정성 테스트

케이스 · FICO 설명가능 ML 챌린지 (2018)

블랙박스를 설명하는 대신, 처음부터 해석 가능한 모델로 바꿨다

해석 가능한 모델과 블랙박스의 정확도 차이: 1% 미만

경과

- FICO가 구글·UC버클리 등과 함께 HELOC(주택담보 한도대출) 데이터로 "블랙박스 + 설명" 경진대회 개최
- 듀크대 루딘 팀은 블랙박스 대신 해석 가능한 모델과 시각화 도구를 제출
- 공식 우승은 아니었지만 FICO Recognition Award 수상

쟁점

- 루딘(2019): 고위험 결정엔 블랙박스를 설명하지 말고 해석 가능한 모델을 쓰라
- 정확도-해석가능성 상충은 늘 성립하지 않는다 → Part 1의 "?"
- 실무: 스코어카드·EBM으로 기준선을 먼저 잡고, 부족할 때만 블랙박스 + SHAP

Rudin & Radin, Harvard Data Science Review (2019) · Rudin, Nature Machine Intelligence (2019)

2024–2026 동향

설명의 단위는 넓어지고(상호작용·파운데이션 모델), 감독 당국은 한계를 전제로 통제를 요구한다

흐름	내용	금융 시사점
고차 상호작용	shapiq (NeurIPS 2024): 2차 이상 샤플리 상호작용 계산	DSR × 소득 같은 조합 효과 검증
표 형식 파운데이션 모델	TabPFN v2 (Nature 2025) — SHAP 연동 지원	소량 데이터 신용 모델에도 같은 설명 틀
감독 당국의 시각	BIS FSI (2025.9) “Managing explanations”: 설명 기법의 한계 인정, 보완 통제를 전제로 고성능 모델 허용 논의	설명 + 통제의 조합으로 거버넌스 설계
LLM 해석	기계적 해석가능성(mechanistic interpretability) — MIT Technology Review 2026 10대 기술	생성형 AI 상담·심사 보조의 설명

토론 질문

Q1	거절 고객에게 SHAP 상위 요인을 그대로 알려도 되는가? 인과가 아닌 “기여”를 어떻게 안내할까	**설명 · 소비자보호**
Q2	DSR과 소득처럼 상관된 변수의 기여를 나누는 기준은 무엇이어야 하나	**상관 · 기준값**
Q3	gain 중요도로 변수를 골라 온 기존 모형, 다시 봐야 할까	**특성 중요도**
Q4	정확도 1% 대 해석가능성 — 우리 조직의 선택 기준은	**모델 거버넌스**

종합 — 오늘 가져갈 세 가지

1

설명가능성은 선택이 아니다

늑대·허스키처럼 이유를 봐야 모델을 믿을 수 있고, 신용 결정은 법이 이유를 요구한다

2

XGBoost 기본 중요도 대신 SHAP

분할 순서에 흔들리지 않는 유일한 배분 — 일관성과 국지 정확성을 함께 갖춘다

3

SHAP은 도구이지 결론이 아니다

상관·기준값·인과의 한계를 알고 거절 사유·모니터링·규제 대응에 쓴다

점수 → 기여도 → 사유 → 검증: 설명의 전 과정을 설계하라

참고문헌·출처

- 원안 강의자료: 이대형, 「설명가능한 머신러닝 — 금융 전문가의 관점에서 풀어본」(2019)
- Shapley, L. (1953). A Value for n-Person Games. Contributions to the Theory of Games II
- Ribeiro, Singh & Guestrin (2016). "Why Should I Trust You?". KDD
- Lundberg & Lee (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS
- Lundberg (2018). Interpretable Machine Learning with XGBoost. Towards Data Science
- Lundberg et al. (2020). From Local Explanations to Global Understanding with Explainable AI for Trees. Nature Machine Intelligence 2
- Chen, Janizek, Lundberg & Lee (2020). True to the Model or True to the Data? · Slack et al. (2020). Fooling LIME and SHAP. AIES
- Rudin (2019). Stop Explaining Black Box Machine Learning Models… Nature Machine Intelligence · Rudin & Radin (2019). HDSR
- Grinsztajn, Oyallon & Varoquaux (2022). Why Do Tree-Based Models Still Outperform Deep Learning on Tabular Data? NeurIPS
- NYDFS (2021). Report on Apple Card Investigation · BIS FSI Occasional Paper No. 24 (2025). Managing Explanations
- 신용정보법 제36조의2 · 인공지능 기본법 · GDPR · EU AI Act (2024/1689, 2026/1744) · Fed SR 26-2