EXPLAINABLE MACHINE LEARNING

설명가능한 머신러닝

금융 전문가의 관점에서 풀어 본 샤플리 값과 SHAP

Explainable Machine Learning — Shapley Values, SHAP and XGBoost

모델의 점수만으로는 부족하다. 그 점수가 어디서 나왔는지를 특성별 기여도로 나눠 보고,
XGBoost 소득 예측 모델로 글로벌 특성 중요도와 SHAP 값을 직접 비교한다.

왜 설명이 필요한지 보고, SHAP으로 근거를 확인한다

설명이 필요한 이유, 설명하는 방법, XGBoost 실습의 세 부분으로 진행한다

1

머신러닝의 설명 가능성

늑대와 허스키, 카드 사기 탐지, 대출 거절 사례로 설명이 왜 필요한지 본다

2

샤플리 값과 SHAP

게임이론의 공헌도 배분을 특성 기여도로 옮기고, 상호작용과 모니터링까지 읽는다

3

XGBoost로 배우는 해석

세 가지 글로벌 중요도가 엇갈리는 것을 보고, SHAP 그림으로 소득 모델을 다시 읽는다

01

PART 1 · 설명 가능성

머신러닝의 설명 가능성

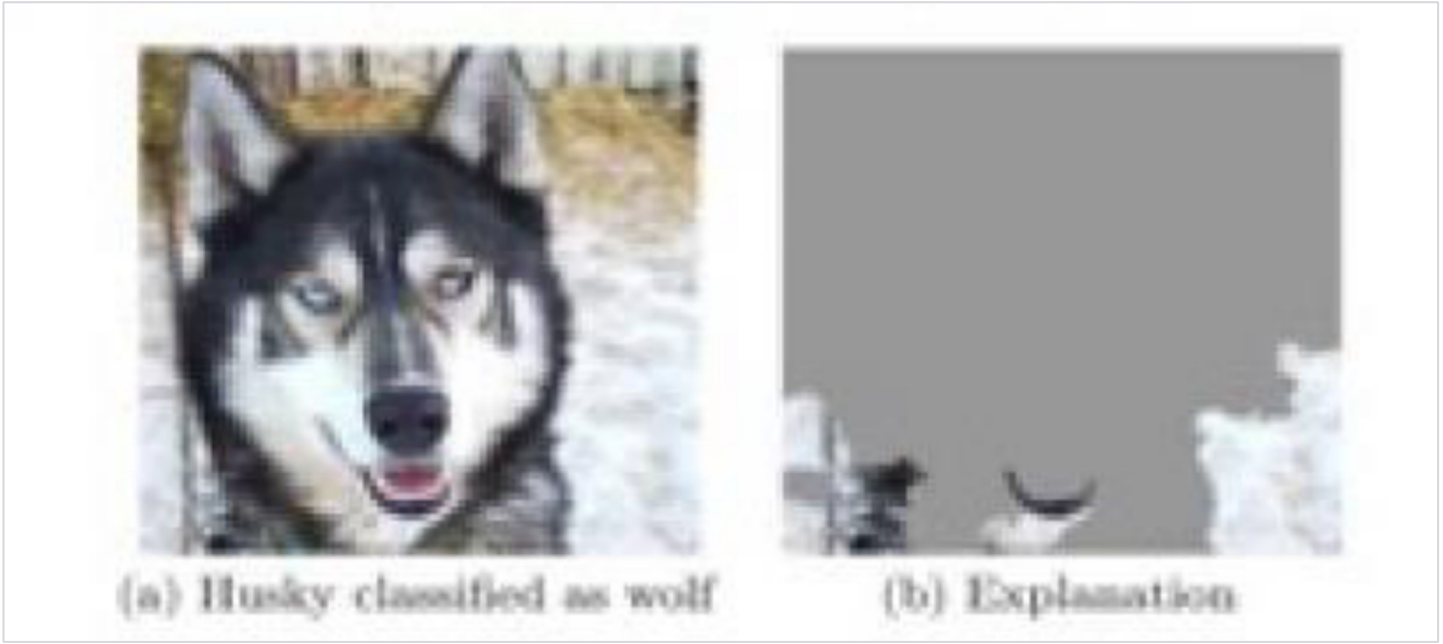
잘 맞히는 모델이 왜 맞혔는지 알아야 하는 이유

잘 맞힌 모델도 엉뚱한 이유로 맞혔을 수 있다

이미지 분류: 늑대와 허스키 — (a) 늑대로 분류된 허스키, (b) 모델이 근거로 삼은 영역

무엇을 보나

- 머신러닝은 늑대와 허스키를 놀랍게 잘 분류했다
- 그러나 근거는 동물이 아니라 배경의 눈이었다
- 설명을 보지 않으면 이런 지름길 학습을 알아채지 못한다

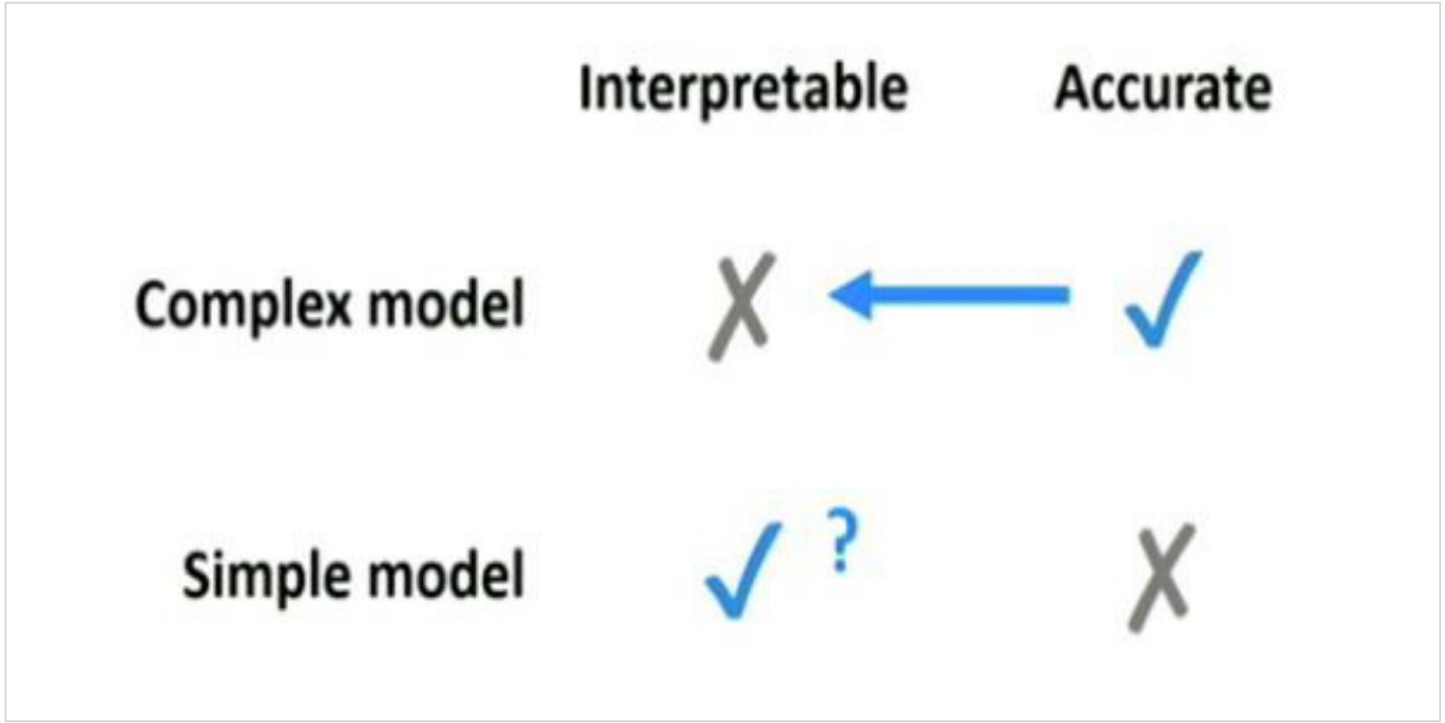


복잡한 모델은 예측력이 좋지만 해석하기 어렵다

단순함 대 해석가능성 — 정확한 복잡 모델(complex model)과 해석 가능한 단순 모델(simple model)

트레이드오프

- 복잡한 모델은 예측력은 좋으나 블랙박스라 해석할 수 없다
- 단순한 모델은 해석은 되지만 정확도가 떨어진다
- 화살표: 복잡한 모델을 해석 가능하게 만드는 것이 설명가능한 ML의 목표다



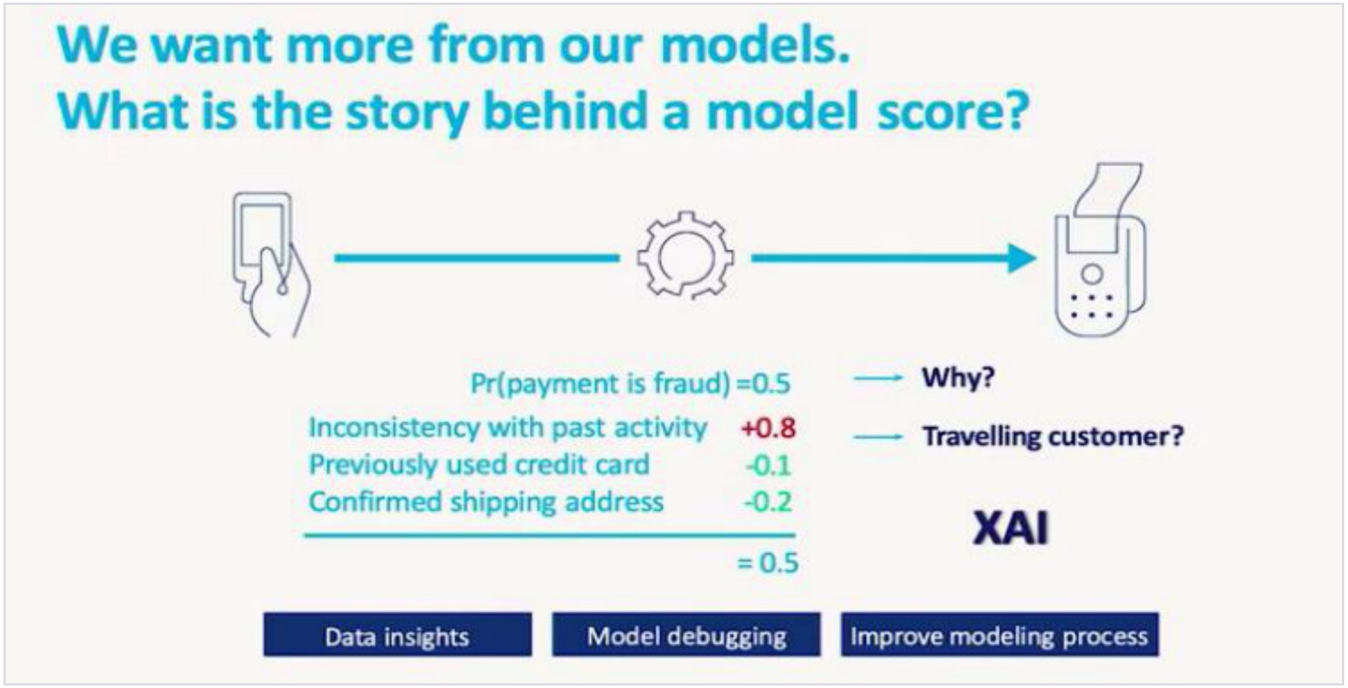
점수만으로는 부족하고, 그 점수가 나온 이유를 알아야 한다

신용카드 사기의 확률은? 도대체 이 확률이 어디서 나오는 것인가?



설명이 주는 것

- 설명도 할 수 있고, 모델을 검증하고 개선할 수 있다

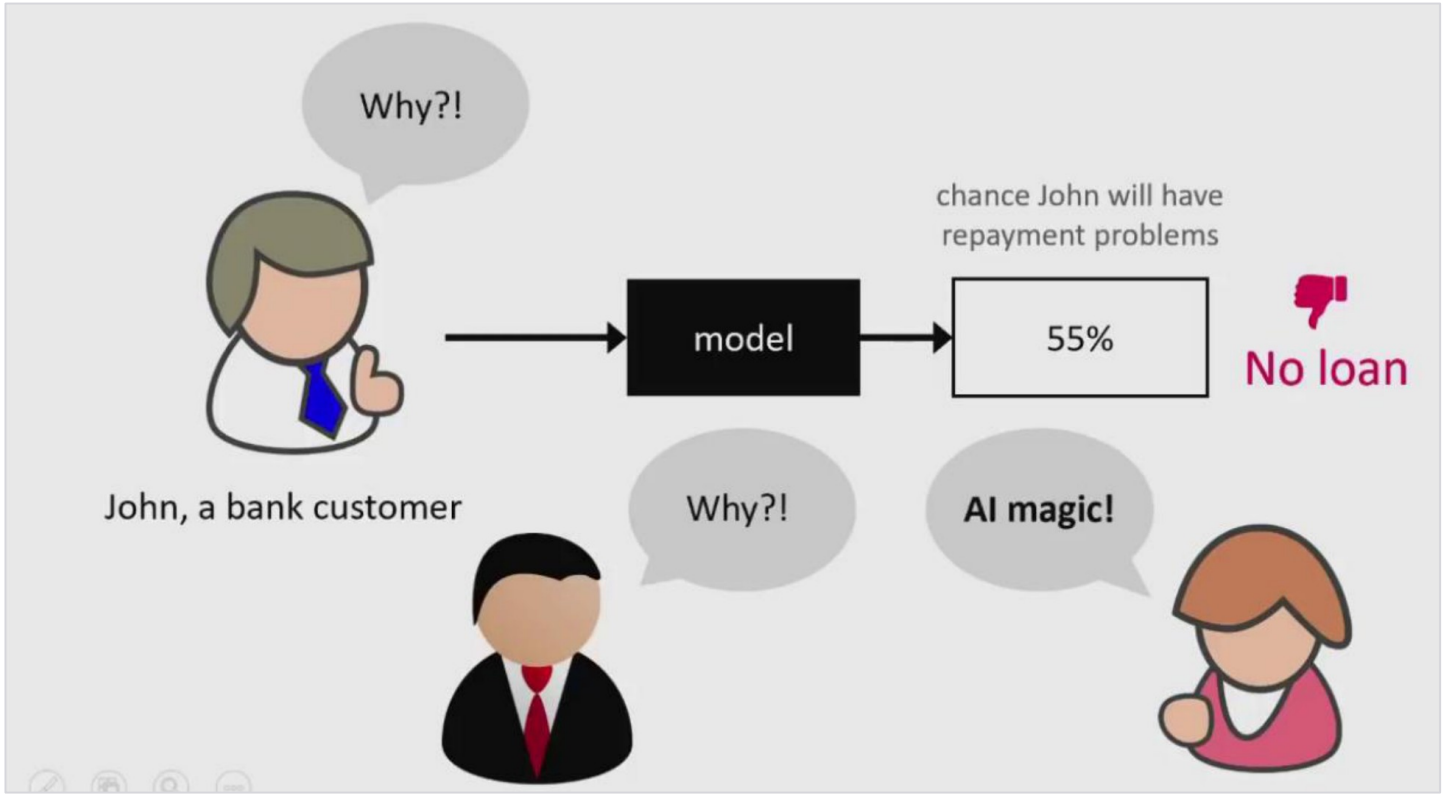


대출 기각의 이유를 고객에게 설명할 수 있어야 한다

상환 문제 확률 55% → 대출 거절. 고객도 직원도 "왜?"라고 묻는다

설명 책임

- 유럽의 GDPR은 자동화된 결정의 이유를 제공하라고 한다
- 그 이유가 인종차별적이거나 정치적으로 옳지 못한 것일 수도 있다
- "AI 마법"은 답이 될 수 없다



02

PART 2 · 샤플리 값과 SHAP

샤플리 값과 SHAP

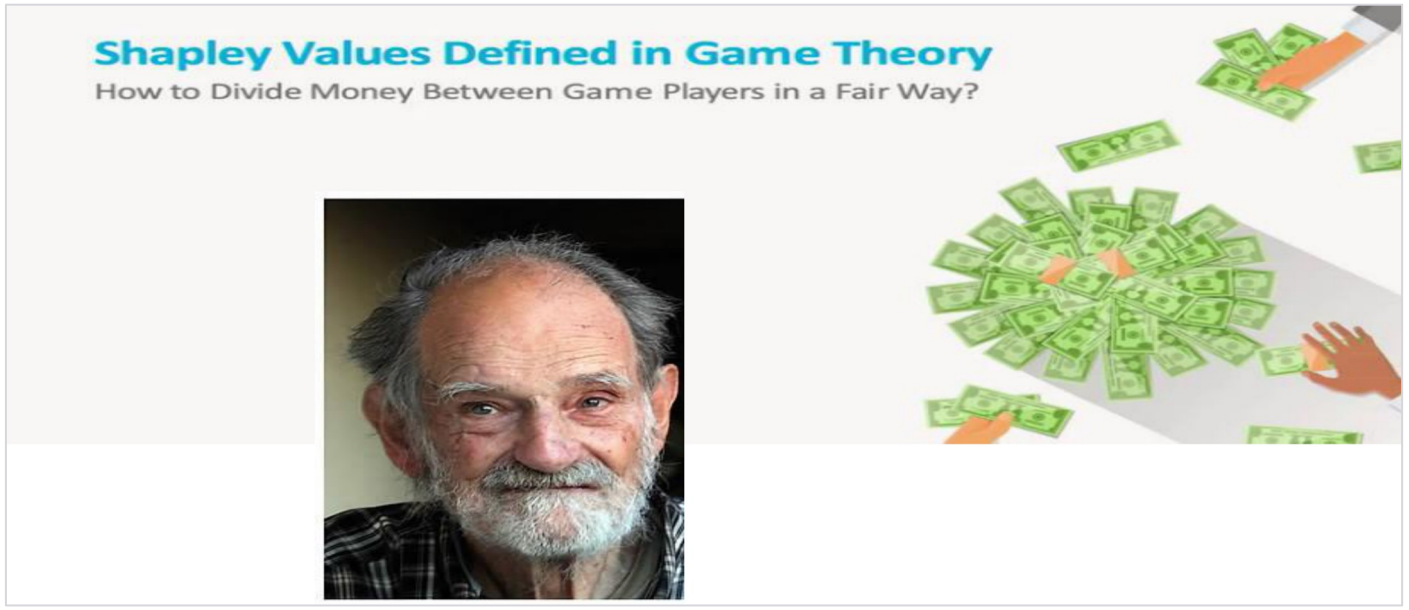
협력 게임의 공정한 배분을 특성 기여도로 옮긴다

샤플리 값은 협력 게임에서 각 플레이어의 공헌도를 잰다

샤플리 값(Shapley value) — 게임 참가자들에게 상금을 공정하게 나누는 방법

게임이론에서 머신러닝으로

- 게임이론에서 도출된 개념이다. 2012년 노벨 경제학상 수상자 로이드 샤플리(Lloyd Shapley)의 작품이다
- 협력 게임에서 각 플레이어의 공헌도를 측정하는 값이다
- 머신러닝에서는 플레이어가 특성이고, 상금이 모델의 예측값이다

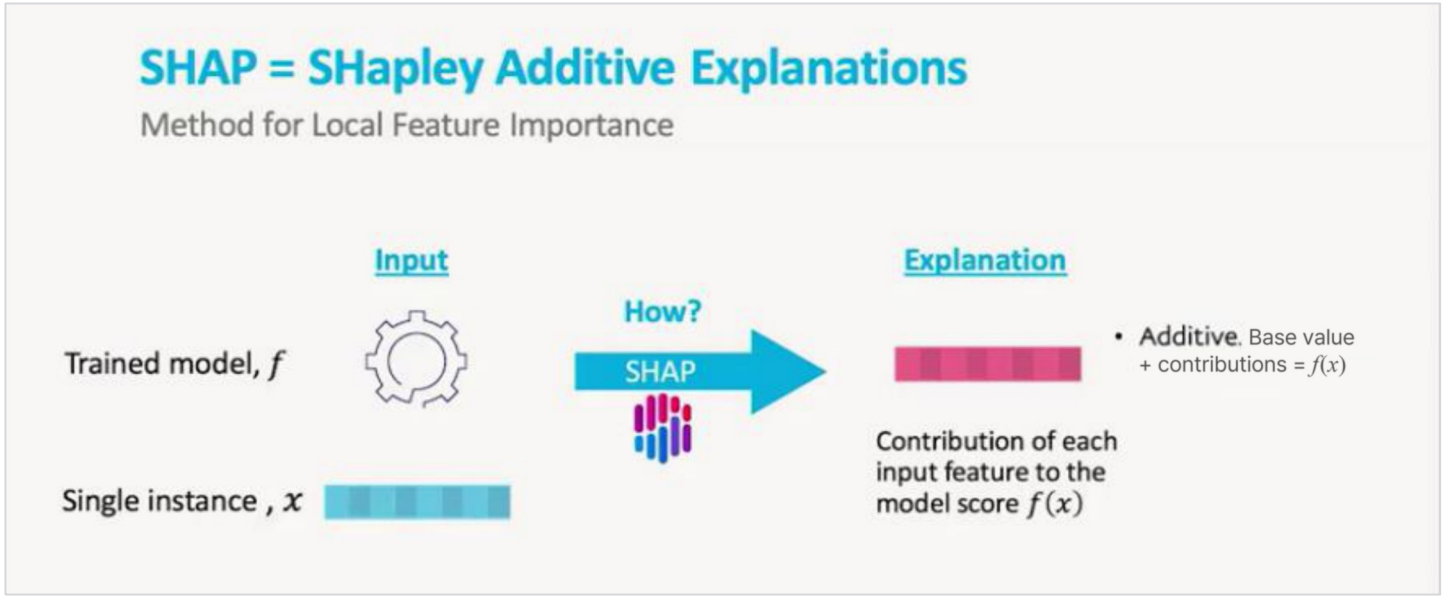


SHAP은 한 예측을 특성별 기여도로 나눈다

SHAP = SHapley Additive exPlanations — 국지적 특성 중요도(local feature importance) 방법

두 성질

- 샤플리 값은 일관성과 가산성을 갖추고 있다
- 가산성: 기준값에 특성별 기여도를 모두 더하면 모델 출력 f(x)가 된다
- 입력은 학습된 모델과 하나의 관측치, 출력은 그 관측치의 특성별 기여도다

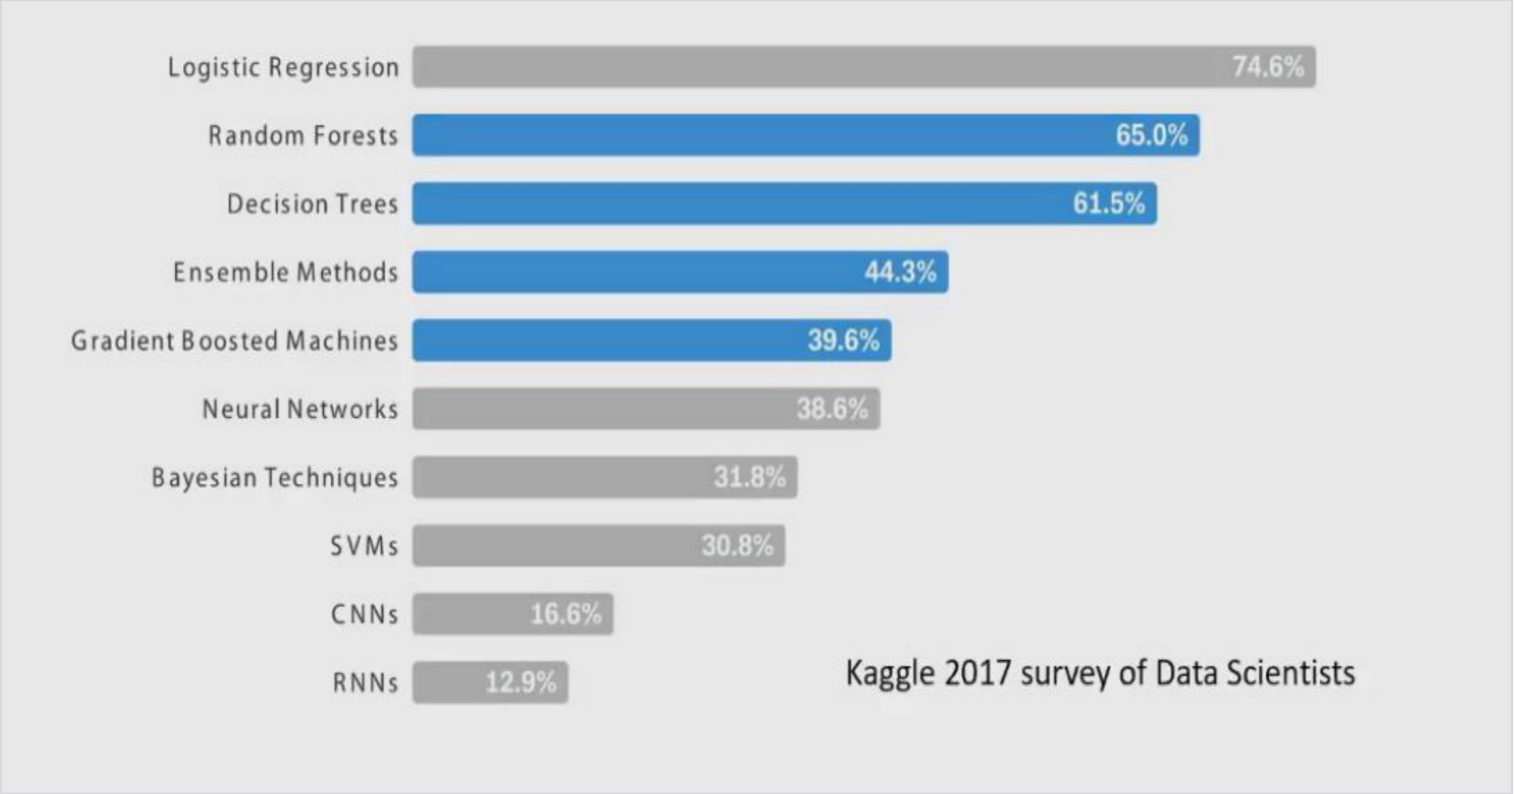


트리 모델이 실무에서 가장 많이 쓰이는 복잡한 모델이다

Kaggle 2017 설문, 직함 Data Scientist 2,039명 — 파란 막대가 트리 계열(랜덤 포레스트, 의사결정트리, 앙상블, GBM)

왜 트리인가

- 로지스틱 회귀 다음으로 랜덤 포레스트(65.0%)와 의사결정트리(61.5%)가 많이 쓰인다
- 그래서 트리 모델을 설명하는 도구가 실무에서 가장 쓸모가 크다
- 전체 응답자 7,301명 기준은 로지스틱 회귀 63.5%, 의사결정트리 49.9%, 랜덤 포레스트 46.3%다

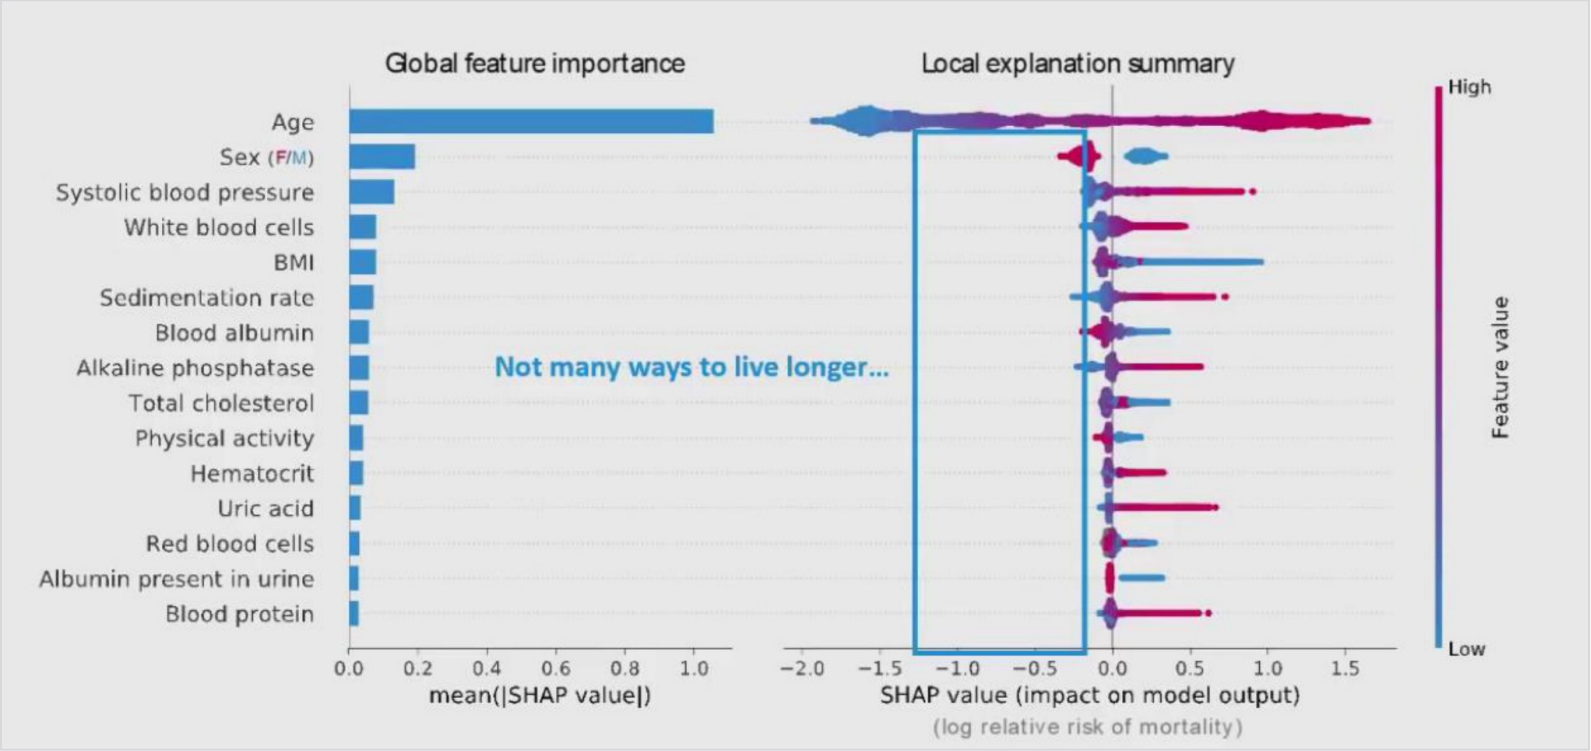


SHAP은 글로벌 특성 중요도가 감추는 개별 효과를 드러낸다

왼쪽: 글로벌 특성 중요도(SHAP 절댓값 평균), 오른쪽: 개체별 SHAP 값 요약 — 사망 위험의 로그 상대위험

그림 읽기

- 각 개별 개체에 대해 특성 기여도를 계산한다(로컬)
- 점 하나가 한 사람, 색은 특성 값의 높고 낮음이다
- 네모 칸: 오래 사는 쪽(왼쪽)으로 끄는 특성은 많지 않다

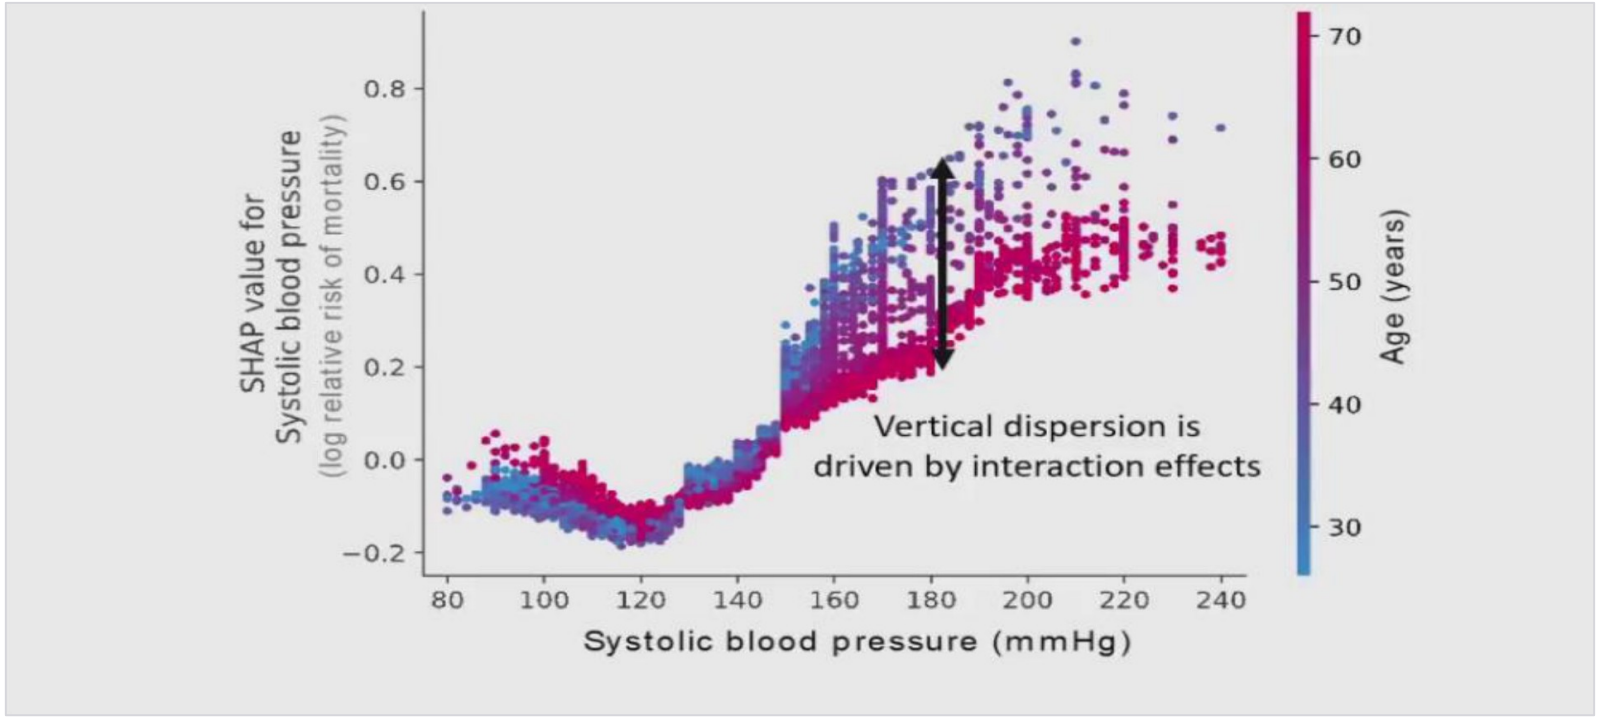


같은 혈압이라도 나이에 따라 위험 기여도가 다르다

두 개의 특성을 같이 고려한다 — 수축기 혈압의 SHAP 값, 색은 나이

그림 읽기

- 혈압이 120을 넘으면 위험 기여도가 커진다
- 같은 혈압에서 세로로 퍼진 폭은 상호작용 효과다
- 180 근처에서 젊은 사람(파랑)의 기여도가 더 크다

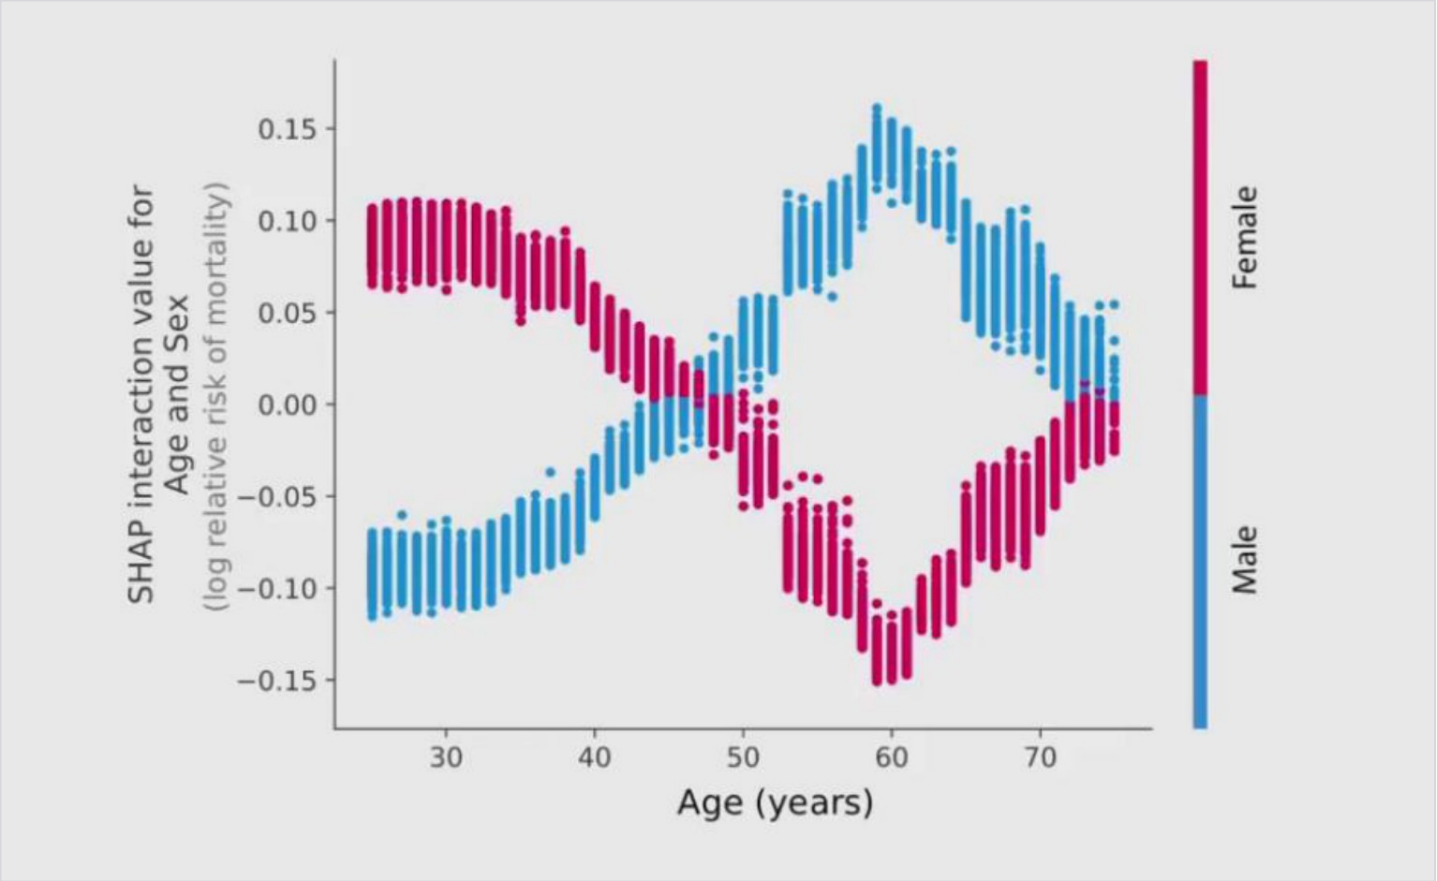


SHAP 상호작용 값은 나이의 효과를 성별에 따라 나눠 보여 준다

하나의 특성을 분해해 동시에 고려한다 — 나이와 성별의 SHAP 상호작용 값

그림 읽기

- 40세 이전에는 여성(빨강)의 상호작용 값이 양수, 남성(파랑)이 음수다
- 60세 전후에는 방향이 뒤집혀 남성 쪽이 크게 양수다
- 나이의 효과가 성별에 따라 다르다는 사실을 한 그림에서 읽는다

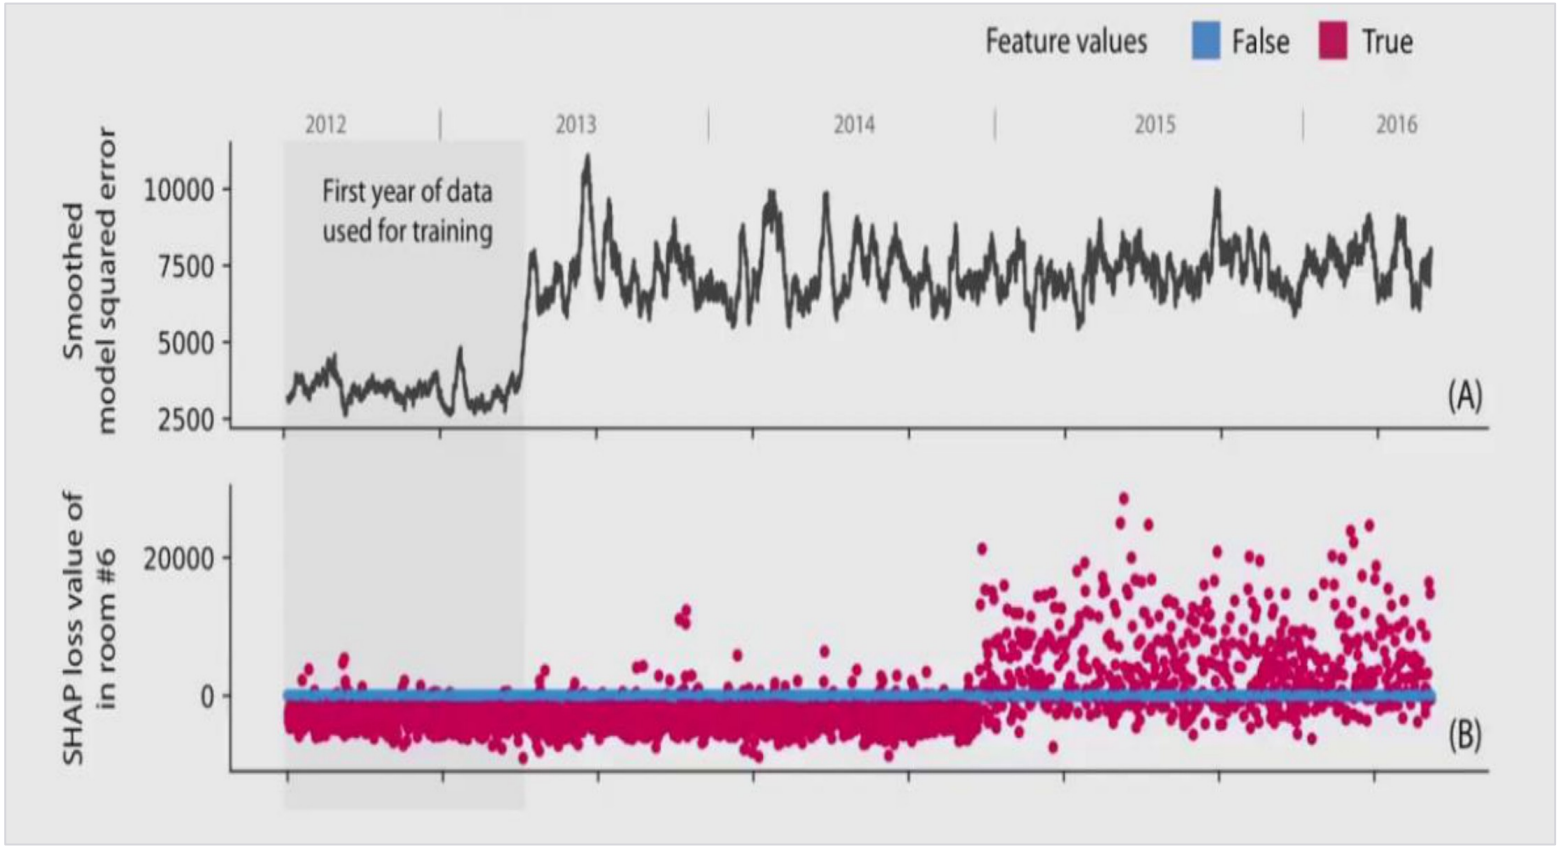


SHAP 손실 값으로 배포 뒤의 모델 오류 원인을 추적한다

시간에 따른 모델 모니터링 — (A) 평활한 모델 제곱오차, (B) 6번 수술실 특성의 SHAP 손실 값

그림 읽기

- 회색 구간(첫해)만 훈련에 썼다
- 2015년 무렵부터 6번 수술실 특성의 손실 기여가 커진다
- 오류가 늘어난 원인이 특정 특성임을 짚어 낸다

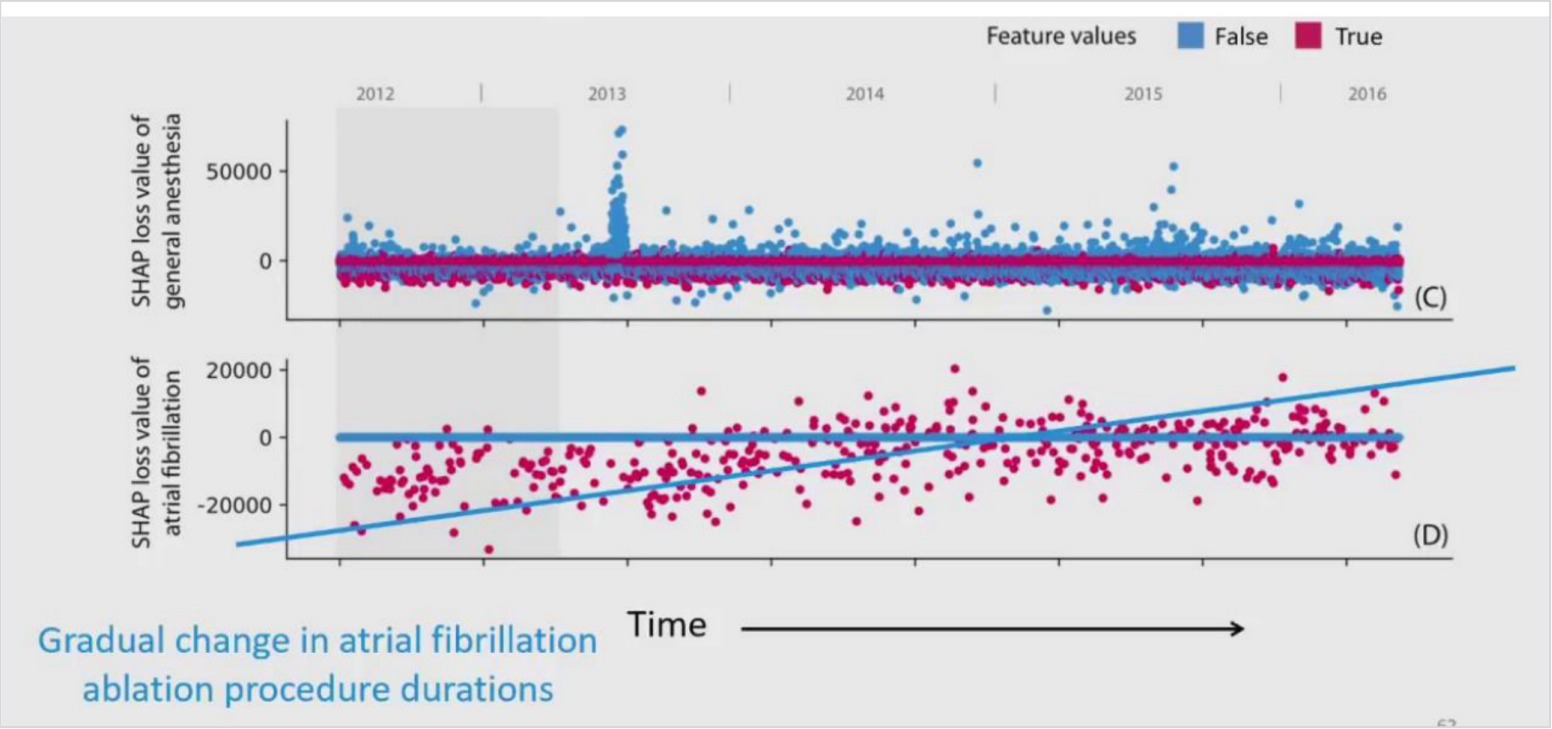


점진적인 데이터 변화도 SHAP 손실 값의 추세로 드러난다

시간에 따른 모델 모니터링 — (C) 전신마취, (D) 심방세동 특성의 SHAP 손실 값

그림 읽기

- (C) 2013년 초 전신마취 특성에 일시적 급등이 있다
- (D) 심방세동 특성의 손실 기여가 시간에 따라 꾸준히 오른다
- 심방세동 절제술 소요 시간이 서서히 바뀐 탓이다



03

PART 3 · XGBoost 실습

해석가능한 머신러닝: XGBoost로 배워 보자

Adult 데이터 — 연 소득 5만 달러 초과 여부를 예측하는 모델

XGBoost 기본 중요도는 나이를 가장 중요한 특성으로 꼽는다

XGBoost 기본 중요도 그림 — 기본값은 가중치(weight), 즉 분할에 쓰인 횟수

[입력] 프롬프트 ① · Claude Code (Code 탭)

```
adult-lab 폴더에서 다음을 해 줘.
1. 가상환경에 xgboost 3.4, shap 0.54를 설치하고
   requirements.txt로 고정해.
2. shap.datasets.adult()로 데이터를 불러와
  학습 80%, 테스트 20%로 나눠(random_state=7).
3. 이진 분류 모델을 학습해. eta 0.01, max_depth 4,
   subsample 0.5, 트리 최대 5000개, 조기 종료 20회.
4. weight, cover, gain 중요도를 각각 막대 그림으로
  그리고 순위를 importance.csv로 저장해.
5. 2026년 기준 API로 쓰고, 경고가 나면 알려 줘.
```

[확인] 결과에서 사람이 볼 점

- 1위가 weight는 Age, cover는 Capital Gain, gain은 Relationship인가?
- 트리 수가 5000개에 닿기 전에 조기 종료로 멈췄는가?
- 버전이 달라 수치가 그림과 달라도 1위가 같으면 된다

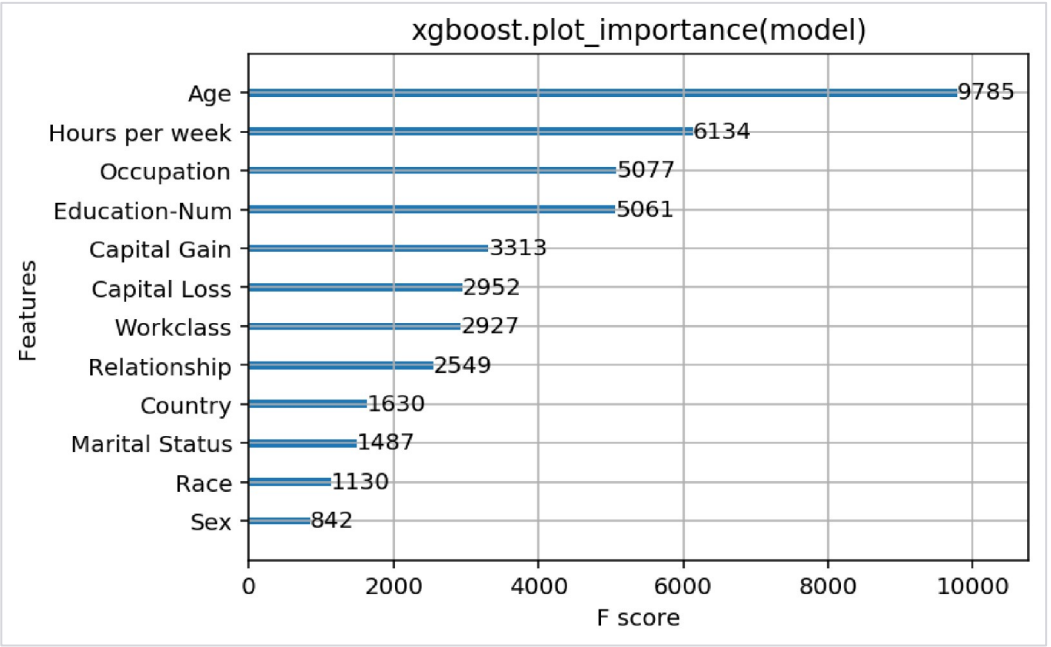


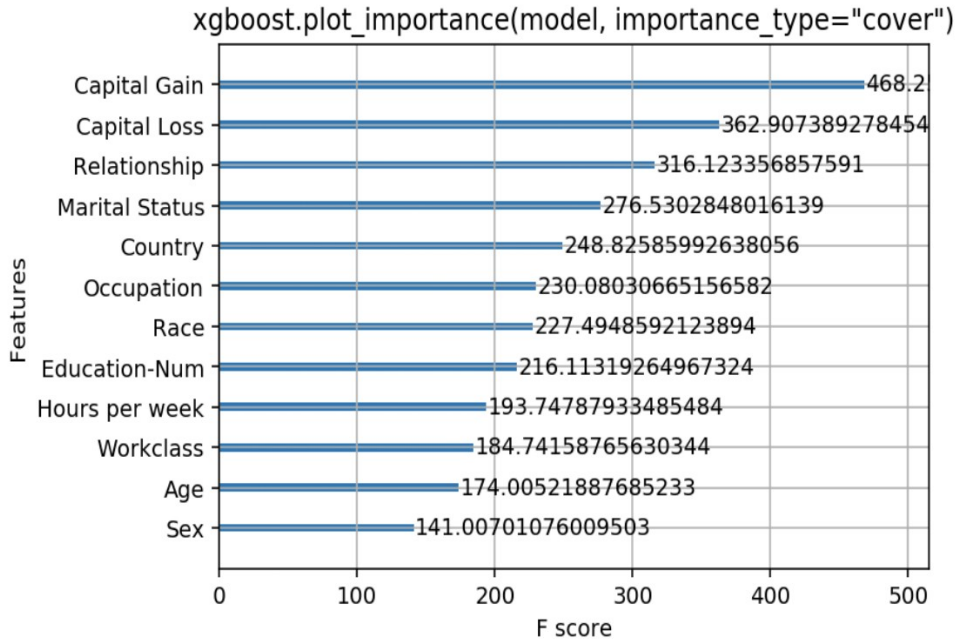
그림 읽기

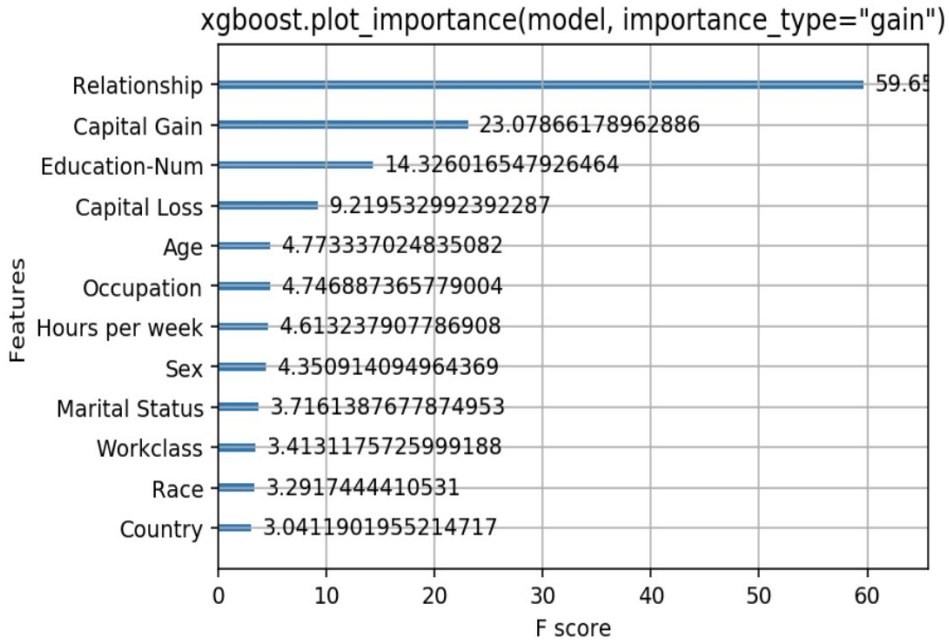
- Age 9785, Hours per week 6134, Occupation 5077 순이다
- 이 순서가 정말 모델이 의존하는 순서일까?

실망스럽게도 중요도 옵션에 따라 특성 순서가 달라진다

1위가 weight는 Age, cover(왼쪽)는 Capital Gain, gain(오른쪽)은 Relationship이다

- 가중치(Weight): 모든 트리에 걸쳐 데이터를 분할하는 데 특성이 사용된 횟수
- 커버리지(Cover): 분할을 통과하는 훈련 데이터 개수로 가중한, 특성이 분할에 사용된 횟수
- 개선도(Gain): 분할에 특성을 썼을 때의 평균 훈련 손실 감소



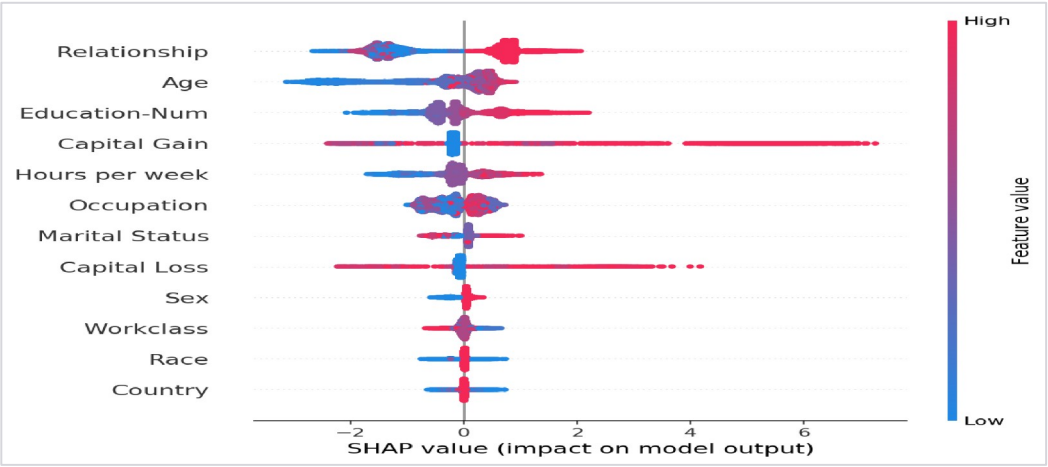


SHAP 값은 일관성과 가산성을 모두 갖춘 중요도를 준다

SHAP 요약 그림(summary plot) — 점 하나가 고객 한 명, 색은 특성 값(빨강 높음, 파랑 낮음)

[입력] 프롬프트 ② · Claude Code (Code 탭)

```
앞의 모델로 SHAP 분석을 해 줘.
1. TreeExplainer로 전체 X의 SHAP 값을 계산하고
   기준값과 더해 모델 출력(로그 오즈)과 맞는지 확인해.
2. 요약 그림을 summary.png로 저장해.
3. 의존 그림 세 장을 저장해: Age, Age(색 Education-Num),
   Hours per week(색 Relationship).
4. 평균 |SHAP| 순위를 shap_rank.csv로 저장하고
   상위 5개 특성의 영향 방향을 한 줄씩 설명해 줘.
```



[확인] 결과에서 사람이 볼 점

- 상위 세 특성이 Relationship, Age, Education-Num인가?
- 기준값과 SHAP 값의 합이 모델 출력과 맞는가?
- Age 의존 그림이 20대 초반 음수, 40~60세 정점인가?

그림 읽기

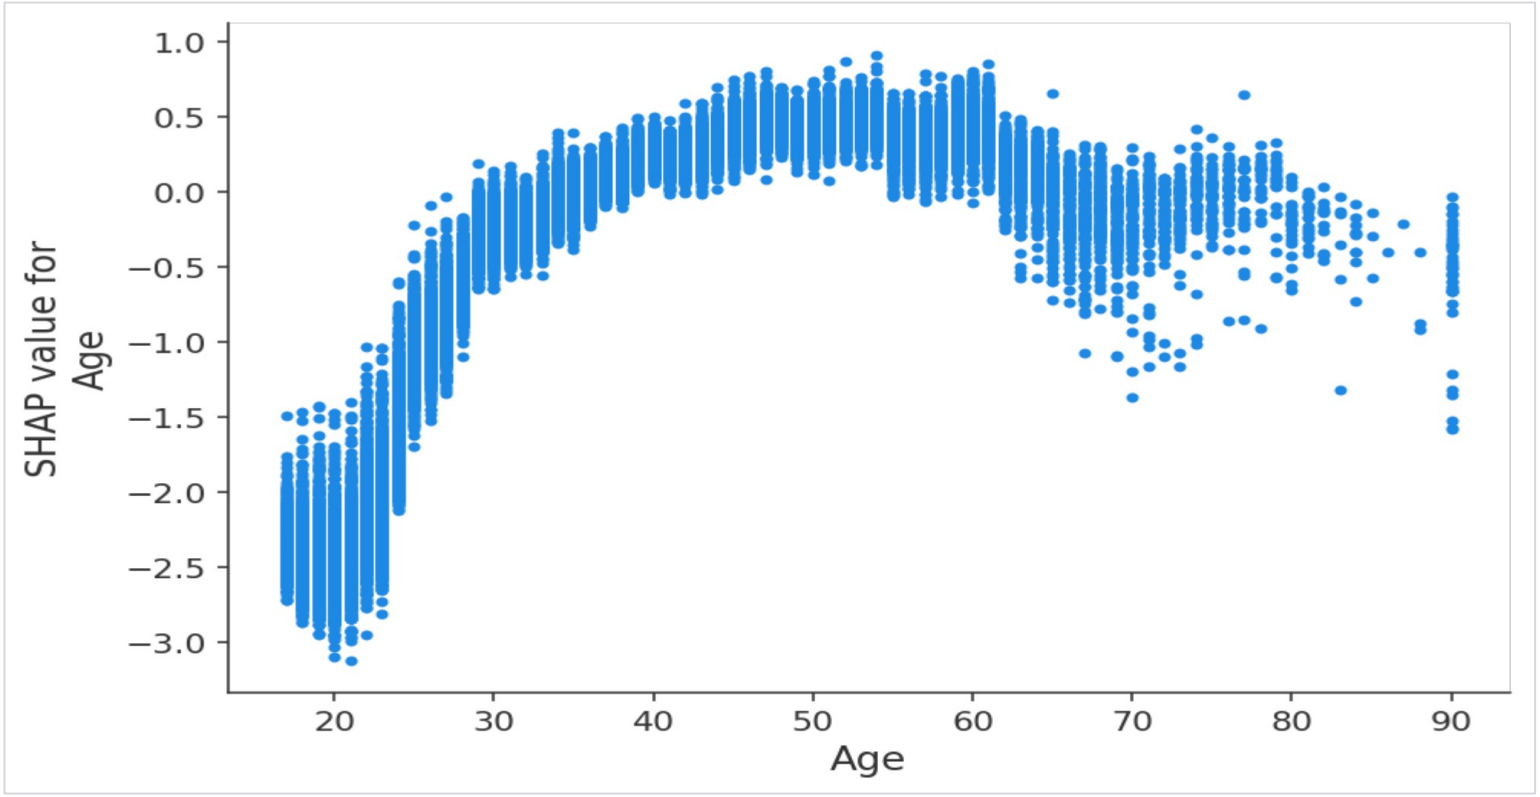
- Relationship, Age, Education-Num 순으로 영향이 크다
- Capital Gain은 드물지만 크면 매우 크게 올린다

소득 기여도는 나이에 따라 오르다가 60대부터 내려간다

특성과 SHAP 값 — 나이의 SHAP 의존 그림(dependence plot)

그림 읽기

- y축은 나이가 바뀔 때 연 5만 달러 초과 소득의 로그 오즈(log odds) 변화다
- 각 점은 데이터셋의 고객 한 명이다
- 20대 초반은 크게 음수, 40~60세가 정점이다

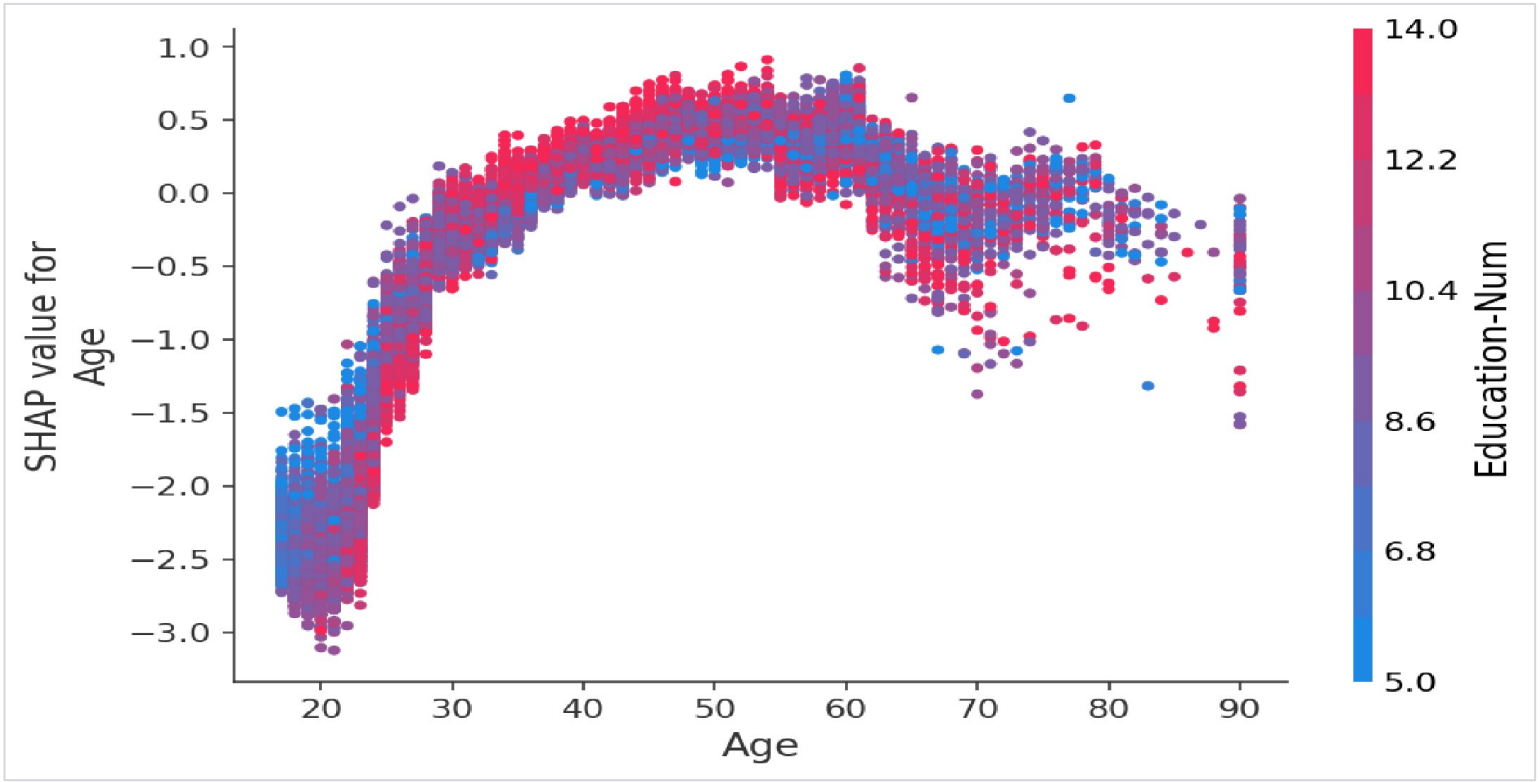


색을 더하면 나이 효과와 교육 연수의 상호작용이 보인다

특성과 SHAP 값 — 나이의 SHAP 값, 색은 Education-Num

그림 읽기

- y축은 나이에 따른 로그 오즈(log odds)의 변화다
- Education-Num은 고객이 마친 교육 연수다
- 같은 나이에서도 교육 연수에 따라 기여도가 달라진다

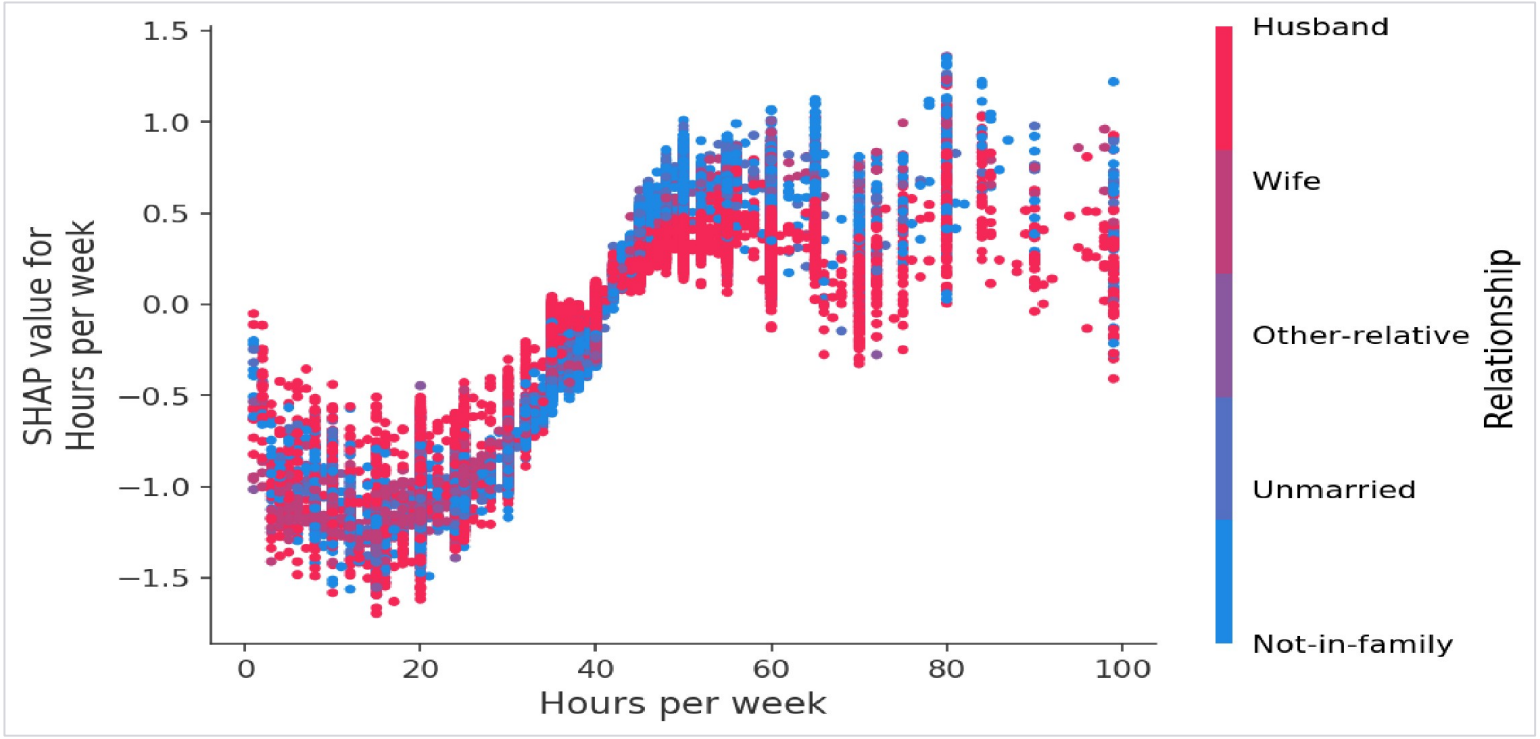


주당 근로시간이 40시간을 넘으면 소득 기여도가 양수로 바뀐다

특성과 SHAP 값 — 주당 근로시간의 SHAP 값, 색은 Relationship

그림 읽기

- 주당 근로시간과 근로시간이 이익 잠재력(potential)에 주는 영향이다
- 30시간 이하에서는 음수, 40~50시간에서 양수로 넘어간다
- 색(가족 관계)에 따라 같은 시간에서도 기여도가 다르다



근거를 설명할 수 있어야 모델을 믿고 고칠 수 있다

설명은 모델을 믿고 쓸 때, 고칠 때, 운영 중에 감시할 때 모두 필요하다

1

설명이 필요한 이유

엉뚱한 근거로 맞히는 모델을 걸러 내고, 대출 거절처럼 결정의 이유를 제시해야 한다

2

샤플리 값과 SHAP

개체마다 특성 기여도를 더해 예측을 재구성하고, 상호작용과 시간 변화까지 읽는다

3

XGBoost 실습

weight·cover·gain은 순서가 엇갈린다. 일관성과 가산성을 갖춘 SHAP 값으로 비교한다