

6주차 보강 수업 · 회귀분석

로지스틱 회귀모델

시그모이드 · 최대우도 · 혼동행렬 · ROC와 AUC · 정밀도-재현율

실습: 혼동행렬 손계산과 코스피 월간 방향 예측 (Python · scikit-learn · Colab)

이기홍 교수

오늘의 세 가지 메시지

강의가 끝나면 이 세 문장을 설명할 수 있어야 합니다

1

로지스틱 회귀는 확률을 내는 선형모델이다

특성의 선형결합을 시그모이드에 넣어 0~1 확률로 바꾸고, 최대우도로 계수를 찾는다.

2

분류는 임계값이 만든다

같은 모델도 임계값에 따라 혼동행렬이 달라진다. ROC 곡선은 모든 임계값을 한 장에 담는다.

3

지표는 목적과 기준선에 맞춘다

정확도만 보지 말고 재현율·정밀도·F1·AUC를 함께, 그리고 항상 단순 기준선과 비교한다.

정확도 55%는 좋은가? — 기준선이 50%인지 57%인지 모르면 답할 수 없다.

로드맵

모델 → 평가의 기본 셋업 → 혼동행렬 → ROC·AUC → 연습 → 코스피 실습 순서로 간다

#	섹션	핵심 질문
01	로지스틱 회귀모델	확률을 어떻게 만들고, 계수는 어떻게 찾는가?
02	분류 성과지표의 기본 셋업	확률을 어떻게 '비만/정상' 판정으로 바꾸는가?
03	혼동행렬과 성과지표	무엇을 맞히고 무엇을 틀렸는가?
04	ROC 곡선	임계값을 바꾸면 무엇이 달라지는가?
05	AUC와 정밀도-재현율	모델 전체를 숫자 하나로 비교하려면?
06	연습	혼동행렬을 손으로 채울 수 있는가?
07	코스피 방향 예측 실습	다음 달 상승·하락을 맞힐 수 있는가?

01

SECTION 01

로지스틱 회귀모델

시그모이드 · 오즈와 로그오즈 · 최대우도 · 규제


먼저 용어부터

분류 문제에서 계속 쓰는 말들 — 정의를 먼저 잡고 간다

용어	뜻	예
분류 (classification)	관찰을 정해진 범주 중 하나로 판정	비만/정상, 상승/하락
양성·음성 (positive/negative)	관심 사건 = 양성(1), 나머지 = 음성(0)	비만 = 1, 정상 = 0
확률 Q	양성일 가능성 (0~1)	$Q = 0.8$
오즈 (odds)	$Q / (1 - Q)$: 양성이 음성보다 몇 배 가능한가	$0.8 / 0.2 = 4$
로그오즈·로짓 (log-odds, logit)	$\ln(\text{오즈})$ — 로지스틱 회귀가 선형으로 모델링하는 값	$\ln 4 \approx 1.39$
임계값 (threshold)	확률을 판정으로 바꾸는 기준	$Q \geq 0.5 \rightarrow \text{양성}$
결정경계 (decision boundary)	$Q = \text{임계값}$ 이 되는 특성 공간의 경계	$Y = 0$ (임계값 0.5)

로지스틱 회귀: 모델

특성 데이터로 관찰을 '양성'과 '음성'으로 분류한다 — 선형결합 Y 를 시그모이드에 넣어 확률 Q 를 만든다



원본 수정: Y 식 마지막 항 $X_m \rightarrow b_m \cdot X_m$, '데이트' → 데이터

$$Q = P(y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-Y}}$$


$$Y = a + b_1X_1 + b_2X_2 + \cdots + b_mX_m$$

읽는 법

- Y 는 어떤 실수든 가능, Q 는 항상 0~1
- $Y = 0$ 이면 $Q = 0.5$
- L1·L2 규제도 적용 가능 (sklearn 'l1', 'l2')

시그모이드 함수로 데이터를 적합한다

체중(x)이 늘수록 비만(파랑)일 확률이 0에서 1로 S자를 그리며 올라간다




왜 선형회귀를 쓰지 않는가?

선형회귀와 로지스틱 회귀의 비교 — 0/1 목표에 직선을 맞추면 확률로 읽을 수 없다

차이


- 직선은 0 아래 · 1 위로 나간다
- 끝의 점 하나에 기울기가 끌려간다
- S자 곡선은 항상 0~1



계수 해석: 오즈와 로그오즈

로지스틱 회귀는 확률이 아니라 로그오즈를 특성의 선형함수로 놓는다

$$\ln \frac{Q}{1-Q} = Y = a + b_1 X_1 + \dots + b_m X_m$$



해석

- b_j : x_j 가 1 늘 때 로그오즈의 변화
- 확률 변화는 현재 Q에 따라 다르다

최대우도추정 (Maximum Likelihood Estimation)

계수 a, b 를 찾는 방법 — 아이디어와 식 하나

관측된 레이블이 가장 그럴듯해지도록 계수를 고른다.

오늘은 이 아이디어면 충분하다 — 계산은 scikit-learn의 fit()이 해 준다.

$$\max_{a, b} \sum_{\text{양성}} \ln Q_i + \sum_{\text{음성}} \ln(1 - Q_i)$$

말로 하면

- 실제 양성은 확률 Q 가 1에 가깝게
- 실제 음성은 Q 가 0에 가깝게
- 훈련 레이블이 가장 그럴듯해지는 계수가 '최대우도' 추정값

scikit-learn의 규제: C는 규제 강도의 역수

릿지·라쏘와 같은 L2·L1 벌점을 쓰지만, 손잡이 C의 방향이 반대다

$$\text{L2} : \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^m \ell_i$$

$$\text{L1} : \min_{\mathbf{w}, b} \|\mathbf{w}\|_1 + C \sum_{i=1}^m \ell_i \quad C = \frac{1}{\lambda}$$

C 읽는 법

- $C = 1/\lambda$: C가 작을수록 규제가 강하다
- 선형회귀의 alpha와 방향이 반대
- 기본값 $C = 1.0$, `penalty = 'l2'`
- L1은 계수를 0으로 → 변수 선택

실무 메모

- 규제는 스케일에 민감 → 반드시 표준화
- L1은 `liblinear`·`saga` 솔버에서 지원
- scikit-learn 1.8부터 `penalty` 대신 `l1_ratio` ($1 = \text{L1}$, $0 = \text{L2}$)
- C는 교차검증으로 고른다

02



SECTION 02

분류 성과지표를 위한 기본 셋업

※ 분류에서 가장 중요한 개념 — 확률에서 판정으로




체중으로 비만과 정상을 분류한다

왼쪽: 데이터 (파랑 = 비만, 빨강 = 정상) · 오른쪽: 로지스틱 곡선으로 적합



y축은 비만일 확률이다


왼쪽: y축을 확률로 읽는다 · 오른쪽 위: 무거우면 비만일 확률이 높다 · 오른쪽 아래: 가벼우면 낮다




임계값 0.5로 확률을 판정으로 바꾼다

확률이 0.5보다 크면 비만, 작으면 정상으로 분류한다

임계값을 0.5로 지정해
비만/정상을 분류할 수 있다.





이경우 비만으로 분류될 것이다.





실제 정답과 겹쳐 본다

빨간 점은 실제 정상, 파란 점은 실제 비만 — 이제 판정과 정답을 비교할 수 있다





정분류와 오분류 (1)

왼쪽: 정상을 정상으로 — 정분류 · 오른쪽: 비만을 정상으로 — 오분류



정분류와 오분류 (2)

왼쪽: 정상을 비만으로 — 오분류 · 오른쪽: 비만을 비만으로 — 정분류. 8마리 중 6마리를 맞혔다



03

SECTION 03

혼동행렬과 성과지표

정확도 · 재현율 · 정밀도 · F1 · 민감도 · 특이도

혼동행렬 (Confusion Matrix)

앞의 8마리를 표로 정리하면: 비만 3·1, 정상 1·3

배치 주의

- 이 그림: 행 = 예측, 열 = 실제
- sklearn: 행 = 실제, 열 = 예측
- 배치만 다르고 내용은 같다

		Actual	
		Is Obese	Is Not Obese
Predicted	Is Obese	3	1
	Is Not Obese	1	3

네 칸의 이름과 기본 지표

참(True)/거짓(False)은 맞혔는지, 양성(Positive)/음성(Negative)은 모델이 무엇이라고 했는지

	실제: 비만	실제: 정상
예측: 비만	참양성 (TP) 3	거짓양성 (FP) 1
예측: 정상	거짓음성 (FN) 1	참음성 (TN) 3

앞 장의 생쥐 8마리를 네 칸으로 나누는 것

$$\text{정확도} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{재현율} = \frac{TP}{TP + FN}$$

$$\text{정밀도} = \frac{TP}{TP + FP}$$

재현율: 실제 양성 중 몇 개를 잡았나 · 정밀도: 양성이라 한 것 중 몇 개가 진짜인가

성과지표 한눈에

같은 네 칸에서 나오는 지표들 — 이름이 여러 개인 경우가 많다

지표	식	묻는 질문	다른 이름
정확도 (Accuracy)	$(TP+TN) / \text{전체}$	전체 중 몇 개를 맞혔나?	1 - 오분류율
정밀도 (Precision)	$TP / (TP+FP)$	양성 판정 중 진짜 양성은?	양성예측도 (PPV)
재현율 (Recall)	$TP / (TP+FN)$	실제 양성 중 몇 개를 잡았나?	민감도 · TPR
특이도 (Specificity)	$TN / (TN+FP)$	실제 음성을 음성이라 한 비율은?	참음성률 (TNR)
거짓양성률 (FPR)	$FP / (FP+TN)$	실제 음성을 양성이라 한 비율은?	1 - 특이도
F1 점수	$2PR / (P+R)$	정밀도와 재현율이 둘 다 높은가?	조화평균

예제: 모두 민간인이라고 예측하면?

반대 지시: 아무도 잡지 않으면 — 100명 중 99명을 맞히지만, 테러리스트 1명은 그대로 통과

	실제 테러리스트	실제 아님	합계
테러리스트로 예측	0 (TP)	0 (FP)	0
아니라고 예측	1 (FN)	99 (TN)	100
합계	1	99	100

$$Acc = \frac{0 + 99}{100} = 0.99 \quad R = \frac{0}{0 + 1} = 0 \quad P = \frac{0}{0 + 0}$$

양성이 드물면, 한 번도 '양성'이라 하지 않는 모델도 정확도 99% — 정확도만으로는 판단할 수 없다.

읽는 법

- 정확도 99% — 훌륭해 보인다
- 재현율 0%: 테러리스트 1명을 놓친다
- 정밀도는 0/0 — 정의되지 않음 (sklearn은 0으로 보고)
- $F1 = 0$
- 다음 장: 반대로 — 모두 잡으면

예제: 모두 테러리스트라고 예측하면?

'무조건 잡아라'는 특명에 100명 전원을 테러리스트로 판정 — 실제 테러리스트는 1명

	실제 테러리스트	실제 아님	합계
테러리스트로 예측	1 (TP)	99 (FP)	100
아니라고 예측	0 (FN)	0 (TN)	0
합계	1	99	100

$$P = \frac{1}{1 + 99} = 0.01 \quad R = \frac{1}{1 + 0} = 1 \quad F_1 = \frac{2(0.01)(1)}{0.01 + 1} \approx 0.02$$

원본의 '평균은 여전히 50%로 높음'은 산술평균을 말한다 — 그래서 조화평균인 F1이 필요하다.

읽는 법

- 재현율 100%, 정밀도 1%
- 정확도 1% — '모두 민간인'은 99%였다
- 산술평균은 50.5%로 그럴듯해 보인다
- $F1 \approx 2\%$ 가 실상을 보여 준다
- 다음 장: 둘을 한 점수로, F1

F1 점수: 정밀도와 재현율의 조화평균

둘 중 하나라도 0에 가까우면 F1도 0에 가까워진다 — 높은 F1은 둘 다 높아야 나온다

$$F_1 = \frac{2}{\frac{1}{P} + \frac{1}{R}} = \frac{2PR}{P + R}$$

언제 무엇을

- 놓치면 비싸다 → 재현율 중시
- 헛경보가 비싸다 → 정밀도 중시
- 둘 다 중요 → F1

정밀도 P	재현율 R	산술평균	F1
0.01	1.00	0.505	0.020
0.50	0.50	0.500	0.500
0.60	0.80	0.700	0.686
0.90	0.10	0.500	0.180

원본 수정: 'F!' → F1, 'recal' → recall

놓침(FN)이 비싼 일, 헛경보(FP)가 비싼 일

경보 뒤에 사람이 한 번 더 확인하는 관문이 있으면 재현율을 올리고, 경보가 곧 최종 조치면 정밀도를 올린다

상황	놓침(FN)의 대가	헛경보(FP)의 대가	2차 관문	우선 지표
공항 보안 검색	대형 인명 피해	2차 검색 몇 분	있음	재현율
암 선별검사	치료 시기를 놓침	추가 검사·불안	있음	재현율
이상거래 탐지	사기 손실·제재	분석가 재확인	있음	재현율
신약 후보 선별	좋은 후보를 버림	실험 한 번 더	있음	재현율
스팸 필터	스팸 한 통을 봄	중요 메일 유실	없음	정밀도
매매신호 집행	기회를 놓침	실제 손실 발생	없음	정밀도

테러 예제가 재현율 쪽인 이유: 공항에는 2차 검색 관문이 있어 FP 한 건이 싸다 — 그래도 정밀도 1%는 너무 낮다.

민감도와 특이도

민감도(= 재현율): 실제 양성을 양성으로 · 특이도: 실제 음성을 음성으로 판정한 비율

$$\text{Sensitivity} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

		Actual	
		Has Heart Disease	Does Not Have Heart Disease
Predicted	Has Heart Disease	True Positives	False Positives
	Does Not Have Heart Disease	False Negatives	True Negatives

$$\text{Specificity} = \frac{\text{True Negatives}}{\text{True Negatives} + \text{False Positives}}$$

		Actual	
		Has Heart Disease	Does Not Have Heart Disease
Predicted	Has Heart Disease	True Positives	False Positives
	Does Not Have Heart Disease	False Negatives	True Negatives

민감도와 특이도 구하기

심장병 예제: 303명 중 심장병 171명, 정상 132명

	Has Heart Disease	Does Not Have Heart Disease
Has Heart Disease	139	20
Does Not Have Heart Disease	32	112

$$\text{민감도} = \frac{139}{139 + 32} = 0.81 \quad \text{특이도} = \frac{112}{112 + 20} = 0.85$$

지표	계산	값
정밀도	$139 / (139 + 20)$	0.874
정확도	$(139 + 112) / 303$	0.828
F1	$2PR / (P + R)$	0.842

같은 모델이라도 어떤 지표를 보느냐에 따라 인상이 달라진다 — 목적에 맞는 지표를 먼저 정한다.

04

SECTION 04

ROC 곡선


임계값을 바꾸면 혼동행렬이 바뀐다 — 그 모든 경우를 한 장에

임계값을 0.1로 낮추면

비만은 모두 잡아낸다(TP 4, FN 0). 대신 정상 2마리를 비만으로 잘못 판정한다(FP 2)


		Actual	
		Infected	Not Infected
Predicted	Infected	4	2
	Not Infected	0	2

임계값을 낮추면 거짓양성(비만으로 예측했는데 틀린것)은 높아지지만 양성은 다 잡아낸다.



임계값을 0.9로 높이면

정상은 모두 맞히고(FP 0) 비만 1마리를 놓친다(FN 1). 정확도는 $7/8 = 0.875$ 로 가장 높다




임계값을 높이면, 이 경우 분류 정확도가 더 높아진 것을 알 수 있다.

임계값은 어떻게 정할까?

임계값마다 혼동행렬을 그리면 비교할 표가 너무 많아진다

문제

- 임계값은 무수히 많다
- 표 여러 장은 비교가 어렵다
- → 한 장의 그림으로




ROC 그래프로 한눈에

ROC(Receiver Operating Characteristic): 임계값마다 (거짓양성률, 참양성률) 점을 찍은 그래프

구성



- y축: 참양성률 = 민감도
- x축: 거짓양성률 = 1 - 특이도
- 점 하나 = 임계값 하나



y축: 참양성률 (민감도)

실제 비만 가운데 비만으로 맞힌 비율



$$\text{TPR} = \text{민감도} = \frac{TP}{TP + FN}$$



x축: 거짓양성률 (1 - 특이도)


실제 정상 가운데 비만으로 잘못 판정한 비율

$$FPR = 1 - \text{특이도} = \frac{FP}{FP + TN}$$




임계값이 아주 낮으면: 점 (1, 1)

모두 비만으로 판정 → $TPR = 4/4 = 1$, $FPR = 4/4 = 1$. 초록 대각선은 $TPR = FPR$ 인 '찍기' 수준





- 초록색선은 참양성율과 거짓양성율이 같은 경우를 표시하며, 예에서 비만을 비만으로 정확하게 분류하는 비율과 정상을 비만으로 오분류하는 비율이 같은 경우를 의미한다.





조금 올리면: 점 (0.75, 1)

정상 1마리만 정상으로 → TPR 1, FPR 3/4 = 0.75. 대각선 왼쪽 = 첫 임계값보다 낮다




더 올리면: 점 (0.5, 1)

TPR은 그대로 1, FPR은 $2/4 = 0.5$ 로 줄었다




계속 올리면: (0.25, 0.75) → (0, 0.75)

점 (0, 0.75)의 임계값은 비만 75%를 잡으면서 정상은 100% 맞힌다





새로운 점 (0, 0.75)에 의해
표현되는 임계값은 75%의
비만샘플과 100%의 정상샘플
정확하게 분류한다.



끝까지 올린 뒤 점을 잇는다

임계값을 최대로 올리면 점 (0, 0) — 모든 점을 이르면 ROC 곡선이 된다




왼쪽 위로 갈수록 좋은 임계값

같은 TPR이면 FPR이 낮은 쪽이 낫다: (0, 0.75)가 (0.25, 0.75)보다 좋다

읽는 법



- 왼쪽 위 (0, 1) = 완벽
- 대각선 = 무작위
- 대각선 아래 = 거꾸로 맞힘

왼쪽의 임계값이 이 임계값보다 나음을 알 수 있다.



한 장으로 보는 ROC 작성법

점수를 정렬하고 임계값을 한 칸씩 옮기며 (FPR, TPR)을 찍는다 — 앞 예제를 다시 계산한 결과



임계값은 오류의 비용으로 정한다

ROC는 선택지를 보여 줄 뿐, 어느 점을 쓸지는 업무가 정한다

$$J = \text{TPR} - \text{FPR} = \text{민감도} + \text{특이도} - 1$$

비용이 비슷할 때의 기준: Youden 지수 J가 가장 큰 임계값

놓치면 비싼 경우 → 임계값 ↓

- 암 진단, 사기 거래 탐지
- 재현율(민감도)을 우선
- 헛경보는 2차 검사로 거른다

헛경보가 비싼 경우 → 임계값 ↑

- 스팸 필터, 매매 신호 (거래비용)
- 정밀도(특이도)를 우선
- 확신이 클 때만 행동

05

SECTION 05


AUC와 정밀도-재현율 곡선

모델 전체를 숫자 하나로 — 그리고 불균형 데이터에서의 주의점

ROC AUC: 곡선 아래 면적

예제의 AUC = 0.9 (정확히는 0.906) — 임계값과 무관하게 모델의 순위 매기기 능력을 잴다

AUC(곡선 아래의 면적) = 0.9



$$AUC = P(\hat{s}(x^+) > \hat{s}(x^-))$$

읽는 법

- 1 = 완벽, 0.5 = 무작위
- 양성·음성을 하나씩 뽑았을 때 양성 점수가 더 높을 확률
- 예제: 16쌍 중 14.5쌍 → 0.906


AUC로 모델을 비교한다

빨강(로지스틱 회귀)이 파랑(랜덤 포레스트)보다 면적이 크다 → 로지스틱 회귀를 고른다

주의

- 곡선이 교차하면 AUC만으로 부족
- 실제 쓸 구간(FPR 범위)을 본다
- AUC는 보정(확률 정확도)을 재지 않는다

빨간 ROC 곡선이 로지스틱 회귀를 나타내고 파란 ROC 곡선이 랜덤 포레스트를 나타내면, 로지스틱 회귀를 선택할 것이다.




FPR 대신 정밀도: 정밀도-재현율 곡선

정밀도는 참음성(TN)을 쓰지 않는다 — 음성이 압도적으로 많을 때 양성 쪽 성과를 드러낸다

원본 수정

- '불균형에 영향 없음'은 틀림
- 정밀도는 양성 비율에 좌우된다
- PR 기준선 = 양성 비율



06

SECTION 06

연습: 혼동행렬 손으로 채우기

예측 10개 → 네 칸 → 정확도·정밀도·재현율·특이도·F1

연습: 정확도와 혼동행렬 구하기

10개 중 3개를 틀렸다 → 오분류율 0.3, 정확도 0.7. 혼동행렬까지 채워 보자

Idx	y	y_hat
1	1	1
2	1	1
3	1	0
4	1	1
5	1	1
6	0	0
7	0	0
8	0	1
9	0	1
10	0	0

	실제 1	실제 0
예측 1	TP = 4	FP = 2
예측 0	FN = 1	TN = 3

지표	계산	값
정확도	$(4+3) / 10$	0.70
정밀도	$4 / 6$	0.67
재현율	$4 / 5$	0.80
특이도	$3 / 5$	0.60
F1	$2PR / (P+R)$	0.73

07

SECTION 07

코스피 방향 예측 실습


Colab 노트북: 이번 달 지표로 다음 달 코스피 상승·하락을 맞힐 수 있는가

목표변수: 다음 달에 오르면 1

한 행 = 이번 달 지표 29개 + 다음 달 방향 — 각 행은 독립 관측치다

원본 노트북 코드

```
kospi['다음달'] = kospi['코스피지수'].shift(-1)
kospi = kospi[:-1] # 마지막 달 제외
def classify(current, future):
    return 1 if future > current else 0
kospi['target'] = list(map(classify,
    kospi['코스피지수'], kospi['다음달']))
```



159개월

- 상승 91 (57%) · 하락·보합 68 (43%)

원본 노트북 결과: 정확도 0.525

L1 로지스틱 회귀 (liblinear, C = 10), 무작위 75/25 분할

원본 노트북 코드

```
X_train, X_test, y_train, y_test = \
    train_test_split(X, y, random_state=42)
lr = LogisticRegression(solver='liblinear',
                        penalty='l1', C=10)
lr.fit(X_train, y_train)
accuracy_score(y_pred, y_test) # 0.525
```

0.55

모델 정확도 (테스트
40개)

0.50

테스트 세트 상승
비율

다시 실행하면

- 저장된 출력(157행, 0.525)은 첫 두 행이 빠진 상태의 결과
- 처음부터 실행하면 159행, 정확도 0.55

첫 질문

- 기준선은 얼마인가?
- '항상 상승' 예측과 비교해야 한다

혼동행렬로 다시 보면

처음부터 다시 실행한 결과 (159행, 무작위 분할, 테스트 40개)

	실제 상승	실제 하락
예측 상승	TP = 13	FP = 11
예측 하락	FN = 7	TN = 9

지표	값
정확도	0.550
정밀도	0.542
재현율	0.650
F1	0.591
ROC AUC	≈ 0.55

해석

- AUC 0.55: 동전 던지기(0.50)와 거의 같다
- 상승을 조금 더 자주 외쳐 재현율만 높다
- 스케일을 맞춰도(StandardScaler) 정확도 0.55, AUC 0.56 — 결론은 같다

함정 1: 기준선 없이 정확도를 읽는다

코스피는 159개월 중 57%가 올랐다 — '항상 상승'만 외쳐도 그만큼 맞는다

0.550

로지스틱 회귀 (무작위
분할)

0.500

항상 상승 (무작위 분할
테스트)

0.545

로지스틱 회귀 (무작위
분할 100회 평균)

0.570

항상 상승 (같은 100회
분할)

기준선 후보

- 다수 클래스 (항상 상승)
- 무작위 추측 (AUC 0.5)

원칙

- 모델 지표는 기준선과 나란히 보고한다
- 불균형이면 정확도 대신 AUC·F1도 함께

함정 2: 표준화 없이 L1 규제를 건다

특성 단위가 제각각이면 벌점도 제각각 — 출국자 수(수십만 명)와 금리(몇 %)가 같은 벌점을 받는다

Python · Colab (수정)

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
model = make_pipeline(
    StandardScaler(),
    LogisticRegression(solver='liblinear',
                       penalty='l1', C=10))
```

파이프라인의 장점

- 교차검증 때도 스케일러가 훈련 폴드에서만 fit된다

왜 중요한가

- L1·L2 벌점은 계수 크기에 걸린다
- 단위가 크면 계수가 작아 벌점을 덜 받는다
- scikit-learn 1.8+: penalty 대신 l1_ratio=1

월간 지수 방향은 동전 던지기에 가깝다

무작위 75/25 분할을 100번 반복하면 정확도 평균 0.545 — 항상 상승(0.570)보다 낮다

정확도 55%가 의미를 가지려면 세 관문을 넘어야 한다

1 기준선을 넘는가

같은 분할의 항상 상승(0.570)을 이겨야 한다 — 100번 중 40번만 이겼다

2 다른 무작위 분할에서도 반복되는가

분할 한 번은 표본 하나다 — 100번 분할에서 정확도는 0.375~0.725

3 비용 뒤에도 남는가

적중률 몇 %p 차이는 거래비용·세금에 쉽게 사라진다

토론 질문

Q1

비만 예제에서 임계값 0.9의 정확도가 가장 높았다. 그래도 0.9를 쓰면 안 되는 상황은?

임계값**Q2**

사기 거래가 0.1%인 데이터에서 AUC 0.95 모델을 받았다. 무엇을 더 확인해야 하나?

불균형**Q3**

다음 달 방향 대신 '다음 달 수익률이 -5% 이하일 확률'을 예측하도록 바꾸면 무엇이 달라지나?

설계

요약

1

로지스틱 회귀 = 로그오즈의 선형모델

시그모이드로 확률을 만들고 최대우도로 적합한다. C는 규제의 역수.

2

임계값 → 혼동행렬 → 지표

정밀도·재현율·F1·특이도는 같은 네 칸에서 나온다. ROC는 모든 임계값을, AUC는 순위 능력을 요약한다.

3

기준선과 비교하고 분할 한 번에 기대지 않는다

코스피 방향 예측은 기준선을 넘지 못했다. 불균형 데이터에서는 PR 곡선도 함께 본다.

과제: 한국어 Colab 노트북을 실행해 7절의 숫자를 직접 재현해 보라.