


머신러닝 알고리즘 계보도

알고리즘을 외우기 전에 어느 가족인지부터 봅니다



Machine Learning Algorithm Family Tree

머신러닝 알고리즘은 네 가족으로 나뉩니다

원본 인포그래픽 전체 — 이후 장에서 가족별로 확대해 읽는다

지도학습

정답 y 가 있는 데이터 — 회귀·분류
Supervised

비지도학습

입력 X 만 있는 데이터 — 군집화·차원축소
Unsupervised

앙상블


여러 모형 결합 — 배깅·부스팅
Ensemble

강화학습

환경과 상호작용하며 보상 최대화
Reinforcement

알고리즘 이름보다 학습 신호가 먼저입니다

Machine Learning Algorithm Family Tree



네 가족은 최적화하는 목표가 서로 다릅니다

기본 지식 — 각 가족이 무엇을 최소화·최대화하는지 한 줄 식으로 정리한다

지도학습 · 예측 오차 최소화

$$\hat{f} = \arg \min_f \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$$

비지도학습 · 데이터 구조(분포) 학습

$$\hat{\theta} = \arg \max_{\theta} \sum_{i=1}^n \log p_{\theta}(x_i)$$

앙상블 · 약한 모형의 가중 결합

$$F(x) = \sum_{m=1}^M \alpha_m h_m(x)$$

강화학습 · 누적 할인 보상 최대화

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

목표함수를 보면 그 알고리즘이 어느 가족인지 바로 드러납니다

01

지도학습 (Supervised Learning)

정답 레이블 y 가 붙은 데이터로 입력 $X \rightarrow$ 출력 y 의 관계를 배운다


지도학습은 목표변수의 형태에 따라 회귀와 분류로 갈립니다

Learn from labeled data (X, y) — 원본 상단 구획

REGRESSION vs CLASSIFICATION

y 는 연속인가 범주인가


- 회귀 — 가격·수익률
- 분류 — 부도 여부·등급
- y 형태가 손실을 정한다



회귀는 오차의 크기를, 분류는 경계의 위치를 학습합니다

회귀 알고리즘은 선형모형에서 트리 부스팅까지 이어집니다

Regression (Predict continuous values) — 원본의 회귀 열 7개 알고리즘



선형 → 규제(Ridge·Lasso·Elastic Net) → 마진(SVR) → 트리·부스팅 순으로 유연해진다

유연성이 커질수록 과적합 통제가 핵심 과제가 됩니다

규제항의 종류가 회귀계수의 모양을 결정합니다

Ridge(L2)는 계수를 고르게 줄이고, Lasso(L1)는 일부를 정확히 0으로 만든다

Ridge · L2 규제

$$\min_w \sum_i (y_i - w^\top x_i)^2 + \lambda \|w\|_2^2$$

Lasso · L1 규제 (변수 선택)

$$\min_w \sum_i (y_i - w^\top x_i)^2 + \lambda \|w\|_1$$

Elastic Net · L1 + L2

$$\min_w \sum_i (y_i - w^\top x_i)^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$$


SVR · ϵ -무감 손실 (ϵ -insensitive loss)

$$L_\epsilon(y, f(x)) = \max(0, |y - f(x)| - \epsilon)$$

λ 는 편향과 분산을 맞바꾸는 손잡이이며 교차검증으로 고릅니다

분류 알고리즘은 확률·마진·이웃·트리 네 갈래로 묶입니다

Classification (Predict discrete classes) — 원본의 분류 열 8개 알고리즘



Logistic·Naive Bayes는 확률, SVM은 마진, KNN은 이웃, 트리 계열은 분할 규칙

실무 정형 데이터에서는 GBM 계열(XGBoost·LightGBM·CatBoost)이 기본 출발점입니다

분류기마다 결정 경계를 만드는 원리가 다릅니다

시그모이드가 선형 점수를 확률로 바꾸고, KNN은 가장 가까운 k개 이웃만 본다

Logistic Regression · 교차엔트로피 최소화

$$\mathcal{L} = - \sum_i \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] \\ p_i = \sigma(w^\top x_i + b)$$

SVM · 마진 최대화 (마진 = $2/\|w\|$)

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1$$

KNN · k개 이웃의 다수결

$$\hat{y}(x) = \arg \max_c \sum_{i \in N_k(x)} \mathbf{1}[y_i = c]$$

Naive Bayes · 조건부 독립 가정

$$P(C \mid x) \propto P(C) \prod_{j=1}^d P(x_j \mid C)$$

확률 출력이 필요하면 Logistic, 고차원·소표본이면 SVM이 출발점입니다

02

비지도학습 (Unsupervised Learning)

레이블 없이 입력 X만으로 군집과 저차원 구조를 찾는다


비지도학습은 군집화와 차원축소 두 과제로 나뉩니다

Learn from unlabeled data (X) — 원본 상단 구획

CLUSTERING vs DIM. REDUCTION

행을 묶나, 열을 줄이나


- 군집화 — 표본(행)을 묶음
- 차원축소 — 특성(열) 압축
- 지도학습 전처리로도 사용



정답이 없으므로 결과 해석과 검증 설계가 모형 선택만큼 중요합니다

군집화 알고리즘은 거리·밀도·계층·확률 기준으로 구분됩니다


Clustering (Group similar samples) — 원본의 군집화 열 5개 알고리즘



K-Means·K-Medoids는 중심 거리, DBSCAN은 밀도, 계층 군집은 병합 트리, GMM은 확률 군집 모양이 둥글지 않거나 이상치가 많으면 DBSCAN·GMM을 먼저 검토합니다

차원축소는 선형 분산 보존에서 비선형 구조 보존으로 확장됩니다

Dimensionality Reduction (Reduce features & visualize) — 원본의 차원축소 열 4개 알고리즘



PCA는 분산 최대 방향, t-SNE는 국소 구조, UMAP은 국소·전역 구조, 오토인코더는 신경망 압축
t-SNE·UMAP은 시각화용이며 축의 거리 자체를 해석하지 않습니다

비지도학습 알고리즘도 명확한 목적함수를 가집니다

Σ 는 공분산행렬, f_ϕ 와 g_θ 는 오토인코더의 인코더·디코더

K-Means · 군집 내 제곱합(SSE) 최소화

$$\min_{\{C_k, \mu_k\}} \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

GMM · 가우시안 혼합 (soft clustering)

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$$

PCA · 분산 최대 방향 = 고유벡터

$$w_1 = \arg \max_{\|w\|=1} w^\top \Sigma w \Rightarrow \Sigma w_1 = \lambda_1 w_1$$

Autoencoder · 복원 오차 최소화

$$\min_{\phi, \theta} \sum_i \|x_i - g_\theta(f_\phi(x_i))\|^2$$

K-Means는 GMM에서 공분산을 같게 두고 할당을 0/1로 만든 특수한 경우입니다

03

앙상블과 강화학습

모형을 결합해 성능을 높이는 방법과, 보상으로 행동 정책을 배우는 방법


배깅은 분산을, 부스팅은 편향을 줄입니다

Ensemble Learning (Powerful Combinations) — 원본 하단 좌측 구획

BAGGING vs BOOSTING

병렬 평균, 순차 보정

- 배깅 — 독립 학습 후 평균
- 부스팅 — 앞 모형 잔차 학습
- 오차 원인에 맞춰 고른다



깊은 트리의 과적합엔 배깅, 얇은 트리의 과소적합엔 부스팅이 맞습니다

두 앙상블은 수식 구조부터 다릅니다

배깅의 효과는 모형 간 상관인, 부스팅의 보폭은 학습률(shrinkage)이 정한다

Bagging · B개 모형의 평균

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}_b(x)$$

Bagging · 평균의 분산

$$\text{Var}(\hat{f}_{\text{bag}}) = \rho \sigma^2 + \frac{1-\rho}{B} \sigma^2$$

Boosting · 가법 모형 (additive model)

$$F_m(x) = F_{m-1}(x) + \nu h_m(x)$$

Gradient Boosting · 음의 기울기 적합

$$h_m \approx - \frac{\partial L(y, F(x))}{\partial F(x)} \bigg|_{F=F_{m-1}}$$

모형 간 상관 ρ 가 낮을수록 배깅의 분산 감소 효과가 커진다 — RF가 특성을 무작위 추출하는 이유

부스팅은 손실함수의 기울기를 따라 함수 공간에서 경사하강을 합니다


강화학습은 가치 기반에서 정책 기반으로 발전했습니다

Reinforcement Learning (Learn by interacting with environment) — 원본 하단 우측 구획

Q-LEARNING → DQN → PPO

표에서 신경망으로

- Q-Learning — Q값 표 갱신
- DQN — 신경망 Q 근사
- PPO — 정책 직접 최적화



정답 대신 보상만 주어지므로 탐색과 활용의 균형이 핵심입니다

세 알고리즘은 벨만 방정식을 서로 다르게 활용합니다

할인율·학습률·목표 네트워크·신구 정책 확률비가 네 식의 핵심 요소다

벨만 최적 방정식 (Bellman optimality)

$$Q^*(s, a) = \mathbb{E} \left[r + \gamma \max_{a'} Q^*(s', a') \right]$$

Q-Learning · TD 갱신

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

DQN · 목표 네트워크 기반 손실

$$\mathcal{L}(\theta) = \left(r + \gamma \max_{a'} Q_{\theta^-}(s', a') - Q_{\theta}(s, a) \right)^2$$

PPO · 클리핑으로 정책 변화 제한

$$L^{\text{CLIP}} = \mathbb{E}_t \left[\min \left(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$$

PPO는 한 번에 정책이 크게 바뀌지 않도록 막아 학습을 안정시킵니다

알고리즘 선택은 데이터와 목적을 묻는 데서 시작합니다

원본의 결론 — 모든 알고리즘을 외우기보다 언제·왜 쓰는지를 이해한다

먼저 물을 질문

가족

출발점 알고리즘

정답 y 가 연속값인가

지도 · 회귀

Linear·Ridge → GBM

정답 y 가 범주인가

지도 · 분류

Logistic → XGBoost·LightGBM

정답 없이 묶고 싶은가

비지도 · 군집화

K-Means → DBSCAN·GMM

특성이 너무 많은가

비지도 · 차원축소

PCA → UMAP·Autoencoder

행동을 순차로 결정하는가

강화학습

Q-Learning → DQN·PPO

단순한 기준 모형부터 시작해 성능을 비교하며 복잡도를 올립니다

학습 신호가 가족을 정하고,
가족이 목표함수를 정하며,
목표함수가 알고리즘을 정합니다.

기초부터, 실제 데이터로,
성능을 비교하며 확장한다

※ 그림 출처: Pooja Pawar, "Machine Learning Algorithm Family Tree" 인포그래픽(원본 이미지 발췌)